كل ما تحتاجه هو الانتباه

شرح مبسط لورقة المحولات التي أحدثت ثورة في الذكاء الاصطناعي

All You Need Is Attention

د. فضل محمد الأكوع

Dr. Fadhl Mohammed Alakwaa

2026

English · عربي

كل ما تحتاجه هو الانتباه

All You Need Is Attention

شرح مبسط لورقة المحولات التي أحدثت ثورة في الذكاء الاصطناعي

د. فضل محمد الأكوع

Dr. Fadhl Mohammed Alakwaa

First Edition · 2026 — الطبعة الأولى

جميع الحقوق محفوظة للمؤلف

بسم الله الرحمن الرحيم

إهداء

إلى كل طالب علم عربي يقرأ الأوراق البحثية بعيون متسائلة
وإلى من يؤمن أن فهم الذكاء الاصطناعي ليس حكرا على
الغرب وإلى كل من قال يوما: لا أفهم هذه الورقة هذا الكتاب
كتب من أجلك.

تنبيه

هذا الكتاب أُنتج بمساعدة نموذج Claude Opus 4.7 من شركة Anthropic، تحت إشراف وتوجيه المؤلف. التوجيه الفكري واختيار الموضوع والمراجعة والمسؤولية النهائية للمؤلف الدكتور فضل محمد الأكوع. الكتاب لأغراض ثقيفية وإثرائية، ولا يُغني عن استشارة المتخصصين في الموضوعات القانونية والطبية والمالية والشرعية.

Notice

This book was produced with the assistance of Anthropic's Claude Opus 4.7 model, under the author's direction and supervision. Intellectual direction, topic selection, review, and final responsibility rest with the author, Dr. Fadhl Mohammed Alakwaa. The book is for educational purposes and does not substitute for consultation with specialists in legal, medical, financial, or religious matters.

المحتويات

الفصل الأول: البداية — ما هي هذه الورقة البحثية؟	1
الفصل الثاني: قبل المحولات — مشاكل الترجمة الآلية	2
الفصل الثالث: الانتباه — الفكرة التي غيّرت كل شيء	3
الفصل الرابع: كيف يعمل الانتباه؟ — المفاتيح والاستعلامات والقيم	4
الفصل الخامس: الانتباه متعدّد الرؤوس — عيونٌ كثيرة وفهمٌ واحد	5
الفصل السادس: الترميز الموضعي — كيف يعرف النموذج الترتيب؟	6
الفصل السابع: المُشفِّر والمُفكِّك — قلب المحوّل	7
الفصل الثامن: الشبكة التغذوية الأمامية والتطبيع	8
الفصل التاسع: التدريب — كيف تعلّم النموذج؟	9
الفصل العاشر: ما الذي جعل هذه الورقة ثوريّة؟	10

الفصل الحادي عشر: من المحوّل إلى ChatGPT — الخطّ الزمني 11

الفصل الثاني عشر: الخاتمة — الانتباه وما بعده 12

الفصل الثالث عشر: المراجع وقراءاتٌ للاستزادة 13

الفصل الأول: البداية — ما هي هذه الورقة البحثية؟

﴿وَعَلَّمَكَ مَا لَمْ تَكُنْ تَعْلَمُ وَكَانَ فَضْلُ اللَّهِ عَلَيْكَ عَظِيمًا﴾

— سورة النساء: ١١٣

في صيف عام ٢٠١٧، نشر فريقٌ صغير من الباحثين في شركة جوجل ورقةً بحثيةً عنوانها مثيرٌ للفضول: «الانتباه هو كل ما تحتاجه» (Attention Is All You Need). كانت الورقة قصيرةً نسبيًا — لا تتجاوز خمس عشرة صفحة — ولم يكن مؤلفوها الثمانية من المشاهير في ذلك الوقت. لكنّ ما حملته تلك الصفحات من فكرة بسيطة وعميقة في آنٍ واحد، أحدث ثورةً في علم الذكاء الاصطناعي لم يشهد لها العالم مثيلًا منذ ولادة الشبكات العصبية الحديثة.

أتذكر جيدًا اليوم الذي قرأتُ فيه هذه الورقة لأول مرة. كنتُ حينها باحثًا في علم الأحياء الحاسوبي، أعمل على تحليل التعبير الجيني في الخلايا السرطانية. لم أكن أتوقع أن ورقةً عن الترجمة الآلية ستغيّر طريقة عملي ونظرتي إلى البيانات البيولوجية. لكنّ ذلك ما حدث بالفعل، ليس لي وحدي، بل لآلاف الباحثين حول العالم في مجالات متباعدة كالطب والفيزياء والكيمياء واللسانيات.

من هم مؤلفو هذه الورقة؟

كتب الورقةَ ثمانيةُ باحثين: أشيش فاسواني، ونوام شازير، ونيكي بارمار، وياكوب أوسكوريت، وليون جونز، وإيدان غوميز، ولوكاس كايزر، وإيليا بولوسوخين. كان معظمهم يعملون في جوجل برين (Google Brain) وجوجل ريسيرش (Google Research). والأمر الذي يلفت الانتباه — وهو درس مهم لكل طالب علم — أنّ كثيرًا منهم لم يكن يحمل لقب «الأستاذ» أو «المدير»، بل كانوا باحثين شبابًا قرروا أن يجرّبوا فكرةً مختلفة. هذا يذكّرنا أنّ الإسهام في العلم لا يحتاج بالضرورة إلى منصبٍ كبير، بل إلى عقلٍ متسائل وجرأةٍ على تحدّي ما هو سائد.

ما الذي جعل الورقة استثنائية؟

قبل عام ٢٠١٧، كانت معالجة اللغة الطبيعية تعتمد على ما يُسمى بالشبكات العصبية المتكررة (Recurrent Neural Networks)، وعلى وجه الخصوص الشبكات ذات الذاكرة طويلة المدى (LSTM). كانت هذه الشبكات تعمل بطريقةٍ تشبه قراءتك لكتابٍ كلمةً بكلمة من البداية إلى النهاية، تحمل في ذاكرتك ما قرأتَه سابقًا لتفهم ما يأتي. لكنّ المشكلة كانت أنّ هذه الذاكرة محدودة، وأنّ الحساب يتمّ بشكلٍ تتابعي — كلمة بعد أخرى — مما يجعل تدريب النماذج بطيئًا للغاية ومكلفًا.

جاءت ورقة «الانتباه هو كل ما تحتاجه» لتقول شيئًا جريئًا: تخلَّوا عن التتابع. تخلَّوا عن الذاكرة المتسلسلة. استبدلوها بآليةٍ واحدة فقط، تُسمى «الانتباه الذاتي» (Self-Attention)، تستطيع أن تنظر إلى كلّ كلمات الجملة في الوقت ذاته، وتقرّر بنفسها ما هي الكلمات المهمة لفهم كل كلمة أخرى. هذه الفكرة البسيطة فتحت الباب أمام نماذج أسرع، وأكثر دقة، وأكثر قابليةً للتوسّع، من أيّ شيء سبقها.

كيف ولدت ChatGPT و BERT و Claude من هذه الورقة؟

كل نموذج لغوي كبير تسمع عنه اليوم — ChatGPT من OpenAI، وClaude من Anthropic، وGemini من جوجل، وLlama من Meta، وغيرها — هو في جوهره تطويرٌ مباشر للهندسة المعمارية التي اقترحتها هذه الورقة. حين تكتب سؤالًا في ChatGPT، فإنّ ما يحدث في الخلفية هو مليارات العمليات الحسابية التي تستند إلى آلية الانتباه المُقترحة عام ٢٠١٧.

دعني أوضّح الفكرة بتشبيهٍ بسيط: تخيّل أنّ ورقة فاسواني وزملائه كانت بمثابة اكتشاف العجلة. قبل العجلة، كان البشر يحملون الأشياء على ظهورهم. بعد العجلة، صنعوا العربات، ثم السيارات، ثم القطارات، ثم الطائرات. الانتباه هو «العجلة» التي بُنيت عليها كل هذه الأنظمة.

في عام ٢٠١٨، أصدرت جوجل نموذج BERT، وهو يستخدم «المُشفِّر» فقط من المحوّل الأصلي. غيّر BERT مجال البحث في النصوص، وأصبح أساسًا لمحرك بحث جوجل نفسه. في العام ذاته، أطلقت OpenAI نموذج GPT-1، الذي يستخدم «المُفكِّك» فقط، وفتح الطريق أمام النماذج التوليدية. ثم جاء GPT-2 و GPT-3 و GPT-4، وكل منها أكبر وأقوى من سابقه، لكنّ المعمار الأساسي بقي هو ذاته: محوّل (Transformer).

لحظة شخصية: حين قرأتُ الورقة لأول مرة

في عملي بجامعة ميشيغان، أتعامل مع بياناتٍ بيولوجية معقدة جدًا — تعابير جينية لمئات الآلاف من الخلايا، وتسلسلات بروتينية، وصور أنسجة مرضية. حين قرأتُ ورقة المحوّلات لأول مرة، لم أكن أرى علاقةً مباشرة بينها وبين عملي. لكنّ بعد عامين، خرجت ورقة AlphaFold 2 من شركة DeepMind، وكانت تستخدم آلية الانتباه ذاتها للتنبؤ ببنية البروتينات بدقّة مذهلة. عُدتُ حينها إلى ورقة ٢٠١٧، وقرأتها مرةً ثانية بعينٍ جديدة. أدركتُ أنّ ما اعتقدتُه «أداةً للترجمة» هو في الحقيقة طريقةٌ عامةٌ لفهم العلاقات بين العناصر، أيًا كانت هذه العناصر — كلماتٍ في جملة، أو أحماضًا أمينية في بروتين، أو خلايا في نسيج.

هذه اللحظة علّمتني درسًا مهمًا: الأفكار العلمية الكبرى نادرًا ما تبقى حبيسة المجال الذي وُلدت فيه. حين يكتشف عالمٌ في مجالٍ ما طريقةً جديدة للتفكير، فإنّها تنتشر — كأمواجٍ في بحيرة — لتلامس مجالاتٍ أخرى لم يتخيّلها أحد. وقد قال

الله سبحانه وتعالى: ﴿وَعَلَّمَكَ مَا لَمْ تَكُنْ تَعْلَمُ﴾. من فضل الله علينا أن جعل العلم مفتاحًا يفتح أبوابًا كثيرة، حتى الأبواب التي لم نطرقها بعد.

ما الذي ستجده في هذا الكتاب؟

سأصطحبك في هذا الكتاب رحلةً عبر أهم ورقةٍ علميةٍ في تاريخ الذكاء الاصطناعي الحديث. لكنّني لن أُغرقك في الرياضيات، ولن أفترض أنّك مهندس برمجيات. سأشرح الأفكار بلغةٍ بسيطة، وبتشبيهاتٍ من الحياة اليومية — من المكتبات والأوركسترات واللجان الاستشارية. وفي كل فصل، سأبدأ بآيةٍ من القرآن الكريم تذكّرنا بمكانة العلم وفضل التدبّر في الإسلام.

في الفصل القادم، سنرجع إلى الوراء قليلًا لنفهم ما الذي كان موجودًا قبل المحوّلات، ولماذا احتاج العالم إلى هذه القفزة الكبرى. سنرى كيف كانت الحواسيب تتعامل مع اللغة، وما هي المشاكل التي عانى منها الباحثون لسنواتٍ طويلة، وكيف فتحت ورقة فاسواني بابًا جديدًا. ثم في الفصل الثالث، سنغوص في قلب الفكرة: ما هو «الانتباه» وكيف غيّر كل شيء؟

أهلًا بك في هذه الرحلة. وأسأل الله أن ينفعنا بما علّمنا، ويعلّمنا ما ينفعنا، وأن يجعل هذا العمل خالصًا لوجهه الكريم.

الفصل الثاني: قبل المحولات — مشاكل الترجمة الآلية

﴿وَمَا أُوتِيتُم مِّنَ الْعِلْمِ إِلَّا قَلِيلًا﴾

— سورة الإسراء: ٨٥

قبل أن نفهم لماذا كانت ورقة المحوّلات ثوريةً إلى هذا الحد، علينا أن نعرف أوّلًا: ما الذي كان موجودًا قبلها؟ ما المشاكل التي عانى منها الباحثون لسنواتٍ طويلة؟ وكيف كانت الحواسيب تتعامل مع اللغة قبل عام ٢٠١٧؟

تخيّل أنّك دخلتَ إلى مكتبةٍ قديمة، ووجدتَ مكتبيًا يقرأ كتابًا حرفًا حرفًا، يحفظ في ذاكرته كل حرفٍ قرأه، فإذا وصل إلى الكلمة العاشرة نسي الحرف الأول، وإذا وصل إلى الجملة العاشرة نسي الكلمة الأولى. هكذا تقريبًا كانت تعمل معظم نماذج معالجة اللغة قبل المحوّلات. كانت تقرأ الكلمات واحدةً بعد الأخرى، تحمل في «ذاكرتها» سياق ما قرأت، لكنّ هذه الذاكرة كانت تتسرّب وتتآكل مع كل خطوة جديدة.

الشبكات العصبية المتكررة (RNN): الجيل الأول

في أواخر التسعينيات وبدايات الألفية الثالثة، كانت الشبكات العصبية المتكررة (Recurrent Neural Networks) هي الأداة الأساسية في معالجة النصوص. الفكرة كانت بسيطة وأنيقة: عند معالجة كلمةٍ ما، يأخذ النموذج معلومتين: الكلمة الحالية، و«حالة خفية» (hidden state) تلخّص كل ما سبق. ثم يُحدِّث هذه الحالة الخفية، ويُمرّرها إلى الخطوة التالية. وهكذا، خطوةً بخطوة، تنتقل المعلومات عبر الجملة.

التشبيه الأقرب لهذا أنّك ترسل خطابًا في سلسلةٍ من البريد، حيث كل ساعي بريد يقرأ الخطاب، يضيف ملاحظةً، ويُمرّره للساعي التالي. الفكرة جميلة من الناحية النظرية، لكنّ المشكلة تظهر حين تطول السلسلة. كلما زاد عدد سعاة البريد، تشوّهت الملاحظات الأصلية، وضاعت تفاصيل مهمة. هذه هي مشكلة «اضمحلال التدرّج» (Vanishing Gradient) التي عانت منها الشبكات المتكررة لسنواتٍ طويلة.

الحلّ المؤقت: شبكات LSTM

في عام ١٩٩٧، قبل أكثر من عقدين من ورقة المحوّلات، اقترح العالمان زيب هوكرايتر ويورغن شميدهوبر بنيةً جديدة تُسمى «الذاكرة طويلة-قصيرة

المدى» (Long Short-Term Memory) أو اختصارًا LSTM. كانت LSTM محاولةً ذكيةً لحلّ مشكلة الذاكرة المتسرّبة في الشبكات المتكررة.

أتخيّل LSTM على هيئة مكتبٍ منظّم بثلاث خزائن: خزانة «النسيان» التي تقرّر ما الذي يمكن التخلّص منه من الذاكرة القديمة، وخزانة «الإدخال» التي تحدّد ما يستحقّ أن يُحفظ من الجديد، وخزانة «الإخراج» التي تختار ما الذي سيُمرَّر إلى الخطوة التالية. هذا التنظيم سمح للنموذج بالاحتفاظ بمعلوماتٍ مهمة لمسافاتٍ أطول، وأن «ينسى» المعلومات غير الضرورية.

كانت LSTM إنجازًا كبيرًا، وهيمنت على مجال معالجة اللغة لسنواتٍ. استُخدمت في الترجمة الآلية، وفي التعرّف على الكلام، وفي تلخيص النصوص. لكنّ كل هذا التطوّر لم يحلّ المشكلة الجوهرية: كانت LSTM تعمل تتابعيًا، وكانت بطيئةً في التدريب، وكانت تعاني حين تطول الجمل أكثر من اللازم.

مشكلة عنق الزجاجة في الترجمة

كانت أكبر مشكلة في هذه النماذج هي ما يُعرف بـ«عنق الزجاجة» (Bottleneck Problem). دعني أوضّح هذا بمثالٍ من واقع الترجمة.

لنفترض أنّك تريد ترجمة الجملة الإنجليزية: "*The cat that the dog chased ran away*" إلى العربية: «هرب القط الذي طارده الكلب». الفكرة العامة في النماذج القديمة كانت كالتالي: يقرأ المُشفِّر (encoder) الجملة الإنجليزية كاملةً، ويضغطها

في «شعاع» (vector) واحد من الأرقام — مثل أن تختصر كتابًا كاملًا في فقرةٍ واحدة. ثم يأخذ المُفكِّك (decoder) هذا الشعاع، ويبدأ في توليد الترجمة العربية كلمةً بكلمة.

المشكلة واضحة: كل المعلومات في الجملة الأصلية يجب أن تمرّ عبر هذا الشعاع الواحد، الذي يصبح «عنق زجاجة» يختنق حين تكون الجملة طويلة. تخيّل أنّك تحاول أن تنقل محتوى موسوعةٍ كاملة عبر أنبوبٍ رفيع — ستفقد الكثير في الطريق.

محاولة الحل: انتباه باهداناو

في عام ٢٠١٤، قدّم الباحث ديميتري باهداناو وزملاؤه فكرةً جديدة: لماذا نُجبر المُفكِّك على الاعتماد على شعاعٍ واحد؟ لماذا لا نسمح له، عند توليد كل كلمة، أن يعود إلى الجملة الأصلية، ويُلقي نظرةً سريعةً عليها، ويختار الأجزاء الأكثر صلةً بما يريد توليده؟

هذه الفكرة كانت أوّل ظهورٍ لكلمة «انتباه» (Attention) في معالجة اللغة. كان النموذج لا يزال يستخدم LSTM في الأساس، لكنّه أضاف طبقةً علوية تسمح للمُفكِّك بأن «يلتفت» إلى أجزاءٍ مختلفة من الجملة الأصلية في كل خطوة. كانت النتائج رائعة، وتحسّنت جودة الترجمة بشكلٍ ملحوظ.

لكنّ المشكلة الأساسية بقيت قائمة: كان الحساب لا يزال تتابعيًا. لم يكن من الممكن معالجة عدّة كلماتٍ في الوقت نفسه. كانت الشبكات العصبية المتكررة بحاجةٍ إلى أن تنهي معالجة الكلمة الأولى قبل أن تبدأ بالثانية. وفي عصرٍ تتطوّر فيه قوة الحوسبة المتوازية بسرعةٍ مذهلة، كان هذا قيدًا مكلفًا.

التشبيه الأقرب: قراءة كتابٍ بشمعة

دعني أقدّم لك تشبيهًا يلخّص كلّ ما سبق: تخيّل أنّك تقرأ كتابًا في غرفةٍ مظلمة، وفي يدك شمعةٌ صغيرة تضيء حرفًا واحدًا فقط في كل لحظة. يجب عليك أن تتذكّر كل حرفٍ قرأتَه لتفهم الكلمة، وكل كلمةٍ لتفهم الجملة، وكل جملةٍ لتفهم الفقرة. مع ضعف ضوء الشمعة، يصعب عليك الالتفات إلى ما قرأتَه قبل صفحاتٍ عديدة. وحين تصل إلى نهاية الفصل، قد تكون قد نسيتَ ما قاله المؤلف في البداية.

هذا تقريبًا ما كانت تواجهه الشبكات العصبية المتكررة. كانت كل خطوةٍ تعتمد على ما سبق، لكنّ ذاكرة ما سبق كانت تخبو شيئًا فشيئًا.

ما الذي كان يحلم به الباحثون؟

في السنوات التي سبقت ٢٠١٧، كان هناك شعورٌ عام بأنّ معالجة اللغة وصلت إلى حدّ ما إلى سقفٍ تقني. كانت LSTM تتحسّن بنسبٍ صغيرة كل عام، لكنّ القفزات الكبرى توقّفت. كان الباحثون يحلمون بثلاثة أشياء:

أوّلًا، **التوازي (Parallelization)**: قدرة معالجة كل كلمات الجملة في الوقت نفسه، بدلًا من واحدةٍ تلو الأخرى، لتسريع التدريب بشكلٍ هائل.

ثانيًا، **العلاقات بعيدة المدى (Long-Range Dependencies)**: قدرة الربط بين كلمتين تفصل بينهما عشرات أو مئات الكلمات، دون أن تضيع المعلومة في الطريق.

ثالثًا، **البساطة (Simplicity)**: التخلّص من البنى المعقّدة المتراكمة (LSTM ضمن انتباه باهداناو ضمن شبكات تلافيفية...) واستبدالها بآليةٍ واحدةٍ أنيقة.

كانت هذه الأحلام تبدو متناقضة. كيف تجمع بين البساطة والقدرة العالية؟ كيف تتخلّص من التتابع وتحافظ على فهم اللغة؟ بدا أنّ هناك مقايضةً (trade-off) بين هذه الأهداف.

الفجر القادم

في عام ٢٠١٧، جاءت ورقة فاسواني وزملائه لتقول: لا، ليست هناك مقايضة. يمكنكم تحقيق كل هذه الأهداف في آنٍ واحد. كل ما تحتاجونه هو الانتباه. تخلَّوا عن LSTM. تخلَّوا عن الشبكات المتكررة. تخلَّوا عن التتابع. ابنوا نموذجكم بالكامل من طبقاتٍ من الانتباه، وستحصلون على شيءٍ أسرع وأذكى وأبسط.

كان هذا تحدّيًا للحكمة السائدة في المجال. كثيرون شكّكوا في الفكرة في البداية. كيف يمكن لنموذجٍ يتجاهل الترتيب أن يفهم اللغة، التي يعتمد معناها على الترتيب؟ سنرى في الفصول القادمة كيف أجاب فاسواني وزملاؤه على هذا السؤال بأناقةٍ بالغة.

والقرآن الكريم يذكّرنا: ﴿وَمَا أُوتِيتُم مِّنَ الْعِلْمِ إِلَّا قَلِيلًا﴾. كل ما نعتقد أنّنا نعرفه هو في الحقيقة قطرةٌ في بحرٍ واسع. كل اكتشافٍ جديد يفتح أبوابًا أكثر مما يُغلقها. وفي القصة التي نحن بصددها، فتحت ورقةٌ واحدة بابًا لعالمٍ جديد كان يحلم به الباحثون لعقود.

في الفصل القادم، سنغوص في الفكرة الجوهرية: ما هو الانتباه؟ كيف يعمل في عقل الإنسان، وكيف نقله المهندسون إلى الآلة؟

الفصل الثالث: الانتباه — الفكرة التي غيّرت كل شيء

﴿إِنَّ فِي ذَٰلِكَ لَذِكْرَىٰ لِمَن كَانَ لَهُ قَلْبٌ أَوْ أَلْقَى السَّمْعَ وَهُوَ شَهِيدٌ﴾

— سورة ق: ٣٧

ما هو «الانتباه»؟

قبل أن نتحدّث عن الانتباه في الذكاء الاصطناعي، دعنا نتأمّل لحظةً في الانتباه كما نعيشه نحن البشر. حين تجلس في مقهى مزدحم وتستمع إلى صديقك، فإنّ أذنيك تتلقّيان عشرات الأصوات في الوقت نفسه: حديث الجالسين على الطاولة المجاورة، وصوت ماكينة القهوة، وموسيقى خلفية، وضحكات بعيدة. لكنّ عقلك يختار صوت صديقك من بين كل هذه الأصوات، ويُعطيه الأولوية القصوى. هذا هو الانتباه.

أو حين تقرأ صفحةً من كتاب، فإنّ عينك تلتقط آلاف الحروف، لكنّ ذهنك يركّز على كلماتٍ بعينها — تلك التي تحمل المعنى الجوهري. الكلمات الأخرى موجودة، لكنّك «تُمرّر» عليها بسرعة. هذا أيضًا انتباه.

الانتباه إذًا هو القدرة على تمييز ما هو مهم من بين ضوضاء كثيرة. هو ترتيب الأولويات الإدراكية. وما اكتشفه فاسواني وزملاؤه هو أنّ هذه القدرة، بالضبط، هي ما تحتاجه الآلة لفهم اللغة.

مثال يكشف جوهر المسألة

دعني أقدّم لك مثالًا شهيرًا في الأدبيات العلمية، لأنّه يكشف بوضوحٍ تامّ ما تفعله آلية الانتباه.

تأمّل هذه الجملة الإنجليزية: "*The animal didn't cross the street because it was too tired.*" (لم يعبر الحيوان الشارع لأنّه كان متعبًا جدًا).

السؤال الآن: إلى ماذا يشير الضمير "*it*"؟ هل يشير إلى الحيوان (animal) أم إلى الشارع (street)؟ بالنسبة لك، كقارئ بشري، الإجابة بديهية: يشير إلى الحيوان، لأنّ الشارع لا يتعب. لكنّ كيف عرفتَ ذلك؟

عقلك «انتبه» إلى كلمة «متعب» (tired)، وربطها بالكلمات الأخرى في الجملة، وأدرك أنّ هذه الصفة تنطبق على الحيوانات لا على الشوارع. أنتَ ربطتَ بين كلمتين متباعدتين في الجملة لتفهم المعنى.

الآن غيّر الجملة قليلًا: "*The animal didn't cross the street because it was too wide.*" (لم يعبر الحيوان الشارع لأنّه كان واسعًا جدًا).

هنا يشير "*it*" إلى الشارع، لأنّ الشوارع هي ما يتّصف بالاتّساع. مرةً أخرى، عقلك انتبه إلى كلمةٍ واحدة (واسع) وأعاد ترتيب فهمه للجملة كاملة بناءً عليها.

هذا هو السحر الذي تحاول آلية الانتباه محاكاته في الآلة. النموذج، عند معالجة كلمة "*it*"، يحتاج أن «يلتفت» إلى الكلمات الأخرى في الجملة، ويُقرّر أيّها الأكثر صلةً بفهمها. وحين تكون الكلمة الأكثر صلة هي «متعب»، فإنّ النموذج يربط "*it*" بـ«الحيوان». وحين تكون «واسع»، يربطها بـ«الشارع».

لماذا فشلت النماذج القديمة في هذا؟

في الشبكات العصبية المتكررة (RNN/LSTM)، كانت المعلومات تتدفّق من اليسار إلى اليمين، خطوةً بخطوة. حين يصل النموذج إلى كلمة "*it*"، فإنّه يحمل معه «حالةً خفية» تلخّص كل ما سبق. لكنّ هذه الحالة الخفية لا تستطيع أن «تعود» إلى كلمةٍ بعينها. هي مجرّد ملخّص ضبابي.

أمّا مع الانتباه، فالأمر مختلف تمامًا. النموذج يستطيع أن ينظر إلى كلّ كلمةٍ في الجملة بشكلٍ مباشر، ويُقرّر بنفسه: «الكلمة tired أهمّ بكثير من الكلمات الأخرى لفهم it». هذا ليس ملخّصًا. هذا اتّصالٌ مباشر بين كلمتين، حتى لو كانتا متباعدتين.

التشبيه الأقرب: قاعة الاجتماعات

أحبّ أن أُشبّه آلية الانتباه بقاعة اجتماعات مهنية. تخيّل أنّ هناك عشرة موظفين جالسين حول طاولة مستديرة، وكلّ واحدٍ منهم خبير في تخصّصٍ مختلف: المالية، والتسويق، والهندسة، والقانون، والموارد البشرية، وغيرها. حين يطرح المدير سؤالًا، لا يريد سماع رأي الجميع بالتساوي. يريد أن يوجّه انتباهه إلى الخبير الأنسب للسؤال.

إذا كان السؤال عن الأرباح، يلتفت إلى مدير المالية. إذا كان عن حملة إعلانية، يلتفت إلى مدير التسويق. وإذا كان عن دعوى قضائية، يلتفت إلى المستشار القانوني. هو يستمع للجميع نظريًا، لكنّه يُعطي «وزنًا» أكبر لرأي الخبير الأكثر صلة.

هذا بالضبط ما تفعله آلية الانتباه. عند معالجة كلمةٍ معيّنة، يُحسب «وزنٌ» لكل كلمةٍ أخرى في الجملة. الكلمات الأكثر صلةً تحصل على أوزانٍ عالية، والكلمات الأقل صلةً تحصل على أوزانٍ منخفضة. ثم يُجمَع هذا كلّه ليُكوّن «فهمًا» جديدًا للكلمة الأصلية.

الانتباه الذاتي: حين تنظر الجملة إلى نفسها

ما اقترحته ورقة فاسواني تحديدًا هو ما يُسمى «الانتباه الذاتي» (Self-Attention). الكلمة المفتاحية هنا هي «الذاتي». في النماذج السابقة، كان الانتباه

يحدث بين جملتين مختلفتين — الجملة الأصلية والجملة المُترجَمة. أمّا في الانتباه الذاتي، فإنّ الجملة تنظر إلى نفسها.

كل كلمةٍ في الجملة تنظر إلى كل الكلمات الأخرى في الجملة ذاتها (بما فيها نفسها)، وتقرّر أيّها مهمّ لفهم معناها. هذا يخلق شبكةً ثرية من العلاقات داخل الجملة. الفعل يفهم فاعله ومفعوله. الصفة تفهم الموصوف. الضمير يفهم مرجعه.

تخيّل قبيلةً من بدوٍ يسافرون في الصحراء، وكل فردٍ منهم يلتفت إلى الآخرين باستمرار، يتحقّق من مكانهم، ويعدّل خطاه ليبقى منسجمًا مع الجماعة. لو سار كلّ منهم بمعزلٍ عن الآخرين، لتفرّقت القافلة. الانتباه الذاتي هو ما يجعل الكلمات «جماعةً متماسكة» تُكوّن معنىً متكاملًا.

ميزات الانتباه التي قلبت الموازين

دعني أعدّ لك المزايا التي جعلت الانتباه يطيح بكل النماذج السابقة:

أوّلًا، **التوازي المطلق**: يمكن حساب الانتباه لكل الكلمات في وقتٍ واحد. لا حاجة للانتظار. هذا يعني أنّ تدريب النموذج يصبح أسرع بعشرات الأضعاف، خصوصًا على بطاقات الرسوميات الحديثة (GPUs) التي صُمّمت أصلًا للعمليات المتوازية.

ثانيًا، **المسافات الطويلة**: لا يهمّ أن تكون كلمتان متباعدتين في الجملة. الانتباه يصلهما مباشرةً، دون أن تتآكل المعلومة في الطريق. هذا حلّ مشكلة عُمرها عقود.

ثالثًا، **القابلية للتفسير**: يمكنك أن «ترى» إلى ماذا ينتبه النموذج. باحثون كثيرون رسموا «خرائط الانتباه» (attention maps) لاكتشاف ما يفهمه النموذج فعلًا، وهذا فتح بابًا جديدًا في فهم الشبكات العصبية، التي كانت تُسمى تاريخيًا «صناديق سوداء».

رابعًا، **العمومية**: آلية الانتباه ليست خاصةً باللغة. يمكن تطبيقها على أيّ مجموعةٍ من العناصر التي تتفاعل مع بعضها. وهذا ما جعلها تنتشر إلى مجالاتٍ أخرى لاحقًا — كالرؤية الحاسوبية، وعلوم الجينوم، وحتى الموسيقى.

وقفة قرآنية: ﴿أَوْ أَلْقَى السَّمْعَ وَهُوَ شَهِيدٌ﴾

في الآية الكريمة التي افتتحنا بها هذا الفصل، يلفت القرآن انتباهنا إلى شرطين أساسيّين للذكر والتعلّم: «قلبٌ» يفقه، أو «إلقاء سمع» مع «شهود» — أي حضورٌ ذهنيّ كامل. وهذا في جوهره هو الانتباه. ليس مجرّد سماع، بل سماعٌ بحضور. ليس مجرّد رؤية، بل رؤيةٌ بفهم.

لطالما عرف علماء المسلمين أنّ التعلّم لا يكون بمجرّد ترديد الكلام، بل بـ«حضور القلب». كان ابن جماعة يقول: «من علامة العلم النافع أن يكون قلبك حاضرًا

حين تسمع». وهذا تمامًا ما يحاول الذكاء الاصطناعي اليوم أن يحاكيه: نموذجٌ «حاضر» مع كل كلمة، يربطها بسياقها، ويفهمها في علاقتها بأخواتها.

لحظة شخصية من المختبر

في مختبري بجامعة ميشيغان، أتعامل مع آلاف الجينات في كل خلية. كل جين له «تعبيره» الخاص، لكنّ الجينات لا تعمل بمعزلٍ عن بعضها. إنّها تتفاعل في شبكاتٍ معقّدة. حين فكّرتُ في تطبيق آلية الانتباه على هذه البيانات، أدركتُ أنّ كل جينٍ يمكن أن يكون كـ«كلمة»، وأنّ النموذج يستطيع أن «ينتبه» إلى الجينات الأخرى الأكثر صلةً به في كل لحظة. النتيجة كانت مذهلة: نماذج أعمق، تكتشف علاقاتٍ بيولوجية لم نكن نراها بالأساليب التقليدية.

هذه قوّة الفكرة الجوهرية. حين تكون الفكرة عميقة، فإنّها تتجاوز السياق الذي وُلدت فيه.

الخطوة التالية

في الفصل القادم، سننتقل من «ما هو الانتباه» إلى «كيف يعمل الانتباه». سنفكّك الآلية الرياضية إلى مكوّناتها الثلاثة الجوهرية: الاستعلام (Query)، والمفتاح (Key)، والقيمة (Value). وسنفعل ذلك بتشبيه المكتبة الذي يجعل

الفكرة سهلة الفهم لأيّ قارئ. إذا فهمتَ الفصل القادم، فأنتَ قد فهمتَ ٨٠٪ من المحوّلات.

والله سبحانه وتعالى أعلم.

الفصل الرابع: كيف يعمل الانتباه؟ — المفاتيح والاستعلامات والقيم

﴿أَفَلَا يَتَدَبَّرُونَ الْقُرْآنَ أَمْ عَلَىٰ قُلُوبٍ أَقْفَالُهَا﴾

— سورة محمد: ٢٤

في الفصل السابق، عرفنا ما هو الانتباه ولماذا هو مهم. الآن حان وقت أن نتعلّم كيف يعمل، لكن دون أن نغرق في الرياضيات. وعدتُك أنّك إذا فهمتَ هذا الفصل، فستكون قد فهمتَ ٨٠٪ من المحوّلات. سأفي بوعدي.

سأستخدم تشبيهًا واحدًا متماسكًا يقودنا خطوةً بخطوة: مكتبة كبيرة. تخيّل مكتبةً ضخمةً تضمّ ملايين الكتب، ولها فهرسٌ منظّم، ومكتبيٌّ ماهر. هذه المكتبة هي قلب آلية الانتباه.

ثلاثة عناصر: الاستعلام، المفتاح، القيمة

في كل عملية انتباه، هناك ثلاثة عناصر جوهرية، تحمل أسماءً أنيقة من عالم قواعد البيانات:

الاستعلام (Query): هو السؤال الذي تحمله في عقلك. مثلًا: «أريد كتابًا عن تاريخ الأندلس».

المفتاح (Key): هو الوسم أو العنوان الذي تحمله الكتب على رفوفها. مثلًا: «التاريخ الإسلامي»، «الأدب العربي»، «العلوم الطبية».

القيمة (Value): هي محتوى الكتاب نفسه — الذي ستحصل عليه إذا قرّرتَ أنّ هذا الكتاب هو الذي تريده.

الآن لنرى كيف تعمل العملية كاملةً في المكتبة:

1. تدخل إلى المكتبة وفي ذهنك استعلامك (Query): «أريد كتابًا عن تاريخ الأندلس».

2. تنظر إلى المفاتيح (Keys) المعلّقة على الرفوف: «العلوم»، «الأدب»، «التاريخ»، «الفلسفة»، إلخ.

3. تُقارن استعلامك بكلّ مفتاح، وتُعطي درجةً (score) لكلّ مقارنة. الرفّ المكتوب عليه «التاريخ» يحصل على درجةٍ عالية. الرفّ المكتوب عليه «العلوم الطبية» يحصل على درجةٍ منخفضة.

4. بناءً على هذه الدرجات، تذهب إلى الرفّ الأعلى درجةً، وتأخذ القيمة (Value) — أي محتوى الكتاب.

هذه هي آلية الانتباه باختصار. لكنّ ما تفعله الآلة أعمق قليلًا: بدلًا من أن تختار كتابًا واحدًا فقط، تأخذ «خليطًا مرجّحًا» من كل الكتب، حيث كل كتاب يُساهم بنسبةٍ تتناسب مع درجته. الكتب الأعلى درجةً تساهم أكثر، والكتب الأقل درجةً تساهم أقل، لكنّها كلّها تشارك في النهاية.

مثال تطبيقي على جملة

لنطبّق هذا على الجملة التي رأيناها في الفصل السابق: «لم يعبر الحيوان الشارع لأنّه كان متعبًا».

عند معالجة كلمة «أنّه»، يولّد النموذج لها استعلامًا (Query) يعني تقريبًا: «إلى ماذا أُشير؟ ما الكلمة التي أُمثّلها في هذه الجملة؟».

ثم يأخذ النموذج مفاتيح (Keys) كل الكلمات الأخرى: «لم»، «يعبر»، «الحيوان»، «الشارع»، «لأنّه»، «كان»، «متعبًا». كل كلمةٍ لها مفتاحها الخاص الذي يُلخّص «هويتها» في هذا السياق.

يُقارن النموذج الاستعلام بكل المفاتيح. يجد أنّ مفتاح «الحيوان» يتطابق بشكلٍ كبير مع الاستعلام، لأنّ السياق (وجود كلمة «متعبًا») يدعم هذا التطابق. تحصل كلمة «الحيوان» على درجةٍ عالية. الكلمات الأخرى تحصل على درجاتٍ منخفضة.

ثم يأخذ النموذج قيم (Values) كل الكلمات، ويجمعها بأوزانٍ تتناسب مع الدرجات. النتيجة: «فهمٌ» جديد لكلمة «أنّه»، يحمل في طيّاته معظم المعلومات من «الحيوان»، وقليلًا من الكلمات الأخرى. الآن أصبحت كلمة «أنّه» في عقل النموذج «تحمل بصمة الحيوان».

من أين تأتي هذه الاستعلامات والمفاتيح والقيم؟

هنا يأتي السؤال الذكي: هذه الاستعلامات والمفاتيح والقيم — من أين تأتي؟ هل أكتبها أنا يدويًا؟

الجواب: لا. النموذج يتعلّمها بنفسه أثناء التدريب.

كل كلمةٍ في النموذج تُمثَّل أوّلًا برقمٍ متّجه (vector) من مئات الأرقام. ثم يضرب النموذج هذا المتّجه في ثلاث مصفوفات (matrices) تعلّمها أثناء التدريب: مصفوفة الاستعلام، ومصفوفة المفتاح، ومصفوفة القيمة. هذه المصفوفات هي «المعرفة» التي اكتسبها النموذج من ملايين الجمل التي رآها.

تخيّل أنّ كل كلمة كأنّها قطعةٌ من عجين، والمصفوفات الثلاث كأنّها ثلاثة قوالب مختلفة. حين تمرّر العجين عبر القالب الأوّل، تحصل على شكل «الاستعلام». عبر القالب الثاني، تحصل على شكل «المفتاح». عبر الثالث، شكل «القيمة». كلّها مشتقّةٌ من نفس الكلمة الأصلية، لكنّها تُؤدّي أدوارًا مختلفة في الرقصة.

الضرب النقطي: قياس التشابه

كيف يقيس النموذج التشابه بين استعلامٍ ومفتاح؟ يستخدم عمليةً رياضيةً تُسمى «الضرب النقطي» (Dot Product). لا تخف — لن أشرح الرياضيات. سأشرح الفكرة فقط.

تخيّل أنّ كل استعلامٍ وكل مفتاحٍ هو سهمٌ يُشير في اتّجاهٍ ما في فضاء متعدّد الأبعاد. حين يكون السهمان يُشيران في الاتّجاه ذاته، يكون الضرب النقطي بينهما كبيرًا — أي إنّهما متشابهان جدًا. وحين يُشيران في اتّجاهين متعامدين، يكون الضرب النقطي صفرًا — أي لا صلة بينهما. وحين يُشيران في اتّجاهين متعاكسين، يكون الضرب النقطي سالبًا — أي إنّهما متضادّان.

هذا تمامًا ما يحدث في الانتباه. الكلمات «المتشابهة دلاليًا» في السياق تُولّد استعلاماتٍ ومفاتيح تُشير في اتّجاهاتٍ متقاربة، فينتج ضربٌ نقطيٌّ كبير، ودرجةٌ عالية.

السوفت ماكس: تحويل الدرجات إلى نسب

بعد أن نحصل على درجاتٍ خامّة لكل كلمة، نحتاج إلى تحويلها إلى «أوزان» (weights) قابلة للجمع والمقارنة. نستخدم لهذا دالّةً تُسمى «السوفت ماكس» (Softmax).

التشبيه الأقرب لما تفعله السوفت ماكس هو هذا: تخيّل أنّك تنظّم تصويتًا بين عشرة موظفين. كل واحدٍ يدلي برأيه على مقياس من ١ إلى ١٠٠. الآن تريد أن تُحوّل هذه الأرقام إلى نسبٍ مئوية تُجمّع مع بعضها لتساوي ١٠٠٪. هذا ما تفعله السوفت ماكس: تأخذ الدرجات، تُكبّر الفروق بينها (الكبير يصبح أكبر، الصغير يصبح أصغر)، ثم تُحوّلها إلى نسبٍ تُجمَع لتساوي ١٠٠٪.

النتيجة: مجموعةٌ من الأوزان، كل وزنٍ يقول «هذه الكلمة تستحقّ كذا بالمئة من انتباهي». الكلمات الأكثر صلةً تحصل على أوزانٍ كبيرة (مثلًا ٧٠٪)، والأقلّ صلةً تحصل على أوزانٍ صغيرة (مثلًا ١٪).

المعادلة بالعربي: لا أرقام، فقط معنى

في الورقة الأصلية، تظهر معادلةٌ شهيرة: $\mathbf{Attention(Q, K, V) = softmax(QK^T/\sqrt{d_k})V}$.

دعني أُترجمها لك بكلماتٍ بشرية، دون رياضيات:

«الانتباه يعمل كالتالي: خذ كل استعلام، قارنه بكل مفتاح بالضرب النقطي، اقسم الناتج على رقمٍ ثابت ليبقى الحساب مستقرًّا، طبّق السوفت ماكس لتحصل على نسبٍ، ثم استخدم هذه النسب لخلط القيم خلطًا مرجّحًا. النتيجة هي الفهم الجديد».

هذا كلّه! المعادلة المخيفة بحروفها الإغريقية ليست أكثر من هذه الفكرة البسيطة.

التشبيه النهائي: المخبرون السرّيون

دعني أعطيك تشبيهًا أخيرًا: تخيّل قائدًا يخطّط لمعركة. يحتاج معلوماتٍ من ساحة المعركة. لديه عشرة مخبرين، كل واحدٍ منهم يحمل ثلاث بطاقات: بطاقة هويته (المفتاح)، وبطاقة تخصّصه (الاستعلام)، وبطاقة معلوماته (القيمة).

حين يحتاج القائد معلومةً عن «حالة جناح اليمين»، فإنّه يُقارن «حاجته» (استعلامه) ببطاقات هويّة المخبرين (مفاتيحهم). المخبر المسؤول عن الجناح الأيمن يحمل بطاقةً تتطابق مع الحاجة. يحصل على درجةٍ عالية. ثم يُقدّم القائد كلّ معلومات المخبرين، لكنّه يُعطي ثقلًا أكبر للمخبر الأكثر تطابقًا. الناتج: قرارٌ مدروس، مبنيٌّ بالأساس على المخبر الأنسب، لكنّه لا يتجاهل تمامًا الآخرين.

﴿أَفَلَا يَتَدَبَّرُونَ الْقُرْآنَ أَمْ عَلَىٰ قُلُوبٍ أَقْفَالُهَا﴾

في الآية الكريمة، يدعو الله سبحانه وتعالى إلى التدبّر، أي إلى قراءة الكلمات بعمق، وربط بعضها ببعض، واستخراج المعاني التي تختبئ بين السطور. التدبّر هو نوعٌ من الانتباه المُركَّز. وحين تُغلق القلوب على نفسها، تفوتنا المعاني العميقة، تمامًا كما يفوت النموذج فهم الجمل إذا غاب عنه الانتباه.

في عملي اليومي، أرى الفرق بين قراءة سطحية وقراءة متدبّرة. حين أقرأ ورقةً علميةً جديدة، إذا قرأتُها مرّةً واحدةً بسرعة، أفهم منها ٣٠٪. أمّا إذا قرأتُها بتدبّر،

أربط فيها بين الأفكار المتباعدة، وأقارن بين فقراتها، أفهم ٩٠٪. هذا هو الانتباه — ليس مجرّد قراءة، بل قراءةٌ مع ربط.

الخلاصة

آلية الانتباه ليست سحرًا. هي عمليةٌ منظّمة من ثلاث خطوات: قارن، وزن، اخلط. الاستعلام يسأل، المفتاح يُعرّف، والقيمة تُقدّم المحتوى. السوفت ماكس يُنظّم الأوزان، والضرب النقطي يقيس التشابه. كلّ هذا يحدث ملايين المرّات في كل ثانيةٍ من تشغيل ChatGPT.

في الفصل القادم، سنرى كيف أنّ آلية انتباهٍ واحدة لم تكن كافيةً لفاسواني وزملائه. لقد جعلوها متعدّدة. ثمانية رؤوس انتباهٍ تعمل في الوقت نفسه، كلّها تنظر إلى الجملة من زوايا مختلفة. هذا ما سندخله في الفصل التالي: «الانتباه متعدّد الرؤوس».

الفصل الخامس: الانتباه متعدّد الرؤوس — عيونٌ كثيرة وفهمٌ واحد

﴿وَشَاوِرْهُمْ فِي الْأَمْرِ﴾

— سورة آل عمران: ١٥٩

في الفصل السابق، تعلّمنا كيف يعمل الانتباه: استعلامٌ ومفتاحٌ وقيمة، ضربٌ نقطيٌّ وسوفت ماكس، ثم خلطٌ مرجَّح. كل هذا جميل. لكنّ فاسواني وزملاءه قالوا: انتظروا، لماذا نكتفي برؤيةٍ واحدة؟ لماذا لا يكون لدينا «عدّة» انتباهاتٍ تعمل في الوقت ذاته، كلٌّ منها ينظر إلى الجملة من زاويةٍ مختلفة؟

هذه هي الفكرة الجوهرية للانتباه متعدّد الرؤوس (Multi-Head Attention). وهي، في تقديري، ثاني أهمّ ابتكارٍ في الورقة بعد الانتباه الذاتي ذاته.

لماذا لا تكفي رؤيةٌ واحدة؟

تأمّل الجملة التالية: «أعطى الأستاذُ الطالبَ المتميّزَ كتابًا قيّمًا في صباحٍ مشمسٍ من أيّام الربيع».

هذه الجملة تحمل أنواعًا كثيرة من العلاقات في آنٍ واحد:

- **علاقة فاعل ومفعول**: من الذي أعطى؟ ولمن؟ وماذا؟
- **علاقة وصف**: «المتميّز» تصف «الطالب»، و«قيّم» تصف «الكتاب».
- **علاقة زمانية**: متى حدث الفعل؟ في صباحٍ مشمسٍ من الربيع.
- **علاقة دلالية أعمق**: لماذا أعطى الأستاذ هذا الكتاب القيّم؟ ربما لأنّ الطالب متميّز، فهي علاقة سببية ضمنية.

هل يمكن لرأسٍ واحدٍ من الانتباه أن يلتقط كل هذه العلاقات في وقتٍ واحد؟ نظريًا نعم، لكنّه سيُجهَد. إنّه كالشخص الذي يحاول أن يستمع إلى عشر محادثاتٍ متوازية في الوقت ذاته. سيلتقط بعضها، لكنّه سيُفوّت كثيرًا.

الحلّ: بدلًا من رأسٍ واحدٍ ضخمٍ يحاول فهم كلّ شيء، استخدم عدّة رؤوسٍ صغيرة، كل رأسٍ يتخصّص في نوعٍ من العلاقات.

التشبيه الأقرب: لجنة الخبراء

تخيّل أنّك مديرٌ في شركة، وأمامك تقريرٌ مهمّ تريد تقييمه. يمكنك أن تقرأه بنفسك، لكنّك ستراه من زاويةٍ واحدة فقط — زاويتك الخاصة. أو يمكنك أن تستدعي لجنةً من ثمانية خبراء:

- خبير المالية يقرأ التقرير ليرى الأرقام
- خبير القانون يقرأه ليتأكّد من الامتثال

- خبير التسويق يقرأه ليرى الإمكانيات
- خبير الجودة يبحث عن الأخطاء
- وهكذا...

كلّ خبيرٍ يقرأ التقرير ذاته، لكنّه يُركّز على شيءٍ مختلف. ثم تجمع آراءهم كلّها لتحصل على صورةٍ متعدّدة الأبعاد.

هذا تمامًا ما يفعله الانتباه متعدّد الرؤوس. الجملة الواحدة تُعطى لثمانية «رؤوس» انتباه، كلّ واحدٍ منها مدرَّبٌ بطريقةٍ مختلفة، وكلٌّ ينظر إلى الجملة من زاويته الخاصة. ثم تُجمَع رؤاهم كلّها في النهاية.

كيف يعمل هذا تقنيًا؟

تذكّر أنّ في الانتباه الواحد، كل كلمةٍ تُمرَّر عبر ثلاث مصفوفات لتنتج: استعلامًا ومفتاحًا وقيمة. في الانتباه متعدّد الرؤوس، نفعل الشيء ذاته، لكنّ بدلًا من ثلاث مصفوفات، نستخدم ثلاثًا في ثمانية، أي ٢٤ مصفوفة. كلّ ثلاث مصفوفاتٍ تُكوّن «رأسًا» مختلفًا.

كل رأسٍ يأخذ الجملة، يُولّد استعلاماته ومفاتيحه وقيمه الخاصة، ويحسب الانتباه بشكلٍ مستقلّ تمامًا عن الرؤوس الأخرى. ثم تُؤخذ مخرجات الرؤوس الثمانية، وتُلصَق ببعضها (concatenation)، وتُمرَّر عبر مصفوفةٍ نهائية لدمجها في تمثيلٍ موحّد.

تخيّل ثمانية موسيقيين في أوركسترا، كلٌّ منهم يعزف آلةً مختلفة — كمنجة، فلوت، طبلة، عود... ثم يجتمع الصوت في النهاية ليُكوّن سيمفونيةً متناغمة. هذا هو الانتباه متعدّد الرؤوس: أصواتٌ متعدّدة تجتمع في لحنٍ واحد.

ما الذي يتعلّمه كل رأس؟

هذا سؤالٌ افتُتِنَ به الباحثون منذ صدور الورقة. هل الرؤوس تتعلّم أشياءَ مختلفة بالفعل؟ أم أنّها تكرّر بعضها بعضًا؟

أجرى باحثون في جامعة هارفارد ولاحقًا في معهد ماساتشوستس للتكنولوجيا تحليلاتٍ مفصّلةً لهذا السؤال. والنتيجة كانت رائعة:

- **رأسٌ يتعلّم تتبّع الضمائر:** يربط الضمير بمرجعه («هو» تشير إلى «الرجل»).
- **رأسٌ يتعلّم العلاقة الفعلية:** يربط الفعل بفاعله ومفعوله.
- **رأسٌ يتعلّم الترتيب التسلسلي:** ينتبه إلى الكلمة السابقة مباشرةً.
- **رأسٌ يتعلّم التراكيب النحوية:** يربط الصفة بالموصوف.
- **رأسٌ يتعلّم العلاقات الدلالية البعيدة:** يربط بين كلماتٍ متباعدة لكنّها مترابطة معنى.

هذه التخصّصات لم يبرمجها أحد. النموذج تعلّمها بنفسه من خلال التدريب على ملايين الجمل. هذا واحدٌ من أعجب الأشياء في الذكاء الاصطناعي الحديث: التخصّصات تظهر تلقائيًا.

لماذا ثمانية رؤوس بالضبط؟

في الورقة الأصلية، اختار فاسواني ثمانية رؤوس. لماذا ثمانية وليس أربعة أو ستة عشر؟ الإجابة الصادقة: لأنّه وُجِد تجريبياً أنّ هذا الرقم يعمل بشكلٍ جيد.

لكنّ هناك منطقًا خلف الاختيار. عدد الرؤوس يجب أن يكون متعلّقًا ببُعد التمثيل الكلي للنموذج. لو كان البُعد ٥١٢، فإنّ ثمانية رؤوس تعني أنّ كل رأسٍ يعمل في فضاءٍ بُعده ٦٤. هذا يخلق توازنًا جميلًا: عدد رؤوسٍ كافٍ لتنوّع الزوايا، وكل رأسٍ كبيرٌ بما يكفي ليلتقط معلوماتٍ ذات معنى.

في النماذج الأحدث، يُستخدم أحيانًا ١٢ أو ١٦ أو حتى ٩٦ رأسًا. الاتّجاه العام: كلّما زاد حجم النموذج، زاد عدد الرؤوس.

ميزة خفية: الموازاة

ميزةٌ مهمّة للانتباه متعدّد الرؤوس هي أنّ الرؤوس تُحسَب بالتوازي — في الوقت ذاته، على بطاقات الرسوميات (GPUs). لا حاجة لانتظار رأسٍ ليفرغ من

حسابه قبل أن يبدأ الآخر. هذا يجعل التدريب سريعًا للغاية مقارنةً بالشبكات المتكررة التي رأيناها في الفصل الثاني.

تخيّل خبّازًا يطهو ثمانية أرغفةٍ من الخبز في الوقت ذاته في فرنٍ كبير، بدلًا من خَبزِها واحدًا تلو الآخر. الوقت الكلّي يصبح ثُمن الوقت الأصلي. هذا هو السحر الذي تُتيحه آلية الانتباه متعدّد الرؤوس.

﴿وَشَاوِرْهُمْ فِي الْأَمْرِ﴾

الآية التي افتتحنا بها هذا الفصل تحمل حكمةً عميقة. الله سبحانه وتعالى يأمر النبي ﷺ بمشاورة أصحابه في الأمر. لماذا؟ ألم يكن النبي ﷺ يُوحَى إليه؟ بلى، لكنّ القرار البشري يكون أفضل حين يجمع آراءً متعدّدة.

هذه فلسفةٌ إسلامية أصيلة: «الأمّة لا تجتمع على ضلالة». الحكمة الجمعية أعمق من حكمة الفرد. حين تتعدّد الرؤى، تتجلّى الحقيقة من جوانب متعدّدة، فتقلّ احتمالية الوقوع في الخطأ.

الانتباه متعدّد الرؤوس هو، في جوهره، تطبيقٌ تقني لهذه الفلسفة. النموذج لا يكتفي برأيٍ واحد. يستشير ثمانية «خبراء» داخليين في كل خطوة، ثم يدمج آراءهم. النتيجة: فهمٌ أعمق وأشمل من فهم أيّ رأسٍ منفرد.

وقفة شخصية: تطبيق على البيانات الجينية

في مختبري، نعمل أحيانًا على تحليل بياناتٍ جينيةٍ معقّدة. كل خلية فيها عشرات الآلاف من الجينات، وهذه الجينات تتفاعل في شبكاتٍ متشابكة. حين بدأنا تطبيق آلية الانتباه، أدركنا سريعًا أنّ رأسًا واحدًا لا يكفي. الجينات تتفاعل عبر «مسارات» متعدّدة: مسار الإشارة، ومسار الأيض، ومسار التحكّم في النموّ، ومسار الموت المبرمج.

استخدمنا الانتباه متعدّد الرؤوس، وفوجئنا بأنّ كل رأسٍ بدأ يتخصّص في نوعٍ من المسارات. لم نخبره بذلك — تعلّمه بنفسه. هذا هو السحر.

التحدّيات والقيود

ليس الانتباه متعدّد الرؤوس بلا قيود. التحدّي الأكبر هو التكلفة الحسابية. كلّ رأسٍ يحتاج إلى ضرب مصفوفاتٍ كبيرة، وهذا يستهلك ذاكرةً ووقتًا. كلّما زاد عدد الرؤوس، زادت التكلفة.

تحدٍّ آخر هو «التكرار»: في النماذج الكبيرة، اكتشف الباحثون أنّ بعض الرؤوس تتعلّم أشياءَ متشابهة، مما يُعتبر هدرًا. هذا قاد إلى أبحاثٍ جديدة في «تقليم الانتباه» (Attention Pruning)، حيث يُحذَف الرؤوس الزائدة دون فقدان كبيرٍ في الأداء.

ومع ذلك، تبقى فكرة الانتباه متعدّد الرؤوس واحدةً من أكثر الأفكار تأثيرًا في تاريخ الذكاء الاصطناعي. هي ليست مجرّد تحسينٍ تقنيّ، بل تجسيدٌ لفلسفةٍ أعمق: الفهم الجيّد يأتي من وجهات نظرٍ متعدّدة.

ما القادم؟

في الفصل القادم، سننتقل إلى إشكاليةٍ ذكية: إذا كان الانتباه ينظر إلى كل الكلمات في الوقت نفسه، فكيف يعرف النموذج أنّ هذه الكلمة جاءت قبل تلك؟ هذا هو السؤال الذي حلّه فاسواني وزملاؤه بأناقةٍ بالغة عبر «الترميز الموضعي» (Positional Encoding). سنرى كيف.

الفصل السادس: الترميز الموضعي — كيف يعرف النموذج الترتيب؟

﴿وَكُلَّ شَيْءٍ أَحْصَيْنَاهُ فِي إِمَامٍ مُّبِينٍ﴾

— سورة يس: ١٢

في الفصول الماضية، رأينا قوة الانتباه: قدرته على ربط كل كلمةٍ بكل كلمة، والتعامل معها بالتوازي بدلًا من التتابع. لكنّ هذه القوة تخفي مشكلةً جوهرية، إذا تأمّلتَها قليلًا، فستجدها مزعجة:

إذا كانت كل الكلمات تُعالَج في الوقت ذاته، فكيف يعرف النموذج أيّها جاءت أوّلًا؟

تأمّل الجملتين التاليتين:

- «الكلب عضّ الرجل».
- «الرجل عضّ الكلب».

الكلمات نفسها، لكن المعنى مختلفٌ تمامًا. الفرق الوحيد بينهما هو الترتيب. إذا قرأ النموذج كل الكلمات معًا دون أن يعرف ترتيبها، فإنّه سيرى الجملتين على أنّهما متطابقتان. وهذه كارثة. اللغة تعتمد بشكلٍ جوهريّ على الترتيب.

كيف حلّ فاسواني وزملاؤه هذه المشكلة؟ بفكرةٍ بسيطةٍ وأنيقةٍ تُسمى «الترميز الموضعي» (Positional Encoding).

الفكرة الأساسية: حقن الموقع

الفكرة باختصار: قبل أن نُمرّر الكلمات إلى طبقات الانتباه، نُضيف إلى كل كلمةٍ «وَسْمًا» يُخبر النموذج بموقعها في الجملة. الكلمة الأولى تحصل على وَسْم «أنا في الموقع ١»، والثانية «أنا في الموقع ٢»، وهكذا.

تخيّل أنّك تنظّم ماراثونًا، وأمامك مئة عدّاء. لو لم يحملوا أرقامًا على ظهورهم، لما استطعتَ أن تعرف من هو الأوّل ومن هو الأخير حتى لو شاهدتَهم جميعًا في الوقت ذاته. الأرقام على الظهر هي «الترميز الموضعي» — هي ما يجعل التوازي ممكنًا دون فقدان معلومة الترتيب.

لماذا لا نستخدم أرقامًا بسيطة؟

السؤال المباشر: لماذا لا نستخدم ١، ٢، ٣، ٤... ببساطة؟ ألن يكون هذا أسهل؟

الجواب أعقد قليلًا. النماذج العصبية تتعامل مع أرقامٍ كسرية صغيرة، عادةً بين ٠ و١. لو استخدمنا الأرقام الطبيعية ١، ٢، ٣... فإنّ القيم ستكبر بسرعةٍ كلّما طالت الجملة. كلمة في الموقع ١٠٠٠ ستحصل على رقم ١٠٠٠، وهذا سيُربك الحسابات الأخرى داخل النموذج.

كذلك، نريد أن يكون الترميز قابلًا للتعميم: إذا تدرّب النموذج على جملٍ طولها ٥٠٠ كلمة، نريده أن يتعامل أيضًا مع جملٍ طولها ١٠٠٠ كلمة دون أن ينهار. الأرقام المتسلسلة لا تُحقّق هذا.

الحلّ: الموجات الجيبية وجيب التمام

اقترح فاسواني وزملاؤه استخدام دوال الجيب (sine) وجيب التمام (cosine) لإنشاء الترميز الموضعي. الفكرة:

كل موقعٍ في الجملة يُمثَّل بمتّجهٍ من أرقامٍ، حيث يأتي بعض هذه الأرقام من دالة الجيب، وبعضها الآخر من دالة جيب التمام، ولكنّ كل بُعدٍ في المتّجه يستخدم تردّدًا (frequency) مختلفًا.

دعني أبسّط هذا. تخيّل أنّك تعزف على بيانو. كل مفتاحٍ في البيانو له تردّدٌ خاص (نوتةٌ مختلفة). الآن تخيّل أنّ كل موقعٍ في الجملة يُعزَف بتركيبةٍ من النوتات. الموقع ١ يُعزَف بمزيجٍ معيّن، والموقع ٢ بمزيجٍ آخر مختلف قليلًا. كلّما تباعد موقعان، اختلف اللحن المُعزَف.

النموذج يستطيع أن «يسمع» هذه الألحان، ومن خلالها يعرف موقع كل كلمة. والأهمّ: يستطيع أن يعرف المسافات النسبية بين الكلمات. الكلمتان المتجاورتان لهما لحنٌ متشابه، والكلمتان المتباعدتان لهما لحنٌ مختلف.

التشبيه الموسيقي: السمفونية الموضعية

أحبّ كثيرًا تشبيه الترميز الموضعي بالسمفونية. تخيّل أوركسترا ضخمة، فيها مئات الموسيقيين. كل موقعٍ على المسرح له «بصمةٌ صوتية» مميّزة، تتشكّل من تردّداتٍ مختلفة من الآلات المختلفة. لو طلبتَ من المايسترو أن يجد الموسيقيّ في الموقع رقم ٤٢، فإنّه يستطيع — لأنّ صوت ذلك الموقع له بصمةٌ فريدة.

الترميز الموضعي يفعل الشيء ذاته للكلمات. كل موقعٍ له بصمتُه التردّدية، والنموذج يتعلّم قراءة هذه البصمات.

كيف يُدمَج الترميز الموضعي مع الكلمات؟

السؤال التقني التالي: كيف نُدخِل هذا الترميز في النموذج؟

الجواب بسيط: نجمعه (نضيفه) إلى تمثيل الكلمة الأصلي. كل كلمةٍ في النموذج تُمثَّل بمتّجهٍ من ٥١٢ رقمًا (في الورقة الأصلية). الترميز الموضعي هو أيضًا متّجهٌ من ٥١٢ رقمًا. نجمع المتّجهين عنصرًا عنصرًا، فينتج متّجهٌ جديد يحمل في طيّاته معلومتين: «ما هي هذه الكلمة» و«أين موقعها».

تخيّل أنّك تكتب رسالةً وتُغلّفها في ظرف. الكلمة هي محتوى الرسالة، والترميز الموضعي هو طابع البريد الذي يحمل تاريخًا ورقمًا تسلسليًا. الظرف يحمل الاثنين معًا.

الذكاء الخفيّ في الفكرة

ما يجعل هذه الفكرة عبقريةً هو قابليّتها للتعميم. لأنّ الجيب وجيب التمام دوالٌّ دورية ومتّصلة، فإنّ النموذج يستطيع أن يستنتج العلاقات بين المواقع التي لم يرَها أثناء التدريب. لو تدرّب على جملٍ بطول ٥٠٠، يستطيع أن يفهم جملًا بطول ١٠٠٠ بدرجةٍ معقولة، لأنّ نمط الموجات يستمرّ بشكلٍ منطقي.

كذلك، الفروق بين المواقع تُحفَظ في صيغةٍ خطية. ما يعني أنّ المسافة بين الموقع ١ والموقع ٥ تُمثَّل بطريقةٍ مشابهة للمسافة بين الموقع ١٠ والموقع ١٤. هذا يساعد النموذج على فهم «المسافات النسبية» بدلًا من المواقع المطلقة فقط.

الترميز الموضعي اليوم: تطوّرات وتنوّع

الترميز الموضعي الذي اقترحته الورقة الأصلية لم يبقَ بلا تطوير. ظهرت أنواعٌ كثيرة منه عبر السنوات:

- **الترميز الموضعي المُتعلَّم**: بدلًا من استخدام الجيب وجيب التمام، يتعلّم النموذج بنفسه ما هو أفضل ترميزٍ لكل موقع.

- **الترميز النسبي (Relative Position)**: يُركّز على المسافات بين الكلمات بدلًا من المواقع المطلقة.
- **RoPE (Rotary Position Embedding)**: تقنيةٌ حديثة تدور بالمتجهات بزوايا تتناسب مع الموقع. تُستخدم اليوم في نماذج كبيرة مثل LLaMA.
- **ALiBi**: طريقةٌ بسيطة تُضيف عقوبةً للانتباه بناءً على المسافة، دون الحاجة إلى ترميزٍ صريح.

كل هذه الأساليب تحاول حلّ المشكلة ذاتها بطرقٍ مختلفة، وكلٌّ منها يصلح لسياقٍ معيّن. لكنّ الفكرة الأساسية تبقى ثابتة: يجب على النموذج أن يعرف الترتيب.

﴿وَكُلَّ شَيْءٍ أَحْصَيْنَاهُ فِي إِمَامٍ مُّبِينٍ﴾

في الآية الكريمة، يُذكّرنا الله سبحانه وتعالى بأنّ كلّ شيءٍ مسجَّلٌ ومُحصى في «إمامٍ مبين» — أي في كتابٍ واضحٍ شامل. كل ذرّةٍ في الكون لها موقعها المعلوم، وكلّ حركةٍ مُسجَّلة. الترتيب جزءٌ أصيل من نظام الكون.

في الذكاء الاصطناعي، حين نريد للآلة أن تفهم الواقع، علينا أن ننقل إليها هذه الفكرة: لا شيء يُفهَم بمعزلٍ عن موقعه. الكلمة في موقعها، والذرّة في مكانها، والحدث في زمانه. الترميز الموضعي ليس مجرّد حيلةٍ تقنية، بل تجسيدٌ لحقيقةٍ كونية: للموقع معنى.

وقفة شخصية: الترميز الموضعي في علم الأحياء

في عملي على بياناتٍ مكانية للخلايا (spatial transcriptomics)، أتعامل مع آلاف الخلايا التي تحمل كلٌّ منها موقعًا في النسيج. الخلية القريبة من الورم تختلف بيولوجياً عن الخلية البعيدة عنه. حين بدأنا تطبيق المحوّلات على هذه البيانات، كان السؤال نفسه: كيف نُخبر النموذج بمواقع الخلايا؟

استخدمنا فكرةً مشابهة للترميز الموضعي، لكن في فضاءٍ ثنائي البعد بدلًا من فضاءٍ خطّي. كل خليةٍ تحصل على «بصمةٍ مكانية» تُخبر النموذج بإحداثيّاتها. النتيجة: نماذج تفهم أنّ الخلية في موقعٍ معيّنٍ لها سياقٌ بيولوجيّ مختلف عن الخلية في موقعٍ آخر.

هذه قوّة الفكرة العامة: تنطبق على الكلمات، وعلى الخلايا، وعلى الجزيئات، وعلى أيّ شيءٍ يتموضع في فضاءٍ ما.

التحدّيات الباقية

الترميز الموضعي أحد المجالات التي ما زال البحث فيها نشطًا. التحدّي الأكبر هو «التعميم خارج التوزيع» (Out-of-Distribution Generalization). إذا تدرّب النموذج على جملٍ طولها ٢٠٤٨ كلمة، فهل يستطيع أن يتعامل مع جملٍ طولها ٣٢٠٠٠ كلمة كما في النماذج الحديثة؟ الإجابة معقّدة، وتعتمد على نوع الترميز المستخدم.

هناك أيضًا أبحاثٌ في الترميز ثلاثيّ الأبعاد للصور، والترميز الزمنيّ للفيديو، والترميز البياني للشبكات الاجتماعية. كل مجالٍ يحتاج إلى نوعٍ مختلف من الترميز الموضعي يُناسب بنية البيانات.

ما القادم؟

الآن لدينا الأدوات الأساسية: الانتباه، الانتباه متعدّد الرؤوس، والترميز الموضعي. في الفصل القادم، سنرى كيف تُجمَع هذه الأدوات في بنيةٍ هندسيةٍ كاملة: المُشفِّر والمُفكِّك (Encoder-Decoder). سنفهم كيف يقرأ النموذج جملةً بلغةٍ ما، ثم يُولّد ترجمتها بلغةٍ أخرى. سنرى أيضًا لماذا قرّرت بعض النماذج لاحقًا (مثل BERT و GPT) أن تستخدم نصف هذه البنية فقط.

الفصل السابع: المُشفِّر والمُفكِّك — قلب المحوّل

﴿وَنَزَّلْنَا عَلَيْكَ الْكِتَابَ تِبْيَانًا لِّكُلِّ شَيْءٍ﴾

— سورة النحل: ٨٩

حتى الآن، تعلّمنا اللبنات الأساسية: الانتباه، والانتباه متعدّد الرؤوس، والترميز الموضعي. لكنّ هذه اللبنات وحدها لا تشكّل بيتًا. نحتاج أن نرى كيف تُجمَع في بنيةٍ هندسيةٍ كاملة.

في الورقة الأصلية، اقترح فاسواني وزملاؤه بنيةً تُسمى «المُشفِّر-المُفكِّك» (Encoder-Decoder). البنية مُصمَّمةٌ بشكلٍ خاص لمهامٍ مثل الترجمة، حيث يكون لدينا نصٌّ في لغةٍ ما، ونريد توليد نصٍّ في لغةٍ أخرى. سنرى في هذا الفصل كيف تعمل هذه البنية، ولماذا قرّر بعض الباحثين لاحقًا أن يستخدموا نصفها فقط.

التشبيه: المترجم البشري

قبل أن نغوص في التفاصيل التقنية، دعني أشبّه الأمر بمترجمٍ بشري ماهر يعمل في مؤتمرٍ دولي.

عند ترجمة جملةٍ من الإنجليزية إلى العربية، يقوم المترجم بمرحلتين متميّزتين:

المرحلة الأولى — الفهم: يستمع إلى الجملة الإنجليزية كاملةً، يحلّلها في عقله، يفهم العلاقات بين الكلمات، يُدرك السياق، ويُكوّن «صورةً ذهنية» متكاملة لما قاله المتحدّث.

المرحلة الثانية — التوليد: ينطلق في توليد الترجمة العربية، كلمةً كلمة، مُعتمدًا على «الصورة الذهنية» التي بناها في المرحلة الأولى. مع كل كلمةٍ يُترجمها، يعود إلى الصورة الذهنية ليتأكّد من المعنى، ويختار الكلمة العربية الأنسب.

المُشفِّر هو المرحلة الأولى. والمُفكِّك هو المرحلة الثانية.

المُشفِّر: بناء الفهم

المُشفِّر هو الجزء الذي «يقرأ» الجملة الأصلية ويبني فهمًا غنيًا لها. هو يأخذ الكلمات (مع ترميزها الموضعي)، ويمرّرها عبر طبقاتٍ متتاليةٍ من الانتباه متعدّد الرؤوس. كل طبقةٍ تُعمّق الفهم: الطبقات الأولى تلتقط العلاقات السطحية (مثل الصفة والموصوف)، والطبقات الأعلى تلتقط العلاقات الأعمق (مثل الموضوع العام، النيّة، الأسلوب).

في الورقة الأصلية، يتكوّن المُشفِّر من ست طبقاتٍ متطابقة (٦ طبقات). كل طبقةٍ تحتوي على:

1. **انتباه ذاتي متعدّد الرؤوس**: تربط كل كلمةٍ بكل كلمةٍ أخرى في الجملة.
2. **شبكة تغذيةٍ أمامية (Feed-Forward Network)**: تعالج كل موقعٍ بشكلٍ مستقل، تضيف عمقًا حسابيًا.
3. **اتّصالات تخطّي (Skip Connections) وتطبيع الطبقة (Layer Normalization)**: مكوّنات تُساعد على استقرار التدريب (سندخل في تفاصيلها في الفصل القادم).

تخيّل المُشفِّر كقارئٍ يقرأ نصًّا ست مرّاتٍ متتالية، في كل مرّةٍ يفهم طبقةً أعمق من المعنى.

المُفكِّك: توليد المخرجات

المُفكِّك هو الجزء الذي «يكتب» الترجمة. وهو أعقد قليلًا من المُشفِّر، لأنّه يقوم بمهمّتين في كل خطوة:

1. **يُولّد الكلمة التالية**: بناءً على الكلمات التي ولّدها سابقًا، يقرّر ما هي الكلمة المناسبة التالية.

2. **يستفيد من فهم المُشفِّر**: يعود إلى تمثيل الجملة الأصلية الذي بناه المُشفِّر، ويلتفت إلى الأجزاء الأكثر صلةً بما يُولّده الآن.

كل طبقةٍ في المُفكِّك تحتوي على ثلاثة مكوّنات (بدلًا من اثنين كما في المُشفِّر):

أ. **انتباه ذاتي مُقنَّع (Masked Self-Attention)**: ينظر إلى الكلمات السابقة فقط في الجملة المُولَّدة، ولا ينظر إلى الكلمات المستقبلية (لأنّها لم تُولَد بعد).

ب. **انتباه المُشفِّر-المُفكِّك (Cross-Attention)**: هنا يحدث «الجسر». استعلامات (Queries) تأتي من المُفكِّك، ومفاتيح (Keys) وقيم (Values) تأتي من المُشفِّر. هذا يسمح للمُفكِّك بأن «يلتفت» إلى الجملة الأصلية في كل خطوة.

ج. **شبكة تغذيةٍ أمامية**: مثل المُشفِّر تمامًا.

القناع: لماذا نمنع المُفكِّك من النظر إلى المستقبل؟

لاحظ أنّ المُفكِّك يستخدم «انتباهًا مُقنَّعًا». لماذا؟

تخيّل أنّك تكتب مقالًا. حين تكتب الكلمة الخامسة، أنت تعرف الكلمات الأربع السابقة، لكنّك لا تعرف الكلمات السادسة والسابعة بعد، لأنّها لم تُكتَب. هذا هو جوهر الكتابة: التولُّد التتابعي.

لو سمحنا للمُفكِّك بأن يرى الكلمات المستقبلية أثناء التدريب، فإنّه «سيغش». سيتعلّم أن يعتمد على معلوماتٍ لن تكون متاحة وقت الاستخدام الفعلي. لذلك نضع «قناعًا» (Mask) يمنعه من الالتفات إلى الكلمات المستقبلية.

التشبيه: تخيّل طالبًا يجلس في امتحان. أمامه ورقة تحوي الأسئلة والإجابات معًا. لو سمحنا له برؤية الإجابات، فإنّه لن يتعلّم. لكن إذا غطّينا الإجابات وكشفناها واحدةً تلو الأخرى بعد محاولته، فإنّه سيتعلّم بشكلٍ صحيح. القناع هو هذا الستر.

الجسر: انتباه المُشفِّر-المُفكِّك

أهمّ مكوّنٍ في البنية كاملة، في رأيي، هو «انتباه المُشفِّر-المُفكِّك». هو ما يربط بين عالمين: عالم الجملة الأصلية، وعالم الجملة المُولَّدة.

تخيّل مهندسًا معماريًا يصمّم بيتًا. عنده مخطّطٌ هندسيٌّ كامل (هذا هو خرج المُشفِّر). الآن هو يقف في موقع البناء، ويبني البيت طوبةً طوبة. عند كل طوبة، يرجع إلى المخطّط ليتأكّد من أنّ ما يبنيه يطابق التصميم. هذا الرجوع إلى المخطّط — هذا الجسر — هو انتباه المُشفِّر-المُفكِّك.

في الترجمة: عند توليد كل كلمةٍ عربية، يعود المُفكِّك إلى تمثيل الجملة الإنجليزية، ويلتفت إلى الأجزاء التي لم يُترجمها بعد، أو الأجزاء الأكثر صلةً بالكلمة الحالية.

نماذج تستخدم نصف البنية فقط

بعد عام ٢٠١٧، اكتشف الباحثون شيئًا مثيرًا: لا تحتاج كل المهام إلى البنية الكاملة. بعض المهام تحتاج المُشفِّر فقط، وبعضها تحتاج المُفكِّك فقط.

مهام الفهم (Understanding): مثل التصنيف، أو الإجابة عن أسئلة، أو استخراج المعلومات. هذه المهام تحتاج إلى فهمٍ عميق للجملة، لكنّها لا تحتاج إلى توليد نصٍّ طويل. لها يستخدم النموذج المُشفِّر فقط. هذا هو نهج BERT (Bidirectional Encoder Representations from Transformers) من جوجل.

مهام التوليد (Generation): مثل كتابة قصص، أو إكمال الجمل، أو الحوار. هذه المهام تحتاج إلى توليد نصوصٍ جديدة من الصفر، اعتمادًا على ما سبق. لها يستخدم النموذج المُفكِّك فقط. هذا هو نهج GPT (Generative Pre-trained Transformer) من OpenAI.

مهام الترجمة والتلخيص: تحتاج إلى الفهم والتوليد معًا. لها يبقى نموذج المُشفِّر-المُفكِّك الكامل. مثل T5 من جوجل.

من المثير للاهتمام أنّ نموذج ChatGPT الذي يستخدمه الناس يوميًا هو في الأساس «مُفكِّك فقط» — لكنّه ضخمٌ بما يكفي ليُحاكي الفهم والتوليد معًا.

لحظة شخصية: تطبيق على البروتينات

في عملي، أتعامل أحيانًا مع تسلسلات الأحماض الأمينية (التي تُكوّن البروتينات). كل بروتينٍ هو سلسلةٌ من «الكلمات» (الأحماض الأمينية)، ويجب أن نفهم كيف تتفاعل هذه الأحماض لتُكوّن بنيةً ثلاثية الأبعاد.

نموذج AlphaFold 2 من DeepMind، الذي حصد جائزة نوبل في الكيمياء عام ٢٠٢٤، يستخدم بنيةً مشابهةً للمُشفِّر-المُفكِّك. المُشفِّر يقرأ تسلسل الأحماض، والمُفكِّك يولّد إحداثيات البنية ثلاثية الأبعاد. الجسر بين الاثنين هو ما يسمح للنموذج بأن يربط كل حمضٍ بموقعه في الفضاء.

هذا انتقالٌ جميل: ما اقترحه فاسواني للترجمة بين اللغات، أصبح حلًّا للترجمة بين «لغة التسلسل» و«لغة البنية» في علم الأحياء.

﴿وَنَزَّلْنَا عَلَيْكَ الْكِتَابَ تِبْيَانًا لِّكُلِّ شَيْءٍ﴾

في الآية الكريمة، يصف الله القرآن بأنّه «تبيانٌ لكلّ شيء». التبيان هو الإيضاح الكامل، الذي يجمع بين الفهم العميق والقدرة على إيصاله إلى الآخرين. القرآن لا يكتفي بالفهم، بل يُعلّم كيف يُبلَّغ هذا الفهم.

هذه فلسفةٌ تنطبق بشكلٍ مذهل على بنية المُشفِّر-المُفكِّك. الفهم وحده لا يكفي. التوليد وحده لا يكفي. القيمة الحقيقية تأتي من الجمع بين الاثنين: فهمٌ عميق ينتج عنه تبليغٌ مبين.

الخلاصة والاستعداد للقادم

البنية الكاملة للمحوّل تتألّف من قسمين:

- **المُشفِّر**: ست طبقاتٍ تبني فهمًا للجملة الأصلية.
- **المُفكِّك**: ست طبقاتٍ تولّد الجملة الجديدة، مع جسر دائمٍ إلى المُشفِّر.

النماذج الحديثة استلهمت من هذه البنية واخترعت تنويعاتٍ كثيرة: BERT (مُشفِّر فقط)، GPT (مُفكِّك فقط)، T5 (الاثنان معًا)، وغيرها.

في الفصل القادم، سنغوص في تفاصيل المكوّنات الأخرى التي تجعل كل طبقةٍ تعمل: الشبكة التغذوية الأمامية، وتطبيع الطبقة، والاتّصالات المتبقّية. هذه المكوّنات قد تبدو هامشيةً، لكنّها أساسٌ لاستقرار التدريب وعمق التعلّم.

الفصل الثامن: الشبكة التغذوية الأمامية والتطبيع

﴿وَأَتْقَنَ كُلَّ شَيْءٍ﴾

— سورة النمل: ٨٨

تخيّل أنّك بنيتَ بيتًا جميلًا. الأساسات قويّة، الجدران مرتفعة، والسقف متماسك. لكنّ البيت لا يكتمل بهذا فقط. تحتاج إلى السباكة، والكهرباء، والتدفئة، والتهوية. هذه «التفاصيل التقنية» قد تبدو غير لافتةٍ للنظر، لكنّها ما يجعل البيت قابلًا للسكن فعلًا.

في عالم المحوّلات، لدينا الانتباه (الأساسات) والانتباه متعدّد الرؤوس (الجدران)، لكنّ هناك مكوّناتٍ أخرى لا تحظى بالشهرة ذاتها، رغم أنّها أساسٌ لاستقرار النموذج وقدرته على التعلّم. هذه المكوّنات هي:

1. الشبكة التغذوية الأمامية (Feed-Forward Network).
2. تطبيع الطبقة (Layer Normalization).
3. الاتّصالات المتبقّية (Residual Connections).

سنغوص في كلّ منها بهدوء.

الشبكة التغذوية الأمامية: مرحلة «التفكير»

بعد أن يُنهي الانتباه عمله، نحتاج إلى مرحلةٍ أخرى نُسمّيها بشكلٍ غير رسمي «مرحلة التفكير». هنا تأتي الشبكة التغذوية الأمامية (FFN).

ما هي الشبكة التغذوية الأمامية؟ هي شبكةٌ عصبيّةٌ بسيطة، تتكوّن من طبقتين خطّيّتين تفصل بينهما دالّة تنشيط (مثل ReLU). هي تأخذ تمثيل كل كلمةٍ على حدة، وتُحوّله إلى تمثيلٍ جديد.

التشبيه الأقرب: الانتباه يجمع المعلومات من «الجيران»، أمّا الشبكة التغذوية الأمامية فتُعالج هذه المعلومات داخليًا، كأنّ كلّ كلمةٍ «تتأمّل» في ما جمعتْه قبل أن تنتقل إلى الطبقة التالية.

تخيّل ندوةً علميّة. الانتباه هو الجلسة العامّة حيث يتبادل المشاركون الأفكار. الشبكة التغذوية الأمامية هي الاستراحة بعد الجلسة، حيث يجلس كلّ مشاركٍ منفردًا في غرفته يفكّر في ما سمعه ويُنظّمه في ذهنه. الجلسة العامّة (الانتباه) ضروريّة لجمع الأفكار، لكنّ الاستراحة (التغذية الأمامية) ضروريّة لاستيعابها.

ملاحظة دقيقة: كل موقعٍ مستقلّ

نقطةٌ مهمّة في الشبكة التغذوية الأمامية: هي تُطبَّق على كلّ كلمةٍ بشكلٍ مستقلّ. الكلمة الأولى لا تؤثّر على معالجة الكلمة الثانية في هذه المرحلة. كلّ كلمةٍ في «غرفتها الخاصّة».

لماذا؟ لأنّ الانتباه قد قام بمهمّة جمع المعلومات بين الكلمات. بعد ذلك، نعطي كل كلمةٍ فرصةً للتفكّر بمفردها. ثم نعود إلى طبقةٍ جديدة من الانتباه (في الطبقة التالية) لنرى كيف تغيّرت العلاقات.

هذا التقسيم — انتباه ثم تفكير، انتباه ثم تفكير — يتكرّر ست مرّاتٍ في الورقة الأصلية. كل تكرارٍ يُعمّق الفهم.

تطبيع الطبقة: الترموستات الذي يحفظ الاستقرار

الآن ننتقل إلى مكوّنٍ يبدو هامشيًا، لكنّه أساسيٌّ تمامًا: تطبيع الطبقة (Layer Normalization).

ما المشكلة التي يحلّها؟ في الشبكات العصبية العميقة، تتراكم الحسابات طبقةً تلو الأخرى. مع كلّ طبقة، تكبر الأرقام أو تصغر بشكلٍ غير منضبط. قد تنفجر القيم إلى ما لا نهاية، أو تتلاشى إلى الصفر. هذا يُسمى مشكلة «انفجار التدرّج» أو «اختفاء التدرّج». النتيجة: التدريب لا يستقرّ، والنموذج لا يتعلّم.

تطبيع الطبقة هو حلٌّ ذكيّ. بعد كلّ مكوّنٍ في النموذج، نُعيد ضبط الأرقام بحيث يكون متوسّطها صفرًا، وانحرافها المعياري واحدًا. هذا يحفظ الأرقام في «نطاقٍ صحّي».

التشبيه الأقرب: الترموستات في البيت. لو ارتفعت الحرارة كثيرًا، يُشغّل المكيّف. لو انخفضت كثيرًا، يُشغّل المدفأة. الهدف: الحفاظ على الحرارة في نطاقٍ مريح. تطبيع الطبقة هو الترموستات الذي يحفظ النموذج في «نطاقٍ حسابيٍّ صحّي».

دون هذا الترموستات، النموذج إمّا «يتجمّد» (التدرّجات تتلاشى)، أو «يحترق» (التدرّجات تنفجر). كلاهما يعني أنّ النموذج لا يتعلّم. مع التطبيع، التدريب يستمرّ بسلاسة لأيّامٍ وأسابيع، حتى يتعلّم النموذج ما هو مطلوب.

الاتّصالات المتبقّية: لماذا «التخطّي» ضروريّ؟

المكوّن الثالث هو الاتّصالات المتبقّية (Residual Connections)، وتُسمى أيضًا «اتّصالات التخطّي» (Skip Connections).

الفكرة بسيطة جدًا، لكنّها قويّة: في كل مكوّنٍ من النموذج، بدلًا من أن نعطي المخرج مباشرةً، نُضيف إليه المدخل. أي:

المخرج النهائي = ما حسبه المكوّن + المدخل الأصلي

لماذا؟ لسببين أساسيين.

السبب الأوّل: السماح للمعلومة الأصلية بالعبور دون تشويه. تخيّل أنّك تُمرّر رسالةً عبر سلسلةٍ من المُترجمين. كل مترجمٍ يحوّلها إلى لغةٍ مختلفة. مع الترجمة المتراكمة، تضيع الرسالة الأصلية. لكن لو احتفظ كلّ مترجمٍ بنسخةٍ من الأصل، يستطيع أن يصحّح ترجمته. هذا تأثير الاتّصال المتبقّي.

السبب الثاني: تسهيل تدفّق التدرّجات أثناء التدريب. التدرّج هو «الإشارة» التي تُخبر النموذج كيف يُحسّن نفسه. في الشبكات العميقة جدًا، هذه الإشارة قد تتلاشى قبل أن تصل إلى الطبقات السفلى. الاتّصال المتبقّي يخلق «طريقًا سريعًا» للتدرّج، يضمن وصوله إلى كلّ طبقة.

التشبيه: تخيّل برجًا من ١٠٠ طابق. بدون مصاعد، الناس في الطابق العاشر لا يستطيعون الوصول إلى السطح بسهولة. الاتّصالات المتبقّية هي المصاعد التي تُسرّع التواصل بين الطوابق.

بنية المكدّس: كيف تُجمَع كل هذه المكوّنات؟

دعني الآن أُجمِّع كلّ ما رأيناه في الفصول الأخيرة. كلّ طبقةٍ في المُشفِّر (وكذلك المُفكِّك) تتألّف من «مكدّس» (stack) من المكوّنات بالترتيب:

1. **مدخل**: تمثيلات الكلمات (مع الترميز الموضعي).

2. **انتباه ذاتي متعدّد الرؤوس**: يجمع المعلومات بين الكلمات.

3. **اتّصال متبقّي + تطبيع طبقة**: يحفظ الاستقرار.

4. **شبكة تغذوية أمامية**: تُعالج كل كلمةٍ بشكلٍ مستقل.

5. **اتّصال متبقّي + تطبيع طبقة**: يحفظ الاستقرار مرّةً أخرى.

6. **مخرج**: تمثيلٌ جديد، يدخل إلى الطبقة التالية.

هذا «المكدّس» يتكرّر ست مرّاتٍ في النموذج الأصلي. النماذج الأحدث تستخدم تكرارًا أكبر بكثير: GPT-3 يستخدم ٩٦ طبقة، و GPT-4 يستخدم أكثر من ذلك (الأرقام الدقيقة سرّيّة).

التشبيه النهائي: المصنع المُحكَم

تخيّل مصنعًا حديثًا لإنتاج السيّارات. على خطّ التجميع، السيّارة تمرّ بمحطّاتٍ متتالية. كلّ محطّةٍ تُضيف شيئًا: العجلات، ثم المحرّك، ثم الكهرباء، ثم الطلاء، إلخ. لكنّ المصنع يحتاج أيضًا إلى:

- **مفتشي الجودة** (تطبيع الطبقة): يتأكّدون من أنّ كلّ محطّةٍ أنتجت ما هو مطلوب، ويعدّلون الانحرافات.
- **خطوط طوارئ** (الاتّصالات المتبقّية): إذا تعطّلت محطّةٌ ما، الإنتاج لا يتوقّف، لأنّ هناك مسارًا بديلًا.

• **محطّات الراحة** (الشبكة التغذوية الأمامية): حيث تُعالَج التفاصيل الدقيقة قبل الانتقال إلى المرحلة التالية.

كلّ هذه المكوّنات تعمل معًا لتُنتج سيّارةً متقنة. وكلّ مكوّنٍ في المحوّل، حتى أصغرها، يُسهم في إتقان النموذج.

﴿وَأَتْقَنَ كُلَّ شَيْءٍ﴾

في الآية الكريمة، يُذكّرنا الله سبحانه وتعالى بأنّه أتقن كلّ شيءٍ خلقه. الإتقان هو الكمال في التفصيل. ليس فقط الفكرة الكبيرة، بل التفاصيل الصغيرة التي تجعل الفكرة الكبيرة تعمل.

في عالم الذكاء الاصطناعي، نتعلّم درسًا مشابهًا: العبقرية ليست فقط في الفكرة الكبرى (الانتباه)، بل في تفاصيل التنفيذ (التطبيع، الاتّصالات المتبقّية، الشبكة التغذوية الأمامية). لو غاب أيّ من هذه المكوّنات، النموذج لا يعمل. كلّ تفصيلٍ مدروس.

أعجبني دائمًا قول العلماء المسلمين: «التحقيق في الفروع لا يقلّ شأنًا عن التحقيق في الأصول». الأصول تعطي الإطار، لكنّ الفروع تعطي الحياة. وفي بنية المحوّل، الانتباه هو الأصل، وكلّ هذه المكوّنات هي الفروع التي تجعل الأصل ينبض.

وقفة شخصية: حين فشل أوّل تجاربي

في أوّل تجاربي مع المحوّلات، حاولتُ بناء نموذجٍ مبسّط وحذفتُ تطبيع الطبقة لأنّني اعتقدتُ أنّه «تفصيلٌ ثانوي». النتيجة: النموذج لم يتعلّم شيئًا. كانت الخسارة (loss) تتقلّب بشكلٍ عشوائي ولا تنخفض أبدًا.

أعدتُ تطبيع الطبقة، وفجأةً النموذج بدأ يتعلّم. كان درسًا مهمًّا: في الذكاء الاصطناعي، لا يوجد «تفصيلٌ ثانوي». كلّ مكوّنٍ موجودٌ لسبب، وحذفه قد يُحطّم النموذج كاملًا.

التحدّيات الباقية

الأبحاث الحديثة طوّرت هذه المكوّنات. على سبيل المثال:

- **Pre-LayerNorm**: تطبيق التطبيع قبل الانتباه بدلًا من بعده، مما يُحسّن الاستقرار في النماذج الكبيرة.
- **RMSNorm**: نسخةٌ أبسط من تطبيع الطبقة، تُستخدم في نماذج LLaMA الحديثة.
- **GeLU بدلًا من ReLU**: دالّة تنشيطٍ أعقد قليلًا، لكنّها تعطي أداءً أفضل.

كلّ هذه التطويرات تُحسّن في «الفروع»، بينما يبقى «الأصل» (آلية الانتباه) كما هو منذ ٢٠١٧.

ما القادم؟

الآن نفهم البنية الكاملة للمحوّل. لكنّ السؤال يبقى: كيف يتعلّم هذا النموذج فعلًا؟ كيف نُدرّبه؟ ما هي البيانات؟ ما هي «دالّة الخسارة» التي تخبره أنّه أخطأ؟ كم تحتاج من حواسيب وزمن؟

كلّ هذا في الفصل القادم: «التدريب — كيف تعلّم النموذج؟».

الفصل التاسع: التدريب — كيف تعلّم النموذج؟

﴿وَقُل رَّبِّ زِدْنِي عِلْمًا﴾

— سورة طه: ١١٤

حتى الآن، تحدّثنا عن البنية: المُشفِّر والمُفكِّك، الانتباه، الترميز الموضعي، والمكوّنات المساعدة. لكنّ السؤال الأعمق يبقى: كيف يتعلّم هذا النموذج فعلًا؟ كيف يُدرَّب على ملايين الجمل؟ كيف يكتشف بنفسه قواعد اللغة وعلاقات الكلمات؟

في هذا الفصل، سنغوص في عالم تدريب المحوّلات. سنرى البيانات، والخسارة، والأمثلة، والصبر الذي يحتاجه الباحثون لتعليم هذه النماذج.

ماذا يعني «التدريب»؟

التدريب في الذكاء الاصطناعي يُشبه تعليم طفلٍ لغةً جديدة. لا تُعطي الطفل قائمةً بالقواعد النحوية وتقول له «هذه هي اللغة، احفظها». بدلًا من ذلك، تعرّضه لآلاف الجمل، تُصحّح أخطاءه، تُكرّر معه الأنماط، حتى يستوعب اللغة بطريقةٍ ضمنيّة.

هذا تمامًا ما نفعله مع المحوّلات. لا نُبرمج فيها قواعد اللغة. نعرّضها لملايين الجمل، ونُعدّل «أوزانها» الداخليّة (المصفوفات) تدريجيًّا حتى تتعلّم بنفسها كيف تتنبّأ بالكلمة التالية، أو كيف تُترجم.

البيانات: وقود التعلّم

في الورقة الأصلية لعام ٢٠١٧، تدرّب نموذج المحوّل على مهمّتين أساسيّتين:

أوّلًا: ترجمة من الإنجليزية إلى الألمانية. استخدموا مجموعة بيانات WMT 2014، التي تحتوي على ٤.٥ مليون زوجٍ من الجمل (إنجليزي + ترجمتها بالألمانية).

ثانيًا: ترجمة من الإنجليزية إلى الفرنسية. استخدموا مجموعةً أكبر، ٣٦ مليون زوجٍ من الجمل.

هذه أرقامٌ هائلة. ٤.٥ مليون جملةٍ تساوي تقريبًا ٤٥٠ كتابًا متوسّطًا. و ٣٦ مليون جملةٍ تساوي حوالي ٣٦٠٠ كتاب. النموذج «يقرأ» كلّ هذه البيانات، أو بالأحرى، يمرّ عليها مراتٍ عديدة (تُسمى «الحقب» أو epochs)، حتى يتعلّم.

النماذج الحديثة تستخدم بياناتٍ أكبر بكثير. GPT-3 تدرّب على ٥٠٠ مليار «رمز» (token)، وهذا يعادل تقريبًا ٧٠٠ ألف كتاب. GPT-4 و Claude يستخدمان كمّياتٍ أكبر، تشمل تقريبًا كل ما هو متاحٌ من نصوصٍ على الإنترنت.

دالّة الخسارة: كيف يعرف النموذج أنّه أخطأ؟

التدريب يحتاج إلى «إشارة». بعد كل تنبّؤ، نحتاج أن نُخبر النموذج: «هذا الجواب صحيح» أو «هذا الجواب خطأ». بدون هذه الإشارة، النموذج لا يعرف كيف يُحسّن نفسه.

في الترجمة، الإشارة تأتي من الترجمة الصحيحة الموجودة في البيانات. النموذج يحاول ترجمة جملةٍ إنجليزية، ينتج كلمةً عربية مقترحة، ثم نُقارنها بالكلمة العربية الصحيحة في البيانات. الفرق بينهما هو «الخسارة» (Loss).

التشبيه: تخيّل معلّمًا يصحّح إجابات تلميذه. التلميذ يكتب إجابة، المعلّم يقرأها ويقول: «أنتَ بعيدٌ بعشر درجاتٍ عن الإجابة الصحيحة، حاول مرّةً أخرى». هذه الدرجات هي الخسارة.

في المحوّلات، نستخدم دالّةً تُسمى «الانتروبيا المتقاطعة» (Cross-Entropy). لا تُقلِق نفسك بالاسم — الفكرة ببساطة: نقارن توزيع الاحتمالات الذي ينتجه النموذج بالتوزيع الصحيح، ونحسب «الفرق».

الانتشار العكسي: كيف يُحسّن النموذج نفسه؟

بعد أن يحسب الخسارة، يبدأ النموذج عمليّةً تُسمى «الانتشار العكسي» (Backpropagation). الفكرة:

1. الخسارة تُحسَب في الأعلى (طبقة المخرجات).
2. ثم تنتقل «إشارة الخطأ» إلى الخلف، طبقةً طبقة، حتى تصل إلى أوّل طبقة.
3. في كل طبقة، نحسب «التدرّج» — أي بمقدار كم يجب تعديل كل وزنٍ ليُقلّل الخسارة.
4. نُحدّث الأوزان قليلًا في الاتّجاه الذي يُقلّل الخسارة.

التشبيه: تخيّل أنّك ترمي سهمًا على هدف، فيخطئ بمقدار مترين إلى اليمين. تُحلّل: «حسنًا، يدي كانت مرتفعةً قليلًا، وقدمي كانت مائلة، وقبضتي كانت غير مستقيمة». تعدّل كلّ هذه الأمور قليلًا، ثم ترمي مرّةً أخرى. مع كلّ رميةٍ، تتحسّن قليلًا، حتى تصيب الهدف.

النموذج يفعل هذا ملايين المرّات. كلّ مرّةٍ يرى جملةً جديدة، يرمي «سهمه» (التنبّؤ)، يحسب الخطأ، ويُعدّل أوزانه قليلًا. مع الوقت، يتقن الرماية.

التدريب المُعلِّم: حيلةٌ تُسرّع التعلّم

في تدريب المُفكِّك، يستخدم الباحثون حيلةً ذكيّةً تُسمى «تدريب المُعلِّم» (Teacher Forcing).

في الاستخدام الحقيقي، المُفكِّك يولّد الكلمات واحدةً تلو الأخرى، حيث كلّ كلمةٍ تعتمد على الكلمات السابقة التي ولّدها هو نفسه. لكن أثناء التدريب، إذا اعتمدنا على هذا، فإنّ النموذج قد يتراكم أخطاؤه، وتصبح الجمل سيّئةً جدًا.

الحلّ: أثناء التدريب، نُعطي النموذج الكلمات الصحيحة (من البيانات) بدلًا من الكلمات التي ولّدها بنفسه. كأنّ المعلّم يُمسك بيد التلميذ ويرشده. هذا يُسرّع التعلّم بشكلٍ كبير.

التشبيه: تخيّل أنّك تتعلّم العزف على البيانو. في البداية، يجلس بجانبك معلّمٌ ماهر، ويرشدك إلى أيّ مفتاحٍ تضغط. بعد أن تتعلّم القطعة، يتركك تعزف وحدك. تدريب المُعلِّم هو هذه المرحلة المرشدة.

الإسقاط: لماذا «نتلف» النموذج عمدًا؟

من المفارقات في تدريب الشبكات العصبية أنّنا نُتلف النموذج عمدًا أثناء التدريب! نستخدم تقنيّةً تُسمى «الإسقاط» (Dropout)، حيث نُلغي عشوائيًا بعض «العصبونات» في كلّ خطوة.

لماذا نفعل هذا؟ لمنع النموذج من «الحفظ». لو حفظ النموذج بياناته بالحرف، فإنّه سيُؤدّي بشكلٍ ممتازٍ على البيانات التي رآها، لكنّه سيفشل على بياناتٍ جديدة. هذه مشكلة «الإفراط في التطابق» (Overfitting).

الإسقاط يُجبر النموذج على عدم الاعتماد على عصبونٍ بعينه. كلّ عصبونٍ يجب أن يكون قادرًا على العمل حتى لو غاب جيرانه. النتيجة: نموذجٌ أكثر مرونةً وقدرةً على التعميم.

التشبيه: تخيّل فريقًا رياضيًا يتدرّب. المدرّب يتعمّد أحيانًا منع لاعبٍ من المشاركة في التدريب، حتى يتعلّم بقيّة الفريق العمل دون الاعتماد عليه. هذا يجعل الفريق كاملًا أقوى.

الأجهزة: كم تحتاج من حواسيب؟

في الورقة الأصلية، تدرّب النموذج «الأساس» على ٨ بطاقات رسومات (GPUs) من نوع Nvidia P100 لمدّة ١٢ ساعة. النموذج «الكبير» احتاج ٨ بطاقاتٍ لمدّة ٣.٥ يوم. هذه أرقامٌ متواضعةٌ بمقاييس اليوم، لكنّها كانت معقولةً عام ٢٠١٧.

اليوم، تدريب نموذج GPT-4 يحتاج إلى آلاف بطاقات الرسومات لأشهر متواصلة. التكلفة تُقدَّر بمئات الملايين من الدولارات. هذا تحوّلٌ هائل في حجم الموارد المطلوبة لبناء نماذجٍ متقدّمة.

السبب في هذا التضخّم: النماذج تكبر، والبيانات تكبر، والقدرة الحسابية المطلوبة تكبر بالتناسب.

النتائج التي صدمت العالم

ما أعلنه فاسواني وزملاؤه في ورقتهم لم يكن مجرّد بنيةٍ جديدة، بل تحسّنٌ هائلٌ في الأرقام. استخدموا مقياسًا يُسمى BLEU score لتقييم جودة الترجمة (يُقاس من ٠ إلى ١٠٠، حيث ١٠٠ ترجمةٌ مثاليّة).

في الترجمة من الإنجليزية إلى الألمانية، حقّق المحوّل درجة ٢٨.٤ — متجاوزًا أفضل النماذج السابقة بأكثر من نقطتين. وفي الإنجليزية إلى الفرنسية، حقّق ٤١.٨ — رقمٌ قياسيٌّ جديد.

الأهمّ من الأرقام: تدريبه استغرق وقتًا أقلّ بكثير. النماذج السابقة كانت تحتاج إلى أسابيع. المحوّل الأساسيّ تدرّب في ١٢ ساعة. هذا التحسّن في الكفاءة هو ما أذهل المجتمع البحثي.

﴿وَقُل رَّبِّ زِدْنِي عِلْمًا﴾

في الآية الكريمة، يأمر الله نبيّه ﷺ بأن يدعو ربّه قائلًا: «ربّ زدني علمًا». لاحظ التركيب: «زدني». الزيادة تعني أنّ هناك علمًا سابقًا، ونريد أكثر. التعلّم لا يتوقّف. كلّما زاد علم الإنسان، أدرك أكثر مدى جهله، فطلب المزيد.

في الذكاء الاصطناعي، التدريب أيضًا لا يتوقّف. النموذج يبدأ بـ«علمٍ صفر» (أوزانٌ عشوائية)، ومع كل جملةٍ يراها، يزداد علمه قليلًا. لا توجد لحظةٌ يقول فيها النموذج: «انتهيتُ من التعلّم». التحسّن مستمرّ، إن أُعطي مزيدًا من البيانات والوقت.

هذه روحٌ علميّةٌ نبيلة: العلم لا ينتهي، والتعلّم رحلةٌ مدى الحياة. هذا ما تعلّمه نماذجنا، وهذا ما يجب أن نتعلّمه نحن البشر أيضًا.

وقفة شخصية: تدريب نموذجٍ في مختبري

في مختبري بجامعة ميشيغان، دربتُ نموذج محوّلاتٍ على بياناتٍ بيولوجيّة. التدريب استغرق أسبوعًا كاملًا على ٤ بطاقات رسومات. كنتُ أراقب «منحنى الخسارة» كلّ ساعة، أحيانًا في منتصف الليل. كان شعورًا غريبًا: أرى رقمًا ينخفض ببطء، وأعلم أنّ خلف هذا الرقم نموذجًا «يفهم» شيئًا لم يكن يفهمه قبل ساعات.

في اليوم الخامس، حدث شيءٌ مذهل. الخسارة انخفضت فجأةً إلى نصف قيمتها السابقة. كأنّ النموذج «اكتشف» شيئًا. في علم التعلّم العميق، نُسمّي هذه اللحظات «نقاط الانكسار» (Phase Transitions). النموذج يعبر عتبةً معيّنةً ويصل إلى مستوى فهمٍ جديد.

كنتُ أستمتع بهذه اللحظات أكثر من أيّ شيءٍ آخر في عملي. لحظة أن «يفهم» نموذجٌ شيئًا جديدًا — هذا هو السحر الحقيقيّ للذكاء الاصطناعي.

ما القادم؟

الآن نفهم البنية، ونفهم التدريب. لكنّ السؤال الأكبر: لماذا كانت هذه الورقة ثوريّةً إلى هذا الحدّ؟ ما الذي ميّزها عن آلاف الأوراق الأخرى التي تُنشَر كلّ عام؟

في الفصل القادم، سنُجيب على هذا السؤال. سنرى لماذا تحوّلت ورقةٌ علميّةٌ من ١٥ صفحة إلى نقطة تحوّلٍ في تاريخ الذكاء الاصطناعي.

الفصل العاشر: ما الذي جعل هذه الورقة ثوريّة؟

﴿يَرْفَعِ اللَّهُ الَّذِينَ آمَنُوا مِنكُمْ وَالَّذِينَ أُوتُوا الْعِلْمَ دَرَجَاتٍ﴾

— سورة المجادلة: ١١

كل عام تُنشَر آلاف الأوراق العلميّة في مجال الذكاء الاصطناعي. معظمها يُقرأ من بضعة باحثين، ويُنسى. بعضها يُحدِث تأثيرًا في مجالٍ ضيّق. لكنّ نادرًا، نادرًا جدًا، تظهر ورقةٌ تُغيّر المجال كاملًا.

ورقة «الانتباه هو كلّ ما تحتاجه» كانت واحدةً من تلك الأوراق النادرة. اليوم، بعد قرابة عقدٍ من نشرها، يمكننا أن نتأمّل بهدوء: ما الذي جعلها ثوريّةً إلى هذا الحدّ؟ ما هي الخصائص التي ميّزتها عن غيرها؟

في هذا الفصل، سنحلّل خمس خصائصَ جوهريّة أعطت الورقة قوّتها الباقية.

الخاصّيّة الأولى: السرعة — كسر قيد التتابع

كما رأينا في الفصل الثاني، النماذج السابقة (RNN و LSTM) كانت بطيئةً بشكلٍ متأصّل. كانت تعالج الكلمات واحدةً تلو الأخرى، ولم يكن من الممكن تسريعها بإضافة المزيد من العتاد.

المحوّل غيّر هذا تمامًا. لأنّ الانتباه يُحسَب لكلّ الكلمات بالتوازي، فإنّه يستفيد من بطاقات الرسومات الحديثة (GPUs) التي صُمِّمت أصلًا للحساب المتوازي.

الأرقام كانت مذهلة. في الورقة، أظهر فاسواني وزملاؤه أنّ نموذج المحوّل تدرّب في «جزءٍ صغيرٍ» من الوقت الذي كانت تحتاجه النماذج السابقة. تخفيضٌ بنسبة ١٠٠٠٪ أحيانًا. ما كان يستغرق أسابيعَ أصبح يحتاج ساعات.

هذه السرعة فتحت بابًا جديدًا: أصبح من الممكن تجربة أفكارٍ كثيرة بسرعة، وتدريب نماذج أكبر بكثير. لو كانت النماذج لا تزال بطيئةً مثل LSTM، لما رأينا GPT-3 و GPT-4 أبدًا. السرعة هي ما جعل الحجم ممكنًا.

الخاصّيّة الثانية: الجودة — تحطيم الأرقام القياسيّة

السرعة وحدها لا تكفي. كان يمكن للمحوّل أن يكون «أسرع لكن أسوأ». لكنّه لم يكن. كان أسرع وأفضل في آنٍ معًا.

في معايير الترجمة الآلية المعروفة، تجاوز المحوّل أفضل النماذج السابقة بهامشٍ كبير. هذا في حدّ ذاته أمرٌ نادر. عادةً، التحسينات في الذكاء الاصطناعي تأتي بنسبٍ صغيرة (٠.٠٥٪ هنا، ١٪ هناك). لكنّ المحوّل قفز قفزةً كبيرة، وفي نفس الوقت كان أبسط بنيةً وأسرع تدريبًا.

هذه «الثلاثيّة الذهبيّة» — أبسط، أسرع، أفضل — هي ما يحلم بها كل باحثٍ ولا يحقّقها إلا قلّة.

الخاصّيّة الثالثة: القابليّة للتوسّع — كلّما كبر، تحسّن

هنا تكمن القوّة الأعمق للمحوّل. اكتشف الباحثون لاحقًا قانونًا مدهشًا يُسمى «قوانين التوسّع» (Scaling Laws): كلّما زدتَ حجم النموذج، وزدتَ كمّيّة البيانات، وزدتَ القدرة الحسابيّة، تحسّن الأداء بشكلٍ متوقّع وقابلٍ للقياس.

هذا لم يكن صحيحًا للنماذج السابقة. LSTM كانت تصل إلى «حدّ أعلى»، حيث إضافة المزيد من المعاملات لا تُحسّن النتائج. لكنّ المحوّلات؟ كلّما كبرت، تحسّنت.

النتيجة المباشرة: سباقٌ نحو التوسّع. نموذج فاسواني الأصلي كان لديه ٦٥ مليون معامل (parameter). BERT كان لديه ٣٤٠ مليون. GPT-2 كان ١.٥ مليار. GPT-3 كان ١٧٥ مليار. GPT-4 يُقدَّر أنّه يحوي تريليونات. كلّ زيادةٍ جلبت قدراتٍ جديدة لم تكن موجودةً في الحجم السابق.

التشبيه: تخيّل بذرةً صغيرة. كلّما سقيتَها أكثر وأعطيتَها أرضًا أوسع، نمت أكبر. لكنّ بعض البذور لها سقفٌ طبيعي — تنمو إلى متر، ثم تتوقّف. بذرة المحوّل كأنّها «شجرةٌ ساحرة»: لا سقف لنموّها. أعطها مزيدًا من الموارد، تكبر، وتُثمر فاكهةً جديدة.

الخاصّيّة الرابعة: العموميّة — الفكرة تنتقل عبر المجالات

هذا، بالنسبة لي، هو الأمر الأكثر إثارةً للدهشة. آلية الانتباه ليست خاصّةً باللغة. إنّها فكرةٌ عامّة تنطبق على أيّ مجموعةٍ من العناصر التي تتفاعل.

في السنوات التي تلت الورقة، انتشر المحوّل إلى مجالاتٍ لم يحلم بها فاسواني وزملاؤه:

- **الرؤية الحاسوبيّة (Computer Vision)**: نموذج Vision Transformer (ViT) من جوجل عام ٢٠٢٠ أثبت أنّ المحوّلات تتفوّق على الشبكات التلافيفيّة (CNNs) في تصنيف الصور.
- **علوم البروتينات**: AlphaFold 2 من DeepMind استخدمت آلية الانتباه للتنبّؤ ببنية البروتينات. هذا قاد إلى جائزة نوبل في الكيمياء عام ٢٠٢٤.

- **الموسيقى**: نماذج مثل MusicLM تُولّد موسيقى من وصفٍ نصّيّ، باستخدام محوّلات.

- **الرياضيّات**: نماذج تحلّ معادلاتٍ رياضيّة معقّدة وتثبت نظريّات.

- **علم الجينوم**: في مختبري، نطبّق المحوّلات على بيانات التعبير الجينيّ والبيانات المكانيّة للخلايا.

- **القيادة الذاتيّة**: تيسلا و Waymo يستخدمان المحوّلات لفهم محيط السيّارة.

كلّ هذه التطبيقات تستخدم البنية الأساسيّة ذاتها، مع تعديلاتٍ بسيطة. هذا «التعميم» نادرٌ جدًا في تاريخ العلوم.

الخاصّيّة الخامسة: البساطة — الأناقة الرياضيّة

الخاصّيّة الأخيرة، وربّما الأكثر أهمّيّةً من الناحية الفلسفيّة، هي البساطة.

ورقة فاسواني لا تتجاوز ١٥ صفحة. الفكرة الأساسيّة يمكن شرحها (كما فعلتُ في الفصول السابقة) بدون رياضيّاتٍ معقّدة. البنية الكاملة يمكن رسمها على ورقةٍ واحدة.

قارن هذا بنماذج LSTM المعقّدة، أو بالشبكات التلافيفيّة الهرميّة، أو بالنماذج الهجينة التي كانت سائدةً قبل ٢٠١٧. كانت تلك النماذج معقّدةً معماريًا، صعبة الفهم، ومليئة بالحيل التقنيّة.

المحوّل أناقةٌ في البساطة. هو يقول: «خذ آليّةً واحدة (الانتباه)، وكرّرها مع تطبيع. هذا كلّ شيء». في الفيزياء، يُقال إنّ المعادلات الجميلة هي المعادلات الصحيحة. في الذكاء الاصطناعي، البنى البسيطة هي البنى التي تستمرّ.

التشبيه: العجلة والمحرّك البخاري

دعني أُختم هذا الفصل بتشبيهٍ عميق. في تاريخ التكنولوجيا، هناك اختراعاتٌ معيّنة تُغيّر كلّ شيء بعدها. العجلة. المحرّك البخاري. الترانزستور. الإنترنت.

ما يجعل هذه الاختراعات «عظيمة» هو أنّها لا تحلّ مشكلةً واحدةً فقط. إنّها تخلق إمكانيّاتٍ كاملة لم تكن ممكنةً قبلها. العجلة لم تخترع السيّارات والقطارات فقط؛ أعادت تشكيل الجغرافيا البشريّة. المحرّك البخاريّ لم يخترع المصنع فقط؛ أعاد تشكيل الاقتصاد والمدن.

المحوّل هو في هذه الفئة. لم يحسّن الترجمة فحسب. خلق إمكانيّةً كاملةً لنوعٍ جديد من الذكاء الاصطناعي. ChatGPT وصورها التوليديّة و AlphaFold و آلاف التطبيقات الأخرى — كلّها أبناء هذا الاختراع.

﴿يَرْفَعِ اللَّهُ الَّذِينَ آمَنُوا مِنكُمْ وَالَّذِينَ أُوتُوا الْعِلْمَ دَرَجَاتٍ﴾

في الآية الكريمة، يربط الله بين الإيمان والعلم، ويرفع منزلة أهلهما درجات. هذا الربط بين الإيمان والعلم له دلالةٌ عميقة: العلم ليس نقيضًا للإيمان، بل أحد سُبل تعظيم الخالق وتدبّر آياته في الكون.

حين أتأمّل ورقة المحوّلات، أرى فيها آيةً من آيات الله في عقول البشر. هذه القدرة على ابتكار آليّاتٍ تُحاكي بعض جوانب الإدراك البشري — هي هبةٌ من الله، تستحقّ أن نستخدمها لخير البشريّة.

كثيرون من المسلمين يخافون من الذكاء الاصطناعي، أو يعتبرونه «صناعةً غربيّة». لكنّني أنظر إلى الأمر بشكلٍ مختلف. التاريخ الإسلامي مليءٌ بالعلماء الذين تعلّموا من الإغريق والهنود والفرس، ثم طوّروا وأضافوا. الجزء العربي الأصيل في التاريخ العلمي العالمي كبيرٌ جدًا. لماذا لا يكون لنا اليوم دورٌ مماثل؟

الورقة كُتبت بالإنجليزيّة، لكنّ الأفكار التي حملتها ملكٌ للبشريّة جمعاء. ما يعنيني، كباحثٍ عربيٍّ مسلم، هو أن نُسهم — لا أن نتفرّج.

وقفة شخصيّة: لحظة استيعاب الثورة

أتذكّر اليوم الذي خرج فيه ChatGPT في نوفمبر ٢٠٢٢. كنتُ في مكتبي بجامعة ميشيغان، وأطلق لي زميلٌ رابطًا. حين جرّبتُه أوّل مرّة، وسألتُه سؤالًا في علم الأحياء الحاسوبي، وأعطاني إجابةً منطقيّة، شعرتُ أنّ شيئًا تغيّر في العالم.

لاحقًا، فهمتُ أنّ ChatGPT لم يكن «مفاجأة» — كان نتيجةً متراكمةً لخمس سنواتٍ من العمل على المحوّلات. لكنّ الجمهور رآها كانفجار. هذا تذكير: الثورات العلميّة تبدأ صامتةً في الأوراق البحثيّة، ثم تظهر فجأةً للعامّة بعد سنوات.

ورقة «الانتباه هو كلّ ما تحتاجه» كانت اللحظة الصامتة. ChatGPT كان الانفجار. وما بينهما، كانت سنواتٌ من العمل الدؤوب لمئات الباحثين الذين بنوا على فكرة فاسواني وأخذوها إلى آفاقٍ لم يتخيّلها.

ما القادم؟

في الفصل القادم، سنرسم خطًّا زمنيًّا واضحًا: من ورقة ٢٠١٧ إلى ChatGPT. سنرى المحطّات الأساسيّة: BERT، و GPT-1, GPT-2, GPT-3، و T5، و AlphaFold 2، و GPT-4، و Claude. سنفهم كيف تطوّرت هذه السلسلة، وأين نقف اليوم، وأين قد نكون غدًا.

الفصل الحادي عشر: من المحوّل إلى ChatGPT — الخطّ الزمني

﴿وَفَوْقَ كُلِّ ذِي عِلْمٍ عَلِيمٌ﴾

— سورة يوسف: ٧٦

في عام ٢٠١٧، كانت ورقة فاسواني وزملائه بذرةً صغيرة. اليوم، بعد قرابة عقد، أنبتت تلك البذرة غابةً كاملةً من النماذج، تشكّل ما يُعرف اليوم بـ«ثورة الذكاء الاصطناعي التوليدي». في هذا الفصل، سنرسم خطًّا زمنيًّا واضحًا لتطوّر هذه السلسلة، من ٢٠١٧ إلى يومنا هذا.

٢٠١٧: الورقة التأسيسيّة

في يونيو ٢٠١٧، نُشرت ورقة *Attention Is All You Need* في مؤتمر NeurIPS. كانت الورقة موجّهةً إلى الترجمة الآلية. لم يكن مؤلفوها يعلمون أنّهم وضعوا الأساس لكلّ ما سيأتي بعد ذلك.

في الأشهر التي تلت النشر، بدأ الباحثون في استكشاف إمكانيّات الفكرة. أصبح من الواضح أنّ المحوّل ليس مجرّد بديلٍ عن LSTM، بل بنيةٌ جديدةٌ لها قدراتٌ مختلفة جوهريًّا.

٢٠١٨: BERT — قراءة عميقة من الجانبين

في أكتوبر ٢٠١٨، أعلنت جوجل عن نموذج BERT (Bidirectional Encoder Representations from Transformers). الفكرة كانت بسيطة لكن قويّة: استخدم المُشفِّر فقط من المحوّل، وادرّبه على فهم النصوص بشكلٍ ثنائيّ الاتّجاه (يقرأ من اليمين إلى اليسار ومن اليسار إلى اليمين معًا).

كيف تدرّب BERT؟ بمهمّة ذكيّة تُسمى «النمذجة المُقنَّعة» (Masked Language Modeling). يُؤخَذ نصّ، تُحذَف منه ١٥٪ من الكلمات بشكلٍ عشوائي، ويُطلَب من النموذج أن يخمّن الكلمات المحذوفة. مثلًا: «ذهب الطفل إلى ____ ليتعلّم». النموذج يجب أن يتنبّأ بـ«المدرسة».

هذه المهمّة بسيطة، لكنّها تُجبر النموذج على فهم كلّ ما يحيط بالكلمة المحذوفة، مما يبني فهمًا عميقًا للّغة.

النتيجة: BERT حطّم أرقامًا قياسيّةً في مجالاتٍ متعدّدة — تصنيف النصوص، الإجابة عن الأسئلة، استخراج المعلومات. أصبح BERT أساسًا لمحرّك بحث جوجل نفسه.

٢٠١٨–٢٠٢٠: GPT-1، GPT-2، GPT-3 — قوّة التوليد

في الجهة الأخرى، كانت OpenAI تستكشف نهجًا مختلفًا. في يونيو ٢٠١٨، أصدرت GPT-1 (Generative Pre-trained Transformer). الفكرة: استخدم المُفكِّك فقط من المحوّل، وادرّبه على التنبّؤ بالكلمة التالية في النصّ.

مثلًا: «الشمس تشرق في ___». النموذج يجب أن يتنبّأ بـ«الصباح» أو «الشرق».

هذه المهمّة، رغم بساطتها، تُجبر النموذج على تعلّم الكثير: قواعد اللغة، الحقائق العامّة، أسلوب الكتابة، إلخ.

في فبراير ٢٠١٩، صدر GPT-2 بـ١٠٥ مليار معامل (أربعة عشر ضعف GPT-1). أحدث ضجّةً في الإعلام لأنّ OpenAI رفضت في البداية إصدار النسخة الكاملة، خوفًا من «إساءة استخدامها». كان النموذج قادرًا على كتابة مقالاتٍ مقنعةٍ من سطرٍ واحدٍ من المُدخَل.

في يونيو ٢٠٢٠، صدر GPT-3 بـ١٧٥ مليار معامل (مئة وعشرة أضعاف GPT-2). كان قفزةً نوعيّة. أصبح النموذج قادرًا على:

- كتابة أكوادٍ برمجيّة من وصفٍ بسيط.
- ترجمة بين لغاتٍ متعدّدة دون تدريبٍ خاصّ.

- كتابة قصصٍ بأساليبَ مختلفة.
- الإجابة عن أسئلةٍ معقّدة.

كانت GPT-3 لحظةً فارقة. أوّل مرّةٍ يشعر فيها كثيرٌ من الباحثين أنّ الذكاء الاصطناعي يقترب من «الذكاء العامّ».

٢٠١٩–٢٠٢٠: T5 و XLNet و RoBERTa — تنويعات

بين BERT و GPT، ظهرت نماذج تجمع بين الجانبين أو تحسّن في أحدهما:

- **T5 (Text-to-Text Transfer Transformer)** من جوجل ٢٠١٩: استخدم البنية الكاملة (المُشفِّر + المُفكِّك)، وحوّل كلّ مهمّةٍ إلى مشكلة «نصٍّ إلى نصّ».
- **XLNet** من كارنيغي ميلون ٢٠١٩: حاول دمج مزايا BERT و GPT.
- **RoBERTa** من Facebook ٢٠١٩: نسخةٌ مُحسَّنة من BERT بتدريبٍ أفضل وبياناتٍ أكثر.

كلّ هذه النماذج كانت تستكشف الفضاء الذي فتحته ورقة فاسواني.

٢٠٢١: AlphaFold 2 — الانتباه يُحوِّل إلى علم البيولوجيا

في عام ٢٠٢١، نشرت DeepMind نموذج AlphaFold 2، الذي حلّ مشكلة «طيّ البروتينات» (Protein Folding) — وهي مشكلةٌ ظلّت مفتوحةً لخمسين عامًا في علم الأحياء.

البروتينات سلاسل من الأحماض الأمينية، تنطوي على نفسها لتأخذ بنيةً ثلاثيّة الأبعاد محدّدة. هذه البنية تحدّد وظيفة البروتين. التنبّؤ بالبنية من التسلسل كان «الكأس المقدّسة» في علم البيولوجيا الحاسوبي.

AlphaFold 2 استخدمت آلية الانتباه بشكلٍ مبتكر، وحقّقت دقّةً مذهلة. أحدثت ثورةً في علم الأدوية، وفتحت أبوابًا لاكتشافاتٍ طبّيّةٍ جديدة. حصل العاملون عليها على جائزة نوبل في الكيمياء عام ٢٠٢٤.

كان هذا تأكيدًا قويًّا لما قلتُه في الفصل السابق: المحوّل ليس أداةً للّغة فقط. إنّه أداةٌ عامّة لفهم العلاقات بين العناصر.

٢٠٢٢: ChatGPT — اللحظة التي عرف فيها العالم

في ٣٠ نوفمبر ٢٠٢٢، أطلقت OpenAI خدمة ChatGPT للجمهور. في غضون أسبوع، تجاوز عدد المستخدمين مليون شخص. خلال شهرين، تجاوز ١٠٠ مليون. كانت أسرع منتجٍ يصل إلى ١٠٠ مليون مستخدم في تاريخ التكنولوجيا.

ChatGPT لم يكن مجرّد GPT-3. كان مدرّبًا بشكلٍ خاصّ على الحوار، باستخدام تقنيّةٍ تُسمى RLHF (Reinforcement Learning from Human Feedback) — تعلّم تعزيزيّ من ملاحظات البشر. آلاف العمّال البشر قيّموا إجاباته، فتعلّم النموذج أن يكون مفيدًا، وآمنًا، وودودًا.

اللحظة التي خرج فيها ChatGPT كانت لحظةً ثقافيّة بقدر ما كانت تقنيّة. فجأةً، أصبح الذكاء الاصطناعي حديث كلّ شخص: من الطلاب، إلى المعلّمين، إلى المديرين، إلى السياسيّين.

٢٠٢٣: GPT-4 و Claude و Gemini — السباق الكبير

في مارس ٢٠٢٣، أعلنت OpenAI عن GPT-4، الذي تجاوز سلفه بفارقٍ كبير. أصبح قادرًا على فهم الصور، وكتابة أكوادٍ معقّدة، وتمرير امتحاناتٍ مهنيّة (مثل امتحان المحاماة).

في مارس ٢٠٢٣ أيضًا، أعلنت Anthropic عن Claude، نموذجها المنافس. ركّزت Anthropic على «السلامة الدستوريّة»، حيث يلتزم النموذج بمبادئَ أخلاقيّةٍ معيّنةٍ في إجاباته.

في نهاية ٢٠٢٣، أطلقت جوجل نموذج Gemini، وفي ٢٠٢٤ أطلقت Meta نسخها المفتوحة من LLaMA.

أصبحنا في «عصر النماذج الكبيرة». كلّ شركة تكنولوجيا كبرى لها نموذجها. كلّ بضعة أشهر، نموذجٌ جديدٌ يحطّم أرقامًا قياسيّة.

٢٠٢٤-٢٠٢٦: التوسّع والتخصّص

في الفترة الأخيرة، نشهد تطوّرَين متوازيَين:

أوّلًا — التوسّع المستمرّ: نماذج أكبر، بياناتٌ أكثر، قدراتٌ جديدة. ChatGPT بات يقرأ الصور ويولّد الفيديوهات (Sora). Claude بات قادرًا على تشغيل الحاسوب. Gemini يُدمَج في كلّ منتجات جوجل.

ثانيًا — التخصّص: نماذج صغيرة لكن متخصّصة. نماذج طبّيّة، نماذج برمجيّة، نماذج علميّة. Anthropic أصدرت Claude في الكود، وOpenAI أصدرت Codex. في علم الأحياء، نماذج مثل ESM-2 و AlphaFold 3 تحدّد البنى البيولوجيّة بدقّةٍ متزايدة.

بحثي الشخصي: المحوّلات في علم الجينوم

في مختبري بجامعة ميشيغان، نطبّق المحوّلات على بياناتٍ بيولوجيّة معقّدة. مجال تخصّصي هو «علم النسخ المكاني» (Spatial Transcriptomics) — حيث نقيس تعبير الجينات في خلايا فرديّة، مع معرفة موقع كلّ خليّة في النسيج.

تخيّل أنّ كلّ خليّة هي «كلمة»، وكلّ نسيج هو «جملة». المحوّلات تُساعدنا في فهم كيف تتفاعل الخلايا مع جيرانها، وكيف يتغيّر هذا التفاعل في الأمراض مثل السرطان.

نشرنا مؤخّرًا ورقةً عن استخدام المحوّلات في تحليل بيانات سرطان الكبد. النموذج تعلّم وحده أن يكتشف أنماطًا في تفاعلات الخلايا التي يفوّتها الباحثون البشر. هذا، بالنسبة لي، هو الإنجاز الحقيقي للذكاء الاصطناعي في الطبّ: ليس استبدال الأطبّاء، بل تمكينهم من رؤية ما لم يكونوا قادرين على رؤيته.

﴿وَفَوْقَ كُلِّ ذِي عِلْمٍ عَلِيمٌ﴾

في الآية الكريمة، يذكّرنا الله بأنّ فوق كلّ صاحب علمٍ عالمًا أعلم منه. هذه آيةٌ مهمّة في عصرنا. مهما تقدّم الذكاء الاصطناعي، يبقى هناك من هو أعلم: العالم الحقيقي، الأفراد المتخصّصون، والله سبحانه وتعالى الذي علم الإنسان ما لم يعلم.

ChatGPT يُجيب عن أسئلتك، لكنّ الطبيب الذي تتعامل معه يعلم سياق حالتك. الطبيب يعالجك، لكنّ الباحث الذي اكتشف الدواء فهم آليّةً عميقة. الباحث يكتشف، لكنّ خالق الكون أتقن كلّ شيء.

هذه الهرميّة من «العلم الأعلى» تُذكّرنا بالتواضع. كلّ ما نبنيه، مهما كان متقدّمًا، يبقى محدودًا أمام عظمة الخلق.

ما القادم؟

في الفصل الأخير، سنختم رحلتنا. سنلخّص ما تعلّمناه. سنناقش حدود المحوّلات والاتّجاهات المستقبليّة. وسأُوجّه دعوةً مفتوحةً لكلّ قارئٍ عربيٍّ مهتمّ: لا تكتفِ بالقراءة، شارك في صنع المستقبل.

الفصل الثاني عشر: الخاتمة — الانتباه وما بعده

﴿قُلْ هَلْ يَسْتَوِي الَّذِينَ يَعْلَمُونَ وَالَّذِينَ لَا يَعْلَمُونَ﴾

— سورة الزمر: ٩

ها قد وصلنا إلى نهاية رحلتنا. اثنا عشر فصلًا، بدأنا فيها بسؤال بسيط: ما هي ورقة «الانتباه هو كلّ ما تحتاجه»؟ ولماذا غيّرت العالم؟

في هذا الفصل الأخير، سأفعل ثلاثة أمور: أوّلًا، أخلّص ما تعلّمناه. ثانيًا، أناقش حدود المحوّلات والاتّجاهات المستقبليّة. ثالثًا، أوجّه دعوةً مفتوحةً لكل قارئٍ عربيٍّ يصل إلى هذه الصفحات.

ما تعلّمناه في رحلتنا

دعني أُعيد سرد القصّة كاملةً في فقراتٍ قليلة.

في صيف ٢٠١٧، نشر فريقٌ من ثمانية باحثين في جوجل ورقةً قصيرةً بعنوان جريء: «الانتباه هو كلّ ما تحتاجه». الورقة اقترحت بنيةً جديدةً للذكاء الاصطناعي تُسمى «المحوّل» (Transformer)، تتخلّى عن الشبكات العصبيّة

المتكرّرة (RNN/LSTM) التي كانت سائدةً في معالجة اللغة، وتعتمد بشكلٍ كاملٍ على آليّةٍ واحدة: الانتباه الذاتي (Self-Attention).

الانتباه فكرةٌ مستوحاةٌ من الإدراك البشري. حين نقرأ جملة، لا ننظر إلى كلّ كلمةٍ بنفس الأهمّيّة. عقلنا «ينتبه» إلى الكلمات الأكثر صلةً بالفهم. آلية الانتباه نقلت هذه الفكرة إلى الآلة. كل كلمةٍ تنظر إلى كلّ الكلمات الأخرى، وتُحسَب أوزانٌ تحدّد أيّها أكثر أهمّيّة.

تقنيًا، آلية الانتباه تعتمد على ثلاثة عناصر: الاستعلام (Query)، والمفتاح (Key)، والقيمة (Value). كل كلمة تولّد هذه العناصر الثلاثة. الاستعلامات تُقارَن بالمفاتيح بالضرب النقطي، وتُحَوَّل إلى أوزانٍ بالسوفت ماكس، ثم تُستخدَم لخلط القيم.

لتقوية الفهم، استخدم فاسواني وزملاؤه «الانتباه متعدّد الرؤوس» (Multi-Head Attention)، حيث تعمل عدّة آليّاتٍ من الانتباه بالتوازي، كلّ واحدةٍ تنظر إلى الجملة من زاويةٍ مختلفة.

ولأنّ الانتباه يتجاهل الترتيب، أضافوا «الترميز الموضعي» (Positional Encoding) ليُخبر النموذج بمواقع الكلمات.

البنية الكاملة للمحوّل تتألّف من «مُشفِّر» يبني فهمًا للجملة الأصليّة، و«مُفكِّك» يولّد الجملة الجديدة. لكنّ النماذج اللاحقة (BERT، GPT) استخدمت نصف البنية فقط، حسب الحاجة.

تدريب المحوّل يحتاج إلى بياناتٍ هائلة، ودالّة خسارةٍ تُخبر النموذج بأخطائه، وعمليّة الانتشار العكسي لتحديث الأوزان. الورقة الأصليّة تدرّبت على ٤٠٥ مليون زوجٍ من الجمل في ١٢ ساعة. اليوم، النماذج الكبيرة تحتاج ملايين الدولارات وأشهرًا من الحساب.

ما جعل الورقة ثوريّةً كان السرعة، والجودة، والقابليّة للتوسّع، والعموميّة، والبساطة. هذه الخصائص الخمس فتحت بابًا لجيلٍ كاملٍ من النماذج: BERT، Gemini، Claude، ChatGPT، AlphaFold، GPT-3، GPT-2، وغيرها.

رسالة الورقة الكامنة: البساطة والتوسّع = القوّة

إذا أردتُ أن أُلخّص رسالة ورقة فاسواني في جملةٍ واحدة، لقلتُ: «البساطة، حين تُجمَع مع التوسّع، تُنتج قوّةً غير مسبوقة».

هذه الرسالة ليست خاصّةً بالذكاء الاصطناعي. هي حقيقةٌ تنطبق على كثيرٍ من مجالات الحياة. الفكرة البسيطة، حين تُكرَّر بإخلاصٍ ومثابرة، تتحوّل إلى شيءٍ عظيم. حلقات الذكر التي تُكرَّر، الصلوات اليوميّة، العادات الصغيرة المتراكمة — كلّها تطبيقاتٌ لنفس المبدأ في حياتنا الروحيّة والعمليّة.

حدود المحوّل

رغم كلّ هذه القوّة، المحوّل ليس بلا حدود. دعني أذكر أهمّ ثلاث:

الحدّ الأوّل — التكلفة الحسابيّة الكوادراتيّة: عدد العمليّات في آلية الانتباه يتناسب مع مربّع طول الجملة. لو ضاعفنا طول الجملة، تضاعفت العمليّات أربع مرّات. هذا يجعل التعامل مع نصوصٍ طويلةٍ جدًا (مثل كتابٍ كامل) مكلفًا للغاية.

الحدّ الثاني — افتقار التفكير الحقيقي: المحوّلات تُجيد «النمذجة الإحصائيّة» للنصوص — أي تتنبّأ بالكلمة التالية بناءً على ما رأته. لكنّها لا «تفكّر» بالمعنى البشري. لا تخطّط، لا تستنتج بشكلٍ منطقي، لا تعرف ما الذي لا تعرفه. هذه الحدود تظهر في «الهلوسة» (Hallucinations) — حين يخترع النموذج معلوماتٍ غير صحيحة بثقة.

الحدّ الثالث — الاعتماد على البيانات المُعدّة بشريًّا: النماذج الحاليّة تتعلّم من نصوصٍ كتبها البشر. إذا أردنا ذكاءً اصطناعيًّا يتعلّم بشكلٍ مستقلّ، نحتاج إلى آليّاتٍ مختلفة.

الاتّجاهات المستقبليّة

أين يتّجه المجال؟ بعض التطوّرات الحاليّة:

نماذج فضاء الحالة (State Space Models): مثل Mamba، تحاول تحقيق فوائد المحوّلات بتكلفةٍ حسابيّةٍ أقلّ. تعمل بشكلٍ خطّي بدلًا من كوادراتي.

الانتباه المتفرّق (Sparse Attention): يحاول تقليل العمليّات بالتركيز على «الكلمات المهمّة» فقط بدلًا من كلّ الكلمات.

النماذج الهجينة: تجمع بين المحوّلات وبنىً أخرى. مثلًا، نماذج تستخدم محوّلات على المستوى الكلامي و RNN على المستوى الكلمي.

الذكاء الوكيل (Agentic AI): نماذج لا تكتفي بالإجابة، بل تخطّط، وتتّخذ قرارات، وتنفّذ مهامّ متعدّدة الخطوات. ChatGPT و Claude بدأت تتّجه في هذا الاتّجاه.

المحوّلات في علم الأحياء: نماذج تفهم الحمض النوويّ، البروتينات، الخلايا، والأنسجة. هذا مجالي، وأرى مستقبلًا مذهلًا فيه.

الذكاء العامّ (AGI): السؤال الأكبر — هل ستصل النماذج إلى ذكاءٍ يضاهي البشر في كلّ المهامّ؟ بعض الباحثين يعتقدون أنّنا قريبون. آخرون يرون أنّ هناك عقباتٍ جوهريّةً ما زالت قائمة. الجواب الأمين: لا أحد يعرف.

دعوةٌ مفتوحة للقارئ العربي

أصل الآن إلى الجزء الذي أعتزّ به أكثر من غيره في هذا الكتاب. أنتَ، القارئ العربي الذي وصلت إلى هذه الصفحات: أتوجّه إليك بدعوةٍ مباشرة.

كثيرٌ منّا، نحن العرب، نقرأ عن الذكاء الاصطناعي بمنظور المتفرّج. نتابع ما يُصنَع في وادي السيليكون والصين، ونتساءل: لماذا لسنا منهم؟ لماذا لم نُسهم؟

الإجابة بسيطة: لأنّنا لم نقرّر أن نُسهم بعد. هذا الكتاب — هذه الصفحات التي بين يديك — هي بداية. هي تثبت أنّ المعرفة التقنيّة العميقة يمكن أن تُكتَب باللغة العربيّة، وأن تُنقَل إلى عقولٍ عربيّة، وأن تُلهم جيلًا جديدًا.

إن كنتَ طالبًا، تعلّم البرمجة. لا يكفي أن تفهم النظريّة. ابدأ بـPython، بـPyTorch، بـHugging Face. درّب نماذجك الصغيرة. اكسر شيئًا، ثمّ صلّحه. تعلّم بالعمل.

إن كنتَ باحثًا، انشر بالعربيّة بقدر ما تنشر بالإنجليزيّة. اكتب مدوّناتٍ تُلخّص الأوراق الجديدة. شارك في المجتمعات العربيّة على تويتر و LinkedIn. أنتَ نموذجٌ يحتاجه الجيل التالي.

إن كنتَ مهنيًّا في مجالٍ آخر — طبيبًا، مهندسًا، محاسبًا، معلّمًا — فكّر كيف يمكن للذكاء الاصطناعي أن يخدم مجالك. أنتَ تعرف مشاكل مجالك أكثر من أيّ مهندسٍ في وادي السيليكون. ربط معرفتك التخصّصيّة بهذه الأدوات الجديدة قد يُنتج شيئًا فريدًا.

إن كنتَ والدًا، علّم أبناءك أنّ الذكاء الاصطناعي ليس أعجوبةً غامضة. إنّه أداة. ساعدهم على فهمها، استخدامها بحكمة، والإسهام في تطويرها.

إن كنتَ ثريًا، استثمر في باحثين عرب. ادعم مختبراتٍ بحثيّةٍ في جامعاتنا. ابنِ شركاتٍ ناشئةً عربيّة. الذهب الحقيقي في عصر الذكاء الاصطناعي ليس النفط — بل الباحث الذي يحلّ مشكلةً جديدة.

وقفةٌ شخصيّة أخيرة

كباحثٍ يمنيّ يعيش في الولايات المتّحدة منذ سنوات، أحمل معي دائمًا إحساسًا بالمسؤوليّة. كلّ ورقةٍ أنشرها، أتأمّل: هل هذه الورقة تخدم البشريّة كاملةً؟ هل تخدم بلدي؟ هل تخدم الأمّة العربيّة والإسلاميّة؟

كتبتُ هذا الكتاب لسببٍ واحد: أن أُفكّك حاجزًا. الحاجز الذي يمنع كثيرًا من إخواني وأخواتي من الاقتراب من هذا المجال. الحاجز الذي يقول: «هذا للغرب، ليس لنا». الحاجز الذي يجعل المصطلحات الإنجليزيّة تبدو كأنّها سحرٌ غامض.

لكنّ الذكاء الاصطناعي ليس سحرًا. هو عملٌ بشريٌّ، يقوم به أُناسٌ مثلي ومثلك، يحملون الأفكار، ويخطئون، ويتعلّمون، ويُسهمون. لا فرق بين باحثٍ في ميشيغان وباحثٍ في صنعاء أو القاهرة أو الرياض، إلا الفرص.

ولذلك، أنهي هذا الكتاب بدعاء: اللهمّ علّمنا ما ينفعنا، وانفعنا بما علّمتنا، وزدنا علمًا. اللهمّ اجعل هذه الأمّة أمّةً تُسهم في كلّ علمٍ نافع، وفي كلّ خيرٍ للبشريّة جمعاء. اللهمّ اهدنا إلى أحسن الأخلاق، فإنّه لا يهدي لأحسنها إلاّ أنت، واصرف عنّا سيّئها، فإنّه لا يصرف عنّا سيّئها إلاّ أنت.

والله أعلم.

الفصل الثالث عشر: المراجع وقراءاتٌ للاستزادة

﴿وَمَا أُوتِيتُم مِّنَ الْعِلْمِ إِلَّا قَلِيلًا﴾

— سورة الإسراء: ٨٥

كلّ كتابٍ هو نقطة بداية، لا نقطة نهاية. ما قدّمتُه لك في الفصول الاثني عشر السابقة هو خلاصةٌ مبسّطةٌ لما تعلّمتُه ودرستُه على مدى سنوات. لكنّ الموضوع أعمق وأوسع بكثير. في هذا الفصل، أضع بين يديك دليلًا مفصّلًا للقراءة الإضافيّة، مرتّبًا حسب المستوى والاهتمام.

أوّلًا: الورقة الأصليّة وما يُحيط بها

الورقة المؤسّسة:

1. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems* (*NeurIPS*), 30.

متاحة مجّانًا على arXiv: https://arxiv.org/abs/1706.03762

هذه هي الورقة التي تحدّثنا عنها طوال الكتاب. أنصحك بقراءتها بنفسك بعد إنهاء هذا الكتاب — ستجدها أسهل ممّا تتخيّل.

شروحات بصريّة ممتازة باللغة الإنجليزيّة:

1. Alammar, J. (2018). "The Illustrated Transformer". مدوّنةٌ شخصيّةٌ تشرح المحوّل بصريًّا بشكلٍ مذهل. https://jalammar.github.io/illustrated-transformer/

2. Karpathy, A. (2022). "Let's Build GPT From Scratch". سلسلة فيديوهاتٍ على يوتيوب من أحد أبرز الباحثين في OpenAI سابقًا.

ثانيًا: المحطّات الرئيسيّة في تطوّر النماذج

BERT:

1. Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *arXiv*:1810.04805.

سلسلة GPT:

1. Radford, A., Narasimhan, K., Salimans, T., & Sutskever, I. (2018). Improving Language Understanding by Generative Pre-Training (GPT-1).

2. Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., & Sutskever, I. (2019). Language Models are Unsupervised Multitask Learners (GPT-2).

3. Brown, T. B., et al. (2020). Language Models are Few-Shot Learners (GPT-3). *NeurIPS* 2020.

4. OpenAI. (2023). GPT-4 Technical Report. *arXiv*: 2303.08774.

T5 و RoBERTa:

1. Raffel, C., et al. (2020). Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer (T5). *Journal of Machine Learning Research*.

2. Liu, Y., et al. (2019). RoBERTa: A Robustly Optimized BERT Pretraining Approach. *arXiv*:1907.11692.

ثالثًا: المحوّلات في علوم الأحياء

AlphaFold:

1. Jumper, J., et al. (2021). Highly accurate protein structure prediction with AlphaFold. *Nature*, 596 (7873), 583-589.

هذه الورقة حصل عليها أصحابها على جائزة نوبل في الكيمياء عام ٢٠٢٤.

1. Abramson, J., et al. (2024). Accurate structure prediction of biomolecular interactions with AlphaFold 3. *Nature*.

نماذج البروتينات الأخرى:

1. Lin, Z., et al. (2023). Evolutionary-scale prediction of atomic-level protein structure with a language model (ESM-2). *Science*.

علم النسخ المكاني والمحوّلات:

1. Cui, H., et al. (2024). scGPT: Toward Building a Foundation Model for Single-Cell Multi-omics Using Generative AI. *Nature Methods*.

2. أوراقي البحثيّة في مختبر جامعة ميشيغان حول تطبيق المحوّلات على بيانات سرطان الكبد، متاحة عبر صفحتي على Google Scholar.

رابعًا: المحوّلات في الرؤية الحاسوبيّة

1. Dosovitskiy, A., et al. (2021). An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale (ViT). *ICLR* 2021.

2. Liu, Z., et al. (2021). Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. *ICCV* 2021.

خامسًا: تطوّرات حديثة (٢٠٢٤-٢٠٢٦)

نماذج فضاء الحالة:

1. Gu, A., & Dao, T. (2024). Mamba: Linear-Time Sequence Modeling with Selective State Spaces. *ICLR* 2024.

RoPE (الترميز الموضعي الدوّار):

1. Su, J., et al. (2024). RoFormer: Enhanced Transformer with Rotary Position Embedding. *Neurocomputing*.

تحسينات تدريب النماذج الكبيرة:

1. Hoffmann, J., et al. (2022). Training Compute-Optimal Large Language Models (Chinchilla). *arXiv*:2203.15556.

2. Kaplan, J., et al. (2020). Scaling Laws for Neural Language Models. *arXiv*:2001.08361.

سادسًا: مصادر للقارئ المبتدئ بالعربيّة

للأسف، المراجع العربيّة في هذا المجال شحيحة. لكنّ هناك جهودًا حميدة:

- منصّة «إدراك» — تقدّم دوراتٍ مجّانيّة في الذكاء الاصطناعي وأساسيّاته.
- قناة «أحمد علاء» على يوتيوب — دروسٌ بالعربيّة في تعلّم الآلة والشبكات العصبيّة.
- مدوّنة «أكاديميّة حسوب» — مقالاتٌ تقنيّة باللغة العربيّة.
- موقع «الذكاء الاصطناعي بالعربيّة» — ترجماتٌ ومقالاتٌ مختارة.

سابعًا: مصادر للتعلّم العملي

إذا أردتَ تطبيق ما تعلّمتَ، إليك أفضل البدايات:

1. **Hugging Face Transformers**: مكتبةٌ مجّانيّة تتيح استخدام المحوّلات بسهولة. https://huggingface.co/
2. **PyTorch Tutorials**: دروسٌ رسميّةٌ من Meta AI. https://pytorch.org/tutorials/
3. **Andrej Karpathy's nanoGPT**: نموذج GPT مبسّط بحوالي ٣٠٠ سطرٍ من الكود، ممتازٌ للتعلّم. https://github.com/karpathy/nanoGPT
4. **fast.ai**: دوراتٌ مجّانيّة عمليّة في التعلّم العميق. https://www.fast.ai/

ثامنًا: مصادر روحيّة وفكريّة

العلم لا ينفصل عن المعنى. إليك بعض المراجع التي تربط بين العلوم الحديثة والتراث الإسلامي:

- ابن خلدون، المقدّمة — حول طبيعة المعرفة ومنهج العلم.
- الغزالي، إحياء علوم الدين — حول طلب العلم وآدابه.

- محمد عبد الله دراز، دستور الأخلاق في القرآن — مرجعٌ في الأخلاق.
- مالك بن نبي، مشكلة الأفكار في العالم الإسلامي — حول دور الأفكار في نهضة الأمم.
- زيد عابدين الكوكباني، الفكر العلمي عند المسلمين — تأمّلاتٌ في تاريخ العلوم الإسلاميّة.

تاسعًا: للتواصل والمتابعة

أتاحت لي وسائل التواصل الحديثة فرصةً للتفاعل مع القرّاء. إن أردتَ متابعة جديد أبحاثي وكتاباتي:

- موقعي الشخصي ومكتبتي: https://fadhlyemen.github.io/library/
- بريدي الإلكتروني: alakwaaf@umich.edu
- صفحتي العلميّة: Google Scholar

أرحّب بأسئلتك، تعليقاتك، واقتراحاتك. هذا الكتاب ليس عملي وحدي — هو ثمرة سنواتٍ من العلم والقراءة والنقاش. وأنتَ، القارئ، تُكمل هذه الدائرة بأن تأخذ ما هنا وتنشره وتُطوّره.

كلمة ختاميّة

﴿وَمَا أُوتِيتُم مِّنَ الْعِلْمِ إِلَّا قَلِيلًا﴾. هذه الآية هي خير ما أختم به دليل القراءات. كلّ ما قدّمتُه لك هنا هو قطرةٌ في بحرٍ. هناك مئات الأوراق العلميّة الجديدة كلّ شهر. هناك آلاف الباحثين الذين يكتشفون كلّ يوم.

لا تخَف من الكثرة. ابدأ بمصدرٍ واحد. اقرأه بتدبّر. ثمّ انتقل إلى الذي يليه. مع الوقت، ستبني فهمًا متراكمًا، وستجد نفسك جزءًا من المحادثة العالميّة في هذا المجال.

والله الموفّق، وعليه التكلان.

القسم الإنجليزي

English Section

Table of Contents

Chapter 1: The Beginning — What Is This Paper? 1

Chapter 2: Before Transformers — The Machine Translation Problem 2

Chapter 3: Attention — The Idea That Changed Everything 3

Chapter 4: How Does Attention Work? — Keys, Queries, and Values 4

Chapter 5: Multi-Head Attention — Many Eyes, One Understanding 5

Chapter 6: Positional Encoding — Teaching Order Without Sequence 6

Chapter 7: The Encoder and Decoder — Heart of the Transformer 7

Chapter 8: Feed-Forward Networks and Layer Normalization 8

Chapter 9: Training — How Did the Model Learn? 9

Chapter 10: What Made This Paper Revolutionary? 10

Chapter 11: From Transformer to ChatGPT — The Timeline 11

Chapter 12: Conclusion — Attention and Beyond 12

Chapter 13: References and Further Reading 13

Chapter 1: The Beginning — What Is This Paper?

﴿وَعَلَّمَكَ مَا لَمْ تَكُنْ تَعْلَمُ وَكَانَ فَضْلُ اللَّهِ عَلَيْكَ عَظِيمًا﴾

"*And He taught you what you did not know. And ever is the favor of Allah upon you immense*." — Surah An-Nisa: 113

In the summer of 2017, a small team of researchers at Google published a paper with a curiously confident title: *Attention Is All You Need*. The paper was relatively short — fifteen pages or so — and its eight authors were not, at the time, household names. Yet the simple, elegant idea contained in those pages set off a revolution in artificial intelligence the world had not seen since the early days of modern neural networks.

I remember vividly the day I first read this paper. I was a researcher in computational biology, working on gene expression in cancer cells. I did not expect a paper about

machine translation to change the way I thought about biological data. Yet that is exactly what happened — not just for me, but for thousands of researchers across fields as different as medicine, physics, chemistry, and linguistics.

Who Wrote This Paper?

The paper was written by eight researchers: Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan Gomez, Łukasz Kaiser, and Illia Polosukhin. Most of them worked at Google Brain and Google Research. What is striking — and a meaningful lesson for anyone pursuing knowledge — is that many of them did not hold the titles of "Professor" or "Director." They were young researchers who decided to try something different. That is a reminder worth holding onto: contributing to science does not require a grand title. It requires a curious mind and the courage to challenge what others take for granted.

What Made the Paper Exceptional?

Before 2017, natural language processing relied heavily on what are called Recurrent Neural Networks (RNNs), and especially Long Short-Term Memory networks (LSTMs). These networks worked something like the way you would read a book: word by word, from start to finish, carrying in your memory what you had already read in order to make sense of what came next. The trouble was that this memory was limited, and computation happened in strict sequence — one word after another. That made the networks slow to train, expensive to run, and brittle when sentences grew long.

Attention Is All You Need arrived with a bold proposition: throw away the sequence. Throw away the chain of memory. Replace it with a single mechanism — *self-attention* — that can look at every word in a sentence at the same time and decide for itself which words matter most for understanding each other word. That deceptively simple idea opened the door to models that were faster, more accurate, and far more scalable than anything that came before.

How ChatGPT, BERT, and Claude Were Born From This Paper

Every large language model you hear about today — ChatGPT from OpenAI, Claude from Anthropic, Gemini from Google, Llama from Meta, and many more — is, at its core, a direct descendant of the architecture proposed in this paper. When you type a question into ChatGPT, what happens behind the scenes are billions of computations built on the attention mechanism introduced in 2017.

Let me put this in plain terms: imagine that the Vaswani paper was the invention of the wheel. Before the wheel, people carried things on their backs. After the wheel came carts, then carriages, then cars, then trains, then airplanes. *Attention is the wheel* on which all these systems are built.

In 2018, Google released BERT, which uses only the *encoder* half of the original Transformer. BERT changed how text is searched and understood, and became foundational to Google Search itself. The same year, OpenAI released GPT-1, which

uses only the *decoder* half — the generative half. That opened the path to GPT-2, GPT-3, and GPT-4. Each model was larger and more capable than the last, but the underlying architecture stayed the same: a Transformer.

A Personal Moment: Reading the Paper for the First Time

In my work at the University of Michigan, I deal with extremely complex biological data — gene expression for hundreds of thousands of cells, protein sequences, pathology images. When I first read the Transformer paper, I did not see a direct connection to my own work. But two years later, DeepMind released AlphaFold 2, which used the very same attention mechanism to predict protein structures with stunning accuracy. I went back to the 2017 paper and read it again with fresh eyes. I realized that what I had taken to be "a tool for translation" was, in fact, a *general way of understanding relationships between elements* — whatever those elements

happened to be: words in a sentence, amino acids in a protein, or cells in a tissue.

That moment taught me something important. Big scientific ideas rarely stay confined to the field they were born in. When a researcher in one domain discovers a new way of thinking, the idea spreads — like ripples in a pond — to fields no one had imagined. Allah says, "*And He taught you what you did not know*." It is part of His favor that knowledge becomes a key opening doors we have not yet thought to knock on.

What You Will Find in This Book

In this book, I will take you on a journey through the most important paper in the modern history of artificial intelligence. But I will not drown you in mathematics, and I will not assume you are a software engineer. I will explain the ideas in plain language, with analogies drawn from everyday life — libraries, orchestras, advisory committees. Every chapter will open with a verse from the Holy Qur'an that reminds us of the place of

knowledge in Islam and the call to *tadabbur* — careful reflection.

In the next chapter, we will step backward to understand what existed *before* the Transformer, and why the world needed this leap. We will see how computers used to handle language, the problems researchers wrestled with for years, and how the Vaswani paper opened a new door. Then in Chapter 3, we will dive into the heart of the idea: what is *attention*, and why did it change everything?

Welcome to the journey. I ask Allah to benefit us with what He has taught us, to teach us what will benefit us, and to make this work sincere for His sake.

Chapter 2: Before Transformers — The Machine Translation Problem

﴿وَمَا أُوتِيتُم مِّنَ الْعِلْمِ إِلَّا قَلِيلًا﴾

"*And of knowledge, you have been given only a little.*" — Surah Al-Isra: 85

Before we can understand why the Transformer paper was so revolutionary, we need to understand what came before it. What problems did researchers struggle with for years? How did computers handle language before 2017?

Imagine walking into an old library and finding a librarian who reads books one letter at a time. He memorizes every letter he reads, but by the time he reaches the tenth word, he has forgotten the first letter. By the time he reaches the tenth sentence, he has forgotten the first word. That, more or less, is how most language models worked before Transformers. They

read words one after another, carrying a "memory" of context, but that memory leaked and frayed with every step.

Recurrent Neural Networks (RNNs): The First Generation

In the late 1990s and early 2000s, Recurrent Neural Networks (RNNs) were the workhorse of text processing. The idea was simple and elegant. To process a word, the model takes two things: the current word, and a *hidden state* that summarizes everything that came before. It updates this hidden state and passes it forward to the next step. Step by step, information travels through the sentence.

The closest analogy is a chain of postal couriers. Each courier reads the letter, scribbles a note in the margin, and hands it to the next courier. The idea is beautiful in theory, but the trouble appears as the chain grows long. The more couriers in the chain, the more the original notes get distorted, and the more important details get lost. This is the *vanishing gradient problem* that plagued RNNs for years.

A Patch on the Problem: LSTM Networks

In 1997, more than two decades before the Transformer paper, two scientists named Sepp Hochreiter and Jürgen Schmidhuber proposed a new architecture called Long Short-Term Memory (LSTM). It was a clever attempt to fix the leaky-memory problem of RNNs.

I picture an LSTM cell as a tidy office with three filing cabinets. There is a *forget cabinet* that decides what can be discarded from old memory. There is an *input cabinet* that decides what new information is worth keeping. And there is an *output cabinet* that selects what gets passed to the next step. This organization let the model preserve important information across longer distances and "forget" what no longer mattered.

LSTM was a major achievement and dominated language processing for years. It was used in machine translation, speech recognition, and text summarization. But all this progress did not solve the central problem: LSTMs still computed

sequentially, were slow to train, and struggled when sentences grew long.

The Bottleneck Problem in Translation

The biggest problem with these models was what is known as the *bottleneck problem*. Let me illustrate it with a translation example.

Suppose you want to translate the English sentence "*The cat that the dog chased ran away*" into Arabic. The general approach in older models was: an *encoder* would read the entire English sentence and squeeze it into a single *vector* of numbers — like trying to compress an entire book into a single paragraph. Then a *decoder* would take that vector and start producing the Arabic translation, one word at a time.

The problem is obvious. Every piece of information in the original sentence has to pass through this single vector, which becomes a bottleneck that chokes when sentences are long. Imagine trying to push the contents of an entire encyclopedia through a thin straw — much will be lost on the way.

A Half-Solution: Bahdanau Attention

In 2014, the researcher Dzmitry Bahdanau and his colleagues introduced a new idea. Why force the decoder to rely on a single vector? Why not let it, when generating each word, *look back* at the original sentence and pick out the parts most relevant to what it is currently trying to produce?

This was the first appearance of the word *attention* in language processing. The model still used LSTM at its core, but it added an upper layer that allowed the decoder to "attend" to different parts of the source sentence at each step. The results were impressive, and translation quality improved noticeably.

But the central problem remained. Computation was still sequential. You could not process several words at the same time. Recurrent networks had to finish processing the first word before they could begin the second. In an era when parallel computing power was advancing rapidly, this was a costly limitation.

The Closest Analogy: Reading by Candlelight

Here is an analogy that captures all of the above. Imagine reading a book in a dark room, holding a small candle that illuminates only one letter at a time. You must remember every letter you have read in order to make sense of the word, every word to grasp the sentence, every sentence to follow the paragraph. As the candle's light fades, it becomes harder to look back at what you read several pages ago. By the time you reach the end of a chapter, you may have forgotten what the author said at the beginning.

This is roughly what RNNs faced. Every step depended on what came before, but the memory of what came before kept dimming, step by step.

What Were Researchers Dreaming Of?

In the years leading up to 2017, there was a general sense that language processing had hit a kind of ceiling. LSTMs were

improving by small percentages each year, but the big leaps had stopped. Researchers were dreaming of three things.

First, **parallelization** — the ability to process all the words in a sentence at the same time, instead of one after another, making training dramatically faster.

Second, **long-range dependencies** — the ability to connect two words separated by tens or hundreds of other words, without the connection being lost along the way.

Third, **simplicity** — getting rid of the towering stack of complicated structures (LSTM inside Bahdanau attention inside convolutional networks…) and replacing them with a single, elegant mechanism.

These dreams seemed contradictory. How do you combine simplicity with high capacity? How do you get rid of sequence and still understand language? It looked like there was a *trade-off* between these goals.

A Coming Dawn

In 2017, the Vaswani paper arrived to say: no, there is no trade-off. You can have all of these things at once. *All you need is attention*. Throw away LSTM. Throw away recurrence. Throw away the chain. Build your model entirely from layers of attention, and you will get something faster, smarter, and simpler.

It was a challenge to the prevailing wisdom of the field. Many were skeptical at first. How could a model that ignored order possibly understand language, whose meaning depends on order? In the chapters to come, we will see how Vaswani and his colleagues answered that question with great elegance.

The Qur'an reminds us: "*And of knowledge, you have been given only a little*." All that we think we know is, in truth, a drop in a vast sea. Every new discovery opens more doors than it closes. In our story, a single paper opened the door to a new world that researchers had been dreaming of for decades.

In the next chapter, we will dive into the central idea itself: *what is attention*? How does it work in the human mind, and how did engineers carry it over to the machine?

Chapter 3: Attention — The Idea That Changed Everything

﴿إِنَّ فِي ذَٰلِكَ لَذِكْرَىٰ لِمَن كَانَ لَهُ قَلْبٌ أَوْ أَلْقَى السَّمْعَ وَهُوَ شَهِيدٌ﴾

"*Indeed in that is a reminder for whoever has a heart or who listens while he is present in mind.*" — Surah Qaf: 37

What is *attention*?

Before we talk about attention in artificial intelligence, let us pause for a moment on attention as we humans live it. When you sit in a crowded café and listen to your friend, your ears pick up dozens of sounds at once: the conversation at the next table, the espresso machine, background music, distant laughter. But your mind picks out your friend's voice from among them all and gives it priority. That is attention.

Or when you read a page of a book, your eyes take in thousands of letters, but your mind focuses on certain words —

those that carry the central meaning. The other words are present, but you "skim past" them. That, too, is attention.

Attention, then, is the capacity to distinguish what matters from a great deal of noise. It is a ranking of perceptual priorities. What Vaswani and his colleagues discovered is that this very capacity is exactly what a machine needs in order to understand language.

A Famous Example That Reveals the Heart of It

Let me share with you an example that has become famous in the literature, because it shows so clearly what an attention mechanism actually does.

Consider this English sentence: "*The animal didn't cross the street because it was too tired*."

The question is: what does the pronoun *it* refer to? The animal, or the street? For you, as a human reader, the answer is

obvious: it refers to the animal, because streets do not get tired. But how did you know?

Your mind paid *attention* to the word *tired*, connected it to the other words in the sentence, and recognized that this attribute belongs to animals, not to streets. You linked two distant words to make sense of the meaning.

Now change the sentence slightly: "*The animal didn't cross the street because it was too wide*."

Here, *it* refers to the street, because streets are what get described as *wide*. Once again, your mind attended to a single word (*wide*) and reorganized your understanding of the entire sentence around it.

This is the magic an attention mechanism tries to imitate in a machine. When the model processes the word *it*, it needs to "look at" the other words in the sentence and decide which one is most relevant for understanding it. When the most relevant word is *tired*, the model links *it* to *animal*. When the word is *wide*, the model links *it* to *street*.

Why Did the Older Models Fail at This?

In Recurrent Neural Networks (RNNs and LSTMs), information flowed left to right, step by step. By the time the model reached the word *it*, it carried with it a *hidden state* summarizing everything that came before. But that hidden state could not "go back" to a particular word. It was just a hazy summary.

With attention, the picture is completely different. The model can look directly at every word in the sentence and decide for itself: "The word *tired* matters far more than the others for understanding *it*." This is not a summary — it is a direct connection between two words, no matter how far apart they sit.

The Closest Analogy: A Boardroom

I like to picture an attention mechanism as a corporate boardroom. Imagine ten executives sitting around a round table,

each an expert in a different field: finance, marketing, engineering, legal, human resources, and so on. When the CEO asks a question, she does not want to hear everyone's opinion equally. She wants to direct her attention to the most relevant expert.

If the question is about profits, she turns to the CFO. If it is about an ad campaign, she turns to the CMO. If it is about a lawsuit, she turns to legal counsel. She listens to everyone in principle, but she gives more *weight* to the opinion of the most relevant expert.

That is exactly what an attention mechanism does. When processing a particular word, it computes a *weight* for every other word in the sentence. The most relevant words get high weights; the least relevant get low ones. Then it all gets combined to form a new "understanding" of the original word.

Self-Attention: When the Sentence Looks at Itself

What the Vaswani paper specifically proposed is *self-attention*. The key word is *self*. In earlier models, attention happened between two different sentences — the source sentence and the translated sentence. In self-attention, the sentence looks at itself.

Every word in the sentence looks at every other word (including itself) and decides which ones matter most for understanding its meaning. This creates a rich web of relationships *within* the sentence. The verb understands its subject and object. The adjective understands what it modifies. The pronoun understands its referent.

Picture a Bedouin caravan traveling across the desert, where every member is constantly looking around at the others, checking on their position, adjusting their pace to stay together. If everyone walked in isolation, the caravan would scatter. Self-

attention is what makes the words a *cohesive group* that builds a complete meaning.

The Advantages That Tipped the Scales

Let me list the advantages that made attention overturn every model that came before it.

First, **massive parallelism**: attention can be computed for every word at the same time. No waiting. That makes training tens of times faster, especially on modern GPUs, which were designed for parallel operations.

Second, **long-range connections**: it does not matter how far apart two words are. Attention links them directly, without information eroding along the way. This solved a problem that was decades old.

Third, **interpretability**: you can actually *see* what the model is paying attention to. Many researchers drew "attention maps" to discover what the model was really learning, opening a new

window into neural networks, which had historically been called "black boxes."

Fourth, **generality**: the attention mechanism is not specific to language. It can be applied to any set of elements that interact with each other. This is why it later spread to other fields — computer vision, genomics, even music.

A Qur'anic Pause: "*...has a heart or who listens while present in mind*"

In the verse that opens this chapter, the Qur'an points us to two essential conditions for genuine remembrance and learning: *a heart* that comprehends, or *listening while being present* — full mental presence. This, in essence, is attention. It is not mere hearing, but hearing *with presence*. Not mere seeing, but seeing *with understanding*.

Muslim scholars have long known that learning is not simply repeating words, but having "the heart present." Ibn Jama'a once said: "A sign of beneficial knowledge is that your heart is

present when you listen." This is precisely what artificial intelligence today is trying to imitate: a model that is *present* with every word, that links each one to its context, and understands it in relation to its neighbors.

A Personal Moment from the Lab

In my lab at the University of Michigan, I work with thousands of genes per cell. Each gene has its own *expression*, but genes do not act in isolation — they interact in complex networks. When I first thought about applying an attention mechanism to this kind of data, I realized that each gene could be like a "word," and that the model could *attend* to the other genes most relevant to it at any moment. The result was striking: deeper models that uncover biological relationships we could not see with traditional methods.

This is the power of a genuinely deep idea. When an idea is deep, it transcends the context in which it was born.

The Next Step

In the next chapter, we move from "what is attention" to "how does attention work." We will break the mechanism down into its three essential components: the *Query*, the *Key*, and the *Value*. We will do this with a library analogy that makes the idea easy to grasp for any reader. If you understand the next chapter, you will have understood eighty percent of Transformers.

And Allah, exalted be He, knows best.

Chapter 4: How Does Attention Work? — Keys, Queries, and Values

﴿أَفَلَا يَتَدَبَّرُونَ الْقُرْآنَ أَمْ عَلَىٰ قُلُوبٍ أَقْفَالُهَا﴾

"*Then do they not reflect upon the Qur'an, or are there locks upon their hearts?*" — Surah Muhammad: 24

In the previous chapter, we learned what attention is and why it matters. Now it is time to see how it actually works — without drowning in mathematics. I promised you that if you understand this chapter, you will have understood eighty percent of Transformers. I will keep that promise.

I will use a single coherent analogy that walks us through step by step: a large library. Picture an enormous library that holds millions of books, with an organized catalog and a skilled librarian. This library is the heart of the attention mechanism.

Three Elements: Query, Key, Value

Every attention operation involves three essential elements, with elegant names borrowed from the world of databases:

Query: the question you carry in your mind. For example: "*I want a book about the history of Andalusia*."

Key: the label or tag that books carry on their shelves. For example: "*Islamic History*", "*Arabic Literature*", "*Medical Sciences*".

Value: the actual content of the book — what you receive once you decide that this particular book is what you wanted.

Now let us see how the whole process plays out in the library:

1. You walk into the library carrying your **query**: "*I want a book about the history of Andalusia*."
2. You look at the **keys** posted on the shelves: "*Sciences*", "*Literature*", "*History*", "*Philosophy*", and so on.
3. You compare your query to each key and assign a *score* to each comparison. The shelf labeled "*History*" gets a high score. The shelf labeled "*Medical Sciences*" gets a low one.

4. Based on these scores, you go to the highest-scoring shelf and take its **value** — the contents of the book.

That is the attention mechanism in a nutshell. But what the machine actually does goes a step deeper: instead of choosing a single book, it takes a *weighted blend* of all the books, where each book contributes in proportion to its score. Higher-scoring books contribute more, lower-scoring books contribute less, but they all participate in the final answer.

A Worked Example on a Sentence

Let us apply this to the sentence we saw in the previous chapter: "*The animal didn't cross the street because it was too tired*."

When the model processes the word *it*, it generates a query for it that means roughly: "*What am I referring to? Which word do I represent in this sentence?*"

The model then takes the keys of every other word: *the*, *animal*, *didn't*, *cross*, *the*, *street*, *because*, *was*, *too*, *tired*. Each word has its own key that summarizes its "identity" in this context.

The model compares the query to every key. It finds that the key for *animal* matches the query strongly, because the surrounding context (the presence of *tired*) reinforces that match. The word *animal* gets a high score. The other words get low scores.

The model then takes the values of all the words and combines them in proportion to the scores. The result is a fresh "understanding" of the word *it* that mostly carries information from *animal,* with a little from the other words. Now the word *it,* in the model's mind, "carries the imprint of animal."

Where Do Queries, Keys, and Values Come From?

Here is the clever question: where do these queries, keys, and values come from? Do I have to write them by hand?

The answer: no. The model learns them on its own during training.

Every word in the model is first represented by a numerical *vector* of hundreds of numbers. The model then multiplies this vector by three *matrices* it has learned during training: the query matrix, the key matrix, and the value matrix. These three matrices are the "knowledge" the model gained from the millions of sentences it has seen.

Picture every word as a piece of dough, and the three matrices as three different molds. When you press the dough through the first mold, you get the *query* shape. Through the second, the *key* shape. Through the third, the *value* shape. They all come from the same original word, but they play different roles in the dance.

The Dot Product: Measuring Similarity

How does the model measure the similarity between a query and a key? It uses a mathematical operation called the *dot product*. Do not worry — I will not explain the math. I will just explain the idea.

Picture every query and every key as an arrow pointing in some direction in a multi-dimensional space. When two arrows point in the same direction, the dot product between them is large — they are very similar. When they point in perpendicular directions, the dot product is zero — no relationship. When they point in opposite directions, the dot product is negative — they are opposed.

This is exactly what happens in attention. Words that are *semantically related* in context produce queries and keys that point in nearby directions, yielding a large dot product and a high score.

Softmax: Turning Scores into Proportions

Once we have raw scores for each word, we need to turn them into *weights* that can be combined and compared. We use a function called *softmax*.

The closest analogy for what softmax does is this: imagine running a vote among ten employees. Each one rates an option on a scale from 1 to 100. Now you want to convert those numbers into percentages that add up to 100. That is what softmax does. It takes the scores, exaggerates the gaps between them (high becomes higher, low becomes lower), and turns them into proportions that sum to 100%.

The result is a set of weights, each of which says: "*This word deserves such-and-such percent of my attention*." The most relevant words get large weights (say, 70%), and the least relevant get small ones (say, 1%).

The Equation in Plain English

In the original paper, you find a famous equation: **Attention(Q, K, V) = softmax($QK^T/\sqrt{d_k}$)V.**

Let me translate it for you in human words, no math:

"*Attention works like this*: *take every query, compare it to every key with a dot product, divide the result by a constant to keep the math*

stable, apply softmax to get proportions, then use those proportions to mix the values in a weighted blend. The result is the new understanding."

That is all there is to it. The intimidating equation with its Greek letters is nothing more than this simple idea.

A Final Analogy: The Field Reporters

Let me give you one last analogy. Picture a commander planning a battle. He needs information from the field. He has ten reporters, each carrying three cards: an *identity card* (the key), a *specialty card* (the query), and an *intelligence card* (the value).

When the commander needs information about "*the right flank*," he compares his *need* (his query) to the reporters' identity cards (their keys). The reporter responsible for the right flank carries a card that matches the need closely. He gets a high score. The commander then weighs all reporters' intelligence, but gives more weight to the most-matching reporter. The output: a

thoughtful decision, grounded mostly in the most relevant reporter, but not entirely ignoring the others.

"*Then do they not reflect upon the Qur'an?*"

In the verse opening this chapter, Allah calls us to *tadabbur* — to read the words deeply, to connect them with one another, and to draw out meanings hidden between the lines. *Tadabbur* is a kind of focused attention. When hearts close in on themselves, the deep meanings escape us, just as a model fails to understand sentences when attention is missing.

In my own daily work, I see the difference between a surface reading and a reflective one. When I read a new scientific paper once, quickly, I grasp about 30%. When I read it with *tadabbur* — connecting distant ideas, comparing paragraphs — I grasp 90%. That is attention: not mere reading, but reading *with linking*.

Summary

The attention mechanism is not magic. It is an organized three-step operation: compare, weigh, blend. The query asks, the key identifies, and the value provides the content. Softmax organizes the weights, and the dot product measures similarity. All of this happens millions of times every second when ChatGPT runs.

In the next chapter, we will see why a single attention mechanism was not enough for Vaswani and his colleagues. They made it *multi-headed*. Eight attention heads operate at the same time, each looking at the sentence from a different angle. That is what we will explore in the chapter ahead: *Multi-Head Attention*.

Chapter 5: Multi-Head Attention — Many Eyes, One Understanding

﴿وَشَاوِرْهُمْ فِي الْأَمْرِ﴾

"*And consult them in the matter.*" — Surah Aal-Imran: 159

In the previous chapter, we learned how attention works: query, key, and value; dot product and softmax; then a weighted blend. All elegant. But Vaswani and his colleagues said: wait — why settle for a single view? Why not have *several* attentions running at the same time, each looking at the sentence from a different angle?

That is the central idea of *Multi-Head Attention*. In my view, it is the second most important innovation in the paper, after self-attention itself.

Why Isn't One View Enough?

Consider this sentence: "*The professor gave the brilliant student a valuable book on a sunny spring morning*."

This sentence carries many different kinds of relationships at once:

- **Subject–object relations**: who gave? to whom? what?
- **Modification relations**: *brilliant* describes *student*; *valuable* describes *book*.
- **Temporal relations**: when did it happen? on a sunny spring morning.
- **Deeper semantic relations**: why did the professor give this valuable book? Perhaps because the student is brilliant — an implicit causal link.

Could a single attention head capture all of these relationships at once? In theory, yes, but it would be overstretched. It is like trying to listen to ten parallel conversations at the same time. You will catch some of it, but you will miss a great deal.

The solution: instead of one giant head trying to understand everything, use several smaller heads, each specializing in a kind of relationship.

The Closest Analogy: A Panel of Experts

Imagine you are a manager at a company, and you have an important report to evaluate. You could read it yourself, but you would see it from one angle only — your own. Or you could call in a panel of eight experts:

- The finance expert reads it for the numbers.
- The legal expert reads it for compliance.
- The marketing expert reads it for opportunities.
- The quality expert looks for errors.
- And so on.

Each expert reads the same report but focuses on something different. You then gather all of their views to form a multi-dimensional picture.

That is exactly what multi-head attention does. The same sentence is given to eight attention "heads," each trained differently, each looking at the sentence from its own angle. Their views are then combined at the end.

How Does This Work Technically?

Recall that in single-head attention, every word is passed through three matrices to produce: a query, a key, and a value. In multi-head attention, we do the same thing, but instead of three matrices, we use three *times eight* — twenty-four matrices in total. Every group of three matrices forms a different *head*.

Each head takes the sentence, generates its own queries, keys, and values, and computes attention completely independently of the other heads. Then the outputs of all eight heads are taken, *concatenated*, and passed through a final matrix that fuses them into a unified representation.

Picture eight musicians in an orchestra, each playing a different instrument — violin, flute, drum, oud — and the sound coming

together at the end into a harmonious symphony. That is multi-head attention: many voices weaving into a single melody.

What Does Each Head Learn?

This is a question that has fascinated researchers since the paper appeared. Do the heads really learn different things? Or do they end up duplicating one another?

Researchers at Harvard, and later at MIT, conducted detailed analyses on this question, and the result was striking:

- One head learns to **track pronouns**: linking *it* to *the man*.
- Another head learns the **predicate-argument relation**: linking the verb to its subject and object.
- Another head learns **sequential order**: attending mostly to the immediately preceding word.
- Another head learns **syntactic structure**: linking the adjective to its head noun.

- Another head learns **distant semantic relations**: connecting words that are far apart but related in meaning.

No one programmed these specializations. The model learned them on its own from training on millions of sentences. This is one of the most remarkable things about modern artificial intelligence: specialization emerges by itself.

Why Exactly Eight Heads?

In the original paper, Vaswani chose eight heads. Why eight, not four, not sixteen? The honest answer: because experimentally, this number worked well.

But there is logic behind the choice. The number of heads should relate to the model's overall representation dimension. If the dimension is 512, then eight heads means each head operates in a 64-dimensional subspace. This creates a nice balance: enough heads for variety of perspective, and each head large enough to capture meaningful information.

In newer models, you sometimes see 12, or 16, or even 96 heads. The general trend: the larger the model, the more heads.

A Hidden Advantage: Parallelism

A subtle but important advantage of multi-head attention is that the heads are computed *in parallel* — at the same time, on GPUs. There is no waiting for one head to finish before the next begins. This makes training extremely fast compared to the recurrent networks we saw in Chapter 2.

Picture a baker baking eight loaves of bread simultaneously in a large oven, instead of baking them one at a time. The total time becomes one-eighth the original. This is the magic that the multi-head attention mechanism enables.

"*And consult them in the matter.*"

The verse that opens this chapter carries a deep wisdom. Allah, exalted be He, commands the Prophet ﷺ to consult his companions in matters of decision. Why? Was the Prophet ﷺ

not receiving revelation? He was — but human decisions become better when they gather many opinions.

This is a long-standing Islamic philosophy: "*the community does not unite on misguidance*." Collective wisdom is deeper than the wisdom of one. When perspectives multiply, the truth shows itself from several sides, and the chance of error shrinks.

Multi-head attention is, at heart, a technical embodiment of this philosophy. The model does not settle for a single opinion. It consults eight internal "experts" at every step, then merges their views. The result: a deeper, fuller understanding than any single head could produce alone.

A Personal Note: Application to Genomic Data

In my lab, we sometimes work on the analysis of complex gene expression data. Each cell contains tens of thousands of genes, and these genes interact in intricate networks. When we first started applying attention, we quickly realized one head was

not enough. Genes interact through several distinct *pathways*: signaling pathways, metabolic pathways, growth control pathways, programmed cell death pathways.

We used multi-head attention, and were astonished to find that each head began specializing in a kind of pathway. We did not tell it to. It learned that on its own. That is the magic.

Limits and Trade-offs

Multi-head attention is not without limits. The biggest is computational cost. Every head requires multiplying large matrices, consuming memory and time. The more heads, the higher the cost.

Another trade-off is *redundancy*: in large models, researchers have found that some heads end up learning similar things, which is wasteful. This led to new research on *attention pruning*, where redundant heads are dropped without significant loss in performance.

Still, the idea of multi-head attention remains one of the most influential ideas in the history of artificial intelligence. It is not merely a technical refinement; it embodies a deeper philosophy: *good understanding comes from multiple points of view*.

What Comes Next?

In the next chapter, we will turn to a clever puzzle: if attention looks at all words at the same time, how does the model know that one word came before another? This is the question Vaswani and his colleagues solved with great elegance through *Positional Encoding*. We will see how.

Chapter 6: Positional Encoding — Teaching Order Without Sequence

﴿وَكُلَّ شَيْءٍ أَحْصَيْنَاهُ فِي إِمَامٍ مُّبِينٍ﴾

"*And all things We have enumerated in a clear register.*" — Surah Ya-Sin: 12

In the previous chapters, we saw the power of attention: its ability to link every word to every other word, processing them in parallel rather than in sequence. But this power hides a deeper problem. If you sit with it for a moment, it becomes troubling:

If all the words are processed at the same time, how does the model know which one came first?

Consider these two sentences:

- "*The dog bit the man.*"

- "*The man bit the dog*."

The same words. Two completely different meanings. The only difference is order. If the model reads all the words at once without knowing the order, it sees the two sentences as identical. That is a disaster. Language depends fundamentally on order.

How did Vaswani and his colleagues solve this? With a simple, elegant idea called *Positional Encoding*.

The Core Idea: Injecting Position

The idea, in brief: before passing the words into the attention layers, we *add* a "tag" to each word that tells the model where it sits in the sentence. The first word gets a tag that says "*I am at position* 1," the second "*I am at position* 2," and so on.

Imagine you are organizing a marathon, and you have a hundred runners in front of you. If they did not wear numbers on their backs, you could not tell who was first and who was last, even if you saw them all at the same time. The numbers on

their backs are *positional encoding* — they are what makes parallelism possible *without* losing the information of order.

Why Not Use Plain Numbers?

The obvious question: why not just use 1, 2, 3, 4…? Wouldn't that be easier?

The answer is more subtle. Neural networks work with small fractional numbers, typically between 0 and 1. If we used the natural numbers 1, 2, 3…, the values would grow rapidly with sentence length. A word at position 1000 would carry the value 1000, throwing off the other computations inside the model.

We also want the encoding to *generalize*: if the model trains on sentences of length 500, we want it to handle sentences of length 1000 without falling apart. Plain sequential numbers do not give us this.

The Solution: Sine and Cosine Waves

Vaswani and his colleagues proposed using sine and cosine functions to create the positional encoding. The idea:

Every position in the sentence is represented by a *vector* of numbers, where some numbers come from a sine function and others from a cosine, but each dimension in the vector uses a different *frequency*.

Let me make this concrete. Picture a piano. Every key on the piano has its own frequency (a different note). Now imagine that each position in the sentence is "played" as a chord of notes. Position 1 is played as one specific blend, position 2 as a slightly different blend. The further apart two positions are, the more different the chord.

The model can "hear" these chords, and through them learn the position of every word. More importantly, it can sense the *relative distances* between words. Two adjacent words have very similar chords; two distant words have very different ones.

The Musical Analogy: A Positional Symphony

I am very fond of the musical analogy for positional encoding. Picture a vast orchestra with hundreds of musicians. Each spot on the stage has its own distinctive *acoustic fingerprint*, made up of different frequencies from different instruments. If you asked the conductor to find the musician at spot number 42, he could — because the sound of that spot has a unique fingerprint.

Positional encoding does the same thing for words. Every position has its own frequency fingerprint, and the model learns to read these fingerprints.

How Is Positional Encoding Combined With Words?

The next technical question: how do we get this encoding into the model?

The answer is simple: we *add* it to the word's original representation. Each word in the model is represented by a vector of 512 numbers (in the original paper). The positional encoding is also a vector of 512 numbers. We add the two vectors element by element, producing a new vector that carries two pieces of information at once: *what this word is*, and *where it sits*.

Imagine writing a letter and putting it in an envelope. The word is the contents of the letter; the positional encoding is the postmark — a date and a sequential number. The envelope carries both together.

The Hidden Cleverness of the Idea

What makes this idea genius is its *generalizability*. Because sine and cosine are periodic, continuous functions, the model can infer relationships between positions it never saw during training. If it trained on sentences of length 500, it can handle sentences of length 1000 reasonably well, because the wave pattern continues logically.

Also, differences between positions are preserved in a *linear* form. That means the distance between position 1 and position 5 is represented similarly to the distance between position 10 and position 14. This helps the model understand *relative* distances, not just absolute positions.

Positional Encoding Today: Evolutions and Variants

The positional encoding proposed in the original paper did not stay frozen. Many variants have appeared over the years:

- **Learned positional embeddings**: instead of using sine and cosine, the model learns the best encoding for each position on its own.
- **Relative position encodings**: focus on the distances between words rather than absolute positions.
- **RoPE (Rotary Position Embedding)**: a recent technique that rotates vectors by angles proportional to position. Used today in large models like LLaMA.

- **ALiBi**: a simple method that adds an attention penalty based on distance, with no explicit positional encoding at all.

All of these methods try to solve the same problem in different ways, and each suits a particular context. But the core idea remains: *the model must know the order*.

"*And all things We have enumerated in a clear register.*"

In the verse opening this chapter, Allah, exalted be He, reminds us that everything is recorded and enumerated in *a clear register*. Every atom in the universe has its known position; every motion is recorded. Order is intrinsic to the system of the cosmos.

In artificial intelligence, when we want a machine to understand reality, we have to communicate this idea: *nothing is understood in isolation from its position*. The word in its place, the atom in its location, the event in its time. Positional encoding is not just

a technical trick; it is an embodiment of a cosmic truth: position has meaning.

A Personal Note: Positional Encoding in Biology

In my work on *spatial transcriptomics* — gene expression measured at known locations within a tissue — I deal with thousands of cells, each carrying a position. A cell near a tumor differs biologically from a cell far from it. When we started applying Transformers to this kind of data, the question was the same: how do we tell the model where each cell sits?

We used an idea similar to positional encoding, but in a two-dimensional space rather than a linear one. Each cell got a *spatial fingerprint* that told the model its coordinates. The result: models that understand that a cell at one location has a different biological context from a cell at another.

This is the power of a general idea. It applies to words, to cells, to molecules, to anything that occupies a position in some space.

Open Challenges

Positional encoding is one of the areas where research is still very active. The biggest open problem is *out-of-distribution generalization*. If the model trains on sentences of length 2,048 words, can it handle sentences of length 32,000 words, as in modern long-context models? The answer is complex, and depends on the kind of encoding used.

There is also research on three-dimensional position encoding for images, temporal encoding for video, and graph encodings for social networks. Every domain needs its own kind of positional encoding suited to the structure of its data.

What Comes Next?

Now we have the essential tools: attention, multi-head attention, and positional encoding. In the next chapter, we will see how these tools are assembled into a complete engineering structure: the *encoder–decoder*. We will understand how the model reads a sentence in one language, then generates its translation in another. We will also see why later models (like BERT and GPT) chose to use only *half* of this structure.

Chapter 7: The Encoder and Decoder — Heart of the Transformer

﴿وَنَزَّلْنَا عَلَيْكَ الْكِتَابَ تِبْيَانًا لِّكُلِّ شَيْءٍ﴾

"*And We have sent down to you the Book as a clarification for all things.*" — Surah An-Nahl: 89

So far, we have learned the fundamental building blocks: attention, multi-head attention, and positional encoding. But these blocks alone do not yet form a house. We need to see how they are assembled into a complete engineering structure.

In the original paper, Vaswani and his colleagues proposed a structure called the *encoder–decoder*. It is designed especially for tasks like translation, where we have text in one language and want to generate text in another. In this chapter, we will see how this structure works, and why some researchers later chose to use only half of it.

The Analogy: The Human Translator

Before we dive into the technical details, let me compare it to a skilled human interpreter at an international conference.

When translating a sentence from English to Arabic, the interpreter performs two distinct phases:

Phase one — understanding: she listens to the entire English sentence, analyzes it in her mind, grasps the relationships between the words, takes in the context, and forms a complete *mental picture* of what the speaker said.

Phase two — generation: she begins producing the Arabic translation, word by word, drawing on the mental picture she built in phase one. With every word she translates, she consults her mental picture to confirm the meaning and choose the most fitting Arabic word.

The encoder is phase one. The decoder is phase two.

The Encoder: Building Understanding

The encoder is the part that *reads* the source sentence and builds a rich understanding of it. It takes the words (with their positional encoding) and passes them through successive layers of multi-head attention. Each layer deepens the understanding: early layers capture surface relationships (like adjective–noun), and higher layers capture deeper relationships (like topic, intent, style).

In the original paper, the encoder consists of six identical layers. Each layer contains:

1. **Multi-head self-attention**: linking every word to every other word in the sentence.
2. **Feed-forward network**: processing each position independently, adding computational depth.
3. **Skip connections** and **layer normalization**: components that help stabilize training (we will dive into these in the next chapter).

Picture the encoder as a careful reader who reads a text six times in succession, each time absorbing a deeper layer of meaning.

The Decoder: Generating the Output

The decoder is the part that *writes* the translation. It is a bit more complex than the encoder because at every step it does two jobs:

1. **It generates the next word**: based on the words it has already produced, it decides what the next appropriate word should be.
2. **It draws on the encoder's understanding**: it consults the encoder's representation of the source sentence and attends to the parts most relevant to what it is currently generating.

Each layer in the decoder contains *three* components (instead of two as in the encoder):

a. **Masked self-attention**: looks only at previous words in the generated sentence; it does not look at future words (because they have not been generated yet).

b. **Encoder–decoder attention (cross-attention)**: this is where the bridge happens. *Queries* come from the decoder; *keys* and *values* come from the encoder. This lets the decoder *attend to* the source sentence at every step.

c. **Feed-forward network**: just like the encoder.

The Mask: Why Do We Stop the Decoder From Looking at the Future?

Notice that the decoder uses *masked* attention. Why?

Imagine you are writing an essay. When you write the fifth word, you know the previous four words, but you do not yet know the sixth and seventh because they have not been written. That is the nature of writing: sequential generation.

If we let the decoder see future words during training, it would *cheat*. It would learn to depend on information that will not be available at actual use time. So we put a *mask* over the future tokens, preventing the decoder from attending to them.

The analogy: imagine a student sitting an exam where the question paper happens to also list all the answers. If we let her see the answers, she would not learn. But if we cover the answers and reveal them one by one only after she attempts each question, she would learn properly. The mask is that covering.

The Bridge: Encoder–Decoder Attention

The most important component in the entire structure, in my view, is *encoder–decoder attention*. It is what links two worlds: the world of the source sentence and the world of the generated sentence.

Imagine an architect designing a house. He has a complete blueprint (this is the encoder's output). Now he stands at the construction site and builds the house brick by brick. With each brick, he consults the blueprint to make sure what he is building matches the design. That consultation — that bridge — is encoder–decoder attention.

In translation: when generating each Arabic word, the decoder consults the representation of the English sentence and attends to the parts it has not yet translated, or the parts most relevant to the current word.

Models That Use Only Half the Structure

After 2017, researchers discovered something striking: not all tasks need the full structure. Some need only the encoder; others need only the decoder.

Understanding tasks: such as classification, question answering, or information extraction. These need a deep

understanding of the sentence, but they do not need to generate long text. For these, models use only the encoder. This is the approach of BERT (Bidirectional Encoder Representations from Transformers) from Google.

Generation tasks: such as writing stories, completing sentences, or having a dialogue. These need to generate fresh text from scratch, depending on what came before. For these, models use only the decoder. This is the approach of GPT (Generative Pre-trained Transformer) from OpenAI.

Translation and summarization tasks: need both understanding and generation. For these, the full encoder–decoder structure remains, as in T5 from Google.

It is interesting to note that ChatGPT, which people use daily, is essentially *decoder-only* — but large enough to mimic both understanding and generation.

A Personal Moment: Application to Proteins

In my work, I sometimes deal with sequences of amino acids (which form proteins). Each protein is a chain of *words* (amino acids), and we have to understand how these acids interact to form a three-dimensional structure.

DeepMind's AlphaFold 2 model, which won a Nobel Prize in chemistry in 2024, uses an encoder–decoder–like structure. The encoder reads the amino acid sequence, and the decoder generates the coordinates of the 3D structure. The bridge between the two is what allows the model to link each acid to its position in space.

This is a beautiful transposition: what Vaswani proposed for translation between languages became a solution for translation between *the language of sequence* and *the language of structure* in biology.

"*...as a clarification for all things*"

In the verse opening this chapter, Allah describes the Qur'an as *tibyan* — a clarification for all things. *Tibyan* is *complete clarification*, combining deep understanding with the capacity to convey it to others. The Qur'an does not stop at understanding; it teaches how that understanding is to be communicated.

This philosophy applies remarkably well to the encoder–decoder structure. Understanding alone is not enough. Generation alone is not enough. Real value comes from joining the two: deep understanding that produces clear communication.

Summary, and Preparing for What Comes Next

The complete Transformer structure consists of two parts:

- The **encoder**: six layers that build an understanding of the source sentence.

- The **decoder**: six layers that generate the new sentence, with a continuous bridge to the encoder.

Modern models have drawn on this structure and invented many variations: BERT (encoder-only), GPT (decoder-only), T5 (both), and others.

In the next chapter, we will dive into the other components that make every layer work: the feed-forward network, layer normalization, and residual connections. These components may seem peripheral, but they are foundational to training stability and learning depth.

Chapter 8: Feed-Forward Networks and Layer Normalization

﴿وَأَتْقَنَ كُلَّ شَيْءٍ﴾

"*He has perfected everything*." — Surah An-Naml: 88

Imagine that you have built a beautiful house. The foundation is strong, the walls rise high, and the roof holds firm. But the house is not yet complete. You need plumbing, electricity, heating, ventilation. These "technical details" may not catch the eye, but they are what make the house actually livable.

In the world of Transformers, we have attention (the foundation) and multi-head attention (the walls), but there are other components that do not get the same fame, even though they are essential to model stability and learning. These components are:

1. The Feed-Forward Network (FFN).

2. Layer Normalization.
3. Residual Connections.

We will go through each of them quietly.

The Feed-Forward Network: The "Thinking" Phase

After attention finishes its job, we need another phase that we informally call the *thinking phase*. That is where the Feed-Forward Network comes in.

What is the Feed-Forward Network? It is a simple neural network of two linear layers separated by an activation function (such as ReLU). It takes the representation of each word independently and converts it into a new representation.

The closest analogy: attention gathers information from "the neighbors," while the feed-forward network processes that information internally — as if every word "reflects" on what it has gathered before moving to the next layer.

Picture an academic seminar. Attention is the open discussion where participants exchange ideas. The feed-forward network is the break afterward, where each participant sits alone in a room thinking about what they heard and organizing it in their mind. The open discussion (attention) is essential for gathering ideas, but the quiet break (feed-forward) is essential for absorbing them.

A Subtle Point: Each Position Is Independent

An important detail about the feed-forward network: it is applied to each word independently. The first word does not affect the processing of the second word at this stage. Every word is in its own room.

Why? Because attention has already done the job of mixing information across words. After that, we give each word a chance to think on its own. Then we go back to a fresh layer of attention (in the next layer) to see how the relationships have changed.

This division — attention then thinking, attention then thinking — repeats six times in the original paper. Each repetition deepens understanding.

Layer Normalization: The Thermostat That Keeps Things Stable

Now we turn to a component that may seem peripheral but is absolutely essential: *Layer Normalization*.

What problem does it solve? In deep neural networks, computations stack up layer after layer. With each layer, the numbers grow or shrink in unruly ways. Values may explode toward infinity or vanish toward zero. This is known as the *exploding gradient* or *vanishing gradient* problem. The result: training does not stabilize, and the model does not learn.

Layer normalization is a clever solution. After every component in the model, we readjust the numbers so that their mean is zero and their standard deviation is one. This keeps the numbers in a *healthy range*.

The closest analogy: the thermostat in your house. If the temperature rises too high, it turns on the air conditioning. If it drops too low, it turns on the heater. The goal: keep the temperature in a comfortable range. Layer normalization is the thermostat that keeps the model in a *healthy computational range*.

Without this thermostat, the model either *freezes* (gradients vanish) or *burns* (gradients explode). Either way, the model does not learn. With normalization, training proceeds smoothly for days and weeks, until the model has learned what is required.

Residual Connections: Why "Skipping" Is Essential

The third component is the *residual connection* (also called a *skip connection*).

The idea is very simple, but powerful. In every component of the model, instead of just outputting what was computed, we *add* the input to it. That is:

Final output = what the component computed + the original input.

Why? For two essential reasons.

First: it lets the original information pass through without distortion. Imagine you pass a message through a chain of translators. Each translator converts it into a different language. With cumulative translation, the original message gets lost. But if every translator keeps a copy of the original, they can correct their translation. That is the effect of a residual connection.

Second: it eases the flow of *gradients* during training. The gradient is the *signal* that tells the model how to improve itself. In very deep networks, this signal may vanish before it reaches the lower layers. Residual connections create a "highway" for the gradient, ensuring it reaches every layer.

The analogy: imagine a tower of 100 stories. Without elevators, people on the tenth floor cannot easily reach the rooftop. Residual connections are the elevators that speed up communication between floors.

The Stack: How All These Components Fit Together

Let me now assemble everything we have seen in the recent chapters. Each layer in the encoder (and similarly in the decoder) consists of a *stack* of components in this order:

1. **Input**: word representations (with positional encoding).
2. **Multi-head self-attention**: gathers information across words.
3. **Residual connection + layer norm**: keeps stability.
4. **Feed-forward network**: processes each word independently.
5. **Residual connection + layer norm**: keeps stability again.
6. **Output**: a new representation, fed into the next layer.

This *stack* repeats six times in the original model. Newer models repeat it many more times: GPT-3 uses 96 layers, and GPT-4 uses even more (the precise numbers are proprietary).

A Final Analogy: The Precision Factory

Picture a modern car factory. On the assembly line, the car passes through a series of stations. Each station adds something: wheels, then engine, then electrical, then paint, and so on. But the factory also needs:

- **Quality inspectors** (layer normalization): make sure each station produced what was required, and correct any deviations.
- **Bypass tracks** (residual connections): if a station breaks down, production does not stop, because there is an alternate path.
- **Workshops** (feed-forward network): where fine details are processed before the part moves to the next stage.

All of these components work together to produce a finely engineered car. And every component in the Transformer, even the smallest, contributes to the precision of the model.

"*He has perfected everything.*"

In the verse opening this chapter, Allah, exalted be He, reminds us that He has perfected everything He has created. *Itqan* — perfection — is excellence in detail. Not just the big idea, but the small details that make the big idea actually work.

In artificial intelligence, we learn a similar lesson: genius is not only in the central idea (attention), but in the implementation details (normalization, residual connections, feed-forward networks). If any of these components is missing, the model does not work. Every detail is deliberate.

I have always loved the saying among Muslim scholars: "*Investigation in the branches is no less in importance than investigation in the roots*." The roots give the framework, but the branches give it life. In the Transformer, attention is the root, and these components are the branches that let the root pulse with life.

A Personal Note: When My First Experiments Failed

In one of my early experiments with Transformers, I tried to build a simplified model and removed layer normalization, thinking it was a *secondary detail*. The result: the model learned nothing. The loss bounced around randomly and never went down.

I put layer normalization back, and suddenly the model began to learn. It was an important lesson: in artificial intelligence, there is no such thing as a *secondary detail*. Every component is there for a reason, and removing it can break the entire model.

Open Refinements

Recent research has refined these components. For example:

- **Pre-LayerNorm**: applying normalization before attention rather than after, which improves stability in large models.

- **RMSNorm**: a simpler version of layer normalization, used in modern LLaMA models.
- **GeLU instead of ReLU**: a slightly more complex activation function that gives better performance.

All of these refinements improve the *branches*, while the *root* (the attention mechanism itself) remains the same as in 2017.

What Comes Next?

We now understand the full structure of the Transformer. But the question remains: how does this model actually *learn*? How do we *train* it? What is the data? What is the *loss function* that tells it when it has erred? How much hardware and time does it need?

All of this in the next chapter: *Training — How Did the Model Learn*?

Chapter 9: Training — How Did the Model Learn?

﴿وَقُل رَّبِّ زِدْنِي عِلْمًا﴾

"*And say, 'My Lord, increase me in knowledge.*'" — Surah Ta-Ha: 114

So far we have talked about the structure: encoder and decoder, attention, positional encoding, the supporting components. But the deeper question remains: how does this model actually *learn*? How is it trained on millions of sentences? How does it discover, on its own, the rules of language and the relationships between words?

In this chapter, we will dive into the world of training Transformers. We will see the data, the loss, the examples, and the patience researchers need to teach these models.

What Does "Training" Mean?

Training in artificial intelligence is something like teaching a child a new language. You do not hand the child a list of grammatical rules and say, "*This is the language — memorize it*." Instead, you expose the child to thousands of sentences, correct his mistakes, repeat patterns with him, until he absorbs the language *implicitly*.

That is precisely what we do with Transformers. We do not program the rules of language into them. We expose them to millions of sentences and adjust their internal *weights* (the matrices) gradually until they learn on their own how to predict the next word, or how to translate.

Data: The Fuel of Learning

In the original 2017 paper, the Transformer was trained on two main tasks:

First: translation from English to German. They used the WMT 2014 dataset, which contains 4.5 million sentence pairs (English plus their German translations).

Second: translation from English to French. They used a larger dataset of 36 million sentence pairs.

Those are huge numbers. 4.5 million sentences is roughly the equivalent of 450 average books. 36 million is around 3,600 books. The model "reads" all this data — or rather, passes over it many times (called *epochs*) — until it learns.

Modern models use far more data. GPT-3 was trained on 500 billion *tokens*, roughly equivalent to 700,000 books. GPT-4 and Claude use even larger amounts, including approximately everything publicly available in text on the internet.

The Loss Function: How Does the Model Know It Made a Mistake?

Training needs a *signal*. After every prediction, we need to tell the model: "*This answer is correct*" or "*this answer is wrong*." Without that signal, the model has no way to improve.

In translation, the signal comes from the correct translation already in the data. The model attempts to translate an English sentence, produces a candidate Arabic word, and we compare it to the correct Arabic word in the data. The difference between the two is the *loss*.

The analogy: imagine a teacher grading a student's answer. The student writes a response, the teacher reads it and says, "*You are ten points off the correct answer — try again*." Those points are the loss.

In Transformers, we use a function called *cross-entropy*. Do not let the name worry you — the idea is simply: we compare the

probability distribution the model produced to the correct distribution and compute how far apart they are.

Backpropagation: How Does the Model Improve Itself?

After computing the loss, the model begins a process called *backpropagation*. The idea:

1. The loss is computed at the top (the output layer).
2. The "error signal" is then carried backward, layer by layer, until it reaches the first layer.
3. At each layer, we compute a *gradient* — that is, by how much each weight should be adjusted to reduce the loss.
4. We update the weights slightly in the direction that reduces the loss.

The analogy: imagine you throw an arrow at a target, and it misses by two meters to the right. You analyze: "*My hand was a bit high, my foot was angled, my grip was crooked*." You correct

each of these slightly, then throw again. With every throw, you improve a little, until you hit the target.

The model does this millions of times. Every time it sees a new sentence, it throws its *arrow* (a prediction), computes the error, and adjusts its weights slightly. Over time, it becomes a marksman.

Teacher Forcing: A Trick That Speeds Learning

In training the decoder, researchers use a clever trick called *teacher forcing*.

In actual use, the decoder generates words one at a time, with each word depending on the words it itself produced before. But during training, if we relied on this, the model could compound its mistakes, and the sentences would be very poor.

The fix: during training, we feed the model the *correct* words (from the data) instead of the words it generated. As if the

teacher held the student's hand and guided him. This dramatically speeds up learning.

The analogy: imagine learning to play piano. At first, a skilled teacher sits next to you and shows you which key to press. After you have learned the piece, she leaves you to play on your own. Teacher forcing is that guided phase.

Dropout: Why We Deliberately "Damage" the Model

One of the paradoxes of training neural networks is that we deliberately *damage* the model during training. We use a technique called *dropout*, where we randomly silence some "neurons" at each step.

Why do this? To prevent the model from *memorizing*. If the model memorizes its data verbatim, it will perform brilliantly on the data it has seen, but fail on new data. This is the *overfitting* problem.

Dropout forces the model not to depend on any single neuron. Every neuron must be capable of doing its job even if its neighbors are absent. The result: a more flexible model that generalizes better.

The analogy: imagine a sports team training. The coach deliberately benches a player from time to time, so the rest of the team learns to play without depending on him. This makes the entire team stronger.

Hardware: How Much Computing Do You Need?

In the original paper, the *base* model trained on 8 GPUs (Nvidia P100) for 12 hours. The *large* model needed 8 GPUs for 3.5 days. These are modest numbers by today's standards, but they were reasonable in 2017.

Today, training a model like GPT-4 requires thousands of GPUs for months on end. The cost is estimated at hundreds of

millions of dollars. This is a massive shift in the resources required to build advanced models.

The reason for this inflation: models grow, data grows, and the computation required grows in proportion.

The Results That Shocked the World

What Vaswani and his colleagues announced in their paper was not just a new architecture, but a dramatic improvement in the numbers. They used a metric called the *BLEU score* to evaluate translation quality (measured from 0 to 100, where 100 is a perfect translation).

In English-to-German translation, the Transformer achieved 28.4 — surpassing the best previous models by more than two points. In English-to-French, it achieved 41.8 — a new record.

More important than the numbers: it took far less time to train. Previous models needed weeks. The base Transformer trained in 12 hours. This efficiency improvement is what stunned the research community.

"*And say, 'My Lord, increase me in knowledge.'*"

In the verse opening this chapter, Allah commands His Prophet ﷺ to pray, "*My Lord, increase me in knowledge*." Notice the phrasing: *increase me*. Increase implies that there is prior knowledge, and we want more. Learning does not stop. The more knowledge a person has, the more aware he becomes of how much he does not know — and so he asks for more.

In artificial intelligence, training also does not stop. The model begins with *zero knowledge* (random weights), and with every sentence it sees, its knowledge grows a little. There is no moment at which the model says, "*I have finished learning*." Improvement continues, given more data and more time.

This is a noble scientific spirit: knowledge does not end, and learning is a lifelong journey. That is what our models have learned, and it is what we as humans should learn too.

A Personal Note: Training a Model in My Lab

In my lab at the University of Michigan, I trained a Transformer on biological data. The training took a full week on 4 GPUs. I would watch the *loss curve* every hour, sometimes in the middle of the night. It was a strange feeling: I would see a number slowly decrease, knowing that behind that number a model was *understanding* something it had not understood hours earlier.

On the fifth day, something striking happened. The loss suddenly dropped to half its previous value. As if the model had *discovered* something. In deep learning, we call these moments *phase transitions*. The model crosses some threshold and reaches a new level of understanding.

I enjoyed those moments more than anything else in my work. The moment a model *understands* something new — that is the real magic of artificial intelligence.

What Comes Next?

We now understand the architecture, and we understand training. But the bigger question: why was this paper so revolutionary? What set it apart from the thousands of other papers published every year?

In the next chapter, we will answer this question. We will see why a 15-page scientific paper became a turning point in the history of artificial intelligence.

Chapter 10: What Made This Paper Revolutionary?

﴿يَرْفَعِ اللَّهُ الَّذِينَ آمَنُوا مِنكُمْ وَالَّذِينَ أُوتُوا الْعِلْمَ دَرَجَاتٍ﴾

"*Allah will raise those who have believed among you and those who were given knowledge by degrees.*" — Surah Al-Mujadila: 11

Every year, thousands of papers are published in artificial intelligence. Most are read by a handful of researchers and forgotten. Some have an effect within a narrow field. But rarely, very rarely, a paper appears that changes the entire field.

Attention Is All You Need was one of those rare papers. Today, almost a decade after its publication, we can step back and ask calmly: what made it so revolutionary? What were the qualities that set it apart?

In this chapter, we will examine five core properties that gave the paper its lasting power.

Property One: Speed — Breaking the Chain of Sequence

As we saw in Chapter 2, the previous models (RNN and LSTM) were inherently slow. They processed words one at a time, and there was no way to speed them up by adding more hardware.

The Transformer changed this completely. Because attention is computed for all words in parallel, it benefits from modern GPUs that were originally designed for parallel computation.

The numbers were stunning. In the paper, Vaswani and his colleagues showed that the Transformer trained in *a fraction* of the time previous models needed. Reductions of 90% or more, in some cases. What used to take weeks could be done in hours.

This speed opened a new door: it became possible to try many ideas quickly, and to train far larger models. If models had remained as slow as LSTMs, we would never have seen GPT-3 or GPT-4. Speed is what made scale possible.

Property Two: Quality — Breaking Records

Speed alone is not enough. The Transformer could have been *faster but worse*. But it was not. It was faster *and* better at the same time.

On well-known machine translation benchmarks, the Transformer surpassed the best previous models by a large margin. That alone is rare. Usually, improvements in AI come in small percentages (0.5% here, 1% there). But the Transformer made a leap, while at the same time being simpler in architecture and faster to train.

This *golden trio* — simpler, faster, better — is what every researcher dreams of, and only a few achieve.

Property Three: Scalability — The Bigger You Make It, the Better It Gets

Here lies the deeper power of the Transformer. Researchers later discovered an astonishing rule called the *Scaling Laws*: the more you increase the model size, the more data, and the more compute, the better the performance — predictably and measurably.

This was not true of the previous models. LSTMs hit a *ceiling*, where adding more parameters did not improve results. But Transformers? The bigger they got, the better they performed.

The direct consequence: a race toward scale. Vaswani's original model had 65 million parameters. BERT had 340 million. GPT-2 had 1.5 billion. GPT-3 had 175 billion. GPT-4 is estimated to have trillions. Every increase brought new capabilities that did not exist at the previous scale.

The analogy: imagine a small seed. The more you water it and the wider the soil you give it, the larger it grows. But some

seeds have a natural ceiling — they grow to a meter, then stop. The Transformer seed is like a *magic tree*: there is no ceiling on its growth. Give it more resources, it grows, and bears new fruit.

Property Four: Generality — The Idea Travels Across Fields

This, for me, is the most striking thing. The attention mechanism is not specific to language. It is a *general* idea that applies to any set of elements that interact.

In the years that followed the paper, the Transformer spread to fields its authors could not have imagined:

- **Computer Vision**: Google's Vision Transformer (ViT) in 2020 showed that Transformers could outperform Convolutional Neural Networks (CNNs) at image classification.

- **Protein science**: DeepMind's AlphaFold 2 used the attention mechanism to predict protein structures. This led to a Nobel Prize in chemistry in 2024.
- **Music**: models like MusicLM generate music from a text description, using Transformers.
- **Mathematics**: models that solve complex equations and prove theorems.
- **Genomics**: in my lab, we apply Transformers to gene expression data and to spatial cell data.
- **Self-driving cars**: Tesla and Waymo use Transformers to understand the car's surroundings.

All of these applications use the same underlying architecture, with minor modifications. This *generality* is very rare in the history of science.

Property Five: Simplicity — Mathematical Elegance

The last property, and perhaps the most important philosophically, is *simplicity*.

The Vaswani paper is no more than 15 pages. The core idea can be explained (as I have done in the previous chapters) without complex mathematics. The full architecture can be drawn on a single page.

Compare this with the complex LSTM models, the hierarchical convolutional networks, or the hybrid models that dominated before 2017. Those models were architecturally complex, hard to understand, and full of technical tricks.

The Transformer is *elegance in simplicity*. It says: "*Take one mechanism* (*attention*), *and repeat it with normalization. That is all*." In physics, beautiful equations are said to be the correct equations. In artificial intelligence, simple architectures are the ones that endure.

The Analogy: The Wheel and the Steam Engine

Let me close this chapter with a deeper analogy. In the history of technology, there are certain inventions that change

everything that comes after them. The wheel. The steam engine. The transistor. The internet.

What makes these inventions *great* is that they do not solve a single problem only. They create entire *possibilities* that did not exist before. The wheel did not just invent cars and trains; it reshaped human geography. The steam engine did not just invent the factory; it reshaped economies and cities.

The Transformer is in this category. It did not just improve translation. It created an entire possibility for a new kind of artificial intelligence. ChatGPT, image generators, AlphaFold, and thousands of other applications — all are children of this invention.

"*Allah will raise those who have believed among you and those who were given knowledge by degrees.*"

In the verse opening this chapter, Allah links faith and knowledge, and raises those who hold them by degrees. This

connection between faith and knowledge has a deep meaning: knowledge is not the opposite of faith, but one of the means of glorifying the Creator and reflecting on His signs in the universe.

When I contemplate the Transformer paper, I see in it a sign of Allah within the human mind. This capacity to invent mechanisms that imitate some aspects of human cognition is a gift from Allah, deserving to be used for the good of humanity.

Many Muslims fear artificial intelligence, or treat it as *a Western invention*. But I see things differently. Islamic history is full of scholars who learned from Greeks, Indians, and Persians, and then refined and contributed. The original Arab share in world scientific history is enormous. Why should we not have a similar role today?

The paper was written in English, but the ideas it carried belong to all of humanity. What matters to me, as an Arab Muslim researcher, is that we *contribute* — not merely watch.

A Personal Note: The Moment the Revolution Sank In

I remember the day ChatGPT was released in November 2022. I was in my office at the University of Michigan, and a colleague sent me the link. The first time I tried it, asking it a question in computational biology, and getting a coherent answer back, I felt that something had shifted in the world.

Later, I understood that ChatGPT was not a *surprise* — it was the cumulative result of five years of work on Transformers. But the public saw it as an explosion. That is a reminder: scientific revolutions begin quietly in research papers, and only appear suddenly to the public years later.

Attention Is All You Need was the quiet moment. ChatGPT was the explosion. Between the two were years of patient work by hundreds of researchers who built on Vaswani's idea and took it to horizons no one had imagined.

What Comes Next?

In the next chapter, we will trace a clear timeline: from the 2017 paper to ChatGPT. We will see the key milestones: BERT, GPT-1, GPT-2, GPT-3, T5, AlphaFold 2, GPT-4, Claude. We will understand how this lineage evolved, where we stand today, and where we may be tomorrow.

Chapter 11: From Transformer to ChatGPT — The Timeline

﴿وَفَوْقَ كُلِّ ذِي عِلْمٍ عَلِيمٌ﴾

"*And above every possessor of knowledge is one more knowing*." — Surah Yusuf: 76

In 2017, the Vaswani paper was a small seed. Today, almost a decade later, that seed has grown into an entire forest of models, forming what is now known as the *generative AI revolution*. In this chapter, we will sketch a clear timeline of how this lineage evolved, from 2017 to today.

2017: The Founding Paper

In June 2017, *Attention Is All You Need* was published at the NeurIPS conference. The paper was aimed at machine

translation. Its authors had no idea they had laid the foundation for everything that would follow.

In the months after publication, researchers began to explore the possibilities of the idea. It became clear that the Transformer was not just a replacement for LSTM, but a new architecture with fundamentally different capabilities.

2018: BERT — Deep Reading From Both Sides

In October 2018, Google announced BERT (Bidirectional Encoder Representations from Transformers). The idea was simple but powerful: use only the encoder of the Transformer, and train it to understand text *bidirectionally* (reading both right-to-left and left-to-right at once).

How was BERT trained? With a clever task called *masked language modeling*. A piece of text is taken, 15% of its words are randomly hidden, and the model is asked to predict the missing

words. For example: "*The child went to the ____ to learn.*" The model should predict *school*.

The task is simple, but it forces the model to understand everything around the missing word, building a deep understanding of language.

The result: BERT broke records in many areas — text classification, question answering, information extraction. It became foundational to Google Search itself.

2018–2020: GPT-1, GPT-2, GPT-3 — The Power of Generation

On the other side, OpenAI was exploring a different approach. In June 2018, it released GPT-1 (Generative Pre-trained Transformer). The idea: use only the decoder of the Transformer, and train it to predict the next word in a text.

For example: "*The sun rises in the ___.*" The model should predict *east*.

This task, despite its simplicity, forces the model to learn a great deal: grammar, general facts, writing style, and so on.

In February 2019, GPT-2 was released with 1.5 billion parameters (fourteen times the size of GPT-1). It made headlines because OpenAI initially refused to release the full version, fearing *misuse*. The model could write convincing essays from a single line of input.

In June 2020, GPT-3 was released with 175 billion parameters (more than 110 times GPT-2). It was a qualitative leap. The model became capable of:

- Writing code from a simple description.
- Translating between many languages without specific training.
- Writing stories in different styles.
- Answering complex questions.

GPT-3 was a watershed moment. For the first time, many researchers felt that AI was approaching *general intelligence*.

2019–2020: T5, XLNet, RoBERTa — Variations

Between BERT and GPT, models appeared that combined both sides or refined one of them:

- **T5 (Text-to-Text Transfer Transformer)** from Google in 2019: used the full architecture (encoder + decoder), and turned every task into a "text-to-text" problem.
- **XLNet** from Carnegie Mellon in 2019: tried to combine the advantages of BERT and GPT.
- **RoBERTa** from Facebook in 2019: a refined version of BERT with better training and more data.

All these models were exploring the space opened by the Vaswani paper.

2021: AlphaFold 2 — Attention Travels to Biology

In 2021, DeepMind published AlphaFold 2, which solved the *protein folding* problem — a problem that had remained open for fifty years in biology.

Proteins are chains of amino acids that fold up to take a specific three-dimensional structure. This structure determines the protein's function. Predicting structure from sequence was the *Holy Grail* of computational biology.

AlphaFold 2 used the attention mechanism in an inventive way and achieved astonishing accuracy. It triggered a revolution in drug discovery and opened doors to new medical breakthroughs. Its creators received the Nobel Prize in Chemistry in 2024.

This was a powerful confirmation of what I said in the previous chapter: the Transformer is not just a tool for language. It is a *general* tool for understanding relationships between elements.

2022: ChatGPT — The Moment the World Found Out

On November 30, 2022, OpenAI released ChatGPT to the public. Within a week, it surpassed one million users. Within two months, it surpassed 100 million. It was the fastest product to reach 100 million users in the history of technology.

ChatGPT was not just GPT-3. It was specifically trained for dialogue, using a technique called RLHF (Reinforcement Learning from Human Feedback). Thousands of human workers rated its responses, so the model learned to be helpful, safe, and friendly.

The moment ChatGPT appeared was as much a cultural moment as a technical one. Suddenly, AI became the topic of every conversation: from students to teachers to executives to politicians.

2023: GPT-4, Claude, and Gemini — The Big Race

In March 2023, OpenAI announced GPT-4, which surpassed its predecessor by a wide margin. It became capable of understanding images, writing complex code, and passing professional exams (like the bar exam).

Also in March 2023, Anthropic announced Claude, its competing model. Anthropic focused on *constitutional safety*, where the model commits to certain ethical principles in its responses.

By the end of 2023, Google launched Gemini, and in 2024 Meta released its open versions of LLaMA.

We now live in the *era of large models*. Every major tech company has a model. Every few months, a new one breaks records.

2024–2026: Scaling and Specialization

In recent years, we have seen two parallel developments:

First — continued scaling: bigger models, more data, new capabilities. ChatGPT now reads images and generates videos (Sora). Claude can operate computers. Gemini is integrated into every Google product.

Second — specialization: smaller but specialized models. Medical models, programming models, scientific models. Anthropic released Claude for code, and OpenAI released Codex. In biology, models like ESM-2 and AlphaFold 3 are determining biological structures with rising accuracy.

My Personal Research: Transformers in Genomics

In my lab at the University of Michigan, we apply Transformers to complex biological data. My specialty is *spatial transcriptomics*

— measuring gene expression in individual cells while knowing each cell's position within the tissue.

Imagine each cell as a *word*, and each tissue as a *sentence*. Transformers help us understand how cells interact with their neighbors, and how this interaction changes in diseases like cancer.

We recently published a paper on using Transformers for liver cancer data analysis. The model learned by itself to discover patterns in cell interactions that human researchers were missing. For me, this is the real promise of AI in medicine: not to replace doctors, but to enable them to see what they could not see on their own.

"*And above every possessor of knowledge is one more knowing.*"

In the verse opening this chapter, Allah reminds us that above every possessor of knowledge is one who is more knowing. This is an important verse for our time. However advanced AI

gets, there is always one who knows more: the true expert, the specialized individual, and ultimately Allah, exalted be He, who taught humanity what it did not know.

ChatGPT answers your questions, but the doctor you consult knows the context of your case. The doctor treats you, but the researcher who discovered the drug understood a deep mechanism. The researcher discovers, but the Creator of the universe perfected everything.

This *hierarchy of higher knowledge* reminds us of humility. Whatever we build, however advanced, remains limited before the greatness of creation.

What Comes Next?

In the final chapter, we will close our journey. We will summarize what we have learned. We will discuss the limits of Transformers and future directions. And I will issue an open invitation to every interested Arab reader: do not stop at reading — take part in shaping the future.

Chapter 12: Conclusion — Attention and Beyond

﴿قُلْ هَلْ يَسْتَوِي الَّذِينَ يَعْلَمُونَ وَالَّذِينَ لَا يَعْلَمُونَ﴾

"*Say, 'Are those who know equal to those who do not know?'*" — Surah Az-Zumar: 9

We have now reached the end of our journey. Twelve chapters, beginning with a simple question: *what is the paper Attention Is All You Need? And why did it change the world?*

In this final chapter, I will do three things. First, I will summarize what we have learned. Second, I will discuss the limits of Transformers and future directions. Third, I will issue an open invitation to every Arab reader who has reached these pages.

What We Have Learned in Our Journey

Let me retell the story in a few paragraphs.

In the summer of 2017, a team of eight researchers at Google published a short paper with a bold title: *Attention Is All You Need*. The paper proposed a new architecture for AI called the *Transformer*, which abandoned the recurrent neural networks (RNN/LSTM) that had dominated language processing, and relied entirely on a single mechanism: *self-attention*.

Attention is an idea inspired by human cognition. When we read a sentence, we do not look at every word with equal weight. Our mind *attends to* the words most relevant to understanding. The attention mechanism brought this idea to the machine. Every word looks at every other word, and weights are computed to determine which ones matter most.

Technically, the attention mechanism rests on three elements: *Query*, *Key*, and *Value*. Every word generates these three. Queries are compared to keys via dot product, turned into weights via softmax, then used to mix the values.

To deepen understanding, Vaswani and his colleagues used *multi-head attention*, where several attention mechanisms run in parallel, each viewing the sentence from a different angle.

And because attention ignores order, they added *positional encoding* to tell the model where each word sits.

The full Transformer structure consists of an *encoder* that builds an understanding of the source sentence, and a *decoder* that generates the new sentence. But later models (BERT, GPT) used only half the structure, depending on the task.

Training a Transformer requires huge data, a *loss function* to tell the model when it errs, and *backpropagation* to update weights. The original paper trained on 4.5 million sentence pairs in 12 hours. Today, large models cost millions of dollars and months of compute.

What made the paper revolutionary was speed, quality, scalability, generality, and simplicity. These five properties opened the door to an entire generation of models: BERT, GPT-2, GPT-3, AlphaFold, ChatGPT, Claude, Gemini, and others.

The Paper's Underlying Message: Simplicity and Scale = Power

If I had to summarize the message of the Vaswani paper in a single sentence, it would be: "*Simplicity, when joined with scale, produces unprecedented power.*"

This message is not specific to AI. It is a truth that applies to many parts of life. A simple idea, when repeated faithfully and persistently, becomes something great. The repeated remembrance of Allah, daily prayers, small habits compounded — all are applications of this principle in our spiritual and practical lives.

The Limits of the Transformer

For all its power, the Transformer is not without limits. Let me mention three of the most important.

First — quadratic computational cost: the number of operations in attention scales with the square of sentence

length. If we double the sentence length, the operations quadruple. This makes very long inputs (like an entire book) extremely costly.

Second — lack of true reasoning: Transformers excel at *statistical modeling* of text — they predict the next word based on what they have seen. But they do not *think* in the human sense. They do not plan, they do not reason in a strict logical way, they do not know what they do not know. These limits show up in *hallucinations* — when the model invents incorrect information with confidence.

Third — dependence on human-curated data: today's models learn from text written by humans. If we want AI that can learn more independently, we will need different mechanisms.

Future Directions

Where is the field heading? Some current developments:

State Space Models: such as Mamba, try to achieve the benefits of Transformers at lower computational cost. They scale linearly rather than quadratically.

Sparse attention: tries to reduce operations by focusing only on the *important* words rather than all of them.

Hybrid models: combine Transformers with other architectures. For example, models that use Transformers at the document level and RNNs at the word level.

Agentic AI: models that do not just answer, but plan, decide, and execute multi-step tasks. ChatGPT and Claude have begun moving in this direction.

Transformers in biology: models that understand DNA, proteins, cells, and tissues. This is my field, and I see a stunning future for it.

Artificial General Intelligence (AGI): the largest question — will models reach intelligence rivaling humans across all tasks? Some researchers believe we are close. Others see fundamental obstacles still ahead. The honest answer: nobody knows.

An Open Invitation to the Arab Reader

I now come to the part of this book I treasure most. You, the Arab reader who has reached these pages: I address you directly.

Many of us, we Arabs, read about AI as spectators. We follow what is being made in Silicon Valley and China, and we wonder: *why are we not among them? Why have we not contributed?*

The answer is simple: because we have not yet decided to contribute. This book — these pages in your hands — is a beginning. It is proof that deep technical knowledge can be written in Arabic, conveyed to Arab minds, and inspire a new generation.

If you are a student, learn to program. It is not enough to understand the theory. Start with Python, with PyTorch, with Hugging Face. Train your own small models. Break something, then fix it. Learn by doing.

If you are a researcher, publish in Arabic as much as you publish in English. Write blogs that summarize new papers. Engage in Arabic communities on Twitter and LinkedIn. You are a model the next generation needs.

If you are a professional in another field — a doctor, an engineer, an accountant, a teacher — think about how AI can serve your field. You know your field's problems better than any engineer in Silicon Valley. Connecting your domain knowledge to these new tools may produce something unique.

If you are a parent, teach your children that AI is not a mysterious wonder. It is a tool. Help them understand it, use it wisely, and contribute to its development.

If you are wealthy, invest in Arab researchers. Support research labs in our universities. Build Arab startups. The real gold of the AI era is not oil — it is the researcher who solves a new problem.

A Final Personal Note

As a Yemeni researcher who has lived in the United States for years, I always carry a sense of responsibility. With every paper I publish, I reflect: does this paper serve all of humanity? Does it serve my country? Does it serve the Arab and Islamic world?

I wrote this book for one reason: to dismantle a barrier. The barrier that keeps many of my brothers and sisters from approaching this field. The barrier that says, "*This is for the West, not for us*." The barrier that makes English terminology feel like obscure magic.

But AI is not magic. It is a human enterprise, carried out by people like you and me, who carry ideas, make mistakes, learn, and contribute. There is no difference between a researcher in Michigan and a researcher in Sana'a or Cairo or Riyadh, except opportunity.

So I close this book with a prayer: *O Allah, teach us what benefits us, benefit us with what You have taught us, and increase us in knowledge. O Allah, make this nation a nation that contributes to*

every beneficial science, and to every good for all of humanity. O Allah, guide us to the best of conduct, for none guides to the best of it but You, and turn from us its evil, for none turns its evil from us but You.

And Allah knows best.

Chapter 13: References and Further Reading

﴿وَمَا أُوتِيتُم مِّنَ الْعِلْمِ إِلَّا قَلِيلًا﴾

"*And of knowledge, you have been given only a little.*" — Surah Al-Isra: 85

Every book is a starting point, not an end. What I have given you in the preceding twelve chapters is a simplified distillation of what I have learned and studied over years. But the subject is far deeper and wider than this. In this chapter, I lay out a structured guide for further reading, organized by level and interest.

I. The Original Paper and What Surrounds It

The founding paper:

1. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems* (*NeurIPS*), 30. Available freely on arXiv: https://arxiv.org/abs/1706.03762

This is the paper we have been talking about throughout this book. I encourage you to read it yourself after finishing this book — you will find it easier than you imagine.

Excellent visual explanations in English:

1. Alammar, J. (2018). *The Illustrated Transformer*. A personal blog that explains the Transformer visually with stunning clarity. https://jalammar.github.io/illustrated-transformer/

2. Karpathy, A. (2022). *Let's Build GPT From Scratch*. A YouTube video series from one of the most prominent former OpenAI researchers.

II. Key Milestones in Model Evolution

BERT:

1. Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *arXiv*:1810.04805.

The GPT series:

1. Radford, A., Narasimhan, K., Salimans, T., & Sutskever, I. (2018). Improving Language Understanding by Generative Pre-Training (GPT-1).

2. Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., & Sutskever, I. (2019). Language Models are Unsupervised Multitask Learners (GPT-2).

3. Brown, T. B., et al. (2020). Language Models are Few-Shot Learners (GPT-3). *NeurIPS* 2020.

4. OpenAI. (2023). GPT-4 Technical Report. *arXiv*: 2303.08774.

T5 and RoBERTa:

1. Raffel, C., et al. (2020). Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer (T5). *Journal of Machine Learning Research*.

2. Liu, Y., et al. (2019). RoBERTa: A Robustly Optimized BERT Pretraining Approach. *arXiv*:1907.11692.

III. Transformers in Biology

AlphaFold:

1. Jumper, J., et al. (2021). Highly accurate protein structure prediction with AlphaFold. *Nature*, 596(7873), 583-589.

This work earned its authors the Nobel Prize in Chemistry in 2024.

1. Abramson, J., et al. (2024). Accurate structure prediction of biomolecular interactions with AlphaFold 3. *Nature*.

Other protein models:

1. Lin, Z., et al. (2023). Evolutionary-scale prediction of atomic-level protein structure with a language model (ESM-2). *Science*.

Spatial transcriptomics and Transformers:

1. Cui, H., et al. (2024). scGPT: Toward Building a Foundation Model for Single-Cell Multi-omics Using Generative AI. *Nature Methods*.

2. My own research papers from the University of Michigan lab on applying Transformers to liver cancer data, available through my Google Scholar page.

IV. Transformers in Computer Vision

1. Dosovitskiy, A., et al. (2021). An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale (ViT). *ICLR* 2021.

2. Liu, Z., et al. (2021). Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. *ICCV* 2021.

V. Recent Developments (2024–2026)

State Space Models:

1. Gu, A., & Dao, T. (2024). Mamba: Linear-Time Sequence Modeling with Selective State Spaces. *ICLR* 2024.

RoPE (Rotary Positional Encoding):

1. Su, J., et al. (2024). RoFormer: Enhanced Transformer with Rotary Position Embedding. *Neurocomputing*.

Improvements in training large models:

1. Hoffmann, J., et al. (2022). Training Compute-Optimal Large Language Models (Chinchilla). *arXiv*:2203.15556.

2. Kaplan, J., et al. (2020). Scaling Laws for Neural Language Models. *arXiv*:2001.08361.

VI. Resources for Beginners in Arabic

Unfortunately, Arabic-language references in this field are still scarce. But there are admirable efforts:

- The **Edraak** platform — free courses in AI and its foundations.
- **Ahmed Alaa**'s YouTube channel — Arabic lessons in machine learning and neural networks.
- **Hsoub Academy** blog — technical articles in Arabic.
- The site *Artificial Intelligence in Arabic* — selected translations and articles.

VII. Hands-On Learning Resources

If you want to apply what you have learned, here are the best places to begin:

1. **Hugging Face Transformers**: a free library that lets you use Transformers with ease. https://huggingface.co/
2. **PyTorch Tutorials**: official lessons from Meta AI. https://pytorch.org/tutorials/
3. **Andrej Karpathy's nanoGPT**: a simplified GPT model in about 300 lines of code, excellent for learning. https://github.com/karpathy/nanoGPT
4. **fast.ai**: free practical courses in deep learning. https://www.fast.ai/

VIII. Spiritual and Intellectual Resources

Knowledge is not separable from meaning. Here are some references that connect modern science with the Islamic heritage:

- Ibn Khaldun, *The Muqaddimah* — on the nature of knowledge and scientific method.
- Al-Ghazali, *Ihya' Ulum al-Din* — on the pursuit of knowledge and its etiquette.
- Muhammad Abdullah Draz, *The Moral Constitution in the Qur'an* — a reference in ethics.
- Malik Bennabi, *The Problem of Ideas in the Muslim World* — on the role of ideas in the rise of nations.
- Various works on the history of Islamic science by modern Arab scholars.

IX. To Reach Out and Stay in Touch

Modern communication has given me the opportunity to engage with readers. If you wish to follow new research and writings of mine:

- My personal site and library: https://fadhlyemen.github.io/library/
- My email: alakwaaf@umich.edu
- My academic page: Google Scholar.

I welcome your questions, comments, and suggestions. This book is not my work alone — it is the fruit of years of study, reading, and discussion. And you, the reader, complete this circle by taking what is here and spreading it and refining it.

A Closing Word

"*And of knowledge, you have been given only a little*." This verse is the best note on which to close a reading guide. Everything I have offered here is a drop in an ocean. There are hundreds of

new scientific papers every month. There are thousands of researchers making discoveries every day.

Do not be intimidated by the abundance. Begin with one source. Read it with reflection. Then move to the next. Over time, you will build cumulative understanding and find yourself part of the global conversation in this field.

And success is from Allah alone. Upon Him I rely.

عن الكتاب

شرح مبسط وسلس لورقة المحولات الشهيرة Attention Is All You Need التي أحدثت ثورة في الذكاء الاصطناعي عام 2017 ومهدت الطريق لنماذج مثل ChatGPT وBERT وClaude. يقدم المؤلف المفاهيم التقنية بأسلوب تشبيهي يفهمه القارئ غير المتخصص مع ربطها بمنظور إسلامي في طلب العلم والتدبر.

عن المؤلف

الدكتور فضل محمد الأكوع باحث في البيولوجيا الحاسوبية والمعلوماتية الحيوية والجينوميات المكانية بجامعة ميشيغان في آن أربر. تتمحور أبحاثه حول تطبيق الذكاء الاصطناعي في دراسة الأمراض المزمنة، ومن أبرز أعماله المنشورة دراسات على مثبطات ناقل الصوديوم-غلوكوز 2 (SGLT2) والتغيرات الأنبوبية الكلوية المنشورة في مجلة JCI عام 2023. إلى جانب مسيرته العلمية، يكتب د. فضل باللغتين العربية والإنجليزية في حقول متعددة تشمل الدراسات القرآنية، تاريخ اليمن والسياسة، الذكاء الاصطناعي والتقنية، الأسرة والتربية، ودليل المهاجرين في المهجر.

مؤلفات المؤلف الأخرى

قراءة شرائح الكلى المرضية دليل عملي لتفسير صبغة H&E (2026)

الدليل العملي لمهنة ميكانيكي السيارات في أمريكا (2026)

أفضل المدن للعيش في الولايات المتحدة الأمريكية (2026)

عالم القهوة رحلة من المزرعة إلى الفنجان (2026)

دليل الاستثمار في سوق الأسهم التاريخ والمستقبل وأسرار الثروة (2026)

المثلية الجنسية قراءة في التاريخ والحجج والأديان (2026)

بايثون للذكاء الاصطناعي: من الصفر إلى البناء (2026)

معالجة اللغة العربية مع نماذج الذكاء الاصطناعي: العمل بلغتك الأم (2026)

البناء مع كلود — دليل عملي لواجهة برمجة Anthropic (2026)

بناء معرض أعمالك في مجال الذكاء الاصطناعي: 30 مشروعاً حقيقياً (2026)

هندسة الأوامر — فن التحاور مع الذكاء الاصطناعي (2026)

الذكاء الاصطناعي لصنّاع المحتوى - دليل التصميم والصوت والفيديو (2026)

الأتمتة بدون كود - دليل بناء سير عمل ذكي (2026)

العملاء الأذكياء وبروتوكول MCP - بناء أنظمة ذكاء اصطناعي مستقلة (2026)

التوليد المعزز بالاسترجاع - دليل عملي لبناء أنظمة RAG (2026)

العمل الحر بالذكاء الاصطناعي — دليل المستقل اليمني والعربي (2026)

نوت بوك إل إم — الدليل الشامل (2026)

القانون الجميل الكبير - تشريح إصلاح ترامب الضريبي وتأثيره على أمريكا (2026)

التقارب السني الشيعي (2026)

الذكاء الاصطناعي ومستقبل المهن — أيها يندثر وأيها يصعد (2026)

التأشيرات الاستثمارية في أمريكا — دليل المقارنة والاختيار (2026)

اليمن في ملفات إبستين (2026)

الرئيس إبراهيم الحمدي — حياته ومشروعه الوطني (2026)

الشخصيات العامة التي فقدت وظائفها بسبب موقفها من غزة (2026)

الصوفية — دراسة شاملة (2026)

الطعام والصحة بين العلم الحديث والحديث النبوي (2026)

النظام الضريبي الأمريكي — دليل شامل (2026)

دليل شراء اللحم الحلال في ميشيجان وإنديانا (2026)

سلسلة التوريد — دليل شامل (2026)

ميكانيكا الكم — دراسة شاملة (2026)

أدوات الذكاء الاصطناعي — دليل شامل (2026)

Mythos في مواجهة نماذج Anthropic (2026)

مهارات كلود — كيف يجعلك استخدامها خبيراً في كل شيء (2026)

البوذية والهندوسية — النشأة والانتشار والمقارنة (2026)

الذنوب والمعاصي والأخلاق في الإسلام — مقارنة مع الأديان الأخرى (2026)

الذكاء الاصطناعي وثورة اكتشاف الأدوية (2026)

حرب غزة — كيف فضحت المجتمع الدولي (2026)

مجازر ضد المسلمين عبر العصور (2026)

العلاقات اليمنية السعودية — تاريخ وتحولات عبر الأزمان (2026)

كيف تؤسّس شركتك في أمريكا (2026)

هندسة البيانات — الدليل الشامل (2026)

جماعة الدعوة والتبليغ — دراسة شاملة (2026)

أجيال على المحك — الإسلام في المهجر بين الحفاظ والانسلاخ (2026)

المسلمون في الغرب — الإنجازات والتحديات والاندماج (2026)

الربا في الإسلام والبنوك الإسلامية (2026)

القرآن والإنجيل – دراسة مقارنة في مفاهيم السلام والقتال والتسامح (2026)

نهاية الكون في القرآن الكريم (2026)

مشاكل اليمن عبر الأزمان (2026)

سر التقارب الأمريكي الإسرائيلي – من يقود من؟ (2026)

هل انتهت الوحدة اليمنية؟ (2026)

الرؤساء اليمنيون في مذكرات ويكيليكس (2026)

أسرار قوة التحالف الأمريكي الإسرائيلي (2026)

فن التربية – كيف تصنع قادة من أبنائك (2026)

تأثير النماذج اللغوية الكبيرة على البحث العلمي والتعليم الجامعي (2026)

علامات الساعة (2026)

التخطيط للتقاعد (2026)

العملات الرقمية – دليل شامل للمبتدئين (2026)

وادي السيليكون — تاريخ وابتكار وريادة عالمية (2026)

أشهر المتنزهات الوطنية في أمريكا (2026)

دليل شراء وبيع السيارات المستعملة في أمريكا (2026)

كلود كود — الدليل الشامل (2026)

دليل المهاجر اليمني الجديد إلى أمريكا (2026)

الحقوق الزوجية والحياة الأسرية للمسلمين في الغرب (2026)

مستقبل المعلوماتية الحيوية والبيولوجيا الحاسوبية في عصر الذكاء الاصطناعي (2026)

تصنيف الآيات في القرآن الكريم — دراسة تأملية في البنية الموضوعية (2026)

كيف تعمل النماذج اللغوية الكبيرة — دليل مبسّط (2026)

سر قوة الجامعات الأمريكية (2026)

عتيقة — حكاية جدتي من جبال اليمن (2026)

الخلافة الإسلامية: من السقيفة إلى سقوط غرناطة (2026)

السلفية — دراسة في المفهوم والنشأة والتيارات المعاصرة (2026)

النقد المشروع وحدود معاداة السامية (2026)

كيف تنجح أكاديمياً في الجامعات الأمريكية (2026)

الزواج الناجح — دليل عملي بمنظور إسلامي (2026)

الإعجاز العلمي في القرآن — من منظور باحث في الجينوميات (2026)

أمريكا — صعود القوة وبوادر الأفول (2026)

About this Book

A clear and accessible explanation of the landmark 2017 paper Attention Is All You Need, which revolutionized artificial intelligence and gave rise to ChatGPT, BERT, Claude, and modern language models. The author a computational biologist at the University of Michigan unpacks every concept through analogy, intuition, and Islamic reflection on the pursuit of knowledge.

About the Author

Dr. Fadhl Mohammed Alakwaa is a researcher in computational biology, bioinformatics, and spatial genomics at the University of Michigan in Ann Arbor. His research focuses on applying AI to the study of chronic diseases; among his notable publications are studies on SGLT2 inhibitors and kidney tubular changes published in JCI in 2023. Alongside his scientific career, Dr. Alakwaa writes in both Arabic and English across fields including Quranic studies, Yemeni history and politics, AI and technology, family and parenting, and guides for diaspora life.