كيف تعمل النماذج اللغوية الكبيرة

دليل مبسط لفهم ثورة الذكاء الاصطناعي

How Large Language Models Work

A Simplified Guide to Understanding the AI Revolution

د. فضل محمد الأكوع

Dr. Fadhl Mohammed Alakwaa

Arabic & English | عربي - إنجليزي

2026

كيف تعمل النماذج اللغوية الكبيرة

دليل مبسّط لفهم ثورة الذكاء الاصطناعي

How Large Language Models Work

A Simplified Guide to Understanding the AI Revolution

د. فضل محمد الأكوع

Dr. Fadhl Mohammed Alakwaa

الطبعة الأولى — 2026

جميع الحقوق محفوظة للمؤلف

بِسۡمِ ٱللَّهِ ٱلرَّحۡمَٰنِ ٱلرَّحِيمِ

بِسْمِ اللَّهِ الرَّحْمَٰنِ الرَّحِيمِ

إهداء

إلى كل باحث عن المعرفة

يسعى لفهم التكنولوجيا التي تُشكّل مستقبلنا

إلى أساتذتي الذين علّموني أن العلم نور

وإلى طلابي الذين يدفعونني دائماً للتبسيط والتوضيح

إلى روح والدي رحمه الله

وأمي حفظها الله

وزوجتي وأولادي

المحتويات

المقدمة

الفصل الأول: ما هي النماذج اللغوية الكبيرة؟

— تعريف بسيط — أمثلة من حياتنا اليومية — لماذا كلمة "كبيرة"؟

الفصل الثاني: الرحلة من الصفر — كيف بدأ كل شيء

— من الترجمة الآلية إلى الشبكات العصبية — مشكلة الذاكرة القصيرة

الفصل الثالث: "كل ما تحتاجه هو الانتباه" — ورقة غيّرت العالم

— آلية الانتباه — بنية المحوّل — لماذا كانت ثورية؟

الفصل الرابع: كيف يتعلم النموذج اللغوي؟

— التدريب المسبق — الضبط الدقيق — التعلم من ردود الفعل البشرية

الفصل الخامس: من GPT إلى Claude — خريطة النماذج الكبرى

— جدول مقارنة شامل — نقاط القوة والضعف

الفصل السادس: لماذا كل هذا الاستثمار الضخم؟

— أرقام الاستثمار — سباق الشركات الكبرى

الفصل السابع: الطاقة المُستهلكة — الثمن البيئي

— استهلاك الكهرباء — التأثير على فواتير المواطنين

الفصل الثامن: المحوّلات خارج اللغة — ثورة في البيولوجيا والعلوم

— Geneformer — AlphaFold — محوّلات الصور والصوت

الفصل التاسع: جدول شامل لأهم النماذج المبنية على المحوّلات

الفصل العاشر: المستقبل — إلى أين نتجه؟

الخاتمة

المراجع العلمية

القسم الإنجليزي — English Section

نبذة عن المؤلف

مؤلفات المؤلف

المقدمة

﴿ اقْرَأْ بِاسْمِ رَبِّكَ الَّذِي خَلَقَ ۝ خَلَقَ الْإِنسَانَ مِنْ عَلَقٍ ۝ اقْرَأْ وَرَبُّكَ الْأَكْرَمُ ۝ الَّذِي عَلَّمَ بِالْقَلَمِ ۝ عَلَّمَ الْإِنسَانَ مَا لَمْ يَعْلَمْ ﴾

[سورة العلق: ١-٥]

نعيش اليوم في عصر تحوّل تكنولوجي غير مسبوق. ففي غضون سنوات قليلة، أصبحت النماذج اللغوية الكبيرة (Large Language Models - LLMs) جزءاً من حياتنا اليومية. نستخدمها في كتابة الرسائل، وتلخيص المقالات، والبحث عن المعلومات، بل وحتى في كتابة البرامج الحاسوبية والتشخيص الطبي.

لكن كثيراً من الناس يستخدمون هذه التقنية دون أن يفهموا كيف تعمل. كيف يستطيع برنامج حاسوبي أن "يفهم" سؤالك ويجيبك بلغة طبيعية وكأنه إنسان؟ هل يفكّر فعلاً؟ كيف تم اختراعه؟ ولماذا تُنفق الشركات مليارات الدولارات على تطويره؟

هذا الكتاب كُتب لغير المتخصصين. هدفه أن يشرح لك — ببساطة ووضوح — كل ما تحتاج معرفته عن النماذج اللغوية الكبيرة: كيف وُلدت الفكرة، وكيف تعمل من

الداخل، ولماذا تُعتبر ثورة تكنولوجية حقيقية، وما هو حجم الاستثمار والطاقة التي تستهلكها.

والأمر لا يقتصر على اللغة. فتقنية "المحوّلات" (Transformers) التي تقف خلف هذه النماذج اللغوية قد غزت مجالات أخرى كثيرة: من التنبؤ ببنية البروتينات مع AlphaFold إلى فهم شبكات الجينات مع Geneformer. سنستعرض هذه التطبيقات أيضاً ونرى كيف أن فكرة واحدة بسيطة — وهي آلية "الانتباه" (Attention) — غيّرت وجه العلم والتكنولوجيا.

أسأل الله أن يكون هذا الكتاب مفيداً لكل قارئ يسعى لفهم هذا العالم المتسارع، وأن يُسهم في نشر المعرفة العلمية بلغتنا العربية الجميلة.

الفصل الأول: ما هي النماذج اللغوية الكبيرة؟

﴿ وَعَلَّمَ آدَمَ الْأَسْمَاءَ كُلَّهَا ﴾

[سورة البقرة: ٣١]

تعريف بسيط

تخيّل أنك تقرأ ملايين الكتب والمقالات والمحادثات. بعد كل هذه القراءة، ستكوّن فهماً عميقاً للغة: ستعرف أن كلمة "القهوة" غالباً ما ترتبط بـ"الصباح" و"الكوب" و"النكهة"، وأن "الطبيب" يرتبط بـ"المريض" و"العلاج" و"المستشفى".

هذا بالضبط ما يفعله النموذج اللغوي الكبير. إنه برنامج حاسوبي قرأ كمية هائلة من النصوص — مليارات الصفحات من الإنترنت والكتب والأبحاث — وتعلّم منها أنماط اللغة وعلاقات الكلمات ببعضها.

لكن النموذج اللغوي لا "يفهم" اللغة كما نفهمها نحن البشر. إنه يتنبأ بالكلمة التالية الأكثر احتمالاً بناءً على السياق. عندما تكتب: "الشمس تشرق من..."، يتنبأ النموذج بأن الكلمة التالية هي "الشرق" لأنه رأى هذه العبارة آلاف المرات في بيانات التدريب.

📌 **بكلمات أبسط:** النموذج اللغوي الكبير هو آلة ذكية جداً في التنبؤ بالكلمة التالية. وعندما تفعل ذلك بدقة عالية جداً على نطاق واسع جداً، ينتج عنها نصوص تبدو وكأنها كُتبت بواسطة إنسان.

أمثلة من حياتنا اليومية

في الحقيقة، أنت تستخدم نسخاً مبسّطة من هذه التقنية كل يوم دون أن تدري:

عندما تكتب رسالة على هاتفك ويقترح عليك الهاتف الكلمة التالية — هذه نسخة بسيطة جداً من التنبؤ اللغوي. النماذج اللغوية الكبيرة مثل ChatGPT وClaude وGemini تفعل الشيء نفسه لكن بقدرات أكبر بملايين المرات. يمكنها كتابة مقالات كاملة، وتحليل بيانات معقدة، والإجابة عن أسئلة علمية دقيقة.

عندما تسأل المساعد الذكي في هاتفك سؤالاً، أو تطلب من ChatGPT كتابة بريد إلكتروني، أو تستخدم Claude لمراجعة بحث علمي — كل هذه التطبيقات تعتمد على النماذج اللغوية الكبيرة.

لماذا كلمة "كبيرة"؟

كلمة "كبيرة" في اسم هذه النماذج تشير إلى حجمها الهائل من حيث عدد "المعاملات" (Parameters). المعاملات هي الأرقام التي يتعلمها النموذج أثناء التدريب — تخيلها كخلايا الدماغ والروابط بينها.

النماذج الحديثة تحتوي على مئات المليارات من المعاملات. نموذج GPT-3 مثلاً يحتوي على 175 مليار معامل، والنماذج الأحدث تحتوي على أكثر من تريليون معامل. هذا الحجم الهائل هو ما يمنحها قدرات مذهلة، لكنه أيضاً السبب وراء تكلفتها العالية واستهلاكها الكبير للطاقة كما سنرى لاحقاً.

📌 **مقارنة بسيطة:** دماغ الإنسان يحتوي على حوالي 86 مليار خلية عصبية مع 100 تريليون وصلة بينها. النماذج اللغوية الكبرى تقترب من هذه الأرقام رقمياً، لكنها تعمل بطريقة مختلفة تماماً عن الدماغ البشري.

الفصل الثاني: الرحلة من الصفر — كيف بدأ كل شيء

﴿ وَاللَّهُ أَخْرَجَكُم مِّن بُطُونِ أُمَّهَاتِكُمْ لَا تَعْلَمُونَ شَيْئًا وَجَعَلَ لَكُمُ السَّمْعَ وَالْأَبْصَارَ وَالْأَفْئِدَةَ لَعَلَّكُمْ تَشْكُرُونَ ﴾

[سورة النحل: ٧٨]

البدايات: محاولات ترجمة اللغة

حلم تعليم الحاسوب فهم اللغة البشرية قديم قِدَم الحاسوب نفسه. في خمسينيات القرن العشرين، حاول العلماء بناء برامج ترجمة آلية بقواعد لغوية صارمة: "إذا كانت الكلمة فعلاً ماضياً، ترجمها إلى الزمن الماضي في اللغة الأخرى." لكن اللغة البشرية أعقد بكثير من القواعد الجامدة. الكلمة الواحدة قد يكون لها عشرات المعاني حسب السياق.

الشبكات العصبية: محاكاة الدماغ

في الثمانينيات والتسعينيات، ظهرت فكرة بديلة: بدلاً من كتابة قواعد يدوية، لماذا لا نبني نظاماً يتعلم من الأمثلة كما يتعلم الطفل؟ هذه هي فكرة "الشبكات العصبية

الاصطناعية" (Neural Networks)، وهي نماذج رياضية مستوحاة من طريقة عمل الخلايا العصبية في الدماغ.

الشبكة العصبية الاصطناعية تتكون من طبقات من "العُقد" (Nodes). كل عُقدة تستقبل معلومات من العُقد السابقة، تعالجها، وتمررها للعُقد التالية. من خلال تعديل قوة الروابط بين العُقد (وهذه هي المعاملات)، تتعلم الشبكة التعرف على الأنماط في البيانات.

رسم توضيحي مبسّط للشبكة العصبية:

طبقة الإدخال → طبقات مخفية (معالجة) → طبقة الإخراج

[كلمات النص] → [تحليل الأنماط والعلاقات] → [الكلمة المتوقعة التالية]

كل سهم يمثل "معاملاً" يتم ضبطه أثناء التدريب

الشبكات المتكررة ومشكلة الذاكرة القصيرة

لمعالجة النصوص، طُوّرت "الشبكات العصبية المتكررة" (RNNs)، التي تقرأ النص كلمة كلمة بالتسلسل — تماماً كما نقرأ نحن. كل كلمة تُعالج مع الاحتفاظ بـ"ذاكرة" عن الكلمات السابقة.

لكن هذه الشبكات عانت من مشكلة كبيرة: كلما طال النص، كلما نسيت بداية الجملة. تخيّل أنك تقرأ فقرة طويلة وعندما تصل لنهايتها نسيت بدايتها — هذا بالضبط ما كان يحدث مع RNNs.

جاءت تحسينات مثل LSTM (ذاكرة طويلة قصيرة المدى) وGRU لمحاولة حل هذه المشكلة، لكنها كانت حلولاً جزئية. المشكلة الأكبر كانت أن هذه الشبكات تعالج الكلمات واحدة تلو الأخرى بالتسلسل، مما يجعلها بطيئة جداً ولا يمكن تسريعها بالحوسبة المتوازية.

كان العالم بحاجة إلى فكرة جديدة تماماً. وهذه الفكرة جاءت في عام 2017 من فريق في شركة Google.

الفصل الثالث: "كل ما تحتاجه هو الانتباه"
الورقة التي غيّرت العالم

﴿ إِنَّ فِي ذَٰلِكَ لَآيَاتٍ لِّقَوْمٍ يَتَفَكَّرُونَ ﴾

[سورة الرعد: ٣]

الورقة العلمية التي غيّرت كل شيء

في يونيو 2017، نشر ثمانية باحثين من Google ورقة بحثية بعنوان بسيط لكنه ثوري: "Attention Is All You Need" أي "كل ما تحتاجه هو الانتباه". هذه الورقة قدّمت بنية جديدة تماماً للشبكات العصبية أسمتها "المحوّل" (Transformer).

الباحثون الثمانية هم: أشيش فاسواني، نعومي شازير، نيكي بارمار، جاكوب أوزكوفيتش، ليون جونز، أيدان جوميز، لوكاش كايزر، وإيليا بولوسوخين. كثير منهم أسسوا لاحقاً شركات ذكاء اصطناعي ناجحة، مما يدل على أهمية عملهم.

ما هي آلية الانتباه؟

لنفهم آلية الانتباه بمثال بسيط. عندما تقرأ هذه الجملة: "ذهب الطالب إلى المكتبة لأنه يريد أن يستعير كتاباً"، دماغك يربط تلقائياً كلمة "لأنه" بكلمة "الطالب" وليس "المكتبة". هذا هو "الانتباه" — القدرة على ربط كل كلمة بالكلمات الأكثر صلة بها في الجملة بأكملها.

آلية الانتباه في المحوّل تعمل بالطريقة نفسها. عند معالجة كلمة معينة، ينظر النموذج إلى جميع الكلمات الأخرى في النص ويحسب "درجة انتباه" تحدد مدى أهمية كل كلمة بالنسبة للكلمة المعالجة حالياً.

📌 **مثال عملي:**

الجملة: "القطة جلست على السجادة لأنها مريحة"

عند معالجة "لأنها": هل تعود على "القطة" أم "السجادة"؟

آلية الانتباه تعطي وزناً أعلى لـ"السجادة" لأن صفة "مريحة" ترتبط بها أكثر في هذا السياق.

الانتباه الذاتي (Self-Attention)

"الانتباه الذاتي" هو أهم ابتكار في بنية المحوّل. الفكرة أن كل كلمة في النص "تنظر" إلى جميع الكلمات الأخرى لتحديد أيها أكثر أهمية لفهم معناها. هذا يحدث عبر ثلاث خطوات رياضية بسيطة المفهوم:

١. **الاستعلام (Query):** كل كلمة تسأل: "ما الذي أبحث عنه؟"

٢. **المفتاح (Key):** كل كلمة أخرى تقول: "هذا ما أقدمه."

٣. **القيمة (Value):** كل كلمة تحمل معلوماتها الفعلية.

يتم حساب التوافق بين الاستعلام والمفاتيح لتحديد مقدار "الانتباه" الذي تحصل عليه كل كلمة، ثم تُجمع القيم بحسب هذه الأوزان. النتيجة هي تمثيل غني لكل كلمة يأخذ بعين الاعتبار سياقها الكامل.

الانتباه متعدد الرؤوس (Multi-Head Attention)

لجعل النموذج أكثر قدرة، استخدم الباحثون ما يُسمى "الانتباه متعدد الرؤوس". الفكرة أن النموذج يقوم بعملية الانتباه عدة مرات بشكل متوازٍ، وكل "رأس" ينتبه لنوع مختلف من العلاقات.

تخيّل أنك في اجتماع وهناك عدة أشخاص يستمعون — واحد ينتبه للأسماء، وآخر ينتبه للأرقام، وثالث ينتبه للمشاعر. هذا تقريباً ما تفعله الرؤوس المتعددة: كل رأس يلتقط نوعاً مختلفاً من العلاقات اللغوية.

بنية المحوّل: المُشفّر والمُفكّك

المحوّل الأصلي يتكون من جزأين رئيسيين:

المُشفّر (Encoder): يقرأ النص المُدخل ويحوّله إلى تمثيل رقمي غني بالمعنى. كل طبقة من المُشفّر تتكون من آلية انتباه ذاتي تليها شبكة عصبية بسيطة.

المُفكّك (Decoder): يأخذ التمثيل من المُشفّر ويولّد النص الناتج كلمة بكلمة. يستخدم نوعين من الانتباه: انتباه ذاتي للكلمات التي أنتجها حتى الآن، وانتباه على مخرجات المُشفّر.

Transformer Architecture (Simplified)

Input Text → [Embedding + Position] → [Encoder: Self-Attention → Feed-Forward] × N layers

↓

[Decoder: Masked Self-Attention → Cross-Attention → Feed-Forward] × N layers → Output Text

N = number of layers (e.g., 6 in original, 96+ in modern models)

لماذا كانت هذه الورقة ثورية؟

ثلاثة أسباب جعلت المحوّل ثورياً:

أولاً: التوازي (Parallelism). بعكس الشبكات المتكررة التي تعالج الكلمات واحدة تلو الأخرى، يعالج المحوّل جميع الكلمات في نفس الوقت. هذا يعني أنه يمكن الاستفادة من وحدات معالجة الرسوميات (GPUs) القوية لتسريع التدريب بشكل هائل.

ثانياً: السياق البعيد. يستطيع المحوّل ربط كلمة ببداية النص بكلمة في نهايته مباشرة، دون أن "ينسى" كما كانت تفعل الشبكات المتكررة.

ثالثاً: قابلية التوسع (Scalability). كلما زاد حجم النموذج وبيانات التدريب، تحسّن أداؤه بشكل متوقع ومتسق. هذه الخاصية — المعروفة بـ"قوانين التوسع" (Scaling Laws) — هي ما دفع الشركات لبناء نماذج أكبر وأكبر.

الفصل الرابع: كيف يتعلم النموذج اللغوي؟

﴿ يَرْفَعِ اللَّهُ الَّذِينَ آمَنُوا مِنكُمْ وَالَّذِينَ أُوتُوا الْعِلْمَ دَرَجَاتٍ ﴾

[سورة المجادلة: ١١]

المرحلة الأولى: التدريب المسبق (Pre-training)

تخيّل طفلاً صغيراً يقرأ كل الكتب الموجودة في مكتبة ضخمة. لا أحد يعلّمه قواعد اللغة بشكل مباشر، لكنه يتعلمها من خلال كثرة القراءة. هذا هو مبدأ التدريب المسبق.

يُعطى النموذج كميات هائلة من النصوص — تريليونات الكلمات من الإنترنت والكتب والمقالات — ويتعلم منها عبر مهمة بسيطة: التنبؤ بالكلمة التالية. عند كل خطوة، يحاول النموذج توقع الكلمة القادمة، ثم يقارن توقعه بالكلمة الحقيقية ويعدّل معاملاته ليقترب أكثر من الإجابة الصحيحة.

هذه العملية تتكرر مليارات المرات على ملايين النصوص. وخلالها يتعلم النموذج ليس فقط قواعد اللغة، بل أيضاً معلومات عامة عن العالم: الجغرافيا، التاريخ، العلوم، الثقافة، وحتى المنطق والرياضيات — كلها مشفّرة في معاملاته.

📌 **أرقام مذهلة:** تدريب نموذج مثل GPT-3 استهلك طاقة كهربائية تعادل 1,287 ميغاواط/ساعة وأنتج حوالي 552 طناً من ثاني أكسيد الكربون. النماذج الأحدث تستهلك أكثر بكثير.

المرحلة الثانية: الضبط الدقيق (Fine-tuning)

بعد التدريب المسبق، يكون النموذج قادراً على إكمال النصوص لكنه ليس مساعداً جيداً بعد. قد يجيب على سؤالك بإكمال الجملة بدلاً من تقديم إجابة مفيدة.

في مرحلة الضبط الدقيق، يُدرَّب النموذج على أمثلة محددة من الأسئلة والأجوبة المثالية. يتعلم كيف يكون مساعداً مفيداً: يفهم أن السؤال يحتاج إجابة، وأن طلب التلخيص يحتاج ملخصاً، وأن طلب الترجمة يحتاج ترجمة.

المرحلة الثالثة: التعلم من التغذية الراجعة البشرية (RLHF)

هذه المرحلة هي ما يجعل الفرق بين نموذج لغوي خام ونموذج مفيد وآمن مثل ChatGPT أو Claude. تُسمى RLHF اختصاراً لـ Reinforcement Learning from Human Feedback.

الفكرة بسيطة: يُعطى مقيّمون بشريون عدة إجابات من النموذج ويُرتّبونها من الأفضل إلى الأسوأ. ثم يُدرَّب النموذج على تفضيل نوع الإجابات التي يفضلها البشر. هذا يجعل النموذج أكثر مفيداً وأمناً ودقة.

بفضل هذه المرحلة يتعلم النموذج أن يرفض الطلبات الضارة، وأن يعترف بعدم معرفته بدلاً من الإجابة بمعلومات خاطئة، وأن يقدم إجابات متوازنة في المواضيع الخلافية.

مراحل بناء النموذج اللغوي:

١. التدريب المسبق: قراءة تريليونات الكلمات ← تعلم أنماط اللغة

↓

٢. الضبط الدقيق: التدريب على أمثلة محددة ← تعلم كيف يكون مساعداً

↓

٣. RLHF: التعلم من تقييمات البشر ← تحسين الجودة والأمان

↓

النموذج النهائي الجاهز للاستخدام

الترميز: كيف يقرأ النموذج النص؟

النموذج لا يقرأ الكلمات كما نقرأها نحن. بل يقسّم النص إلى قطع صغيرة تُسمى "رموز" (Tokens). الرمز قد يكون كلمة كاملة، أو جزءاً من كلمة، أو حتى حرفاً واحداً.

مثلاً، كلمة "استخدام" قد تُقسم إلى: "است" + "خدام". وكلمة "الذكاء الاصطناعي" قد تُقسم إلى عدة رموز. كل رمز يُحوَّل إلى رقم فريد ثم إلى "متجه" (Vector) — وهو مجموعة أرقام تمثل معنى الرمز في فضاء رياضي متعدد الأبعاد.

ترميز الموضع (Positional Encoding)

بما أن المحوّل يعالج جميع الكلمات في نفس الوقت (بالتوازي)، فهو لا يعرف ترتيبها تلقائياً. لحل هذه المشكلة، يُضاف "ترميز الموضع" — معلومة رقمية تُخبر النموذج بموضع كل كلمة في الجملة. بهذه الطريقة يعرف النموذج أن "القطة" جاءت قبل "جلست" وبعد "هذه".

الفصل الخامس: من GPT إلى Claude
خريطة النماذج الكبرى

﴿ وَفَوْقَ كُلِّ ذِي عِلْمٍ عَلِيمٌ ﴾

[سورة يوسف: ٧٦]

الأجيال المتعاقبة من النماذج اللغوية

بعد نشر ورقة المحوّل في 2017، انطلق سباق محموم لبناء نماذج أكبر وأقوى. إليك أهم المحطات:

Google — BERT (2018): أول نموذج كبير استخدم المُشفّر فقط من المحوّل. ابتكر طريقة التعلم "ثنائية الاتجاه" حيث ينظر إلى الكلمات من اليمين واليسار معاً. أحدث ثورة في فهم اللغة ومهام مثل تصنيف النصوص والإجابة عن الأسئلة.

OpenAI — GPT-1, GPT-2, GPT-3 (2018-2020): سلسلة نماذج استخدمت المُفكّك فقط من المحوّل. GPT-3 بـ175 مليار معامل أذهل العالم بقدراته على توليد نصوص شبه بشرية.

OpenAI — GPT-4 (2023): نقلة نوعية كبيرة في القدرات، مع إضافة فهم الصور (متعدد الوسائط). أصبح قادراً على اجتياز امتحانات مهنية مثل امتحان المحاماة والطب.

Anthropic — Claude (2023-2026): سلسلة نماذج طُوّرت مع تركيز خاص على الأمان والمحاذاة مع القيم البشرية. تتميز بنافذة سياق كبيرة جداً وقدرات قوية في البرمجة والتحليل. أصبح Claude يحتل المرتبة الأولى في سوق المؤسسات بحصة 32% من الاستخدام.

Google DeepMind — Gemini (2023-2026): نموذج متعدد الوسائط يفهم النصوص والصور والفيديو والصوت. يتكامل مع منتجات Google المختلفة.

Meta — Llama (2023-2025): نموذج مفتوح المصدر أتاح للباحثين والشركات الصغيرة استخدام نماذج قوية مجاناً.

DeepSeek (2024-2025) — الصين: نموذج صيني فاجأ العالم بأدائه القوي مع تكلفة تطوير أقل بكثير من المنافسين الأمريكيين.

جدول مقارنة: أهم النماذج اللغوية الكبيرة

النموذج	الشركة	السنة	أبرز المميزات	النوع
BERT	Google	2018	فهم ثنائي الاتجاه، تصنيف النصوص	مُشفّر فقط
GPT-3	OpenAI	2020		مُفكّك فقط

			175 مليار معامل، توليد نصوص مذهلة	
GPT-4/4o	OpenAI	2023-24	متعدد الوسائط، قدرات استدلال قوية	مُفكّك متعدد الوسائط
Claude 4	Anthropic	2025-26	أمان متقدم، سياق طويل، برمجة قوية	مُفكّك
Gemini 2/3	Google	2024-26	متعدد الوسائط، نافذة سياق مليون رمز	مُشفّر-مُفكّك
Llama 3	Meta	2024	مفتوح المصدر، 405 مليار معامل	مُفكّك
DeepSeek-R1	DeepSeek	2025	استدلال قوي، تكلفة منخفضة	مُفكّك مع استدلال
Mistral Large	Mistral	2024-25	كفاءة عالية، أوروبي	مُفكّك
Grok	xAI	2024-25	متكامل مع منصة X	مُفكّك

الفصل السادس: لماذا كل هذا الاستثمار الضخم؟

﴿ قُلْ هَلْ يَسْتَوِي الَّذِينَ يَعْلَمُونَ وَالَّذِينَ لَا يَعْلَمُونَ ﴾

[سورة الزمر: ٩]

أرقام لا تُصدّق

الأرقام المتعلقة بالاستثمار في الذكاء الاصطناعي مذهلة حقاً. الإنفاق العالمي على تقنيات الذكاء الاصطناعي التوليدي بلغ حوالي 644 مليار دولار في عام 2025 وحده، بزيادة 76% عن العام السابق. والتوقعات لعام 2026 تشير إلى إنفاق إجمالي يصل إلى 2.5 تريليون دولار حسب تقديرات مؤسسة Gartner.

الشركات التكنولوجية الكبرى تتسابق في ضخ الأموال بشكل غير مسبوق. Google أعلنت عن خطط لإنفاق 175 إلى 185 مليار دولار على البنية التحتية في 2026، وهو ما يقارب ضعف إنفاقها في 2025. Meta أعلنت عن 115 إلى 135 مليار دولار. وأما Microsoft فقد ربطت استراتيجيتها بشراكتها مع OpenAI.

حتى الشركات الناشئة تحصل على تمويل ضخم: في عام 2025، استحوذت شركات الذكاء الاصطناعي على 63% من إجمالي رأس المال الاستثماري (Venture Capital)، وبلغت القيمة الإجمالية لشركات الذكاء الاصطناعي الناشئة 2.3 تريليون دولار.

لماذا كل هذه الأموال؟

السبب الأول هو "سباق التسلح" التكنولوجي. كل شركة تخشى أن تتخلف عن المنافسين. 71% من الشركات الكبرى تعتقد أنها ستتخلف عن السوق إذا لم تتبنَّ الذكاء الاصطناعي التوليدي.

السبب الثاني هو التطبيقات الواعدة: من أتمتة خدمة العملاء إلى اكتشاف الأدوية إلى البرمجة المساعدة — كل قطاع يرى إمكانيات هائلة في هذه التقنية.

السبب الثالث هو قوانين التوسع: كلما زاد حجم النموذج وبيانات التدريب، تحسّن الأداء. هذا يخلق حافزاً للبناء بحجم أكبر وأكبر.

الجانب الآخر: هل هي فقاعة؟

بعض المحللين يحذّرون من أن هذه الاستثمارات قد تشكّل فقاعة. شركة OpenAI مثلاً — رغم أنها الشركة الرائدة — من المتوقع أن تتكبد خسائر تتجاوز 100 مليار دولار حتى عام 2029 وفقاً لبعض التقديرات. والمشكلة أن الإيرادات الفعلية لا تتناسب بعد مع حجم الاستثمارات الضخمة.

في عام 2025، أنفقت شركات الحوسبة السحابية 360 مليار دولار على البنية التحتية لمعالجات GPU ومراكز البيانات. وتتوقع Goldman Sachs أن يتجاوز هذا الرقم 500 مليار في 2026. لكن لا يوجد دليل قاطع حتى الآن أن هذه الاستثمارات الضخمة قد حققت مكاسب إنتاجية ملموسة تتناسب مع حجمها.

يبقى السؤال مفتوحاً: هل ستتمكن هذه التقنية من تحقيق العوائد المأمولة وتبرير الاستثمارات الهائلة؟ أم أننا نشهد أكبر فقاعة تكنولوجية في التاريخ؟ الإجابة ستتضح خلال السنوات القليلة القادمة.

الفصل السابع: الطاقة المُستهلكة — الثمن البيئي

﴿ وَلَا تُفْسِدُوا فِي الْأَرْضِ بَعْدَ إِصْلَاحِهَا ﴾

[سورة الأعراف: ٥٦]

أرقام استهلاك الطاقة

مراكز البيانات التي تُشغّل نماذج الذكاء الاصطناعي تستهلك كميات هائلة من الكهرباء. وفقاً لوكالة الطاقة الدولية (IEA)، بلغ استهلاك مراكز البيانات العالمية نحو 415 تيراواط/ساعة في عام 2024، وهو ما يمثل حوالي 1.5% من الاستهلاك العالمي للكهرباء. ومن المتوقع أن يتضاعف هذا الرقم ليصل إلى نحو 945 تيراواط/ساعة بحلول 2030 — وهو ما يعادل استهلاك دولة اليابان بأكملها.

في الولايات المتحدة وحدها، استهلكت مراكز البيانات 183 تيراواط/ساعة في 2024 (أكثر من 4% من استهلاك البلاد)، ومن المتوقع أن ترتفع النسبة إلى 7-12% بحلول 2028.

تتوقع شركة Gartner أن يرتفع استهلاك مراكز البيانات العالمية من 448 تيراواط/ساعة في 2025 إلى 980 تيراواط/ساعة بحلول 2030. واللافت أن الخوادم المُحسّنة للذكاء

الاصطناعي ستمثل 44% من هذا الاستهلاك بحلول 2030 بعد أن كانت 21% فقط في 2025.

تأثيرات على المواطن العادي

هذا الاستهلاك الضخم للطاقة يؤثر مباشرة على فواتير كهرباء المواطنين. في ولاية فيرجينيا الأمريكية — حيث يوجد أكبر تجمع لمراكز البيانات في العالم — تستهلك هذه المراكز حوالي 40% من كهرباء الولاية. وقد أدى ذلك إلى ارتفاع فواتير الكهرباء.

في بعض المناطق الأمريكية، ارتفعت أسعار الكهرباء بنسبة 267% خلال خمس سنوات بسبب التركيز العالي لمراكز البيانات. وفي أيرلندا — أحد المراكز التقنية الأوروبية — تستهلك مراكز البيانات 21% من الكهرباء الوطنية، وقد تصل النسبة إلى 32% بحلول 2026.

📌 **للمقارنة:** تدريب نموذج GPT-3 استهلك طاقة تكفي لتشغيل منزل أمريكي متوسط لمدة 120 سنة. والنماذج الأحدث تستهلك أضعاف ذلك.

البصمة الكربونية

مراكز البيانات لا تستهلك الكهرباء فحسب، بل تُنتج انبعاثات كربونية. تشير التقديرات إلى أن البصمة الكربونية السنوية للذكاء الاصطناعي قد تصل إلى 33-80 مليون طن من ثاني أكسيد الكربون. وقد أعلنت شركات كبرى مثل Google وMeta وMicrosoft

عن ارتفاعات حادة في انبعاثاتها بسبب التوسع في مراكز البيانات، رغم تعهداتها بتحقيق صافي انبعاثات صفري.

الماء أيضاً

إضافة إلى الكهرباء، تستهلك مراكز البيانات كميات كبيرة من المياه للتبريد. أنظمة التبريد وحدها قد تمثل حتى 40% من استهلاك الطاقة في مركز البيانات. هذا يُشكّل ضغطاً إضافياً على موارد المياه خاصة في المناطق التي تعاني من الجفاف.

الفصل الثامن: المحوّلات خارج اللغة
ثورة في البيولوجيا والعلوم

﴿ وَفِي أَنفُسِكُمْ أَفَلَا تُبْصِرُونَ ﴾

[سورة الذاريات: ٢١]

أحد أروع جوانب بنية المحوّل أنها ليست محصورة في اللغة البشرية. الفكرة الأساسية — أن تنظر إلى كل عنصر في سياق جميع العناصر الأخرى — يمكن تطبيقها على أي نوع من البيانات المتسلسلة. وهذا ما حدث بالفعل.

AlphaFold — التنبؤ ببنية البروتينات

البروتينات هي آلات الحياة. كل وظيفة في جسمك — من هضم الطعام إلى نبض القلب — تقوم بها بروتينات. وشكل البروتين ثلاثي الأبعاد يحدد وظيفته. لعقود طويلة، كان تحديد هذا الشكل يتطلب سنوات من العمل المخبري المُكلف.

في عام 2020، أحدث نموذج AlphaFold2 من Google DeepMind ثورة في هذا المجال. استخدم بنية محوّل معدّلة تُسمى "Evoformer" لتحليل تسلسلات البروتين والتنبؤ بشكلها ثلاثي الأبعاد بدقة مذهلة. فاز بمسابقة CASP14 بفارق كبير عن جميع المنافسين.

كيف يعمل؟ تماماً كما يتعلم نموذج اللغة العلاقات بين الكلمات، يتعلم AlphaFold العلاقات بين الأحماض الأمينية في سلسلة البروتين. آلية الانتباه تسمح له بفهم أن حمضاً أمينياً في بداية السلسلة قد يتفاعل مع آخر في نهايتها — تماماً كما تربط كلمة في بداية الجملة بكلمة في نهايتها.

AlphaFold2 قدّم تنبؤات لأكثر من 200 مليون بروتين — تقريباً كل بروتين معروف في الطبيعة — مما وفّر على العلماء ملايين السنوات من العمل المخبري. وقد حصل مطوّروه على جائزة نوبل في الكيمياء لعام 2024.

Geneformer — فهم شبكات الجينات

Geneformer هو نموذج محوّل أساسي طوّره باحثون في معهد Broad التابع لـMIT وHarvard. وهو مثال رائع على كيفية تطبيق نفس الفكرة في مجال مختلف تماماً.

بدلاً من تعلّم اللغة من النصوص، يتعلم Geneformer "لغة الخلية" من بيانات التعبير الجيني. تدرّب على أكثر من 100 مليون نسخة من النسخ الجيني (transcriptome) لخلايا فردية من أنسجة بشرية متنوعة.

كيف يعمل؟ كل خلية تُمثَّل كسلسلة من الجينات مرتبة حسب مستوى تعبيرها (أي نشاطها). هذا يشبه تمثيل الجملة ككلمات مرتبة. ثم يُدرَّب النموذج بطريقة "التعلم المُقنّع" — يُخفى 15% من الجينات ويُطلب من النموذج توقعها — تماماً كما يتعلم BERT بإخفاء كلمات من الجمل.

📌 **التشابه المذهل:**

في نموذج اللغة: كل جملة = سلسلة كلمات → يتعلم العلاقات بين الكلمات

في Geneformer: كل خلية = سلسلة جينات → يتعلم العلاقات بين الجينات

نفس الفكرة الأساسية، تطبيقات مختلفة تماماً!

الإصدار الأحدث (Geneformer V2) تدرّب على أكثر من 104 مليون خلية بشرية فردية. ويُستخدم لتحديد الأهداف العلاجية المحتملة، تصنيف أنواع الخلايا، ونمذجة الأمراض مثل اعتلال عضلة القلب. وقد نجح في تحديد أهداف علاجية محتملة تم التحقق منها تجريبياً.

ESM — لغة البروتينات

ESM (Evolutionary Scale Modeling) من Meta AI هو عائلة من نماذج المحوّلات المدرّبة على تسلسلات البروتين. الإصدار الأحدث ESM-3 يحتوي على 98 مليار معامل وتدرّب على 2.78 مليار تسلسل بروتيني.

الأمر الأكثر إثارة أن ESM-3 لم يكتفِ بفهم البروتينات الموجودة، بل استطاع تصميم بروتينات جديدة تماماً لا توجد في الطبيعة — بروتين فلوري أخضر جديد بنسبة تشابه 58% فقط مع البروتينات المعروفة، وهو ما يعادل مسافة تطورية تقدّر بـ500 مليون سنة.

المحوّلات في مجالات أخرى

Vision Transformer (ViT): طُبّقت بنية المحوّل على الصور بنجاح كبير. بدلاً من الكلمات، تُقسَّم الصورة إلى مربعات صغيرة (patches) وتُعالج كسلسلة — تماماً كالنص. هذا النهج تفوق على الشبكات العصبية التلافيفية (CNNs) التي كانت مهيمنة على معالجة الصور لسنوات.

Nucleotide Transformer: محوّل مدرّب على تسلسلات الحمض النووي DNA. يفهم الأنماط الجينومية ويمكنه التنبؤ بتأثير الطفرات الجينية.

محوّلات الصوت والموسيقى: نماذج مثل Whisper (للتعرف على الكلام) وMusicLM (لتوليد الموسيقى) تستخدم بنية المحوّل لمعالجة البيانات الصوتية.

محوّلات الفيديو: نماذج مثل Sora من OpenAI تستخدم محوّلات لتوليد مقاطع فيديو من وصف نصي.

محوّلات الروبوتات: تُستخدم في التحكم بالروبوتات وتخطيط حركاتها.

الفصل التاسع: جدول شامل لأهم النماذج المبنية على المحوّلات

﴿ وَمَا أُوتِيتُم مِّنَ الْعِلْمِ إِلَّا قَلِيلًا ﴾

[سورة الإسراء: ٨٥]

الجدول التالي يقدم نظرة شاملة على أهم النماذج المبنية على بنية المحوّل عبر مختلف المجالات:

أولاً: نماذج اللغة

النموذج	الشركة	المعاملات	البنية	أبرز الاستخدامات
BERT	Google (2018)	340 مليون	مُشفّر	فهم اللغة، تصنيف النصوص، البحث
T5	Google (2019)	11 مليار	مُشفّر-مُفكّك	ترجمة، تلخيص، إجابة أسئلة
GPT-4o	OpenAI (2024)	غير معلن	مُفكّك متعدد الوسائط	حوار، تحليل صور، برمجة

Claude Opus 4	Anthropic (2025)	غير معلن	مُفكّك	برمجة، تحليل، كتابة، بحث
Gemini 2.5	Google (2025)	غير معلن	متعدد الوسائط	نص، صور، فيديو، صوت، كود
Llama 3.1	Meta (2024)	405 مليار	مُفكّك	مفتوح المصدر، متعدد الاستخدامات
DeepSeek-R1	DeepSeek (2025)	غير معلن	مُفكّك مع استدلال	رياضيات، منطق، برمجة
Mistral Large	Mistral (2024)	غير معلن	مُفكّك	حوار، تحليل، متعدد اللغات

ثانياً: نماذج البيولوجيا والعلوم

النموذج	المطوّر	المجال	بيانات التدريب	أبرز الإنجازات
AlphaFold2/3	DeepMind (2020-24)	بنية البروتينات	PDB + تسلسلات تطورية	تنبؤ دقيق ببنية 200+ مليون بروتين، جائزة نوبل 2024
Geneformer V2	Broad/MIT (2023-24)	شبكات الجينات	104 مليون خلية فردية	

				اكتشاف أهداف علاجية، نمذجة أمراض القلب
ESM-3	Meta AI (2024)	تصميم البروتينات	2.78 مليار تسلسل	تصميم بروتينات جديدة، 98 مليار معامل
Nucleotide Transformer	InstaDeep (2024)	الجينوم (DNA)	تسلسلات DNA	فهم المناطق التنظيمية، تأثير الطفرات
RoseTTAFold	.U Washington (2021)	بنية البروتينات	PDB + MSAs	أسرع من AlphaFold، بروتينات غشائية
ESMFold	Meta AI (2022)	بنية البروتينات	تسلسلات بروتينية	تنبؤ بدون MSA، أسرع بكثير

ثالثاً: نماذج الصور والوسائط

النموذج	المطوّر	المجال	أبرز الاستخدامات
ViT	Google (2020)	تصنيف الصور	تصنيف وفهم الصور بدقة عالية
DALL-E 3		توليد الصور	إنشاء صور من وصف نصي

	OpenAI (2023)		
Stable Diffusion	Stability AI	توليد الصور	مفتوح المصدر، توليد صور واقعية
Whisper	OpenAI (2022)	التعرف على الكلام	تحويل الكلام إلى نص بـ99+ لغة
Sora	OpenAI (2024)	توليد الفيديو	إنشاء مقاطع فيديو واقعية من نص

الفصل العاشر: المستقبل — إلى أين نتجه؟

﴿ وَيَخْلُقُ مَا لَا تَعْلَمُونَ ﴾

[سورة النحل: ٨]

الوكلاء الذكيون (AI Agents)

يُعتبر عام 2025 "عام الوكلاء الذكيين". بدلاً من أن يكون النموذج مجرد مُجيب عن أسئلة، أصبح قادراً على التفكير خطوة بخطوة، واستخدام أدوات خارجية (البحث، الآلة الحاسبة، البرمجة)، وتنفيذ مهام معقدة بشكل مستقل. هذا يُحوّل النماذج اللغوية من "مساعدين" إلى "وكلاء" يمكنهم إنجاز أعمال كاملة.

نافذة السياق الممتدة

النماذج الحديثة أصبحت قادرة على معالجة نصوص أطول بكثير. بعض النماذج يمكنها معالجة مليون رمز (Token) أو أكثر في المرة الواحدة — ما يعادل عدة كتب كاملة. هذا يفتح الباب لتطبيقات مثل تحليل وثائق قانونية ضخمة أو مراجعة أبحاث علمية كاملة دفعة واحدة.

النماذج الأصغر والأكفأ

ليس المستقبل فقط في النماذج الأكبر. هناك اتجاه متزايد نحو بناء نماذج أصغر لكنها أكفأ. تقنيات مثل "التقطير" (Distillation) و"التكميم" (Quantization) تسمح بتقليص حجم النموذج مع الحفاظ على معظم قدراته. نموذج DeepSeek الصيني أثبت أن الابتكار في الكفاءة يمكن أن يعوّض عن الحجم الهائل.

الذكاء الاصطناعي المتخصص

بدلاً من نماذج عامة واحدة لكل شيء، نتجه نحو نماذج متخصصة في مجالات محددة: نماذج طبية تفهم لغة الأطباء والسجلات الصحية، ونماذج قانونية تفهم المصطلحات القانونية، ونماذج علمية مثل Geneformer المتخصصة في البيولوجيا.

التحديات المتبقية

الهلوسة (Hallucination): لا تزال النماذج أحياناً تختلق معلومات غير صحيحة بثقة عالية. تقليل هذه المشكلة يمثل تحدياً كبيراً.

الاستهلاك البيئي: كما رأينا، الطاقة المستهلكة هائلة. البحث عن حلول أكثر كفاءة طاقوية ضرورة ملحة.

العدالة والتحيز: النماذج تتعلم من بيانات الإنترنت التي تحتوي على تحيزات بشرية. ضمان العدالة والحياد يتطلب جهوداً مستمرة.

الخصوصية: استخدام بيانات ضخمة للتدريب يثير أسئلة جدية حول حماية الخصوصية وحقوق الملكية الفكرية.

السلامة: مع ازدياد قدرات هذه النماذج، يزداد القلق بشأن سلامة استخدامها والتأكد من أنها تخدم البشرية وليس العكس.

الخاتمة

في هذا الكتاب، حاولنا أن نقدم رحلة مبسّطة عبر عالم النماذج اللغوية الكبيرة وبنية المحوّلات التي تقف خلفها. بدأنا من السؤال البسيط "كيف يعمل؟" وانتهينا بصورة شاملة تغطي التاريخ والتقنية والاقتصاد والبيئة والمستقبل.

الثورة التي أحدثتها ورقة "Attention Is All You Need" في 2017 لم تقتصر على معالجة اللغة. فبنية المحوّل أصبحت اللبنة الأساسية في عشرات التطبيقات من التنبؤ ببنية البروتينات إلى فهم شبكات الجينات إلى توليد الصور والفيديو.

الأرقام التي رأيناها مذهلة: تريليونات الدولارات من الاستثمارات، ومئات التيراواط/ساعة من الكهرباء، ومليارات المعاملات. لكن الأكثر إذهالاً هو أن هذا كله بدأ بفكرة بسيطة: أن تُعطي كل عنصر في البيانات القدرة على "الانتباه" لجميع العناصر الأخرى.

هذه التقنية لا تزال في بداياتها رغم كل ما حققته. والسنوات القادمة ستحمل تطورات أكبر وتحديات أعقد. المهم أن نفهم هذه التقنية — نقاط قوتها وضعفها — حتى نتمكن من الاستفادة منها بحكمة ومسؤولية.

نسأل الله أن يسخّر العلم والتقنية لخير البشرية جمعاء.

والله أعلم

المراجع العلمية

الأوراق العلمية الأساسية

1. Vaswani, A. et al. (2017). "Attention Is All You Need." Advances in Neural Information Processing Systems (NeurIPS).

2. Devlin, J. et al. (2018). "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding." arXiv:1810.04805.

3. Brown, T. et al. (2020). "Language Models are Few-Shot Learners" (GPT-3). NeurIPS 2020.

4. Ouyang, L. et al. (2022). "Training language models to follow instructions with human feedback." NeurIPS 2022.

5. Kaplan, J. et al. (2020). "Scaling Laws for Neural Language Models". arXiv:2001.08361.

البيولوجيا والعلوم

Jumper, J. et al. (2021). "Highly accurate protein structure prediction .6
.with AlphaFold." Nature 596: 583-589

Theodoris, C.V. et al. (2023). "Transfer learning enables predictions .7
.in network biology." Nature 618: 616-624

-Chen, H. et al. (2024). "Quantized multi-task learning for context .8
.specific representations of gene network dynamics." bioRxiv

Lin, Z. et al. (2023). "Evolutionary-scale prediction of atomic-level .9
.protein structure with a language model." Science 379: 1123-1130
(ESM-2/ESMFold)

Hayes, T. et al. (2024). "Simulating 500 million years of evolution .10
.with a language model." (ESM-3)

Dalla-Torre, H. et al. (2024). "Nucleotide Transformer: building .11
and evaluating robust foundation models for human genomics." Nature
.Methods

Baek, M. et al. (2021). "Accurate prediction of protein structures .12 .and interactions using a three-track neural network." Science (RoseTTAFold)

الرؤية الحاسوبية والوسائط

:Dosovitskiy, A. et al. (2020). "An Image is Worth 16x16 Words .13 Transformers for Image Recognition at Scale." (ViT)

-Radford, A. et al. (2023). "Robust Speech Recognition via Large .14 Scale Weak Supervision." (Whisper)

التقارير والاستثمار والطاقة

.International Energy Agency (2025). "Energy and AI." IEA Report .15

Gartner (2026). "Worldwide AI Spending Will Total $2.5 Trillion .16 ".in 2026

Gartner (2025). "Electricity Demand for Data Centers to Grow .17 ".in 2025 and Double by 2030 16%

Lawrence Berkeley National Laboratory (2024). "United States .18 ".Data Center Energy Usage Report

19. Menlo Ventures (2025). "2025 Mid-Year LLM Market Update".

20. Pew Research Center (2025). "US Data Centers' Energy Use Amid the AI Boom".

التفسير القرآني

21. ابن كثير. تفسير القرآن العظيم.

22. الطبري. جامع البيان عن تأويل آي القرآن.

English Section

How Large Language Models Work

A Simplified Guide to Understanding the AI Revolution

Introduction

We live in an era of unprecedented technological transformation. In just a few years, Large Language Models (LLMs) have become part of our daily lives. We use them to write messages, summarize articles, search for information, and even write computer programs and assist in medical diagnosis.

Yet many people use this technology without understanding how it works. How can a computer program "understand" your question and answer in natural language as if it were human? Does it actually think? How was it invented? And why are companies spending billions of dollars developing it?

This book was written for non-specialists. Its goal is to explain — simply and clearly — everything you need to know about Large Language Models: how the idea was born, how they work from the

inside, why they are considered a genuine technological revolution, and what the scale of investment and energy consumption looks like.

Chapter 1: What Are Large Language Models?

Imagine reading millions of books, articles, and conversations. After all that reading, you would develop a deep understanding of language: you'd know that "coffee" is often associated with "morning," "cup," and "flavor," and that "doctor" relates to "patient," "treatment," and "hospital."

This is exactly what a Large Language Model does. It is a computer program that has read an enormous amount of text — billions of pages from the internet, books, and research — and learned patterns of language and word relationships from them.

However, the model doesn't "understand" language the way we humans do. It predicts the next most likely word based on context. When you type "The sun rises from the..." the model predicts the next word is "east" because it has seen this phrase thousands of times in training data.

In simpler terms: A Large Language Model is a machine that is extremely good at predicting the next word. When you do that with

very high accuracy at a very large scale, the result is text that appears to have been written by a human.

The word "large" in the name refers to the enormous number of parameters — the numbers the model learns during training. Think of them as brain cells and the connections between them. Modern models contain hundreds of billions of parameters. GPT-3, for example, has 175 billion parameters, and newer models have over a trillion.

Chapter 2: The Journey from Zero — How It All Began

The dream of teaching computers to understand human language is as old as computers themselves. In the 1950s, scientists tried building machine translation programs with rigid linguistic rules. But human language is far more complex than rigid rules can capture.

In the 1980s and 1990s, an alternative idea emerged: instead of writing manual rules, why not build a system that learns from examples, like a child does? This is the idea behind artificial neural networks — mathematical models inspired by how neurons work in the brain.

For text processing, Recurrent Neural Networks (RNNs) were developed, reading text word by word sequentially. But they suffered from a major problem: the longer the text, the more they forgot the beginning. Improvements like LSTM and GRU helped partially, but the bigger problem was that these networks processed words one after another, making them very slow and unable to benefit from parallel computing.

The world needed an entirely new idea. And that idea came in 2017 from a team at Google.

Chapter 3: "Attention Is All You Need" — The Paper That Changed the World

In June 2017, eight researchers from Google published a paper with a simple but revolutionary title: "Attention Is All You Need." This paper introduced an entirely new neural network architecture called the "Transformer."

What is the Attention Mechanism?

When you read: "The student went to the library because he wanted to borrow a book," your brain automatically connects "he" with "student"

and not "library." This is "attention" — the ability to connect each word with the most relevant words in the entire sentence.

The attention mechanism in the Transformer works the same way. When processing a certain word, the model looks at all other words in the text and calculates an "attention score" that determines how important each word is to the word currently being processed.

This happens through three mathematical steps: Query (what am I looking for?), Key (what do I offer?), and Value (my actual information). The compatibility between Query and Keys determines how much attention each word receives, then Values are combined according to these weights.

Why Was This Revolutionary?

Three reasons made the Transformer revolutionary: First, **parallelism** — unlike RNNs that process words one at a time, the Transformer processes all words simultaneously, leveraging powerful GPUs. Second, **long-range context** — it can connect a word at the beginning of the text with one at the end directly. Third, **scalability** — as model size and training data increase, performance improves predictably and consistently.

Chapter 4: How Does a Language Model Learn?

Training a language model involves three main stages:

Stage 1: Pre-training. The model is given enormous amounts of text — trillions of words — and learns through a simple task: predicting the next word. This process is repeated billions of times, during which the model learns not only language rules but also general knowledge about the world.

Stage 2: Fine-tuning. The model is trained on specific examples of ideal questions and answers. It learns how to be a helpful assistant: understanding that a question needs an answer, a summarization request needs a summary, and a translation request needs a translation.

Stage 3: RLHF (Reinforcement Learning from Human Feedback). Human evaluators rank multiple model responses from best to worst. The model then learns to prefer the types of answers humans prefer, making it more helpful, safe, and accurate.

Chapter 5: From GPT to Claude — A Map of Major Models

After the Transformer paper in 2017, an intense race began to build larger and more powerful models. Key milestones include BERT (Google, 2018), GPT-3 (OpenAI, 2020), GPT-4 (OpenAI, 2023), Claude (Anthropic, 2023-2026), Gemini (Google DeepMind, 2023-2026), Llama (Meta, 2023-2025), and DeepSeek (China, 2024-2025).

By mid-2025, Anthropic's Claude had become the leading model in enterprise markets with a 32% share, ahead of OpenAI and Google at 20% each. Code generation emerged as AI's first breakout use case, with Claude capturing 42% market share in that domain.

Chapter 6: Why Such Massive Investment?

The investment numbers are truly staggering. Global spending on generative AI technologies reached approximately $644 billion in 2025 alone, a 76% increase from the previous year. Gartner projects worldwide AI spending will total $2.5 trillion in 2026.

The major tech companies are pouring in unprecedented amounts: Google announced plans to spend $175-185 billion on infrastructure in 2026, nearly doubling its 2025 spending. Meta announced $115-135 billion. In 2025, cloud operators spent $360 billion on GPU infrastructure and data centers, with Goldman Sachs expecting this to exceed $500 billion in 2026.

AI startups captured 63% of all venture capital in 2025, with the combined valuation of AI startups reaching $2.3 trillion. However, some analysts warn this could be a bubble — OpenAI alone was projected to accumulate over $100 billion in losses through 2029.

Chapter 7: The Energy Cost — Environmental Impact

Data centers powering AI models consume enormous amounts of electricity. According to the International Energy Agency (IEA), global data center electricity consumption reached about 415 TWh in 2024 — roughly 1.5% of global consumption. This is projected to double to approximately 945 TWh by 2030 — equivalent to Japan's entire electricity demand.

In the US alone, data centers consumed 183 TWh in 2024 (over 4% of the country's total), projected to rise to 7-12% by 2028. Gartner estimates worldwide data center consumption will rise from 448 TWh in 2025 to 980 TWh by 2030, with AI-optimized servers representing 44% of this consumption by 2030.

The impact on ordinary citizens is direct: in Virginia, data centers account for about 40% of the state's electricity. Some US regions have seen electricity prices jump 267% over five years due to high data center concentration. In Ireland, data centers consume 21% of national electricity, potentially rising to 32% by 2026.

Chapter 8: Transformers Beyond Language — A Revolution in Biology and Science

One of the most remarkable aspects of the Transformer architecture is that it isn't limited to human language. The core idea — letting each element attend to all other elements — can be applied to any type of sequential data.

AlphaFold from Google DeepMind used a modified Transformer architecture called "Evoformer" to predict protein 3D structures with

remarkable accuracy. It provided predictions for over 200 million proteins, earning its developers the 2024 Nobel Prize in Chemistry.

Geneformer, developed at MIT and Harvard's Broad Institute, applies the same idea to single-cell transcriptomics. Trained on over 100 million single-cell transcriptomes, it learns "the language of cells" using a masked learning objective — hiding 15% of genes and learning to predict them, just as BERT masks words in sentences. It has successfully identified therapeutic targets for cardiomyopathy that were experimentally validated.

ESM-3 from Meta AI, with 98 billion parameters trained on 2.78 billion protein sequences, can design entirely new proteins that don't exist in nature — including a novel green fluorescent protein with only 58% similarity to known examples, equivalent to 500 million years of evolution.

Other applications include Vision Transformers (ViT) for image classification, Nucleotide Transformers for DNA analysis, Whisper for speech recognition, and Sora for video generation.

Chapter 9: Comprehensive Table of Key Transformer-Based Models

Please refer to the Arabic section tables for a comprehensive comparison of transformer-based models across language, biology, and multimedia domains. The tables cover model names, developers, parameter counts, architecture types, and key applications.

Chapter 10: The Future — Where Are We Heading?

Key trends include: **AI Agents** that can think step-by-step and use external tools; **extended context windows** processing a million or more tokens at once; **smaller, more efficient models** through distillation and quantization; **specialized AI** for specific domains like medicine and law; and persistent challenges including hallucination, environmental impact, bias, privacy, and safety.

Conclusion

In this book, we have taken a simplified journey through the world of Large Language Models and the Transformer architecture behind

them. The revolution sparked by "Attention Is All You Need" in 2017 extended far beyond language processing, becoming the foundational building block for dozens of applications.

The numbers we've seen are staggering: trillions of dollars in investment, hundreds of terawatt-hours of electricity, and billions of parameters. But most astonishing is that it all started with one simple idea: give every element in the data the ability to "attend" to all other elements.

This technology is still in its early stages despite all it has achieved. The coming years will bring even greater developments and more complex challenges. What matters is that we understand this technology — its strengths and weaknesses — so we can benefit from it wisely and responsibly.

نبذة عن المؤلف

د. فضل محمد الأكوع

Dr. Fadhl Mohammed Alakwaa

باحث في البيولوجيا الحاسوبية والمعلوماتية الحيوية وعلم الجينوم المكاني في جامعة ميشيغان بالولايات المتحدة الأمريكية. حاصل على درجة الدكتوراه ولديه أبحاث منشورة في مجلات علمية محكّمة في مجالات تشمل مثبطات SGLT2 وأيض الكلى، والتغيرات الجزيئية بعد جراحات السمنة، وتطبيقات الذكاء الاصطناعي في الطب الحيوي.

إلى جانب عمله الأكاديمي، يُعد مؤلفاً ثنائي اللغة غزير الإنتاج، يكتب بالعربية والإنجليزية في مواضيع متنوعة تشمل العلوم والتكنولوجيا والدراسات الإسلامية والشؤون اليمنية والجيوسياسية.

Dr. Fadhl Mohammed Alakwaa is a researcher in computational biology, bioinformatics, and spatial genomics at the University of Michigan, USA. He holds a PhD and has published peer-reviewed research in fields including SGLT2 inhibitors and kidney metabolism, molecular changes following bariatric surgery, and AI applications in biomedicine.

Alongside his academic work, he is a prolific bilingual author writing in Arabic and English on topics spanning science, technology, Islamic scholarship, Yemeni affairs, and geopolitics.

مؤلفات المؤلف

1. نهاية الكون في القرآن الكريم – تحليل علمي شامل (2026)
2. أدوات وتطبيقات الذكاء الاصطناعي منذ 2025 (2026)
3. أبحاث GLP-1/SGLT2 والتقاليد الغذائية الإسلامية (2026)
4. التغيرات الدينية بين أجيال المسلمين في المهجر (2026)
5. التحالف الأمريكي الإسرائيلي – دراسة تحليلية (2026)
6. الرؤساء اليمنيون في وثائق ويكيليكس (2026)
7. الوحدة اليمنية – التاريخ والآفاق (2026)
8. المعرفة والتعليم – كتاب تحفيزي للأجيال القادمة (2026)
9. تأثير النماذج اللغوية الكبيرة على البحث العلمي والتعليم الجامعي (2026)
10. تصنيف الآيات في القرآن الكريم – دراسة تأملية في البنية الموضوعية (2026)
11. **كيف تعمل النماذج اللغوية الكبيرة – دليل مبسّط لفهم ثورة الذكاء الاصطناعي (2026)**

عن الكتاب

يقدم هذا الكتاب شرحا مبسطا وشاملا لكيفية عمل النماذج اللغوية الكبيرة التي غيرت عالم التكنولوجيا. يستعرض الكتاب رحلة تطور هذه النماذج من ورقة المحولات الشهيرة الى التطبيقات المتقدمة في الطب والبيولوجيا والعلوم. كما يناقش حجم الاستثمارات الضخمة واستهلاك الطاقة الهائل المرتبط بها.

عن المؤلف

د. فضل محمد الأكوع
باحث في البيولوجيا الحاسوبية والمعلوماتية الحيوية
وعلم الجينوم المكاني في جامعة ميشيغان
Dr. Fadhl Mohammed Alakwaa

جميع الحقوق محفوظة للمؤلف © 2026