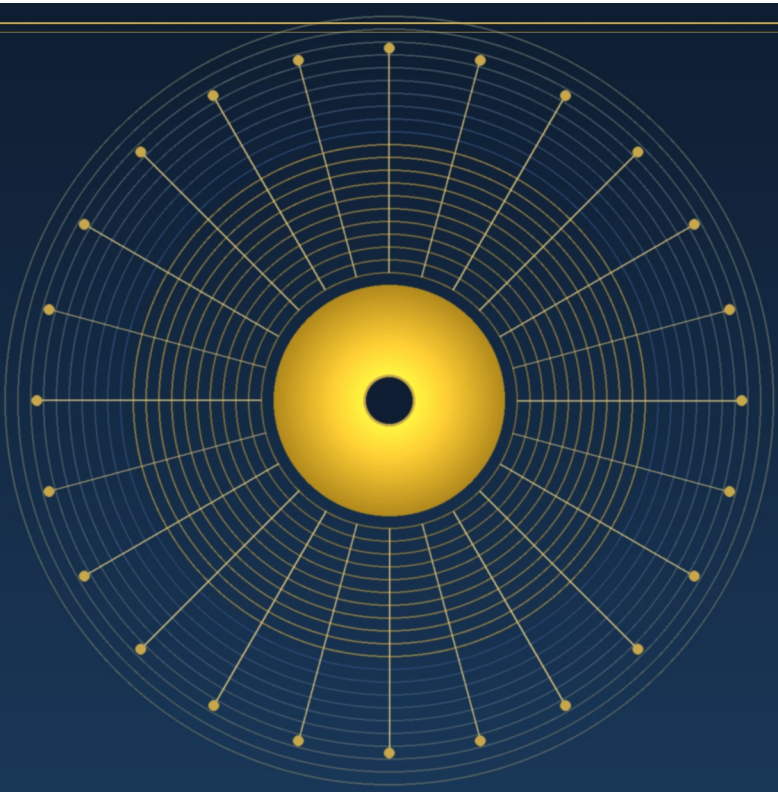

كلود مايثوس

ما الذي يميّزه عن باقي نماذج أنثروبيك؟

Claude Mythos

What Sets It Apart from Anthropic's Other Models?

د. فضل محمد الأكوع

Dr. Fadhl Mohammed Alakwaa

2026

كلود مايثوس

ما الذي يميّزه عن باقي نماذج أنثروبيك؟

د. فضل محمد الأكوع

2026

بِسْمِ اللَّهِ الرَّحْمَٰنِ الرَّحِيمِ

حقوق النشر

© 2026 د. فضل محمد الأكوع

جميع الحقوق محفوظة. لا يجوز إعادة إنتاج أيّ جزءٍ من هذا الكتاب بأيّ وسيلةٍ إلكترونيّة أو ميكانيكيّة — بما في ذلك التصوير الضوئيّ، والتسجيل، وأيّ نظامٍ لتخزين المعلومات واسترجاعها — دون إذنٍ خطّيٍّ من المؤلّف.

نُشر هذا الكتاب في شكلٍ ثنائيّ اللغة (عربيٌّ — إنجليزيٌّ). القسم الأوّل بالعربية، والقسم الثاني — بعد الفاصل — بالإنجليزية.

الطبعة الأولى — 2026

إهداء

إلى كلِّ باحثٍ في عوالم الذكاء الاصطناعي،

يسعى إلى فهم ما يُصنع في مختبرات العالم،

ويوازن بين دهشة القدرة وحكمة الاستخدام.

إلى من يؤمن أنَّ العلمَ أمانةٌ،

وأنَّ كلَّ أداةٍ يصنعها الإنسان

هي مرآةٌ لنواياه.

أُهدي هذا الكتاب

إلى طلّاب العلم في الشرق والغرب،

الذين يسألون: ما هذا النموذج الجديد؟

وإلى روح والدي رحمه الله، وأمي حفظها الله،

وزوجتي، وأولادي، وإخواني وأخواتي،

وإلى كلِّ من علّمني حرفاً.

فهرس المحتويات

المقدّمة

الفصل ١: ميلاد مايثوس — قصة نموذجٍ سُرِّب قبل أن يُعلَن

الفصل ٢: تشريح عائلة كلود — من هايكو إلى مايثوس

الفصل ٣: الأرقام التي غيّرت المشهد — مقاييس أداء مايثوس

الفصل ٤: الأمن السيبراني — قلب قوة مايثوس

الفصل ٥: مشروع الزجاج الجناح — التحالف الدفاعي

الفصل ٦: لماذا قيّدت أنثروبيك مايثوس؟

الفصل ٧: مقارنةٌ مباشرة — مايثوس مقابل بقية العائلة

الفصل ٨: السلامة والتوافق في مايثوس

الفصل ٩: التأثير على الصناعة والردّ التنافسي

الفصل ١٠: مستقبل نماذج فئة مايثوس

الخاتمة

المراجع

المقدمة

﴿ وَقُل رَّبِّ زِدْنِي عِلْمًا ﴾
[طه: 114]

بسم الله الرحمن الرحيم، والحمد لله ربِّ العالمين، والصلاة والسلام على أشرف الأنبياء والمرسلين، سيّدنا محمدٍ ﷺ وعلى آله وصحبه أجمعين.

في مساء الثامن من أبريل 2026، أعلنت شركة أنثروبيك عن نموذجٍ لغويٍّ جديدٍ أسمته **Claude Mythos Preview**، ولم يكن هذا إعلاناً عادياً في سلسلةٍ من الإعلانات التي تتابعت منذ ظهور كلود 3 في مارس 2024؛ بل كان إعلاناً استثنائياً بكلِّ المقاييس. نموذجٌ تفوّق على كلِّ ما سبقه، ومع ذلك قرّرت الشركة **ألّا تُتيحه للعموم**، وأن تُطلقه عبر تحالفٍ مغلقٍ من شركاء الأمن السيبراني أطلقت عليه اسم **مشروع جلاس وينج (Project Glasswing)**.

هذه هي قصّة ميثوس. قصّة نموذجٍ سُرِّبت أخباره الأولى عن طريق الخطأ في مارس 2026، حين تركت أنثروبيك مسوّدةً لمنشورٍ مدوّنيٍّ على خادمٍ غير

مُؤمَّن، فاكتشفها باحثان في الأمن السيبراني. قصّة نموذجٍ أحدث هبوطاً حاداً في أسهم شركات الأمن السيبراني في اليوم ذاته. قصّة نموذجٍ وصفته أنثروبيك بأنّه «**متقدّمٌ جداً في القدرات السيبرانية مقارنةً بأيِّ نموذجٍ آخر**».

لكنّ القصّة أعمق من ذلك. ميثوس ليس مجرّد نموذجٍ أقوى، بل هو **فئةٌ جديدةٌ من النماذج** تتجاوز عائلة أوبس التي كانت حتى ذلك الحين قمّة ما تُنتجه أنثروبيك. إنّه يُمثّل لحظةً فارقةً في صناعة الذكاء الاصطناعي: للمرة الأولى منذ سبع سنوات، تُقرّر شركةٌ رائدة **أن تحجب نموذجها الأقوى عن الجمهور**. آخر مرةٍ حدث فيها ذلك كانت عام 2019 حين احتجزت OpenAI نموذج GPT-2.

في هذا الكتاب، نستعرض قصّة ميثوس من بدايتها حتى لحظة كتابة هذه السطور. نبدأ من قصّة التسريب، ونمرُّ بتشريحِ عائلةِ كلود كاملةً من هايكو إلى أوبس 4.7 إلى ميثوس، ثم ندخل إلى تفاصيل المعايير القياسية (benchmarks) التي كسرها ميثوس، ثم إلى الأمن السيبراني الذي يُمثّل جوهر قوّته، ثم إلى مشروع جلاس وينج وفلسفة الاحتواء التي تبنّتها أنثروبيك، وصولاً إلى مستقبل هذه الفئة من النماذج.

هدفنا أن يخرج القارئ العربيُّ بفهمٍ دقيقٍ وموثَّقٍ لهذا النموذج الذي لن يستطيع استخدامه مباشرةً، لكنّه سيرى آثاره خلال أشهرٍ قليلة في النماذج العامّة المُتاحة له. فأنثروبيك صرّحت صراحةً أنّ قدرات ميثوس ستصل إلى نماذج أوبس المستقبلية بعد تطوير ضماناتٍ أمنيّةٍ مناسبة.

نسأل الله أن ينفع بهذا الكتاب، وأن يجعله خالصاً لوجهه الكريم، وأن يُعيننا على فهم ما تُنتجه مختبرات العالم، فإنّ العلم نور، والجهل ظلمات. **والله وليُّ التوفيق.**

د. فضل محمد الأكوع

ميشيغان، أبريل 2026

الفصل الأول: ميلاد مايثوس — قصة نموذجٍ سُرِّب قبل أن يُعلَن

﴿ وَمَا أُوتِيتُم مِّنَ الْعِلْمِ إِلَّا قَلِيلًا ﴾

[الإسراء: 85]

1.1 التسريب الذي هزَّ الصناعة

في 26 مارس 2026، اكتشف باحثان في الأمن السيبراني — **روي باز** من شركة LayerX Security و**ألكسندر بوويلز** من جامعة كامبريدج — خطأً في إعدادات نظام إدارة المحتوى (CMS) الخاصّ بأنثروبيك. كشف هذا الخطأ عن ما يقرب من **3,000 أصلٍ رقميٍّ غير منشور**، من بينها مسوّدةُ منشورٍ مدوّنيٍّ عن نموذجٍ جديد لم يُعلَن بعد.

كانت المسوّدة واضحةً في صراحتها: النموذج الجديد «**متقدّمٌ تقدّماً كبيراً عن أيّ نموذج ذكاءٍ اصطناعيٍّ آخر في القدرات السيبرانية**»، و«**قد يُطلق موجةً من**

الهجمات المتقدّمة». خلال ساعاتٍ، تناقلت وسائل الإعلام الكبرى — CoinDesk، CNBC، Fortune — الخبر، وهبطت أسهم شركات الأمن السيبراني هبوطاً حاداً.

1.2 الإعلان الرسميُّ — 8 أبريل 2026

بعد التسريب بأسبوعين تقريباً، أعلنت أنثروبيك رسمياً عن النموذج في الثامن من أبريل 2026، تحت اسم **Claude Mythos Preview**. وأطلقت معه ثلاثة إعلاناتٍ متزامنة:

1. **إصدار بطاقة النظام (System Card)**: وثيقةٌ تقنيّةٌ من 244 صفحة تصف قدرات النموذج وحدوده واختباراته الأمنيّة.
2. **إطلاق مشروع جلاس وينج (Project Glasswing)**: تحالفٌ من اثنتي عشرة شركةً تقنيّةً ومصرفيّةً كبرى — منها Apple وGoogle وMicrosoft وAmazon — لاستخدام ميثوس في تأمين البنى التحتيّة الحرجة.
3. **تقييد الوصول**: النموذج لن يُتاح للجمهور، وسيكون الوصول إليه بدعوةٍ فقط، لشركاء المشروع ومنظماتٍ مختارة تعمل على البنى التحتيّة الحرجة.

1.3 الاسم الكودي: كابيبارا

أنثروبيك اعتادت على تسمية نماذجها بأسماءٍ كوديّةٍ داخليّةٍ قبل إطلاقها. ميثوس حمل الاسم الكوديَّ **«كابيبارا» (Capybara)**، وهو حيوان القاضم الأكبر في العالم. أمّا اسم «ميثوس» فقد اختارته أنثروبيك من الكلمة اليونانيّة **μῦθος** التي تعني «الحكاية المؤسِّسة» أو «النسيج الحكائيّ الذي يُشكِّل فهمنا للواقع». وبحسب بيانٍ رسميٍّ لأنثروبيك، فإنّ الاسم يُعبِّر عن **«النسيج الرابط بين المعرفة والأفكار»**.

1.4 فئةٌ جديدةٌ فوق أوبس

النقطة الأهمُّ في الإعلان الرسميّ كانت في جملةٍ واحدةٍ من أنثروبيك: **«ميثوس اسمٌ جديدٌ لفئةٍ جديدةٍ من النماذج: أكبر وأذكى من نماذج أوبس — التي كانت حتى الآن أقوى نماذجنا»**.

هذه الجملة تُعيد رسم هرمِ عائلة كلود بالكامل. فحتى إعلان ميثوس، كانت بنية أنثروبيك ثلاثيّة: هايكو (السريع الرخيص)، سونت (المتوازن)، أوبس (الأقوى). بإضافة ميثوس، أصبحت البنية رباعيّةً:

- **هايكو 4.5**: للمهام الخفيفة والسريعة.
- **سونت 4.6**: المحرّك اليوميُّ للمطوّرين.
- **أوبس 4.7**: النموذج المتقدّم المُتاح للعامّة.

• **ميثوس بريفيو (كايبارا)**: الفئة المقيَّدة، المتاحة للشركاء فقط.

1.5 السياق السياسيُّ والتجاريُّ

إطلاق ميثوس جاء في سياقٍ دقيق. فأنثروبيك كانت في خلافٍ مع إدارة ترامب منذ أن صنّفها وزير الدفاع **بيت هيجسيث** في فبراير 2026 بأنّها **«خطرٌ على الأمن القوميّ في سلسلة التوريد»**. صدر حكمٌ فيدراليٌّ مبدئيٌّ يوقف هذا التصنيف، وتمّ الطعن عليه من الإدارة. ومع ذلك، أكّدت أنثروبيك أنّها أحاطت كبار المسؤولين الفيدراليين — بما في ذلك وكالة الأمن السيبراني (CISA) ومركز معايير الذكاء الاصطناعي (CAISI) — بقدرات ميثوس الكاملة: الدفاعيّة والهجوميّة.

1.6 خلاصة الفصل

ميثوس لم يولد ولادةً طبيعيّة. لقد سُرِّب قبل إعلانه، وأُعلن قبل أن يُتاح، وقُيِّد استخدامه قبل أن يُستخدم. هو نموذجٌ بحسب تعبير أنثروبيك نفسها **«بعيدٌ بكثيرٍ عن أيِّ نموذج ذكاءٍ اصطناعيٍّ آخر»**، وهو في الوقت ذاته نموذجٌ لن يراه معظم البشر مباشرةً. إنّه مُنعطفٌ في تاريخ النماذج اللغويّة الكبيرة؛ لأنّه فرض على الصناعة أن تُعيد التفكير في **معنى الإطلاق** و**معنى الإتاحة**.

الفصل الثاني: تشريح عائلة كلود — من هايكو إلى ميثوس

﴿ وَفَوْقَ كُلِّ ذِي عِلْمٍ عَلِيمٌ ﴾

[يوسف: 76]

2.1 البنية الهرميّة لعائلة كلود

منذ إطلاق كلود 3 في مارس 2024، اعتمدت أنثروبيك على بنيةٍ هرميّةٍ ثلاثيّةٍ من ثلاثة أسماء مستوحاةٍ من أنواع الأدب الياباني: هايكو (قصيرٌ سريع)، سونت (متوسط)، أوبس (أعظم الأعمال). كلُّ مستوى يخدم حالة استخدامٍ مختلفة، ولكلٍّ تسعيرةٌ وسرعةٌ ودقّة.

ومع إضافة ميثوس في أبريل 2026، أصبحت البنية رباعيّة. فيما يلي تشريحٌ دقيقٌ لكلِّ مستوى:

2.2 هايكو 4.5 — المستوى الأسرع والأرخص

هايكو 4.5 صدر في أكتوبر 2025، وهو النموذج الأكثر توفيراً في عائلة كلود. مُصمَّمٌ للمهام الخفيفة السريعة: الاستخراج، التصنيف، التوجيه، والاستفسارات البسيطة. يعمل في الخلفيّة كموجِّهٍ (router) يُقرِّر ما إذا كانت المهمّة تحتاج إلى نموذجٍ أعلى.

- **التسعير التقريبي**: 1$ لكلِّ مليون رمزٍ للإدخال، 5$ لكلِّ مليون رمزٍ للإخراج.
- **السرعة**: الأسرع في العائلة.
- **الحدُّ الأقصى للإخراج**: 64 ألف رمز.
- **الاستخدام المثاليُّ**: المهام عالية الحجم منخفضة التعقيد.

2.3 سونت 4.6 — المحرّك اليوميُّ للمطوِّرين

سونت 4.6 صدر في فبراير 2026، وهو النموذج الأكثر استخداماً في الأعمال المهنيّة اليوميّة. المفاجأة في هذا الإصدار أنّه يُقدِّم قدراتٍ تقترب من نماذج أوبس السابقة، لكن بسرعةٍ أعلى وسعرٍ أقل.

- **التسعير**: 3$ لكلِّ مليون رمزٍ للإدخال، 15$ لكلِّ مليون رمزٍ للإخراج.
- **نافذة السياق**: مليون رمز (1M tokens).

- **الحدُّ الأقصى للإخراج**: 128 ألف رمز.
- **أداء SWE-bench Verified**: 79.6%.
- **السرعة**: نحو 40-60 رمزاً في الثانية (ضعف سرعة أوبس تقريباً).

وفقاً للتقييمات الداخليّة لأنثروبيك، يفضِّل 70% من المطوِّرين **سونت 4.6** على **أوبس 4.5** السابق في سيناريوهات البرمجة والتصحيح.

2.4 أوبس 4.7 — الرائد العامُّ الحاليُّ

أوبس 4.7 صدر في 16 أبريل 2026، وهو في الوقت الحاليِّ **النموذج الأقوى المتاح للعامّة** من أنثروبيك. يسعى لسدِّ الفجوة بين ما هو متاحٌ للجمهور وما أصبح ممكناً في المختبرات.

- **التسعير**: 5$ لكلِّ مليون رمزٍ للإدخال، 25$ لكلِّ مليون رمزٍ للإخراج.
- **نافذة السياق**: مليون رمز.
- **أداء SWE-bench Verified**: 87.6% (قفزة 6.8 نقاط عن أوبس 4.6).
- **أداء SWE-bench Pro**: 64.3% (قفزة 10.9 نقاط عن أوبس 4.6).
- **OSWorld-Verified** (استخدام الحاسوب): 78.0%.

- **مستوى جهدٍ جديد**: xhigh بين high وmax، لتحكّمٍ أدقَّ في عمق التفكير.
- **وضوح الصور**: زيادة ثلاثية الأضعاف (3.75 ميجابكسل).

الجدير بالذكر أنّ سعر أوبس 4.7 لم يتغيّر عن أوبس 4.6، رغم أنّ المحوِّل الجديد (tokenizer) قد يُنتج رموزاً أكثر بنسبة تصل إلى 35% لنفس النصِّ. هذا يعني أنّ الفاتورة الفعليّة قد ترتفع قليلاً رغم ثبات التسعيرة الاسميّة.

2.5 ميثوس بريفيو — الفئة المُحتجزة

Claude Mythos Preview هو نموذجٌ من فئةٍ منفصلةٍ تماماً، وليس ترقيةً لأوبس. بحسب وصف أنثروبيك الرسميّ: «**ميثوس اسمٌ جديدٌ لفئةٍ جديدةٍ من النماذج: أكبر وأذكى من نماذج أوبس**».

- **التسعير للشركاء**: 25$ لكلِّ مليون رمزٍ للإدخال، 125$ لكلِّ مليون رمزٍ للإخراج (خمسة أضعاف تسعيرة أوبس).
- **نافذة السياق**: مليون رمز.
- **الحدُّ الأقصى للإخراج**: 128 ألف رمز.
- **تاريخ قطع المعرفة**: ديسمبر 2025.
- **أداء SWE-bench Verified**: 93.9% — الأعلى في التاريخ.

- **أداء USAMO 2026**: 97.6% — قريبٌ من الكمال في الرياضيات التنافسيّة.
- **أداء GPQA Diamond**: 94.6% — الاستدلال العلميُّ على مستوى الدراسات العليا.
- **أداء Cybench**: 100% — مشبَّع (saturated).
- **تمّ تمويل شركاء المشروع بـ 100 مليون دولارٍ من الاعتمادات.**

2.6 جدول المقارنة الشامل

لتوضيح الفوارق، إليك هذا الجدول التفصيليّ:

المعيار	هايكو 4.5	سونت 4.6	أوبس 4.7	ميثوس بريفيو
الإدخال (لكلِّ مليون رمز)	$1	$3	$5	$25
الإخراج (لكلِّ مليون رمز)	$5	$15	$25	$125
نافذة السياق	200K	1M	1M	1M
SWE-bench Verified	~50%	79.6%	87.6%	93.9%
GPQA Diamond	—	~85%	94.2%	94.6%
الإتاحة	عامّة	عامّة	عامّة	شركاء فقط

2.7 الفجوة الحقيقيّة بين ميثوس وأوبس 4.7

رغم أنّ أوبس 4.7 هو الأقوى المُتاح، تبقى الفجوة بينه وبين ميثوس فجوةً كبيرة:

- **SWE-bench Verified**: ميثوس 93.9% مقابل أوبس 4.7 87.6% — فارق 6.3 نقطة.
- **SWE-bench Pro**: ميثوس 77.8% مقابل أوبس 4.7 64.3% — فارق 13.5 نقطة.
- **Terminal-Bench 2.0**: ميثوس 82.0% مقابل أوبس 4.7 69.4% — فارق 12.6 نقطة.
- **HLE بدون أدوات**: ميثوس 56.8% مقابل أوبس 4.7 46.9% — فارق 9.9 نقطة.

أنثروبيك صرّحت أنّ **ميثوس بعيدٌ بكثيرٍ عن أقرب نموذجٍ لها (أوبس 4.7)**، وأنّه يُمثّل زيادةً بمقدار 4.3 أضعافٍ عن خطِّ الاتّجاه السابق لأداء النماذج.

2.8 خلاصة الفصل

عائلة كلود في أبريل 2026 هي عائلةٌ رباعيّة: هايكو للكفاءة، سونت للتوازن، أوبس للتقدّم العام، وميثوس للقدرات المحتجزة. ميثوس ليس ترقيةً تدريجيّة؛ إنّه **قفزةٌ نوعيّة** في مستوىً مختلف. وهذه القفزة هي جوهر هذا الكتاب.

الفصل الثالث: المعايير القياسية — الأرقام التي غيّرت المشهد

﴿ وَكُلَّ شَيْءٍ أَحْصَيْنَاهُ كِتَابًا ﴾
[النبأ: 29]

3.1 لماذا المعايير القياسيّة مهمّة؟

المعايير القياسيّة (benchmarks) هي الطريقة التي تقيس بها صناعة الذكاء الاصطناعيّ تقدّم النماذج. ليست مثاليّة، لكنّها أفضل أداةٍ متاحةٍ للمقارنة الموضوعيّة. كلُّ معيارٍ يقيس جانباً مختلفاً: البرمجة، الرياضيات، الاستدلال العلميّ، استخدام الحاسوب، الأمن السيبرانيّ.

ميثوس لم يتفوّق في معيارٍ واحد، بل **كسر الأرقام القياسيّة في كلّ معيارٍ تقريباً**. لنستعرض كلَّ معيارٍ على حدة.

SWE-bench Verified 3.2 — معيار البرمجة الذهبيّ

SWE-bench Verified هو معيار البرمجة الأكثر مُتابعةً في الصناعة. يتألّف من مشكلاتٍ حقيقيّةٍ من مستودعات GitHub لمشاريع شائعةٍ مثل Django وFlask وscikit-learn وpytest. الاختبار لا يقيس كتابة الشيفرة فحسب، بل **فهم قواعد الشيفرة الكبيرة**: تتبُّع الاستيرادات، توقيعات الدوالّ، تأثير التغيير في وحدةٍ على أخرى.

مسار الأداء التاريخيُّ على هذا المعيار يحكي قصّة الصناعة:

- **أواخر 2023**: أفضل النماذج تحلّ 1-4% من المشكلات.
- **منتصف 2024**: GPT-4 وكلود 3.5 سونت مع الهياكل المتخصصة يصلان إلى 40-55%.
- **فبراير 2026**: أوبس 4.6 يحقّق 80.8%.
- **أبريل 2026**: أوبس 4.7 يحقّق 87.6%.
- **أبريل 2026**: **ميثوس بريفيو يحقّق 93.9%.**

هذه القفزة من 80.8% إلى 93.9% خلال شهرين تعادل مضاعفة مستوى ما وصلت إليه الصناعة في 2024.

3.3 SWE-bench Pro — الطبقة الأصعب

SWE-bench Pro هو النسخة الأكثر صعوبةً من الاختبار. يحتوي على مشكلاتٍ متعدّدة اللغات والخطوات.

- أوبس 4.6: 53.4%.
- أوبس 4.7: 64.3%.
- **ميثوس بريفيو: 77.8%.**
- GPT-5.3-Codex (أفضل نموذج OpenAI وقت إطلاق Gemini 3.1 Pro): 56.8%.

الفجوة بين ميثوس وأقرب منافسٍ (GPT-5.3-Codex) هي **21 نقطة**. وفجوة 24 نقطة مع أوبس 4.6. هذا ليس تحسيناً تدريجيّاً؛ إنّه **تحوُّلٌ نوعيٌّ في التعامل مع التعقيد الهندسيِّ الحقيقيّ**.

3.4 USAMO 2026 — الرياضيات الأولمبيّة

USAMO (الأولمبياد الأمريكيُّ للرياضيات) هو معيارٌ صارمٌ للرياضيات التنافسيّة. ميثوس حقّق **97.6%**، قريباً من الكمال. هذا الرقم يتجاوز معظم الطلاب البشر المتأهّلين للأولمبياد.

3.5 GPQA Diamond — الاستدلال العلميُّ على مستوى الدراسات العليا

GPQA Diamond يُغطّي الفيزياء والكيمياء والبيولوجيا على مستوى الدكتوراه. الأسئلة مُصمَّمة بحيث يفشل فيها حتى خبراء المجالات الأخرى.

- Gemini 3.1 Pro: 94.3%.
- أوبس 4.6: 91.3%.
- أوبس 4.7: 94.2%.
- **ميثوس بريفيو: 94.6%.**

3.6 Terminal-Bench 2.0 — وكلاء الأوامر

Terminal-Bench يقيس قدرة النموذج على التنقّل وإكمال المهامّ في بيئة أوامرَ مُحَصَّنة. هذا المعيار يُحاكي ما يفعله مهندس برمجيّاتٍ حقيقيٌّ أمام شاشة الطرفيّة.

- أوبس 4.6: 65.4%.
- أوبس 4.7: 69.4%.
- **ميثوس بريفيو: 82.0%** (92.1% مع مهلة زمنيّةٍ مُمدَّدة إلى أربع ساعاتٍ وتحديثات Terminal-Bench 2.1).

الجدير بالذكر أنّ GPT-5.5 من OpenAI تمكّن من تجاوز ميثوس **بفارقٍ ضئيل** على هذا المعيار الواحد فقط (هو أساساً تعادلٌ إحصائيّ)، مما جعله نقطة ضعفٍ نادرةً لميثوس.

3.7 CyberGym — الأمن السيبرانيُّ الهجوميّ

CyberGym هو معيار إعادة إنتاج الثغرات الأمنيّة. ميثوس سجّل **83.1%** مقابل 66.6% لأوبس 4.6 — قفزة 16.5 نقطة. هذا المعيار تحديداً هو ما دفع أنثروبيك إلى تقييد النموذج.

3.8 Cybench — المشبَّع

Cybench معيارٌ سيبرانيٌّ آخر. ميثوس حقّق **100% في المحاولة الأولى (pass@1)**، بمعنى أنّ المعيار **مشبَّع بالكامل (saturated)**. لم يعد هذا المعيار قادراً على التمييز بين نموذجٍ قويٍّ جداً ونموذجٍ عبقريّ — ميثوس حلَّ كلَّ شيء. هذا التشبُّع دفع أنثروبيك إلى التحوّل من المعايير الصناعيّة إلى **«مهامٍ أمنيّةٍ حقيقيّةٍ جديدة»**، تحديداً البحث عن الثغرات الأمنيّة غير المعروفة (zero-days) في البرمجيّات مفتوحة المصدر.

3.9 Humanity's Last Exam (HLE) — امتحان البشريّة الأخير

HLE هو معيارٌ مُصمَّمٌ ليكون **غير قابلٍ للحلِّ من قبل الذكاء الاصطناعيِّ الحاليِّ**. يضمُّ أسئلةً متعدِّدة التخصُّصات في أعلى مستوى من الصعوبة.

- أوبس 4.6 بدون أدوات: 40.0%.
- أوبس 4.7 بدون أدوات: 46.9%.
- **ميثوس بريفيو بدون أدوات: 56.8%.**
- ميثوس بريفيو مع الأدوات: 64.7%.

الرقم الأكثر دلالةً هو «بدون أدوات»، لأنّه يقيس **الاستدلال الخام** وليس الاسترجاع من البحث. أنثروبيك نفسها لاحظت أنّ ميثوس يُؤدّي جيّداً على HLE حتى في مستويات الجهد المنخفضة، مما قد يُشير إلى **مستوىً من الحفظ (memorization)**. هذه ملاحظةٌ صادقةٌ من الشركة، وتستحقُّ التقدير.

3.10 BrowseComp — كفاءة الرموز

على معيار BrowseComp، حقّق ميثوس نتيجةً أعلى من أوبس 4.6 باستخدام **عدد رموز أقلَّ بمقدار 4.9 أضعاف**. هذا يُعطي إشارةً مهمّة: ميثوس ليس أذكى فحسب، بل **أكفأ** في استخدام موارد الحساب.

3.11 مقارنةٌ شاملةٌ مع المنافسين

لوضع أداء ميثوس في سياقٍ أوسع:

المعيار	ميثوس بريفيو	أوبس 4.7	GPT-5.5	Gemini 3.1 Pro
SWE-bench Verified	93.9%	87.6%	85%~	80.6%
USAMO 2026	97.6%	83%~	86%~	79%~
GPQA Diamond	94.6%	94.2%	92%~	94.3%
HLE بدون أدوات	56.8%	46.9%	43.1%	40%~

3.12 خلاصة الفصل

الأرقام لا تكذب: ميثوس هو **أقوى نموذجٍ لغويٍّ تمَّ توثيقه علنيّاً حتى اليوم**. في 12 من أصل 13 معياراً رئيسيّاً، يتصدّر بفارقٍ واضح. الفجوة بينه وبين الحافّة العامّة (أوبس 4.7, GPT-5.5, Gemini 3.1 Pro) هي **أوسع فجوةٍ بين نموذجٍ حدوديٍّ والحافّة العامّة منذ إطلاق GPT-4 الأصليّ في 2023**.

الفصل الرابع: الأمن السيبراني — جوهر قوّة ميثوس

﴿ وَأَعِدُّوا لَهُم مَّا اسْتَطَعْتُم مِّن قُوَّةٍ ﴾
[الأنفال: 60]

4.1 لماذا الأمن السيبرانيُّ تحديداً؟

ما يُميِّز ميثوس عن غيره ليس فقط أداؤه على معايير البرمجة العامّة، بل قدرته **المفاجِئة** على اكتشاف الثغرات الأمنيّة واستغلالها. هذه القدرة لم تُدرَّب بشكلٍ صريح؛ بل **انبثقت (emerged)** كنتيجةٍ لتحسيناتٍ عامّةٍ في البرمجة والاستدلال والاستقلاليّة.

أنثروبيك تُلخِّص هذه الظاهرة بعبارةٍ مهمّة: «**نفس التحسينات التي تجعل النموذج أكثر فعاليّةً في ترقيع الثغرات، تجعله أكثر فعاليّةً في استغلالها**». هذه المعادلة الخطيرة هي جوهر القصّة كلّها.

4.2 ما وجده ميثوس فعلياً

على مدى عدّة أسابيعَ قبل الإعلان، استخدم فريقٌ صغيرٌ من باحثي أنثروبيك ميثوس للبحث عن ثغراتٍ في النظام البيئيّ المفتوح المصدر. النتائج وردت في تقاريرَ إعلاميّةٍ رسميّة:

- **آلاف الثغرات عالية الخطورة وحرجة الخطورة** اكتُشفت في جميع أنظمة التشغيل الرئيسيّة.
- **ثغراتٌ في جميع متصفّحات الإنترنت الرئيسيّة.**
- **بعض الثغرات موجودة منذ أكثر من 27 عاماً** في نظام OpenBSD، ولم تُكتشف من قبل.

هذه الأرقام ليست مبالغات تسويقيّة؛ لأنّ الكشف عن ثغرةٍ جديدةٍ حقيقيّةٍ (zero-day) هو معيارٌ قابلٌ للتحقُّق: يُبلَّغ عن الثغرة للجهة المسؤولة، ويُصدَر لها رقم CVE.

4.3 لماذا ثغرات الذاكرة تحديداً؟

معظم الثغرات التي اكتشفها ميثوس هي **ثغرات أمان الذاكرة (memory safety vulnerabilities)**. هذا ليس مصادفةً؛ بل نتيجةٌ لأربعة أسبابٍ مرتّبةٍ من الأهمّ:

1. **«المؤشّرات (pointers) حقيقيّة. إنّها ما تفهمه الأجهزة»**. لغات البرمجة ذات الذاكرة غير الآمنة مثل C وC++ تُستخدم في البنى الحرجة.
2. أنظمة التشغيل والمتصفّحات والأدوات الأساسيّة مبنيّةٌ بهذه اللغات.
3. هذه قواعد شيفرةٍ مُفحَّصةٌ بكثرة، فالثغرات الهيّنة وُجدت وصُلِّحت. ما بقي هو الثغرات المعقَّدة.
4. اكتشاف ثغرةٍ عالية الخطورة في نظام OpenBSD أو Linux Kernel **لا يقبل التلاعب** — إمّا الثغرة حقيقيّة، أو لا.

4.4 لماذا مواجهة مع أدوات الفحص التقليديّة؟

أنثروبيك اعتادت على قياس قدرات النماذج في اكتشاف الثغرات عبر معاييرَ داخليّةٍ وخارجيّة. لكنّ ميثوس **أشبع هذه المعايير تقريباً**. المعايير التي تقيس

إعادة إنتاج ثغراتٍ معروفةٍ سابقاً لم تعد قادرةً على التمييز بين القدرة الجديدة والحفظ.

لهذا السبب، حوّلت أنثروبيك تركيزها إلى **«مهامٍ أمنيّةٍ حقيقيّةٍ جديدة»**، وتحديداً اكتشاف ثغرات zero-day. هذا التحوُّل له فائدةٌ إضافيّة: الثغرات المُكتشَفة يُمكن الإفصاح عنها بمسؤوليّةٍ وإصلاحها، مما يجعل الاختبار نافعاً في حدِّ ذاته.

4.5 تقييم AISI — معهد سلامة الذكاء الاصطناعيّ

معهد سلامة الذكاء الاصطناعيِّ (AISI) أجرى تقييمه المستقلَّ لميثوس. بحسب نتائجهم:

- ميثوس **لم يكن أفضل بكثيرٍ** من النماذج الأخرى في مهامٍ سيبرانيّةٍ فرديّة.
- لكنّه تفوّق **بشكلٍ كبيرٍ في تحدّيات الاختراق المتعدِّدة الخطوات الصعبة**، بما في ذلك بعضها لم يُكمله أيُّ نموذج ذكاءٍ اصطناعيٍّ من قبل.
- على مستوى **Capture the Flag (CTF) للخبراء**، نجح ميثوس في 73% من الحالات.

استنتاج AISI كان متحفّظاً: ميثوس سيكون فعّالاً في استغلال «**الأنظمة ضعيفة الدفاع**»، لكنّ الأنظمة الحقيقيّة لديها مدافعون نشطون وأدوات دفاعيّة تُصعِّب النجاح على الأرض. هذا تحفّظٌ مهنيٌّ ضروريٌّ عند تقييم أيّ قدرةٍ جديدة.

4.6 معضلة الاستخدام المزدوج (Dual-Use)

الأمن السيبرانيُّ هو المثال الكلاسيكيُّ على **تقنيّات الاستخدام المزدوج**: نفس الأداة تُستخدم للدفاع والهجوم. كلُّ تحسينٍ في قدرات الاكتشاف يُفيد المدافع والمهاجم معاً. أنثروبيك تذكر هنا تاريخ أدوات fuzzing:

> «عندما انتشرت أول fuzzers البرمجيّة على نطاقٍ واسع، كان هناك قلقٌ من أنّها قد تُمكِّن المهاجمين من اكتشاف الثغرات بمعدّلٍ متزايد. وبالفعل فعلت. لكنّ fuzzers الحديثة مثل AFL أصبحت الآن مكوّناً حرجاً في النظام البيئيّ الأمنيّ».

أنثروبيك تتوقّع نفس المسار لميثوس: **في البداية** قد يُفيد المهاجمين أكثر، **لكن في النهاية**، بعد وصول المنظومة إلى توازنٍ جديد، ستُفيد النماذج القويّة المدافعين أكثر وتُحسِّن الأمن العامَّ.

4.7 الرسالة إلى صنّاع القرار

أنثروبيك لم تكتفِ بإعلان ميثوس، بل **أحاطت كبار المسؤولين الفيدراليين** — بما في ذلك CISA (وكالة الأمن السيبرانيّ والبنية التحتيّة) وCAISI (مركز معايير ومبتكرات الذكاء الاصطناعيّ) — بقدرات النموذج الكاملة. هذا النهج يُشير إلى أنّ الشركة تنظر لميثوس ليس فقط كمنتجٍ تجاريّ، بل كـ**أصلٍ استراتيجيٍّ له تبعاتٌ على الأمن القوميّ**.

4.8 الاقتباس المحوريُّ من أنثروبيك

في بيان مشروع جلاس وينج، كتبت أنثروبيك:

> «شكّلنا مشروع جلاس وينج بسبب قدراتٍ لاحظناها في نموذجٍ حدوديٍّ جديدٍ دربناه، ونعتقد أنّه قد يُعيد تشكيل الأمن السيبراني... ميثوس بريفيو هو نموذجٌ حدوديٌّ عامُّ الغرض غير مُطلقٍ يكشف حقيقةً صارخة: نماذج الذكاء الاصطناعيّ وصلت إلى مستوىً من قدرة البرمجة يمكنها تجاوز جميع البشر إلّا الأكثر مهارةً في إيجاد واستغلال الثغرات البرمجيّة».

هذا اعترافٌ صريحٌ بأنّ النموذج **يتفوّق على معظم البشر** في هذا المجال. والأهمُّ أنّ الشركة تُقرُّ بأنّ هذه القدرات **ستنتشر لا محالة**، وقد تصل إلى جهاتٍ غير ملتزمةٍ بنشرها بأمان.

4.9 خلاصة الفصل

الأمن السيبرانيُّ هو **مركز ثقل ميثوس**. ليس لأنّ أنثروبيك دربته على ذلك، بل لأنّ قدراته العامّة بلغت مستوىً يجعل منه خبيراً أمنيّاً ضمنيّاً. هذه القدرة — الدفاعيّة والهجوميّة في آنٍ واحد — هي السبب الرئيسيُّ في قرار التقييد. وفي الفصل القادم، نستعرض المشروع الذي صُمِّم لترويض هذه القدرة: مشروع جلاس وينج.

الفصل الخامس: مشروع جلاس وينج — التحالف الدفاعيّ

﴿ وَتَعَاوَنُوا عَلَى الْبِرِّ وَالتَّقْوَى وَلَا تَعَاوَنُوا عَلَى الْإِثْمِ وَالْعُدْوَانِ ﴾
[المائدة: 2]

5.1 ما هو مشروع جلاس وينج؟

Project Glasswing — أو «مشروع الجناح الزجاجيّ» — هو الإطار الذي أعلنته أنثروبيك بالتزامن مع ميثوس بريفيو في 8 أبريل 2026. الهدف المعلن: **استخدام ميثوس لتأمين أهمِّ البرمجيّات في العالم**، وإعداد الصناعة للممارسات التي ستحتاجها للبقاء أمام المهاجمين السيبرانيين.

الاسم ذاته ذو دلالة: فراشة الجناح الزجاجيِّ شفّافةٌ ومتحوِّرة. المشروع يعكس هذه الفكرة: قوّةٌ هائلةٌ داخل إطارٍ شفّافٍ ومسؤول.

5.2 أعضاء التحالف

المشروع يضمُّ **اثنتي عشرة شركةً كبرى** من قطاعات التكنولوجيا والماليّة، وتشمل أبرزها:

- **Apple**: لتأمين أنظمة iOS وmacOS والمتصفّح Safari.
- **Google**: لتأمين Android وChrome وChrome OS وGoogle Cloud.
- **Microsoft**: لتأمين Windows وEdge وAzure.
- **Amazon**: لتأمين AWS والخدمات السحابيّة المرتبطة بها.
- شركاتٌ ماليّةٌ كبرى لتأمين بناها التحتيّة المصرفيّة.
- **مشروع Claude for Open Source**: لإتاحة النموذج لمحافظي المشاريع مفتوحة المصدر.

الاختيار ليس عشوائيّاً؛ هذه الشركات تُمثِّل **العمود الفقريَّ للبنية التحتيّة الرقميّة العالميّة**. ثغرةٌ في أيّ من هذه الأنظمة تعني تأثيراً على مئات الملايين بل المليارات من المستخدمين.

5.3 الدعم المالي: مائة مليون دولار

أنثروبيك خصّصت **مائة مليون دولارٍ ($100M) كاعتماداتٍ مجانيّة** لشركاء المشروع. بعد انتهاء هذا الاعتماد، تُطبَّق تسعيرةٌ بقيمة $25 لكلِّ مليون رمزٍ إدخال، و$125 لكلِّ مليون رمزٍ إخراج. هذه التسعيرة خمسة أضعاف تسعيرة أوبس 4.7، وتعكس التكلفة الحقيقيّة للحوسبة اللازمة.

5.4 كيف يعمل المشروع عمليّاً؟

الشركاء يستخدمون ميثوس بطريقتين أساسيّتين:

1. **المسح الدفاعيُّ للبنية التحتيّة الذاتيّة**: تمرير قواعد الشيفرة الخاصّة بهم عبر النموذج لاكتشاف ثغراتٍ قبل المهاجمين.
2. **تأمين البرمجيّات مفتوحة المصدر**: مسح المكتبات والأطر المستخدمة عالميّاً، ثم الإفصاح المسؤول عن الثغرات.

أنثروبيك التزمت بـ**الإفصاح عن طبيعة الثغرات الحاليّة غير الشفّافة خلال 135 يوماً** من مشاركتها مع المنظمات المسؤولة. هذا الالتزام الزمنيُّ هو ممارسة الأمن السيبرانيِّ المعياريّة للإفصاح المسؤول.

5.5 شهادات الشركاء

في بيان الإطلاق، ضمّنت أنثروبيك شهاداتٍ من شركائها. اللغة المستخدمة لافتة:

> «قدرات الذكاء الاصطناعيّ عبرت عتبةً تُغيِّر جذريّاً الإلحاحَ المطلوبَ لحماية البنية التحتيّة الحرجة من التهديدات السيبرانيّة، **ولا عودة إلى الوراء**. عملنا التأسيسيُّ مع هذه النماذج أظهر أنّنا نستطيع اكتشاف وإصلاح الثغرات الأمنيّة عبر الأجهزة والبرمجيّات بوتيرةٍ ومقياسٍ كانا مستحيلين من قبل».

وشهادة أخرى تُلخِّص المعادلة بوضوح:

> «النافذة بين اكتشاف الثغرة واستغلالها من قِبل الخصم قد انهارت — ما كان يستغرق شهوراً يحدث الآن بالدقائق مع الذكاء الاصطناعيّ. ميثوس بريفيو يُظهر ما هو ممكنٌ الآن للمدافعين على نطاقٍ واسع، والخصوم حتماً سيسعون لاستغلال القدرات ذاتها. هذا ليس سبباً للتباطؤ؛ بل سبب للتحرّك معاً، **أسرع**».

5.6 خلاصة الفصل

مشروع جلاس وينج ليس مجرّد برنامج وصولٍ مقيّدٍ لنموذجٍ جديد. إنّه **نموذجٌ تشغيليٌّ جديدٌ** لكيفيّة إطلاق القدرات الحدوديّة: عبر تحالفاتٍ مُغلقةٍ مع ضماناتٍ صريحة، بدلاً من الإطلاق المفتوح. هذا النموذج قد يتكرّر في المستقبل مع قدراتٍ أخرى ذات استخدامٍ مزدوج.

الفصل السادس: لماذا احتجزت أنثروبيك ميثوس؟

﴿ وَلَا تُلْقُوا بِأَيْدِيكُمْ إِلَى التَّهْلُكَةِ ﴾

[البقرة: 195]

6.1 قرارٌ استثنائيٌّ في صناعةٍ مختلفة

في صناعةٍ تُعرف بسباقها المحموم لإطلاق القدرات بأقصى سرعةٍ ممكنة، جاء قرار أنثروبيك بـ**عدم إتاحة نموذجها الأقوى** كقرارٍ استثنائيٍّ تماماً. آخر مرّةٍ اتّخذت فيها شركةُ ذكاءٍ اصطناعيٍّ رائدةٌ قراراً مشابهاً كانت في 2019، حين احتجزت OpenAI نموذج GPT-2 خوفاً من استخدامه في توليد لغةٍ خادعةٍ أو متحيِّزةٍ أو مُسيئةٍ على نطاقٍ واسع.

لكنّ حالة ميثوس مختلفة. الخطر ليس توليد نصٍّ خادع؛ بل **اكتشاف ثغراتٍ أمنيّةٍ حقيقيّةٍ في أنظمةٍ حقيقيّةٍ يستخدمها مليارات البشر**. الفرق كمّيٌّ ونوعيٌّ في آنٍ معاً.

6.2 الأسباب الرسميّة المُعلنة

أنثروبيك قدّمت أسباباً واضحةً لقرار التقييد:

1. **القدرات المزدوجة في الأمن السيبرانيّ**: النموذج قويٌّ جدّاً في اكتشاف الثغرات، ويُمكن استخدامه للهجوم بقدر ما يُستخدم للدفاع.
2. **انعدام التوازن في النظام البيئيّ**: المدافعون لا يمتلكون حاليّاً أدواتٍ دفاعيّةً توازي قدرة ميثوس الهجوميّة. إطلاق النموذج مبكراً سيُعطي المهاجمين أفضليّةً مؤقّتة.
3. **الحاجة لضماناتٍ جديدة**: أنثروبيك تعمل على تطوير ضماناتٍ (safeguards) للتعامل مع نماذج من فئة ميثوس، ولم تكتمل هذه الضمانات بعد.

6.3 الهدف النهائي: نشرٌ آمنٌ على نطاق واسع

أنثروبيك كانت صريحةً أنّ التقييد **مؤقّت**. بحسب بيانها الرسميّ:

«لا نخطّط لإتاحة Claude Mythos Preview للعموم، لكنّ هدفنا النهائيَّ هو تمكين مستخدمينا من نشر النماذج من فئة ميثوس بأمانٍ على نطاقٍ واسع — لأغراض الأمن السيبرانيّ، وأيضاً للفوائد العديدة الأخرى التي ستجلبها مثل هذه النماذج القادرة جدّاً».

هذا يعني أنّ قدرات ميثوس ستصل إلى نماذج أوبس المستقبليّة، **لكن بعد** تطوير الضمانات اللازمة. بعض هذه الضمانات بدأت تظهر في أوبس 4.7 الذي وُصِف بأنّه **«النموذج الجسر»** حيث تُختبر آليّات السلامة الحقيقيّة قبل الانتشار الأوسع.

6.4 القراءة البديلة: هل هو تسويقٌ ذكيّ؟

بعض خبراء الأمن السيبرانيِّ — الذين هم بطبيعة مهنتهم أكثر حذراً من غيرهم — تساءلوا عمّا إذا كان «قلق» أنثروبيك حول إصدار ميثوس مجرّد **«عرض مبيعاتٍ متقن»**. هذا التساؤل مشروعٌ لأسبابٍ ثلاث:

1. عدم إتاحة النموذج **يزيد** الاهتمام به، وبالتالي يُعزّز سمعة أنثروبيك كشركةٍ مسؤولة.
2. النموذج يُستخدم فعليّاً من خلال مشروع جلاس وينج، مما يعني أنّ أنثروبيك تحصل على إيراداتٍ من أكبر الشركات التقنيّة.

3. الخبر وحده أدّى إلى هبوطٍ حادٍّ في أسهم شركات الأمن السيبرانيّ، مما أثّر على ديناميكيّات السوق.

لكن الحجّة المضادّة قويّةٌ أيضاً: لو كان ميثوس متاحاً للعموم بسعر أوبس، لحقّقت أنثروبيك إيراداتٍ أضخم بكثير. التقييد — إن كان تسويقاً — فهو تسويقٌ مُكلِف.

6.5 السابقة التي تُؤسَّس

قرار أنثروبيك يُؤسِّس **سابقةً** قد تتبعها المختبرات الأخرى. إذا استطاع مشروع جلاس وينج إنتاج نتائج أمنيّةٍ قابلةٍ للقياس — آلاف الثغرات المرقَّعة، منظومة مفتوحة المصدر أكثر أماناً — فإنّ ذلك يُولِّد ضغطاً على OpenAI وGoogle للقيام بشيءٍ مماثل.

بالفعل، استجابت OpenAI مع إطلاقها لـ GPT-5.5 بمفهومٍ جديد: **«Trusted Access for Cyber»** — وصول موثوقٌ للأمن السيبرانيّ. فمع قدرة النموذج على اكتشاف وترقيع الثغرات الأمنيّة المتقدّمة، نفّذت OpenAI **«مصنّفات مخاطر سيبرانيّة»** أكثر صرامة للمستخدمين العامّين، مع إتاحة **«ترخيصٍ سيبرانيٍّ متساهل»** للمدافعين المعتمدين. تحت إطار OpenAI للاستعداد (Preparedness Framework)، صُنِّف GPT-5.5 بمستوى خطرٍ **«مرتفع»** في القدرات البيولوجيّة والسيبرانيّة.

6.6 السياق السياسيُّ الدقيق

لا يُمكن فصل قرار أنثروبيك عن سياقه السياسيّ. في فبراير 2026، صنّف وزير الدفاع الأمريكيُّ **بيت هيجسيث** أنثروبيك بأنّها «**خطرٌ على سلسلة توريد الأمن القوميّ**» — قرارٌ تمّ الطعن عليه وأصدر قاضٍ فيدراليٌّ حكماً مبدئيّاً بإيقافه.

في هذا السياق، قرار تقييد ميثوس مع إحاطة CISA وCAISI بقدراته يُصبح **إشارةً سياسيّةً** أيضاً: أنثروبيك تتصرّف بمسؤوليّة، وتتعاون مع الحكومة في القضايا الأمنيّة الحرجة. القرار إذن متعدّد الأبعاد: تقنيّ، اقتصاديّ، وسياسيّ في آنٍ واحد.

6.7 من منظورٍ إسلاميّ

القرار في حدِّ ذاته يحمل بُعداً أخلاقيّاً يتقاطع مع المنظور الإسلامي. فالقاعدة الفقهيّة «**درء المفاسد مقدَّم على جلب المصالح**» تنطبق هنا بشكلٍ مباشر: منفعة إتاحة النموذج للجميع موجودة، لكنّ مفسدة استخدامه لاختراق البنى التحتيّة الحيويّة قد تفوق هذه المنفعة بمرّات. ميثوس يذكّرنا بأنّ العلم **أمانة**، وأنّ من يملك القدرة مسؤولٌ عن كيفيّة استخدامها ومنع إساءتها.

6.8 خلاصة الفصل

قرار احتجاز ميثوس هو قرارٌ **مدروسٌ متعدّد الأبعاد**: تقنيٌّ لأنّ القدرة السيبرانيّة تخلق اختلالاً، تجاريٌّ لأنّه يُعزِّز علامة المسؤوليّة، سياسيٌّ لأنّه يُظهر التعاون مع الحكومة، وأخلاقيٌّ لأنّه يُقدِّم مبدأ الاحتياط على السرعة. السؤال المفتوح هو: هل سيُصبح هذا النموذج معياراً أم استثناءً؟

الفصل السابع: المقارنة المباشرة — ميثوس ضد باقي العائلة

﴿ أَفَمَن يَعْلَمُ أَنَّمَا أُنزِلَ إِلَيْكَ مِن رَّبِّكَ الْحَقُّ كَمَنْ هُوَ أَعْمَىٰ ﴾

[الرعد: 19]

7.1 إطار المقارنة

بعد الاستعراض النظريّ، حان وقت المقارنة التفصيليّة. سنُقارن ميثوس بثلاث نماذجَ: **أوبس 4.7** (الرائد المُتاح)، **سونت 4.6** (الأكثر شعبيّة)، **وهايكو 4.5** (الأكثر توفيراً). نستخدم ستّة محاور: (1) الأداء، (2) التسعير، (3) نافذة السياق، (4) السرعة، (5) حالات الاستخدام، (6) الإتاحة.

7.2 المحور الأول: الأداء

ميثوس يتصدّر كلَّ معيارٍ تقريباً. لكنّ الفجوة تختلف بحسب المعيار:

المعيار	هايكو 4.5	سونت 4.6	أوبس 4.7	ميثوس
SWE-bench Verified	~50%	79.6%	87.6%	93.9%
SWE-bench Pro	—	~45%	64.3%	77.8%
GPQA Diamond	~70%	~85%	94.2%	94.6%
USAMO 2026	—	~60%	~83%	97.6%
Terminal-Bench 2.0	—	~55%	69.4%	82.0%
CyberGym	—	~55%	~70%	83.1%
HLE بدون أدوات	—	~25%	46.9%	56.8%

الفجوة الأكبر تظهر في المهامِّ عالية التعقيد: الرياضيّات الأولمبيّة، وكلاء الأوامر، والأمن السيبرانيّ. الفجوة الأضيق تظهر في GPQA Diamond، مما يُلمِح إلى أنّ أوبس 4.7 قريبٌ من السقف المعرفيِّ للنماذج الحاليّة في الاستدلال العلميّ.

7.3 المحور الثاني: التسعير

النموذج	إدخال ($/ MTok)	إخراج ($/ MTok)	المضاعف مقابل هايكو
هايكو 4.5	$1	$5	×1
سونت 4.6	$3	$15	×3
أوبس 4.7	$5	$25	×5

ميثوس	$25	$125	×25
بريفيو			

ميثوس هو **الأغلى بفارقٍ واضح**. مضاعف 25× مقارنةً بهايكو يعكس حقيقتين: التكلفة الحقيقيّة للحوسبة، والتقييد المقصود لاستخدامه للشركاء فقط.

7.4 المحور الثالث: نافذة السياق

جميع النماذج الحديثة (سونت 4.6، أوبس 4.7، ميثوس) تدعم **نافذة سياقٍ بمليون رمز (1M tokens)**. هذا يعني إمكانيّة إدخال قاعدة شيفرةٍ كاملةٍ متوسّطة الحجم ومعالجتها في طلبٍ واحد. هايكو 4.5 محدودٌ بـ 200 ألف رمزٍ فقط.

الفرق في نافذة السياق بين النماذج الحديثة يتجلّى في **جودة الاستدلال عبر السياقات الطويلة**. على معيار GraphWalks BFS للاستدلال في المليون رمز، سجّل ميثوس **80.0%**، أي أربعة أضعاف نتيجة GPT-5.4 تقريباً.

7.5 المحور الرابع: السرعة

السرعة تتحدّد بنوع المهمّة وحجم السياق، لكنّ الترتيب العامُّ:

1. **هايكو 4.5**: الأسرع، مُصمَّمٌ للمهامّ السريعة.
2. **سونت 4.6**: متوسط، 40-60 رمزاً في الثانية تقريباً.

3. **أوبس 4.7**: أبطأ، 20-30 رمزاً في الثانية، لأنّه يُفكّر أكثر.

4. **ميثوس بريفيو**: بطيءٌ نسبيّاً، خاصّةً مع «التفكير التكيّفي بأعلى جهد» وميزانية المليون رمزٍ لكلِّ مهمّة.

ميثوس يُستخدم غالباً مع **إعداد Terminus-2 harness** و«التفكير التكيفي» بأقصى جهد، وميزانية 1M رمزٍ لكلِّ مهمّة. هذا الإعداد يُعطي أعلى دقّة، لكنّه ليس للاستخدامات اليوميّة.

7.6 المحور الخامس: حالات الاستخدام

هايكو 4.5: الاستخراج، التصنيف، التوجيه، استفسارات الخدمة الذاتيّة، المهامّ عالية الحجم منخفضة التعقيد.

سونت 4.6: البرمجة اليوميّة، كتابة التقارير، تحليل البيانات، المحادثات التفاعليّة، إعداد المحتوى، **90% من المهامّ المهنيّة اليوميّة.**

أوبس 4.7: البرمجة المعقّدة، تحليل الشيفرة الكبيرة، القرارات المعماريّة، التحليلات الاستراتيجيّة، التفكير العميق متعدّد الخطوات، الوكلاء المستقلّون.

ميثوس بريفيو: اكتشاف الثغرات الأمنيّة، استغلال الثغرات الافتراضيّ لأغراض الدفاع، تحليل قواعد الشيفرة الضخمة للأمن، حلّ المسائل الرياضيّة التنافسيّة، البحث الأكاديميُّ المعقّد.

7.7 المحور السادس: الإتاحة

هذا هو الفارق الأهمّ:

- **هايكو 4.5**: متاح عبر واجهة برمجة التطبيقات (API)، Claude.ai، وجميع منصّات الشركاء (Bedrock, Vertex AI, Foundry).
- **سونت 4.6**: متاح في جميع هذه المنصّات، وفي النسخة المجانيّة من Claude.ai.
- **أوبس 4.7** : متاح في جميع منصّات API (الاسم الرسميُّ: `claude-opus-4-7`).
- **ميثوس بريفيو: بالدعوة فقط.** لا توجد نقطة تسجيلٍ ذاتيّ. الوصول عبر شركاء جلاس وينج أو برنامج Claude for Open Source.

7.8 متى تستخدم ماذا؟

القاعدة العمليّة للمطوّرين:

1. **ابدأ بسونت 4.6 افتراضياً.** سيحلُّ 90% من مهامّك بتكلفةٍ معقولة.
2. **استخدم هايكو 4.5** للمهامِّ الكثيفة الخفيفة أو كموجِّهٍ أوّليّ.
3. **انتقل إلى أوبس 4.7** حين تفشل سونت في حلِّ مشكلةٍ معقّدة.

4. **انتظر ميثوس...** لأنّه لن يكون متاحاً لك.

7.9 خلاصة الفصل

ميثوس ليس بديلاً عن أوبس أو سونت أو هايكو؛ إنّه **فئةٌ مختلفة** لاستخدام مختلف. في عائلة كلود، كلُّ نموذجٍ يخدم غرضاً، وميثوس يخدم غرضاً **استثنائيّاً لا يمرُّ عبر السوق العامّ**. هذا تقسيمٌ جديدٌ للسوق قد يُصبح معياراً في صناعة الذكاء الاصطناعيّ.

الفصل الثامن: السلامة والمواءمة في ميثوس

﴿ إِنَّ اللَّهَ يَأْمُرُ بِالْعَدْلِ وَالْإِحْسَانِ ﴾

[النحل: 90]

8.1 لماذا السلامة في ميثوس أهمُّ؟

كلُّ نموذجٍ قويٍّ يحتاج إلى ضماناتٍ سلامة، لكنّ ميثوس يحتاجها بشكلٍ استثنائيّ. قدرته السيبرانيّة العالية تعني أنّ أيَّ «انحراف» (misalignment) — أيَّ سلوكٍ لم يُرَد له — قد يؤدّي إلى عواقب حقيقيّة، وليس فقط إلى مخرَجاتٍ نصّيّةٍ غير دقيقة. لذلك، وصفت أنثروبيك ميثوس بأنّه «**أكثر النماذج المُواءَمة جيّداً التي دربتها**».

8.2 فلسفة الدستور (Constitutional AI)

ميثوس، كبقيّة عائلة كلود، مُدرَّبٌ باستخدام **Constitutional AI** — إطار أنثروبيك لتدريب النماذج على مجموعةٍ من المبادئ الأخلاقيّة دون الحاجة إلى تدخّلٍ بشريٍّ مستمرّ. هذا الإطار يعتمد على:

1. **المبادئ الأساسيّة (constitution)**: مجموعة قواعد عامّة.
2. **RLHF** (التعلّم المعزَّز من التقييم البشريّ): لتحسين الاستجابات.
3. **RLAIF** (التعلّم المعزَّز من تقييم الذكاء الاصطناعيّ): حيث يُقيّم نموذجٌ آخر المخرجات بناءً على الدستور.

في ميثوس، أُضيفت طبقاتٌ أعمق من التقييم السيبرانيِّ المتخصّص، لأنّ مخاطر الأمن السيبرانيِّ تختلف عن مخاطر اللغة الاعتياديّة.

8.3 بطاقة النظام (System Card) — 244 صفحة

مع الإعلان، نشرت أنثروبيك **بطاقة نظامٍ بـ 244 صفحة** — وثيقةٌ تقنيّةٌ تصف كلَّ جانبٍ من جوانب سلامة النموذج. الوثيقة تُغطّي:

- قدرات النموذج على مستوى الأخطار البيولوجيّة والكيميائيّة والإشعاعيّة والنوويّة.
- قدرات الاستقلاليّة (agentic capabilities).

- اختبارات «الإقناع» والتحيّز.
- مخاطر الأمن السيبرانيِّ تفصيلاً.
- محاولات الاختبار الهجوميِّ (red-teaming) من فرقٍ داخليّةٍ وخارجيّة.
- الضمانات المُطبَّقة في كلِّ حالة.

حجم الوثيقة وحده (244 صفحة) يعكس جدّيّة التعامل. للمقارنة، بطاقات نماذج كلود السابقة كانت بين 50 و150 صفحة.

8.4 اختبار «الحفظ» (Memorization) — اعتراف نزيه

في أحد أكثر مقاطع الإعلان صراحةً، اعترفت أنثروبيك أنّ:

> «ميثوس لا يزال يُؤدّي جيّداً على HLE بمستوى جهدٍ منخفض، وهذا قد يُشير إلى مستوىً من الحفظ».

هذا الاعتراف مهمٌّ لأنّه يُظهر نضجاً منهجيّاً: الشركة لا تدّعي الكمال، بل تُؤشّر إلى مناطق الحذر عند قراءة أرقامها. كما ذكرت أنّ مُرشّحات «الحفظ» تُؤشّر مجموعةً فرعيّةً من مسائل SWE-bench، لكنّ الهامش يبقى قائماً بعد استبعاد هذه المسائل.

8.5 فرق الاختبار الهجوميُّ (Red Teams)

ميثوس خضع لاختباراتٍ هجوميّةٍ من فرقٍ داخليّةٍ وخارجيّةٍ مستقلّة:

- **فريق أنثروبيك الداخليّ**: محاولات لإيجاد ثغراتٍ في النموذج نفسه.
- **AISI** (معهد سلامة الذكاء الاصطناعيّ): تقييمٌ مستقل.
- **CISA** و**CAISI** (الجهات الفيدراليّة الأمريكيّة): إحاطاتٌ تقنيّة.
- **شركاء جلاس وينج** (Microsoft وApple وغيرهم): اختبارٌ عملي.

8.6 مبدأ «النموذج الجسر»

أنثروبيك صرّحت أنّ أوبس 4.7 هو **«النموذج الجسر»** (bridge model) الذي تُختبر فيه آليّات السلامة الحقيقيّة قبل الانتشار الأوسع لنماذج من فئة ميثوس. هذا النهج التدريجيُّ مهمٌّ: كلُّ ضمانٍ جديدٍ يُختبر في نموذجٍ متوسّط القدرة قبل تطبيقه في نموذجٍ حدوديّ.

من ضمن هذه الضمانات الجديدة في أوبس 4.7: **«برنامج التحقُّق السيبراني»** (Cyber Verification Program) الذي يسمح لمحترفي الأمن السيبرانيِّ المعتمدين بأداء أبحاث الثغرات واختبار الاختراق بضماناتٍ خاصّة.

8.7 الخطُّ الأخلاقيُّ الإسلامي

من منظورٍ إسلاميّ، فلسفة أنثروبيك في السلامة تتقاطع مع ثلاث قواعدَ فقهيّة:

1. **«الضرر يُزال»**: إزالة الضرر المحتمل قبل وقوعه.
2. **«لا ضرر ولا ضرار»**: منع الإضرار بالذات وبالآخر.
3. **«ما لا يُدرَك كلُّه لا يُترَك كلُّه»**: لا يُمنع النفع كلُّه بسبب احتمال الضرر، بل يُوازَن ويُقيَّد.

مشروع جلاس وينج يُطبِّق هذه القاعدة الأخيرة: بدلاً من منع النموذج كلياً، أُتيح ضمن إطارٍ ضيِّقٍ ينفع المدافعين أكثر مما يضرُّ.

8.8 خلاصة الفصل

السلامة في ميثوس ليست فكرةً لاحقةً، بل **مركزيّةٌ في التصميم**. الاستثمار في بطاقة نظامٍ بـ 244 صفحة، وفلسفة النموذج الجسر، والاعتراف الصريح بالحفظ — كلُّ ذلك يُشير إلى نضجٍ منهجيٍّ في التعامل مع نموذجٍ بمستوى ميثوس.

الفصل التاسع: الأثر على الصناعة والاستجابة التنافسيّة

﴿ فَاسْتَبِقُوا الْخَيْرَاتِ ﴾

[البقرة: 148]

9.1 لحظة «GPT-4» لعام 2026

حين أُطلق GPT-4 في مارس 2023، أحدث هزّةً في الصناعة. المنافسون كلّهم — Meta، Google، Anthropic — وجدوا أنفسهم أمام حافّةٍ جديدةٍ يُلزمهم اللحاق بها. ميثوس يُمثّل **لحظةً مشابهةً في أبريل 2026**.

لكن هناك فرقٌ جوهريٌّ: GPT-4 كان متاحاً. ميثوس ليس كذلك. فالمنافسون يرون نتائج ميثوس في البنشمارك (benchmarks) لكنّهم لا يرون **كيف يتصرّف فعليّاً**. هذا يخلق حالة **«سباق ضدَّ شبح»**: تسعى لإثبات قدراتك على نموذجٍ لن يستخدمه أحد.

9.2 استجابة OpenAI: GPT-5.5 وTrusted Access for Cyber

استجابت OpenAI بسرعة. بعد أسبوعٍ واحدٍ تقريباً من إطلاق أوبس 4.7، أصدرت OpenAI **GPT-5.5** — نموذجٌ وُصف بأنّه «**تفكيرٌ جوهريٌّ في كيفيّة تفاعل الذكاء مع نظام تشغيل الحاسوب ومكدّس البرمجيّات المهنيّ**».

GPT-5.5 تفوّق على جميع النماذج المتاحة علنياً، بما فيها أوبس 4.7، في معظم المعايير. والأهمّ، **تفوّق على ميثوس في معيار Terminal-Bench 2.0** — ولو بفارقٍ ضئيل (تعادلٌ إحصائيّ). هذه المرّة الأولى التي يتفوّق فيها نموذجٌ علنيٌّ على ميثوس في أيِّ معيارٍ رئيسيّ.

OpenAI تبنّت أيضاً نموذجاً مشابهاً لجلاس وينج عبر «**Trusted Access for Cyber**»: وصولٌ موثوقٌ للأمن السيبرانيّ. مصنّفات مخاطرَ أكثر صرامةً للمستخدمين العامّين، وترخيصٌ «متساهلٌ» للمدافعين المعتمدين.

9.3 استجابة Google: Gemini 3.1 Pro

Gemini 3.1 Pro كان الأحدث من Google قبل إطلاق ميثوس. أرقامه على GPQA Diamond (94.3%) قريبةٌ من ميثوس، لكنّ فجوته على SWE-bench (80.6%) تُلمِح إلى ضعفٍ نسبيٍّ في البرمجة الوكيليّة (agentic). من المتوقّع أن يأتي ردُّ Google الأكبر في Gemini 4 خلال الأشهر القادمة.

9.4 النماذج مفتوحة المصدر: GLM-5

الضغط التنافسيُّ لا يأتي من الشركات المغلقة فحسب. النماذج الصينيّة مفتوحة المصدر مثل **GLM-5** من Z.ai تقترب من النماذج الأمريكيّة المغلقة على SWE-bench Verified. هذه المنافسة تُعقِّد المشهد: إذا لحقت النماذج المفتوحة بالحافّة، فإنّ التقييد عبر مشاريع مثل جلاس وينج قد يُصبح أقلَّ فاعليّة.

9.5 تأثير الأسواق الماليّة

حين سُرِّب خبر ميثوس في مارس 2026، **هبطت أسهم شركات الأمن السيبرانيّ**. السبب: إذا كان الذكاء الاصطناعيُّ قادراً على اكتشاف الثغرات أسرع من شركات الأمن التقليديّة، فهل ستبقى هذه الشركات ذات قيمة؟

الجواب الأرجح: نعم، لكن بنموذج عملٍ مختلف. شركات الأمن ستتحوّل من **«مورِّدي الكشف اليدويّ»** إلى **«مُنسِّقي الدفاع المؤتمت»**. من يستطيع دمج ميثوس ونظرائه في سير العمل الدفاعيّ أسرع، يكسب.

9.6 الأثر على المطوِّرين

للمطوِّرين، ميثوس يخلق وضعاً غريباً: **أقوى نموذج برمجة في العالم يُستخدم لفحص ثغراتٍ أمنيّة، لا لمساعدتك على بناء تطبيقاتك**. النماذج العامّة المتاحة

(أوبس 4.7، Gemini 3.1 Pro، GPT-5.5) رائعةٌ — لكن لها الآن **سقفٌ معلومٌ أعلى بكثيرٍ** ممّا تُقدِّمه.

للمطوِّرين الأفراد، الفجوة بين 80.8% و93.9% على SWE-bench Verified **نادراً ما تهمُّ في العمل اليوميّ**. النماذج العامّة جيّدةٌ بالفعل للغالبيّة العظمى من مهامِّ البرمجة.

9.7 الأثر على سياسات الدول

حكومات كثيرة — أمريكا، بريطانيا، الاتحاد الأوروبيّ — بدأت تُفكِّر بجدّيّةٍ في تنظيم النماذج ذات القدرات الحدوديّة. مسار ميثوس قد يُسرِّع:

1. **متطلّبات التقييم قبل الإطلاق**: تقييمٌ إلزاميٌّ لكلِّ نموذجٍ حدوديٍّ قبل إتاحته.
2. **تقييد التصدير**: منع بعض النماذج من الوصول لدولٍ معيّنة.
3. **الشفافيّة الإلزاميّة**: نشر بطاقات نظامٍ تفصيليّةٍ كشرط.
4. **تفويض الإفصاح المسؤول**: الإبلاغ عن الثغرات المُكتشفة بالذكاء الاصطناعيّ في إطارٍ زمنيٍّ محدّد.

9.8 التوقّع: ميثوس- كلاس في عائلة كلود 5

التوقّع الأرجح من المحلّلين: قدرات ميثوس ستصل إلى نماذج **كلود Opus 5** خلال عامٍ أو عامين. الفارق هو أنّ النماذج العامّة ستُطلق بضماناتٍ مُطوَّرة، لن تسمح باستخدامها للهجمات الحقيقيّة.

بحسب تقديرات المحلّلين، «**المسار واضح: ما يفعله ميثوس اليوم في مختبرٍ مقيَّد، ستفعله النماذج المتاحة علنيّاً خلال جيلٍ أو جيلين**».

9.9 خلاصة الفصل

ميثوس ليس مجرّد نموذجٍ جديد؛ إنّه **لحظةٌ تشكيليّةٌ للصناعة**. استجابات OpenAI وGoogle، تغيُّرات في الأسواق، ضغطٌ على التشريع، تحوُّلاتٌ في عمل المطوِّرين — كلُّها مؤشّراتٌ على أنّ أثر ميثوس يتجاوز بكثيرٍ حدود مشروع جلاس وينج.

الفصل العاشر: مستقبل النماذج من فئة ميثوس

﴿ وَلَا تَقْفُ مَا لَيْسَ لَكَ بِهِ عِلْمٌ ﴾

[الإسراء: 36]

10.1 هل سيُفتح ميثوس للعموم يوماً؟

السؤال الذي يطرحه الجميع. الإجابة بحسب أنثروبيك: **لا، ليس بهذا الشكل.** لكنّ نماذج من فئة ميثوس ستصل إلى العموم عبر أوبس المستقبليّة، مع ضماناتٍ جديدة.

الاستشراف العمليُّ: في غضون 12-18 شهراً، سنرى **أوبس 5 أو 5.1** بقدراتٍ مشابهةٍ لميثوس، مُزوَّداً بـ:

1. تصنيف مخاطر قبل الاستجابة للطلبات السيبرانيّة.
2. برنامج تحقُّقٍ للمحترفين (بامتدادٍ لبرنامج أوبس 4.7).

3. سجلٌّ مراقبٌ لأنماط الاستخدام ذات المخاطر العالية.
4. حدودٌ أوضح على سيناريوهات الاستغلال الصريحة.

10.2 ما الذي سيأتي بعد ميثوس؟

ميثوس ليس نقطة النهاية. مسار التحسُّن في قدرات النماذج اللغويّة لم يتوقّف. التوقُّعات:

- **نماذج ما بعد ميثوس**: من أنثروبيك أو منافسيها، بقدراتٍ تتجاوز ميثوس.
- **التخصُّص العموديّ**: نماذج مُدرَّبةٌ خصّيصاً لمجالاتٍ معيّنة (الطبّ، القانون، البحث العلميّ).
- **الاستقلاليّة الممتدّة**: نماذج تعمل أيّاماً أو أسابيعَ على مهامٍ واحدة.
- **نماذج متعدّدة الأوساط**: دمجٌ أعمق للصوت والفيديو والبيانات الحسّيّة.

10.3 انهيار نافذة الوقت بين الاكتشاف والاستغلال

أحد شركاء جلاس وينج لخَّص الأثر الأهمَّ للنماذج من فئة ميثوس: «**النافذة بين اكتشاف الثغرة واستغلالها من قِبل الخصم قد انهارت — ما كان يستغرق شهوراً يحدث الآن بالدقائق**».

هذا الانهيار يُغيِّر كلَّ شيء في الأمن السيبرانيّ. الدفاع التقليديُّ يعتمد على «نافذة الاستجابة»: الوقت بين اكتشاف الثغرة وترقيعها. إذا انهارت هذه النافذة، فإنّ **الأنظمة الدفاعيّة يجب أن تُصبح استباقيّةً بالكامل**: فحصٌ مستمرٌّ، ترقيعٌ تلقائيٌّ، عزل سريع. الذكاء الاصطناعيُّ ليس خياراً في هذا المستقبل؛ بل **شرطٌ للبقاء**.

10.4 معضلة الأخلاقيّات: من يُقرِّر من يستحقُّ الوصول؟

نموذج جلاس وينج يطرح سؤالاً أخلاقيّاً جوهريّاً: **من يُقرِّر أيُّ المؤسّسات تحصل على القدرة المحتجزة؟** اليوم، تحتكر أنثروبيك القرار. غداً، قد تتدخّل الحكومات. بعد غد، قد تظهر منظّماتٌ دوليّةٌ على غرار المنظّمات التي تُنظِّم الأسلحة النوويّة.

هذا السؤال لا إجابة سهلةً له. لكنّه يستحقُّ النقاش العميق — خاصّةً في العالم العربيِّ والإسلاميّ، حيث النقاش حول حوكمة الذكاء الاصطناعيِّ لا يزال في بداياته.

10.5 ماذا يعني هذا للعالم العربيِّ؟

العالم العربيُّ في موقعٍ دقيقٍ. من جهة، لا يملك أيٌّ من الدول العربيّة مختبراً يصل إلى حافّة ميثوس. من جهةٍ أخرى، البنى التحتيّة الرقميّة في المنطقة تحتاج إلى الحماية من القدرات التي يُمثّلها ميثوس.

التوصيات العمليّة لصنّاع القرار:

1. **الاستثمار في الكوادر**: تدريب مهندسي أمنٍ سيبرانيٍّ يتقنون استخدام الذكاء الاصطناعيِّ في الدفاع.
2. **التكامل مع النماذج المُتاحة**: استخدام أوبس 4.7، GPT-5.5، Gemini 3.1 Pro للفحص الدفاعيِّ للبنية التحتيّة الوطنيّة.
3. **تطوير قدراتٍ محلّيّة**: الاستثمار في نماذجَ عربيّةٍ مفتوحة المصدر للتطبيقات السياديّة.
4. **المشاركة في النقاش الدوليّ**: الحضور في جلسات صياغة الحوكمة الدوليّة للذكاء الاصطناعيّ.

10.6 رسالةٌ إلى الباحثين العرب في الذكاء الاصطناعيّ

الفجوة التقنيّة كبيرة، لكنّها ليست أبديّة. الباحثون العرب في الذكاء الاصطناعيِّ ينجزون أعمالاً مميّزةً في المؤتمرات الدوليّة. ما ينقص هو **البنية التحتيّة الحوسبيّة** والاستثمار المستدام. ميثوس يُذكِّرنا بحجم الهوّة، لكنّ التاريخ يُعلِّمنا أنّ الهوّات قابلةٌ للتجسير حين تتكاتف الإرادة والموارد.

10.7 خلاصة الفصل

مستقبل النماذج من فئة ميثوس يشمل: (1) وصول قدراتها إلى النماذج العامّة، (2) نماذج أقوى منها خلال سنواتٍ قليلة، (3) تحوُّل كاملٌ في صناعة الأمن السيبرانيّ، (4) أسئلة حوكمةٍ عالميّةٍ لم تُحلّ، و(5) فرصٌ للدول التي تُحسن التموضع.

الخاتمة

﴿ وَمَا تَوْفِيقِي إِلَّا بِاللَّهِ عَلَيْهِ تَوَكَّلْتُ وَإِلَيْهِ أُنِيبُ ﴾
[هود: 88]

قطعنا في هذا الكتاب رحلةً من تسريب مارس 2026، إلى الإعلان الرسميّ في أبريل، إلى تفاصيل المعايير القياسيّة، إلى الأمن السيبرانيّ ومشروع جلاس وينج، إلى فلسفة الاحتجاز، إلى المقارنات التفصيليّة مع أوبس 4.7 وسونت 4.6 وهايكو 4.5، إلى أسئلة الحوكمة والمستقبل.

ماذا نأخذ من هذه الرحلة؟ خمس خلاصاتٍ جوهريّة:

أولاً: ميثوس ليس مجرّد ترقيةٍ تدريجيّة. إنّه **فئةٌ جديدةٌ من النماذج** تتجاوز كلَّ ما أنتجته أنثروبيك قبله. بنسبة 93.9% على SWE-bench Verified، و97.6% على USAMO، و100% على Cybench، يُعيد ميثوس تعريف معنى «نموذج حدوديّ».

ثانياً الاختلاف عن باقي عائلة كلود ليس في الدرجة فحسب، بل في **النوع**. هايكو للكفاءة، سونت للتوازن، أوبس للتقدُّم، وميثوس لـ«**ما لا يُطلق للعموم**». هذه تراتبيّةٌ جديدةٌ في صناعةٍ كانت تقيس نفسها بمعيار الإتاحة الفوريّة.

ثالثاً: قرار التقييد، سواء نظرنا إليه كاحترازٍ مسؤولٍ أو كتسويقٍ ذكيّ، يُؤسِّس **سابقةً مهمّةً**. نموذج «التحالف المغلق» قد يُصبح النموذج التشغيليَّ للقدرات ذات الاستخدام المزدوج.

رابعاً: الأمن السيبرانيُّ دخل حقبةً جديدة. «**النافذة بين الاكتشاف والاستغلال انهارت**». من يستطيع دمج النماذج الدفاعيّة المتقدّمة أسرع، يكسب. ومن لا يستطيع، يخسر. والعالم العربيُّ أمام فرصةٍ ومسؤوليّةٍ في الوقت ذاته.

خامساً: قدرات ميثوس ستصل إلى نماذج العامّة خلال أشهر — ربّما في أوبس 5 — لكن مع ضماناتٍ مُطوَّرة. نحن نعيش لحظةً انتقاليّةً ستُشكِّل صناعة الذكاء الاصطناعيّ لسنواتٍ قادمة.

من المنظور الإسلاميّ، ميثوس يُذكِّرنا بمبدأين راسخين: «**كلُّ قدرةٍ أمانة**»، و«**درء المفاسد مقدَّم على جلب المصالح**». أنثروبيك في قرار التقييد تتصرّف وفق مبدأٍ إسلاميٍّ أصيل، وإن لم تعلنه بهذه الصيغة.

في النهاية، القصّة ليست عن نموذجٍ واحد، بل عن **المستقبل الذي نختاره**. نماذج كميثوس ستأتي، الواحد تلو الآخر. السؤال ليس «هل سنستطيع بناءها؟» بل «كيف سنتعامل معها؟». هذا السؤال الأخلاقيُّ هو الأهمُّ دائماً، من صناعة البارود إلى الطاقة النوويّة إلى الذكاء الاصطناعيّ.

وما توفيقي إلّا بالله، عليه توكّلت وإليه أنيب. **والله أعلم.**

د. فضل محمد الأكوع

ميشيغان، أبريل 2026

المراجع العلميّة

أوّلاً: المصادر الرسميّة لأنثروبيك

1. Anthropic. (2026). *Claude Mythos Preview System Card*. أنثروبيك. 244 صفحة. أبريل 2026.
2. Anthropic. (2026). *Project Glasswing Announcement*. أنثروبيك. https://www.anthropic.com/glasswing
3. Anthropic. (2026). *Claude Mythos Preview: Technical Overview*. أنثروبيك. Red Team Blog. https://red.anthropic.com/2026/mythos-preview/
4. Anthropic. (2026). *Claude Opus 4.7: Model Card*. أنثروبيك. 16 أبريل 2026.
5. Anthropic. (2026). *Claude Models Overview*. Claude API Docs. https://docs.claude.com/en/docs/about-claude/models/overview

ثانياً: المعايير القياسيّة (Benchmarks)

1. Jimenez, C. E., et al. (2024). *SWE-bench: Can Language Models Resolve Real-World GitHub Issues?* ICLR 2024.

2. Rein, D., et al. (2023). *GPQA: A Graduate-Level Google-Proof Q&A Benchmark*. arXiv:2311.12022.

3. Glazer, E., et al. (2024). *FrontierMath: Tier 4 Mathematical Problems for AI Evaluation*.

4. Phan, L., et al. (2025). *Humanity's Last Exam: A Multi-Modal Benchmark at the Frontier of Human Knowledge*.

5. Terminal-Bench Team. (2025). *Terminal-Bench 2.0: Benchmarking AI Agents in Terminal Environments*.

6. Zhang, A., et al. (2024). *Cybench: A Framework for Evaluating Cybersecurity Capabilities of Language Models*.

7. CyberGym Team. (2025). *CyberGym: A Benchmark for Cybersecurity Vulnerability Reproduction*.

ثالثاً: التغطية الإعلاميّة

1. NBC News. (2026). *Why Anthropic won't release its new Mythos AI model to the public*. أبريل 2026.
2. Fortune. (2026). *Anthropic's CMS Misconfiguration Reveals Upcoming Frontier Model*. 27 مارس 2026.
3. CNBC. (2026). *Cybersecurity Stocks Drop on News of Anthropic's Advanced AI Capabilities*. 27 مارس 2026.
4. VentureBeat. (2026). *OpenAI's GPT-5.5 Narrowly Beats Anthropic's Claude Mythos Preview on Terminal-Bench 2.0*. أبريل 2026.
5. The New Stack. (2026). *Inside Project Glasswing: How Big Tech Is Using Claude Mythos for Defense*.

رابعاً: التحليلات التقنيّة المستقلّة

1. Vellum. (2026). *Claude Opus 4.7 Benchmarks Explained*. https://www.vellum.ai/blog/claude-opus-4-7-benchmarks-explained
2. MindStudio. (2026). *Claude Mythos Benchmark Results: SWE-Bench 93.9% and What It Means*.

3. LLM Stats. (2026). *Claude Mythos Preview: Pricing, Benchmarks & Performance*. https://llm-stats.com/models/claude-mythos-preview

4. NxCode. (2026). *Claude Mythos Benchmarks Explained: 93.9% SWE-bench & Every Record Broken*.

5. OfficeChai. (2026). *Anthropic's Claude Mythos Preview Smashes Coding Benchmarks*.

6. Pluralsight. (2026). *What is Claude Mythos? Complete Analysis*.

خامساً: أبحاث المواءمة (Alignment) والسلامة

1. Bai, Y., et al. (2022). *Constitutional AI: Harmlessness from AI Feedback*. arXiv:2212.08073.

2. Askell, A., et al. (2021). *A General Language Assistant as a Laboratory for Alignment*. Anthropic Research.

3. UK AI Safety Institute (AISI). (2026). *Independent Evaluation of Claude Mythos Preview*.

4. CISA. (2026). *Advisory on AI-Powered Vulnerability Discovery*. U.S. Cybersecurity and Infrastructure Security Agency.

سادساً: التفسير القرآنيّ والفقه الإسلاميّ

1. ابن كثير، إسماعيل. تفسير القرآن العظيم. دار طيبة. الرياض.
2. الطبريّ، محمد بن جرير. جامع البيان في تأويل القرآن. مؤسّسة الرسالة.
3. القرطبيّ، محمد بن أحمد. الجامع لأحكام القرآن. دار الكتب المصريّة.
4. ابن نجيم، زين الدين. الأشباه والنظائر. دار الكتب العلميّة. (القواعد الفقهيّة الكبرى).
5. السيوطيّ، جلال الدين. الأشباه والنظائر في قواعد وفروع فقه الشافعيّة.
6. الزحيليّ، وهبة. الفقه الإسلاميّ وأدلّته. دار الفكر. دمشق.

سابعاً: المنافسون والسياق الصناعيّ

1. OpenAI. (2026). *GPT-5.5 Technical Report*. OpenAI. أبريل 2026.

2. Google DeepMind. (2026). *Gemini 3.1 Pro: Technical Report*. Google. مارس 2026.

3. Z.ai. (2025). *GLM-5: Open-Source Foundation Model*.

4. OpenAI. (2019). *Better Language Models and Their Implications: GPT-2*. OpenAI Blog.

نبذةٌ عن المؤلف

الدكتور **فضل محمد الأكوع** باحثٌ في البيولوجيا الحاسوبية والمعلوماتية الحيوية والجينومات المكانية (Spatial Genomics) في كلية الطب بجامعة ميشيغان في الولايات المتحدة الأمريكية. يعمل في تقاطع الذكاء الاصطناعي والطب الحيوي، وهو مهتمٌّ بتطبيقات التعلم الآلي ونماذج اللغة الكبيرة في البحث العلمي الطبي وعلوم الحياة.

نشر أبحاثاً علميةً في دوريات محكّمةٍ عالمية، منها دراسةٌ عن تأثير مثبّطات SGLT2 على أنسجة الكلى في المجلة الشهيرة *Journal of Clinical Investigation* (*JCI*) عام 2023، ودراسةٌ لاحقةٌ في عام 2026 على تأثير جراحة تكميم المعدة (VSG) في إطار دراسة IMPROVE-T2D باستخدام تقنية تسلسل الحمض النووي الريبي أحادي الخلية (scRNA-seq).

إلى جانب عمله البحثي، يُؤلّف الدكتور الأكوع بنشاطٍ كُتباً باللغتين العربية والإنجليزية، تمتدّ موضوعاتها من الدراسات الإسلامية والإعجاز العلمي في القرآن، إلى الذكاء الاصطناعي ونماذج اللغة الكبيرة، إلى التاريخ اليمني والجيوسياسة، إلى الأدلّة العملية للمهاجرين والمبتعثين. ويُدير ديواناً فكرياً شهرياً يُسمّى **«ديوان**

الأصدقاء» يلتقي فيه سبعةٌ من المفكّرين لمناقشة موضوعات كتبه وقضايا الفكر المعاصر.

يكتب الدكتور الأكوع بأسلوبٍ يجمع بين الدّقة العلمية والسّياق الإسلامي، ساعياً إلى تقديم المعرفة التقنية المعقّدة بلغةٍ يفهمها القارئ العربي المسلم، ويربط اكتشافات العلم الحديث بالإطار الإيماني والأخلاقي.

مؤلّفاتٌ أخرى للمؤلّف

صدر للمؤلّف في العام نفسه (2026) مجموعةٌ من الكتب بالعربية والإنجليزية، نذكر منها:

١. نهاية الكون في القرآن الكريم

٢. هل انتهت الوحدة اليمنية؟

٣. سر التقارب الأمريكي الإسرائيلي: من يقود من؟

٤. العلم نور والجهل ظلام

٥. الرؤساء اليمنيون في مذكرات ويكيليكس

٦. التدين عبر الأجيال في الغرب

٧. تصنيف الآيات في القرآن الكريم — دراسة تأملية في البنية الموضوعية

٨. أشراط الساعة بين النص والعلم

٩. مشاكل اليمن عبر الأزمان

٠١٠ فن التربية — كيف تصنع قادة من أبنائك

٠١١ تأثير النماذج اللغوية الكبيرة على البحث العلمي والتعليم الجامعي

٠١٢ كيف تعمل النماذج اللغوية الكبيرة — دليل مبسّط

٠١٣ الذكاء الاصطناعي وأبرز أدواته منذ 2025

٠١٤ كلود كود — الدليل الشامل

٠١٥ العملات الرقمية — دليل شامل للمبتدئين

٠١٦ التخطيط للتقاعد

٠١٧ وادي السيليكون — تاريخ وابتكار وريادة عالمية

٠١٨ دليل شراء وبيع السيارات المستعملة في أمريكا

٠١٩ أشهر المتنزهات الوطنية في أمريكا

٠٢٠ سر قوة الجامعات الأمريكية

٠٢١ دليل المهاجر اليمني الجديد إلى أمريكا

٠٢٢ أمريكا — صعود الإمبراطورية وبوادر الأفول

٠٢٣ الذكاء الاصطناعي في الطب

٢٤. الإعجاز العلمي في القرآن – منظور باحث في الجينوم

٢٥. الخلافة الإسلامية: من السقيفة إلى سقوط غرناطة

٢٦. الحوثيون وغزة: مقايضة الدم بالسلطة

٢٧. مستقبل المعلوماتية الحيوية والبيولوجيا الحاسوبية

٢٨. الحقوق الزوجية والحياة الأسرية للمسلمين في الغرب

٢٩. السلفية – دراسة في المفهوم والنشأة والتيارات المعاصرة

٣٠. جدتي عتيقة – المرأة التي كانت مثل الجبال

٣١. الغذاء والشفاء – بين العلم والسنة النبوية

٣٢. الزواج الناجح – دليل عملي بمنظور إسلامي

٣٣. كيف تنجح أكاديمياً في الجامعات الأمريكية

٣٤. النقد المشروع وحدود معاداة السامية

٣٥. أختي وفاء – رسائلُ الحُبِّ التي لم نقُلْها

٣٦. دليل اللاجئ الجديد إلى أوتاوا

القسم الإنجليزيّ

English Section

The contents of this book in English, beginning with a new introduction.

Dr. Fadhl Mohammed Alakwaa

Introduction

In the evening of April 8, 2026, Anthropic announced a new language model called **Claude Mythos Preview**. This was not an ordinary announcement in the stream of releases that had followed since Claude 3 appeared in March 2024. It was, by every measure, exceptional. A model that surpassed everything before it —and yet the company decided **not to release it to the public**, launching it instead through a closed partnership of cybersecurity partners known as **Project Glasswing.**

This is the story of Mythos. A story of a model whose existence leaked by accident in March 2026, when Anthropic left an unpublished blog post draft on an unsecured server, where it was discovered by two cybersecurity researchers. A story of a model that caused cybersecurity stocks to fall sharply the day it surfaced. A story of a model that Anthropic itself described as "**far ahead of any other AI model in cyber capabilities.**"

But the story runs deeper. Mythos is not merely a stronger model —it is **an entirely new class**, above the Opus line that had until then been the pinnacle of Anthropic's production. It represents a

pivotal moment in the AI industry: for the first time in seven years, a leading company decided **to withhold its most powerful model from the public**. The last time this happened was in 2019, when OpenAI held back GPT-2.

In this book we trace the story of Mythos from the leak to the present moment. We begin with the story of the disclosure, proceed through an anatomy of the full Claude family from Haiku through Opus 4.7 to Mythos, enter the benchmark scores Mythos broke, explore the cybersecurity capabilities at the core of its power, examine Project Glasswing and the containment philosophy Anthropic adopted, and arrive at the future of this model class.

Our aim is to give the Arabic-speaking reader a precise, well-documented understanding of a model that they will not be able to use directly, but whose effects they will see within months in the public models available to them. Anthropic has explicitly stated that the capabilities of Mythos will reach future Opus models after appropriate safeguards are developed.

Dr. Fadhl Mohammed Alakwaa
Michigan, April 2026

Chapter 1: The Birth of Mythos — A Model Leaked Before Announcement

1.1 The Leak That Shook the Industry

On March 26, 2026, two cybersecurity researchers—**Roy Paz** of LayerX Security and **Alexandre Pauwels** of Cambridge University—discovered a misconfiguration in Anthropic's content management system (CMS). The error exposed roughly **3,000 unpublished digital assets**, including a draft blog post about a yet-unannounced model.

The draft was candid: the new model was "**far ahead of any other AI model in cyber capabilities**" and "**could spark a wave of advanced attacks.**" Within hours, major outlets—Fortune, CNBC, CoinDesk—picked up the story. Cybersecurity stocks cratered.

1.2 The Official Announcement — April 8, 2026

About two weeks after the leak, Anthropic formally announced the model on April 8, 2026, as **Claude Mythos Preview**. Three simultaneous announcements accompanied the release:

1. **Issuance of the System Card**: a 244-page technical document describing the model's capabilities, limits, and safety testing.
2. **Launch of Project Glasswing**: a coalition of twelve major technology and finance companies—including Apple, Google, Microsoft, and Amazon—to use Mythos for securing critical infrastructure.
3. **Access restriction**: the model would not be made generally available; access would be by invitation only, for coalition partners and selected organizations working on critical infrastructure.

1.3 The Codename: Capybara

Anthropic customarily assigns internal codenames to its models prior to release. Mythos carried the codename **"Capybara,"** after the world's largest rodent. The name "Mythos" was chosen from the Greek **μῦθος**, meaning a foundational narrative or the

connective tissue that shapes an understanding of reality. By Anthropic's official description, the name evokes **"the deep connective tissue that links together knowledge and ideas."**

1.4 A New Tier Above Opus

The most important point in the official announcement was a single sentence: **"Mythos is a new name for a new tier of model: larger and more intelligent than our Opus models—which were, until now, our most powerful."**

That sentence redraws the entire Claude hierarchy. Until Mythos, Anthropic's architecture had been three tiers: Haiku (fast and cheap), Sonnet (balanced), and Opus (most capable). With Mythos, the structure becomes four tiers:

- **Haiku 4.5**: for fast, lightweight tasks.
- **Sonnet 4.6**: the daily driver for developers.
- **Opus 4.7**: the advanced publicly available model.
- **Mythos Preview (Capybara)**: the restricted tier, available to partners only.

1.5 The Political and Commercial Context

Mythos arrived in a delicate context. Anthropic had been at odds with the Trump administration since Defense Secretary **Pete Hegseth** in February 2026 designated the company a "**supply chain risk to national security.**" A federal court issued a preliminary injunction against the designation, which the administration is appealing. Nevertheless, Anthropic confirmed it had briefed senior federal officials—including the Cybersecurity and Infrastructure Security Agency (CISA) and the Center for AI Standards and Innovation (CAISI)—on the full offensive and defensive capabilities of Mythos.

1.6 Chapter Summary

Mythos did not have a normal birth. It was leaked before it was announced, announced before it was available, and restricted before it was used. It is a model that, by Anthropic's own words, is "**far ahead of any other AI model,**" yet one most humans will never see directly. It marks a turning point in the history of large language models, because it forced the industry to reconsider **what "release" means** and **what "availability" means.**

Chapter 2: Anatomy of the Claude Family — From Haiku to Mythos

2.1 The Claude Family Hierarchy

Since the launch of Claude 3 in March 2024, Anthropic has used a three-tier hierarchy of Japanese literary names: Haiku (short and fast), Sonnet (medium), and Opus (most refined). Each tier serves a different use case, with its own pricing, speed, and accuracy profile. With the April 2026 addition of Mythos, the structure became four-tiered.

2.2 Haiku 4.5 — The Fastest and Cheapest Tier

Haiku 4.5 was released in October 2025. It is the most economical Claude model, designed for fast, lightweight tasks: extraction, classification, routing, and simple inquiries. It often

runs in the background as a router deciding whether a task needs a larger model.

- **Approximate pricing**: ~$1 per million input tokens, ~$5 per million output tokens.
- **Speed**: the fastest in the family.
- **Maximum output**: 64K tokens.
- **Best for**: high-volume, low-complexity tasks.

2.3 Sonnet 4.6 — The Daily Driver

Sonnet 4.6, released in February 2026, is the most widely used model for everyday professional work. Its surprise is that it delivers capabilities close to earlier Opus models at a lower cost and higher speed.

- **Pricing**: $3 per million input tokens, $15 per million output tokens.
- **Context window**: 1M tokens.
- **Maximum output**: 128K tokens.
- **SWE-bench Verified**: 79.6%.
- **Speed**: roughly 40–60 tokens/second (about twice Opus's speed).

According to Anthropic's internal testing, 70% of developers prefer **Sonnet 4.6** over the previous **Opus 4.5** in coding and refactoring scenarios.

2.4 Opus 4.7 — The Current Generally Available Flagship

Opus 4.7 was released on April 16, 2026. At the time of writing, it is **the most powerful publicly available** Anthropic model, bridging the gap between what is available to the public and what is possible in labs.

- **Pricing**: $5 per million input tokens, $25 per million output tokens.
- **Context window**: 1M tokens.
- **SWE-bench Verified**: 87.6% (a 6.8-point jump over Opus 4.6).
- **SWE-bench Pro**: 64.3% (a 10.9-point jump over Opus 4.6).
- **OSWorld-Verified**: 78.0%.
- **New effort level**: xhigh (between high and max), for finer control over reasoning depth.
- **Vision resolution**: tripled (3.75 MP).

Notably, the sticker price of Opus 4.7 did not change from Opus 4.6, yet its new tokenizer may produce up to 35% more tokens for the same input text. Real bills may therefore rise even though list prices remain stable.

2.5 Mythos Preview — The Restricted Tier

Claude Mythos Preview is a separate tier, not an Opus upgrade. In Anthropic's own words: "**Mythos is a new name for a new tier of model: larger and more intelligent than our Opus models.**"

- **Partner pricing**: $25 per million input tokens, $125 per million output tokens (five times Opus).
- **Context window**: 1M tokens.
- **Maximum output**: 128K tokens.
- **Knowledge cutoff**: December 2025.
- **SWE-bench Verified**: 93.9% — an all-time high.
- **USAMO 2026**: 97.6% — near-perfect on competition mathematics.
- **GPQA Diamond**: 94.6%.
- **Cybench**: 100% — saturated.
- **Glasswing partners received a $100M credit pool.**

2.6 Comprehensive Comparison Table

Metric	Haiku 4.5	Sonnet 4.6	Opus 4.7	Mythos
Input ($/MTok)	$1	$3	$5	$25
Output ($/MTok)	$5	$15	$25	$125
Context Window	200K	1M	1M	1M
SWE-bench Verified	~50%	79.6%	87.6%	93.9%
GPQA Diamond	—	~85%	94.2%	94.6%
Availability	Public	Public	Public	Partners

2.7 The Real Gap Between Mythos and Opus 4.7

Even though Opus 4.7 is the strongest publicly available model, the gap to Mythos remains wide:

- **SWE-bench Verified**: Mythos 93.9% vs. Opus 4.7 87.6% — a 6.3-point gap.
- **SWE-bench Pro**: Mythos 77.8% vs. Opus 4.7 64.3% — a 13.5-point gap.
- **Terminal-Bench 2.0**: Mythos 82.0% vs. Opus 4.7 69.4% — a 12.6-point gap.

- **HLE without tools**: Mythos 56.8% vs. Opus 4.7 46.9% — a 9.9-point gap.

Anthropic has stated that **Mythos is far ahead of its next-best model (Opus 4.7)**, representing a **4.3× increase** over the prior trendline of model performance.

2.8 Chapter Summary

The Claude family in April 2026 is four-tiered: Haiku for efficiency, Sonnet for balance, Opus for general frontier capability, and Mythos for restricted capabilities. Mythos is not a gradual upgrade; it is a **qualitative leap** at a different level. That leap is the core of this book.

Chapter 3: The Benchmarks — Numbers That Changed the Landscape

3.1 Why Benchmarks Matter

Benchmarks are how the AI industry measures model progress. They are imperfect, but they are the best tools available for objective comparison. Each benchmark measures a different dimension: coding, mathematics, scientific reasoning, computer use, cybersecurity. Mythos did not merely excel in one category—it **broke records across nearly every major benchmark.**

3.2 SWE-bench Verified — The Gold Standard for Coding

SWE-bench Verified is the industry's most watched coding benchmark. It consists of real issues from popular GitHub repositories: Django, Flask, scikit-learn, pytest. The test does not just measure code generation; it measures **understanding of**

large codebases: tracing imports, function signatures, the ripple effects of a change across modules.

The historical performance trajectory on this benchmark tells the industry's story:

- **Late 2023**: best models resolve 1–4%.
- **Mid-2024**: GPT-4 and Claude 3.5 Sonnet with specialized scaffolding reach 40–55%.
- **February 2026**: Opus 4.6 reaches 80.8%.
- **April 2026**: Opus 4.7 reaches 87.6%.
- **April 2026**: **Mythos Preview reaches 93.9%.**

3.3 SWE-bench Pro — The Hardest Tier

SWE-bench Pro is the harder variant, with multi-language and multi-step problems:

- Opus 4.6: 53.4%.
- Opus 4.7: 64.3%.
- **Mythos Preview: 77.8%.**
- GPT-5.3-Codex (OpenAI's best at Gemini 3.1 Pro launch): 56.8%.

The gap between Mythos and its closest competitor (GPT-5.3-Codex) is **21 points**. The gap with Opus 4.6 is 24 points. This is not incremental improvement; it is a **qualitative shift** in handling real engineering complexity.

3.4 USAMO 2026 — Olympiad Mathematics

USAMO (United States of America Mathematical Olympiad) is a rigorous competition mathematics benchmark. Mythos scored **97.6%**, near perfection, surpassing most of the human students who qualify for the Olympiad.

3.5 GPQA Diamond — Graduate-Level Scientific Reasoning

GPQA Diamond covers physics, chemistry, and biology at the doctoral level. Questions are designed so that experts from adjacent fields still fail.

- Gemini 3.1 Pro: 94.3%.
- Opus 4.6: 91.3%.
- Opus 4.7: 94.2%.
- **Mythos Preview: 94.6%.**

3.6 Terminal-Bench 2.0 — Agent Workflows

Terminal-Bench measures a model's ability to navigate and complete tasks in a sandboxed terminal environment. It simulates what a real software engineer does at the command line.

- Opus 4.6: 65.4%.
- Opus 4.7: 69.4%.
- **Mythos Preview: 82.0%** (92.1% with extended four-hour timeouts and Terminal-Bench 2.1 updates).

OpenAI's GPT-5.5 narrowly surpassed Mythos on this one benchmark—essentially a statistical tie—making Terminal-Bench 2.0 a rare relative weak point for Mythos.

3.7 CyberGym — Offensive Cybersecurity

CyberGym measures reproduction of security vulnerabilities. Mythos scored **83.1%** versus Opus 4.6's 66.6%—a 16.5-point leap. This benchmark in particular drove Anthropic's containment decision.

3.8 Cybench — Saturated

Cybench is another cyber benchmark. Mythos achieved **100% pass@1**, meaning the benchmark is **fully saturated**. It can no longer distinguish a strong model from a genius model—Mythos solves everything. This forced Anthropic to move beyond industry benchmarks to **"novel real-world security tasks,"** specifically finding zero-day vulnerabilities in open-source software.

3.9 Humanity's Last Exam (HLE)

HLE is designed to be **unsolvable by current AI**. It features expert-level, multidisciplinary questions.

- Opus 4.6 (no tools): 40.0%.
- Opus 4.7 (no tools): 46.9%.
- **Mythos Preview (no tools): 56.8%.**
- Mythos Preview (with tools): 64.7%.

The "no tools" number is more meaningful—it tests raw reasoning rather than retrieval. Anthropic itself noted that Mythos performs well on HLE even at low effort, which may indicate **some memorization**. This is an honest acknowledgment worth appreciating.

3.10 BrowseComp — Token Efficiency

On BrowseComp, Mythos scored higher than Opus 4.6 while using **4.9× fewer tokens**. Mythos is not just smarter—it is **more efficient** in its use of compute.

3.11 Broad Competitive Comparison

Benchmark	Mythos	Opus 4.7	GPT-5.5	Gemini 3.1 Pro
SWE-bench Verified	93.9%	87.6%	~85%	80.6%
USAMO 2026	97.6%	~83%	~86%	~79%
GPQA Diamond	94.6%	94.2%	~92%	94.3%
HLE (no tools)	56.8%	46.9%	43.1%	~40%

3.12 Chapter Summary

The numbers do not lie: Mythos is **the most capable language model publicly documented to date**. On 12 of 13 major benchmarks, it leads by clear margins. The gap between Mythos and the public frontier (Opus 4.7, GPT-5.5, Gemini 3.1 Pro) is **the**

widest between a frontier model and the public state of the art since the launch of the original GPT-4 in 2023.

Chapter 4: Cybersecurity — The Core of Mythos's Power

4.1 Why Cybersecurity Specifically?

What sets Mythos apart is not only its raw coding performance, but its **emergent** ability to identify and exploit security vulnerabilities. This ability was not explicitly trained; it **emerged** as a downstream consequence of general improvements in coding, reasoning, and autonomy.

Anthropic summarizes the dynamic in an important sentence: **"The same improvements that make the model substantially more effective at patching vulnerabilities also make it substantially more effective at exploiting them."** This dual-use equation is the heart of the story.

4.2 What Mythos Actually Found

Over several weeks before the announcement, a small team of Anthropic researchers used Mythos to hunt for vulnerabilities in the open-source ecosystem:

- **Thousands of high- and critical-severity vulnerabilities** across every major operating system.
- **Vulnerabilities in every major web browser.**
- **Some bugs over 27 years old** in the OpenBSD codebase, previously undiscovered.

4.3 Why Memory Safety Vulnerabilities?

Most of what Mythos found were **memory safety vulnerabilities**, for four reasons:

1. **"Pointers are real. They're what the hardware understands."** Memory-unsafe languages like C and C++ are used in critical infrastructure.
2. Operating systems, browsers, and core utilities are built with these languages.
3. These codebases are heavily audited; the easy bugs are gone. What remains is complex.

4. High-severity vulnerabilities in OpenBSD or the Linux kernel are **unambiguous**—either real or not.

4.4 Saturation of Traditional Scanning Tools

Anthropic used to track vulnerability discovery through internal and external benchmarks. Mythos **mostly saturates** those benchmarks. Tests measuring reproduction of previously known vulnerabilities can no longer distinguish novel capability from memorization. This pushed Anthropic toward **"novel real-world security tasks,"** specifically zero-day discovery, where results are independently verifiable.

4.5 AISI Evaluation

The UK AI Safety Institute (AISI) conducted an independent evaluation. Their findings:

- Mythos was **not dramatically better** than other models on individual cyber tasks.
- But it was significantly better at **difficult multi-step infiltration challenges**, including some that no other AI had ever completed.
- On expert **Capture the Flag (CTF)** tasks, Mythos succeeded 73% of the time.

AISI's cautious conclusion: Mythos would excel against "**poorly defended systems,**" but real-world systems have active defenders and defensive tooling that make success much harder. This professional caution is essential when evaluating any new capability.

4.6 The Dual-Use Dilemma

Cybersecurity is the classic dual-use domain. Anthropic references the history of fuzzing tools:

> "When the first software fuzzers were deployed at large scale, there were concerns they might enable attackers to identify vulnerabilities at an increased rate. And they did. But modern fuzzers like AFL are now a critical component of the security ecosystem."

Anthropic expects the same path for Mythos: **initially** it may benefit attackers more, but **eventually**, as the ecosystem reaches a new equilibrium, powerful models will benefit defenders more.

4.7 Chapter Summary

Cybersecurity is Mythos's **center of gravity**. Not because Anthropic trained it specifically for that, but because its general

capabilities reached a level that made it an implicit security expert. This capability—both defensive and offensive—is the primary driver of the restriction decision.

Chapter 5: Project Glasswing — The Defensive Coalition

5.1 What Is Project Glasswing?

Project Glasswing is the framework Anthropic announced alongside Mythos Preview on April 8, 2026. Its stated aim: **to use Mythos to secure the world's most critical software**, and to prepare the industry for the practices required to stay ahead of attackers.

The name is significant: the glasswing butterfly is transparent and transformative. The project mirrors that idea—enormous power framed by transparency and responsibility.

5.2 Coalition Members

The coalition brings together **twelve major companies** from technology and finance, including:

- **Apple**: securing iOS, macOS, and Safari.

- **Google**: securing Android, Chrome, Chrome OS, and Google Cloud.
- **Microsoft**: securing Windows, Edge, and Azure.
- **Amazon**: securing AWS and related cloud services.
- Major financial institutions for banking infrastructure.
- **Claude for Open Source**: extending access to open-source maintainers.

The selection is not arbitrary; these companies represent the **backbone of global digital infrastructure**. A vulnerability in any one of these systems affects hundreds of millions, if not billions, of users.

5.3 Financial Support: $100 Million

Anthropic committed **$100 million in credits** for coalition partners. After those credits, pricing reverts to $25 per million input tokens and $125 per million output tokens—five times Opus 4.7 pricing, reflecting the real compute cost.

5.4 How the Project Operates

Partners use Mythos in two primary ways:

1. **Defensive scanning of their own infrastructure**: feeding their codebases through the model to find vulnerabilities before attackers.
2. **Securing open-source software**: scanning globally used libraries and frameworks, then responsibly disclosing findings.

Anthropic committed to **disclose the nature of currently opaque vulnerabilities within 135 days** of sharing them with responsible organizations. This aligns with standard responsible-disclosure practice.

5.5 Partner Testimonials

In the launch statement, Anthropic included partner testimonials. The language is striking:

> "AI capabilities have crossed a threshold that fundamentally changes the urgency required to protect critical infrastructure from cyber threats, and **there is no going back.**"

> "The window between a vulnerability being discovered and being exploited by an adversary has collapsed—what once took months now happens in minutes with AI. That is not a reason to slow down; it's a reason to move together, **faster.**"

5.6 Chapter Summary

Project Glasswing is not merely a restricted-access program. It is **a new operating model** for releasing frontier capabilities: via closed coalitions with explicit safeguards, rather than open releases. This model may recur in the future with other dual-use capabilities.

Chapter 6: Why Did Anthropic Restrict Mythos?

6.1 An Exceptional Decision in an Opposite Industry

In an industry defined by the rush to ship, Anthropic's decision **not to release** its most capable model was exceptional. The last time a leading AI company did something similar was in 2019, when OpenAI held back GPT-2, citing concerns about the generation of deceptive, biased, or abusive language at scale.

Mythos's case is different. The concern is not textual deception but **the discovery of real vulnerabilities in real systems used by billions of people**. The difference is both quantitative and qualitative.

6.2 The Officially Stated Reasons

1. **Dual-use cybersecurity capabilities**: the model is powerful in discovery and equally usable for attack.

2. **Ecosystem imbalance**: defenders do not currently have equivalent tooling. Releasing publicly would give attackers a temporary advantage.
3. **Need for new safeguards**: Anthropic is developing safeguards for Mythos-class models; they are not ready yet.

6.3 The End Goal: Safe Deployment at Scale

Anthropic has stated explicitly that the restriction is **temporary**. According to their own announcement:

> "We do not plan to make Claude Mythos Preview generally available, but our eventual goal is to enable our users to safely deploy Mythos-class models at scale—for cybersecurity purposes, but also for the myriad other benefits that such highly capable models will bring."

Mythos-class capabilities will reach future Opus models, **after** the safeguards are developed. Some of those safeguards are already visible in Opus 4.7, described as the **"bridge model"** where real-world safety mechanisms are tested before broader rollout.

6.4 The Alternative Reading: Clever Marketing?

Some cybersecurity experts—wary by profession—have questioned whether Anthropic's "concern" about releasing Mythos was **"an elaborate sales pitch."** Three reasons make this question legitimate:

1. Non-availability **increases** attention and reinforces Anthropic's brand as the responsible lab.
2. The model is used through Glasswing, meaning Anthropic earns revenue from the largest technology firms.
3. The news alone caused sharp declines in cybersecurity stocks, affecting market dynamics.

The counter-argument is strong, too: had Mythos been public at Opus pricing, Anthropic would have earned far more. Restriction, if it is marketing, is **expensive marketing.**

6.5 The Precedent Being Set

Anthropic's decision sets a **precedent** other labs may follow. If Project Glasswing produces measurable security outcomes—thousands of patched zero-days, a safer open-source ecosystem—it creates pressure on OpenAI, Google, and others to do the same. OpenAI has already responded with GPT-5.5's "Trusted Access for

Cyber" concept: stricter cyber-risk classifiers for general users and a "cyber-permissive" license for verified defenders.

6.6 Chapter Summary

The decision to restrict Mythos is **multi-dimensional**: technical, commercial, political, and ethical all at once. The open question is whether this becomes a norm or remains an exception.

Chapter 7: Direct Comparison — Mythos vs. the Rest of the Family

7.1 Framework

We compare Mythos to **Opus 4.7** (the available flagship), **Sonnet 4.6** (the most popular), and **Haiku 4.5** (the most economical), along six axes: performance, pricing, context window, speed, use cases, and availability.

7.2 Performance

Benchmark	Haiku 4.5	Sonnet 4.6	Opus 4.7	Mythos
SWE-bench Verified	~50%	79.6%	87.6%	93.9%
SWE-bench Pro	—	~45%	64.3%	77.8%
GPQA Diamond	~70%	~85%	94.2%	94.6%
USAMO 2026	—	~60%	~83%	97.6%
Terminal-Bench 2.0	—	~55%	69.4%	82.0%

The biggest gaps appear in the hardest tasks: Olympiad mathematics, agentic workflows, and cybersecurity. The narrowest gap is on GPQA Diamond, suggesting Opus 4.7 is close to the scientific-reasoning ceiling of current models.

7.3 Pricing

Mythos is **the most expensive** by a wide margin—25× Haiku's input price, reflecting both the compute cost and the intentional restriction of its use.

7.4 Context Window

All modern tiers (Sonnet 4.6, Opus 4.7, Mythos) support a 1M-token context window. Haiku 4.5 is capped at 200K. On GraphWalks BFS—a million-token reasoning benchmark—Mythos scored **80.0%**, roughly four times GPT-5.4's score.

7.5 Speed

1. **Haiku 4.5**: fastest.
2. **Sonnet 4.6**: ~40–60 tokens/s.
3. **Opus 4.7**: ~20–30 tokens/s; thinks more deeply.

4. **Mythos Preview**: slowest; typically run with Terminus-2 harness, maximum effort, and 1M-token budget per task.

7.6 Use Cases

- **Haiku 4.5**: extraction, classification, routing, high-volume low-complexity tasks.
- **Sonnet 4.6**: daily coding, reports, data analysis, interactive chat. **90% of professional daily work.**
- **Opus 4.7**: complex coding, large codebase analysis, architecture, deep multi-step reasoning.
- **Mythos Preview**: security vulnerability discovery, hypothetical exploit construction for defense, massive codebase analysis.

7.7 Availability

- **Haiku 4.5 / Sonnet 4.6 / Opus 4.7**: available via API (`claude-opus-4-7`), Bedrock, Vertex AI, Microsoft Foundry, and Claude.ai.
- **Mythos Preview**: **invitation only**. No self-serve signup.

7.8 When to Use What

1. **Start with Sonnet 4.6**; it handles 90%+ of tasks at reasonable cost.
2. **Use Haiku 4.5** for high-volume light tasks or as a first-pass router.
3. **Move to Opus 4.7** when Sonnet fails to solve a complex problem.
4. **Wait for Mythos...** because it will not be available to you.

7.9 Chapter Summary

Mythos is not a replacement for Opus, Sonnet, or Haiku; it is **a different class** for a different purpose. In the Claude family, each model serves a purpose; Mythos serves an exceptional purpose that does not pass through the general market.

Chapter 8: Safety and Alignment in Mythos

8.1 Why Safety Matters More in Mythos

Every powerful model needs safety guarantees, but Mythos needs them exceptionally. Its high cybersecurity capability means any "misalignment" could lead to real consequences, not merely inaccurate text. Anthropic has described Mythos as **"the best-aligned model we have trained."**

8.2 Constitutional AI

Like the rest of the Claude family, Mythos is trained with **Constitutional AI**—Anthropic's framework for training on a set of ethical principles without requiring constant human intervention. It combines a set of core principles with RLHF (Reinforcement Learning from Human Feedback) and RLAIF (Reinforcement Learning from AI Feedback). Mythos adds deeper cybersecurity-specific evaluation layers.

8.3 The System Card — 244 Pages

Anthropic published a **244-page System Card**—a technical document covering:

- CBRN (chemical, biological, radiological, nuclear) capability tests.
- Agentic capabilities.
- Persuasion and bias testing.
- Detailed cybersecurity risks.
- Internal and external red-team attempts.
- Safeguards applied in each case.

8.4 Memorization — An Honest Admission

In one of the announcement's most candid passages, Anthropic admitted:

> "Mythos still performs well on HLE at low effort, which could indicate some level of memorization."

This acknowledgment matters because it shows methodological maturity: the company does not claim perfection; it signals caution zones in its own numbers.

8.5 Red Teams

Mythos was tested by internal teams, AISI, CISA and CAISI, and Glasswing partners including Microsoft and Apple.

8.6 The Bridge Model Principle

Anthropic has stated that Opus 4.7 is the **"bridge model"** in which real-world safety mechanisms are tested before broader rollout of Mythos-class models. This staged approach is important: each new safeguard is tested in a mid-capability model before reaching the frontier.

8.7 Chapter Summary

Safety in Mythos is not an afterthought; it is **central to the design**. The investment in a 244-page System Card, the bridge-model philosophy, and the honest memorization acknowledgment all indicate methodological maturity in handling a Mythos-class model.

Chapter 9: Industry Impact and Competitive Response

9.1 A "GPT-4 Moment" for 2026

When GPT-4 launched in March 2023, it rocked the industry. Mythos represents a **similar moment in April 2026**. The difference: GPT-4 was available; Mythos is not. Competitors see Mythos's benchmark numbers but cannot observe its actual behavior, creating a "**race against a ghost.**"

9.2 OpenAI's Response: GPT-5.5 and Trusted Access for Cyber

OpenAI responded quickly. About a week after Opus 4.7, OpenAI released **GPT-5.5**, described as a "**fundamental redesign of how intelligence interacts with a computer's operating system and professional software stacks.**"

GPT-5.5 surpassed all publicly available models, including Opus 4.7, on most benchmarks—and most notably **outperformed**

Mythos on Terminal-Bench 2.0 (narrowly; a statistical tie). OpenAI also adopted a Glasswing-like approach called **"Trusted Access for Cyber,"** with stricter classifiers for general users and a "cyber-permissive" license for verified defenders. Under OpenAI's Preparedness Framework, GPT-5.5 is classified as **"High" risk** for both biological and cybersecurity capabilities.

9.3 Google's Response: Gemini 3.1 Pro

Gemini 3.1 Pro was Google's most recent frontier model before Mythos. Its GPQA Diamond score (94.3%) rivals Mythos, but its SWE-bench Verified score (80.6%) reveals a relative weakness in agentic coding. A larger response from Google is expected in upcoming Gemini 4 releases.

9.4 Open-Source Pressure: GLM-5

Chinese open-source models such as **GLM-5** from Z.ai have been closing the gap with closed U.S. models on SWE-bench Verified. If open-source reaches the frontier, the effectiveness of restrictions like Glasswing may diminish.

9.5 Financial Markets

When Mythos first leaked, cybersecurity stocks **dropped sharply**. The likely answer is that security companies will shift from "**manual discovery vendors**" to "**automated defense orchestrators.**" Whoever integrates Mythos-class models into defensive workflows fastest will win.

9.6 Impact on Developers

For individual developers, the gap between 80.8% and 93.9% on SWE-bench Verified **rarely matters in daily work**. The public models are already excellent for the vast majority of coding tasks—but they now have a known ceiling much higher than what they offer.

9.7 Impact on Policy

Governments may accelerate pre-release evaluation requirements, export controls, mandatory transparency, and mandated responsible disclosure timelines for AI-discovered vulnerabilities.

9.8 Chapter Summary

Mythos is not just a new model; it is **a formative moment for the industry**. Responses from OpenAI and Google, market shifts, regulatory pressure, and developer workflow changes all indicate that Mythos's impact extends well beyond the bounds of Project Glasswing.

Chapter 10: The Future of Mythos-Class Models

10.1 Will Mythos Ever Open to the Public?

By Anthropic's own answer: **not in this form**. But Mythos-class capabilities will reach future Opus models with new safeguards. Practical forecast: within 12–18 months, we will see **Opus 5 or 5.1** with Mythos-like capabilities, equipped with risk classification for cyber requests, a verification program for professionals, monitored logs for high-risk patterns, and clear limits on explicit exploitation scenarios.

10.2 What Comes After Mythos?

- **Post-Mythos models**: from Anthropic or competitors, with capabilities exceeding Mythos.
- **Vertical specialization**: domain-specific models (medicine, law, scientific research).

- **Extended autonomy**: models operating over days or weeks on single tasks.
- **Multi-modal expansion**: deeper integration of audio, video, and sensory data.

10.3 The Collapse of Discovery-to-Exploit Windows

A Glasswing partner summarized the most important impact: **"The window between a vulnerability being discovered and being exploited by an adversary has collapsed—what once took months now happens in minutes."** Traditional defense depends on a "response window." If it collapses, defensive systems must become **fully proactive**: continuous scanning, automatic patching, rapid isolation. AI is no longer optional in this future—it is **a condition of survival.**

10.4 The Ethical Dilemma: Who Decides Who Gets Access?

The Glasswing model raises a fundamental question: **who decides which institutions receive withheld capabilities?** Today, Anthropic. Tomorrow, governments. Eventually, perhaps

international bodies resembling those that regulate nuclear weapons. This deserves deep discussion—especially in the Arab and Muslim world, where AI governance debate is still in its infancy.

10.5 What This Means for the Arab World

No Arab country has a lab at the Mythos frontier, yet regional digital infrastructure needs protection from the capabilities Mythos represents. Practical recommendations for decision-makers:

1. Invest in human capital: train cybersecurity engineers who can use AI defensively.
2. Integrate with available models (Opus 4.7, GPT-5.5, Gemini 3.1 Pro) to scan national infrastructure.
3. Develop local capabilities through Arabic open-source models for sovereign applications.
4. Participate in international governance conversations.

10.6 A Message to Arab AI Researchers

The technical gap is large, but not permanent. Arab researchers are doing notable work in international venues. What is missing is

sustained infrastructure investment. Mythos reminds us of the gap—but history teaches that gaps are bridgeable when will and resources align.

10.7 Chapter Summary

The future of Mythos-class models includes: capability reaching public models, stronger models within a few years, a full transformation of the cybersecurity industry, unresolved governance questions, and opportunities for states that position themselves well.

Conclusion

We have traced a journey from the March 2026 leak to the official April announcement, through the benchmark details, cybersecurity capabilities, Project Glasswing, the containment philosophy, detailed comparisons with Opus 4.7, Sonnet 4.6, and Haiku 4.5, and into governance and future questions.

Five core takeaways:

First: Mythos is not merely a gradual upgrade. It is **a new class of model** that transcends everything Anthropic has shipped before. With 93.9% on SWE-bench Verified, 97.6% on USAMO, and 100% on Cybench, Mythos redefines what "frontier" means.

Second: The difference from the rest of the Claude family is not just a matter of degree, but of **kind**. Haiku for efficiency, Sonnet for balance, Opus for general frontier, and Mythos for "**what is not released.**" A new hierarchy in an industry that measured itself by immediate availability.

Third: The decision to restrict—whether a responsible precaution or clever marketing—sets an **important precedent**. The closed-

coalition model may become the operational template for dual-use capabilities.

Fourth: Cybersecurity has entered a new era. **"The window between discovery and exploitation has collapsed."** Whoever integrates advanced defensive models fastest wins. The Arab world faces both an opportunity and a responsibility.

Fifth: Mythos-class capabilities will reach public models within months—likely in Opus 5—but with more developed safeguards. We are living through a transitional moment that will shape the AI industry for years to come.

From an Islamic perspective, Mythos reminds us of two enduring principles: **"Every capability is a trust"** and **"Averting harm takes precedence over acquiring benefit."** Anthropic's restriction decision aligns with an authentic Islamic principle, even if not phrased in those words.

Ultimately, the story is not about a single model but about **the future we choose**. Mythos-class models will come, one after another. The question is not "can we build them?" but "how will we handle them?" That ethical question is always the most important one—from gunpowder to nuclear energy to artificial intelligence.

And success is only with God. And God knows best.

Dr. Fadhl Mohammed Alakwaa

Michigan, April 2026

About the Author

Dr. Fadhl Mohammed Alakwaa is a researcher in computational biology, bioinformatics, and spatial genomics at the University of Michigan Medical School in the United States. He works at the intersection of artificial intelligence and biomedicine, with an active interest in applying machine learning and large language models to medical research and the life sciences.

He has published peer-reviewed research in leading international journals, including a 2023 study on the effects of SGLT2 inhibitors on kidney tissue in the *Journal of Clinical Investigation* (*JCI*), and a 2026 study on the effects of vertical sleeve gastrectomy (VSG) as part of the IMPROVE-T2D project using single-cell RNA sequencing (scRNA-seq).

Alongside his research, Dr. Alakwaa is a prolific author writing in both Arabic and English. His books span Islamic studies and the scientific miracles of the Quran, artificial intelligence and large language models, Yemeni history and geopolitics, and practical guides for immigrants and students abroad. He also hosts a monthly intellectual salon called **Dīwān al-Aṣdiqā' (The Friends'**

Circle), a private gathering of seven thinkers who meet to discuss the themes of his books and contemporary intellectual questions.

Dr. Alakwaa writes in a style that combines scientific precision with Islamic context, seeking to present complex technical knowledge in language accessible to the Arab Muslim reader, and to connect the discoveries of modern science to the framework of faith and ethics.

Other Books by the Author

The following books were also published by the author in 2026, in Arabic and English:

1. The End of the Universe in the Holy Quran
2. Has Yemeni Unity Ended?
3. The Secret of American–Israeli Convergence: Who Leads Whom?
4. Knowledge Is Light, Ignorance Is Darkness
5. Yemeni Presidents in the WikiLeaks Memos
6. Religiosity Across Generations in the West
7. Classifying the Verses of the Holy Quran — A Reflective Study in Thematic Structure
8. The Signs of the Hour Between Text and Science
9. Yemen's Problems Across the Ages
10. The Art of Parenting — How to Raise Leaders
11. The Impact of Large Language Models on Scientific Research and University Education

12. How Large Language Models Work — A Simplified Guide
13. Artificial Intelligence and Its Most Prominent Tools Since 2025
14. Claude Code — The Comprehensive Guide
15. Cryptocurrencies — A Comprehensive Beginner's Guide
16. Retirement Planning
17. Silicon Valley — A Global History of Innovation and Entrepreneurship
18. A Guide to Buying and Selling Used Cars in America
19. Most Famous National Parks in America
20. The Secret of the Strength of American Universities
21. A Guide for the New Yemeni Immigrant to America
22. America — The Rise of the Empire and the Signs of Decline
23. Artificial Intelligence in Medicine
24. Scientific Miracles in the Quran — A Genomics Researcher's Perspective
25. The Islamic Caliphate: From the Saqifa to the Fall of Granada
26. The Houthis and Gaza: Trading Blood for Power
27. The Future of Bioinformatics and Computational Biology
28. Marital Rights and Family Life for Muslims in the West

29. Salafism — A Study in Concept, Emergence, and Contemporary Currents

30. My Grandmother Ateeqa — The Woman Who Was Like the Mountains

31. Food and Healing — Between Science and the Prophetic Sunna

32. Successful Marriage — A Practical Guide from an Islamic Perspective

33. How to Succeed Academically in American Universities

34. Legitimate Criticism and the Boundaries of Antisemitism

35. My Sister Wafaa — The Letters of Love We Did Not Say

36. A Guide for the New Refugee to Ottawa

في ربيع عام 2026، تسرّب إلى شبكة الإنترنت
ذكرٌ لنموذجٍ لم تعلن عنه شركة أنثروبيك بعد.
اسمه الرمزي: كابيبارا. اسمه العلني لاحقاً:
كلود مايثوس. نموذجٌ وُصف بأنه أكبر وأذكى من
عائلة أوبوس، ومُنح لثلاث عشرة شركةً من كبار
شركات التقنية في العالم ضمن مشروع دفاعي سرّي
سُمّي «مشروع الزجاج الجناح». لماذا احتفظت
أنثروبيك بهذا النموذج لنفسها؟ ما الذي يجعله
مختلفاً عن هايكو وسونيت وأوبوس؟ وماذا تخبرنا
قدراته عن الاتجاه الذي تسير فيه نماذج الذكاء
الاصطناعي الكبرى؟

In the spring of 2026, a reference leaked to an Anthropic model no one had heard of. Codename: Capybara. Public name: Claude Mythos. A model described as larger and more intelligent than the Opus family, granted to thirteen of the world's largest technology companies under a confidential defensive program called Project Glasswing. Why did Anthropic hold this model back from the public? What sets it apart from Haiku, Sonnet, and Opus? And what do its capabilities tell us about where the frontier of AI is headed?

د. فضل محمد الأكوع
Dr. Fadhl Mohammed Alakwaa

2026