

علم الوراثة الإحصائية: الموسوعة العملية

25 فصلا من المسائل والحلول بـ SAIGE و REGENIE و PLINK2 و R على بيانات حقيقية

Statistical Genetics: The Complete Practical Encyclopedia

د. فضل محمد الأكوع

Dr. Fadhl Mohammed Alakwaa

2026

عربي · English

علم الوراثة الإحصائية: الموسوعة العملية

*Statistical Genetics: The Complete Practical
Encyclopedia*

25 فصلا من المسائل والحلول بـ SAIGE و REGENIE
و PLINK2 و R على بيانات حقيقية

د. فضل محمد الأكوع

Dr. Fadhl Mohammed Alakwaa

الطبعة الأولى — 2026 · First Edition

جميع الحقوق محفوظة للمؤلف

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

إهداء

إلى كل باحث عربي جلس أمام شاشته في الساعة الثانية صباحا يحاول أن يفهم لماذا فشل *SAIGE* أو لماذا يختلف مانهاته عن الورقة البحثية أو لماذا لا يقبل ملفه في خادم الاستيفاء. هذا الكتاب كتب من تلك اللحظات لأجلك.

تنبیه

هذا الكتاب أُنتج بمساعدة نموذج Claude Opus 4.7 من شركة Anthropic، تحت إشراف وتوجيه المؤلف. التوجيه الفكري واختيار الموضوع والمراجعة والمسؤولية النهائية للمؤلف الدكتور فضل محمد الأكوع. الكتاب لأغراض تثقيفية وإثرائية، ولا يُعني عن استشارة المتخصصين في الموضوعات القانونية والطبية والمالية والشرعية.

Notice

This book was produced with the assistance of Anthropic's Claude Opus 4.7 model, under the author's direction and supervision. Intellectual direction, topic selection, review, and final responsibility rest with the author, Dr. Fadhl Mohammed Alakwaa. The book is for educational purposes and does not substitute for consultation with specialists in legal, medical, financial, or religious matters.

المحتويات

- 1 Complete Environment Setup / إعداد البيئة الكاملة / الفصل الأول
 - 2 Genetic Data File / تنسيقات ملفات البيانات الجينية / الفصل الثاني
Formats
 - 3 Variant Quality Control / مراقبة جودة المتغيرات / الفصل الثالث
 - 4 Sample Quality Control / مراقبة جودة العينات / الفصل الرابع
 - 5 Advanced PCA / تحليل المكونات الرئيسية المتقدم / الفصل الخامس
Analysis
 - 6 Genotype Imputation / استيفاء البيانات الجينية / الفصل السادس
 - 7 PLINK2 / Basic / الفصل السابع — اختبارات الارتباط الأساسية بـ
Association Testing with PLINK2
-

- 8 الفصل الثامن — REGENIE: نموذج الانحدار على مستوى الجينوم /
REGENIE: Whole Genome Regression
-
- 9 الفصل التاسع — SAIGE: النماذج المختلطة للبيانات غير المتوازنة / SAIGE:
Mixed Models for Imbalanced Data
-
- 10 الفصل العاشر — تصحيح الاختبارات المتعددة والقوة الإحصائية /
Multiple Testing and Power
-
- 11 الفصل الحادي عشر — تحليل عدم التوازن الترابطي والهابلوتايب / Linkage
Disequilibrium and Haplotype Analysis
-
- 12 الفصل الثاني عشر — التحليل الدقيق للموضع الجيني / Fine-Mapping a
GWAS Locus
-
- 13 الفصل الثالث عشر — تحليل eQTL والتعبير الجيني / eQTL Analysis
and Gene Expression
-
- 14 الفصل الرابع عشر — الوراثة ومعامل الارتباط الجيني بـ GCTA
LDSC / Heritability and Genetic Correlation
-
- 15 الفصل الخامس عشر — درجات الخطر متعدد الجينات: طرق متقدمة /
Polygenic Risk Scores: Advanced Methods
-

16	Rare Variant / تحليل المتغيرات النادرة	الفصل السادس عشر –
	Analysis	
17	Multi-Ancestry / التحليل متعدد السكان	الفصل السابع عشر –
	Analysis	
18	Simulation and / المحاكاة والإطار الإحصائي	الفصل الثامن عشر –
	Statistical Framework	
19	Meta-Analysis / ميتا-أناليسيس	الفصل التاسع عشر –
20	Gene-Environment / التفاعل الجيني والبيئي	الفصل العشرون –
	Interaction	
21	Mendelian / العشوائية المندلية: طرق متقدمة	الفصل الحادي والعشرون –
	Randomization: Advanced Methods	
22	/ تحليل البقاء الجينومي والوقت حتى الحدث	الفصل الثاني والعشرون –
	Survival GWAS and Time-to-Event Analysis	
23	/ الجينات الدوائية	الفصل الثالث والعشرون –
	Pharmacogenomics and Drug Target Genetics	
24	Validation / التحقق من الصحة وإعادة الإنتاج	الفصل الرابع والعشرون –
	and Reproducibility	

25 الفصل الخامس والعشرون — المشروع النهائي: ورقة بحثية كاملة / Final

Project: A Complete GWAS Paper

26 الفصل السادس والعشرون — المراجع الموحدة والموارد / Consolidated

References and Resources

الفصل الأول — إعداد البيئة الكاملة / Complete Environment Setup

﴿اقْرَأْ بِاسْمِ رَبِّكَ الَّذِي خَلَقَ﴾

— سورة العلق: ١

أول أمرٍ في الوحي كان "اقرأ"؛ والقراءةُ تحتاجُ أداةً وبيئةً وإعداداً. كذلك أولُ خطوةٍ في رحلة الوراثة الإحصائية هي بناءُ البيئة التي بها نقرأ الجينوم: نثبِتُ الأدوات والتحقّقُ منها قبل أن نقرأ حرفاً واحداً من البيانات.

📖 سيناريو بحثي

يومك الأول في مختبر الجينوم. أعطاك مدير المختبر حساباً على الحاسوب العنقوديّ عالي الأداء (HPC)، وقال: "قبل أن تحلّل أيّ بيانات، أريد بيئةً تعمل: PLINK2 و REGENIE و SAIGE و GCTA و LDSC وكلّ حزم R. وأريد سكرتيراً واحداً يتحقّق أنّ كلّ شيءٍ مثبتٌ ويعمل." تبدو المهمةُ بسيطةً، لكنّها في الواقع أكثرُ ما يُعطّل الباحثين الجدد: تعارضُ الإصدارات، ومسارات المكتبات، وبيئاتُ conda المتضاربة. هذا الفصل يجعلك تتجاوز هذه العقبة مرّةً واحدةً وإلى الأبد.

سنبني بيئةً معزولةً نظيفة، نثبت فيها كلَّ أداة، ونتحقق من كلِّ واحدةٍ ببياناتٍ تجريبيةٍ صغيرة، ثم نكتب سكربتَ تحقّقٍ شاملاً يعطي تقريرَ "نجاح/فشل" لكلِّ أداة. حين تنتمي، ستملك أساساً صلباً تبني عليه بقية الكتاب.

مجموعة البيانات لهذا الفصل

نستخدم بيانات HapMap3 التجريبية الصغيرة المرفقة مع دروس PLINK:

```
bin/plink/hapmap3_r3_b36_fwd.consensus.qc.poly.bed  
# الملفات: bed. (الأنماط الجينية الثنائية)، bim. (مع  
# الحجم: نحو ١,١١٥ فرداً و ١,٤ مليون متغيّر
```

كما نستخدم كروموسوم ٢٢ من مشروع الجينومات الألف للاختبارات الأثقل:

```
k/vol11/ftp/release/20130502/ALL.chr22.phase3.vcf.gz
```

أهداف التعلم

بعد هذا الفصل تستطيع أن: (١) تثبت PLINK2 وتحقق منه؛ (٢) تشغل الخطوة الأولى من REGENIE وتفسر مخرجاتها؛ (٣) تثبت SAIGE عبر conda؛ (٤) تحسب مصفوفة العلاقات الجينية بـ GCTA؛ (٥) تعدّ بيئة R بكاملها؛ (٦) تكتب سكربتَ تحقّقٍ آلياً شاملاً.

الخلفية الأساسية

كلُّ أدوات الوراثة الإحصائية تشارك منطقاً واحداً: قراءة مصفوفة الأنماط الجينية (أفراد $\times$ متغيرات)، ثم إجراء عمليات خطية عليها. الصيغة المركزية التي تجمعها جميعاً هي نموذج الانحدار الخطي المعمم:

$$g(E[y]) = X\beta + G\gamma$$

حيث y الصفة، و X المتغيرات المشتركة (العمر، الجنس، المكونات الرئيسية)، و G النمط الجيني، و g دالة الربط (هوية للصفات المتصلة، ولوجستية للشائبة).

تشبيه: إعداد بيئة الحوسبة لإعداد مطبخ احترافي قبل الطبخ. لا يبدأ الطاهي بالطبخ ثم يبحث عن السكين؛ يرتب أدواته أولاً، يشحذها، يتحقق منها، فإذا جاء وقت الطبخ كان كل شيء في مكانه. السكرتير الذي نكتبه في المسألة ٦ هو "قائمة تجهيز المطبخ" التي تشغلها مرة فتطمئن.

المسائل

المسألة ١.١ ★ [مبتدئ]

ثبت PLINK2 وتحقق منه باستخدام بيانات HapMap3. شغل أمراً يقرأ الملفات ويخرج عدد العينات وعدد المتغيرات. ما الذي يُخبرك أن التثبيت نجح؟

تلميح: الأمر `freq--` أو مجرد قراءة الملف بـ `validate--` يكفي للتحقق.

الحلّ ١٠.١ ✓

```
# التنزيل والتثبيت
com/plink2-assets/plink2_linux_x86_64_20240105.zip
unzip plink2_linux_x86_64_20240105.zip
chmod +x plink2
plink2 --version/.
```

```
# التحقق ببيانات HapMap3
plink2 --bfile hapmap3_r3_b36_fwd.consensus.qc.poly/.
\ freq--
out hapmap_check--
```

المخرجات المتوقّعة (تمثيلية):

```
PLINK v2.00a5.10 64-bit (5 Jan 2024)
ples (562 females, 553 males) loaded from .fam 1115
.variants loaded from .bim 1457897
```

.Calculating allele frequencies... done
Allele frequencies written to hapmap_check.afreq--

التفسير: ظهور عدد العينات (١٠١١٥) وعدد المتغيرات (١٠٤٥٧٠٨٩٧) دليل قاطع على أنّ PLINK2 يقرأ الملفات الثنائية بنجاح. ملفُ afreq الناتج يحتوي تواتر كلّ أليل – وهو أولُ ناتجٍ حقيقيّ ستراه. لو فشل التثبيت لظهرت رسالة "command not found" أو خطأً في قراءة الملف.

ماذا لو؟ لو كانت بياناتك بصيغة VCF بدلاً من BED، تستبدل --bfile بـ --vcf ويبقى الباقي كما هو.

المسألة ١٠٢ ★ [مبتدئ]

تبت REGENIE، وشغل الخطوة الأولى على بياناتٍ تجريبية، وفّر ملفاتِ المخرجات. ما معنى ملفِ pred.list؟

تلميح: الخطوة الأولى تبني تنبؤاتٍ متعددة الجينات بطريقة "ترك كروموسوم واحد" (LOCO).

الحلّ ١٠٢ ✓

releases/download/v3.4/regenie_v3.4_linux_x86_64.zip
unzip regenie_v3.4_linux_x86_64.zip


```

chmod +x regenie_v3.4_linux_x86_64

\ regenie_v3.4_linux_x86_64/.
\ step 1--
\ bed hapmap3_r3_b36_fwd.consensus.qc.poly--
\ phenoFile phenotypes.txt--
\ bsize 1000--
\ bt--
out fit_step1--

```

المخرجات المتوقعة (تمثيلية):

```

|=====|
|          REGENIE v3.4.gha          |
|=====|

```

Number of individuals retained: 1115

Number of variants used: 145320 (after QC)

Fitting null model... done in 42.3s

Output files: fit_step1_pred.list, fit_step1_1.loco

التفسير: ملفُ pred.list هو فهرسٌ يربط كلَّ صفةٍ بملفِّ
 تنبؤاتها .loco. تنبؤاتُ LOCO هي جوهرُ REGENIE: لكلِّ كروموسوم،

يُحسب تنبؤ متعدد الجينات مبنيٌّ على بقية الكروموسومات، لتفادي "الازدواج" (proximal contamination) الذي يُفقد القوة الإحصائية. ستُغذي هذا الملف إلى الخطوة الثانية.

المسألة ١٠٣ ★ [مبتدئ]

تُثبت SAIGE عبر conda وتحقق منه بالمثال المدمج.

الحل ١٠٣ ✓

```
conda create -n saige_env -c conda-forge -c bioconda r-saige
conda activate saige_env
# التحقق
conda install -e 'library(SAIGE); print(packageVersion("SAIGE"))'
```

المخرجات المتوقعة:

```
'1.3.0' [1]
```

التفسير: ظهور رقم الإصدار دون أخطاءٍ في تحميل المكتبة يعني أنّ SAIGE وكلّ اعتماداته (RcppArmadillo, SPAtest, ...) تُثبتت سليمة. SAIGE معروفٌ بصعوبة تثبيتته بسبب اعتماده على مكتبات ++C مترجمة؛ ولهذا يُفضل كثيرٌ من الباحثين صورة Docker الرسمية بدلاً من conda.

المسألة ١٠٤ ★★ [متوسط]

تُبَتَّ GCTA واحسب مصفوفة العلاقات الجينية (GRM) على كروموسوم ٢٢ من الجينومات الألف.

الحلّ ١٠٤ ✓

```
ware/gcta/bin/gcta-1.94.1-linux-kernel-3-x86_64.zip
unzip gcta-1.94.1-linux-kernel-3-x86_64.zip
chr22_1kg --make-grm --out chr22_grm --thread-num 8/.
```

المخرجات المتوقعة (تمثيلية):

```
.. Computing the genetic relationship matrix (GRM)
.individuals are in common in these files 2504
.SNPs are included in the analysis 145112
2504 individuals has been saved: chr22_grm.grm.bin
Mean of diagonal GRM elements: 1.001
```

التفسير: مصفوفة GRM تقيس درجة القرابة الجينية بين كل زوج من الأفراد. متوسط القطر القريب من ١.٠٠ علامة سلامة (كل فرد مرتبط بنفسه بقيمة ≈ 1). القيم خارج القطر المرتفعة جداً تكشف أقارب – وهذا أساس كل النماذج المختلطة لاحقاً.

المسألة ١٠٥ ★★ [متوسط]

أعدّ بيئة R، وثبّت كلّ الحِزم، وشغل سكربتَ تحقّقٍ من الإصدارات.

✓ الحلّ ١٠٥

```
'data.table', 'ggplot2', 'dplyr', 'qqman', 'TwoSampleMR'
'coloc', 'susieR', 'SNPRelate', 'GWASTools'
    } for (p in pkgs)
  if (!requireNamespace(p, quietly = TRUE))
    install.packages(p)
5s : %s\n", p, as.character(packageVersion(p)))
{
```

المخرجات المتوقّعة (تمثيلية):

```
data.table      : 1.15.0
ggplot2         : 3.4.4
TwoSampleMR     : 0.5.7
coloc           : 5.2.3
susieR          : 0.12.35
```

التفسير: طباعة كل حزمة مع إصدارها دليل على نجاح التثبيت. توثيق الإصدارات مهم لإعادة الإنتاج (الفصل ٢٤): ورقتك البحثية يجب أن تذكر إصدارات الأدوات بدقة.

المسألة ١.٦ ★★★ [متقدم]

اكتب سكريبتاً رئيسياً `setup_check.sh` يثبت ويتحقق من كل الأدوات، ويخرج تقرير نجاح/فشل.

الحل ١.٦ ✓

```
bin/bash/!#

report() { printf "%-12s : %s\n" "$1" "$2"; }

& report "$1" "PASS ✓" || report "$1" "FAIL ✗"; }

=== تقرير التحقق من بيئة الوراثة الإحصائية ===
check ./plink2
check ./regenie_v3.4_linux_x86_64
check ./gcta-1.94.1

t -e 'q <- c("SAIGE","data.table","coloc","susier")
,for (p in q) cat(sprintf("%-12s : %s\n", p
ireNamespace(p,quietly=TRUE),"PASS ✓","FAIL ✗")
```

المخرجات المتوقعة:

=== تقرير التحقق من بيئة الوراثة الإحصائية ===

✓ plink2 : PASS/.

✓ gcta-1.94.1 : PASS

✓ SAIGE : PASS

✓ coloc : PASS

التفسير: هذا السكريبتُ هو "قائمةُ تجهيز المطبخ" الكاملة. تشغله مرّةً واحدةً في كلّ بيئةٍ جديدة، فيخبرك بدقّةٍ أيّ أداةٍ ناقصة قبل أن تبدأ تحليلًا يستغرق ساعات ثمّ يفشل في منتصفه.

⚠ الأخطاء الشائعة وتصحيحها

plink2: command not found - نسيّت +x chmod أو لم
تضف المسار؛ استخدم plink2/. أو أضفه إلى PATH\$
error.
while loading shared libraries
libgomp.so.1 - مكتبةُ OpenMP ناقصة؛
conda install
REGENIE: phenotype file has fewer libgomp
samples - ترتيبُ الأعمدة أو رؤوسها خاطئة؛ يجب أن تكون FID
IID أوّل عمودين. SAIGE installation fails.
compiling RcppArmadillo - إصدارُ مترجم ++C قديم؛

استخدم Docker. GCTA segmentation fault - ملف BED
تالف أو ذاكرة غير كافية؛ تحقق بـ `validate--` وزد الذاكرة. cannot
allocate vector of size R في - الذاكرة نفدت؛ اقرأ
البيانات على دفعات بـ `data.table::fread`.

📖 الغوص العميق

في مختبرنا بجامعة ميشيغان، نُدير عشرات المشاريع المتوازية على حاسوبٍ
عنقوديٍّ مشتركٍ، ولكلِّ مشروعٍ بيئةٌ conda مستقلة. تعلّمتُ بالطريق الصعب أنَّ
خلطَ الأدوات في بيئةٍ واحدةٍ كارثة: مشروعُ الكلى يحتاج إصداراً من R،
ومشروعُ الخلية المفردة يحتاج آخر، فيتعارضان. الحلُّ الذي اعتمدناه: بيئةٌ
conda معزولة لكلِّ مشروعٍ، مع ملفِّ `environment.yml` محفوظٍ في
مستودعٍ git، بحيثٍ يستطيع أيُّ زميلٍ إعادة بناء البيئة بأمرٍ واحد. هذا
الانضباطُ في الإعداد وفّر علينا أسابيعٍ من تتبّع الأخطاء، وجعل نتائجنا قابلةً
لإعادة الإنتاج حين يراجعها المحكّمون. النظامُ على HPC يُحمّل عبر module
load، لكنَّ الإصدارات المتاحة محدودة، فبنيتُ أدواتنا الحرجة محلياً في مجلّد
المشروع.

🔧 تحدِّ مفتوح

اكتب سكريبتاً يبيّن صورة Docker واحدة تحتوي كلَّ الأدوات الستّ
بإصداراتها المثبتة، بحيثٍ يستطيع باحثٌ في أيِّ مكانٍ تشغيلَ كامل خطِّ أنابيب

الكتاب بأمرٍ واحد `docker run`. تحقّق من أنّ حجم الصورة أقلّ من ٥ غيغابايت، ووثّق كلّ إصدار.

مراجع أساسية

- "Chang C.C. et al. (2015). "Second-generation PLINK
.PLINK2. Mbatchou J. et al. (2021) الورقة المرجعية لـ *GigaScience*
Computationally efficient whole-genome regression"
Zhou W. et al. (2018). "Efficiently *Nature Genetics*".(REGENIE)
Nature ".controlling for case-control imbalance (SAIGE)
Yang J. et al. (2011). "GCTA: A Tool for Genome-wide *Genetics*
.AJHG ".Complex Trait Analysis

الفصل الثاني — تنسيقات ملفات البيانات الجينية /

Genetic Data File Formats

﴿وَعَلَّمَ الْبَيَانَ﴾

— سورة الرحمن: ٤

عَلَّمَ اللَّهُ الْإِنْسَانَ الْبَيَانَ، أي القدرة على التعبير والترميز. وملفات البيانات الجينية ليست إلا "بيانات" مرمّزاً للجينوم؛ من يُتقن قراءة ترميزها يُتقن قراءة الحياة المكتوبة فيها.

📖 سيناريو بحثي

وصلتك بيانات من ثلاثة متعاونين: الأول أرسل ملف VCF، والثاني ملفات PLINK BED، والثالث ملف BGEN من بياناتٍ مستوفاة. كلُّ منهم استخدم شريحةً مختلفة، وبعضهم رمّز الأليلات على الخيط الموجب وآخر على السالب. مهمتك: توحيد كلِّ هذا في صيغة واحدة نظيفة، مع التحقق من سلامة كلِّ ملف. تبدو مهمة إدارية مملة، لكن ٩٠٪ من أخطاء GWAS الكارثية تبدأ هنا: أليلٌ مقلوب، أو عينة غير متطابقة، أو ملفٌ مبتور.

البيانات الجينية تُخزّن بصيغٍ متعدّدة لأسبابٍ تاريخيةٍ وتقنيةٍ: VCF للمرونة والقراءة البشرية، BED للكفاءة، BGEN للبيانات المستوفاة الاحتمالية. فهم متى وكيف نحول بينها هو مهارةٌ أساسية لا يستغني عنها أيُّ باحث.

مجموعة البيانات لهذا الفصل

VCF من الجينومات الألف
k/vol1/ftp/release/20130502/ALL.chr22.phase3.vcf.gz
BED من HapMap3 (من الفصل السابق)
BGEN تجريبي من توثيق REGENIE
n/rgcgithub/regenie/raw/master/example/example.bgen

أهداف التعلّم

بعد هذا الفصل تستطيع أن: (١) تقرأ VCF في R وتفكّك مكوناته؛ (٢) تحوّل VCF إلى BED؛ (٣) تفهم ترميز BIM/FAM/BED على مستوى البايث؛ (٤) تحوّل BGEN إلى PGEN؛ (٥) تدبج مجموعاتٍ من شرائحٍ مختلفة مع معالجة قلب الخيط؛ (٦) تكتب دالةً تقرأ نحسّ صيغ؛ (٧) تتحقّق من سلامة الملفات.

الخلفية الأساسية

ملف VCF نصيٍّ مقسّم إلى رأسٍ (أسطر تبدأ ب ##) وجدولٍ، كلُّ صفٍّ متغيّرٌ وكلُّ عمودٍ بعد التاسع عينة. أما BED فنثائيٌّ مضغوط: كلُّ نمطٍ جينيٍّ يرمز في بيتين فقط (٢ بت)، فأربعة أنماطٍ في بايتٍ واحد. الصيغة:

$$\text{times} \setminus \{ \{ \text{عينات} \} \text{text} \} _ \text{approx} \setminus \frac{N \setminus \{ \text{BED} \} \text{text} \} {N \setminus \{ \text{متغيّرات} \} \text{text} \} \setminus \{ \text{بايت} \} \setminus \{ 4 \} \}$$

تشبيه: الصيغ المختلفة للغات المختلفة لكّابة الرقم نفسه: VCF كالأرقام المكتوبة بالحروف ("ثلاثة وعشرون") — مقروءة لكن مُسببة؛ BED كالأرقام الرومانية المضغوطة — كفؤة لكن تحتاج خبرة لقراءتها؛ BGEN كصيغةٍ علميةٍ تحمل عدم اليقين (٢٣ ± ٠,١). التحويل بينها كالترجمة: يجب أن تحفظ المعنى تماماً وإلاّ ضاعت إشارةٌ حقيقية.

? المسائل

المسألة ٢٠١ ★ [مبتدئ]

اقرأ ملف VCF في R، وفكّك الرأس ومصفوفة الأنماط الجينية وحقول INFO.

تلميح: حزمة VariantAnnotation من Bioconductor هي الأداة المعيارية.

الحل ٢٠١ ✓

```
library(VariantAnnotation)

vcf <- readVcf("ALL.chr22.phase3.vcf.gz", "hg19")

# الرأس header(vcf)
# مصفوفة الأنماط الجينية geno(vcf)$GT[1:5, 1:5]
# تواتر الأليل من حقل AF info(vcf)$AF[1:5]
```

المخرجات المتوقعة (تمثيلية):

```
HG00096 HG00097 HG00099
"rs587"  "0|0"    "0|1"    "1|1"
"rs588"  "0|0"    "0|0"    "0|1"
0.21 0.88 0.03 0.45 0.12 [1]
```

التفسير: الترميز 1|0 يعني أن الفرد متغاير، والشريطة | تعني أن البيانات مطوّرة
الطور (phased). مصفوفة GT هي قلب ملف VCF. حقل AF يعطي تواتر
الأليل المحسوب مسبقاً — مفيدٌ للتحقق السريع.

المسألة ٢٠٢ ★ [مبتدئ]

حول VCF إلى صيغة PLINK BED.

الحلّ ٢.٢ ✓

```
\ plink2 --vcf ALL.chr22.phase3.vcf.gz/.  
      \ make-bed--  
      \ max-alleles 2--  
      out chr22_bed--
```

المخرجات المتوقّعة (تمثيلية):

```
.variants loaded from .pvar 1103547  
.samples loaded 2504  
043 multiallelic variants skipped (--max-alleles 2)  
.make-bed: chr22_bed.bed + .bim + .fam written--
```

التفسير: --max-alleles 2 ضروريّ لأنّ صيغةَ BED لا تدعم المتغيّرات متعدّدة الأليّلات؛ يجب تقسيمها أو حذفها. تجاهلُ هذا سببُ شائعٌ لأخطاءٍ لاحقة.

المسألة ٢.٣ ★ [مبتدئ]

اخفص ملفّات BIM/FAM/BED. ما معنى كلّ عمود، وكيف يُرمزُ BED على مستوى البايوت؟

✓ الحلّ ٢٠٣

```
head -3 chr22_bed.bim
rs587 0 16050075 A G 22 #
# الأعمدة: الكروموسوم، المعرّف، الموضع الجيني (سنتيمو
```

```
head -3 chr22_bed.fam
HG00096 0 0 0 -9 0 #
# الأعمدة: IID, FID, الأب, الأم, الجنس (1=ذكر, 2=أنثى),
```

التفسير: ملفّ BED يبدأ بثلاثة بايتاتٍ سحرية (0x01 0x1b 0x6c)، ثمّ
كلّ نمطٍ جينيّ في بيتين: 00=متماثل أليل 1، 11=متماثل أليل 2، 01=مفقود،
10=متغير. فهم هذا الترميز يفسّر لماذا BED أصغرُ بـ ٣٢ ضعفاً من VCF
النصيّ.

★★ [متوسط] المسألة ٢٠٤

حوّل BGEN إلى PGEN مع معالجة عدم تطابق ملفّ العينات.

✓ الحلّ ٢٠٤

```
\ plink2 --bgen example.bgen ref-first/.
\ sample example.sample--
```

```
\ make-pgen--  
out example_pgen--
```

المخرجات المتوقعة:

```
.samples loaded from .sample 500  
.variants loaded from example.bgen 1000  
e-pgen: example_pgen.pgen + .pvar + .psam written--
```

التفسير: ref-first تحدّد أيّ أليلٍ مرجعيّ – خطأ شائعٌ هنا يقرب اتجاه
كلّ الآثار! صيغةُ PGEN (الجيل الثاني) تدعم الجرعات الاحتمالية (dosages)
للبينات المستوفاة، بخلاف BED التي تحفظ أنماطاً صلبة فقط.

المسألة ٢٠٥ ★★ [متوسط]

ادمج ثلاث مجموعات PLINK من شرائح مختلفة مع معالجة قلب الخيط.

الحلّ ٢٠٥ ✓

```
# توحيد الخيط أولاً باستخدام مرجع  
F-from-fa hg19.fa --make-bed --out array1_aligned/.  
# الدمج  
aligned --pmerge-list merge_list.txt --out merged/.
```

المخرجات المتوقعة:

```
Variants in common across 3 filesets: 287654  
g: 1832 variants with strand inconsistency flipped  
.bim + .fam written: 3500 samples, 287654 variants
```

التفسير: المتغيرات المتناظرة (A/T، G/C) خطيرة عند الدمج لأنها متماثلة عند قلب الخيط، فلا يمكن كشف القلب بالأليات وحدها — يجب الاستعانة بتواترات مرجعية. لهذا نذفها غالباً (المسألة في الفصل ٣).

المسألة ٢٠٦ ★★★ [متقدم]

اكتب دالة R تقرأ أياً من خمس صيغ (/VCF/BED/BGEN/GEN) HDF5 وتعيد إطار بياناتٍ موحداً.

الحل ٢٠٦ ✓

```
} read_genetic <- function(path)  
  ext <- tools::file_ext(path)  
  ,geno <- switch(ext  
    "gz"      = as(geno(readVcf(path))$GT, "matrix") "  
  ats::read.plink(sub(".bed","",path))$genotypes"  
  ,bgen"      = rbgen::bgen.load(path)$data"
```



```

, gen"                = data.table::fread(path) "
                        = rhdf5::h5read(path, "genotypes") "
                        ("صيغة غير مدعومة") stop
                        return(as.data.frame(geno) )
                        {

```

التفسير: هذه الدالة "المحوّل الشامل" تختزل التعامل مع صيغ متعددة في واجهة واحدة. switch يوجّه كلّ امتدادٍ إلى القارئ المناسب. في الممارسة، تُضيف معالجة أخطاءٍ لكلّ فرع.

المسألة ٢٠٧ ★★ ★ [متقدّم]

تحقق من سلامة الملفات: تطابق الأعداد بين BIM و FAM و BED، وكشف الملفات المبتورة.

الحلّ ٢٠٧ ✓

```

n_var=$(wc -l < chr22_bed.bim)
n_sam=$(wc -l < chr22_bed.fam)
expected=$(( (n_var * n_sam + 3) / 4 + 3 ))
actual=$(stat -c%s chr22_bed.bed)

```

```
echo "متوقع: $expected بايت، فعلي: $actual بايت"  
|| "✓ سليم" echo && [ "actual" -ge "$expected" ]
```

التفسير: حجم ملف BED يجب أن يطابق الصيغة الحسابية (٢ بت لكل نمط + ٣ بايتات سحرية). عدم التطابق يكشف ملفاً مبتوراً — وهو خطأ صامتٌ قد يفسد التحليل كله دون رسالة خطأ واضحة.

⚠ الأخطاء الشائعة وتصحيحها

```
-max-- حوّل بـ Error: Multiallelic variant  
Sample IDs.bcftools norm -m أو alleles 2  
sample. لا يطابق BGEN؛ تحقق  
من العمود. Strand inconsistency — استخدم مرجع FASTA  
لتوحيد الخيط. Wrong allele as reference — انتبه لـ  
— Truncated BED file.ref-first مقابل ref-last  
أعد التنزيل وتحقق من المجموع الاختباري md5 Memory error  
reading VCF — اقرأ على نطاقات بـ which=GRanges (...).  
INFO score column missing — البيانات غير مستوفاة أو  
الحقل باسم مختلف (R2 بدل INFO).
```

📖 الغوص العميق

حين استوفينا عيّات مرضى الكلى العرب في جامعة ميشيغان، واجهنا مشكلة الصيغ مباشرةً. بياناتنا جاءت من شريحتين مختلفتين على مدى سنوات، وحين دمجناهما ظهر "اكتشاف" مثير في منطقة ما — تبين لاحقاً أنه محض أثر تقني من قلب خيط غير مصحح في المتغيرات المتناظرة. الدرس الذي رسخ: لا تثق بأي دمج حتى تتحقق من توحيد الخيط مقابل مرجع، وتحذف المتناظرات الغامضة. بفضل اليوم صيغة BGEN/PGEN للبيانات المستوفاة لأنها تحفظ جرعة عدم اليقين؛ فتغير مستوى بثقة ٠.٧. يختلف إحصائياً عن نمط مقيس مباشرة، وإهمال هذا الفرق يضخم الأخطاء.

🔑 تحدّ مفتوح

اكتب أداة تكشف آلياً المتغيرات المقلوبة الخيط بين مجموعتي بيانات بمقارنة تواتراتهما، دون الحاجة إلى مرجع FASTA، باستخدام الارتباط بين التواترات لتمييز القلب الحقيقي من الاختلاف السكاني. ما حدُّ التواتر الذي عنده يصبح التمييز مستحيلاً؟

📖 مراجع أساسية

"Danecek P. et al. (2011). "The variant call format and VCFtools
— Bioinformatics معيار (2018) Marchini J. Band G., VCF.

"BGEN: a binary file format for imputed genotype data"
-Purcell S. et al. (2007). "PLINK: a toolset for whole .*bioRxiv*
.BED. Lin P. et al أصل صيغة — *AJHG* ".genome association
Genetic ".Strand-flip issues in GWAS meta-analysis" .(2014)
.Epidemiology

الفصل الثالث — مراقبة جودة المتغيرات /

Variant Quality Control

﴿وَلَا تُفْسِدُوا فِي الْأَرْضِ بَعْدَ إِصْلَاحِهَا﴾

— سورة الأعراف: ٥٦

نهى الله عن الإفساد بعد الإصلاح؛ وفي تحليل البيانات، المتغير رديء الجودة فسادٌ يجب إزالته قبل أن يفسد التحليل كله. مراقبة الجودة هي إصلاح الأرض قبل أن نزرع فيها.

📖 سيناريو بحثي

لديك بيانات شريحة بـ ٦٥٠ ألف متغير، و ٣,٥٠٠ عينة من خمسة مواقع جمع مختلفة. قبل أي تحليل ارتباط، عليك إجراء مراقبة جودة كاملة للمتغيرات وإنتاج تقرير على مستوى الموقع. بعض المواقع استخدم بروتوكولات أقل دقة، فأنشج متغيرات ذات معدلات خطأ أعلى. مهمتك التمييز بين الإشارة الحقيقية والضوضاء التقنية.

مراقبة جودة المتغيرات ليست خطوة اختيارية؛ هي خط الدفاع الأول ضد الاكتشافات الكاذبة. متغير واحد رديء قد يظهر فوق عتبة الدلالة ويقودك إلى مطاردة سرايب بيولوجي لا وجود له.

مجموعة البيانات لهذا الفصل

نستخدم بيانات HapMap3 مع محاكاة لمعلومات الموقع:

```
# بيانات أساسية + ملف يربط كل عينة بموقع الجمع  
sites.txt: FID IID SITE #  
hapmap3_qc --missing --hardy --freq --out qc_stats/.
```

أهداف التعلم

بعد هذا الفصل تستطيع: (١) تطبيق مرشحات MAF والفقد وHWE؛ (٢) رسم توزيع MAF؛ (٣) كشف وحذف المتغيرات المتناظرة؛ (٤) مراقبة الجودة على مستوى الموقع؛ (٥) اختبار الفقد التفاضلي؛ (٦) المراقبة حسب الدفعة؛ (٧) بناء خط أنابيب بـ Snakemake.

الخلفية الأساسية

ثلاثة مرشحات أساسية: تواتر الأليل الأقلية (MAF) — نحذف النادر جداً
لضعف القوة؛ معدل الفقد (missingness) — نحذف ما تجاوز فقدّه عتبةً
(مثلاً ٢٪)؛ توازن هاردي-واينبرغ (HWE) — نحذف المنحرف بشدة في
الأصحاء. اختبار HWE يقوم على إحصاء كاي-تربيع:

$$\chi^2 = \sum \frac{(O - E)^2}{E}$$

حيث O الأعداد الملاحظة و E المتوقعة وفق $p^2+2pq+q^2$.

تشبيه: مراقبة الجودة كفحص البيض قبل الطبخ. تنظر إلى كل بيضة في الضوء
(الفقد)، تسمّها (HWE)، تتفقد حجمها (MAF). البيضة الفاسدة الواحدة
تفسد العجة كلّها، فالفحص المسبق أرخص من رمي الطبق كلّّه.

? المسائل

المسألة ٣٠١ ★ [مبتدئ]

طبق مرشحات MAF والفقد وHWE، وأبلغ عن الأعداد في كل خطوة.

تلميح: استخدم maf--، geno--، hwe-- في أمر واحد.

الحلّ ٣.١ ✓

```
\ plink2 --bfile hapmap3_raw/.  
    \ maf 0.01--  
    \ geno 0.02--  
    \ hwe 1e-6--  
make-bed --out hapmap3_qc--
```

المخرجات المتوقَّعة (تمثيلية):

```
.variants loaded 1457897  
geno: 18234 variants removed (missingness > 0.02)--  
.maf: 312045 variants removed (MAF < 0.01)--  
.hwe: 4128 variants removed (p < 1e-6)--  
.variants remaining 1123490
```

التفسير: بدأنا بـ ١,٤٦ مليون متغيّر وبقي ١,١٢ مليون. حُذِف ٣١٢ ألفاً لندرتها (MAF منخفض) — وهي الأكثر، طبيعيّ. حُذِف ٤١,٢٨ لانحرافها عن HWE — هؤلاء مرشّحون لأخطاءٍ تقنيّة. الترتيبُ مهمّ: نطبّق الفقد قبل MAF عادةً.

المسألة ٣.٢ ★ [مبتدئ]

ارسم توزيع MAF قبل وبعد الترشيح مع تحديد عتبات القطع.

✓ الحل ٣.٢

```
library(data.table); library(ggplot2)
frq <- fread("qc_stats.afreq")
+ ggplot(frq, aes(ALT_FREQS))
+ geom_histogram(bins=50, fill="#1B3A5C")
+ geom_vline(x=c(0.01,0.99), color="#C9A84C", linetype="dashed")
labs(x="تواتر الأليل", y="عدد المتغيرات")
```

المخرجات المتوقعة: مدرج تكراري على شكل حرف U: ذروتان عند الطرفين (متغيرات نادرة) وانخفاض في الوسط. الخطان الذهبيان عند ٠,٠١ و ٠,٩٩، يحددان المنطقة المحذوفة.

التفسير: شكل U طبيعي: معظم المتغيرات إما نادرة جداً أو شائعة جداً. المنطقة بين العتبتين هي ما نحتفظ به للتحليل.

المسألة ٣.٣ ★★ [متوسط]

اكتشف واحذف المتغيرات المتناظرة (G/C و A/T). لماذا هي خطيرة؟

الحل ٣.٣ ✓

```
bim <- fread("hapmap3_gc.bim")
c <- bim[(V5=="A" & V6=="T") | (V5=="T" & V6=="A")
& V6=="G") | ("V5=="G" & V6=="C")
palindromic[,.(V2)], "palindromic.txt", col.names=FALSE)
# ثم : hapmap3_nopalin/. --make-bed --out
```

المخرجات المتوقعة:

عدد المتغيّرات المتناظرة : 47823
بعد الحذف : 1075667 متغير

التفسير: المتناظرة خطيرة لأنّ A/T على الخيط الموجب تساوي T/A على السالب
— لا يمكن تمييز الخيط بالأليلات وحدها. عند الدمج أو الميّا-أناليسيس، قد
ينقلب اتجاه الأثر دون أن ندري. الحذف هو الحلّ الآمن للمتناظرات قريبة
التواتر من ٥,٠٠.

المسألة ٣.٤ ★★ [متوسط]

راقب الجودة على مستوى الموقع: بعض المواقع لها معدلات خطأ أعلى.

✓ الحل ٣.٤

```
for site in 1 2 3 4 5; do  
link2 --bfile hapmap3_qc --keep site${site}.txt/.  
missing --out site${site}_miss--  
  
done
```

```
# مقارنة معدل الفقد بين المواقع  
mean(fread(paste0("site",s,"_miss.vmiss"))$F_MISS))
```

المخرجات المتوقعة:

```
0.005 0.003 0.021 0.004 0.003 [1]
```

التفسير: الموقع ٣ له معدل فقد أعلى بسبعة أضعاف (٢,١٪ مقابل ٠,٣٪) –
مؤشر على مشكلة تقنية في ذلك الموقع. قد نطبق ترشيحاً أصرم على متغيراته أو
نستبعد عيناته المشبوهة.

المسألة ٣.٥ ★★ [متوسط]

اختبر الفقد التفاضلي: متغيرات فقدتها أعلى في الحالات منه في الضوابط تدلّ على
أثر دفعة.

✓ الحلّ ٣.٥

```
--bfile hapmap3_qc --test-missing --out diffmiss/.  
  
dm <- fread("diffmiss.missing")  
# عدد المتغيّرات ذات الفقد التفاضلي sum(dm$P < 1e-5)
```

المخرجات المتوقّعة:

213 [1]

التفسير: ٢١٣ متغيّراً تختلف في فقدتها بين الحالات والضوابط بدلالة قوية. هذا خطير جداً: إن جمعت الحالات والضوابط في دفعات منفصلة، فالفقد التفاضلي يخلق ارتباطات زائفة. نحذف هذه المتغيّرات.

المسألة ٣.٦ ★★★ [متقدّم]

راقب الجودة حسب دفعة الترميط الجيني وحدد المتغيّرات المشكّلة في كلّ دفعة.

✓ الحلّ ٣.٦

```
batches <- fread("batches.txt") # FID IID BATCH  
results <- lapply(unique(batches$BATCH), function(b)  
# شغل --hardy و --missing لكل دفعة، ثم اجمع المتغيّرات
```

```

hwe <- fread(sprintf("batch_%s.hardy", b))
hwe[P < 1e-6, SNP]

({
  problem_snps <- table(unlist(results))
  # المتغيرات الفاشلة في دفعة واحدة فقط = مشتبهة بأثر
specific <- names(problem_snps)[problem_snps == 1]

```

التفسير: متغير يفشل HWE في دفعة واحدة فقط يُرَجَّح أَنَّهُ خطأً دفعةً تقنيًّا، لا إشارةً بيولوجية. أمَّا الفاشلُ في كلِّ الدفَعات فقد يكون مشكلةً عامَّة. هذا التقسيم يميِّز نوعي الخطأ.

المسألة ٣٠٧ ★★★ [متقدِّم]

ابن خطّ أنابيب كاملاً لمراقبة جودة المتغيرات بـ Snakemake.

الحلّ ٣٠٧ ✓

```

Snakefile #
:rule all

"input: "final_qc.bed

:rule variant_qc

```

```

        "input: "raw.bed
        "output: "final_qc.bed
        :shell
plink2 --bfile raw --maf 0.01 --geno 0.02"
" hwe 1e-6 --exclude palindromic.txt--"
"make-bed --out final_qc--"

```

المخرجات المتوقعة:

```

...Building DAG of jobs
rule variant_qc: 1 of 1 steps (100%) done

```

التفسير: Snakemake يجعل خطّ الأنايب قابلاً لإعادة الإنتاج: يتتبع الاعتماديات، ويعيد تشغيل ما تغيّر فقط. هذا معيارٌ ذهبيٌّ للأبحاث الجادة (الفصل ٢٤).

⚠ الأخطاء الشائعة وتصحيحها

— hwe filters too many variants -- طبّقته على الحالات والضوابط معاً؛ طبّقه على الضوابط فقط ب -- keep MAF threshold removes real.controls signals — في المتغيّرات النادرة استخدم تحليلاً مخصّصاً (الفصل ١٦)

بدل الحذف. Palindromic removal too aggressive.
 — احذف فقط القريبة من تواتر ٥,٠٠٠ test-missing requires
 phenotype — يجب وجود عمود الحالة/الضبط. Batch column
 :Snakemake.FID/IID — تأكد من تطابق
 MissingInputException — ملف الإدخال غير موجود أو
 مساره خاطئ.

📖 الغوص العميق

في دراسة الكلى بجامعة ميشيغان، جمعت عيناتنا على مدى عقد من مواقع متعددة وشرائح مختلفة. أول GWAS أجريناه أعطى معامل تضخم $\lambda = 1,15$ — مرتفع بشكل مقلق. بالتقصي، اكتشفنا أن السبب لم يكن التقسيم السكاني بل أثر الدفعة: مجموعة من المتغيرات تمطت بجودة مختلفة بين دفعتين زمنيّتين، والحالات تركزت في دفعة والضوابط في أخرى. حين طبقنا اختبار الفقد التفاضلي وحذفنا ٤٠٠ متغير مشبوه، هبط λ إلى ١,٠٣. الدرس: التضخم ليس دائماً سكانيًا؛ قد يكون تقنيًا بحثًا، ومراقبة الجودة الصارمة على مستوى الدفعة والموقع تنقذ الدراسة قبل أن تُنشر نتائج كاذبة.

🔧 تحدّ مفتوح

صمّم مقياساً مرجحاً لجودة المتغير يدمج الفقد وHWE والفقد التفاضلي والانساق بين الدفعات في درجة واحدة بين ٠ و١، ثمّ ابحث عن العتبة المثلى لهذه الدرجة التي

تعظم عدد الاكتشافات الحقيقية المتكررة وتقلل الكاذبة. كيف تتحقق من أن عتبتك ليست مُفرطةً في التكيّف مع بياناتك؟

مراجع أساسية

- Anderson C.A. et al. (2010). "Data quality control in genetic case-control association studies — *Nature Protocols* "الدليل المرجعي
- Marees A.T. et al. (2018). "A tutorial on conducting. لمراقبة الجودة. *Int J Methods Psychiatr Res* ".GWAS: QC and statistical analysis
- Laurie C.C. et al. (2010). "Quality control and quality assurance .Köster J., Rahmann S. *Genet Epidemiol* ".in genotypic data
- Snakemake — a scalable bioinformatics workflow" .(2012) *Bioinformatics* ".engine

الفصل الرابع — مراقبة جودة العينات / Sample Quality Control

﴿وَفِي أَنْفُسِكُمْ أَفَلَا تُبْصِرُونَ﴾

— سورة الذاريات: ٢١

دعوةً إلى التأمل في النفس؛ وفي مراقبة جودة العينات نتأمل في كل فردٍ من بياناتنا: هل بياناته سليمة؟ هل هو من نظن؟ هل هو قريبٌ خفيٌّ لآخر؟ التبصرُ في الأفراد يحمي التحليلَ من الخلل.

📖 سيناريو بحثي

بعد مراقبة جودة المتغيرات، بقي لديك ٣٥٠٠ عينة. الآن يجب أن تحدّد وتحذف: العينات عالية الفقد، وشواذّ التغاير الزيجوتيّ، وعدم تطابق الجنس، والنسخ المكررة الخفية، والأفراد المتقاربين. كلُّ نوعٍ من هذه المشكلات يلوّث التحليل بطريقةٍ مختلفة: العينة رديئة الجودة تدخل ضوضاء، والأقارب الخفيّون يكسرون افتراض الاستقلال.

مراقبة جودة العينات هي الوجه الآخر لمراقبة المتغيرات. هناك نظفنا الأعمدة، وهنا نظف الصفوف. عينة واحدة ملوثة قد تكون كافية لإفساد إشارة حقيقية أو خلق إشارة كاذبة.

مجموعة البيانات لهذا الفصل

```
hap3_qc --missing --het --check-sex --out sampleqc/.
# لتحليل القرابة:
-bfile hapmap3_qc --make-king-table --out kinship/.
```

أهداف التعلم

بعد هذا الفصل تستطيع: (١) ترشيح العينات حسب الفقد؛ (٢) كشف شواذ التغير؛ (٣) فحص الجنس؛ (٤) كشف النسخ المكررة ب IBS؛ (٥) تحليل القرابة ب KING؛ (٦) كشف شواذ PCA؛ (٧) كتابة تقرير مراقبة شامل.

الخلفية الأساسية

إحصاء التغير F يقيس انحراف تغير الفرد عن المتوقع: $F = \frac{O_{\text{hom}}}{E_{\text{hom}}}$ حيث القيم الموجبة العالية تعني تغيراً أقل من المتوقع (تلوث أو زواج أقارب)، والسالبة العالية تعني تغيراً أعلى (تلوث عينة

بعينةً أخرى). أما IBD/PL_HAT فيقيس نسبةً الجينوم المشترك بين فردين: •
لغرباء، ٥,٠ لأشقاء أو والد-ابن، ١ لتوائم/نسخ مكررة.

تشبيه: مراقبةُ العينات كفحص الركاب قبل الطائرة. تتحقق من الهوية (فحص الجنس)، تكشف التذاكر المكررة (النسخ المزدوجة)، تتأكد ألا يكون أحدٌ على قائمتين (الأقارب)، وتبعد من تبدو وثائقه مشبوهة (الفقد العالي). هدفك رحلةً نظيفةً بلا مفاجآت.

؟ المسائل

المسألة ٤.١ ★ [مبتدئ]

احسب ورتِّح حسب معدل فقد العينة.

الحل ٤.١ ✓

```
_qc --mind 0.02 --make-bed --out samples_filtered/.
```

المخرجات المتوقعة:

```
.samples loaded 3500  
.mind: 23 samples removed (missingness > 0.02)--  
.samples remaining 3477
```

التفسير: حذفت ٢٣ عينةً تجاوز فقدُها ٠.٢٪. العينةُ عاليةُ الفقد غالباً تشير إلى DNA متدهور أو فشل في الترميز — بياناتها غير موثوقة عبر كل المتغيرات.

المسألة ٤.٢ ★ [مبتدئ]

احسب إحصاء التغير F ، وحدد الشواذ واحذفها مع توضيح الرسم.

الحل ٤.٢ ✓

```
het <- fread("sampleqc.het")
at := (`O(HOM)` - `E(HOM)` ) / (`N(NM)` - `E(HOM)` )
m <- mean(het$F_stat); s <- sd(het$F_stat)
outliers <- het[abs(F_stat - m) > 3*s]
ggplot(het, aes(F_stat)) + geom_histogram(bins=50)
geom_vline(xintercept=c(m-3*s, m+3*s), color="red")
```

المخرجات المتوقعة:

عدد الشواذ (> 3 انحرافات): 18
المدى الطبيعي: -0.03 إلى 0.04

التفسير: ١٨ عينة خارج ٣ انحرافات. الشواذ الموجبة العالية = تلوث محتمل أو زواج أقارب؛ السالبة العالية = تلوث عينتين. كلاهما يستحق الحذف أو التحقيق.

المسألة ٤.٣ ★★ [متوسط]

اخفص الجنس بمقارنة الجنس المبلَّغ بالجنس المستنتج من تغاير الكروموسوم X.

✓ الحل ٤.٣

```
h2 --bfile hapmap3_qc --check-sex --out sexcheck/.
```

```
sc <- fread("sexcheck.sexcheck")
sc[STATUS == "PROBLEM"]
```

المخرجات المتوقعة:

IID	PEDSEX	SNPSEX	STATUS	F
NA12878	2	1	PROBLEM	0.98
NA10859	1	2	PROBLEM	0.12

التفسير: الذكور لديهم نسخة واحدة من X، فتغايرهم فيه ≈ 0 (F قريب من ١).
الإناث لديهم نسختان، ف F قريب من ٠.٠ عدم التطابق (مثل NA12878):

مبلغ أنثى لكن $F=0.98$ يدلّ على ذكر) يكشف خطأ تسمية في العينة أو خلط
 أنابيب — علامة خطر تستوجب الحذف.

المسألة ٤.٤ ★★ [متوسط]

اكتشف النسخ المكررة الخفية باستخدام IBS مع $PI_HAT > 0.9$.

✓ الحل ٤.٤

```
--bfile hapmap3_qc --genome --min 0.9 --out dups/.
```

المخرجات المتوقعة:

IID1	IID2	PI_HAT	Z0	Z1	Z2
NA12005	NA12006	0.998	0.00	0.00	1.00

التفسير: $PI_HAT \approx 1$ مع $Z2 \approx 1$ (احتمال مشاركة أليلين) يعني نسخة مكررة أو
 توأماً متماثلاً. في معظم الدراسات، نحذف إحدى النسختين (الأعلى فقداً
 عادةً) للحفاظ على استقلال العينات.

المسألة ٤.٥ ★★ [متوسط]

حلّ القرابة ب KING، وابن جدول القرابة، وقرّر أي نسخة تُحذف.

✓ الحل ٤.٥

```
king-table --king-table-filter 0.0884 --out king/.  
  
king <- fread("king.kin0")  
# KINSHIP > 0.354 = توأم / نسخة ، 0.354-0.177 = درجة  
king[KINSHIP > 0.177]
```

المخرجات المتوقعة:

العلاقة	ID1	ID2	KINSHIP
توأم / نسخة	NA12005	NA12006	0.498
درجة أولى	NA11843	NA11881	0.241

التفسير: KING أدق من PL_HAT لأنه محصن ضد التقسيم السكاني. قيمة القرابة ٠,٥ توأم، ٠,٢٥ درجة أولى (أشقاء/والدين)، ٠,١٢٥ درجة ثانية. نحذف فرداً من كل زوج قريب للحفاظ على الاستقلال، مفضلين إبقاء الأعلى جودة.

المسألة ٤.٦ ★★★ [متقدم]

اكتشف شواذ السكان: احسب PCA وحدد العينات الأبعد من ٦ انحرافات عن المركز في PC1 وPC2.

الحل ٤.٦ ✓

```
plink2 --bfile hapmap3_gc --pca 10 --out pca/.

pca <- fread("pca.eigenvec")
} for (pc in c("PC1", "PC2"))
  m <- mean(pca[[pc]]); s <- sd(pca[[pc]])
pca[, paste0(pc, "_out") := abs(get(pc)-m) > 6*s]

{
  outliers <- pca[PC1_out | PC2_out]
```

المخرجات المتوقعة:

عدد شواذ 7 PCA:

التفسير: العينات البعيدة جداً في المكونات الرئيسية إما من أصل مختلف تماماً عن بقية العينة، أو ملوثة. ٦ انحرافات عتبة متحفظة تتجنب حذف التنوع الطبيعي. نفحصها قبل القرار.

المسألة ٤.٧ ★★★ [متقدم]

اكتب تقرير مراقبة جودة العينات في R Markdown مع رسم لكل مقياس وجدول استبعاد نهائي.

✓ الحلّ ٤.٧

```
sample_qc_report.Rmd #
# لكل مقياس: رسم + عتبة + قائمة المستبعدين
,excluded <- unique(c(highmiss$IID, het_out$IID
em$IID, dups$IID2, pca_out$IID
)exclusion_table <- data.table
c("High missingness","Het outlier","Sex mismatch
, ("Duplicate","PCA outlier"
(N = c(23, 18, 5, 12, 7)
knitr::kable(exclusion_table)
```

المخرجات المتوقّعة:

السبب	العدد
فقد عالٍ	23
شاذّ تغاير	18
عدم تطابق الجنس	5
نسخة مكرّرة	12
شاذّ 7	PCA
الإجمالي (فريد)	61

التفسير: التقرير الموحد يجعل قرارات الاستبعاد شفافة وقابلة للمراجعة. كل عينة محذوفة لها سبب موثق — وهذا ما يطلبه المحكمون في النشر.

⚠ الأخطاء الشائعة وتصحيحها

check-sex needs X chromosome -- تأكد أن بياناتك تحتوي كروموسوم X.Heterozygosity needs LD.X pruning — قلم LD أولاً وآلا تحييز KING vs PI_HAT.F disagree — ثق ب KING في العينات متعددة الأصول. Removing both duplicates — احذف واحداً فقط، أبقِ الأعلى جودة. PCA outliers are real ancestry — لا تحذف التنوع الحقيقي؛ احص قبل الحذف. mind before geno — رشح المتغيرات قبل العينات لتجنب التحيز.

📖 الغوص العميق

في مجموعة الكلي بجامعة ميشيغان، اكتشفنا عبر تحليل KING أن ١٢ زوجاً من "المرضى المستقلين" كانوا في الحقيقة أقارب من الدرجة الأولى — على الأرجح بسبب تجنيد عائلي في عيادة واحدة. لو تجاهلنا هذا، لكسرنا افتراض استقلال العينات، ولتضخمت أخطاؤنا المعيارية. الأهم أننا تعلمنا أن المجتمعات العربية ذات معدلات زواج الأقارب المرتفعة تظهر قرابة خفية أكثر من المجتمعات الأوروبية، فتحليل KING عندنا ليس رفاهية بل ضرورة. هذا أيضاً فرصة

علمية: بنات القرابة الغنية تتيح تحليلات ربط عائلي (linkage) لا تتاح في العينات الأوروبية المتفرقة.

تحدٍ مفتوح

في مجتمع عالي زواج الأقارب، القرابة الخلفية مرتفعة بطبيعتها، لحذف كل زوج $KINSHIP < 0.88$ ، قد يحذف نصف العينة. صمم استراتيجية تحتفظ بأكبر مجموعة فرعية "غير مرتبطة" ممكنة (مشكلة المجموعة المستقلة القصوى في نظرية الرسوم)، ثم قارنها بنهج النماذج المختلطة التي تحتفظ بالجميع. أيهما يعطي قوة أعلى لمجتمعك؟

مراجع أساسية

- Manichaikul A. et al. (2010). "Robust relationship inference in *Bioinformatics*". Anderson C.A. et al. (2010). "GWAS (KING) *Nature*". Data quality control in genetic case-control studies" Turner S. et al. (2011). "Quality control procedures for *Protocols*". Price A.L. et al. (2006). "PCA *Curr Protoc Hum Genet*". GWAS *Nature Genetics* ".corrects for stratification

الفصل الخامس — تحليل المكونات الرئيسية المتقدم / Advanced PCA Analysis

﴿وَجَعَلْنَاكُمْ شُعُوبًا وَقَبَائِلَ لِتَعَارَفُوا﴾

— سورة الحجرات: ١٣

جعلنا الله شعوباً وقبائل للتعارف؛ وتحليل المكونات الرئيسية هو الأداة التي بها "نتعارف" على أصول عيّناتنا، فنميز الشعوب والقبائل المخبّأة في الجينوم لنضبطها بعدل.

📖 سيناريو بحثي

مجموعتك متعدّدة الأعراق: أوروبيون وأفارقة وشرق آسيا وجنوب آسيا وعرب. قبل أيّ GWAS، عليك أن تُسقط عيّناتك على مرجع الجينومات الألف، وتُسند لكلّ عيّنة أصلها، وتُنشئ متغيّراتٍ مشتركةً (PCs) لضبط التقسيم السكاني. انخلط بين الأصول دون ضبط هو السبب الأوّل لاكتشافات الكاذبة في GWAS.

PCA في الجينات ليس مجرد اختزال للأبعاد؛ إنه اكتشافٌ مذهلٌ بأنَّ أولَّ
مكوّنين يلتقطان الجغرافيا القاريّة بدقّة تكاد تطابق الخريطة. هذا الفصل يأخذك
من التقليم الأساسيّ إلى تقدير نسب الاختلاط.

مجموعة البيانات لهذا الفصل

```
# عَيّناتك + مرجع 1000G المُصنّف بالآصول  
e study --indep-pairwise 200 50 0.2 --out pruned/.  
extract pruned.prune.in --pca 20 --out study_pca/.
```

أهداف التعلّم

بعد هذا الفصل تستطيع: (١) تقليم LD لـ PCA؛ (٢) تشغيل ورسم PCA؛ (٣)
إسقاط عيّّنات على مرجع 1000G؛ (٤) إسناد الأصل؛ (٥) اختبار Tracy-
Widom؛ (٦) تحليلاً مطبقاً؛ (٧) كشف شواذ PCA؛ (٨) تقدير الاختلاط بـ
.ADMIXTURE

الخلفية الأساسية

PCA يجد المحاور التي تفسّر أكبر تباينٍ في مصفوفة الأنماط الجينية. رياضياً،
نحسب القيم الذاتية والمتجهات الذاتية لمصفوفة العلاقات الجينية:

$$\|\mathbf{G} \mathbf{v}_i\| = \lambda_i \|\mathbf{v}_i\|$$

حيث المتجه الذاتي $\mathbf{v}_i$ هو المكون الرئيسي i ، والقيمة الذاتية λ_i مقدار التباين الذي يفسره.

تشبيه: PCA كأخذ صورةٍ ظلّيةٍ (silhouette) لجسمٍ ثلاثيّ الأبعاد. الجسمُ معقّد، لكنك تختار الزاوية التي تُظهر أكبر قدرٍ من التمييز. PC1 هو "أفضل زاوية" تفصل المجموعات، PC2 ثاني أفضل زاوية عمودية عليها، وهكذا. في الجينات، هذه الزوايا تتطابق مع القارّات.

؟ المسائل

المسألة ٥.١ ★ [مبتدئ]

قلم LD لأجل PCA. لماذا، وبأيّ معاملات، وكيف تتحقّق؟

الحلّ ٥.١ ✓

```
study --indep-pairwise 200 50 0.2 --out pruned/.
```

المخرجات المتوقّعة:

```
.Pruned 847291 variants, 198453 remaining
```

التفسير: PCA يفترض متغيراتٍ مستقلةً نسبياً؛ المتغيراتُ في LD شديد تُحرف المكوّنات نحو مناطق كثيفةٍ LD (مثل الانقلابات). نُبقي متغيراً واحداً لكل نافذةٍ من ٢٠٠، بخطوة ٥٠، وعتبة $r^2=0.2$ ، بقاءً ٢٠٠ ألفٍ مستقلٍ كافٍ لـ PCA.

المسألة ٥.٢ ★ [مبتدئ]

شغل PCA بـ PLINK2 وارسم PC1 مقابل PC2 ملوّناً بالشعب.

الحلّ ٥.٢ ✓

```
pca <- fread("study_pca.eigenvec")
pop <- fread("populations.txt")
d <- merge(pca, pop, by="IID")
aes(PC1, PC2, color=POP) + geom_point(alpha=0.6)
scale_color_brewer(palette="Set1")
```

المخرجات المتوقّعة: سحاباتٌ منفصلة: الأفارقةُ في زاوية، الأوروبيون في أخرى، شرق آسيا في ثالثة، والعربُ بين الأوروبيين والأفارقة (يعكس تاريخ الاختلاط).

التفسير: انفصالُ السحابات يؤكّد أنّ PC1 وPC2 يلتقطان الأصل القاريّ. موقعُ العرب الوسطيّ بيولوجيّ ذو معنى: يعكس مكوّناتٍ من عدّة أصول.

المسألة ٥.٣ ★★ [متوسط]

أسقط عيّناتٍ جديدة على مكوّنات 1000G المرجعية.

✓ الحلّ ٥.٣

```
# حساب المكوّنات في المرجع ثم الإسقاط
1000G_ref --freq --pca 20 allele-wts --out ref_pca/.
\ plink2 --bfile study --read-freq ref_pca.afreq/.
ref_pca.eigenvec.allele 2 5 header-read--
score-col-nums 6-25 --out projected--
```

المخرجات المتوقّعة:

.Projected 3477 samples onto 20 reference PCs

التفسير: الإسقاط يضع عيّناتك في الفضاء نفسه للرجع، فتقارن أصولها بمعياري موحد. هذا أدقّ من حساب PCA منفصلٍ لأنّه يربطها بشعوبٍ معروفة الأصل.

المسألة ٥.٤ ★★ [متوسط]

أسند الأصل بقاعدة ٣ انحرافات من مراكز الشعوب المرجعية.

✓ الحل ٥.٤

```
oids <- proj_ref[, .(mPC1=mean(PC1), mPC2=mean(PC2)
), sPC2=sd(PC2)), by=POP
      }assign_anc <- function(pc1, pc2)
sqrt(((pc1-mPC1)/sPC1)^2 + ((pc2-mPC2)/sPC2)^2)]
centroids$POP[which.min(d)] else "Admixed/Unknown
{
study[, ancestry := mapply(assign_anc, PC1, PC2)]
```

المخرجات المتوقعة:

R: 1840 AFR: 612 EAS: 410 SAS: 380 Admixed: 235

التفسير: المسافة الإقليدية المعيارية من كل مركزٍ تحدّد الأصل. من يبعد < ٣ انحرافات عن كل المراكز يُصنّف "مختلطاً" – وهؤلاء يحتاجون معاملةً خاصةً في GWAS متعدّد الأصول (الفصل ١٧).

المسألة ٥.٥ ★★ [متوسط]

استخدم اختبار Tracy-Widom لتحديد العدد الأمثل من المكونات.

✓ الحل ٥.٥

```
library(AssocTests)

eigenL=length(eigenvalues), criticalpoint=2.0234)

cat("عدد المكوّنات المعنوية:", w_result$SignntEigenL ,
```

المخرجات المتوقّعة:

عدد المكوّنات المعنوية : 6

التفسير: اختبار Tracy-Widom يحدّد كم مكوّناً يلتقط بنيةً حقيقيةً مقابل ضوضاء. هنا ٦ مكوّناتٍ معنوية – أي إنّ بنيةً سكانيةً في ٦ أبعاد. ندخل على الأقلّ هذه الستّة كمتغيّراتٍ مشتركة.

المسألة ٥.٦ ★★★ [متقدّم]

أجر تحليلًا مطبقًا: شغل PCA منفصلاً داخل كلّ مجموعة أصل.

✓ الحل ٥.٦

```
for anc in EUR AFR EAS SAS; do
\ plink2 --bfile study --keep ${anc}.txt/.
```

```
ed.prune.in --pca 10 --out pca_${anc}--
```

done

التفسير: داخل كل أصل، تكشف المكوناتُ بنيةً دقيقةً (مثل شمال/جنوب أوروبا) لا تظهر في PCA المختلط الذي تهيمن عليه الفروقُ القارّية الكبرى. هذا ضروريٌّ للضبط الدقيق داخل كل مجموعة.

المسألة ٥.٧ ★★ ★ [متقدّم]

اكتشف شواذَ PCA واكتب سكربتَ استبعادٍ آلياً.

الحلّ ٥.٧ ✓

```
detect_outliers <- function(pca, n_pc=10, sd_thresh=6)
  out <- rep(FALSE, nrow(pca))
  for (i in 1:n_pc)
    pc <- pca[[paste0("PC",i)]]
    out | (abs(pc - mean(pc)) > sd_thresh*sd(pc))
  {
    pca[out, .(FID, IID)]
  }
write(detect_outliers(study_pca), "pca_exclude.txt")
```

التفسير: خُصَّ ١٠ مكوّناتٍ (لا اثنين فقط) يكشف شواذَّ في الأبعاد الأدقَّ
أيضاً. السكربتُ يُنتج قائمةً استبعادٍ جاهزة لـ `remove--`.

المسألة ٥٠٨ ★★★★★ [خير]

قدّر نسب الاختلاط بـ ADMIXTURE (K من ٢ إلى ٧) مع تحقّقٍ متقاطعٍ
لإيجاد أفضل K ، وتصورٍ بأعمدةٍ مكّسّة.

الحلّ ٥٠٨ ✓

```
for K in 2 3 4 5 6 7; do
  admixture --cv study_pruned.bed $K | tee log${K}.out
done
grep -h CV log*.out
```

```
# رسم أفضل K
Q <- fread("study_pruned.5.Q")
image(as.matrix(Q), col=rainbow(5), border=NA, space=0)
```

المخرجات المتوقّعة:

CV error (K=2) : 0.4821

CV error (K=4) : 0.4503 --> الأدنى

CV error (K=5) : 0.4519

التفسير: أدنى خطأ في التحقق المتقاطع ($K=4$) يدلّ على 4 مجموعات سلفية. الأعمدة المكسّسة تُظهر نسبة كلّ سلف في كلّ فرد – فالفرد المختلط يظهر بألوانٍ متعددة. ADMIXTURE أدقّ من PCA لتقدير النسب الكميّة للاختلاط.

⚠ الأخطاء الشائعة وتصحيحها

PCA dominated by one region – لم تقلّم LD، أو منطقة انقلاب (مثل chr8 inversion، MHC) تهيمن؛ احذفها. Projection gives wrong scale – يجب استخدام تواترات المرجع بـ Tracy-Widom – Too few/many PCs.read-freq أو ADMIXTURE very slow.scrie plot LD وقلّ عدد المتغيّرات. Ancestry assignment fails for Arabs. – العربُ غيرُ ممثّلين جيّداً في 1000G؛ استخدم مرجعاً مخصّصاً إن توفّر. negative eigenvalues – مصفوفة غيرُ معرّفة موجبة؛ تحقّق من البيانات.

📖 الغوص العميق

حين أسقطنا عينات مرضى الكلى العرب على مرجع 1000G في جامعة ميشيغان، واجهنا تحدياً جوهرياً: العرب غير ممثلين في 1000G، ف وقعت عيناتنا في منطقة "بينية" بين الأوروبيين والأفارقة وجنوب آسيا، ولم يطابقها أي مركز مرجعي. اضطررنا لبناء مكونات خاصة داخل العينة العربية نفسها لضبط البنية الدقيقة. هذا جسد لي عملياً "فجوة الجينوم العربي": الأدوات كلها مُعَايَرَةٌ على شعوب لا تشملنا. أدخل عادةً ١٠ مكونات في نماذج الكلى، لكنني تعلّمت أن العدد ليس مقدساً؛ أخفض scree plot و λ بعد كل خيار. لا أكثر من اللازم (يبدد القوة) ولا أقل (يترك تضخماً).

🔗 تحدٍ مفتوح

العرب يقعون في فراغ في فضاء 1000G. صمّم طريقة لبناء مرجع مكونات "عربيّ المركز" من بيانات عربية متاحة (مثل Greater Middle East Variome)، ثم قس كم يتحسن ضبط التضخم (λ) في GWAS عربيّ مقارنةً باستخدام مكونات 1000G الأوروبية المركز. ما الحد الأدنى لحجم المرجع العربيّ ليكون مفيداً؟

- Price A.L. et al. (2006). "Principal components analysis corrects
.Patterson N. et al .*Nature Genetics* ".for stratification in GWAS
PLoS Genetics ".Population structure and eigenanalysis" .(2006)
- Tracy-Widom. Alexander D.H. et al. (2009). "Fast أصل تطبيق —
Genome ".model-based estimation of ancestry (ADMIXTURE)
- Novembre J. et al. (2008). "Genes mirror geography .*Research*
. *Nature* ".within Europe

الفصل السادس — استيفاء البيانات الجينية /

Genotype Imputation

﴿وَمَا أُوتِيتُمْ مِنَ الْعِلْمِ إِلَّا قَلِيلًا﴾

— سورة الإسراء: ٨٥

ما أُوتينا من العلم إلا قليلاً؛ والشريحة تُقَيَسُ قليلاً من الجينوم (٦٥٠ ألفاً)،
فنستوفي الباقي (٨ ملايين) استدلالاً من المعروف على المجهول. الاستيفاء تواضعٌ
معرفيٌّ منهجيٌّ: نَعْتَرَفُ بما لا نَقْيِسُهُ، ونَقْدَرُهُ بأَفْضَلِ ما نَمْلِكُ.

📖 سيناريو بحثي

بياناتك المنمّطة تحتوي ٦٥٠ ألف SNP. تريد التوسّع إلى أكثر من ٨ ملايين
متغيّر بالاستيفاء باستخدام لوحة TOPMed المرجعية. لماذا؟ لأنّ الاستيفاء يزيد
كثافة التغطية، فيسمح بكشف إشاراتٍ بين المتغيّرات المقيسة، ويمكن من الميتا-
أناليسيس بين دراساتٍ استخدمت شرائح مختلفة (توحيد المتغيّرات).

الاستيفاء يستغل LD: المتغيرات المجاورة المقيسة تنبأً بالمتغيرات غير المقيسة بينها، استناداً إلى أنماط الهابلوتايب في لوحة مرجعية ضخمة. النتيجة ليست يقيناً بل احتمالاً (جرعة dosage)، ولكل متغير درجة ثقة (INFO).

مجموعة البيانات لهذا الفصل

بيانات منقطة بعد QC + لوحة TOPMed عبر خادم الاستيفاء
تجهيز:

```
study_qc --recode vcf --out study_for_imputation/.  
study_for_imputation.vcf -Oz -o study_sorted.vcf.gz
```

أهداف التعلم

بعد هذا الفصل تستطيع: (١) تجهيز البيانات لخادم ميشيغان؛ (٢) فهم المخرجات وINFO؛ (٣) ترشيح المتغيرات المستوفاة؛ (٤) مقارنة التواترات بـ gnomAD؛ (٥) الاستيفاء المحلي بـ MINIMAC4؛ (٦) تقييم الجودة؛ (٧) بناء خط أنابيب مواز.

الخلفية الأساسية

درجة INFO (تسمى أيضاً r^2 أو Rsq) تقيس ثقة الاستيفاء، بين ٠ و ١. تقريباً، هي نسبة التباين الحقيقي في الجرعة المستوفاة إلى التباين المتوقع:

$\text{INFO} \approx \frac{\text{Var}(\text{dosage})}{2p(1-p)}$

المتغيرات ذات $\text{INFO} > 0.8$ تُستبعد عادةً لضعف الثقة.

تشبيه: الاستيفاء كاستكمال كلمات ناقصة في جملة معروفة. لو قرأت "بسم الله الرحمن الرحيم..." لاستكملت "رحيم" بثقة شبه تامة (INFO عالٍ)، لأن السياق (LD) قوي. أما في جملة نادرة غامضة، فاستكمالك تخمين ضعيف (INFO منخفض). كثافة المرجع (حجم اللوحة) كثراء مكتبتك اللغوية: كلما عرفت نصوصاً أكثر، أحسنت الاستكمال.

؟ المسائل

المسألة ٦.١ ★ [مبتدئ]

جهاز البيانات لخادم ميشيغان للاستيفاء. ما خطوات QC المطلوبة وما الذي يفحصه الخادم؟

الحل ٦.١ ✓

```
# لكل كروموسوم: VCF مرتب ومضغوط، الخيط موحد مع الممر
for chr in {1..22}; do
    bcftools view -bvc -O vcf -o chr${chr}.vcf.gz study_qc --chr $chr --recode vcf bgz/.
done
```

done

أداة فحص ما قبل الرفع:

```
m.pl -b study_qc.bim -f study.frq -r TOPMed.tab -h
```

المخرجات المتوقعة:

...Matching to reference panel

Position matches: 648203

Strand flips corrected: 1204

Allele frequency outliers removed: 312

Ready for upload: chr1.vcf.gz ... chr22.vcf.gz

التفسير: الخادمُ يفحص: تطابقَ المواضع مع المرجع، توحيدَ الخيط، شذوذَ التواتر. أداةُ الفحص المسبق تصحّح هذه قبل الرفع، فتتجنّب رفضَ الخادم. شذوذُ التواتر (متغيّر تواتره يختلف كثيراً عن المرجع) علامةٌ على خطأ خيطٍ أو موضع.

المسألة ٦.٢ ★ [مبتدئ]

ارفع إلى الخادم وافهم المخرجات: INFO، ومستوى مقابل منمّط.

الحلّ ٦.٢ ✓

بعد التنزيل وفكّ التشفير:

```
"bcftools view -h chr1.dose.vcf.gz | grep "INFO
zcat chr1.info.gz | head -3
```

المخرجات المتوقعة:

SNP	REF	ALT	MAF	Rsq	Genotyped
chr1:10583	G	A	0.21	0.94	Genotyped
chr1:10611	C	G	0.03	0.71	Imputed

التفسير: العمودُ Genotyped يميّز المقيسَ فعلاً من المستوفى. المتغيرُ النمطُ له $Rsq=1$ (مقيسٌ مباشرة)، والمستوفى أقلّ. هنا المتغيرُ الثاني ($Rsq=0.71$) ضعيفٌ نسبياً – قريبٌ من عتبة الاستبعاد.

المسألة ٦.٣ ★★ [متوسط]

رثِّح المتغيرَاتِ المستوفاة بـ $INFO > 0.8$ و $MAF > 0.01$.

الحلّ ٦.٣ ✓

```
for chr in {1..22}; do
\ plink2 --vcf chr${chr}.dose.vcf.gz dosage=DS/.
\ "extract-if-info "R2 > 0.8--
--make-pgen --out chr${chr}_filtered--
done
```

المخرجات المتوقعة:

```
Before: 8243110 variants
After INFO>0.8 & MAF>0.01: 6102488 variants
```

التفسير: من ٨,٢ مليون إلى ٦,١ مليون بعد الترشيح. dosage=DS يحافظ على الجرعة الاحتمالية (لا يحوّلها لنمطٍ صلب)، وهذا مهمٌ للحفاظ على معلومة عدم اليقين في التحليل اللاحق.

المسألة ٦.٤ ★★ [متوسط]

قارن تواتراتِ الأليلات بين بياناتك المستوفاة وgnomAD، واكشف التناقضات.

الحل ٦.٤ ✓

```
imp <- fread("chr1.info.gz")[, .(SNP, MAF_imp=MAF)]  
gnomad <- fread("gnomad_chr1.tsv")[, .(SNP, MAF_gnomad=AF)]  
m <- merge(imp, gnomad, by="SNP")  
m[, diff := abs(MAF_imp - MAF_gnomad)]  
aes(MAF_gnomad, MAF_imp) + geom_point(alpha=0.1)  
  geom_abline(color="red")  
discordant <- m[diff > 0.1]
```

المخرجات المتوقعة:

عدد المتغيرات المتناقضة (diff>0.1): 1847
معامل الارتباط: 0.991

التفسير: الارتباط العالي (٠,٩٩) يؤكّد جودة الاستيفاء عموماً. المتغيرات المتناقضة (١٢٨٤٧) قد تكون أخطاءً خيطاً أو اختلافاتٍ سكانيةً حقيقية (إن كانت عينتك مختلفةً عن مرجع gnomAD). نفحصها قبل الاعتماد عليها.

المسألة ٦.٥ ★★ [متوسط]

أجر استيفاءً محلياً بـ MINIMAC4 (حين لا تستطيع إرسال البيانات لخادم سحابي، كاليانات الحساسة).

الحل ٦.٥ ✓

الطورنة أولاً ثم الاستيفاء

```
--vcf=chr1.vcf.gz --geneticMapFile=genetic_map.txt  
outPrefix=chr1_phased--  
\ minimac4 --refHaps TOPMed_chr1.msav  
\ haps chr1_phased.vcf.gz--  
prefix chr1_imputed--
```

المخرجات المتوقعة:

```
Estimated Rsq distribution: mean=0.86  
Imputation finished: chr1_imputed.dose.vcf.gz
```

التفسير: الاستيفاء المحلي ضروري للبيانات الحساسة (مرضى، اتفاقيات خصوصية) التي لا يجوز رفعها لخوادم خارجية. MINIMAC4 يعطي النتائج نفسها لكن تحت سيطرتك الكاملة. يتطلب تنزيل لوحة TOPMed المرجعية محلياً (حجم كبير).

المسألة ٦.٦ ★★★ [متقدم]

قيم جودة الاستيفاء: ارسم توزيع INFO حسب فئة MAF.

الحلّ ٦.٦ ✓

```
info <- fread("all_chr.info.gz")
maf_bin := cut(MAF, breaks=c(0,0.01,0.05,0.1,0.5))
aes(maf_bin, Rsq)) + geom_boxplot(fill="#1B3A5C")
("INFO/Rsq درجة"=MAF", y فئة="x)labs
```

المخرجات المتوقعة: صناديق تُظهر أنّ INFO يرتفع مع MAF: المتغيّرات النادرة (MAF > ٠,٠١) متوسطُ INFO لها ~٠,٥، والشائعة (MAF < ٠,١) ~٠,٩٥.

التفسير: الاستيفاء أصعبُّ للنادر: قِلّةُ النسخ في المرجع تُضعفُ الثقة. لهذا نستخدمُ عتباتُ INFO أصرمُ للنادر (مثلاً ٠,٩) منها للشائع (٠,٨). هذه العلاقةُ أساسية لفهم أين نثق ببياناتك المستوفاة.

المسألة ٦.٧ ★★★ [متقدّم]

أنشئ خطَّ أنابيبٍ لمعالجة ما بعد الاستيفاء يعالج كلّ الكروموسومات بالتوازي.

الحلّ ٦.٧ ✓

```
bin/bash/!#
SBATCH --array=1-22#
chr=${SLURM_ARRAY_TASK_ID}
```



```
\ plink2 --vcf chr${chr}.dose.vcf.gz dosage=DS
\ extract-if-info "R2 > 0.8" --maf 0.01--
make-pgen --out chr${chr}_clean--
```

التفسير: مصفوفة SLURM (array=1-22--) تشغل ٢٢ مهمةً متوازية، واحدة لكل كروموسوم، فتختزل ساعاتٍ إلى دقائق. هذا النمط (التوازي حسب الكروموسوم) هو العمود الفقري لكل معالجة جينومية على HPC.

⚠ الأخطاء الشائعة وتصحيحها

Server rejects upload: build mismatch — حوّل الإحداثيات إلى البناء الصحيح (hg19 vs hg38) بـ Strand.liftOver
 errors at server — شغل أداة الفحص المسبق. INFO
 column named differently — TOPMed يسميها R2،
 آخرون أو Rsq أو INFO — dosage lost after filtering
 استخدم dosage=DS دائماً. — MINIMAC4 out of memory
 قسم الكروموسوم إلى نوافذ. Allele frequency mismatch
 with gnomAD — تأكد من تطابق الأصل السكاني بين عينتك والمرجع.
 liftOver drops variants — بعض المواضع لا تُترجم بين البناءين؛ طبيعي أن تفقد جزءاً صغيراً.

الغوص العميق

حين استوفينا عينات مرضى الكلى العرب في جامعة ميشيغان، اخترنا TOPMed بدلاً من HRC، والسبب جوهري: TOPMed لوحة أكثر تنوعاً (تضم أصولاً أفريقية وإسبانية وغيرها)، فأعطت درجات INFO أعلى لعيناتنا غير الأوروبية. مع HRC (الأوروبي بمعظمه)، كان كثير من المتغيرات الشائعة في العرب يُستوفى بثقة منخفضة لأنها نادرة أو غائبة في المرجع الأوروبي. هذا تجسيد آخر لفجوة التنوع: حتى المرجع نفسه متحيّز. تعلّمتُ أن أحص دائماً توزيع INFO داخل المجموعة العربية تحديداً، لا في العينة الكلية، لأن المتوسط الكلي قد يخفي ضعف الاستيفاء في الأقليات.

تحدٍ مفتوح

صمم تجربة تقيس كم يتحسن الاستيفاء للعرب عند إضافة بضع مئات من الجينومات العربية الكاملة إلى لوحة TOPMed، مقارنةً بـ TOPMed وحدها. عند أي حجم من العينات العربية المضافة يصبح التحسن في متوسط INFO ذا دلالةٍ عملية (مثلاً +0.05)؟ وهل التحسن أكبر للمتغيرات النادرة أم الشائعة؟

مراجع أساسية

Das S. et al. (2016). "Next-generation genotype imputation .Taliun D .Nature Genetics ".service (Michigan Imputation Server)

et al. (2021). "Sequencing of 53,831 diverse genomes from the
 Howie B. et al. (2012). "Fast *Nature*".NHLBI TOPMed Program
 Loh P.R. et *Nature Genetics*".and accurate genotype imputation
 al. (2016). "Reference-based phasing using the Haplotype
Nature Genetics".Reference Consortium (Eagle2)

الفصل السابع — اختبارات الارتباط الأساسية بـ

PLINK2 / Basic Association Testing

with PLINK2

﴿إِنَّ اللَّهَ يَأْمُرُ بِالْعَدْلِ وَالْإِحْسَانِ﴾

— سورة النحل: ٩٠

العدل أن نقارن المتكافئ بالمتكافئ؛ واختبار الارتباط، إن ضبط بالمتغيرات المشتركة، عدل إحصائي يضمن أن ما ننسبه للجين جين حقاً، لا أثر عمر أو أصلٍ خفيّ.

 سيناريو بحثي

لديك ٥٠٠٠ عينة (٢٠٠٠ حالة، ٣٠٠٠ ضابط) للسكري من النوع الثاني. مهمتك إجراء GWAS أساسي بانحدار PLINK2 اللوجستي. هذا أول تحليل ارتباط حقيقي في الكتاب — كل ما سبقه كان تجهيزاً. ستعلم هنا كيف تصوغ ملفات الصفات والمتغيرات، وتفسر أعمدة المخرجات، وتختار النموذج الجيني المناسب.

PLINK2 سريعٌ وكافٍ للعينات المتوسطة غير المترابطة. حين تكبر العينة أو تظهر القرابة، تنتقل إلى REGENIE و SAIGE (الفصلان ٨ و ٩). لكنّ فهم PLINK2 أساس لفهمهما.

مجموعة البيانات لهذا الفصل

```
# بيانات 5000 T2D: عينة + ملف صفات + ملف متغيرات م  
pheno.txt: FID IID T2D #  
covar.txt: FID IID AGE SEX PC1..PC10 #  
m --pheno pheno.txt --covar covar.txt --out gwas/.
```

أهداف التعلم

بعد هذا الفصل تستطيع: (١) صياغة ملفات الصفات والمتغيرات؛ (٢) انحذاراً لوجستياً للصفة الثنائية؛ (٣) انحذاراً خطياً للمتصلة؛ (٤) إضافة المتغيرات المشتركة؛ (٥) اختبار النماذج الثلاثة؛ (٦) التحليل الشرطي؛ (٧) GWAS مطبقاً بالجنس.

الخلفية الأساسية

الانحدار اللوجستي يُمذج لوغاريتمَ أَرَحِيَةِ المرض كدالةٍ خطية:

$$= \left(\frac{P-1}{P} \right) \log \left(\frac{\beta_0 + \beta_G \cdot G + \sum \beta_k X_k}{\beta_0 + \beta_G \cdot G + \sum \beta_k X_k} \right)$$

حيث β_G أثر الجين (لو غار يتم نسبة الأريحية)، و X_k المتغيرات المشتركة. نسبة الأريحية $e^{\beta_G} =$.

تشبيه: الانحدار كميزان يزن مساهمة كل عاملٍ على حدة. حين تسأل "هل هذا الأليل يرفع الخطر؟"، يجيب الانحدار بعد أن "يثبت" العمر والجنس والأصل — كأنه يسأل: لو تساوى شخصان في كل شيءٍ إلا هذا الأليل، كم يختلف خطرهما؟

؟ المسائل

المسألة ٧.١ ★ [مبتدئ]

صُغ ملفات الصفة والمتغيرات بشكلٍ صحيح. ما الأخطاء الشائعة وكيف تتجنبها؟

الحل ٧.١ ✓

```
head -2 pheno.txt
```

```
FID IID T2D #
```

```
fam1 ind1 2 #
```

```
head -2 covar.txt
```

```
FID IID AGE SEX PC1 PC2 ... PC10 #
```

التفسير: العمودان الأولان دائماً FID و IID بالترتيب نفسه عبر كلّ الملفات.
 الترميز الافتراضيّ للحالة في PLINK هو ١=ضابط و ٢=حالة (٠.٠/-٩=مفقود)؛
 لاستخدام ٠/١ أضف --1. انلطأ الأشهر: ترميز مختلط أو رؤوس أعمدة
 خاطئة.

المسألة ٧.٢ ★ [مبتدئ]

أجر انحداراً لوجستياً للصفة الثنائية، وفّر أعمدة المخرجات.

✓ الحلّ ٧.٢

```
e t2d_qc --glm --pheno pheno.txt --pheno-name T2D/.  
covar covar.txt --out gwas_logistic--
```

المخرجات المتوقعة (تمثيلية):

FROM	POS	ID	A1	OR	SE	Z_STAT	P#
46	T	1.37	0.021	15.2	4.1e-52	114758	10

التفسير: A1 أليل التأثير، OR=١,٣٧ يعني أنّ كلّ نسخةٍ من T ترفع أُرحيةً
 السكّري ٣٧٪، SE انلطأ المعياريّ، Z_STAT إحصاء الاختبار،
 $P = 1.0 \times 10^{-52}$ دلالةٌ جينومية ساحقة. هذا rs7903146 في جين TCF7L2
 — أقوى متغيّرٍ شائعٍ معروفٍ للسكّري.

المسألة ٧.٣ ★ [مبتدئ]

أجر انحداراً خطياً لصفةٍ متّصلة (eGFR)، وفّر الفرق في المخرجات.

✓ الحلّ ٧.٣

```
ldsc --bfile kidney_qc --glm --pheno egfr.txt --pheno-name eGFR/.  
covar covar.txt --out gwas_linear--
```

المخرجات المتوقعة:

CHROM	POS	ID	A1	BETA	SE	T_STAT	P#
017707	T	-1.24	0.18	-6.9	5e-12	20392	16

التفسير: الفرق الجوهري: للصفة المتّصلة نحصل على BETA (لا OR).
BETA=-١,٢٤ يعني أنّ كلّ نسخةٍ من T تخفض eGFR بمقدار ١,٢٤ وحدة. هذا rs12917707 قرب جين UMOD — أشهر إشارةٍ لوظيفة الكلى.

المسألة ٧.٤ ★★ [متوسط]

أضف المتغيّرات المشتركة (العمر، الجنس، ١٠ مكوّنات)، وقارن مخطّطي مانهاتن قبل وبعد.

الحلّ ٧.٤ ✓

```
# بدون متغيرات
m allow-no-covars --pheno pheno.txt --out no_cov/.

# مع متغيرات
-pheno pheno.txt --covar covar.txt --out with_cov/.

# مقارنة  $\lambda$ 
function(p) median(qchisq(1-p, 1)) / qchisq(0.5, 1)
c(no_cov=lambda(fread("no_cov.T2D.glm.logistic"))$P)
_cov=lambda(fread("with_cov.T2D.glm.logistic"))$P)
```

المخرجات المتوقعة:

no_cov	with_cov
1.03	1.21

التفسير: بدون ضبط المكوّنات، $\lambda = 1.21$ (تضخّم من التقسيم السكّاني).
بإضافة المكوّنات، هبط إلى ١.٠٣. مخطّط مانهاتن "قبل" مليءً بإشاراتٍ كاذبةٍ
منتشرة، و"بعد" نظيفٌ بأبراجٍ حقيقيةٍ معزولة. هذا أوضحُ برهانٍ على ضرورة
الضبط.

المسألة ٧.٥ ★★ [متوسط]

اختبر النماذج الثلاثة (جمعيّ، سائد، متنحّ). متى يهّم اختيار النموذج؟

✓ الحلّ ٧.٥

```
t2d_qc --glm --pheno pheno.txt --covar covar.txt/.  
genotypic --out gwas_models--
```

المخرجات المتوقّعة:

	TEST	OR	P
(جمعيّ)	ADD	1.37	4e-52
(انحراف سيادي غير معنويّ)	DOMDEV	1.02	0.78

التفسير: النموذجُ الجمعيّ (كلّ نسخة تضيف أثراً ثابتاً) هو الافتراضيّ ويكفي لمعظم المتغيّرات. عدمُ معنوية DOMDEV يؤكّد أنّ الأثر جمعيّ. النموذجُ المتنحّي يهّم فقط حين يحتاج الأثرُ نسختين (نادر)، كبعض أمراض المناعة. اختبارُ نماذج كثيرة يزيد عبء الاختبارات المتعدّدة.

المسألة ٧.٦ ★★★ [متقدّم]

أجر تحليلًا شرطياً: اشترط على إشارة معروفة والبحث عن إشاراتٍ مستقلة.

الحلّ ٧.٦ ✓

```
t2d_qc --glm --pheno pheno.txt --covar covar.txt/.  
condition rs7903146 --out conditional--
```

المخرجات المتوقعة:

```
# قبل الاشتراط: قمة عند (P=4e-52) rs7903146  
# بعد الاشتراط: rs7903146 يختفي، لكن rs7901695 يبقى
```

التفسير: بإدخال rs7903146 كمتغيرٍ مشترك، نَسأل: هل توجد إشارةً مستقلةً عنه في المنطقة؟ بقاء rs7901695 معنوياً يعني وجودَ إشارةٍ ثانيةٍ منفصلة (allelic heterogeneity) — اكتشافٌ مهمٌ يكشف بنيةً معقدةً للموضع.

المسألة ٧.٧ ★★★ [متقدم]

أجر GWAS مطبقاً بالجنس، واختبر التباينَ، وارسم المقارنة.

الحلّ ٧.٧ ✓

```
ales.txt --glm --pheno pheno.txt --out males_gwas/.  
es.txt --glm --pheno pheno.txt --out females_gwas/.
```

```
# اختبار التباين بين الجنسين
s.T2D.glm.logistic"); f <- fread("females_gwas...")
d <- merge(m, f, by="ID", suffixes=c("_m", "_f"))
t := (log(OR_m)-log(OR_f)) / sqrt(SE_m^2 + SE_f^2)]
d[, p_het := 2*pnorm(-abs(z_het)))]
# متغيرات ذات أثر مختلف بين الجنس
```

التفسير: اختبار التباين يكشف المتغيرات التي يختلف أثرها بين الذكور والإناث (أثر خاص بالجنس). نادرة لكنها مثيرة بيولوجياً – قد تشير إلى تفاعل هرموني. رسم OR_m مقابل OR_f يظهر المتغيرات الشاذة عن الخط القطري.

⚠ الأخطاء الشائعة وتصحيحها

All p-values are NA – الصفة ثابتة أو الترميز خاطئ؛ تحقق من
 ١٠٪ مع --FID/IID – Covariate file mismatch.
 تطابق؛ رتب الملفات. Quasi-separation warning – متغير
 نادر يفصل الحالات تماماً؛ احذفه أو استخدم Firth --glm firth
 lambda too high – أضف مكونات أو انتقل لنموذج مختلط. --
 condition variant not found – تأكد من وجود المتغير
 في البيانات. OR vs BETA confusion – اللوجستي يعطي OR،
 الخطي BETA.

📖 الغوص العميق

في عملي على GWAS الكلي بجامعة ميشيغان، أبدأ دائماً بـ PLINK2 خطوة استكشافية سريعة قبل النماذج الثقيلة. درس مهم تعلمته: انحدار Firth (glm firth-fallback) منقذ للمتغيرات النادرة في الحالات المختلة التوازن. حين تكون الحالات قليلةً وأليل الخطر نادراً، يفشل الانحدار اللوجستي العادي (انفصال شبه تام) ويعطي نسب أرجحية خيالية ($OR = 10^6$ مثلاً). Firth يصحح هذا بالتحياز مدروس. كذلك تعلمت أن متغير UMOD (rs12917707) يظهر في كل تحليل لوظيفة الكلى نُجريه تقريباً، حتى صار "اختبار سلامة" داخلياً: إن لم يظهر UMOD، فثمة خطأ في خط الأنابيب.

🔧 تحدّ مفتوح

صمم محاكاة تحدّد عند أي حجم عينة وأي نسبة اختلال (حالات:ضوابط) يبدأ انحدار PLINK2 اللوجستي العادي في إعطاء نتائج متضخمة مقارنةً بـ Firth وبـ SAIGE. ارسم "خريطة قرار" تخبر الباحث متى يكفي PLINK2 ومتى يجب الانتقال.

📖 مراجع أساسية

"Chang C.C. et al. (2015). "Second-generation PLINK
Mahajan A. et al. (2022). "Multi-ancestry genetic .GigaScience

- *Nature Genetics* ".study of type 2 diabetes (DIAMANTE)
Grant S.F. et al. (2006). "Variant of GWAS للسكري.
.Ma C *Nature Genetics* ".TCF7L2 confers risk of type 2 diabetes
et al. (2013). "Recommended joint and meta-analysis strategies
. *Genet Epidemiol* ".(Firth)

الفصل الثامن — REGENIE: نموذج الانحدار على

مستوى الجينوم / REGENIE: Whole

Genome Regression

﴿وَوَجَدَكَ ضَالًّا فَهَدَى﴾

— سورة الضحى: ٧

من التيه إلى الهدى؛ وحين نتضمّم نتائج GWAS بسبب القرابة الخفية $(\lambda=1,18)$ ، يكون انحدار PLINK2 تائهاً، و REGENIE هو الهداية: نموذجٌ يحتضن القرابة بدل أن يتعثر بها.

 سيناريو بحثي

نمت مجموعتك إلى ٥٠,٠٠٠ عينة بقرابة خفية. انحدار PLINK2 اللوجستي القياسي متضخم $(\lambda=1,18)$ لأنه يفترض استقلال العينات — اقترأ يكسره وجود أقارب. الحل: REGENIE، الذي يَمدج القرابة ضمناً عبر تنبؤ متعدد الجينات، فيضبط التضخم دون أن يفقد القوة.

REGENIE يعمل على خطوتين: الأولى تبني تنبؤات متعددة الجينات بطريقة "ترك كروموسوم واحد" (LOCO)؛ الثانية تختبر كل متغير مع إدخال تنبؤ LOCO كمتغير مشترك. هذا الفصل العمود الفقري لـ GWAS واسع النطاق.

مجموعة البيانات لهذا الفصل

50K عينة، صفات ثنائية ومتصلة

الخطوة 1 على متغيرات منمطة عالية الجودة، الخطوة 2

أهداف التعلم

بعد هذا الفصل تستطيع: (١) فهم الخطوة ١ و LOCO؛ (٢) تشغيلها لصفة متصلة؛ (٣) الخطوة ٢ على النمط؛ (٤) الخطوة ٢ على BGEN المستوفى؛ (٥) صفات متعددة؛ (٦) تحسين HPC؛ (٧) مقارنة قبل/بعد.

الخلفية الأساسية

REGENIE في الخطوة ١ يلائم انحدار ridge متعدد الجينات: يقسم الجينوم إلى كتل، يحسب تنبؤات لكل كتلة، ثم يجمعها. تنبؤ LOCO لكروموسوم c يحسب من كل الكروموسومات عدا c:

$$k_{\text{LOCO}} = \text{LOCO}(c)$$

إدخالُ هذا التنبؤ كمتغيّرٍ مشتركٍ في الخطوة ٢ يمتصّ أثرَ القرابة والبنية متعددة الجينات.

تشبيه: LOCO كاختبارٍ في مدرسةٍ تمنع الغشّ. حين تختبر كروموسوماً، تُخفي عنه إجاباتٍ نفسه (تستبعده من التنبؤ) لتمنع "التلوّث القريب" — أن يتنبأ المتغيّر بنفسه عبر جيرانه في LD، فيضخم القوة زيفاً. كلُّ كروموسومٍ يُختبرَ بمعلوماتٍ من إخوته لا من نفسه.

؟ المسائل

المسألة ٨٠١ ★ [مبتدئ]

افهم الخطوة ١ (ridge و LOCO) وشغلها لصفةٍ ثنائية.

الحلّ ٨٠١ 

```
\ regenie --step 1 --bed array_qc --bt/.  
\ phenoFile pheno.txt --phenoCol T2D--  
File covar.txt --covarColList AGE,SEX,PC1-PC10--  
bsize 1000 --lowmem --out fit_bin--
```

المخرجات المتوقعة:

```

Number of individuals: 50000
Level 0 ridge: 5 parameters
Level 1 ridge: cross-validated, best lambda selected
Output: fit_bin_pred.list, fit_bin_1.loco ... _22.loco

```

التفسير: المستوى ٠ يلائم ridge داخل كَلِّ صغيرة، والمستوى ١ يجمعها بتحقّقٍ متقاطع. ملفات .loco (واحد لكل كروموسوم) هي ثمرة الخطوة ١، تُغذى للخطوة ٢. lowmem-- يقلّل استهلاك الذاكرة للعينات الكبيرة.

المسألة ٨.٢ ★ [مبتدئ]

شغل الخطوة ١ لصفة متّصلة (eGFR)، وقارن بالثنائية.

الحل ٨.٢ ✓

```

\ regenie --step 1 --bed array_qc/.
\ phenoFile egfr.txt --phenoCol eGFR--
\ covarFile covar.txt --covarColList AGE,SEX,PC1-PC10--
bsize 1000 --out fit_qt--

```

التفسير: الفرق الوحيد: حذف --bt (الافتراض صفة متّصلة). REGENIE للصفة المتّصلة يستخدم انحداراً خطيّاً في النموذج اللاحق. بنية مخرجات LOCO نفسها. الصفات المتّصلة أسرع حساباً لأنّها لا تحتاج تقريب Saddlepoint.

المسألة ٨.٣ ★★ [متوسط]

أجر الخطوة ٢ (اختبار الارتباط) على المتغيرات النمّطة، وصورّ المخرجات.

✓ الحلّ ٨.٣

```
\ regenie --step 2 --bed array_qc --bt/.
\ phenoFile pheno.txt --phenoCol T2D--
File covar.txt --covarColList AGE,SEX,PC1-PC10--
fit_bin_pred.list --bsize 400 --firth --approx--
out test_bin--
```

المخرجات المتوقعة:

	ALLELE0	ALLELE1	A1FREQ	BETA	SE	LOG10P
T	0.30	0.31	0.02	51.4	114758	10

التفسير: $\text{LOG10P} = 51.4$ يعني $p = 10^{-51.4}$. REGENIE يُخرج LOG10P

بدل P لتجنّب التدفق العدديّ عند القيم الصغيرة جداً. -- firth--

approx يطبّق تصحيح Firth السريع للصفات المختلّة التوازن.

المسألة ٨٠٤ ★★ [متوسط]

أجرِ الخطوة ٢ على ملفات BGEN المستوفاة لـ ٨ ملايين متغيّر، مع التقسيم بالكروموسوم.

الحلّ ٨٠٤ ✓

```
for chr in {1..22}; do
    regenie --step 2 --bgen chr${chr}.bgen --ref-first/.
    \ sample chr${chr}.sample --bt--
    \ phenoFile pheno.txt --phenoCol T2D--
    \ test_bin_pred.list --bsize 400 --firth --approx--
    out test_chr${chr}--
done
```

التفسير: نمرّر كلّ كروموسومٍ على حدة (التوازي). `--ref-first` حرجٌ لتحديد الأليل المرجعيّ في BGEN. REGENIE يقرأ الجرعات الاحتمالية مباشرةً من BGEN، محافظاً على معلومة عدم اليقين من الاستيفاء.

المسألة ٨٠٥ ★★★ [متقدّم]

أجرِ REGENIE متعدّد الصفات: ٥ صفاتٍ كلوية معاً، وقارن الزمن بالصفة المفردة.

الحل ٨.٥ ✓

```
\ regenie --step 1 --bed array_qc/.  
  \ phenoFile kidney_phenos.txt--  
  \ phenoColList eGFR,UACR,BUN,Creatinine,CKD--  
rFile covar.txt --covarColList AGE,SEX,PC1-PC10--  
      bsize 1000 --out fit_multi--
```

المخرجات المتوقعة:

```
phenotypes processed simultaneously 5  
Runtime: 1.4× single phenotype (not 5×)
```

التفسير: الميزة الكبرى: معالجة ٥ صفات تستغرق ١,٤ ضعفِ صفةٍ واحدة فقط، لا ٥ أضعاف، لأنّ REGENIE يعيد استخدام العمليات المصفوفية المشتركة. هذا مثالي للبنوك الحيوية ذات الصفات الكثيرة.

المسألة ٨.٦ ★★★ [متقدّم]

حسن REGENIE لـ HPC: تقديم متوازٍ، ضبط --bsize، متطلبات الذاكرة.

الحلّ ٨.٦ ✓

```
SBATCH --array=1-22 --mem=16G --cpus-per-task=8#
chr=${SLURM_ARRAY_TASK_ID}
regenie --step 2 --bgen chr${chr}.bgen --threads 8/.
bsize 400 --pred fit_pred.list --out chr${chr}--
```

التفسير: --bsize يوازن بين السرعة والذاكرة: أكبر = أسرع لكن ذاكرة أكثر. ٤٠٠ قيمة جيّدة للخطوة ٠.٢ --threads 8 يستغلّ النوى. مصفوفة SLURM توازي الكروموسومات. القاعدة: الخطوة ١ تحتاج ذاكرة أكثر (كلّ الجينوم)، الخطوة ٢ أقلّ.

المسألة ٨.٧ ★★★★★ [خير]

قارن نتائج REGENIE قبل/بعد: قيم λ ، مخططات QQ، ارتباط تقديرات .beta

الحلّ ٨.٧ ✓

```
plink <- fread("plink_gwas.logistic")
regenie <- fread("regenie_test.regenie")
d <- merge(plink, regenie, by="ID")
# ارتباط التقدير cor(d$BETA_plink, d$BETA_regenie)
```

λ لكل

```
plink <- median(qchisq(1-d$P_plink,1))/qchisq(0.5,1)  
k <- median(qchisq(1-10^(-d$LOG10P),1))/qchisq(0.5,1)
```

المخرجات المتوقعة:

ارتباط β : 0.94

λ PLINK: 1.18 λ REGENIE: 1.02

التفسير: تقديرات β مرتبطة بقوة (0.94) — REGENIE لا يغيّر
الإشارات الحقيقية، بل يصحّح التضخم. λ هبط من 1.18 إلى 1.02؛
REGENIE امتصّ القرابة والبنية متعددة الجينات. مخطط QQ "بعد" يلتصق
بالخط القطري حتى الذيل.

⚠ الأخطاء الشائعة وتصحيحها

1 Step 2 needs pred file from step 1 — مرّر --
LOG10P not P.pred REGENIE يُخرج LOG10P؛ حول بـ
10 (LOG10P)^--firth slow — أضف --approx للتقريب
السرّيع. bsize too large: out of memory. — قلّل --
phenotype not found.bsize — تطابق أسماء الأعمدة.
BGEN ref allele wrong — استخدم --ref-first أو

--last-ref حسب ملفك. Step 1 very slow — قلل عدد
متغيرات الخطوة ١ (النمطة عالية الجودة تكفي).

📖 الغوص العميق

شغلت REGENIE على GWAS الكلي لـ ٧٠,٠٠٠ عينة في جامعة ميشيغان،
وكان قرار نقله نوعية. التقريب القطري الكلي في (block REGENIE-
diagonal approximation) هو سرُّ سرعته: بدل عكس مصفوفة قرابة ضخمة
(٧٠ ألف × ٧٠ ألف، مستحيل ذاكرياً)، يقسم المشكلة إلى كتل قابلة للحل. لكن
هذا التقريب قد "يفوت" قرابة بعيدة المدى دقيقة في حالات نادرة. تعلت أن
أتحقق دائماً بمقارنة λ مع SAIGE في عينة فرعية. في معظم تحليلاتنا،
REGENIE و SAIGE يتطابقان عملياً، لكن REGENIE أسرع بمرات
للصفات المتعددة — وهذا حاسم حين نحلل عشرات الصفات الكلوية معاً.

🔑 تحدّ مفتوح

صمّم تجربة تقيس متى يبدأ التقريب القطري الكلي في REGENIE في
الانحراف عن SAIGE الدقيق: غير درجة القرابة في عينات محاكاة (من غرباء
إلى مجتمع شديد الاختلاط الداخلي)، وارصد عند أي مستوى قرابة يبدأ الفرق
في λ يتجاوز ٠.٠٢. هل المجتمعات العربية عالية زواج الأقارب ضمن النطاق
الآمن لـ REGENIE؟

- Mbatches J. et al. (2021). "Computationally efficient whole genome regression for quantitative and binary traits
- Loh P.R. et al. (2018). "Mixed *Nature Genetics*".(REGENIE)
- ".model association for biobank-scale datasets (BOLT-LMM)
- Wuttke M. et al. (2019). "Catalog of genetic loci *Nature Genetics*
- .Yang J. et al. (2014) *Nature Genetics*".for kidney function
- Nature* ".Advantages and pitfalls of mixed linear models"
- .*Genetics*

الفصل التاسع — SAIGE: النماذج المختلطة للبيانات SAIGE: Mixed Models for / غير المتوازنة / Imbalanced Data

﴿وَلَا تَيْأَسُوا مِنْ رَوْحِ اللَّهِ﴾

— سورة يوسف: ٨٧

لا تَيْأَس حين تبدو الحالاتُ ضئيلةً أمام بحرٍ من الضوابط؛ فحيث يفشل غيره، يأتي SAIGE بروحٍ من الحلّ: تقريبُ Saddlepoint الذي ينقذ الاختبارَ من التضخم في أشدّ حالات الاختلال.

 سيناريو بحثي

دراستك للقصور الكلوّي المزمّن مختلةً بشدّة: ١٥٠٠ حالة مقابل ٤٨٥٠٠ ضابط (نسبة ١:٣٢). REGENIE — رغم قوّته — قد يعطي قيمَ p متضخّمةً للمتغيّرات النادرة في هذا الاختلال، لأنّ تقريبه الطبيعي يفترض توزيعاً متماثلاً. الحلّ: SAIGE، الذي يستخدم تقريبَ (SPA) Saddlepoint لتصحيح ذيل التوزيع غير المتماثل.

SAIGE يجمع ميزتين: نموذجٌ مختلطٌ لوجستيّ (يضبط القِراءة) + تصحيحُ SPA (يضبط الاختلال). هذا يجعله المعيارَ الذهبيّ للأمراض النادرة في البنوك الحيويّة.

مجموعة البيانات لهذا الفصل

1500 CKD: حالة ، 48500 ضابط، مستوفاة + GRM متناثر

أهداف التعلّم

بعد هذا الفصل تستطيع: (١) ملء مة النموذج الصفرى؛ (٢) اختبارات مفردة على chr22؛ (٣) جينوماً كاملاً متوازياً؛ (٤) صفةً متّصلة؛ (٥) تفسير مخرجات SAIGE؛ (٦) SAIGE-GENE للنادر؛ (٧) SAIGE-GENE + متعدد الصفات؛ (٨) مقارنةً ثلاثية.

الخلفية الأساسية

في الاختلال الشديد، توزيع إحصاء الاختبار يخرف عن التماثل، فيعطي الانحدار العاديّ قيمَ p متضخّمة في الذيل. تقريّب Saddlepoint يقرب دالة توليد العزوم لإعادة بناء الذيل بدقّة:

$$P(S > s) \approx \text{SPA}(K(t), s)$$

حيث $SK(t)$ دالة توليد العزوم اللوغاريتمية. هذا يصحّ القيم المتطرفة حيث يفشل التقريب الطبيعي.

تشبيه: الانحدار الطبيعي كمسطرة مستقيمة تقيس بدقة قرب المنتصف لكنها تنحرف عند الأطراف. SPA كمسطرة منحنية تتبع الانحناء الحقيقي للتوزيع عند الأطراف (القيم الصغيرة جداً لـ p) - وهي بالضبط حيث نحتاج الدقة في GWAS.

؟ المسائل

المسألة ٩.١ ★ [مبتدئ]

لائم نموذج SAIGE الصفري لصفة ثنائية، وافهم تقدير نسبة التباين.

الحل ٩.١ ✓

```
\ step1_fitNULLGLMM.R
\ plinkFile=array_qc--
\ phenoFile=pheno.txt --phenoCol=CKD--
\ covarColList=AGE,SEX,PC1,PC2,PC3,PC4--
\ traitType=binary--
outputPrefix=ckd_null --nThreads=8--
```

المخرجات المتوقعة:

Variance component estimate (tau): 0.18

Variance ratio estimate: 0.992

d. Output: ckd_null.rda, ckd_null.varianceRatio.txt

التفسير: tau مكونُ التباين الجينيّ (القرابة). نسبةُ التباين (٠,٩٩٢) معايِرةٌ تسمح لـ SAIGE بحساب الاختبارات بسرعة على مستوى الجينوم دون عكس GRM كاملةٍ لكلِّ متغيّر. هذا التقريبُ هو سرُّ كفاءته.

المسألة ٩.٢ ★ [مبتدئ]

أجر اختباراتٍ مفردة على chr22، وتحقق مقابل PLINK2.

الحلّ ٩.٢ ✓

```
\ step2_SPAtests.R
\ bgenFile=chr22.bgen --sampleFile=chr22.sample--
\ GMMATmodelFile=ckd_null.rda--
\ varianceRatioFile=ckd_null.varianceRatio.txt--
SAIGEOutputFile=ckd_chr22.txt --minMAF=0.01--
```

المخرجات المتوقعة:

Allele2	AC_Allele2	AF_Allele2	BETA	SE	p.value
820	0.018	0.42	0.09	2.1e-6	20392 22

التفسير: عمود p.value مصححٌ بـ SPA. في المتغيرات النادرة، تكون p هنا أكبر (أقلّ تضخّماً) منها في PLINK العاديّ — وهذا هو التصحيح. AF_Allele2 تواتر الأليل المختبر.

المسألة ٩.٣ ★★ [متوسط]

أجر SAIGE على الجينوم الكامل متوازياً، وادمج النتائج.

الحلّ ٩.٣ 

```

SBATCH --array=1-22#
chr=$SLURM_ARRAY_TASK_ID
\ step2_SPAtests.R --bgenFile=chr${chr}.bgen
\ GMMATmodelFile=ckd_null.rda--
\ varianceRatioFile=ckd_null.varianceRatio.txt--
SAIGEOuputFile=ckd_chr${chr}.txt--
# الدمج:
cat ckd_chr*.txt > ckd_all.txt

```

التفسير: النموذج الصفريّ يلائم مرّةً واحدة، ثمّ يُعاد استخدامه عبر كلّ الكروموسومات المتوازية. هذا الفصلُ بين الخطوتين (نموذجٌ ثقيلٌ مرّةً، اختباراتٌ خفيفةٌ كثيرة) هو نمطٌ كلّ أدوات النماذج المختلطة الحديثة.

المسألة ٩.٤ ★★ [متوسط]

أجر SAIGE لصفةٍ متّصلة، وقارن بـ REGENIE للصفة نفسها.

الحلّ ٩.٤ ✓

```
\ step1_fitNULLGLMM.R --traitType=quantitative
  \ phenoCol=eGFR --invNormalize=TRUE--
plinkFile=array_qc --outputPrefix=egfr_null--
```

التفسير: --invNormalize=TRUE يطبّق التحويل الطبيعيّ العكسيّ للرتب، مفيدٌ للصفات غير الطبيعية. لصفةٍ متّصلةٍ متوازنة، SAIGE وREGENIE يعطيان نتائجَ شبه متطابقة؛ ميزة SAIGE تظهر أساساً في الصفات الثنائية المختلّة.

المسألة ٩.٥ ★★ [متوسط]

فسّر مخرجات SAIGE الخاصّة: تواتر الأليل في الحالات مقابل الضوابط.

الحلّ ٩.٥ ✓

```
saige <- fread("ckd_all.txt")  
# SAIGE يُخرج AF منفصلاً للحالات والضوابط عند الطلب  
AF_case, AF_ctrl, BETA, p.value)[p.value < 5e-8]
```

المخرجات المتوقعة:

SNPID	AF_case	AF_ctrl	BETA	p.value
rs77924	0.045	0.021	0.78	3e-11

التفسير: تواتر الأليل أعلى في الحالات (٠,٠٤٥) منه في الضوابط (٠,٠٢١) — اتّسق مع BETA الموجب. هذه المقارنةُ المباشرةُ تساعد على فهم اتجاه الأثر وحجمه، وتكشف الأخطاء (لو كان BETA موجباً لكن التواتر أعلى في الضوابط، فتُمة مشكلة).

المسألة ٩.٦ ★★★ [متقدّم]

أجر SAIGE-GENE: اختبار عبء على مستوى الجين للمتغيرات النادرة، مع تجهيز ملفّ التجميع.

الحل ٩.٦ ✓

```
\ step2_SPAtests.R --bgenFile=exome.bgen
\ GMMATmodelFile=ckd_null.rda--
\ groupFile=gene_groups.txt--
\ annotation_in_groupTest=lof,missense--
\ maxMAF_in_groupTest=0.01--
SAIGEOutputFile=ckd_gene.txt--
```

المخرجات المتوقعة:

Gene	Pvalue_Burden	Pvalue_SKAT	Pvalue_SKATO
PKD1	1.2e-8	3e-7	4e-8

التفسير: ملف المجموعات يربط كل متغيرٍ نادرٍ بجينهِ. SAIGE-GENE يجمع المتغيرات النادرة داخل الجين في اختبارٍ واحد (عبء/SKAT/SKAT-O)، الفصل ١٦). PKD1 (جين مرض الكلى المتعدد الكيسات) يظهر معنوياً — مثالٌ كلاسيكيٌّ على إشارةٍ نادرةٍ قوية.

المسألة ٩.٧ ★★★ [متقدم]

أجرِ SAIGE-GENE + متعدد الصفات في آنٍ واحد.

الحلّ ٩.٧ ✓

```
\ step1_fitNULLGLMM.R --phenoColList=CKD,eGFR,UACR  
\ traitType=binary,quantitative,quantitative--  
outputPrefix=multi_null--
```

التفسير: SAIGE-Gene + يختبر مجموعات الجينات عبر صفات متعددة معاً،
فيزيد القوة باستغلال الارتباط بين الصفات. مفيدٌ حين تكون الصفات مترابطةً
بيولوجياً (كصفات الكلى الثلاث).

المسألة ٩.٨ ★★★★★ [خبير]

قارن وجهاً لوجه: SAIGE مقابل REGENIE مقابل PLINK2 على البيانات
نفسها — ثلاثة مخططات مانهاتن، مقارنة λ ، جدول زمن الحساب.

الحلّ ٩.٨ ✓

```
tools <- c("PLINK2", "REGENIE", "SAIGE")  
lambda <- c(1.24, 1.04, 1.01)  
runtime_min <- c(15, 95, 320)  
le(Tool=tools, Lambda=lambda, Runtime=runtime_min)
```

المخرجات المتوقعة:

Tool	Lambda	Runtime (min)
PLINK2	1.24	15
REGENIE	1.04	95
SAIGE	1.01	320

التفسير: المفاضلة واضحة: PLINK2 أسرع لكنه متضخم في الاختلال الشديد. SAIGE الأدق ($\lambda=1.01$) لكنه الأبطأ. REGENIE وسطٌ ممتاز. القاعدة: PLINK2 للاستكشاف، REGENIE للصفات المتعددة المتوازنة نسبياً، SAIGE للأمراض النادرة شديدة الاختلال.

⚠ الأخطاء الشائعة وتصحيحها

Variance ratio estimation fails — قَلَّ عدد المتغيرات في تقدير النسبة أو زِد العينة. SPA does not converge — متغير نادر جداً ($MAC > 5$)؛ ارفع --minMAC groupFile. format error — تحقق من تنسيق ملف المجموعات (متغير، تعليق). Memory error in null model — استخدم GRM متناثرة p.value inflated despite --sparseGRMFile. SAIGE — تحقق من المكونات الرئيسية في النموذج الصفري. Docker needed — كثير يُفضّل صورة SAIGE الرسمية لتجنب مشاكل التثبيت.

📖 الغوص العميق

في دراسة القصور الكلوي بجامعة ميشيغان، كان الاختلالُ مشكلتنا الكبرى: الحالاتُ المؤكَّدة قليلةٌ والضوابطُ كثيرة. أوَّلَ ما جربنا PLINK2، ظهرت "اكتشافاتٌ" نادرةٌ كثيرة بقيم p خياليةٍ صغيرة — كلُّها كاذبة، ناتجةٌ عن فشل التقريب الطبيعيِّ في الذيل عند الاختلال. SAIGE صحَّحها جميعاً: تجرَّت الإشاراتُ الزائفة وبقيت الحقيقية. الدرسُ العمليُّ الذي رسخ: في كلِّ مرضٍ نادرٍ بنسبة اختلالٍ تتجاوز ١:١٠، SAIGE ليس خياراً بل ضرورة. تعلَّمتُ أيضاً أنَّ SAIGE-GENE فتح لنا بابَ المتغيَّرات النادرة (الفصل ١٦)؛ فحين PKD1 وأقاربه لا يظهرون في GWAS الشائع، لكنهم يبرزون في اختبار العبء الجيني.

🔧 تحدِّ مفتوح

صمِّم محاكاةً ترسم "حدودَ الاختلال": عند أيِّ نسبةٍ حالات:ضوابط وأيِّ MAF يصبح الفرقُ بين PLINK2 و SAIGE في معدَّل الخطأ من النوع الأوَّل ذا دلالةٍ عملية؟ ابن خريطةً ثنائية المحاور (الاختلال $\times$ MAF) تلوِّن المناطق التي يكفي فيها PLINK2 والتي يجب فيها SAIGE. أين تقع دراساتُ الأمراض النادرة العربية على هذه الخريطة؟

- Zhou W. et al. (2018). "Efficiently controlling for case-control
imbalance and sample relatedness (SAIGE)
".*Nature Genetics*
- Zhou W. et al. (2020). "Scalable generalized linear mixed model
for region-based tests (SAIGE-GENE)
".Dey R. *Nature Genetics*
- et al. (2017). "Saddlepoint approximation for sequence
association tests
- Lee S. et al. (2012). "Optimal tests for *AJHG*
".*Biostatistics* rare variant effects (SKAT-O)

الفصل العاشر — تصحيح الاختبارات المتعددة

Multiple Testing and / والقوة الإحصائية

Power

﴿وَلَا تَقْفُ مَا لَيْسَ لَكَ بِهِ عِلْمٌ﴾

— سورة الإسراء: ٣٦

لا تَتَّبِعْ مَا لَا عِلْمَ لَكَ بِهِ؛ ومع ملايين الاختبارات، يخدعنا بعضها بإشاراتٍ كاذبة. تصحيح الاختبارات المتعددة وحساب القوة هما حارسان يمنعان "القفو" بلا دليل كافٍ.

 سيناريو بحثي

تخطّط لـ GWAS جديد. كم يجب أن تكون عيّنتك؟ ما أحجام الأثر التي تستطيع كشفها؟ هذه أسئلة يجب أن تُجاب قبل جمع البيانات، لا بعد فشل الدراسة. حساب القوة يحوّل التخطيط من تخمين إلى علم: يخبرك إن كانت ٥٠٠٠ عيّنة كافية أم أنك تحتاج ٥٠٠٠٠٠.

في الطرف الآخر، بعد التحليل، تواجه مشكلة الاختبارات المتعددة: ٨ ملايين اختبار تعني آلاف الإيجابيات الكاذبة بالصدفة. هذا الفصل يجمع وجهي العملة: ضبط الخطأ، وتقدير القوة.

مجموعة البيانات لهذا الفصل

بيانات محاكاة + نتائج GWAS حقيقية للتصحيح

`fread("gwas_results.txt") # ID, BETA, SE, P, MAF`

أهداف التعلم

بعد هذا الفصل تستطيع: (١) تصحيح بونفيروني؛ (٢) FDR بطريقة BH؛ (٣) بناءً منحني قوة؛ (٤) محاكاة القوة؛ (٥) حساب حجم العينة المطلوب؛ (٦) عتبة بالتبديل؛ (٧) تحليل القوة البعدي.

الخلفية الأساسية

القوة الإحصائية هي احتمال كشف أثر حقيقي. تعتمد على أربعة: حجم الأثر، حجم العينة، تواتر الأليل (MAF)، وعتبة الدلالة. للصفة المتصلة، تباين الأثر المفسر:

$$R^2 = 2 \cdot \text{MAF} \cdot (1 - \text{MAF}) \cdot \beta^2$$

كلّما صغر MAF أو β ، صغر R^2 ، فاحتجنا عيّنةً أكبر لكشفه.

تشبيه: القوّة كقدرة تلسكوب على رؤية نجم خافت. النجم الخافت (أثر صغير، MAF نادر) يحتاج تلسكوباً أكبر (عيّنة أكبر). تصميم الدراسة بلا حساب قوّة كشراء تلسكوبٍ دون معرفة هل يكفي لرؤية ما تريد — قد تنفق ثروة ثمّ لا ترى شيئاً.

؟ المسائل

المسألة ١٠٠١ ★ [مبتدئ]

احسب عتبةً بونفيروني لـ ٨ ملايين اختبار، وتحقّق لماذا تُستخدم 10^{-8} .

✓ الحلّ ١٠٠١

```
n_tests <- 8e6
alpha <- 0.05
bonferroni <- alpha / n_tests
cat("عتبة بونفيروني الخام:", "\n", bonferroni)
# لكن الاختبارات المستقلّة فعلياً ~1 مليون بسبب LD
```



```
independent_tests <- 1e6
cat(alpha/independent_tests, "\n , "العتبة المعدلة: ",
```

المخرجات المتوقعة:

عتبة بونفيروني الخام : $6.25e-09$
العتبة المعدلة : $5e-08$

التفسير: بونفيروني الخام لـ ٨ ملايين يعطي 10^{-9} ، لكن LD يجعل عدد الاختبارات المستقلة نحو مليون، فالعتبة المعيارية 10^{-8} . هذا يوازن بين الحذر المفرط (٨ ملايين) والتساهل.

المسألة ١٠.٢ ★ [مبتدئ]

طبق FDR بطريقة BH على نتائج حقيقية. متى تستخدمها بدل بونفيروني؟

الحل ١٠.٢ ✓

```
gwas[, fdr := p.adjust(P, method="BH")]
cat("اكتشافات بونفيروني: ", "\n", sum(gwas$P < 5e-8), "\n",
cat("اكتشافات ", "\n", sum(gwas$fdr < 0.05), "\n", FDR<0.05: ",
```

المخرجات المتوقعة:

اكتشافات بونفيريوني: 42

اكتشافات $FDR < 0.05$: 118

التفسير: FDR أقل صرامة (١١٨ مقابل ٤٢)، لأنّه يتحكّم في نسبة الكاذبة لا وجود أيّ كاذبة. نستخدمه في التحليلات الاستكشافية (تحليل التعبير، المسارات) حيث نتسامح مع بعض الكاذبة مقابل اكتشافات أكثر. في GWAS التأكيدي نلتزم بونفيريوني.

المسألة ١٠.٣ ★★ [متوسط]

ابن منحنى قوّة: حجم العينة مقابل القوّة ل MAF و OR معطين.

الحلّ ١٠.٣ ✓

```
library(genpwr)

curve <- sapply(seq(1000, 50000, 5000), function(n)
, genpwr.calc(calc="power", model="logistic", N=n
se.Rate=0.3, MAF=0.2, OR=1.2, Alpha=5e-8)$Power

({
, "plot(seq(1000, 50000, 5000), power_curve, type="b
("حجم العينة"=xlab , "القوّة"=ylab
```

المخرجات المتوقعة: منحنى صاعدٌ يبلغ ٨٠٪ قوةً عند ~٢٥٠٠٠ عينة لـ
 $OR=١,٢$ و $MAF=٠,٢$

التفسير: المنحنى يخبرك بالضبط: لكشف أثر متوسط ($OR=١,٢$) بقوة ٨٠٪،
 تحتاج ~٢٥ ألف عينة. هذا أساس التخطيط: لو ميزانيتك تسمح بـ ٥٠٠٠٠
 فقط، فلن تكشف إلا الآثار الكبيرة جداً.

المسألة ١٠٠٤ ★★ [متوسط]

محاكاة القوة: حاك ١٠٠٠ مجموعة بيانات، وعدّ كم مرة يكشف المتغير السببي.

الحل ١٠٠٤ ☒

```

} , detect <- replicate(1000
n <- 10000; maf <- 0.2; beta <- 0.15
g <- rbinom(n, 2, maf)
y <- beta*g + rnorm(n)
summary(lm(y ~ g))$coefficients[2,4] < 5e-8
({
cat("القوة المُحاكاة:",

```

المخرجات المتوقعة:

القوة المُحاكاة : 0.83

التفسير: من ١٠٠٠ محاكاة، كُشف المتغير في ٨٣٪ - أي القوة ٨٣٪.
المحاكاة أدق من الصيغ التحليلية لأنها تحاكي ظروفك الفعلية. القوة ٨٣٪ تعني أنك ستفوت ١٧٪ من الآثار الحقيقية بهذا الحجم.

المسألة ١٠.٥ ★★ [متوسط]

احسب حجم العينة المطلوب لقوة ٨٠٪ عند تركيبات متعددة (MAF, OR)،
وأنتج خريطة حرارية.

✓ الحل ١٠.٥

```
grid(MAF=c(0.05,0.1,0.2,0.4), OR=c(1.1,1.2,1.3,1.5))
grid$N <- mapply(function(m,o)
  enpwr.calc(calc="ss", model="logistic", Power=0.8
    MAF=m, OR=o, Alpha=5e-8)$N, grid$MAF, grid$OR
  ggplot(grid, aes(factor(MAF), factor(OR), fill=N))
    geom_tile() + geom_text(aes(label=round(N)))
```

المخرجات المتوقعة: خريطة تُظهر أنّ أثراً صغيراً نادراً (OR=١,١)،
(MAF=٠,٠٥) يحتاج < ١٥٠ ألف عينة، بينما أثر كبير شائع (OR=١,٥)،
(MAF=٠,٤) يحتاج ~ ٢٠٠٠٠.

التفسير: الخريطة تكشف لماذا الآثار الصغيرة النادرة هي "الورثة المفقودة":
كشفتها يتطلب أحجاماً هائلة. هذا يفسر تطور GWAS نحو البنوك الحيوية
الضخمة.

المسألة ١٠.٦ ★★★ [متقدم]

احسب عتبة الدلالة بالتبديل (permutation). متى وكيف تستخدمها بدل
بونفيروني؟

✓ الحل ١٠.٦

```

    } , max_stats <- replicate(1000
      y_perm <- sample(y) # خلط الصفه
      max(abs(sapply(1:ncol(G), function(j)
        ((cor(y_perm, G[,j]) * sqrt(length(y)-2)
          ({
            emp_threshold <- quantile(max_stats, 0.95)

```

التفسير: التبديل يبني توزيع "أقصى إحصاء" تحت الفرضية الصفرية لبياناتك
تحديداً، محترماً بنية LD تلقائياً. العتبة التجريبية (المئين ٩٥) أدق من بونفيروني
للبيانات المترابطة، لكنها مكلفة حسابياً. نستخدمها حين تكون بنية LD معقدة أو
العينة صغيرة.

المسألة ١٠٠٧ ★★★ [متقدّم]

تحليل القوة البعديّ: للإشارات التي لم تتكرّر، احسب القوة التي كانت لديك لكشفها.

✓ الحلّ ١٠٠٧

```
failed_replication <- fread("non_replicated_hits.txt")
d_replication[, power := mapply(function(b, se_rep)
  s(b)/se_rep - qnorm(1-5e-8/2)), BETA_disc, SE_rep
ال # فشلت بسبب نقص
```

التفسير: فشل التكرار قد يكون لأنّ الإشارة كاذبة، أو لأنّ عينة التكرار صغيرة (قوة ناقصة). هذا التحليل يميّز السببين: إشارة قوتها ٠,٣ في التكرار فشلت لنقص القوة لا للكذب. حكم عادل على الإشارات.

⚠ الأخطاء الشائعة وتصحيحها

Bonferroni too conservative for correlated
p.adjust. tests — استخدم العتبة المعيارية 10^{-8} أو التبديل.
Power.FWER $\downarrow$ FDR، bonferroni $\downarrow$ BH — wrong method
Winner's LD — calc ignores LD أدق.

curse inflates effect – أثر الاكتشاف متضخم، توقع أصغر
 في التكرار. genpwr wrong model – طابق logistic/linear مع
 صفتك. Permutation too slow – قلل عدد التباديل أو استخدم
 التقريب. Post-hoc power misused – احسبها بحجم أثر
 مفترض مسبقاً لا الملاحظ.

📖 الغوص العميق

في تخطيط دراسات الكلى بجامعة ميشيغان، حساب القوة المسبق أنقذنا من
 مشاريع محكومة بالفشل. مرةً، أراد متعاون دراسة أثر متغير نادر
 (MAF=0.02) على تدهور الكلى بعينة من 800 مريض. حساب القوة أظهر
 أننا سنملك 15٪ قوة فقط – أي 85٪ احتمال تفويت أثر حقيقي. أوقفنا
 المشروع قبل إهدار الموارد، وانتظرنا حتى تجمعت عينة أكبر. الدرس: القوة
 الناقصة لا تعني فقط فشل الكشف، بل تجعل أي نتيجة إيجابية مشكوكاً فيها
 (لعنة الفائز، حيث الأثر المكتشف متضخم). أعلم طلابي أن يبدأوا كل
 مشروع بسؤال: ما قوتنا؟ قبل سؤال: ماذا وجدنا؟

🔧 تحدّ مفتوح

طور إطار محاكاة يدمج "لعنة الفائز" في تخطيط دراسات التكرار: بالنظر إلى أثر
 مكتشف بحجم معين وقيمة p ، قدر حجم الأثر الحقيقي المصحح (المنكش)، ثم

احسب حجم عينة التكرار اللازم لتأكيد به قوة ٨٠٪. كم تكون التقديرات مضللة لو تجاهلنا الانكماش؟

مراجع أساسية

- Benjamini Y., Hochberg Y. (1995). "Controlling the false
.Dudbridge F., Gusnanto A. (2008). *JRSS B* ".discovery rate
Genet ".Estimation of significance thresholds for GWAS"
Sham P.C., Purcell S.M. (2014). "Statistical power and *Epidemiol*
Zhong *.Nature Reviews Genetics* ".significance testing in GWAS
H., Prentice R.L. (2008). "Bias-reduced estimators for the
.Biostatistics ".winner's curse

الفصل الحادي عشر — تحليل عدم التوازن الترابطي Linkage Disequilibrium and / والهابلوتايب Haplotype Analysis

﴿وَجَعَلْنَا مِنْ كُلِّ شَيْءٍ زَوْجَيْنِ﴾

— سورة الذاريات: ٤٩

من كل شيء زوجان؛ وفي الجينوم مواضع تسير مقترنة لا تكاد تفترق. عدم التوازن الترابطي هو لغة هذا الاقتران، ومن يقرأها يفهم بنية الإشارة في كل منطقة.

 سيناريو بحثي

وجدت إشارة GWAS على الكروموسوم ١٠. الآن عليك تحليل بنية LD في تلك المنطقة لفهم أي المتغيرات تسير معاً، وأياً قد يكون السببي. الإشارة ليست متغيراً واحداً بل "حياً" كاملاً من متغيرات مترابطة، وفهم هذا الحي خطوة ضرورية نحو التخریط الدقيق (الفصل ١٢).

LD هو أساس كفاءة GWAS لكنّه أيضاً مصدرُ غموضه: المتغيّرُ الأقوى إحصائياً ليس بالضرورة السببيّ، بل قد يكون مجرد "مثّل" مرتبطٍ به. هذا الفصل يعلّمك قراءة بنية LD وتحليل الهابلوتايات.

مجموعة البيانات لهذا الفصل

منطقة 1Mb حول إشارة، من الجينومات الألف
-bfile chr10_region --r2-unphased --out ld_matrix/.

أهداف التعلّم

بعد هذا الفصل تستطيع: (١) حساب مصفوفة LD ورسمها؛ (٢) تحديد كتل LD؛ (٣) مقارنة LD بين الشعوب؛ (٤) تجميع النتائج (clumping)؛ (٥) رسم ارتباط إقليمي؛ (٦) الطورنة بـ SHAPEIT4؛ (٧) اختبار ارتباط هابلوتايات.

الخلفية الأساسية

مقياس r^2 يقيس القدرة التنبؤية بين موضعين:

$$r^2 = \frac{(p_{AB} - p_A p_B)^2}{p_A(1-p_A)p_B(1-p_B)}$$

$r^2=1$ يعني تنبؤاً تاماً، و. يعني استقلالاً. يتضاءل r^2 مع المسافة بسبب إعادة التركيب.

تشبيه: كَلُّ LD كـ "أحياء" على الكروموسوم؛ سَكَّانُ الحيِّ يَنْتَقِلُونَ معاً. حين تجد إشارة، أنت تجد حياً كاملاً مشبوهاً، لا منزلاً واحداً. مهمةُ التخریط الدقيق لاحقاً هي تحديدُ "المنزل" (المتغيّر) الجاني داخل الحيّ.

؟ المسائل

المسألة ١١.١ ★ [مبتدئ]

احسب مصفوفة LD لمنطقة ١ Mb حول إشارة، وارسم الخريطة الحرارية.

✓ الحل ١١.١

```
bcftools reformat -r chr10_region --r2-unphased square --out ld/.
```

```
library(LDheatmap)
ld <- as.matrix(fread("ld.ld"))
LDheatmap(ld, color=heat.colors(20))
```

المخرجات المتوقعة: خريطةٌ مثلثيةٌ بكُلِّ داكنةٍ على القطر (LD عالٍ داخل الكل) وفاتحةٍ بينها.

التفسير: الكلّ الداكنة هي "أحياء" LD: متغيّراتٌ مترابطةٌ بشدّة. المتغيّر السببي يقع غالباً داخل أكبر كتلةٍ داكنةٍ حول الإشارة. هذا أوّلُ بصرٍ على بنية المنطقة.

المسألة ١١.٢ ★ [مبتدئ]

حدّد كلّ LD باختبار الجاميتات الأربعة.

✓ الحلّ ١١.٢

```
e chr10_region --blocks no-pheno-req --out blocks/.  
head blocks.blocks.det
```

المخرجات المتوقّعة:

CHR	BP1	BP2	KB	NSNPS	SNPS
..rs.. rs	23	80	114780	114700	10

التفسير: اختبارُ الجاميتات الأربعة يحدّد حدودَ الكلّ: حيث توجد كلّ التركيبات الأربعة لأليلين، فتمّة إعادة تركيب تكسر الكتلة. الكتلة هنا ٨٠ كيلوقاعدة تضمّ ٢٣ متغيّراً — وحدة وراثيّة طبيعيّة.

المسألة ١١.٣ ★★ [متوسط]

قارن LD في الأوروبيين مقابل الأفارقة في المنطقة نفسها.

✓ الحل ١١.٣

```
region --keep EUR.txt --r2-unphased --out ld_eur/.  
region --keep AFR.txt --r2-unphased --out ld_afr/.  
  
cat (eur.ld)$UNPHASED_R2), "\n , "أوروبي:  $r^2$  متوسط  
cat (afr.ld)$UNPHASED_R2), "\n , "أفريقي:  $r^2$  متوسط
```

المخرجات المتوقعة:

متوسط r^2 أوروبي: 0.34

متوسط r^2 أفريقي: 0.19

التفسير: LD أقصر في الأفارقة ($r^2=0.19$, مقابل 0.34) لأنهم أقدم سكانيًا،
فتركت إعادة التركيب. هذا يعني أن التخریط الدقيق أسهل في الأفارقة (كُلُّ
أصغر = دقة أعلى)، وهي ميزة لـ GWAS متعدد الأصول (الفصل ١٧).

المسألة ١١.٤ ★★ [متوسط]

جمع نتائج GWAS (clumping): اختزل ٥٠٠ ألف متغيرٍ معنويٍّ إلى إشاراتٍ
مستقلة.

الحلّ ١١.٤ ✓

```
\ plink2 --bfile ref --clump gwas_results.txt/.  
p-p1 5e-8 --clump-r2 0.1 --clump-kb 250--  
out clumped--
```

المخرجات المتوقعة:

```
significant variants 500234  
clump: 47 independent loci identified--
```

التفسير: التجميعُ يأخذ المتغيرَ الأقوى في كلّ منطقة ويضمُّ إليه المترابطين ($r^2 < 0.1$ ، خلال ٢٥٠ كيلوقاعدة). من ٥٠٠ ألف "إشارة" إلى ٤٧ موضعاً مستقلاً حقيقياً. هذا يفرّق بين عدد المتغيرات المعنوية وعدد الاكتشافات الحقيقية.

المسألة ١١.٥ ★★ [متوسط]

ارسم ارتباطاً إقليمياً (نمط LocusZoom) لإشارة GWAS.

الحل ١١.٥ ✓

```
library(ggplot2)

region <- gwas[CHR==10 & BP > 114e6 & BP < 115e6]
lead <- region[which.min(P)]
# region[, r2_with_lead := ld_with_lead]
plot(region, aes(BP, -log10(P), color=r2_with_lead))
+ scale_color_gradient(low="blue", high="red")
```

المخرجات المتوقعة: نقاط ملونة ب LD مع الإشارة الرائدة: الحمراء (LD عالٍ)
قرب القمة، الزرقاء (منخفض) متفرقة.

التفسير: مخطط الارتباط الإقليمي يكشف بصرياً: هل الإشارة ككل واحدة
متناسكة (سبب واحد) أم متفرقة (إشارات متعددة)؟ التلوين ب LD يميز
المتراطين الحقيقيين من المتغيرات المستقلة المجاورة.

المسألة ١١.٦ ★★★ [متقدم]

طوّر البيانات ب SHAPEIT4، وقدر معدّل خطأ التبديل.

الحلّ ١١.٦ ✓

```
shapeit4 --input region.vcf.gz --map genetic_map.txt  
output region_phased.vcf.gz --sequencing--
```

المخرجات المتوقعة:

```
.Phasing completed  
Estimated switch error rate: 0.018 (1.8%)
```

التفسير: الطورنة تُستنتج أيُّ أليلٍ على أيِّ كروموسوم. معدّلُ خطأ التبدّل (١,٨٪) يقيس الجودة: نسبةُ المواضع التي يُخطئ فيها التبدّل بين النسختين. أقلُّ من ٢٪ جيّد. الجودةُ تعتمد على حجم المرجع وكثافة المتغيّرات.

المسألة ١١.٧ ★★★ [متقدّم]

أجر اختبارَ ارتباطٍ هابلوتايبّي، وقارنه بالاختبار المفرد.

الحلّ ١١.٧ ✓

```
2 --bfile region --hap-assoc haplotype_blocks.txt/.  
pheno pheno.txt --out hap_test--
```

المخرجات المتوقعة:

	Haplotype	Freq	OR	P
(هابلوتايب الخطر)	A-T-G	0.21	1.45	2e-9
	G-C-A	0.34	0.92	0.03
أفضل اختبار مفرد: $P=3e-7$				

التفسير: الاختبار الهابلوتايبى ($p=2 \times 10^{-9}$) أقوى من أفضل اختبار مفرد
 هنا، لأن الأثر الحقيقي يحمله تركيب أليلات معين لا متغير
 واحد. هذا يحدث حين تتفاعل المتغيرات على النسخة نفسها (cis-
 interaction).

⚠ الأخطاء الشائعة وتصحيحها

LD confusion r^2 vs r^2 للتنبؤ، 'D' للتاريخ التطوري. LD
 computed across populations - احسب LD داخل
 أصل واحد. clump-kb too small - قد يقسم إشارة واحدة؛
 استخدم ٢٥٠-٥٠٠. Phasing without genetic map -
 الخريطة الجينية ضرورية للدقة. Switch error high - حجم المرجع
 صغير أو كثافة المتغيرات منخفضة. Haplotype test
 underpowered - كثرة الهابلوتايبات تبذل القوة. LD heatmap
 too large - حدّ النطاق لمنطقة معقولة.

الغوص العميق

في تحليل منطقة كلوية بجامعة ميشيغان، علّمتني بنية LD درساً جوهرياً. وجدنا إشارة قوية عند متغير مفرد، لكن التجميع كشف أنّها في كتلة تضم ٤٠ متغيراً في LD شديد ($r^2 < 0.9$). المتغير الأقوى إحصائياً لم يكن السببي – تبين لاحقاً بالتخريط الدقيق أنّ السببي متغير آخر في الكتلة، تنظيمي يقع في معزز. هذا رنخ لدي قاعدة: لا تثق أبداً بأنّ "المتغير الرائد" هو السببي؛ هو مجرد قمة الحبي. كما استفدنا من قصر LD في عيناتنا غير الأوروبية: الكل الأصغر ضيّقت قائمة المرشحين بسرعة، فكان التنوع السكاني أداة للتخريط لا عائفاً.

تحدّ مفتوح

صمّم طريقة تستغلّ الفروق في بنية LD بين الأصول المتعددة (قصير في الأفارقة، طويل في الأوروبيين) لتضييق منطقة إشارة مشتركة إلى أقل عدد من المرشحين السببيين، دون الحاجة إلى بيانات وظيفية. كم متغيراً يمكن استبعاده بدمج ثلاثة أصول مقارنةً بأصل واحد؟

مراجع أساسية

Gabriel S.B. et al. (2002). "The structure of haplotype blocks in the human genome". Pritchard J.K., Przeworski M. *Science*.
Delaneau O. *AJHG* (2001). "Linkage disequilibrium in humans"

Nature ".et al. (2019). "Accurate, scalable phasing (SHAPEIT4)
Pruim R.J. et al. (2010). "LocusZoom: regional *.Communications*
.Bioinformatics ".visualization of GWAS results

الفصل الثاني عشر — التحليل الدقيق للموضع الجيني / Fine-Mapping a GWAS Locus

﴿أَفَلَا يَتَذَكَّرُونَ الْقُرْآنَ﴾

— سورة محمد: ٢٤

التدبرُ تجاوزُ الظاهر إلى المعنى، والتخريط الدقيق تجاوزُ "الإشارة" إلى "المتغير السببي" الحقيقي المختبئ بين عشراتٍ من المترابطين.

📖 سيناريو بحثي

أظهر GWAS لـ eGFR قِمةً على الكروموسوم ٢. هناك ٤٧ متغيراً في LD. أيها سببيُّ على الأرجح؟ الإشارةُ الإحصائية وحدها لا تكفي — كلها مترابطةٌ ومعنوية. التخريط الدقيق يستخدم نماذجَ احتمالية لتقدير "احتمال أن يكون كلُّ متغيرٍ هو السببي"، فيختزل ٤٧ مرشحاً إلى مجموعةٍ ثقةٍ صغيرة.

هذا الفصل الجسرُ بين الاكتشاف الإحصائي والبيولوجيا. بدونه، تبقى نتائجُ GWAS مناطقَ غامضةٍ، به، نقرب من المتغير الوظيفي الذي يستحق التجربة المخبرية.

مجموعة البيانات لهذا الفصل

منطقة z-scores + chr2 من GWAS + مصفوفة LD
تجهيز الإدخال لـ FINEMAP و SuSiE

أهداف التعلم

بعد هذا الفصل تستطيع: (١) FINEMAP؛ (٢) SuSiE؛ (٣) مقارنتهما؛ (٤) تعليق مجموعة الثقة؛ (٥) التوضع المشترك؛ (٦) hypercoloc؛ (٧) خطّ التخریط الكامل.

الخلفية الأساسية

التخریط الدقيق يحسب احتمال الإدراج اللاحق (PIP) لكل متغير: احتمال أن يكون ضمن المتغيرات السببية، مشروطاً بالبيانات و LD. "مجموعة الثقة ٩٥٪" هي أصغر مجموعة احتمالها التراكمي ≤ 0.95 SuSiE. يَتمِذج عدّة إشاراتٍ مستقلة عبر "مجاميع الانكماش الفردية":

$$\mathbf{y} = \sum_{l=1}^L \mathbf{X}_l \mathbf{b}_l + \mathbf{e}$$

حيث كل $\mathbf{b}_l$ متجه متناثر يحمل إشارة سببية واحدة.

تشبيه: التخریط الدقيق كتحقيق جنائيّ في حيّ به ٤٧ مشتبهاً. الأدلة (LD + قوة الإشارة) لا تدين واحداً بيقين، لكنّها تضيق القائمة إلى ٣-٥ مشتبهين رئيسيين (مجموعة الثقة). PIP هو "درجة الاشتباه" لكل فرد.

؟ المسائل

المسألة ١٢٠١ ★ [مبتدئ]

شغل FINEMAP: جهّز الإدخال (z-scores، مصفوفة LD)، وفسّر المخرجات.

✓ الحلّ ١٢٠١

```
# ملف master يشير إلى z و ld.
finemap --sss --in-files master --n-causal-snp 5
cat region.snp | sort -grk11 | head
```

المخرجات المتوقّعة:

rsid	prob	log10bf
rs13391	0.62	8.4
rs13388	0.21	5.1
rs13402	0.08	3.2

التفسير: عمود prob هو PIP. rs13391 له ٠.٦٢٪ احتمال أن يكون سببياً –
 المرشح الأقوى. مجموع الاحتمالات يقترب من ١ لكل إشارة سببية. --n-
 5 causal-snps يسمح بحتى ٥ إشاراتٍ مستقلة في المنطقة.

المسألة ١٢.٢ ★★ [متوسط]

شغل susie_rss (susie): مجاميع الثقة مقابل احتمالات FINEMAP.

✓ الحل ١٢.٢

```
library(susieR)
susie_rss(z=zscores, R=ld_matrix, n=765000, L=10)
# مجاميع الثقة print(fit$sets$cs)
# احتمالات الإدراج susie_get_pip(fit)[1:5]
```

المخرجات المتوقعة:

```
L1: rs13391$ (مجموعة ثقة من متغير واحد!)
L2: rs13450, rs13455, rs13460$ (مجموعة من 3)
PIP: rs13391=0.94
```

التفسير: SuSiE يفصل الإشارات المستقلة في مجاميع منفصلة. المجموعة L1 فيها متغير واحد فقط (PIP، rs13391=٠,٩٤) – تخريط دقيق شبه تام! L2 فيها

٣ متغيرات لم نستطع التمييز بينها (LD شديد). هذا أوضح من FINEMAP في فصل الإشارات.

المسألة ١٢.٣ ★★ [متوسط]

قارن مجاميع ثقة FINEMAP و SuSiE: كم مرة يتفقان؟

✓ الحل ١٢.٣

```
finemap_top <- finemap_res[prob > 0.5, rsid]  
on(s) names(s)[which.max(susie_get_pip(fit)[s]))  
intersect(finemap_top, susie_top)
```

المخرجات المتوقعة:

الاتفاق: rs13391 (كلاهما يضعه كسببي رئيسي)
معدل الاتفاق عبر 47 موضعاً: 89%

التفسير: اتفاق الطريقتين (٨٩٪) يعزز الثقة. حين يتفقان، نطمئن للمرشح؛ حين يختلفان، نشك في جودة مصفوفة LD أو في وجود إشارات معقدة. استخدام طريقتين مستقلتين ممارسة جيدة.

المسألة ١٢٠٤ ★★ [متوسط]

عَلِّقْ مجموعةَ الثقة: مُشَفِّر/غير مُشَفِّر، تنظيمي، تداخلٌ مع eQTL.

✓ الحلّ ١٢٠٤

```
library(VariantAnnotation)

credible_set <- c("rs13391", "rs13450", "rs13455")

# تعليق وظيفي عبر VEP API أو biomaRt
annotations <- query_vep(credible_set)

as[, .(rsid, consequence, regulatory, eqtl_kidney)]
```

المخرجات المتوقعة:

rsid	consequence	regulatory	eqtl_kidney
rs13391	intron_variant	enhancer	YES (UMOD)
rs13450	missense	-	NO

التفسير: rs13391 في معرِّز وهو eQTL لـ UMOD في الكلى — مرشحٌ سببي تنظيمي قوي. التعليق الوظيفي يحوّل "متغيراً إحصائياً" إلى "فرضية بيولوجية": يؤثّر في تعبير UMOD في نسيج الكلى.

المسألة ١٢.٥ ★★★ [متقدّم]

أجر التوضّع المشترك بـ coloc: هل تتوضّع إشارة GWAS مع eQTL في كلى ؟GTEEx

الحلّ ١٢.٥ ✓

```
library(coloc)
)result <- coloc.abf
_beta, varbeta=gwas_se^2, type="quant", N=765000)
qtl_beta, varbeta=eql_se^2, type="quant", N=300)
result$summary["PP.H4.abf"]
```

المخرجات المتوقّعة:

PP.H4 (إشارة مشتركة) : 0.91
PP.H3 (إشارتان مستقلّتان) : 0.06

التفسير: $PP.H4 = 0.91$ يعني احتمالاً عالياً أنّ إشارة GWAS و eQTL تتشاركان المتغيّر السببي نفسه. هذا دليل قويّ على أنّ تأثير المتغيّر على الكلى يعمل عبر تغيير تعبير UMOD. PP.H3 المنخفض يستبعد الصدفة.

المسألة ١٢.٦ ★★★ [متقدّم]

أجر hypercoloc لصفاتٍ متعدّدة معاً، مشاركاً معلوماتِ التخرّيط عبر الصفات.

✓ الحلّ ١٢.٦

```
library(hyprcoloc)

and(eGFR_beta, BUN_beta, UACR_beta, UMOD_eqtl_beta)

es <- cbind(eGFR_se, BUN_se, UACR_se, UMOD_eqtl_se)

ses, trait.names=c("eGFR", "BUN", "UACR", "UMOD_eQTL")

(snp.id=snp_ids
```

المخرجات المتوقّعة:

```
R, BUN, UMOD_eQTL share candidate rs13391 (PP=0.88)

UACR: separate signal
```

التفسير: hypercoloc يكشف أنّ ٣ صفاتٍ (eGFR، BUN، UMOD) تتشارك المتغيّر نفسه — شبكةٌ سببيةٌ متّسقة. UACR إشارةٌ منفصلة. مشاركة المعلومات عبر الصفات تزيد قوّة التخرّيط مقارنةً بصفةٍ واحدة.

المسألة ١٢.٧ ★★★★★ [خير]

خطُ التخریط الكامل: GWAS ← مجموعة ثقة ← تعليق ← تموضع ← جين
هدف ← ملخص صفحة واحدة.

✓ الحل ١٢.٧

```
}finemap_pipeline <- function(locus)
  .cs <- run_susie(locus) # 1
  .annot <- annotate_vep(cs) # 2
  .coloc <- run_coloc(locus, gtex) # 3
  .target <- coloc[PP.H4 > 0.8, gene] # 4
  .eQTL <- coloc[eQTL > 0.8, gene] # 5
  .dible_set=cs, target_gene=target, evidence=coloc)
{
```

التفسير: هذا الخطُّ يحوّل إشارة GWAS خاماً إلى جينٍ هدفٍ قابلٍ للتجربة، في أربع خطواتٍ مؤتمتة. الناتج: "المنطقة chr2 ← المتغير rs13391 ← معرّز ← eQTL لـ UMOD ← الجين الهدف UMOD". هذا هو المنتج النهائي المطلوب لكلّ موضعٍ مكتشف.

⚠ الأخطاء الشائعة وتصحيحها

LD matrix mismatch with z-scores – يجب أن تكون
من السكان نفسه وبالترتيب نفسه. SuSiE too many credible
sets – قلل L أو تحقق من جودة LD. coloc assumes
single causal – استخدم SuSiE-coloc للإشارات المتعددة.
PP.H4 low but signals overlap – قد تكون إشارات
مستقلة في (H3) LD. FINEMAP n-causal too high – يبطئ
وَيُدخل ضوضاء. LD – Reference LD vs in-sample LD
داخل العينة أدق. eQTL different tissue – طابق النسيج ذا
الصلة (الكلّي لأمراضها).

📖 الغوص العميق

خُطّ التخريط الكامل هو جوهرٌ عملي بجامعة ميشيغان. لمتغيّر كلويّ، بدأنا بإشارة
GWAS في منطقة بها عشرات المرشّحين. SuSiE ضيّقها إلى متغيّر واحد بـ
PIP=0.09. وجدناه في GTEx eQTL لجينٍ معيّن في نسيج الكلى تحديداً.
coloc أكّد التوضع (PP.H4=0.91). فانتقلنا من "منطقة غامضة" إلى "جين
هدف" في أيام. منطقة UMOD مثالٌ كلاسيكيّ نجح فيه هذا تماماً. الدرسُ
الأعمق: التخريط الدقيق يحوّل الإحصاء إلى بيولوجيا، لكنّه يعتمد كلياً على

جودة مصفوفة LD – ومصفوفة LD المرجعية الأوروبية تعطي نتائج مضللة لعيناتنا غير الأوروبية، فنحرص على استخدام LD داخل العينة نفسها.

🔑 تحدّ مفتوح

التخريط الدقيق يفشل حين تختلف مصفوفة LD المرجعية عن العينة. صمّم تجربة تقيس كم تدهور دقة SuSiE (هل يضع المتغيّر السببي الحقيقي في مجموعة الثقة؟) كلما زاد التباين بين LD المرجعي وLD العينة الفعلي، خاصة للعينات العربية المخرطة بمرجع أوروبي. ما حدّ التباين الذي عنده يصبح التخريط غير موثوق؟

📖 مراجع أساسية

- Wang G. et al. (2020). "A simple new approach to variable selection in regression, with application to fine-mapping
- Benner C. et al. (2016). "FINEMAP: efficient *JRSS B*".(SuSiE) *Bioinformatics* ".variable selection using summary data
- Giambartolomei C. et al. (2014). "Bayesian test for
- Foley C.N. et al. (2021). "A *PLoS Genetics* ".colocalisation (coloc)
- Nature* ".fast and efficient colocalization algorithm (HyPrColoc)
- Communications*

الفصل الثالث عشر — تحليل eQTL والتعبير الجيني / eQTL Analysis and Gene

Expression

﴿وَفَوْقَ كُلِّ ذِي عِلْمٍ عِلْمٌ﴾

— سورة يوسف: ٧٦

فوق كلِّ علمٍ علمٌ؛ ومعرفةٌ أنّ متغيّراً مرتبطاً بمرضٍ علمٌ، لكن فوقه علمٌ أعمقُ:
كيف يعمل؟ تحليلُ eQTL يرفعنا طبقةً: من الارتباط إلى آلية التعبير الجيني.

📖 سيناريو بحثي

تريد فهم أيّ الجينات تنظّمها متغيّراتُ GWAS لديك. تحلّل eQTL في نسيج
الكلّي: هل المتغيّر المرتبط بالمرض يرفع أم يخفض تعبيرَ جينٍ معيّن؟ معظمُ
متغيّراتِ GWAS تنظيميّةٌ لا مُشفّرةٌ، فأثرها على المرض يمرّ عبر تغيير كميّة
البروتين المنتج، لا تركيبه.

eQTL (موضعُ صفةٍ كميّةٍ تعبيرية) هو الجسرُ بين الجينوم والوظيفة. GTEx —
الذي قاس التعبير في ٤٩ نسيجاً — هو المرجعُ الذهبيّ. هذا الفصل يعلِّبك ربطَ
المتغيّرات بالجينات التي تنظّمها.

مجموعة البيانات لهذا الفصل

GTEx v8: بيانات eQTL لـ 49 نسيجاً
واجهة API أو تنزيل ملخصات الكلي
/Kidney_Cortex.v8.signif_variant_gene_pairs.txt.gz

أهداف التعلّم

بعد هذا الفصل تستطيع: (١) استعمالَ GTEx API؛ (٢) تحديدَ cis-eQTL؛
(٣) FastQTL لـ trans؛ (٤) التوضعَ المشترك؛ (٥) sQTL؛ (٦) eQTL
أحاديّ الخلية؛ (٧) TWAS؛ (٨) خطّ التكامل.

الخلفية الأساسية

eQTL يختبر ارتباطَ النمط الجينيّ بمستوى تعبير جين:

$$+ \cdot G \setminus \{ \$\beta_0 + \beta \} = \{ \text{text}\{gene\} \} \setminus \{ \text{text}\{Expression\} \} \$\$ \\ \text{text}\{covariates\}$$

cis-eQTL: المتغير قرب الجين ($\pm 1\text{Mb}$) – شائعٌ وقويّ. **trans-eQTL**: المتغير بعيدٌ أو على كروموسومٍ آخر – نادرٌ وضعيفٌ.

تشبيه: الجينُ كمصباح، و eQTL كفتاح التعتيم (dimmer). المتغيرُ المُشَفَّرُ يغيّر شكلَ المصباح نفسه (البروتين)، أمّا eQTL فيغيّر سطوعه (كمّيّة التعبير). معظمُ إشارات GWAS تعمل عبر "مفاتيح التعتيم" البعيدة، لا بتغيير المصباح.

؟ المسائل

المسألة ١٣.١ ★ [مبتدئ]

استعلم GTEx API عن eQTL لجينٍ مرثّجٍ في قشرة الكلى.

الحلّ ١٣.١ ✓

```
library(httr); library(jsonlite)
gtexportal.org/api/v2/association/singleTissueEqtl
codeId="UMOD", tissueSiteDetailId="Kidney_Cortex"))
eqtls <- fromJSON(content(res, "text"))$data
head(eqtls[, c("variantId", "pValue", "nes")])
```

المخرجات المتوقّعة:

variantId	pValue	nes
chr16_20364_C_T	3.2e-15	-0.42
chr16_20392_A_G	1.1e-12	-0.38

التفسير: nes (حجمُ الأثر الطبيعيّ) سالبٌ: الأليلُ البديلُ يخفّضُ تعبيرَ
 UMOD. p صغيرةٌ جدّاً (3×10^{-15}) eQTL قويٌّ في الكلى. هذا يربط
 المتغيّرَ بآليةً بيولوجيةً: تقليلُ UMOD.

المسألة ١٣.٢ ★ [مبتدئ]

نزل ملخصاتِ كلى GTEx وحدّد cis-eQTL لإشارات GWAS.

الحلّ ١٣.٢ ✓

```
(Kidney_Cortex.v8.signif_variant_gene_pairs.txt.gz)
gwas_hits <- fread("gwas_loci.txt")
gtex, gwas_hits, by.x="variant_id", by.y="variant")
clap[, .(variant_id, gene_id, pval_nominal, slope)]
```

المخرجات المتوقّعة:

variant_id	gene_id	pval_nominal	slope
chr16_20392	UMOD	1.1e-12	-0.38
chr2_15310	SHROOM3	4e-9	0.31

التفسير: تداخلُ متغيّرات GWAS مع eQTL يكشف الجينات المرشحة:
 UMOD و SHROOM3 — كلاهما جينٌ كلي معروف. التداخلُ وحده ليس
 دليلاً قاطعاً (قد يكون صدفةً في LD)؛ نحتاج التوضّع المشترك (المسألة
 ١٣.٤).

المسألة ١٣.٣ ★★ [متوسط]

أجر FastQTL لتخريط trans-eQTL. ما هي trans-eQTL ولماذا هي نادرة؟

الحل ١٣.٣ ✓

```
FastQTL --vcf genotypes.vcf.gz --bed expression.bed.gz  
--window 5e6 --out trans_eqtl --threshold 1e-5--
```

التفسير: trans-eQTL: متغيّر يؤثّر في جينٍ بعيدٍ (أو على كروموسومٍ آخر)، غالباً
 عبر عاملٍ نسخٍ وسيط. نادرةٌ لأنّ أثرها يُخفّف عبر السلسلة (متغيّر ← عامل
 نسخ ← جين هدف)، وضعيفةٌ تُتطلّب عيناتٌ ضخمةٌ وتصحيحاً صارماً (كلُّ
 متغيّر × كلُّ جين = اختباراتٌ هائلة). عتبة trans أصرمُ بكثير.

المسألة ١٣.٤ ★★ [متوسط]

أجر التوضعَ المشتركَ بعتبة $PP.H4 > 0.8$ ، واختبر الحساسيةَ للأولويات.

✓ الحلّ ١٣.٤

```
library(coloc)
<- coloc.abf(dataset1=gwas_data, dataset2=eqtl_data
              (p1=1e-4, p2=1e-4, p12=1e-5
              # اختبار الحساسية للأ
```

المخرجات المتوقعة:

```
PP.H4 = 0.89
Sensitivity: robust to p12 in [1e-6, 1e-4]
```

التفسير: $PP.H4 = 0.89$ ، يؤكد التوضعَ. اختبار الحساسية يتحقق أنّ النتيجة ليست هشةً تجاه اختيار الأولوية p_{12} (الأولوية المشتركة). المتانة عبر نطاقٍ من القيم تعزز الثقة — ممارسة نقدية كثيراً ما تُهمل.

المسألة ١٣.٥ ★★ [متوسط]

أجر تحليلَ sQTL (صفة التضفير الكمية). كيف تختلف عن eQTL؟

✓ الحل ١٣.٥

```
fread("Kidney_Cortex.v8.sqtl_signifpairs.txt.gz")  
"UMOD", .(variant_id, phenotype_id, pval_nominal)]
```

التفسير: sQTL يؤثر في كيفية تضفير الجين (أي إكسونات تُدرَج)، لا في كميته الكلية. قد يُنتج المتغيرُ بروتيناً مختلفاً بنوياً دون تغيير المستوى الإجمالي. مكملٌ لـ eQTL: بعضُ متغيّرات المرض تعمل عبر التضفير لا التعبير. كلاهما آلية تنظيمية.

المسألة ١٣.٦ ★★★ [متقدّم]

eQTL أحادي الخلية: المفهوم وكيف يختلف عن النسيج الكليّ.

✓ الحل ١٣.٦

```
# eQTL في نوع خلية محدّد بدل خليط النسيج  
library(Seurat)  
# لكل نوع خلية: اختبر ارتباط النمط الجيني بالتعبير  
type_eqtl <- run_eqtl_by_celltype(sc_data, genotypes  
s=c("podocyte", "proximal_tubule"))
```

التفسير: النسيج الكلّي خليطٌ من أنواع خلايا؛ eQTL أحاديّ الخلية يكشف أنّ متغيراً قد يكون eQTL في خلايا الأنوب القريب فقط لا في الكبيبات. هذه الدقة الخلوية تكشف آلياتٍ يخفيها متوسطُ النسيج. مجالٌ صاعدٌ بقوة (الفصل ٢٥ يتطرّق لمستقبله).

المسألة ١٣.٧ ★★★ [متقدّم]

أجرِ TWAS بـ FUSION: اختبر تعبيرَ الجين كوسيطٍ لإشارة GWAS.

✓ الحلّ ١٣.٧

```
\ Rscript FUSION.assoc_test.R
```

```
\ sumstats egfr.sumstats --weights kidney.pos--
```

```
\ /weights_dir ./WEIGHTS/ --ref_ld_chr ./LDREF--
```

```
chr 16 --out twas_chr16.dat--
```

المخرجات المتوقعة:

ID	TWAS.Z	TWAS.P
UMOD	-7.8	6e-15

التفسير: TWAS يدمج وزنَ التعبير (من GTEx) مع GWAS ليختبر: هل التعبيرُ المتوقع جينياً لجينٍ مرتبطٌ بالصفة؟ UMOD معنويٌّ جداً ($p < 10^{-8}$) - التعبيرُ

المنخفض مرتبط بـ TWAS. eGFR. أقوى من eQTL وحده لأنه يجمع كل المتغيرات المنظمة للجين في اختبار واحد.

المسألة ١٣.٨ ★★★★★ [خير]

الخط الكامل: إشارة coloc ← GWAS مع TWAS ← GTEx ← تحديد الجين الهدف ← تحقق بيولوجي.

الحل ١٣.٨ ✓

```
}integrate_functional <- function(locus)
  coloc_res <- run_coloc(locus, gtex_kidney)
  twas_res <- run_twas(locus, kidney_weights)
  coloc_res[PP.H4>0.8, gene], twas_res[P<5e-8, gene])
  return(consensus)
  # جينات يدعمها الدليلان
  {
```

التفسير: الجين الذي يدعمه كلا الدليلين (coloc + TWAS) هو الأقوى ترشيحاً. تقاطع طريقتين مستقلتين يقلل الكاذبة. الناتج: قائمة جينات هدف عالية الثقة، جاهزة للتحقق المخبري (مثلاً تعديل التعبير في خلايا الكلى).

⚠ الأخطاء الشائعة وتصحيحها

Wrong tissue for disease – استخدم النسيج ذا الصلة
(الكلّي لأمرأضها). eQTL overlap $\neq$ causation – التداخلُ
يحتاج coloc لتأكيده. trans-eQTL false positives –
عتبةً أصرمُ وتصحيحٌ للبنية. TWAS weights ancestry
mismatch – أوزانُ GTEx أوروبية؛ حذرٌ للأصول الأخرى. GTEx
API rate limit – نزلُ الملخصات بدل الاستعلام المتكرر. sQTL
vs eQTL confusion – التضييق مقابل المستوى.
colocalization single causal assumption –
استخدم SuSiE-coloc لل متعدد.

📖 الغوص العميق

في عملي على الجينوميّات أحاديّة الخلية وأمراض الكلّي بجامعة ميشيغان، تحليلُ
eQTL هو حلقةُ الوصل التي تحوّل إشاراتنا إلى بيولوجيا. لمتغيّر كلويّ، ربطناه
عبر coloc بتعبير جين في الكلّي ($PP.H4 < 0.8$)، ثمّ أكّده TWAS. لكنّ
القفزة الكبرى كانت أحاديّة الخلية: اكتشفنا أنّ المتغيّر eQTL في نوع خلويّ
محدّد (خلايا الأنبوب القريب)، لا في الكلّي ككلّ. هذا غير فهمنا لآلية تماماً.
الدرس: متوسّط النسيج يخفي الحقيقة الخلوية. تحذير مهمّ أيضاً: أوزان TWAS

من GTEx أوروبية الأصل، فحين نطبّقها على مرضانا العرب نتعامل بحذر، لأنّ بنية LD المختلفة قد تشوّه التنبؤ بالتعبير.

🔗 تحدّ مفتوح

GTEx لا يحتوي نسيج كلّي من أصولٍ عربية. صمّم استراتيجيّة لتقدير eQTL الكلوّي في العرب رغم غياب المرجع: هل يمكن نقل أوزان التعبير الأوروبية مع تصحيح ل LD؟ كم تدهور دقّة TWAS حين تختلف بنية LD بين مرجع الأوزان والعينة المستهدفة؟ صمّم مقياساً يتنبأ بموثوقية النقل لكلّ جين.

📖 مراجع أساسية

GTEx Consortium (2020). "The GTEx atlas of genetic
.Gamazon E.R. *Science* ".regulatory effects across human tissues
".et al. (2015). "A gene-based association method (PrediXcan)
Gusev A. et al. (2016). "Integrative approaches *Nature Genetics*
Ongen H. et *Nature Genetics* ".for large-scale TWAS (FUSION)
".al. (2016). "Fast and efficient QTL mapper (FastQTL)
".*Bioinformatics*

الفصل الرابع عشر — الوراثة ومعامل الارتباط الجيني بـ LDSC / Heritability and GCTA Genetic Correlation

﴿وَخَلَقَ كُلَّ شَيْءٍ فَقَدَرَهُ تَقْدِيرًا﴾

— سورة الفرقان: ٢

خلق فقدّر تقديراً؛ ومعامل الوراثة تقديرٌ كميّ لنصيب الجين من الصفة. LDSC وGCTA يقيسان هذا "التقدير": كم من تباين الصفة جينيّ، وكم تشارك الصفات في أساسها الجينيّ.

 سيناريو بحثي

تريد أن تعرف كم eGFR وراثي، وهل يتشارك بنيةً جينيةً مع السكرّي. هذان سؤالان مختلفان: الأوّل معاملُ الوراثة (h^2)، والثاني معاملُ الارتباط الجينيّ (rg). كلاهما يُحسب من الإحصاءات الموجزة وحدها بـ LDSC — دون الحاجة إلى البيانات الفردية، ما يجعله متاحاً لأيّ باحثٍ يملك نتائج GWAS منشورة.

LDSC ثورة منهجية: استغلَّ العلاقة بين قوَّة الإشارة وLD المحيط لفصل الإشارة الجينية الحقيقية عن التضخم. هذا الفصل يعلمك قياس الوراثة، والارتباط، والإثراء الوظيفي.

مجموعة البيانات لهذا الفصل

إحصاءات موجزة لـ eGFR وصفات أخرى + درجات LD مرجع
[stitute.org/alkesgroup/LDSCORE/eur_w_ld_chr.tar.bz2](https://www.alkesgroup.org/LDSCORE/eur_w_ld_chr.tar.bz2)

أهداف التعلم

بعد هذا الفصل تستطيع: (١) h^2 من LDSC؛ (٢) rg بين الصفات؛ (٣) LDSC مطبقاً؛ (٤) GREML من البيانات الفردية؛ (٥) GREML ثنائياً؛ (٦) تفسير التقاطع؛ (٧) إثراء الوراثة الوظيفي.

الخلفية الأساسية

فكرة LDSC: المتغير في منطقة كثيفة LD "يلتقط" إشاراتٍ سببيةً أكثر، فتزداد إحصاءاته. الانحدار:

$$E[\chi^2_j] = \frac{N h^2}{M} \ell_j + N a + 1$$

حيث $\$ll_j\$$ درجة LD للمتغير j . المنحدر يعطي h^2 ، والتقاطع (intercept) يكشف التضخم من الخلط لا من الإشارة الجينية.

تشبيه: LDSC كالتمييز بين صدى الجبل وصوت المتحدث. المتغير في LD عالٍ كمتحدث في وادٍ ذي صدًى (يُضخم الصوت الحقيقي)؛ المنحدر يُقيس قوّة الصوت الأصلي (الوراثة)، والتقاطع يُقيس ضوضاء الخلفية (التضخم التقني). هكذا نفصل الإشارة الحقيقية عن الضوضاء بالملخصات وحدها.

؟ المسائل

المسألة ١٤٠١ ★ [مبتدئ]

احسب الوراثة من LDSC: جهّز sumstats، شغل ldsc.py، فسر h^2 SNP.

✓ الحل ١٤٠١

```
s.py --sumstats egfr_gwas.txt --N 765000 --out egfr
py --h2 egfr.sumstats.gz --ref-ld-chr eur_w_ld_chr
w-ld-chr eur_w_ld_chr/ --out egfr_h2--
```

المخرجات المتوقعة:

Total Observed scale h2: 0.16 (0.011)

Lambda GC: 1.21

Intercept: 1.03 (0.008)

التفسير: $h^2 = 0.16$ ، يعني أنّ المتغيّرات الشائعة تفسّر ١٦٪ من تباين eGFR. الأهم: التقاطع ١.٠٣ (قريب من ١) بينما $\lambda = 1.21$ - هذا يخبرنا أنّ التضخم في λ حقيقي متعدد الجينات لا خلطٌ تقني. لو كان التقاطع مرتفعاً (مثلاً ١.١٥)، لدلّ على خلطٍ سكانيّ.

المسألة ١٤.٢ ★★ [متوسط]

احسب معامل الارتباط الجينيّ (rg) بين eGFR و ١٠ صفاتٍ كلوية.

الحلّ ١٤.٢ ✓

```
rg egfr.sumstats.gz,t2d.sumstats.gz,bun.sumstats.gz  
--w-ld-chr eur_w_ld_chr/ --out rg_results--
```

المخرجات المتوقّعة:

	p1	p2	rg	se	p
eGFR	BUN	-0.74	0.05	2e-40	
eGFR	T2D	-0.18	0.04	1e-5	

التفسير: $r = -0.74$ بين eGFR وBUN: ارتباطٌ جينيٌّ سالبٌ قويٌّ (وظيفةٌ كلِّ أفضل = BUN أقل، منطقيٌّ). $r = -0.18$ مع السكرى: ارتباطٌ أضعفٌ لكن معنويٌّ — أساسٌ جينيٌّ مشتركٌ بين السكرى وتدهور الكلى. هذا يكشف شبكات بيولوجيةً مشتركة.

المسألة ١٤.٣ ★★ [متوسط]

أجر LDSC مطبقاً: أيُّ أنواع الخلايا مُثراً لورثة eGFR؟

✓ الحل ١٤.٣

```
fr.sumstats.gz --ref-ld-chr baseline.,Kidney.,Liver
ot --frqfile-chr 1000G. --out partitioned--
```

المخرجات المتوقعة:

Category	Enrichment	P
Kidney_H3K27ac	8.4	3e-12
Liver_H3K27ac	1.2	0.4

التفسير: الإثراء ٨,٤ ضعفاً في علامات الكلى التنظيمية (H3K27ac) يعني أنّ وراثة eGFR تتركز في المناطق النشطة في الكلى — تأكيدٌ بيولوجيٌّ أنّ الإشارات

صحيحة. الكبد غير مُثرى (١,٢) كما يُتوقع. هذا يربط الوراثة بالأنسجة ذات الصلة.

المسألة ١٤٠٤ ★★ [متوسط]

احسب GREML من البيانات الفردية بـ GCTA. متى تستخدمه بدل LDSC؟

✓ الحل ١٤٠٤

```
\ gcta --reml --grm study_grm --pheno egfr.phen  
qcovar covar.txt --out greml_h2--
```

المخرجات المتوقعة:

$V(G)/V_p(h^2) : 0.21 \text{ (SE } 0.03)$

LRT P: $2e-18$

التفسير: GREML يقدر $h^2 = 0.21$ من البيانات الفردية مباشرة (لا من الملخصات). أعلى قليلاً من LDSC (٠,١٦) لأنه يلتقط إشارات أكثر. نستخدم GREML حين نملك البيانات الفردية والعينة متوسطة؛ وLDSC حين نملك الملخصات فقط أو العينة ضخمة.

المسألة ١٤.٥ ★★★ [متقدّم]

قدّر الارتباط الجيني بـ GREML ثنائي المتغير من البيانات الفردية.

✓ الحل ١٤.٥

```
\ gcta --reml-bivar 1 2 --grm study_grm  
pheno egfr_t2d.phen --out bivar_rg--
```

المخرجات المتوقعة:

rg: -0.19 (SE 0.06)

التفسير: GREML الثنائي يقدّر rg من البيانات الفردية، مفيدٌ حين تكون العينة نفسها قيسَت لها صفتان. النتيجة (-0.19) تطابق LDSC تقريباً — تأكيد متبادل. ميزته: يعمل حتى للصفات النادرة حيث LDSC ضعيف.

المسألة ١٤.٦ ★★★ [متقدّم]

استخدم تقاطع LDSC للتمييز بين التضخم والإشارة متعددة الجينات.

✓ الحل ١٤.٦

```
) results <- data.table
  , trait=c("eGFR", "study_B", "study_C")
  , lambda=c(1.21, 1.30, 1.15)
  (intercept=c(1.03, 1.18, 1.02)
results[, interpretation := ifelse(intercept > 1.05
  "تضخم/خلط", "إشارة متعددة الجينات")]
```

المخرجات المتوقعة:

trait	lambda	intercept	interpretation
إشارة متعددة الجينات	eGFR	1.21	1.03
تضخم/خلط	study_B	1.30	1.18

التفسير: هذا جوهر قوة LDSC. study_B له λ مرتفع (١,٣) وتقاطع مرتفع (١,١٨) = تضخم من خلط سكاني (مشكلة!) eGFR له λ مرتفع لكن تقاطع طبيعي = إشارة متعددة الجينات حقيقية (جيد!). التقاطع يميز الحالتين حيث λ وحده يعجز.

★★★ المسألة ١٤.٧ [متقدم]

احسب إثراء الوراثة بـ S-LDSC مع ٥٣ تعليقاً وظيفياً.

✓ الحل ١٤٠٧

```
\ ldsc.py --h2 egfr.sumstats.gz  
\ .ref-ld-chr baselineLD.53annot--  
overlap-annot --out s_ldsc_53--
```

المخرجات المتوقعة:

Conserved_region	Enrichment: 12.1	P: 1e-15
Enhancer	Enrichment: 4.2	P: 3e-8
Coding	Enrichment: 5.8	P: 2e-6

التفسير: النموذج الأساسي بـ ٥٣ تعليقاً يكشف أنّ الوراثة مُثراً في المناطق المحفوظة تطورياً (١٢ ضعفاً) والمعززات. هذا يخبرنا أين تقع الوراثة وظيفياً، فيوجه البحث عن الآليات. الإثراء في المحفوظات منطقي: المناطق الوظيفية محفوظة عبر الأنواع.

⚠ الأخطاء الشائعة وتصحيحها

munge_sumstats removes too many SNPs — تحقق من أعمدة الأليات وN. h2 out of bounds — العينة صغيرة أو الصفة غريبة؛ تحقق من sumstats. $rg > 1$ or < -1 — ضوضاء في صفة منخفضة الوراثة. Intercept >> 1 — خلط سكاني غير مضبوط.

ref-ld ancestry mismatch — درجات LD يجب أن تطابق أصل العينّة (أوروبية لأوروبية). GRM — GREML memory error. كبيرة؛ استخدم --partitioned needs.grm-sparse baseline — أدرج التعليق الأساسي دائماً.

📖 الغوص العميق

استخدمت LDSC كثيراً في أبحاث الكلي بجامعة ميشيغان، وأكثر ما علمني هو التقاطع. مرّة، أعطى GWAS لنا $\lambda = 0.21$ — مقلق ظاهرياً. الانطباع الأول: خلط سكاني. لكن LDSC كشف تقاطعاً قدره 0.21 فقط: التضخم كان إشارة متعددة الجينات حقيقية، لا خطأ. هذا أنقذنا من "إصلاح" كان سيديمر إشارات حقيقية. الدرس: λ وحده مضلل؛ التقاطع هو الحكم. تحذير مهم: درجات LD المرجعية أوروبية بمعظمها، فحين نحلل صفات في عينات عربية، نحتاج درجات LD مناسبة للأصل، وإلا انحرفت تقديرات الوراثة. هذا قيد عملي آخر من فجوة التنوع.

🔑 تحدّ مفتوح

LDSC يحتاج درجات LD مطابقة للأصل، وهي غير متاحة للعرب. صمم طريقة لتقدير وراثة الصفات في العينات العربية: هل يمكن بناء درجات LD عربية من بضع مئات من العينات؟ كم تنحرف تقديرات h^2 حين نستخدم

درجات LD أوروبية لعينة عربية؟ صمم محاكاة تقيس هذا الانحراف وتقتراح أصغر مرجع عربي كافٍ.

مراجع أساسية

Bulik-Sullivan B. et al. (2015). "LD Score regression
. *Nature Genetics* ".distinguishes confounding from polygenicity
Bulik-Sullivan B. et al. (2015). "An atlas of genetic correlations
.Finucane H.K. et al .*Nature Genetics* ".across human diseases
-Partitioning heritability by functional annotation (S" .(2015)
Yang J. et al. (2010). "Common SNPs .*Nature Genetics* ".(LDSC
-explain a large proportion of heritability for height (GCTA
. *Nature Genetics* ".(GREML

الفصل الخامس عشر — درجات الخطر متعدد

الجينات: طرق متقدمة / Polygenic Risk

Scores: Advanced Methods

﴿وَمَا تَدْرِي نَفْسٌ مَّاذَا تَكْسِبُ غَدًا﴾

— سورة لقمان: ٣٤

لا تدري نفس ماذا تكسب غداً؛ ودرجات الخطر لا تدعي علم الغيب، بل تقدّر ميلاً احتمالياً. تقدّم الطرق من C+T البسيطة إلى LDpred2 وPRS-CS هو سعيٌ لتقديرٍ أدقّ للهيل، مع الاعتراف بحدوده.

 سيناريو بحثي

ابن أفضل درجةٍ خطرٍ ممكنةٍ لخطر تقدّم القصور الكلويّ المزمن، وتحقّق منها في مجموعةٍ عربيةٍ مستقلة. التحديّ مزدوج: بناءً درجةٍ دقيقة (الطرق الحديثة)، ثمّ مواجهة "مشكلة التنوع" — أنّ الدرجاتِ المبنية على أوروبيين تدهور في العرب.

درجات الخطر هي أقرب تطبيقات الوراثة الإحصائية إلى العيادة. هذا الفصل يأخذك من أبسط طريقةٍ إلى أحدثها، ويواجه بصراحةٍ قيدَ النقل بين الأصول.

مجموعة البيانات لهذا الفصل

إحصاءات CKDGen الموجزة + مجموعة تدريب أوروبية +

أهداف التعلّم

بعد هذا الفصل تستطيع: (١) C+T بـ PRSice-2؛ (٢) LDpred2؛ (٣) PRS-CS؛ (٤) درجة مُصحَّحة بالأصل؛ (٥) التحقق في مجموعة مستقلة؛ (٦) دمج الجين والسريي؛ (٧) تحليل العُشير؛ (٨) قالب تقرير سريي.

الخلفية الأساسية

درجة الخطر تجمع آثار آلاف المتغيرات:

$$\hat{\beta}_M = \sum \text{PRS}$$

التحدّي: $\hat{\beta}_M$ من GWAS متضخّمة بـ LD. الطرق الحديثة (LDpred2، PRS-CS) تُعيد ترجيح الآثار بانكاش بايزي يراعي LD، فتنفوق على C+T الذي يقطع ببساطة.

تشبيه: بناء PRS كتقدير وزن صندوق بجمع أوزان محتوياته. C+T كأن تأخذ أثقل غرض في كل منطقة وتتجاهل الباقي (فقد معلومات). LDpred2 كأن

تزن كلَّ غرضٍ بدقّةٍ مع تصحيح التداخل (LD) – أدقّ لكن أعقد. كلّما أحسنتَ الترجيح، دقّ التقدير.

؟ المسائل

المسألة ١٥.١ ★ [مبتدئ]

ابن درجة C+T (تجميع وعتبة) بـ PRSice-2.

✓ الحلّ ١٥.١

```
PRSice --base ckd_gwas.txt --target validation_cohort  
\ thread 8 --stat BETA --binary-target T--  
out prs_ct--
```

المخرجات المتوقّعة:

```
Best-fit P-threshold: 0.01  
PRS R2 at best threshold: 0.043  
P-value: 2e-15
```

التفسير: PRSice يجرب عتبات p متعدّدة ويختار الأفضل (هنا $p > 0.01$).
 $R^2 = 0.043$ يعني أنّ الدرجة تفسّر ٤,٣٪ من تباين الخطر. C+T بسيط

وسريع، لكنّه "يهدر" المتغيّرات تحت العتبة. تحذير: اختيار أفضل عتبة في عيّنة التحقق نفسها يضخم R^2 ؛ يجب التحقق في عيّنة ثالثة.

المسألة ١٥.٢ ★★ [متوسط]

طبّق LDpred2 (auto، grid، infinitesimal). أيّها أفضل لصفّتك؟

✓ الحلّ ١٥.٢

```
library(bigsnp)
# LDpred2-auto: يقدّر الوراثة ونسبة السببية تلقائياً
auto <- snp_ldpred2_auto(corr=ld, df_beta=sumstats
(h2_init=0.16, vec_p_init=0.1
big_prodVec(genotypes, ldpred2_auto[[1]]$beta_est)
```

المخرجات المتوقّعة:

```
LDpred2-auto: R2 = 0.061
LDpred2-inf: R2 = 0.048
LDpred2-grid: R2 = 0.063 (best p=0.05, h2=0.16)
```

التفسير: LDpred2 يتفوّق على C+T (٠.٦١ مقابل ٠.٤٣) لأنّه يستخدم كلّ المتغيّرات بأوزانٍ منكشّة بإزيّاً تراعي LD. النسخة auto تقدّر المعاملات

تلقائياً (مريحة)، grid تجرّب شبكة (أدق قليلاً)، inf تفترض كلّ المتغيّرات
سببية (أبسط). للصفات متعددة الجينات، auto عادةً ممتازة.

المسألة ١٥.٣ ★★ [متوسط]

طبّق PRS-CS (أولويّاتُ انكماشٍ متّصلة)، وقارن بـ LDpred2.

الحلّ ١٥.٣ ✓

```
PRScs.py --ref_dir=ldblk_1kg_eur --bim_prefix=target  
st_file=ckd_sumstats.txt --n_gwas=765000--  
out_dir=prscs_out--
```

المخرجات المتوقّعة:

PRS-CS $R^2 = 0.060$

Correlation with LDpred2-auto: 0.97

التفسير: PRS-CS يعطي نتائج شبه متطابقة لـ LDpred2 ($R^2 = 0.060$ ،
ارتباط ٠.٩٧). كلاهما بايزيّ متّصلُ الانكماش. الفروق التقنية: PRS-CS
أبسطُ في الضبط، LDpred2 أسرعُ في R. اختيارُ أحدهما مسألةُ تفضيلٍ عمليّ
غالباً.

المسألة ١٥.٤ ★★ [متوسط]

درجة مُصحَّحة بالأصل: لماذا تفشل الدرجة الأوروبية في العرب؟ استخدم GWAS متعدّد الأصول.

✓ الحلّ ١٥.٤

```
# اختبار الدرجة الأوروبية في أصول مختلفة
r2_by_ancestry <- data.table
,ancestry=c("EUR","SAS","Arab","AFR")
(r2=c(0.061, 0.038, 0.029, 0.018))
```

المخرجات المتوقعة:

	ancestry	r2
	EUR	0.061
(نصف الأداة)	Arab	0.029
(ثلث الأداة)	AFR	0.018

التفسير: الدرجة الأوروبية تفقد نصف أدائها في العرب وثلثه في الأفارقة. الأسباب: اختلاف LD، تواترات الأليلات، الآثار. الحلّ الأفضل: GWAS متعدّد الأصول (الفصل ١٧) في التدريب. هذه "مشكلة النوع" — أخطر قيد أخلاقيّ في تطبيق PRS سريريّاً.

المسألة ١٥.٥ ★★★ [متقدّم]

تحقق من الدرجة في مجموعةٍ مستقلة: R^2 ، AUC، OR لكل Nagelkerke، انحراف.

✓ الحل ١٥.٥

```
library(pROC)
n(CKD ~ PRS + AGE + SEX, data=val, family=binomial)
auc(val$CKD, predict(model, type="response"))
val[, prs_z := scale(PRS)]
s_z, data=val, family=binomial))["prs_z"]) # OR/SD
```

المخرجات المتوقعة:

AUC: 0.68

Nagelkerke R2: 0.071

OR per SD: 1.58

التفسير: AUC=0.68، (تمييز متواضع لكن مفيد)، OR لكل انحراف=1.58،
(كل زيادة انحراف ترفع الخطر ٥٨٪). هذه المقاييس الثلاثة معاً تعطي صورةً
كاملة. التحقق في عينةٍ مستقلة تماماً عن التدريب والضبط شرط لتقدير غير
متحيز.

المسألة ١٥.٦ ★★★ [متقدّم]

نموذج مدمج (PRS + سريري): هل يضيف الجين قيمةً فوق عوامل الخطر السريرية؟

✓ الحل ١٥.٦

```
D ~ AGE+SEX+DIABETES+BP, data=val, family=binomial)
AGE+SEX+DIABETES+BP+PRS, data=val, family=binomial)
# مقارنة AUC ومؤشر إعادة التصنيف
fitted(clinical)), roc(val$CKD, fitted(combined)))
```

المخرجات المتوقعة:

AUC سريري فقط: 0.71

AUC مدمج: 0.74

p لتحسن AUC: 0.002

NRI: 0.08

التفسير: السؤال السريري الحاسم: هل الجين يضيف فوق ما نعرفه؟ ارتفاع AUC من ٠.٧١ إلى ٠.٧٤ ($p=0.002$) يعني نعم، لكن التحسن متواضع. مؤشّر إعادة التصنيف ($NRI=0.08$) يقيس كم مريضاً أُعيد تصنيفه صحيحاً. هذا يحدّد القيمة السريرية الحقيقية للدرجة.

المسألة ١٥.٧ ★★★ [متقدّم]

تحليل العُشير: ارسم الخطرَ حسب عُشير الدرجة، وقارن أعلى ١٠٪ بأدنى ١٠٪.

✓ الحلّ ١٥.٧

```
decile := cut(PRS, quantile(PRS, 0:10/10), labels=1:10)
risk_by_decile <- val[, .(risk=mean(CKD)), by=decile]
bottom <- (risk_by_decile[10]/(1-risk_by_decile[10]))
top <- (risk_by_decile[1]/(1-risk_by_decile[1]))
```

المخرجات المتوقّعة:

العُشير 1 (الأدنى): خطر 4%
العُشير 10 (الأعلى): خطر 19%
OR أعلى مقابل أدنى: 5.6

التفسير: أعلى ١٠٪ جيئاً لديهم خطرٌ أعلى ٥,٦ أضعاف من أدنى ١٠٪. تحليل العُشير أوضح سريريّاً من R^2 : يخبر الطيّب مباشرةً "هذا المريض في الشريحة العليا، خطره ١٩٪". هذا التمثيل هو ما يُستخدم في التقارير السريرية.

المسألة ١٥٠٨ ★★★★★ [خير]

ابنِ قالبٍ تقريرٍ سريريٍّ لـ PRS في R Markdown: درجةُ المريض مع فترات الثقة.

الحلّ ١٥٠٨ ✓

```
erate_prs_report <- function(patient_prs, ref_dist)
percentile <- mean(ref_dist < patient_prs) * 100
ci <- patient_prs + c(-1.96, 1.96) * prs_se
=list(percentile=percentile, risk_category
ntile<10) ifelse, "مرتفع", percentile>90) ifelse
(confidence_interval=ci
{
```

التفسير: التقريرُ السريريُّ يحوّل رقماً مجرداً إلى معلومةٍ قابلةٍ للفعل: "مريضُك في المئين ٩٢ — خطرٌ مرتفع". فتراتُ الثقة حاسمة: درجةُ PRS تُقدّرُ لا يقين، وإخفاءُ عدم اليقين خطأً سريريّ. الحذرُ في العرض جزءٌ من المسؤولية الطبية.

⚠ الأخطاء الشائعة وتصحيحها

Best threshold overfits — اختر العتبة في عينة منفصلة عن التحقق. LD reference ancestry mismatch — استخدم مرجع LD مطابقاً. PRS-CS slow — استخدم النسخة المتوازية PRS-CSx. AUC inflated — تأكد من استقلال عينة التحقق. European PRS in non-Europeans — توقع تدهوراً؛ استخدم متعدد الأصول. Decile unstable — العينة صغيرة جداً للعشيرة. Missing CI in report — أظهر دائماً عدم اليقين.

📖 الغوص العميق

أستخدم درجات الخطر للتنبؤ بأمراض الكلى في جامعة ميشيغان، والوعد حقيقي: في الأصول الأوروبية، تضيف الدرجة قيمة فوق العوامل السريرية. لكن أعمق درسٍ تعلّمته هو حدود النقل. حين اختبرنا درجة أوروبية على مرضانا العرب، تدهور أدائها للنصف. هذا ليس عيباً تقنياً يصلح بمعايرة؛ إنه نتيجةً بنيوية لأن كل مكونات الدرجة (الآثار، LD، التواترات) مُعايرة على شعبٍ آخر. تعلّمت أن أقدم الدرجة دائماً مع تحذيرٍ صريحٍ عن الأصل، وآلا أعاملها كبديلٍ عن الحكم السريري. الحل الحقيقي ليس معايرة أفضل، بل GWAS عربي يولد آثاراً مناسبة لشعبنا — وهذا جوهر دعوتي.

🔖 تحدّ مفتوح

صمّم درجة خطر "محمولة عبر الأصول" تجمع GWAS أوروبياً ضخماً (آثار دقيقة) مع GWAS عربيّ صغير (LD وتواترات مناسبة)، بوزن أمثل بينهما. عند أيّ حجمٍ من العينة العربية يصبح دمجها أفضل من الأوروبيّ وحده في التنبؤ للعرب؟ هل الوزن الأمثل ثابت أم يعتمد على الصفة؟

📖 مراجع أساسية

"Privé F. et al. (2020). "LDpred2: better, faster, stronger
Ge T. et al. (2019). "Polygenic prediction via *Bioinformatics*
Nature ".Bayesian regression and continuous shrinkage (PRS-CS)
Martin A.R. et al. (2019). "Current polygenic *Communications*
Choi *Nature Genetics* ".scores may exacerbate health disparities
S.W. et al. (2020). "Tutorial: a guide to performing PRS
Nature Protocols ".analyses

الفصل السادس عشر — تحليل المتغيرات النادرة /

Rare Variant Analysis

﴿وَاللَّهُ خَلَقَكُمْ وَمَا تَعْمَلُونَ﴾

— سورة الصافات: ٩٦

خلقكم وما تعملون؛ والمتغيرات النادرة كثيراً ما تحمل أثراً كبيراً مخبئاً، تماماً كأعمال صغيرة ذات أثر عظيم. حين تعجز GWAS الشائعة، يكشف تحليل النادر طبقة جديدة من الوراثة.

📖 سيناريو بحثي

المتغيرات الشائعة تفسّر ١٠٪ فقط من وراثة القصور الكلوي. تبحث عن متغيرات نادرة ($MAF > 1\%$) قد تفسّر تبايناً إضافياً. المشكلة: المتغير النادر مفردٌ ضعيفُ القوة (نسخٌ قليلة)، فلا يصلح اختبارُهُ فردياً. الحل: تجميع المتغيرات النادرة داخل الجين في اختبارٍ واحد.

تحليل النادر يتطلب بيانات تسلسل (إكسوم أو جينوم كامل) لا شرائح، وطرقاً إحصائية مختلفة (العبء، SKAT). هذا الفصل يفتح باب الوراثة النادرة عن GWAS الشائع.

مجموعة البيانات لهذا الفصل

بيانات تسلسل إكسوم (WES) + تعليق وظيفي
تصفية المتغيرات النادرة الوظيفية

أهداف التعلم

بعد هذا الفصل تستطيع: (١) فهم لماذا تفشل GWAS للنادر؛ (٢) اختبار العبء؛ (٣) SKAT؛ (٤) SKAT-O؛ (٥) SAIGE-GENE؛ (٦) تحليل مجموعات الجينات؛ (٧) خط أنابيب الإكسوم الكامل.

الخلفية الأساسية

اختبار العبء (burden) يجمع المتغيرات النادرة في درجة واحدة للجين:

$$w_j \cdot G_{ij} = \sum_{i \in \text{Burden}} w_j \cdot G_{ij}$$

ثم يختبر ارتباط هذه الدرجة بالصفة. يفترض أن كل المتغيرات تؤثر في الاتجاه نفسه — وهنا تكمن قوته وضعفه.

تشبيه: المتغير النادر كقطرة في دلو؛ قطرة واحدة لا تُحدث فرقاً مقيساً (قوة ضعيفة)، لكنّ جمعَ كلِّ قطرات الجين في دلو واحد (العبء) يجعل المستوى مقيساً. SKAT أذكى: يسمح لبعض القطرات بأن ترفع ولبعضها بأن تنخفض (آثارٌ مختلطة)، فلا يُلغى بعضها بعضاً.

؟ المسائل

المسألة ١٦.١ ★ [مبتدئ]

لماذا تفشل GWAS القياسية للمتغيرات النادرة؟ عتبة التواتر والقوة.

✓ الحل ١٦.١

```
# محاكاة: قوة الاختبار المفرد عند تواترات مختلفة
p <- 0.001
n <- 5000
maf <- c(0.001, 0.01, 0.05, 0.2)
nrep <- 1000
pval <- sapply(maf, function(maf) {
  mac <- 2 * n * maf
  ifelse(mac < 20, "ضعيفة جداً", "كافية")
})
```

المخرجات المتوقعة:

10 : MAF=0.001 نسخ - ضعيفة جداً

100 : MAF=0.01 نسخ - حدية

2000 : MAF=0.2 نسخ - كافية

التفسير: عند $MAF=0.001$ ، في ٥٠٠٠ عينة، يوجد ١٠ نسخ فقط - لا يكفي لاختبار مفرد موثوق. القوة تناسب مع عدد النسخ (MAC)؛ النادر جداً يحتاج عينات هائلة. لهذا نجمع: بدل اختبار ١٠٠ متغير ضعيف، نختبر "عبء" الجين مرةً.

المسألة ١٦.٢ ★★ [متوسط]

أجر اختبار العبء: اجمع كل المتغيرات النادرة في جين في اختبار واحد.

الحل ١٦.٢ ✓

```
\ plink2 --bfile exome --set gene_sets.txt/.  
burden --pheno ckd.txt --out burden_test--
```

المخرجات المتوقعة:

Gene	N_rare_variants	BETA	P
PKD1	47	0.92	3e-9
PKD2	23	0.71	2e-5

التفسير: اختبار العبء جمع ٤٧ متغيراً نادراً في PKD1 ووجد ارتباطاً قوياً $(p=10^{-9})$. PKD1 هو جينٌ مرض الكلى المتعدد الكيسات – منطقيّ تماماً. العبء أقوى ما يكون حين معظم المتغيرات النادرة ضارّةً بالاتجاه نفسه (مثل طفرات فقدان الوظيفة).

المسألة ١٦.٣ ★★ [متوسط]

أجرِ SKAT (اختبار النواة لتسلسل الارتباط): ترجيحٌ مرنٌ لآثار المتغيرات.

✓ الحل ١٦.٣

```
library(SKAT)
l_Model(CKD ~ AGE + SEX + PC1 + PC2, out_type="D")
SKAT(genotype_matrix_gene, obj)$p.value
```

المخرجات المتوقعة:

```
SKAT p-value (PKD1): 4e-8
SKAT p-value (GENE_X): 2e-6 (فاتها العبء)
```

التفسير: SKAT لا يفترض اتجاهًا واحدًا؛ يسمح لبعض المتغيرات بأن ترفع الخطر وبعضها بأن تخفضه. لهذا يكشف GENE_X الذي فاتته العبء (لأنّ

آثاره مختلطة الاتجاه فالغى بعضها بعضاً في درجة العبء). SKAT أقوى للآثار المختلطة، العبء أقوى للأحادية الاتجاه.

المسألة ١٦.٤ ★★ [متوسط]

أجر SKAT-O: الاختبار الموحد الأمثل الجامع بين العبء و SKAT.

✓ الحل ١٦.٤

```
(genotype_matrix_gene, obj, method="SKATO")$p.value
```

المخرجات المتوقعة:

SKAT-O p-value (PKD1): 1e-9 (أقوى من كليهما)
rho optimal: 0.8 (أقرب للعبء)

التفسير: SKAT-O يجرب مزيجاً مثالياً بين العبء ($\rho=1$) و SKAT ($\rho=0$)، فيأخذ أفضل ما في الاثنين. هنا $\rho=0.8$ ، يعني أنّ الأثر أقرب للعبء (معظم المتغيرات بالاتجاه نفسه). SKAT-O الخيار الافتراضي الآمن لأنّه لا يلزمك بافتراض مسبق عن بنية الآثار.

المسألة ١٦.٥ ★★★ [متقدّم]

أجر SAIGE-GENE: جهّز التعليق، شغل العبء+SKAT+SKAT-O، قارن.

✓ الحل ١٦.٥

```
\ step2_SPAtests.R --bgenFile=exome.bgen
ATmodelFile=ckd_null.rda --groupFile=groups.txt--
\ "annotation_in_groupTest="lof;lof:missense--
\ maxMAF_in_groupTest=0.01,0.001--
SAIGEOutputFile=saige_gene.txt--
```

المخرجات المتوقعة:

Gene	Annotation	max_MAF	Pvalue_SKATO
PKD1	lof	0.001	8e-11
PKD1	lof:missense	0.01	3e-9

التفسير: SAIGE-GENE يجمع مزايا SAIGE (ضبط الاختلال والقرابة) مع اختبارات المجموعات. يختبر فئات متعددة: فقد الوظيفة وحده (lof)، أو مع المغلوطة (missense). فقد الوظيفة النادر جداً ($MAF > 0.001$) أقوى إشارة — منطقي، فالطفرات المعطلة أشد أثراً.

المسألة ١٦.٦ ★★★ [متقدم]

أجر تحليل مجموعات الجينات: اختبر إثراء عبء المسار.

✓ الحل ١٦.٦

```
# تجميع الجينات في مسارات ثم اختبار العبء على مستوى  
pathway_genes <- get_pathway("kidney_development")  
pathway_burden <- rowSums(gene_burden[, pathway_genes])  
glm(CKD ~ pathway_burden + covars, family=binomial))
```

المخرجات المتوقعة:

```
Pathway: kidney_development  
Burden P: 2e-6 (إثراء معنوي)
```

التفسير: حين لا يبلغ أي جين مفرد الدلالة، قد يبلغها المسار ككل بتجميع عبء جيناته. مسار تطور الكلى مُثري بطفرات نادرة – إشارة بيولوجية أوسع من جين واحد. هذا يرفع القوة بتجميع الإشارات الضعيفة المتناثرة.

المسألة ١٦.٧ ★★★★★ [خير]

خطّ تحليل الإكسوم الكامل: WES ← تعليق ← تجميع النادر ← اختبار جينيّ
← تصوير.

✓ الحل ١٦٠٧

1. تعليق وظيفي

```
vep -i exome.vcf -o annotated.vcf --plugin LoF
```

2. تصفية النادر الوظيفي

```
FO/AF<0.01 & LoF="HC" annotated.vcf > rare_lof.vcf
```

3. تجميع + 4. اختبار SAIGE-GENE + 5. تصوير

التفسير: الخطُ الكامل: تعليق (VEP يحدّد فقدان الوظيفة)، تصفية (نادر + معطل)، تجميع بالجين، اختبار بـ SAIGE-GENE، تصوير بخطّ مانهاتن جيني. هذا يحوّل ملايين المتغيّرات النادرة إلى قائمة جينات قابلة للتفسير. التعليق الوظيفي حاسم: نركّز على المتغيّرات المعطلة الأرجح ضرراً.

⚠ الأخطاء الشائعة وتصحيحها

Burden test no signal but SKAT yes — الآثار

Too few rare.SKAT/SKAT-O استخدم

variants per gene — اجمع عبر فئات أوسع أو مسارات.

Annotation file mismatch — تطابق معرفّات المتغيّرات.

MAC too low for SPA — ارفع الحد الأدنى أو اجمع. LoF

annotation missing — شغل إضافة LOFTEE في VEP.

Multiple MAF thresholds confusing — ابدأ بـ ٠,٠١.

ثمَّ جَرَّبَ الأندَر. WES vs WGS coverage – الإكسومُ يَفُوتُ
المتغيّراتِ التنظيمية.

📖 الغوص العميق

فتح SAIGE-GENE لنا بابَ المتغيّراتِ النادرة في أبحاثِ الكلى بجامعة
ميشيغان. جيناتُ مثل PKD1 و PKD2 (مرض الكلى المتعدّد الكيسات)
وCOL4A (متلازمة ألبورت) لا تظهر في GWAS الشائع لأنّ طفراتها نادرةٌ
ومتنوّعة — كلّ عائلةٍ قد تحملُ طفرةً مختلفة في الجين نفسه. اختبارُ العبء يجمع
هذه الطفراتِ المتفرّقة في إشارةٍ واحدةٍ قويّة. درسٌ مهمّ: في المجتمعات العربية
عالية زواج الأقارب، المتغيّراتُ النادرة المتنحية أكثرُ ظهوراً (homozygosity)،
ما يجعل تحليلَ النادر فيها مثمراً بشكلٍ خاصّ. هذه فرصةٌ علمية: مجتمعاتنا غنيّةٌ
بالأمراض المتنحية النادرة التي يصعب دراستها في الغرب المتفرّق وراثياً.

🔑 تحدّ مفتوح

المجتمعاتُ العربيةُ عالية زواج الأقارب تُظهر متغيّراتٍ نادرةً متنحيةً بتواترٍ أعلى.
صمّم اختبارَ عبءٍ مُحسّناً يستغلّ التماثلَ الزيجوتيّ (الجريانُ المتماثل، runs of
homozygosity) لزيادة قوّة كشف المتغيّراتِ المتنحية النادرة. كم تزيّد القوّة في
مجمّع بمعدّل زواج أقارب ٣٠٪ مقارنةً بمجمّع خارجيّ التزاوج؟

Wu M.C. et al. (2011). "Rare-variant association testing for
Lee S. et al. (2012). "Optimal *AJHG* ".sequencing data (SKAT)
Zhou W. et *Biostatistics* ".unified test for rare variants (SKAT-O)
-al. (2020). "Scalable region-based test for biobank data (SAIGE
.Cirulli E.T., Goldstein D.B. (2010) *Nature Genetics* ".(GENE
•*Nature Reviews Genetics* ".Uncovering the roles of rare variants"

الفصل السابع عشر — التحليل متعدد السكان / Multi-Ancestry Analysis

﴿وَاخْتِلَافُ أَلْسِنَتِكُمْ وَالْوِلَانِكُمْ إِنَّ فِي ذَلِكَ لَآيَاتٍ﴾

— سورة الروم: ٢٢

اختلافُ الألسنة والألوان آيةٌ من آياتِ الخلق؛ والتنوعُ السكانيُّ في الجينوم ليس عائقاً بل آيةٌ ومورد. التحليلُ متعددُ السكان يحوّل هذا الاختلافَ من مشكلةٍ إلى قوّةٍ علميةٍ وعدالةٍ صحيّةٍ.

📖 سيناريو بحثي

لدى تجمّعك البحثي مجموعاتٌ من خمسة أصول. تُجري GWAS متعدّد الأصول وتقارنه بنتائج الأصل الواحد. التحديّ والفرصة معاً: الأصول المختلفة لها بنيات LD وتواترات مختلفة، ما يعقّد الدمجَ لكنه أيضاً يضيق المناطق السببية ويكشف متغيّراتٍ غائبةً عن الأوروبيين.

أكثرُ من ٩٠٪ من GWAS أوروبيّ — خللٌ علميٌّ وأخلاقيّ. هذا الفصل يعلمك كيف تدمج الأصول بعدلٍ، وكيف يكون التنوعُ أداةً للاكتشاف لا مجرد شعار.

مجموعة البيانات لهذا الفصل

مجموعات GWAS من 5 أصول: EUR, AFR, EAS, SAS, Arab
إحصاءات موجزة لكل أصل للميتا-أناليسيس

أهداف التعلم

بعد هذا الفصل تستطيع: (١) GWAS مطبقاً بالأصل؛ (٢) ميتا-أناليسيس بـ METAL؛ (٣) اختبار التباين؛ (٤) تخريطاً دقيقاً متعدد الأصول؛ (٥) PRS عابراً للأصول؛ (٦) كشف متغيرات خاصة بالأصل؛ (٧) جينيات السكان العرب.

الخلفية الأساسية

الميتا-أناليسيس ذو الأثر الثابت يجمع الآثار عبر الأصول بوزنٍ عكسيٍّ للتباين:

$$\hat{\beta}_{\text{meta}} = \frac{\sum_k \beta_k / SE_k^2}{\sum_k 1/SE_k^2}$$

التخريط الدقيق متعدد الأصول يستغلّ أنّ LD يختلف بين الأصول: المتغير السببي مرتبط بالصفة في كلّ الأصول، أمّا الممثلون فيختلفون.

تشبيه: الأصول المختلفة كشهود عيانٍ من زوايا مختلفة على الجريمة نفسها. الشاهد الأوروبي يرى مجموعةً من المشتبهين (LD طويل)، والأفريقي يرى مجموعةً أصغر (LD قصير). تقاطعُ شهاداتهم يضيقُ الجانيَ الحقيقي (المتغير السببي) بدقةٍ لا يبلغها شاهدٌ واحد.

؟ المسائل

المسألة ١٧.١ ★★ [متوسط]

أجر GWAS مطبقاً بالأصل منفصلاً، وصور وقارن مخططاتٍ مانهاتن.

✓ الحل ١٧.١

```
for anc in EUR AFR EAS SAS Arab; do
  ep 2 --bgen ${anc}.bgen --pred ${anc}_pred.list/.
  e ${anc}_pheno.txt --out gwas_${anc}--
done
```

المخرجات المتوقعة:

EUR: 42 loci AFR: 28 loci Arab: 15 loci

بعض الإشارات مشتركة، بعضها خاصٌ بأصل

التفسير: كلُّ أصلٍ يكشف مجموعةً مختلفةً جزئياً. العيناتُ الأوروبية الأكبر تكشف مواضعَ أكثر (قوةً)، لكنَّ الأفارقة قد يكشفون متغيّراتٍ غائبةً في الأوروبيين. مقارنةً المخططات تكشف الإشاراتِ المشتركة (بيولوجيا عامة) والخاصّة (بيولوجيا أو تواترٌ خاصٌّ بالأصل).

المسألة ١٧.٢ ★★ [متوسط]

أجرِ ميّتا-أناليسيس ذا أثرٍ ثابت بـ METAL عبر الأصول.

✓ الحلّ ١٧.٢

سكرت METAL

SCHEME STDERR

MARKER SNP

EFFECT BETA

STDERR SE

PROCESS gwas_EUR.txt

PROCESS gwas_AFR.txt

PROCESS gwas_Arab.txt

ANALYZE HETEROGENEITY

المخرجات المتوقّعة:

Meta-analysis of 5 ancestries

New genome-wide significant loci: 12 (لم تظهر في أي

التفسير: الميتا-أناليسيس يجمع القوة عبر الأصول، فيكشف ١٢ موضعاً جديداً لم يبلغ الدلالة في أي أصل منفرد. وزنُ الأثر الثابت العكسيّ للتباين يعطي العيّات الأكبر وزناً أكبر. هذا أقوى من أي دراسة مفردة.

المسألة ١٧.٣ ★★ [متوسط]

اختبر التباين: حدّد المتغيّرات ذات الأثر الخاص بالأصل.

✓ الحلّ ١٧.٣

```
meta <- fread("metal_output.txt")
[, .(SNP, Effect, HetISq, HetPVal)][HetPVal < 1e-5]
```

المخرجات المتوقّعة:

	SNP	Effect	HetISq	HetPVal
(تباين شديد)	rs334	0.45	92%	3e-12

التفسير: $I^2 = 92\%$ يعني أنّ 92% من التباين بين الأصول حقيقيٌّ لا صدفة. rs334 له أثرٌ مختلفٌ جداً بين الأصول — قد يكون متغيّراً سببياً يتفاعل مع البيئة، أو ممثلاً يختلف LD حوله. التباين الشديد يستحقّ تحقيقاً خاصاً.

المسألة ١٧.٤ ★★★ [متقدّم]

أجرِ تخريطاً دقيقاً متعدّد الأصول بـ MESuSiE مستغلاً فروق LD.

✓ الحلّ ١٧.٤

```
library(MESuSiE)

, fit <- mesusie(z_list=list(z_eur, z_afr, z_sas)
LD_list=list(ld_eur, ld_afr, ld_sas)
(N_list=c(50000, 20000, 15000)
fit$cs # مجموعات الثقة المشتركة
```

المخرجات المتوقعة:

مجموعة ثقة أحادية الأصل (EUR فقط): 15 متغيّراً
مجموعة ثقة متعدّدة الأصول: 2 متغيّر فقط!

التفسير: هذه قوّة التنوّع! التخريط الأوروبيّ وحده ترك ١٥ مرشحاً (LD طويل)، لكنّ دمج ثلاثة أصولٍ بفروق LD ضيق المجموعة إلى متغيّرين فقط. الأصول القصيرة LD (الأفارقة) "تكسر" الكلّ الأوروبية الطويلة. التنوّع أداة تخريط قويّة.

المسألة ١٧.٥ ★★★ [متقدّم]

PRS عابرٌ للأصول: تدريبٌ أوروبيّ، اختبارٌ أفريقيّ وعربيّ – قس فجوة الأداء.

✓ الحلّ ١٧.٥

```
library(PRSCsx) # PRS-CSx
# يدمج GWAS أوروبيّ + أفريقيّ + عربيّ بأوزانٍ خاصّة بالأصل
<- data.table(method=c("EUR-only", "PRS-CSx multi")
               (r2_arab=c(0.029, 0.047))
```

المخرجات المتوقّعة:

method	r2_arab
EUR-only	0.029
PRS-CSx multi	0.047

(+62% تحسّن)

التفسير: PRS-CSx يدمج عدّة أصولٍ في الدرجة، فيحسّن أداء العرب بـ ٦٢٪ مقارنةً بالأوروبيّ وحده. هذا حلٌّ عمليّ جزئيّ لمشكلة التنوع: حتى عينةٌ عربيةٌ صغيرة في التدريب تُحدث فرقاً كبيراً. الحلُّ الكامل يبقى جمعَ عيناتٍ عربيةٍ أكبر.

المسألة ١٧.٦ ★★★ [متقدّم]

حدّد متغيّرات أحادية الشكل في الأوروبيين لكنّها شائعة في الأفارقة – يفوّتها GWAS الأوروبيّ.

✓ الحلّ ١٧.٦

```
freq <- merge(eur_freq, afr_freq, by="SNP")  
hidden <- freq[MAF_eur < 0.001 & MAF_afr > 0.05]  
cat(nrow(hidden), "متغيّرات مرئية فقط في الأفارقة:",
```

المخرجات المتوقّعة:

متغيّرات مرئية فقط في الأفارقة: 1.2 مليون
مثال: APOL1 (أمراض الكلى) - شائع أفريقيّ، نادر أوروبيّ

التفسير: ١,٢ مليون متغيّر شائع في الأفارقة لكنّه نادر جدّاً في الأوروبيين – غير قابل للكشف في GWAS أوروبيّ. APOL1 المثال الأشهر: متغيّرات ترفع خطر أمراض الكلى بشدّة في الأصول الأفريقية، غائبة في الأوروبيين. هذا يبرهن أنّ الاختصار على الأوروبيين يفوّت بيولوجيا كاملة.

المسألة ١٧.٧ ★★★★★ [خير]

جينيات السّكان العرب: أين يقع العربُ في PCA الجينومات الألف؟ حلّ فروقَ بنية LD وأثرها على تصميم GWAS.

✓ الحلّ ١٧.٧

```
# إسقاط العرب على 1000G وتحليل موقعهم
proj <- project_onto_1kg(arab_samples)
# العرب يقعون بين EUR و SAS و AFR، قرب مكُونات الشرق
comparison <- compare_ld_decay(arab=arab_ld, eur=eur_ld)
```

المخرجات المتوقعة:

موقع العرب: بين (15%) AFR، (25%) SAS، (35%) EUR، م
تضاؤل LD: أسرع من EUR، أبطأ من AFR

التفسير: العربُ يقعون في فضاءٍ "بينيّ" فريد، بمكوّن خاصّ لا تمثّله 1000G. بنية LD وسطُ بين الأوروبيين والأفارقة. هذا له أثرٌ عمليّ: مراجعُ التخریط والاستيفاء وال PRS الأوروبية لا تناسبهم تماماً، فالعربُ يحتاجون مراجعَ خاصّة. وهذه فرصة: تنوّعهم الفريد وزواجُ الأقارب يجعلهم مورداً علمياً ثميناً للاكتشاف.

⚠ الأخطاء الشائعة وتصحيحها

METAL allele mismatch – وحد الأليل المرجعي قبل الدمج.
Heterogeneity from technical artifact – تحقق
MESuSiE LD must match each. أن التباين بيولوجي لا تقني.
ancestry – كل أصل ومصنوفة LD الخاصة به. PRS-CSx slow
Fixed vs random effects – استخدم
الأثر العشوائي عند التباين الشديد. Arab not in reference
panels – ابن مرجعاً خاصاً. Sample size imbalance
dominates meta – العينات الكبيرة تغطي؛ اخفص كل أصل.

📖 الغوص العميق

التحليل متعدد الأصول هو جوهر رسالتي العلمية في جامعة ميشيغان. حين حللنا أمراض الكلى، علمتنا APOL1 درساً لا ينسى: متغيراته ترفع خطر الفشل الكلوي أضعافاً في الأصول الأفريقية، وهي شبه غائبة في الأوروبيين. لو اقتصرنا على GWAS أوروبي، لفاتنا واحدة من أهم جينات الكلى على الإطلاق. هذا برهان حي أن التنوع ليس "إنصافاً" فحسب بل علم أفضل. تعلّمت أيضاً أن العرب مورد علمي غير مستغل: موقعهم الجيني الفريد وزواج الأقارب يجعلهم نافذة على بيولوجيا لا ترى في الغرب. لكن المراجع كلها (1000G، GTEx)، أوزان

PRS) أوروبية، فكلُّ تحليلٍ عربيٍّ يصطدم بهذا القيد – وهذا بالضبط ما يجب أن يدفع الباحثين العربَ للعمل.

تحدٍّ مفتوح

صمّم دراسةً تقيس "العائد الاكتشافي" لإضافة عينةٍ عربيةٍ إلى ميتا-أناليسيس متعدد الأصول: لكلِّ ١٠٠٠٠ عربيٍّ مُضاف، كم موضعاً جديداً يُكتشف، وكم يتحسن التخریط الدقيق، وكم يرتفع أداءُ PRS للعرب؟ هل العائدُ خطيٌّ أم متناقص؟ قارنه بعائد إضافة ١٠٠٠٠ أوروبيٍّ.

مراجع أساسية

- Willer C.J. et al. (2010). "METAL: fast and efficient meta
.Ruan Y. et al. (2022) *Bioinformatics* "analysis of GWAS
Improving polygenic prediction in ancestrally diverse"
.Genovese G. et al. *Nature Genetics* "populations (PRS-CSx)
Association of trypanolytic ApoL1 variants with kidney" (2010)
Gurdasani D. et al. (2019). "Genomics of *Science* "disease
Nature Reviews "disease risk in globally diverse populations
.Genetics

الفصل الثامن عشر — المحاكاة والإطار الإحصائي / Simulation and Statistical Framework

﴿أَفَلَا يَعْقِلُونَ﴾

— سورة يس: ٦٨

أَفَلَا يَعْقِلُونَ؟ والعقلُ يفهم الظاهرة بتفكيكها وإعادة بنائها. المحاكاةُ هي "إعادةُ بناء" GWAS في بيئةٍ نتحكم فيها، فنفهم خصائصه قبل أن نطبقه على بياناتٍ حقيقيةٍ مجهولة الحقيقة.

 سيناريو بحثي

تريد فهمَ الخصائص الإحصائية لـ GWAS قبل التطبيق على بياناتٍ حقيقية. في البيانات الحقيقية، لا تعرف الحقيقة (أي المتغيرات سببي)، فلا تستطيع قياس دقة طريقتك. المحاكاةُ تحلّ هذا: أنت تخلق البيانات، فتعرف الحقيقة بالضبط، فتقيس كم تكشفها طريقتك.

المحاكاة أداة تعلّم وتحقّق لا غنى عنها: بها نختبر أنّ عباتنا تعطي معدّل الخطأ المنشود، ونقيس القوة، ونكشف التحيزات (لعنة الفائز، التضخّم) في بيئة نظيفة.

مجموعة البيانات لهذا الفصل

لا بيانات خارجية - نوّلدها بأنفسنا
set.seed(2026)

أهداف التعلّم

بعد هذا الفصل تستطيع: (١) محاكاة مجموعة GWAS؛ (٢) التحقّق من معدلات الخطأ؛ (٣) محاكاة لعنة الفائز؛ (٤) صفات مترابطة؛ (٥) قوّة النادر؛ (٦) محاكاة التقسيم السكاني؛ (٧) بناء محاكٍ كامل.

الخلفية الأساسية

نوّلد الأنماط الجينية من توزيع ثنائي، ثمّ الصفة من نموذج خطّي:

$$G_j \sim \text{Binomial}(2, p_j), \quad y = \sum_j \beta_j G_j + \epsilon$$

بمعرفة β_j الحقيقية، نقيس كم مرّة تكشفها الطريقة (القوة) وكم مرّة تكشف الصفرَ زيفاً (الخطأ من النوع الأول).

تشبيه: المحاكاة كنفقٍ هوائي (wind tunnel) لاختبار طائرةٍ قبل الطيران الحقيقي. تتحكّم في كلّ متغيّر (السرعة، الزاوية)، فتعرف بالضبط كيف تتصرّف الطائرة قبل أن تخاطر بأرواح. كذلك نختبر طرقنا الإحصائية في "نفق" محكوم قبل تطبيقها على بياناتٍ حقيقيةٍ غاليةٍ مجهولة.

؟ المسائل

المسألة ١٨.١ ★★ [متوسط]

حاك مجموعة GWAS في R: جُم العينة، طيف MAF، أحجام الأثر، بنية LD.

الحلّ ١٨.١ ✓

```
ate_gwas <- function(n=5000, m=10000, n_causal=10)
  maf <- runif(m, 0.05, 0.5)
  G <- sapply(maf, function(p) rbinom(n, 2, p))
  causal <- sample(m, n_causal)
  ep(0, m); beta[causal] <- rnorm(n_causal, 0, 0.3)
  y <- G %*% beta + rnorm(n)
```

```
list(G=G, y=y, causal=causal, beta=beta)
{
  ()sim <- simulate_gwas
```

المخرجات المتوقعة:

محاكاة: 5000 فرد، 10000 متغير، 10 سببية
تباين مُفسر بالسببية: ~8%

التفسير: هذا "النفق الهوائي": نتحكم في كل شيء. نعرف بالضبط المتغيرات السببية العشرة وآثارها. الآن نشغل GWAS عليها ونقيس: كم سببياً نكشف؟ كم صفرٍ نُخطئ؟ هذا أساس كل التحققات اللاحقة.

المسألة ١٨.٢ ★★ [متوسط]

معدلاً انخطأ من النوعين الأول والثاني: تحقق أن عتبتك تعطي ٥٪ إيجابياتٍ كاذبة.

الحل ١٨.٢ ✓

```
}, null_p <- replicate(10000
g <- rbinom(5000, 2, 0.3); y <- rnorm(5000)
summary(lm(y ~ g))$coefficients[2,4]
```

{

cat("معدل الخطأ عند $\alpha=0.05$:", mean(null_p < 0.05))

المخرجات المتوقعة:

معدل الخطأ عند $\alpha=0.05$: 0.0498

التفسير: تحت الصفر الحقيقي (لا أثر)، عتبة ٠,٠٥ أعطت ٤,٩٨٪ إيجابياتٍ كاذبة — مطابقٌ للمتوقع تماماً. هذا يتحقق أنّ الاختبار مُعيارٌ بشكلٍ صحيح. لو أعطى ٢٠٪، لدلّ على مشكلةٍ في النموذج (تضخم، افتراضٌ مكسور).

المسألة ١٨.٣ ★★ [متوسط]

لعنة الفائز: آثارُ الاكتشاف متضخّمة؛ حاكها وقسها.

الحلّ ١٨.٣ ✓

```
true_beta <- 0.15
```

```
}, discovered <- replicate(1000
```

```
binom(5000,2,0.2); y <- true_beta*g + rnorm(5000)
```

```
fit <- summary(lm(y~g))$coefficients[2,]
```

```
if (fit[4] < 5e-8) fit[1] else NA
```

{

cat("متوسط الأثر المكتشف:", (discovered, na.rm=TRUE)
 "مقابل الحقيقي:", (true_beta

المخرجات المتوقعة:

متوسط الأثر المكتشف: 0.21 مقابل الحقيقي: 0.15

التفسير: الأثر المكتشف (٠,٢١) متضخم ٤٠٪ فوق الحقيقي (٠,١٥)! هذه "لعنة الفائز": فقط المحاولات التي تجاوزت العتبة صدفةً بأثرٍ مبالغٍ تُكتشف. لهذا تكون آثار التكرار أصغرَ دائماً. فهمُ هذا حاسمٌ لتخطيط دراسات التكرار (الفصل ١٠).

المسألة ١٨٠٤ ★★★ [متقدّم]

حاكِ صفاتٍ مترابطة واختبر استعادة الارتباط الجيني.

✓ الحلّ ١٨٠٤

```
# صفتان تتشاركان متغيرات سببية (rg حقيقي = 0.5)
specific1 <- sample(m,5); specific2 <- sample(m,5)
c(shared,specific1) %*% rnorm(10,0,0.3) + rnorm(n)
c(shared,specific2) %*% rnorm(10,0,0.3) + rnorm(n)
# قيس rg المستعاد بـ LDSC أو GREML
```

المخرجات المتوقعة:

rg الحقيقي: 0.50

rg المستعاد (GREML) : (SE 0.08) 0.47

التفسير: محاكاة صفتين تشاركان ٥ متغيّراتٍ سببية، نعرف rg الحقيقي (٠,٥). GREML استعاده بدقة (٠,٤٧). هذا يتحقّق أنّ طريقة تقدير الارتباط الجينيّ تعمل، ويقس دقّتها قبل تطبيقها على بياناتٍ حقيقيةٍ مجهولة rg.

المسألة ١٨.٥ ★★★ [متقدّم]

محاكاة قوة النادر: كيف يؤثّر حجم العينة في قوة SKAT-O؟

✓ الحلّ ١٨.٥

```
ato <- sapply(c(2000,5000,10000,20000), function(n)
  }, mean(replicate(200
# جين به 30 متغيّراً نادراً، 10 سببية
sim_rare_gene(n=n, n_rare=30, n_causal=10)
({
  ({
```

المخرجات المتوقعة:

N=2000 : قوّة 0.22

N=10000 : قوّة 0.68

N=20000 : قوّة 0.89

التفسير: قوّة SKAT-O للنادر ترتفع بحدّة مع العيّنة: من ٢٢٪ عند ٢٠٠٠ إلى ٨٩٪ عند ٢٠٠٠٠. النادر يحتاج عيّناً أكبر بكثيرٍ من الشائع. هذه المحاكاة تخبر الباحث بحجم العيّنة اللازم قبل بدء دراسة الإكسوم.

المسألة ١٨.٦ ★★★ [متقدّم]

حاكِ التقسيمَ السكّانيّ وأظهر كيف يضخّم GWAS دون تصحيح المكونات.

✓ الحلّ ١٨.٦

```
# مجموعتان سكّانيتان بتواترات مختلفة + صفة تختلف بين
pop <- rep(c("A","B"), each=2500)
}G <- sapply(1:m, function(j)
# تواترات مختلفة p <- ifelse(pop=="A", 0.2, 0.4)
({rbinom(n, 2, p)
# فرق بين y <- ifelse(pop=="A", 0, 0.5) + rnorm(n)
lambda_uncorrected <- compute_lambda(gwas(G, y))
corrected <- compute_lambda(gwas(G, y, covar=pca(G)))
```

المخرجات المتوقعة:

λ بدون تصحيح: 1.42

λ مع تصحيح المكونات: 1.03

التفسير: المحاكاة تُظهر الكارثة بوضوح: فرقٌ بيئيٌّ بحث بين مجموعتين (لا جينيّ) ضخم λ إلى ١,٤٢ – كلُّ المتغيرات المختلفة التواتر بدت "مرتبطة" زيفاً. تصحيحُ المكونات أعاد λ إلى ٠,١٠٣. هذا يبرهن عملياً ضرورةَ التصحيح (الفصل ٥).

المسألة ١٨٠٧ ★★★★★ [خبير]

ابن محاكِي GWAS كاملاً: معاملاتٌ ← أنماطٌ ← صفاتٌ ← نتائج ← تقديرُ قوّة، كدالة R.

الحلّ ١٨٠٧ ✓

```
<- function(n, m, n_causal, h2, maf_range, n_pop=1)
# 1. توليد الأنماط (مع بنية سكانية اختيارية)
# 2. توليد الصفة بوراثية محدّدة
# 3. تشغيل GWAS
# 4. قياس القوّة والخطأ ولعنة الفائز
er, type1=type1, winners_curse=wc, lambda=lambda)
```

```
{
  vas_simulator(n=10000, m=50000, n_causal=20, h2=0.3
    (maf_range=c(0.01,0.5))
  )
}
```

التفسير: المحاكى الكامل أداة تخطيطٍ شاملة: تُدخل تصميمَ دراستك (حجم، وراثية، عدد سببي)، فيُخرج القوةَ المتوقعةَ والخطأَ والتحيزات. هذا يحوّل تصميمَ الدراسة من تخمينٍ إلى علمٍ تجريبيّ. أستخدم نسخةً من هذا قبل كلّ مشروعٍ جديد.

⚠ الأخطاء الشائعة وتصحيحها

set.seed missing – النتائج غير قابلةٍ للتكرار؛ ثبتّ البذرة.
 Simulated h2 wrong – غير تباين الخطأ ليطابق الوراثة المنشودة.
 No LD in simulation – أضف بنية LD لواقعية أكبر. Type1
 not 0.05 – تحقق من معايير الاختبار. Winner's curse
 ignored – توقّع دائماً في التكرار. Population sim too
 simple – أضف اختلاطاً متدرجاً. Power sim too few
 reps – ٢٠٠+ إعادةً للاستقرار.

📖 الغوص العميق

المحاكاة أداتي المفضّلة في التدريس والتحقّق بجامعة ميشيغان. قبل كلّ مشروعٍ كلويّ، أبني محاكاةً صغيرةً تجيب: ما قوتنا المتوقعة؟ هل نموذجنا مُعاير؟ مرّةً،

شكّ زميلٌ في أنّ نموذجنا المختلط يضحّم النتائج؛ بدل الجدول، بنينا محاكاةً بقرابةٍ معروفة وأظهرنا أنّ λ يبقى ١,٠ — حُسم النقاش بالبرهان لا بالرأي. الأهمّ: المحاكاة علّمتني التواضع أمام لعنة الفائز. كلُّ أثرٍ نكتشفه متضحٌ بقدرٍ ما، وتخطيطُ التكرار دون مراعاة ذلك يقود للفشل. أعلمُ طلابي أن "يحاكوا قبل أن يحلّوا" — فالمحاكاة تكشف افتراضاتك المخفية قبل أن تكشفها البياناتُ الحقيقية بطريقةٍ مكلفة.

🔒 تحدّ مفتوح

ابن محاكاة واقعية للمجتمعات العربية تدج: زواج الأقارب (تمثالٌ زيجوتي مرتفع)، بنية سكانية قلبية، ومتغيّراتٍ متنحية نادرة. استخدمها لتقدير: كم تختلف القوة الإحصائية وأنماط التضخم في GWAS عربيّ عنها في أوروبيّ بالجسم نفسه؟ أيّ الطرق (PLINK/REGENIE/SAIGE) أكثرُ متانةً لبنية القرابة العربية؟

📖 مراجع أساسية

- Su Z. et al. (2011). "HAPGEN2: simulation of multiple disease
 .Fonseca-Pereira P. et al. (2021) .*Bioinformatics* ".SNPs
 ".Genotype-phenotype simulation frameworks for GWAS"
 Yang J. et al. (2011). "GCTA .*Briefings in Bioinformatics*
 Palmer C., Pe'er I. (2017). "Statistical .*AJHG* ".simulation tools
 .*PLoS Genetics* ".correction of the winner's curse

الفصل التاسع عشر — ميتا-أناليسيس / Meta-Analysis

﴿وَشَاوِرْهُمْ فِي الْأَمْرِ﴾

— سورة آل عمران: ١٥٩

الشورى جمعُ الآراء للوصول إلى حكمٍ أصوب؛ والميتا-أناليسيس "شورى" إحصائية: يجمع نتائج دراساتٍ متعددة في حكمٍ أقوى وأدقّ من أيّ دراسةٍ منفردة.

📖 سيناريو بحثي

لدى تجمعك خمس مجموعات. تريد دمج نتائج GWAS الخاصة بها في ميتا-أناليسيس واحد. لماذا لا تدمج البيانات الخام مباشرة؟ لأنّ اتفاقيات الخصوصية كثيراً ما تمنع مشاركة البيانات الفردية، لكنها تسمح بمشاركة الإحصاءات الموجزة. الميتا-أناليسيس يجمع القوة دون مشاركة بيانات حساسة.

الميتا-أناليسيس هو محركٌ اكتشافات GWAS الحديثة: معظمُ المواضع المعروفة اليوم اكتُشفت بدمج عشرات الدراسات في تجمّعات ضخمة (كـ CKDGen لأُمراض الكلى). هذا الفصل يعلّمك فنّ الدمج الصحيح.

مجموعة البيانات لهذا الفصل

إحصاءات موجزة من 5 دراسات لنفس الصفة
كلُّ: SNP, A1, A2, BETA, SE, P, N

أهداف التعلّم

بعد هذا الفصل تستطيع: (١) تجهيز الإحصاءات لـ METAL؛ (٢) ميتا-أناليسيس ذا أثرٍ ثابت؛ (٣) التحكّم الجينومي؛ (٤) اختبار التباين؛ (٥) GWAMA؛ (٦) GCTA-COJO؛ (٧) خطّ أنابيب كامل.

الخلفية الأساسية

الميتا-أناليسيس ذو الأثر الثابت يرنّج كلَّ دراسةٍ عكسيّاً بتباينها:

$$\hat{\beta}_{\text{meta}} = \frac{\sum_k w_k \beta_k}{\sum_k w_k} \quad w_k = \frac{1}{SE_k^2}$$

الدراساتُ الأدقّ (SE أصغر، عينةٌ أكبر) تحصل على وزنٍ أكبر. هذا أمثُلُ
تجميعٍ إحصائيٍّ تحت افتراض أثرٍ حقيقيٍّ واحد.

تشبيه: الميتا-أناليسيس كمجلسٍ شوريٍّ يرحّب آراءَ الخبراء بخبرتهم. رأيُ الخبير
الواثق (عينةٌ كبيرة، SE صغير) يُعطى وزناً أكبر من رأيِ المبتدئ (عينةٌ
صغيرة). الحكم النهائيُّ أحكمُ من أيِّ رأيٍ منفرد، لأنّه يجمع حكمةَ الجميع بترجيحٍ
عادل.

؟ المسائل

المسألة ١٩٠١ ★ [مبتدئ]

جهازُ الإحصاءاتِ الموجزة لـ METAL: الأعمدةُ المطلوبة، تنسيقُ الأليالات.

✓ الحلّ ١٩٠١

كل دراسة يجب أن تحتوي:

```
"EFFECT_ALLELE", "OTHER_ALLELE", "BETA", "SE", "P", "N")
```

تحقق وتوحيد

```
study <- fread("study1.txt")
```

```
stopifnot(all(required_cols %in% names(study)))
```

```
study[, EFFECT_ALLELE := toupper(EFFECT_ALLELE)]
```

التفسير: التوحيد حاسم: كلُّ دراسةٍ يجب أن تحدّد أليلَ التأثير بوضوح، وإلاّ انقلبت الآثارُ عند الدمج. تطابقُ الأليلات بين الدراسات هو أكثرُ مصادر الأخطاء. التحقّقُ المسبق من الأعمدة يمنع فشلاً صامتاً لاحقاً.

المسألة ١٩.٢ ★★ [متوسط]

أجرِ ميتا-أناليسيس ذا أثرٍ ثابت بـ METAL، وفسر المخرجات.

الحلّ ١٩.٢ ✓

```
SCHEME STDERR
AVERAGEFREQ ON
MINMAXFREQ ON
MARKER SNP
ALLELE EFFECT_ALLELE OTHER_ALLELE
EFFECT BETA
STDERR SE
PROCESS study1.txt
PROCESS study2.txt
...
ANALYZE
```

المخرجات المتوقعة:

```
MarkerName Effect StdErr P-value Direction
+++++ rs7903146 0.31 0.015 3e-95
```

التفسير: عمودُ Direction (+++++) يُظهر اتجاهَ الأثر في كلّ دراسة —
كلُّها موجبة، انساقُ مطمئن. $p = 3 \times 10^{-95}$ أقوى بمراتٍ من أيّ دراسةٍ منفردة.
SCHEME STDERR يستخدم الترجيحَ العكسيّ للتباين (الأمثل). تطابقُ
الاتجاهات عبر الدراسات دليلُ إشارةٍ حقيقية.

المسألة ١٩.٣ ★★ [متوسط]

التحكُّم الجينوميّ قبل الميتا-أناليسيس: كيف يعالج METAL التضخّم؟

الحلّ ١٩.٣ ✓

```
GENOMICCONTROL ON
PROCESS study1.txt
```

المخرجات المتوقعة:

```
Applying genomic control to study1 (lambda=1.08)
Inflation-adjusted statistics used
```

التفسير: التحكّم الجينومي يقسم إحصاءات كل دراسة على λ الخاص بها قبل الدمج، فيصحّ التضخم المتبقي في كل دراسة. هذا يمنع دراسة متضخمة من تلويث الميتا-أناليسيس ككله. لكن الأفضل عموماً معالجة التضخم في كل دراسة بنموذج مختلط (REGENIE/SAIGE) أصلاً.

المسألة ١٩٠٤ ★★ [متوسط]

اختبر التباين (I^2 ، Q لكوكران): حدّد القطع الأثرية الخاصة بدراسة.

✓ الحلّ ١٩٠٤

```
meta <- fread("metal_out.txt")
(MarkerName, Effect, HetISq, HetPVal)[HetISq > 75]
```

المخرجات المتوقعة:

MarkerName	Effect	HetISq	HetPVal
rs99021	0.08	88%	2e-7

(تباين شديد - من)

التفسير: $I^2 = 88\%$ يعني تبايناً شديداً بين الدراسات. قد يكون السبب: أثر تقني في دراسة واحدة (شريحة مختلفة)، أو فرق سكاني، أو خطأ أليل. المتغيرات عالية التباين تستحقّ فحصاً يدوياً قبل الوثوق بها. التباين الشديد إنذار لا يُجاهل.

المسألة ١٩٠٥ ★★★ [متقدّم]

استخدم GWAMA كأداةٍ بديلةٍ وقارن النتائجَ بـ METAL.

✓ الحلّ ١٩٠٥

```
lelist studies.txt --output gwama_results --random
```

المخرجات المتوقّعة:

```
GWAMA fixed-effect: matches METAL (cor=0.999)  
GWAMA random-effect: wider CIs for heterogeneous SNPs
```

التفسير: GWAMA يطابق METAL في الأثر الثابت (تأكيدٌ متبادل)، لكنّه يضيف الأثر العشوائيّ الذي يوسّع فتراتِ الثقة للمتغيّرات عالية التباين. الأثر العشوائيّ أكثرُ تحفظاً حين تكون الدراساتُ غيرَ متجانسة. استخدامُ أداتين يكشف الأخطاءَ الخاصّةَ بإحدهما.

المسألة ١٩٠٦ ★★★ [متقدّم]

أجرِ تحليلاً شرطياً ومشتركاً (GCTA-COJO): حدّد الإشاراتِ المستقلّة في نتائج الميّا.

✓ الحلّ ١٩.٦

```
\ gcta --bfile ref_panel --cojo-file meta.ma  
cojo-slct --out cojo_independent--
```

المخرجات المتوقعة:

```
Locus chr16: 3 independent signals identified  
(primary), rs77924 (secondary), rs34 (tertiary)
```

التفسير: COJO يستخدم مرجع LD لاكتشاف الإشارات المستقلة داخل موضع واحد من الإحصاءات الموجزة وحدها (لا يحتاج بيانات فردية). منطقة chr16 بها ٣ إشارات مستقلة – تعدد أليلي. هذا يكشف بنية معقدة يخفيها النظر إلى الإشارة الرائدة وحدها.

المسألة ١٩.٧ ★★★★★ [خبير]

ابن خط أنابيب ميتا كامل: QC ← توحيد ← METAL ← شرطي ←
تخطيط ← مخططات غابة للقمم.

الحلّ ١٩٠٧ ✓

```
}meta_pipeline <- function(studies)

d <- lapply(studies, qc_sumstats)          # 1. QC
.harmonized <- harmonize_alleles(qc'd)      # 2
<- run_metal(harmonized)                   # 3. METAL
.independent <- run_cojo(meta)              # 4
.finemap <- finemap_loci(independent)       # 5
.forest_plots <- make_forest(meta, top_hits) # 6
{
```

المخرجات المتوقعة:

خط أنابيب كامل: 5 دراسات → 67 موضعاً مستقلاً → مخططات

التفسير: الخطُّ الكامل يأخذ خمسَ دراساتٍ خامّة ويُخرج ٦٧ موضعاً مستقلاً
مع مخططات غابة توضّح اتّساق كلّ قَمّة عبر الدراسات. مخطّط الغابة هو التصويرُ
المعياريّ للميتا: كلّ دراسة خطُّ بفترة ثقة، والماسة في الأسفل هي التقديرُ المجمع.
هذا المنتج النهائي لأيّ تجمّع بحثيّ.

⚠ الأخطاء الشائعة وتصحيحها

Allele mismatch flips effects – وحد أليل التأثير بدقة
قبل الدمج. Sample overlap inflates – الدراسات المتداخلة
عيناتها تكسر الاستقلال؛ استخدم MTAG أو صحّح. Heterogeneity
– ignored – إحصاء I^2 دائماً. Genomic control double –
corrects – لا تطبقه إن كانت الدراسات مصحّحة بنموذج مختلط.
COJO needs matching LD ref – مرجع LD يطابق أصل
البيانات. Direction column all over – اتجاهات متضاربة
تنذر بأخطاء أليل. MAF filter inconsistent – وحد عتبات
الترشيح عبر الدراسات.

📖 الغوص العميق

الميتا-أناليسيس هو كيف تُكتشف معظم جينات الكلى. تجمعُ CKDGen –
الذي يدمج عشرات الدراسات لوظيفة الكلى – مثالٌ يحتذى، وقد استفدتُ من
نتائجهِ في عملي بجامعة ميشيغان. درسُ تعلّتهُ بألم: تداخلُ العينات قاتلٌ صامت.
مرّةً، دمجنا دراستين دون أن ندري أنّهما تشاركان ٣٠٪ من العينات (مرضى
جندوا في دراستين)، فتضخّمت نتائجنا لأنّ الاستقلال مكسور. اكتشفنا الخطأ
بفحص الإحصاءات المتوقّعة وصحّحناه. الدرس: تحقّق دائماً من تداخل العينات
قبل الدمج. كما تعلّمتُ أنّ توحيد الأليلات – الخطوة المملّة الظاهرة – هو أكثرُ

ما يفسد الميتا حين يُهمل: أليلٌ مقلوبٌ في دراسةٍ يقلب اتجاه أثرها، فيُلغى إشارةٌ حقيقية.

🔗 تحدّ مفتوح

صمّم طريقةً لكشف تداخل العيّات الخفيّ بين دراساتٍ تشارك إحصاءاتها الموجزة فقط (دون الوصول للبيانات الفردية لأسباب خصوصية)، باستخدام الارتباط بين إحصاءات الاختبار تحت الصفر. كم نسبةً تداخلٍ يمكن كشفها بموثوقية؟ وكيف تصحّح الميتا-أناليسيس للتداخل المكتشف؟

📖 مراجع أساسية

- Willer C.J. et al. (2010). "METAL: fast and efficient meta analysis :Magi R., Morris A.P. (2010). "GWAMA .*Bioinformatics* ".analysis *BMC* ".software for genome-wide association meta-analysis
- Yang J. et al. (2012). "Conditional and joint .*Bioinformatics* Wuttke .*Nature Genetics* ".multiple-SNP analysis (GCTA-COJO)
- M. et al. (2019). "A catalog of genetic loci for kidney function .*Nature Genetics* ".(CKDGen)

الفصل العشرون — التفاعل الجيني والبيئي / Gene-Environment Interaction

﴿إِنَّ اللَّهَ لَا يَغَيِّرُ مَا بَقِيَ حَتَّى يَغَيِّرُوا مَا بِأَنْفُسِهِمْ﴾

— سورة الرعد: ١١

التغيير يأتي من تفاعل الداخل مع الخارج؛ والتفاعل الجيني البيئي هو هذا بالضبط: أثر الجين (الداخل) يتغير بحسب البيئة (الخارج). فقد يكون لمتغير أثر في بيئة ويختفي في أخرى.

📖 سيناريو بحثي

هل يتعدّل الخطر الجيني للسكري بمؤشر كتلة الجسم (BMI)؟ تختبر التفاعل الجيني البيئي (GxE): قد يكون لمتغير أثر قوي في الأشخاص ذوي BMI العالي وضعيف في النحفاء. هذا يفسّر لماذا "تختفي" بعض الآثار الجينية في بيئات معينة، ويكشف بيولوجيا أعمق من الأثر الرئيسي وحده.

GxE صعب إحصائياً (قوة منخفضة، إيجابيات كاذبة من عدم تجانس التباين)، لكنه ضروري لفهم كيف تتفاعل الجينات مع نمط الحياة. هذا الفصل يعلمك كشفه وتجنب فخاخه.

مجموعة البيانات لهذا الفصل

بيانات T2D + متغير بيئي (BMI) + أنماط جينية

أهداف التعلم

بعد هذا الفصل تستطيع: (١) نموذج GxE الضريبي؛ (٢) GWAS تفاعلياً؛ (٣) اختبار الدرجتين؛ (٤) REGENIE للتفاعل؛ (٥) تصحيح GxE الزائف؛ (٦) تصوير GxE؛ (٧) كشف التفاعل النقي.

الخلفية الأساسية

نموذج التفاعل الضريبي يضيف حد تفاعل إلى الانحدار:

$$g(E[y]) = \beta_0 + \beta_G G + \beta_E E + \beta_{GE} (G \times E)$$

المعامل β_{GE} هو التفاعل: إن كان معنوياً، فأثر الجين يعتمد على البيئة. الحد $G \times E$ هو حاصل ضرب النمط في المتغير البيئي.

تشبيه: التفاعل كبدرة ومناخ. البذرة (الجين) نفسها قد تنبت شجرةً باسقةً في تربةٍ خصبة (بيئة) وتذبل في صحراء. أثر البذرة لا يفهم دون مناخها. GxE يقيس كم يعتمد "نمو" الأثر الجيني على "مناخ" البيئة المحيطة.

؟ المسائل

المسألة ٢٠٠١ ★★ [متوسط]

نموذجُ GxE الضريّ: حدُّ التفاعل في الانحدار اللوجستيّ؛ فسّر المعامل.

✓ الحلّ ٢٠٠١

```
model <- glm(T2D ~ SNP * BMI + AGE + SEX + PC1 + PC2
              (data=d, family=binomial
summary(model)$coefficients["SNP:BMI", ]
```

المخرجات المتوقعة:

Estimate	Std.Error	z value	Pr(> z)
6e-6	4.5	0.004	0.018

التفسير: معاملُ التفاعل SNP:BMI = ٠,٠١٨ معنويٌّ ($p=٦ \times ١٠^{-6}$) وموجب: أثرُ أليل الخطر يزداد مع BMI. أي إنّ المتغيرَ يرفع خطرَ السكري أكثر في البدناء

منه في النحفاء. هذا تفاعلٌ حقيقيٌّ يكشف أنَّ الجينَ والبيئة لا يعملان منفصلين.

المسألة ٢٠٠٢ ★★ [متوسط]

GWAS تفاعليّ: اختر كلَّ SNP للتفاعل مع BMI.

الحلّ ٢٠٠٢ ✓

```
\ plink2 --bfile data --glm interaction/.  
\ pheno t2d.txt --covar covar.txt--  
parameters 1-3,7 --out gxe_gwas--
```

المخرجات المتوقعة:

عبر الجينوم: 3 متغيرات بتفاعل GxE معنوي ($p < 5e-8$)
معظمها قرب جينات استقلاب الدهون

التفسير: GWAS التفاعليّ يبحث عن متغيرات يعتمد أثرها على البيئة عبر الجينوم.
القوة أقل بكثير من الأثر الرئيسيّ (نحتاج عينات أكبر لكشف التفاعل)، فعدد
الاكتشافات قليل. تركّزها قرب جينات استقلاب الدهون منطقيّ بيولوجياً.

المسألة ٢٠٠٣ ★★ [متوسط]

اختبار الدرجتين (2DF): أقوى لكشف GxE.

✓ الحل ٢٠٠٣

```
# اختبار مشترك للأثر الرئيسي والتفاعل معاً (درجتا حري  
glm(T2D ~ SNP + SNP:BMI + covars, family=binomial)  
null <- glm(T2D ~ covars, family=binomial)  
2DF اختبار # anova(null, full, test="Chisq")
```

المخرجات المتوقعة:

2DF P: 2e-9 (أقوى من اختبار التفاعل وحده)

التفسير: اختبار الدرجتين يختبر الأثر الرئيسي والتفاعل معاً، فيكشف متغيرات لها أثر رئيسي معتدل وتفاعل معتدل، قد يفوتها اختبار كل على حدة. أقوى حين يكون للمتغير أثر في كلا البعدين. مقيضته: لا يميز هل الإشارة من الأثر الرئيسي أم التفاعل.

المسألة ٢٠٠٤ ★★★ [متقدم]

REGENIE للتفاعل: شغل علم --interaction، وفسر النتائج.

✓ الحل ٢٠٠٤

```
\ regenie --step 2 --bgen data.bgen --bt/.  
\ phenoFile t2d.txt --interaction BMI--  
pred pred.list --out gxe_regenie--
```

المخرجات المتوقعة:

ID	BETA_main	BETA_int	P_int	P_2df
rs7903146	0.31	0.012	3e-4	1e-50

التفسير: REGENIE يُخرج الأثر الرئيسي والتفاعل و2DF معاً، مع ضبط القرابة والبنية. $p_{int} (3 \times 10^{-4})$ للتفاعل أضعف من الأثر الرئيسي — نمط شائع: الأثر الرئيسي قوي والتفاعل خفيف. REGENIE يجعل GxE واسع النطاق ممكناً للبنوك الحيوية.

المسألة ٢٠٠٥ ★★★ [متقدم]

صحّح GxE الزائف: اختباراً ثابت المقياس (OSCA) لعدم تجانس تباين الصفة.

✓ الحل ٢٠٠٥

```
-vqtl --befile expr --pheno t2d.txt --out vqtl_test
```

المخرجات المتوقعة:

3 من أصل 5 تفاعلات GxE اختفت بعد تصحيح vQTL
السبب: عدم تجانس تباين على مقياس غير صحيح

التفسير: خطرٌ كبير: التفاعلُ الزائف قد ينشأ من عدم تجانس تباين الصفة لا من تفاعلٍ بيولوجيٍّ حقيقيٍّ. لو كان تباينُ الصفة يختلف بين فئات البيئة، ظهر تفاعلٌ كاذب. اختبارُ vQTL يكشف هذا: ٣ من ٥ تفاعلات كانت زائفة. التحويلُ المناسب للصفة (مثل اللوغاريتم) قد يزيلها. هذا أكثرُ نفاخ GxE خداعاً.

المسألة ٢٠٠٦ ★★★ [متقدم]

صوّر GxE: ارسم الخطرَ الجينيَّ حسب رُبع البيئة؛ نمطُ "المروحة".

الحلّ ٢٠٠٦ ✓

```
d[, bmi_quartile := cut(BMI, quantile(BMI, 0:4/4))]  
(risk=mean(T2D)), by=.(SNP_genotype, bmi_quartile)]  
sk_by, aes(SNP_genotype, risk, color=bmi_quartile))  
("GxE = نمط المروحة"=title)geom_line() + labs
```

المخرجات المتوقعة: خطوطُ تباعد ("مروحة"): في BMI المنخفض، الخطرُ ثابتٌ
عبر الأنماط؛ في BMI العالي، الخطرُ يرتفع بحدّةٍ مع أليل الخطر.

التفسير: "نمط المروحة" هو التوقع البصري للفاعل: الخطوط متوازية تعني لا تفاعل، ومتباعدة تعني تفاعلاً. هنا أثر الجين يظهر فقط في BMI العالي – تفاعل واضح. التصوير يجعل التفاعل المجرد ملهوساً وقابلاً للتواصل.

المسألة ٢٠٠٧ ★★★★★ [خير]

حدّد متغيّرات GxE بلا أثر رئيسي – سيناريو "التفاعل النقي" ولماذا هو نادر.

الحلّ ٢٠٠٧ ✓

متغيّرات بتفاعل معنوي لكن أثر رئيسي غير معنوي

```
re_int <- gxe_results[P_int < 5e-8 & P_main > 0.05]
```

المخرجات المتوقعة:

تفاعلات نقية (بلا أثر رئيسي): 1 من أصل 4

التفسير: التفاعل النقي (أثر في اتجاه بيئة، وعكسي بأخرى، فيُلغى الأثر الرئيسي) نادر جداً. مثاله: أليل نافع في الجوع وضار في الوفرة، فيختفي أثره الرئيسي في عينة مختلطة. ندرته تعني أنّ البحث عنه وحده غير مجدٍ عادةً؛ اختبار 2DF (الذي يجمع الرئيسي والتفاعل) أكفأ من البحث عن التفاعل النقي.

⚠ الأخطاء الشائعة وتصحيحها

- Spurious GxE from variance heterogeneity
- Low power for interaction. اختبار vQTL وحول الصفة.
- GxE يحتاج عينات أكبر $\times 4$ من الأثر الرئيسي. Scale dependence
- التفاعل الضري قد يختفي على مقياسٍ جمعي. Environment measurement error — يخفف التفاعل الحقيقي.
- Collinearity G and E — حدُّ التفاعل غير مستقر.
- Multiple testing for GxE — العتبة نفسها 1.0×10^{-8} .
- Confounded environment — البيئة قد ترتبط بالأصل، اضبط.

📖 الغوص العميق

في أبحاث الكلى بجامعة ميشيغان، التفاعلُ الجينيُّ البيئيُّ مجالٌ آسرٌ لكنه مليءٌ بالفخاخ. أكبرُ درسٍ تعلَّمته: معظمُ "تفاعلات GxE" المنشورة المبكرة كانت زائفة، ناتجةً عن عدم تجانس تباین الصفة أو خطأ القياس، لا عن بيولوجيا. حين بدأنا نختبر تفاعل المتغيرات الجينية مع السكرّي وضغط الدم في تدهور الكلى، طبقنا اختبارَ vQTL بصرامة، فاختفى معظمُ التفاعلات "المثيرة". الدرسُ: الشكُّ الصحيُّ في GxE فضيلة. التفاعلُ الحقيقيُّ نادرٌ ويحتاج قوةً هائلة. لكن حين يصمد التفاعلُ أمام كلِّ الفحوص، يكشف بيولوجيا ثينة: كيف يعدلُ نمط الحياة الخطرَ الجينيُّ — معلومة ذات قيمةٍ سريريةٍ مباشرة للوقاية.

📖 تحدّ مفتوح

في المجتمعات العربية، التحوّل الغذائيّ السريع (من نمطٍ تقليديّ إلى غربيّ) خلق تبايناً بيئياً حاداً بين الأجيال. صمّم دراسةً تستغلّ هذا "التجربة الطبيعية" لكشف تفاعلات GxE للسكري: هل الآثارُ الجينية التي ظهرت مع التحوّل الغذائيّ تكشف متغيّراتٍ تفاعليّةً يخفيها مجتمعٌ غذائياً متجانسٌ؟ كيف تميّز التفاعل الحقيقيّ من أثر العمر المتزامن؟

📖 مراجع أساسية

- Aschard H. et al. (2012). "Inclusion of gene-gene and gene .Marderstein A.R. et al. (2021) *AJHG* "environment interactions .Kerin M., Marchini J *AJHG* ".vQTL analysis and GxE (OSCA)" Inferring gene-environment interactions with" .(2020)
.Gauderman W.J. et al. (2017) *Nature Genetics* ".REGENIE
.Am J Epidemiol ".Update on the state of the science for GxE"

الفصل الحادي والعشرون — العشوائية المنдлиّة: طرق

متقدمة / Mendelian Randomization:

Advanced Methods

﴿وَخَلَقَ الْإِنْسَانَ ضَعِيفًا﴾

— سورة النساء: ٢٨

خُلِقَ الْإِنْسَانُ ضَعِيفًا، عاجزاً عن إجراء تجاربٍ مثاليةٍ على نفسه؛ لكنّ الطبيعةَ أجرت "تجربةً عشوائيةً" عند الولادة بتوزيع الأليلات. العشوائيةُ المنдлиّة تستغلّ هذه التجربةَ الإلهيةَ لاختبار السببية حيث يعجز الإنسان.

📖 سيناريو بحثي

هل يسبّب ارتفاعُ BMI زيادةَ خطر القصور الكلويّ سببياً؟ هل يؤثر مرضُ الكلى سببياً في ضغط الدم؟ هذه أسئلةٌ سببية لا يمكن حلّها بالملاحظة وحدها (الارتباطُ ليس سببية). العشوائيةُ المنдлиّة (MR) تستخدم المتغيّرات الجينية "متغيّرات أداتية" لاختبار السببية، لأنّ الجينات تُوزّع عشوائياً عند التكوين، فهي محصّنةٌ من معظم الخلط.

MR ثورة في الاستدلال السببي الوباي: تحاكي تجربة عشوائية مضبوطة باستخدام بيانات رصدية. هذا الفصل يعلّك طرقها المتقدمة وفحوص متانتها.

مجموعة البيانات لهذا الفصل

library(TwoSampleMR)

إحصاءات GWAS للتعرض (BMI) والنتيجة (CKD) من GWAS

أهداف التعلم

بعد هذا الفصل تستطيع: (١) MR بعينتين (IVW)؛ (٢) MR-Egger؛ (٣) الوسيط والمنوال المرّحين؛ (٤) MR-PRESSO؛ (٥) MR ثنائي الاتجاه؛ (٦) MR متعدّد المتغيّرات؛ (٧) ترشيح Steiger؛ (٨) خطّ أنابيب كامل.

الخلفية الأساسية

تعتمد MR على ثلاثة افتراضات للأداة الجينية: (١) ترتبط بالتعرض، (٢) لا ترتبط بالمربكات، (٣) تؤثر في النتيجة فقط عبر التعرض (لا تعدّد وظائف).
مقدّر IVW:

$$\beta_{Xj} / \sigma_{Yj} \bigg/ \sqrt{\frac{\sum_j \beta_{Xj}^2}{\sum_j \sigma_{Yj}^2}} = \hat{MR}_{\beta}$$

حيث β_{Xj} أثر المتغير على التعرض و β_{Yj} على النتيجة.

تشبيه: الأداة الجينية كقرعة نزيهة وزعت الناس عشوائياً إلى "ميل جيني لارتفاع BMI" أو لا، عند الولادة. بما أن القرعة عشوائية (لا تختار نمط الحياة)، فأى فرق في خطر الكلى بين المجموعتين سببي على الأرجح. الطبيعة أجرت التجربة التي يحرمها الأخلاق علينا.

المسائل ؟

المسألة ٢١٠١ ★ [مبتدئ]

MR بعينتين بـ TwoSampleMR (طريقة IVW)؛ فسر OR وفترة الثقة.

الحل ٢١٠١ ✓

```
library(TwoSampleMR)
exposure <- extract_instruments("ieu-a-2") # BMI
outcome <- extract_outcome_data(exposure$SNP, "ieu-a-CKD")
dat <- harmonise_data(exposure, outcome)
mr(dat, method_list="mr_ivw")
```

المخرجات المتوقعة:

method	nsnp	b	se	pval	OR (95% CI)
78	0.32	0.06	3e-7	1.38	(1.22-1.56)

التفسير: $OR=1.38$ يعني أنّ كلّ زيادةٍ انحرافٍ معياريّ في BMI (جينيّاً) ترفع خطرَ الكلى 38% ، سببياً. $p=3 \times 10^{-7}$ معنويّ. IVW يفترض أنّ كلّ الأدوات صالحة (لا تعدّد وظائف) – افترضُ نختبره بالطرق التالية.

المسألة ٢١.٢ ★★ [متوسط]

MR-Egger: اكشف وصحّح تعدّد الوظائف؛ فسّر التقاطع.

الحلّ ٢١.٢ ✓

```
mr(dat, method_list=c("mr_egger_regression"))
Egger # اختبار تقاطع
```

المخرجات المتوقّعة:

```
Egger slope: 0.29 (se 0.08)
Egger intercept: 0.004 (p=0.6) # لا تعدّد وظائف اتج
```

التفسير: تقاطع Egger غير معنويّ ($p=0.6$) – مطمئن: لا تعدّد وظائف اتجهاً (الأدوات لا تؤثر في الكلى إلّا عبر BMI). لو كان التقاطع معنوياً، لدلّ

على أن بعض الأدوات تؤثر في النتيجة بطرقٍ أخرى، فتُحيز IVW. ميل Egger (٢٩,٠) قريبٌ من IVW — اتّساقٌ يعزّز الثقة.

المسألة ٢١.٣ ★★ [متوسط]

الوسيطُ والمنوالُ المرّحّان: لماذا هما متينان أمام الأدوات الشاذّة؟

✓ الحلّ ٢١.٣

```
pd_list=c("mr_weighted_median","mr_weighted_mode"))
```

المخرجات المتوقّعة:

Weighted median: b=0.31 (p=2e-6)

Weighted mode: b=0.28 (p=1e-4)

التفسير: الوسيطُ المرّحّ صالحٌ حتى لو كان حتى ٥٠٪ من الأدوات غير صالح (متين أمام الشواذ). المنوالُ يفترض أنّ أكبر مجموعةٍ متنسقةٍ من الأدوات صحيحة. تطابقُ الطرق الثلاث (IVW=٣٢,٠، وسيط=٣١,٠، منوال=٢٨,٠) دليلٌ قويٌّ على سببيةٍ حقيقيةٍ — لا تعتمد على طريقةٍ واحدة.

المسألة ٢١.٤ ★★ [متوسط]

MR-PRESSO: كشفُ الشواذِّ وتصحيحُها؛ تحليلٌ تركٍ واحدٍ.

الحلّ ٢١.٤ ✓

```
library(MRPRESSO)

Outcome="beta.outcome", BetaExposure="beta.exposure",
SdOutcome="se.outcome", SdExposure="se.exposure",
NbDistribution=1000
```

المخرجات المتوقعة:

```
Global test P: 0.02 (يوجد شواذ)
Outliers detected: rs1558902, rs9939609
Corrected estimate: 0.30 (بعد إزالة الشواذ)
```

التفسير: MR-PRESSO يكشف الأدوات الشاذة (متعددة الوظائف) ويزيلها. الاختبار العام معنوي ($p=0.02$) يعني وجود شواذ. بعد إزالة متغيّرين شاذّين، التقدير المصحّح (0.30) قريب من الأصليّ – السببية صامدة. تحليل "ترك واحد" يتحقّق ألا تعتمد النتيجة على متغيّر مفرد.

المسألة ٢١.٥ ★★★ [متقدّم]

MR ثنائي الاتجاه: هل A يسبّب B، أم B يسبّب A، أم كلاهما؟

✓ الحلّ ٢١.٥

```
# الاتجاه الأمامي: BMI -> CKD
forward <- mr(harmonise_data(bmi_inst, ckd_out))

# الاتجاه العكسي: CKD -> BMI
reverse <- mr(harmonise_data(ckd_inst, bmi_out))
```

المخرجات المتوقعة:

BMI -> CKD: $b=0.32$, $p=3e-7$ (سببي)
CKD -> BMI: $b=0.02$, $p=0.7$ (غير سببي)

التفسير: MR ثنائي الاتجاه يحلّ مشكلة "أيّهما أولاً". هنا BMI يسبّب CKD (معنوي) لكنّ CKD لا يسبّب BMI (غير معنوي) – اتجاه سببي واضح من BMI إلى الكلى. لو كان كلاهما معنوياً، لدلّ على سببية متبادلة أو مربك مشترك. هذا يحجي من الاستنتاج العكسي الخاطئ.

المسألة ٢١.٦ ★★★ [متقدّم]

MR متعدّد المتغيّرات (MVMR): الأثر المباشر مقابل الوسيط.

✓ الحلّ ٢١.٦

```
library(MVMR)
```

```
# هل أثر BMI على CKD مباشر أم عبر ضغط الدم؟
```

```
mvmr_result <- mvmr(bmi_bp_exposures, ckd_outcome)
```

المخرجات المتوقعة:

BMI (مضبوط لضغط الدم) : $b=0.21$, $p=2e-4$

BP (مضبوط لـ BMI) : $b=0.18$, $p=1e-3$

التفسير: MVMR يفصل الآثار حين تكون التعرّضات مترابطة. بعد ضبط ضغط الدم، يبقى لـ BMI أثرٌ مباشرٌ على الكلى (٠,٢١، أقلُّ من ٠,٣٢ غير المضبوط) — أي إنّ جزءاً من أثره يمرّ عبر ضغط الدم (وساطة)، وجزءاً مباشراً. هذا يفكّك الشبكة السببية.

المسألة ٢١.٧ ★★★ [متقدّم]

ترشيح Steiger: أزل الأدوات التي تفسّر تبايناً في النتيجة أكثر من التعرّض.

✓ الحل ٢١٠٧

```
dat <- steiger_filtering(dat)
dat_valid <- dat[dat$steiger_dir == TRUE, ]
```

المخرجات المتوقعة:

3 أدوات أزيلت (تفسر النتيجة أكثر من التعرض)
الاتجاه السببي مؤكد بعد الترشيح

التفسير: ترشيح Steiger يتحقق من اتجاه السببية لكل أداة: إن كان متغير يفسر
تباين النتيجة (CKD) أكثر من التعرض (BMI)، فقد يكون الاتجاه معكوساً،
فنزيله. هذا يعني من أدوات "خاطئة الاتجاه" تشوه الاستنتاج. أداة مهمة لضمان
صحة الاتجاه السببي.

المسألة ٢١٠٨ ★★★★★ [خبير]

خط MR كامل: اختيار التعرض ← استخراج الأدوات ← توحيد ← ٦
طرق ← فحوص متانة ← مخطط غابة ← نص المنهجية.

الحل ٢١٠.٨ ✓

```

}full_mr <- function(exposure_id, outcome_id)
  inst <- extract_instruments(exposure_id)
  out <- extract_outcome_data(inst$SNP, outcome_id)
  dat <- harmonise_data(inst, out)
  dat <- steiger_filtering(dat)
  results <- mr(dat) # كل الطرق
  sensitivity <- list(egger=mr_pleiotropy_test(dat)
    ,presso=run_presso(dat)
    (het=mr_heterogeneity(dat)
    sensitivity=sensitivity, plot=mr_forest_plot(dat))
  {

```

التفسير: الخطُّ الكامل ينتج استنتاجاً سببياً موثقاً مدعوماً بستّ طرقٍ وفُوصٍ متانةً متعدّدة. المبدأ الذهبيّ في MR: لا نثق بطريقةً واحدة؛ السببية الحقيقية تصمد عبر IVW و Egger والوسيط و PRESSO معاً. مخطّط الغابة يُظهر اتّساق الأدوات، ونصّ المنهجية يوثق كلّ خطوةٍ للنشر.

⚠ الأخطاء الشائعة وتصحيحها

Weak instruments bias — تحقق من $F\text{-statistic} > 10$ لكل أداة. Pleiotropy undetected. شغل Egger وPRESSO دائماً. Sample overlap (one-sample MR) — يحيز نحو الرصد؛ استخدم عيّنتين منفصلتين. Wrong causal direction — طبق Steiger. Harmonisation flips — تحقق من توحيد الأليات. Few instruments — قوة منخفضة؛ خفف عتبة الأداة بحذر. Winner's curse in instruments — استخدم عينة اكتشاف منفصلة للأدوات.

📖 الغوص العميق

العشوائية المندلية أداة آسرة في أبحاث الكلى بجامعة ميشيغان، لكنها تتطلب انضباطاً صارماً. استخدمناها لاختبار: هل عوامل الخطر القلبية الأيضية (BMI، ضغط الدم، السكري) تسبب تدهور الكلى سببياً، أم مجرد مرافقات؟ النتائج وجهت أولويات التدخل. أكبر درس تعلمته: تعدد الوظائف (pleiotropy) هو عدو MR الأول. متغير يؤثر في عدة صفات مستقلة يكسر افتراض "التأثير عبر التعرض فقط"، فيعطي سببية زائفة. لهذا لا أنشر استنتاجاً سببياً إلا بعد أن يصمد أمام Egger وPRESSO وSteiger معاً. تحذير خاص بالعرب: أدوات

MR مشتقة من GWAS أوروبي، فتطبيقها على أسئلة سببية في العرب يفترض أن الآثار منقولة – افترض يحتاج تحققاً.

🔗 تحدٍ مفتوح

معظم أدوات MR مشتقة من GWAS أوروبي. صمّم إطار "MR عابر للأصول" يستخدم أدوات من أصول متعددة لاختبار سببية في العرب، مع التحقق من أن الأداة صالحة (ترتبط بالتعرض) في الأصل العربي. هل تختلف التقديرات السببية بين الأصول؟ وإن اختلفت، أهو تعدد وظائف أم تفاعل بيئي حقيقي؟

📖 مراجع أساسية

- Hemani G. et al. (2018). "The MR-Base platform supports systematic causal inference". *eLife*.
- Bowden J. et al. (2015). "Mendelian randomization with invalid instruments (MR)-Detection of widespread horizontal pleiotropy (MR-PRESSO)". *Int J Epidemiol*.
- (Egger Verbanck M. et al. (2018). "Detection of widespread horizontal pleiotropy (MR-PRESSO)". *Nature*.
- Sanderson E. et al. (2019). "An examination of multivariable MR". *Int J Epidemiol*.

الفصل الثاني والعشرون — تحليل البقاء الجينومي Survival GWAS and / الوقت حتى الحدث Time-to-Event Analysis

﴿كُلُّ نَفْسٍ ذَائِقَةُ الْمَوْتِ﴾

— سورة آل عمران: ١٨٥

كُلُّ نَفْسٍ ذَائِقَةُ الْمَوْتِ؛ والسؤال ليس "هل" بل "متى". تحليل البقاء يدرس توقيت الأحداث (الفشل الكلوي، الوفاة)، لا مجرد وقوعها — فالوقت معلومة ثمينة يهدرها تحليل النعم/لا.

 سيناريو بحثي

مجموعتك للقصور الكلوي المزمن لديها بيانات متابعة. تريد اختبار أي المتغيرات تنبأ ب زمن الوصول إلى الفشل الكلوي. تحليل الارتباط الثنائي (وصل/لم يصل) يهدر معلومة التوقيت؛ مريض وصل في سنة يختلف عن مريض وصل في عشر. تحليل البقاء يستغل هذا التوقيت، فيزيد القوة ويكشف بيولوجيا التقدم لا مجرد الإصابة.

تحليلُ البقاءِ أساسيٌّ في الطبِّ السريريِّ حيثُ المتابعةُ الزمنيةُ متاحة. هذا الفصلُ يدمجه مع GWAS لكشف الجينات التي تسرّع أو تبطئ تقدّم المرض.

مجموعة البيانات لهذا الفصل

بيانات CKD: زمن المتابعة + حالة الحدث (وصل للفشل / library(survival)

أهداف التعلّم

بعد هذا الفصل تستطيع: (١) نموذج كوكس لمتغيّر مفرد؛ (٢) GWAS بقائياً؛ (٣) REGENIE للبقاء؛ (٤) المخاطر المتنافسة؛ (٥) متغيّرات متغيرةً زمنياً؛ (٦) PRS بقائياً؛ (٧) تحليل المعالم الزمنية.

الخلفية الأساسية

نموذج كوكس للمخاطر المتناسبة يَتمدّل الخطر اللحظيّ (hazard):

$$h(t) = h_0(t) \cdot \exp(\beta_G G + \sum \beta_k X_k)$$

حيث e^{β_G} نسبة الخطر (HR). $HR < 1$ يعني أنّ الأليل يسرّع الحدث. ميزته أنّه يستخدم كلّ المرضى حتى المراقبين (censored) الذين لم يقع لهم الحدث بعد.

تشبيه: التحليلُ الثنائيُّ يسأل "هل وصل القطار؟" (نعم/لا)، أمّا تحليلُ البقاء فيسأل "متى وصل، ولم انتظر من لم يصل بعد؟". المعلومةُ في التوقيت غنيّةٌ جدًّا: مريضان "وصلا للفشل" لكنّ أحدهما في سنةٍ والآخر في عشرٍ مختلفان بيولوجيًّا تمامًا، والتحليلُ الثنائيُّ يساويهما زيفًا.

؟ المسائل

المسألة ٢٢.١ ★★ [متوسط]

نموذجُ كوكسٍ لمتغيّرٍ مفرد؛ تحقّق من الافتراضات (بقايا شوينفلد).

✓ الحلّ ٢٢.١

```
library(survival)
time, event) ~ SNP + AGE + SEX + PC1 + PC2, data=d)
summary(fit)$coefficients["SNP", ]
cox.zph(fit) # اختبار التناسب
```

المخرجات المتوقّعة:

SNP: HR=1.34 (95% CI 1.18-1.52), p=4e-6
cox.zph SNP: p=0.42 (الافتراض صامد)

التفسير: HR=١,٣٤ يعني أنّ كلّ نسخة من أليل الخطر تسرّع الوصول للفشل الكليّ بمعدّل خطر أعلى ٣٤٪. اختبار شوينفلد ($p=٠,٤٢$) يؤكّد افتراض "المخاطر المتناسبة" (أثر الجين ثابت عبر الزمن). لو فشل (p صغير)، لاحتجنا متغيّرات متغيّرة زمنياً.

المسألة ٢٢.٢ ★★ [متوسط]

GWAS بنتيجة بقائية: نهج PLINK2 أو R.

✓ الحل ٢٢.٢

```
# GWAS بقائي في R (متوازٍ)
library(GWASTools)

}results <- lapply(snp_list, function(snp)
  exph(Surv(time,event) ~ genotypes[,snp] + covars)
summary(fit)$coefficients[1, c("coef","Pr(>|z|)")]

({
```

المخرجات المتوقعة:

عبر الجينوم: 8 مواضع تتنبأ بتقدّم الكلى ($p<5e-8$) بعضها يختلف عن مواضع الإصابة (incidence)

التفسير: GWAS البقائي يكشف جيناتِ التقدّم لا الإصابة – وقد تكون مختلفة! جينٌ قد يسبّب المرضَ لكن لا يؤثّر في سرعة تقدّمه، أو العكس. هذا التمييز مهمٌ سريريّاً: نريد جيناتِ التقدّم لتحديد المرضى الذين سيتدهورون بسرعة.

المسألة ٢٢.٣ ★★ [متوسط]

REGENIE لنتائج البقاء بنموذج كوكس.

الحلّ ٢٢.٣ ✓

```
\ regenie --step 2 --bgen data.bgen --t2e/.  
\ phenoFile survival.txt --eventColList event--  
pred pred.list --out cox_gwas--
```

التفسير: `--t2e` (time-to-event) يفعل نموذج كوكس في REGENIE، فيجمع كفاءة النماذج المختلطة (ضبط القرابة) مع تحليل البقاء واسع النطاق. هذا يجعل GWAS البقائي ممكناً للبنوك الحيوية الكبرى، حيث كان سابقاً مكلفاً حسابياً. يضبط التضخم كما في الصفات الأخرى.

المسألة ٢٢.٤ ★★★ [متقدّم]

المخاطر المتنافسة: الفشل الكلوي مقابل الوفاة – نموذج Fine-Gray.

✓ الحل ٢٢.٤

```
library(cmprsk)

# الوفاة قبل الفشل الكلوي "تنافس" الحدث المعني
<- crr(time, event_type, cov=cbind(SNP, AGE, SEX))

# 0=event_type: مراقب, 1=فشل كلوي, 2=وفاة
```

المخرجات المتوقعة:

```
SNP subdistribution HR: 1.28 (p=3e-4)
(أقل من Cox العادي لأنه يحسب منافسة الوفاة)
```

التفسير: المخاطر المتنافسة مشكلةٌ جوهرية: المريض الذي يموت قبل الفشل الكلوي لا يمكن أن "يصل للفشل" — الوفاة تنافس الحدث. نموذج كوكس العادي يتجاهل هذا فيتحيّز. Fine-Gray يحسب المنافسة، فيعطي HR أدق (١,٢٨ مقابل تقدير متضخم في كوكس). حاسم في كبار السن حيث الوفاة شائعة.

المسألة ٢٢.٥ ★★★ [متقدم]

متغيرات متغيرةً زمنياً: حين لا تكفي المتغيرات الأساسية.

✓ الحل ٢٢.٥

```
# ضغط الدم يتغير عبر المتابعة - نموذج زمني متغير  
coxph(Surv(start, stop, event) ~ SNP + BP_timevarying  
      (data=long_format
```

التفسير: بعض العوامل (ضغط الدم، الدواء) تتغير عبر المتابعة، فلا تكفي قيمتها الأساسية. النموذج المتغير زمنياً يستخدم قيمتها في كل نقطة زمنية. يتطلب بيانات بصيغة طويلة (صف لكل فترة). هذا يقدّر أثر الجين بضبط العوامل المتغيرة الحقيقية لا قيمها الأولية فقط.

المسألة ٢٢.٦ ★★★ [متقدم]

PRS بقائي: ادج متغيرات الخطر في متنبّي للوقت حتى الحدث؛ تحقق بـ C-statistic.

✓ الحل ٢٢.٦

```
d[, prs := compute_prs(genotypes, weights)]  
coxph(Surv(time, event) ~ prs + clinical, data=d)  
concordance(fit)$concordance # C-statistic
```

المخرجات المتوقعة:

C-statistic (سريري فقط) : 0.68

C-statistic (سريري + PRS) : 0.72

التفسير: PRS البقائي يتنبأ بسرعة التقدم لا مجرد الإصابة. C-statistic (نظير AUC للبقاء) يرتفع من ٠.٦٨ إلى ٠.٧٢ بإضافة الجين - تحسن في التمييز الزمني. هذا يساعد على تحديد المرضى الذين سيتدهورون بسرعة، فيعطون متابعة أكثر مكرراً.

المسألة ٢٢.٧ ★★★★★ [خير]

تحليل المعالم (landmarking): تنبأ بالخطر المستقبلي عند نقاط زمنية مختلفة
بدمج الجين والسريري.

✓ الحل ٢٢.٧

```
# عند كل معلم زمني (سنة 1، 3، 5)، أعد بناء النموذج
landmark_predict <- function(landmark_time)
{
  survivors <- d[time > landmark_time]
  event ~ prs + updated_clinical, data=survivors
}
```

التفسير: تحليل المعالم يجب سؤالاً سريريًا واقعيًا: "هذا المريض نجا ٣ سنوات؛ ما خطره في الخمس القادمة؟" بإعادة بناء النموذج للناجين عند كل معلم، نُحدّث

التنبؤ ديناميكياً بالمعلومات الجينية والسريية المتاحة وقتها. هذا أقرب لكيفية اتخاذ القرارات السريية فعلياً — تنبؤ متجدد لا ثابت.

⚠ الأخطاء الشائعة وتصحيحها

Proportional hazards violated — اختبار cox.zph؛
استخدم متغيرات متغيرة زمنياً. — Competing risks ignored
استخدم Fine-Gray حين الوفاة شائعة. Censoring
informative — افترض الاستقلال بحذر. Binary instead
of survival — يهدر معلومة التوقيت. C-statistic vs
AUC confusion — C للبقاء، AUC للثنائي. Time-varying
needs long format — صف لكل فترة. Immortal time
bias — انتبه لتعريف بداية المتابعة.

📖 الغوص العميق

في دراسة تدهور الكلى بجامعة ميشيغان، تحليل البقاء غير فهمنا جذرياً. اكتشفنا أن بعض الجينات تنبأ بسرعة التدهور لكن ليس بالإصابة الأولية — تمييز يفوته التحليل الثنائي تماماً. مريضان قد يُصابان بالقصور الكلوي، لكن جيناهما تحدّد هل يصلان لغسيل الكلى في سنتين أم في عشرين. أكبر درسٍ تعلّمته: المخاطر المتنافسة تُخفي. في مرضى الكلى المسنين، كثير يموتون من أسباب قلبية

قبل الوصول للفشل الكلوي؛ تجاهل هذا يحيز كل تقديراتنا. منذ أن تبيننا Fine-Gray، صارت نتائجنا أكثر واقعية وقابلية للتكرار. تحليل البقاء أقرب تحليل إحصائي إلى واقع الطبيب: المريض لا يسأل "هل سأمرض؟" بل "متى، وكم لدي من وقت؟".

🔖 تحدّ مفتوح

صمم نموذج تنبؤ ديناميكياً يدمج درجة الخطر الجيني (ثابتة) مع المؤشرات الحيوية المتغيرة زمنياً (eGFR، البروتين البولي) لتحديث خطر الوصول للفشل الكلوي في كل زيارة. كم يحسن الجين التنبؤ المبكر (عند التشخيص) مقابل المتأخر (بعد سنوات من المتابعة)؟ هل قيمة الجين التنبؤية تتضاءل كلما تراكت بيانات المتابعة السريرية؟

📖 مراجع أساسية

:Modeling Survival Data .Therneau T.M., Grambsch P.M. (2000)
Springer. Fine J.P., Gray R.J. (1999). "A .Extending the Cox Model
proportional hazards model for the subdistribution of a
Bi W. et al. (2020). "Efficient mixed .JASA ".competing risk
van .AJHG ".model for survival GWAS (SPACox/GATE)
Houwelingen H.C. (2007). "Dynamic prediction by landmarking
.Scand J Stat ".in survival analysis

الفصل الثالث والعشرون — فارما كوجينوميكس والجينات الدوائية / Pharmacogenomics and Drug Target Genetics

﴿وَإِذَا مَرِضْتُ فَهُوَ يَشْفِينِ﴾

— سورة الشعراء: ٨٠

وَإِذَا مَرِضْتُ فَهُوَ يَشْفِينِ؛ والشفاء يأتي بالدواء المناسب للشخص المناسب. فارما كوجينوميكس يستخدم الجينوم لإيجاد أهداف دوائية جديدة وللتنبؤ باستجابة كل مريض للدواء — خطوة نحو الطب الدقيق.

 سيناريو بحثي

استخدم نتائج GWAS لتحديد أهداف دوائية والتنبؤ باستجابة الدواء. هذا أحد أتمن تطبيقات الوراثة الإحصائية: المتغيرات الجينية التي ترتبط بالمرض غالباً تشير إلى بروتينات يمكن استهدافها دوائياً. والأدوية المدعومة بدليل جيني أنجح بمرتين في التجارب السريرية. كما يمكن التنبؤ بمن يستجيب لدواء ومن لا يستجيب.

هذا الفصل يربط الوراثة الإحصائية بتطوير الدواء – الجسر من الاكتشاف الأكاديمي إلى العلاج السريري.

مجموعة البيانات لهذا الفصل

GWAS + قاعدة أهداف الأدوية (DGIdb) + (UK Biobank)

أهداف التعلم

بعد هذا الفصل تستطيع: (١) إثراء أهداف الأدوية؛ (٢) تموضعاً مع pQTL؛ (٣) PheWAS؛ (٤) تحليل القابلية للاستهداف؛ (٥) إعادة توظيف الدواء بـ MR؛ (٦) PRS للاستجابة الدوائية؛ (٧) خطّ "من GWAS إلى الهدف".

الخلفية الأساسية

الفكرة المركزية: إن كان متغيرٌ يخفّض تعبيرَ بروتينٍ ويقلّل المرض، فدواءٌ يثبّط ذلك البروتين قد يعالج المرض. هذا "محاكاةٌ جينيةٌ للدواء".

$$\text{\text{\$}\text{\$}\{أثر المتغير على البروتين\} \approx \text{\text{\$}\text{\$}\{أثر الدواء المثبط\}}$$

pQTL (موضعُ صفةٍ كميّةٍ بروتينية) يربط المتغيرَ بمستوى البروتين مباشرةً – أقربُ للدواء من eQTL.

تشبيه: المتغير الجيني كـ "تجربة دوائية طبيعية" استمرت مدى الحياة. شخص يحمل متغيراً يخفض بروتيناً معيناً هو كمن تناول مثبّطاً لذلك البروتين منذ الولادة. إن كان أصحُّ، فالدواء المثبّط واعد؛ وإن أصابه ضررٌ جانبيّ، فالدواء قد يحمل الضررَ نفسه. الطبيعة أجرت التجربة مجّاناً.

؟ المسائل

المسألة ٢٣.١ ★★ [متوسط]

إثراء أهداف الأدوية: هل تتركز إشارات GWAS قرب أهدافٍ دوائيةٍ معروفة؟
استخدم DGIdb.

الحلّ ٢٣.١ ✓

```
library(rDGIdb)
gwas_genes <- fread("gwas_nearest_genes.txt")$gene
druggable <- queryDGIdb(gwas_genes)$drugs
enrichment_test(gwas_genes, druggable_genome)
```

المخرجات المتوقعة:

إثراء أهداف الأدوية: 3.2 ضعفاً ($p=2e-8$)
أمثلة: SLC22A2 (هدف ميتفورمين)، PCSK9

التفسير: إشارات GWAS مُثارة ٣,٢ أضعاف قرب أهداف الأدوية – دليل
أن بيولوجيا المرض المكتشفة قابلة للاستهداف. PCSK9 المثال الذهبي: متغيرات
تخفضه تقلل الكوليسترول، فطور دواءً مثبّط ناجح. هذا يحول GWAS من علم
وصفي إلى مولّد فرضياتٍ علاجية.

المسألة ٢٣.٢ ★★ [متوسط]

تموضع بين GWAS وpQTL: حدّد أهدافاً بروتينية للدواء.

✓ الحلّ ٢٣.٢

```
library(coloc)
# هل إشارة GWAS تتموضع مع pQTL (مستوى بروتين في الدم)
coloc.abf(dataset1=gwas_ckd, dataset2=pqtl_protein)
```

المخرجات المتوقعة:

PP.H4 (UMOD protein): 0.93

البروتين هدفٌ دوائيٌّ محتمل

التفسير: pQTL أقربٌ للدواء من eQTL لأنّ الدواء يستهدف البروتين مباشرة.
تموضع GWAS مع pQTL (PP.H4=٠,٩٣) يعني أنّ المرض يعمل عبر مستوى

هذا البروتين — فتنبئته أو تعزيزه دوائياً قد يعالج. هذا يحدد الهدف الجزيئي المباشر للدواء.

المسألة ٢٣.٣ ★★ [متوسط]

PheWAS: ماذا يؤثر متغيرك أيضاً؟ اختبر عبر ١٤٠٠ صفة في UK Biobank.

الحل ٢٣.٣ ✓

```
library(PheWAS)
phewas(genotypes=snp, phenotypes=ukb_1400_traits
       (covariates=covars
       results[order(p)][1:10]
```

المخرجات المتوقعة:

```
:SNP rs12917707 (UMOD)
eGFR: p=1e-50 (المتوقع)
ضغط الدم: p=3e-8 (أثر جانبي محتمل!)
حصى الكلى: p=2e-6
```

التفسير: PheWAS يعكس GWAS: متغير واحد مقابل آلاف الصفات. يكشف أن متغير UMOD يؤثر في eGFR (المتوقع) وأيضاً ضغط الدم وحصى

الكلّي. للدواء، هذا تحذيرٌ مزدوج: قد يكون أثراً جانبياً (خطر) أو فرصةً إعادة
توظيف (الدواء نفسه لمرضين). PheWAS يكشف ملفّ الأثر الكامل للهدف
قبل تطوير الدواء.

المسألة ٢٣.٤ ★★ ★ [متقدّم]

تحليلُ القابلية للاستهداف: أيّ الجينات المخُطّطة دقيّقا تشفّر بروتيناتٍ قابلةً
للاستهداف؟

✓ الحلّ ٢٣.٤

```
finemapped <- fread("credible_set_genes.txt")
druggability <- annotate_druggability(finemapped$gene)
druggability[tractability == "high" | drug_exists == TRUE]
```

المخرجات المتوقّعة:

Gene	Tractability	Druggable_class
PCSK9	High	Antibody/small molecule
GENE_X (تحتاج تطوير)	Medium	Enzyme

التفسير: ليس كلّ جينٍ قابلاً للاستهداف دوائياً. القابليةُ تعتمد على فئة البروتين:
الإنزيمات والمستقبلاتُ سهلةٌ، وعواملُ النسخ صعبة. هذا التحليل يرتّب الجيناتِ

المخرطة حسب جدواها الدوائية، فيوجه الاستثمار نحو الأهداف القابلة للتطوير فعلياً.

المسألة ٢٣.٥ ★★★ [مقدم]

إعادة توظيف الدواء ب-MR: هل تعبير هدف الدواء المرتفع جينياً يؤثر في المرض؟

✓ الحل ٢٣.٥

متغيرات قرب هدف الدواء كأدوات MR لتعبير الهدف
(harmonise_data(target_eqtl_inst, disease_outcome))

المخرجات المتوقعة:

هدف دواء موجود (لمرض آخر) $OR=0.78, p=4e-5 <$
يقترح إعادة توظيف واقية للكلية

التفسير: MR لإعادة التوظيف: نستخدم متغيرات تحاكي أثر الدواء (تغير تعبير هدفه) لاختبار أثره على مرض آخر. هنا، دواء موجود لمرض آخر يبدو واقعياً للكلية جينياً ($OR=0.78$) - مرشح لإعادة توظيف سريعة (الدواء مجاز بالفعل، فالطريق للتجربة أقصر). هذا يختصر سنوات من تطوير الدواء.

المسألة ٢٣.٦ ★★★ [متقدّم]

PRS للاستجابة الدوائية: تنبأ بفعالية الستاتين أو الميتفورمين من النمط الجيني.

✓ الحل ٢٣.٦

درجة جينية للاستجابة (لا للمرض)

```
se_prs := compute_prs(genotypes, response_weights)]  
responder ~ response_prs + covars, family=binomial)
```

المخرجات المتوقعة:

response_prs: OR=1.9 لكل انحراف ($p=3e-6$)

أعلى عُشير: 70% استجابة مقابل 35% في الأدنى

التفسير: PRS للاستجابة يتنبأ بمن يستفيد من الدواء، لا بمن يمرض. هذا جوهرُ الطبّ الدقيق: إعطاء الدواء لمن يُرجح أن يستجيب، وتجنّبه من لن يستفيد (وقد يتضرر). الفرق بين العُشرين (٧٠٪ مقابل ٣٥٪) ذو قيمةٍ سريريةٍ مباشرة في اختيار العلاج.

المسألة ٢٣.٧ ★★★★★ [خير]

من GWAS إلى هدف الدواء: خطُّ كامل — إشارة ← تخريط ← eQTL ←
pQTL ← قابلية ← دليل MR ← جدول.

الحلّ ٢٣.٧ ✓

```
}gwas_to_drug <- function(locus)
# 1
.cs <- finemap(locus)
# 2. eQTL
eqtl <- coloc_eqtl(cs)
# 3. pQTL
pqt1 <- coloc_pqt1(cs)
# 4
drug <- check_druggability(pqt1$gene)
# 5
mr_ev <- mr_drug_target(pqt1$gene)
drugable=drug, mr_evidence=mr_ev)
{
```

التفسير: الخطُّ الكامل يحوّل إشارة GWAS إلى هدفٍ دوائيّ مُثبتٍ بالدليل:
تخريطٌ يحدّد الجين، eQTL/pQTL يربطانه بالبروتين، تحليل القابلية يؤكّد إمكانَ
استهدافه، وMR يقدّم دليلاً سببياً على اتجاه الأثر المطلوب. الناتج: جدولٌ يرتّب
الأهداف للاستثمار الدوائيّ. هذا أعلى قيمةٍ ترجحيةٍ للوراثة الإحصائية.

⚠ الأخطاء الشائعة وتصحيحها

Nearest gene not the target – استخدم تخريطاً
eQTL/pQTL لا القرب فقط. pQTL tissue mismatch –
طابق النسيج/السائل ذا الصلة (دم، كلى). PheWAS reveals side effects – أثر في صفات أخرى قد يعني ضرراً. MR direction wrong – تأكد من اتجاه الأثر المطلوب (تنشيط مقابل تنشيط).
Druggability overestimated – ليس كل بروتين قابلاً.
Response PRS needs trial data – يتطلب بيانات
استجابة لا مرض. Repurposing needs validation –
الدليل الجيني بداية لا نهاية.

📖 الغوص العميق

ربطُ الوراثة الإحصائية بتطوير الدواء أحد أكثر جوانب عملي إثارة بجامعة
ميشيغان. لأمراض الكلى، نسعى لتحويل إشارات GWAS إلى أهداف علاجية
عبر خطّ التخريط $pQTL \leftarrow eQTL$. درسٌ محوريّ: الدليلُ الجينيّ
يضاعف نجاح الدواء. الأدوية المدعومةُ بدليلٍ جينيّ (ك PCSK9
للكوليسترول) تنجح في التجارب بمعدلٍ أعلى بكثير، لأنّ الجينَ يثبت أنّ الهدفَ
سببيُّ حقاً. لكنّ PheWAS علّمني الحذر: متغيّرٌ يبدو هدفاً واعداً قد يؤثر في
صفاتٍ أخرى، منذراً بأثرٍ جانبيّ خطير. تحذيرٌ خاصّ: بياناتُ pQTL

والاستجابة الدوائية أوروبيةٌ بمعظمها، فالتنبؤ بالاستجابة في مرضانا العرب يحتاج تحقّقاً — قد يستجيب العربُ للأدوية بشكلٍ مختلفٍ لأسبابٍ جينية.

🔑 تحدّ مفتوح

صمّم دراسةً تختبر هل تنبأ درجاتُ الاستجابة الدوائية المبنية على أوروبيين باستجابة المرضى العرب لأدوية الكلى الشائعة (مثبطات ACE، SGLT2). إن اختلفت الاستجابة، هل السببُ جينيُّ (متغيّراتُ استقلاب الدواء كـ CYP المختلفة التواتر في العرب) أم بيئيُّ؟ صمّم PRS استجابةً خاصاً بالعرب وقس تحسّن التنبؤ.

📖 مراجع أساسية

Nelson M.R. et al. (2015). "The support of human genetic Cotto .*Nature Genetics* ".evidence for approved drug indications
".K.C. et al. (2018). "DGIdb 3.0: drug-gene interaction database
Sun B.B. et al. (2018). "Genomic atlas of .*Nucleic Acids Research*
.Denny J.C. et al .*Nature* ".the human plasma proteome (pQTL)
Nature ".PheWAS: systematic phenome-wide association" .(2013)
.Biotechnology

الفصل الرابع والعشرون — التحقق من الصحة

Validation and / وإعادة الإنتاج

Reproducibility

﴿وَلَا تَقْفُ مَا لَيْسَ لَكَ بِهِ عِلْمٌ﴾

— سورة الإسراء: ٣٦

لا تتبّع ما لا علم لك به؛ والنتيجة غير المتكرّرة ليست علماً بعد. التحقق وإعادة الإنتاج هما ما يحولان "اكتشافاً" مؤقتاً إلى معرفة راسخة تصمد أمام التدقيق.

📖 سيناريو بحثي

اكتمل GWAS الخاص بك. الآن عليك ضمان أنّ كلّ نتيجة قابلة لإعادة الإنتاج وأنّ الورقة تجتاز مراجعة الأقران. هذه المرحلة تفصل العلم الجادّ عن الضوضاء: نتيجة لا تتكرّر في عينة مستقلة، أو تحليل لا يستطيع زميل إعادة تشغيله، ليس علماً موثقاً. "أزمة عدم التكرار" دمرت ثقة المجال المبكّر؛ الانضباط المنهجيّ هو الدواء.

هذا الفصل يحوّل عملك من "اكتشاف شخصي" إلى "معرفة عامة قابلة للتحقق" – المعيار الذهبي للنشر الجادّ.

مجموعة البيانات لهذا الفصل

نتائج الاكتشاف + مجموعة تكرار مستقلة + بيئة الحوسبة

أهداف التعلّم

بعد هذا الفصل تستطيع: (١) تحليل التكرار؛ (٢) ميتا الاكتشاف+التكرار؛ (٣) التحقق الوظيفي؛ (٤) كتابة قسم المنهجية؛ (٥) بيئة قابلة للإنتاج؛ (٦) حاوية Docker؛ (٧) معايير الإبلاغ والإيداع.

الخلفية الأساسية

التكرار هو الاختبار النهائي: هل تظهر الإشارة في عينة مستقلة لم تُستخدم في الاكتشاف؟ توقع أثراً أصغر (لعنة الفائز، الفصل ١٨)، لكن بالاتجاه نفسه وبدلالة. معدّل التكرار:

$$\frac{\text{إشارات متكررة}}{\text{إشارات}} = \text{معدّل التكرار} = \text{مكتشفة}$$

إعادة الإنتاج أوسع: هل يستطيع آخر إعادة تحليلك بالضبط من الكود والبيانات؟

تشبيه: الاكتشاف كروية شخص يدعي رؤية شيء نادر. التكرار هو أن يراه شاهد آخر مستقل. إعادة الإنتاج هي أن تُعطي الشاهد الثاني الخريطة نفسها والمنظار نفسه فيرى الشيء نفسه. العلم لا يثق برؤية واحدة مهما كانت واثقة؛ يطلب شاهداً مستقلاً وطريقاً قابلاً للإعادة.

؟ المسائل

المسألة ٢٤٠١ ★★ [متوسط]

تحليل مجموعة التكرار: هل نكرر قُمك العشرون؟ احسب معدل التكرار.

الحل ٢٤٠١ ✓

```
disc <- fread("discovery_hits.txt")[1:20]
rep <- fread("replication.txt")
merge(disc, rep, by="SNP", suffixes=c("_d", "_r"))
ated := P_r < 0.05/20 & sign(BETA_d)==sign(BETA_r)]
cat("معدل التكرار:", mean(m$replicated))
```

المخرجات المتوقعة:

معدّل التكرار: 0.85 (17 من 20)

كلّها بالاتجاه نفسه

التفسير: ١٧ من ٢٠ تكررّت (٨٥٪) عند عتبة بونفيروني للتكرار (٠,٠٥/٢٠) وبالاتجاه نفسه. هذا معدّل جيّد. الثلاثُ التي لم تُتكرّر قد تكون كاذبةً، أو ضعيفةُ القوّة في عينة التكرار (اخفص بتحليل القوّة، الفصل ١٠). تطابقُ الاتجاه شرطُ أساس: إشارةٌ تنقلب اتجاهها مشبوهة.

المسألة ٢٤.٢ ★★ [متوسط]

ميتا-أناليسيس الاكتشاف+التكرار لتقوية الدليل.

✓ الحلّ ٢٤.٢

دمج الاكتشاف والتكرار يعطي أقوى تقدير

```
combined <- meta_analyze(discovery, replication)
combined[SNP %in% top_hits, .(SNP, BETA_meta, P_meta)]
```

المخرجات المتوقّعة:

SNP	P_discovery	P_replication	P_combined
rs12917707	3e-9	2e-4	1e-12

التفسير: دمج الاكتشاف والتكرار يعطي أقوى تقدير نهائي ($p = 1 \times 10^{-12}$). هذا هو الرقم الذي تُبلغ عنه في الورقة كدليل نهائي. الميّا يوازن بين تضخم الاكتشاف (لعنة الفائز) وتقليل التكرار، فيعطي تقدّيراً غير متحيّز.

المسألة ٢٤.٣ ★★ [متوسط]

التحقّق الوظيفي: هل جيناتك معبّرة في النسيج ذي الصلة؟

الحلّ ٢٤.٣ ✓

تحقّق أنّ جينات القمم معبّرة في الكلى (GTEx)

```
top_genes <- c("UMOD", "SHROOM3", "PKD1")
```

```
query_gtex_expression(top_genes, "Kidney_Cortex")
```

```
expression[TPM > 1] # معبّر فعلاً
```

المخرجات المتوقّعة:

UMOD: 850 TPM (شديد التعبير في الكلى)

SHROOM3: 45 TPM (معبّر)

التفسير: التحقّق الوظيفي يعرّز المصادقية: جينٌ مرتبطٌ بأمراض الكلى يجب أن يكون معبّراً في الكلى. UMOD شديد التعبير (850 TPM) — اتّسق بيولوجي

قويّ. لو كان حينَ غيرٍ معبّرٍ في النسيج ذي الصلة، لشكّكنا في كونه السببيّ. هذا دليلٌ تأكيدِيّ مستقلٌّ عن الإحصاء.

المسألة ٢٤٠٤ ★★★ [متقدّم]

اكتب قسمَ منهجية GWAS كاملاً — قائمةُ ٢٥ عنصراً مطلوباً.

✓ الحلّ ٢٤٠٤

قائمة منهجية GWAS (مختصرة) :

1. مصدر العيّنة والموافقة الأخلاقية
2. معايير QC للمتغيّرات (MAF, geno, HWE) + العتبات
3. معايير QC للعيّنات (الفقد، التغاير، القرابة)
4. الاستيفاء (اللوحة، البرنامج، عتبة INFO)
5. نموذج الارتباط (الأداة، المتغيّرات المشتركة، عدد PCs ... (حتى 25)

التفسير: قسمُ المنهجية الكامل يجعل دراستك قابلةً للتقييم والتكرار. كلُّ عنصرٍ ناقصٍ (مثل عدد PCs أو عتبة INFO) يجعل المحكّمين يشكّون والباحثين عاجزين عن الإعادة. المحكّمون يبحثون عن هذه العناصر تحديداً؛ غيابُها سببٌ شائعٌ للرفض.

المسألة ٢٤.٥ ★★★ [متقدّم]

أنشئ بيئة تحليل قابلة للإنتاج بـ (R) renv و conda (Python/الأدوات).

✓ الحل ٢٤.٥

```
# R: تثبيت إصدارات الحزم بالضبط
renv::init()
renv::snapshot() # يحفظ renv.lock بكل الإصدارات

# الأدوات: بيئة conda موثقة
conda env export > environment.yml
```

التفسير: renv.lock و environment.yml يجمدان كل إصدارات الحزم والأدوات. زميلٌ (أو أنت بعد سنتين) يستطيع إعادة بناء البيئة بالضبط بأمرٍ واحد. هذا يحلّ "يعمل على حاسوبي فقط" - أكبر عدوّ لإعادة الإنتاج. تغيير إصدار واحد قد يغيّر النتائج.

المسألة ٢٤.٦ ★★★ [متقدّم]

حاوية Docker نخطّ أنابيبك: بناءً، رفع، اختبار.

الحلّ ٢٤.٦ ✓

```
FROM ubuntu:22.04
apt-get update && apt-get install -y plink2 r-base
/COPY environment.yml renv.lock /pipeline
/COPY scripts/ /pipeline/scripts
ENTRYPOINT ["/pipeline/run_gwas.sh"]

gwas-pipeline . && docker push myrepo/gwas-pipeline
```

التفسير: Docker يحزم كل شيء (نظام التشغيل، الأدوات، الكود) في حاوية واحدة تعمل في أي مكان. هذا أقوى من renv/conda: يضمن إعادة إنتاج كاملة عبر الأنظمة المختلفة. باحث في أي بلد يشغل `docker run` فيحصل على بيئتك بالضبط. المعيار الذهبي لإعادة الإنتاج.

المسألة ٢٤.٧ ★★★★★ [خير]

معايير الإبلاغ (تنسيق إيداع GWAS Catalog): نسق نتائجك للإيداع العام، اكتب README، تحقق من الحقول الوصفية.

✓ الحل ٢٤٠٧

```
# تنسيق الإحصاءات الموجزة وفق معيار GWAS-SSF
ssf <- format_gwas_ssf(results
("chromosome", "base_pair_location", "effect_allele
le", "beta", "standard_error", "p_value"
(("effect_allele_frequency", "rsid"
write_metadata_yaml(study_info) # الحقول الوصفية
```

التفسير: إيداعُ الإحصاءات الموجزة في GWAS Catalog يجعل عملاً متاحاً للمجتمع (لميتا-أناليسيس، PRS، MR مستقبلية). التنسيق المعياري (GWAS-SSF) والحقول الوصفية الكاملة (الأصل، الحجم، الصفة) ضرورية. هذه مساهمة في العلم التراكمي: نتائجك تصبح لبنة لأبحاث الآخرين. كثيرٌ من المجالات تشرط الإيداع الآن.

⚠ الأخطاء الشائعة وتصحيحها

Replication underpowered – احسب القوة قبل لوم الإشارة.
Winner's curse ignored – توقع أثراً أصغر في التكرار.
Methods incomplete – اتبع قائمة الـ ٢٥ Versions.
undocumented – استخدم renv/conda دائماً، Docker too.
large – استخدم صوراً أساسيةً خفيفة. Summary stats wrong.

format — اتباع GWAS-SSF. Metadata missing.
ancestry — حقلٌ إلزاميٌّ للإيداع.

📖 الغوص العميق

إعادة الإنتاج هاجسٌ يوميٌّ في عملي بجامعة ميشيغان، وقد تعلّمتُ قيمتها بالطريق الصعب. مرّةً، حاولتُ إعادة تشغيل تحليلٍ من قبل سنتين، فاكشفتُ أنّ تحديث حزمة في R غير النتائج قليلاً — كانت كارثةً لو حدث أثناء المراجعة. منذ ذلك، كل مشروع يبدأ بـ renv وينتهي بحماية Docker. درسٌ آخر قاسٍ: التكرار الفاشل ليس دائماً فشلاً علمياً. حين لم نتكرّر إحدى إشارتنا، كاد فريق يتجاهلها؛ لكنّ تحليل القوة كشف أنّ عينة التكرار كانت صغيرة جداً (قوة ٣٠٪)، فالفشل كان متوقعاً لا دليل كذب. أعلم طلابي: التحقّق الصارم ليس عائقاً بل درعٌ يحمي سمعتك العلمية. الإشارة التي تصمد أمام التكرار والتحقّق الوظيفي وإعادة الإنتاج هي وحدها التي تستحق اسمك عليها.

🔑 تحدّ مفتوح

التكرار المستقل صعبٌ للعرب لندرة المجموعات العرقية الكبيرة. صمّم استراتيجيّة تحقّق بديلة لاكتشاف جينيّ في عينةٍ عربيةٍ صغيرة لا تتوفّر لها مجموعة تكرارٍ عربيةٍ مستقلة: هل يكفي التحقّق الوظيفي (eQTL، التعبير) والتكرار عبر الأصول (هل نتكرّر في الأوروبيين)؟ ما الحد الأدنى من الأدلة البديلة الذي يجعل اكتشافاً عربياً موثقاً للنشر؟

Marigorta U.M. et al. (2018). "Replicability and prediction in
MacArthur J. et al. (2017). "The new *Trends in Genetics*".GWAS
.Ushey K *Nucleic Acids Research* ".NHGRI-EBI GWAS Catalog
.Boettiger C *RStudio* ".renv: Project Environments for R" .(2023)
".An introduction to Docker for reproducible research" .(2015)
.*ACM SIGOPS*

الفصل الخامس والعشرون — المشروع النهائي: ورقة

Final Project: A Complete / بحثية كاملة

GWAS Paper

﴿قُلْ اَعْمَلُوا فَسِرِّيَ اللّٰهُ عَمَلَكُمْ وَرَسُولُهُ وَالْمُؤْمِنُونَ﴾

— سورة التوبة: ١٠٥

اعملوا فسيري عملكم؛ وهذا الفصل هو "العمل" الذي يجمع كل ما تعلّمته في منتج واحد مرئي: ورقة بحثية كاملة. المعرفة تُختبر بالإنتاج، والإنتاج النهائي هو برهان الإتيان.

سيناريو بحثي

باستخدام مجموعة البيانات البنكية المحاكاة المرفقة، أنتج ورقة GWAS مصغرة كاملة (منهجية + نتائج + أشكال) وفق معايير تقديم مجلة مرفقة. هذا المشروع اختامي يدمج كل فصول الكتاب: من ضبط الجودة (٣-٤)، إلى المكونات (٥)، إلى الارتباط (٧-٩)، إلى التخريط (١٢)، إلى التحقق (٢٤). إنه اختبار النهائي: هل تستطيع أن تأخذ بيانات خاماً وتُخرج علماً قابلاً للنشر؟

مجموعة البيانات لهذا الفصل

بنك مُحاكاة: 10,000 عيّنة، SNP 500,000، صفة eGFR
توليده بكود الفصل الأول (المحاكي)

أهداف التعلم

بعد هذا الفصل تستطيع إنتاج ورقة GWAS كاملة بعشرة مُخرجات معيارية: جدول QC، لوحة PCA، مخطط مناهاتن، Q-Q، ارتباط إقليمي، غابة، تخريط، تموضع، جدول قيم، قسم منهجية.

الخلفية الأساسية

ورقة GWAS النموذجية تتبع بنية ثابتة: مقدمة (الفجوة المعرفية)، طرق (QC) ← المكونات ← الارتباط ← التخريط، نتائج (الأشكال والجداول)، مناقشة (التفسير والقيود). كلُّ شكلٍ يُخدم غرضاً: مناهاتن للنظرة العامة، Q-Q للمعايرة، الارتباط الإقليمي للتفصيل.

تشبيه: الورقة كبناء بيت متكامل. الفصول السابقة علّمتك صناعة الطوب (المهارات المفردة)؛ هذا الفصل يعلّمك العمارة: كيف ترتّب الطوب في بيت قائم يسكنه الآخرون (يقرؤه العلماء وينون عليه). الطوب وحده لا يُؤوي أحداً؛ العمارة هي ما يحوِّله إلى مأوى.

؟ المخرجات مع قوالب الحلّ

المخرَج ١ ★★ جدول ملّخص QC (٥ صفوف × ٥ أعمدة)

```
)qc_table <- data.table  
Step=c("خام", "بعد QC المتغيّرات", "بعد QC العيّّنات")  
variants=c(500000, 451203, 451203, 451203, 451203)  
(Samples=c(10000, 10000, 9847, 9812, 9812))
```

التفسير: جدولُ QC هو أوّل ما يفحصه المحكّم: كم متغيّراً وعيّنة بقيت بعد كلّ خطوة، ولماذا حُذف ما حُذف. الشفافية هنا تبني الثقة.

المخرَج ٢ ★★ لوحة PCA بتسميات الأصل (DPI ٣٠٠)

```
(PC1, PC2, color=ancestry)) + geom_point(alpha=0.6)  
theme_minimal() + ggsave("fig2_pca.png", dpi=300)
```

التفسير: لوحةُ PCA تُظهر بنية العيّنة السكّانية وتبرّر عددَ المكونات المدخلة. الجودةُ DPI ٣٠٠ معيارُ النشر.

المخرَج ٣ ★★★ مخطط مانهاتن (مخرجات REGENIE، معلّم بأسماء الجينات)

```
library(qqman)
manhattan(gwas, annotatePval=5e-8, highlight=top_snps
-log10(1e-5), genomewideline=-log10(5e-8))
```

التفسير: مخطط مانهاتن هو الشكل الأيقونيّ: نظرةٌ شاملةٌ لكلّ الإشارات. تعلّمُ القمم بأسماء الجينات (UMOD، SHROOM3) يربط الإحصاء بالبيولوجيا فوراً.

المخرَج ٤ ★★★ مخطط Q-Q مع معامل التضخّم λ

```
qq(gwas$P)
lambda <- median(qchisq(1-gwas$P,1))/qchisq(0.5,1)
text(1, 5, paste("λ =", round(lambda,3)))
```

التفسير: Q-Q و λ يبرهنان أنّ نتائجك غير متضخّمة ($\lambda \approx 1.0$). هذا أوّل ما يتحقّق منه المحكّمون قبل تصديق أيّ قوّة. $\lambda = 1.2$ مثلاً يقول: "النتائج نظيفة".

المخرج ٥ ★★★ مخطط ارتباط إقليمي للقيمة (LocusZoom)

```
plot(gwas, lead_snp="rs12917707", ld_ref=ld_matrix  
(gene_track=TRUE
```

التفسير: الارتباط الإقليمي يكبر قيمة واحدة، مظهراً بنية LD والجينات المجاورة. يحول "نقطة في مانهاتن" إلى قصة بيولوجية مفصلة.

المخرج ٦ ★★★ مخطط غابة للقيمة عبر المجموعات

```
, "forest_plot(meta_results, snp="rs12917707  
udies=c("Cohort1", "Cohort2", "Cohort3")
```

التفسير: مخطط الغابة يظهر اتساق الأثر عبر المجموعات — كل مجموعة خطأ، والماسة التقدير المجمع. الاتساق يعزز الثقة في الإشارة.

المخرج ٧ ★★★ تصوير مجموعة الثقة من التخریط الدقيق

```
susie_plot(fit, y="PIP") # احتمال الإدراج لكل متغير
```

التفسير: يُظهر أي المتغيرات في مجموعة الثقة وباحتمال كم. يحول قيمة غامضة (٤٧) مرشحاً إلى ١-٥ مرشحين سببيين.

المخرَج ٨ ★★★ تصوير دليل التوضع مع eQTL

```
_signal, eqtl_signal, gene="UMOD", tissue="Kidney")  
PP.H4 = 0.91 #
```

التفسير: يُظهر تطابق إشارة المرض و eQTL بصرياً، مع PP.H4. هذا الدليل يربط المتغيرَ بجينٍ هدفٍ عبر آلية التعبير.

المخرَج ٩ ★★★ جدول أعلى ٢٠ قّة (للملحق)

```
), .(SNP, CHR, BP, A1, A2, EAF, BETA, SE, P, gene)]  
fwrite(top20, "table_sl_top_hits.csv")
```

التفسير: جدولُ القيم هو المرجع الكميّ للنتائج: كلُّ إشارةٍ بموضعها وأليلها وأثرها وقيمتها وجينها. أساسيٌّ للملحق وللميتا-أناليسيس المستقبليّ.

المخرَج ١٠ ★★★★★ قسم المنهجية الكامل (٦٠٠ كلمة)

المنهجية: حلّلنا 9,812 فرداً... ضبطُ جودة المتغيّرات ()
معدّل الفقد >0.02، $p > 1e-6$ (HWE) ... عشرةً مكُوناتٍ رئيسية
الخطوتين... عتبة $5e-8$... تخريطُ بـ SuSiE ... تموضعُ بـ
(حتى 600 كلمة تغطّي كلّ خطوة)

التفسير: قسم المنهجية يجمع كلَّ الكتاب في ٦٠٠ كلمة دقيقة. كلُّ جملة تذكر أداةً وعتبةً ومبرراً. هذا ما يجعل عملك قابلاً للتكرار والتقييم – جوهر العلم الجاد.

⚠ الأخطاء الشائعة وتصحيحها

Figures low resolution – استخدم ٣٠٠ DPI للنشر.
Methods missing thresholds – اذكر كلَّ عتبة.
Manhattan unannotated – علم الجينات. No Q-Q plot
المحكمون يطلبونه أولاً. Table missing effect allele
– أساسي للتفسير. – No data availability statement
أودع الإحصاءات. Discussion overclaims – الارتباط ليس
سببية؛ كن متواضعاً.

📖 الغوص العميق

مثالٌ مُعلقٌ من مقطعٍ حقيقيٍّ (مجهول الهوية) من قسم منهجية GWAS للكلبي، مع شرح لماذا كُتبت كلُّ جملة كما هي: كتبنا "أدخلت عشرةً مكونات رئيسية" – لا أكثر (يبدد القوة) ولا أقل (يترك تضخماً)، والرقم صريحٌ ليُكرَّر. كتبنا "في مجموعة الضبط" عند HWE – لأن تطبيقه على الحالات يحذف إشارات حقيقية. كتبنا "عتبة 5e-8" صراحةً مع مبررها – لأن المحكمين يتحققون منها. في عملي بجامعة ميشيغان، تعلّمتُ أنّ قسم المنهجية ليس روتيناً بل عقدُ ثقةٍ مع القارئ: كلُّ غموضٍ فيه يُضعف مصداقية النتائج مهما كانت قوية.

🔑 تحدّ مفتوح

خذ مجموعة المحاكاة المرفقة، وأنتج ورقة GWAS كاملةً من الصفر — كلّ المخرجات العشرة — ثمّ اعرضها على زميلٍ ليحاول إعادة إنتاجها من كودك وحده. كم خطوةً يعجز عن تكرارها؟ هذا اختبارُ إعادة الإنتاج الحقيقي: ورقتك ليست مكتملةً حتى يستطيع غريبٌ إعادة بنائها بالضبط.

◆ كلمة المؤلف الختامية

والله أعلم. كلُّ أداة، وكلُّ خطٍّ أناييب، وكلُّ خطأٍ في هذا الكتاب جاء من تجربةٍ حقيقيةٍ في مختبري بجامعة ميشيغان — من ليالٍ أمام الشاشة في الثانية صباحاً أحاول فهمَ لماذا فشل SAIGE، أو لماذا يختلف مناهتي عن الورقة، أو لماذا لا يُقبل ملفّي في خادم الاستيفاء. كتبتُ هذا الكتابَ من تلك اللحظات، لأجلك أنت — الباحثُ العربيّ الذي يقف حيث وقفتُ. الأدواتُ مجّانية، والبياناتُ تزايدت، والفجوةُ تنتظر من يردمها. اعمل، فسيُرى عملك. والحمد لله أولاً وآخراً.

📖 مراجع أساسية

Uffelmann E. et al. (2021). "Genome-wide association studies (primer) — *Nature Reviews Methods Primers*".
GWAS. Reed E. et al. (2015). "A guide to GWAS methodology

.Cano-Gamez E., Trynka G .*Statistics in Medicine* ".and reporting
.*Frontiers in Genetics* ".From GWAS to function" .(2020)
:Abdellaoui A. et al. (2023). "15 years of GWAS discovery
.*AJHG* ".realizing the promise

الفصل السادس والعشرون — المراجع الموحدة Consolidated References and / الموارد Resources

﴿وَقُلْ رَبِّ زِدْنِي عِلْمًا﴾

— سورة طه: ١١٤

رَبِّ زِدْنِي عِلْمًا؛ والعلمُ بجرُّ لا ساحل، وهذا الفصلُ يجمعُ مراجعَ الكُتُبِ كُلِّهَا في فهرسٍ واحدٍ مرتَّب، ليكونُ بوصلتكِ إلى ما وراء صفحاته.

أولاً: الكتب الدراسية المرجعية

- *Handbook of*.Balding D., Bishop M., Cannings C. (eds)
Statistical Genetics. Wiley — المرجعُ الموسوعيّ.
- *The Fundamentals of Modern*.Laird N.M., Lange C
Statistical Genetics. Springer.
- *Principles of Population Genetics*.Hartl D.L., Clark A.G
Sinauer.

- A Statistical Approach to Genetic* .Ziegler A., König I.R. •
•Wiley .*Epidemiology*
- An Introduction to Statistical Genetic Data* .Mills M.C. et al. •
•MIT Press .*Analysis* — حديثٌ وعمليٌّ.

ثانياً: الأدوات البرمجية (الأوراق المرجعية)

- Chang C.C. et al. (2015). "Second-generation — **PLINK2** •
•*GigaScience* ".PLINK
- Nature Genetics* .Mbatchesou J. et al. (2021) — **REGENIE** •
- Zhou W. et al. (2018, 2020) — **SAIGE / SAIGE-GENE** •
•*Nature Genetics*
- AJHG* .Yang J. et al. (2011) — **GCTA** •
- Nature Genetics* .Bulik-Sullivan B. et al. (2015) — **LDSC** •
- Bioinformatics* .Willer C.J. et al. (2010) — **METAL** •
- JRSS B* Wang G. et al. (2020) — **SuSiE / FINEMAP** •
•*Bioinformatics* Benner C. et al. (2016)
- PLoS Genetics* .Giambartolomei C. et al. (2014) — **coloc** •
- Hemani G. et al. (2018) — **TwoSampleMR / MR-Base** •
•*eLife*

- Nat Commun Ge T. et al. (2019) — **PRS-CS / LDpred2** •
 • Bioinformatics Privé F. et al. (2020)
 • Loh • Delaneau O. et al. (2019) — **SHAPEIT4 / Eagle** •
 • P.R. et al. (2016)
 • Das S — **MINIMAC4 / Michigan Imputation Server** •
 • Nature Genetics .et al. (2016)

ثالثاً: المنهجيات الأساسية

- Price A.L. et al. (2006). "PCA corrects for stratification" •
 • Nature Genetics
 • Yang J. et al. (2010). "Common SNPs explain heritability" •
 • Nature Genetics
 • Lee S. et al. (2012) • AJHG "Wu M.C. et al. (2011). "SKAT" •
 • Biostatistics "SKAT-O"
 • Int J Epidemiol "Bowden J. et al. (2015). "MR-Egger" •
 • Nature "Verbanck M. et al. (2018). "MR-PRESSO
 • Genetics
 • Benjamini Y., Hochberg Y. (1995). "Controlling the FDR" •
 • JRSS B

Manichaikul A. et al. (2010). "KING relationship •
•*Bioinformatics* ".inference
•*Nature Genetics* ".Yang J. et al. (2012). "GCTA-COJO •

رابعاً: قواعد البيانات والموارد (روابط)

www.ebi.ac.uk/gwas — **GWAS Catalog** •
www.gtexportal.org — **GTEx Portal** •
gnomad.broadinstitute.org — **gnomAD** •
— **Pan-UKBB** ، www.ukbiobank.ac.uk — **UK Biobank** •
pan.ukbb.broadinstitute.org
www.internationalgenome.org — **Genomes 1000** •
www.ncbi.nlm.nih.gov/gap — **dbGaP** •
gwas.mrcieu.ac.uk — **IEU OpenGWAS** •
— **Michigan Imputation Server** •
imputationserver.sph.umich.edu
www.dgldb.org — **DGldb** •
ckdgen.imbi.uni-freiburg.de — **CKDGen Consortium** •

خامساً: مجال المؤلف (أمراض الكلى والجينوم)

- GWAS سلسلة — CKDGen Consortium ,Köttgen A. et al .
لوظيفة الكلى (UMOD، SHROOM3).
- Wuttke M. et al. (2019). "Catalog of genetic loci for
".*Nature Genetics* ".kidney function
- Genovese G. et al. (2010). "ApoL1 variants and kidney
".*Science* ".disease
- Mahajan A. et al. (2022). "Multi-ancestry T2D study
".*Nature Genetics* ".(DIAMANTE)

سادساً: التنوع والعدالة الجينومية

- Martin A.R. et al. (2019). "PRS may exacerbate health
".*Nature Genetics* ".disparities
- Gurdasani D. et al. (2019). "Genomics of disease risk in
".*Nature Reviews Genetics* ".diverse populations
- Ruan Y. et al. (2022). "PRS-CSx: prediction in diverse
".*Nature Genetics* ".populations
- Sirugo G. et al. (2019). "The missing diversity in human
".*Cell* ".genetic studies

سابعاً: موارد التعلم المفتوحة

- دروسُ معهد **Broad** في الوراثة الإحصائية والمعلوماتية الحيوية.
- دوراتُ **Coursera** و **edX** في الجينوم والإحصاء الوراثي.
- التوثيقُ الرسمي لـ **SAIGE**، **REGENIE**، **PLINK** — مليءٌ بالأمثلة التطبيقية.
- مراجعاتُ شاملة: (2021) *Nat Rev Methods* Uffelmann E. et al.
- *Primers*؛ (2017) *AJHG* Visscher P.M. et al.

ملاحظة منهجية: كلُّ الأكواد والمخرجات في هذا الكتاب صُممت تعليمياً. الأكوادُ صحيحةٌ وقابلةٌ للتشغيل، والمخرجاتُ تمثيليةٌ تطابق صيغ الأدوات الحقيقية، لكنها ليست مقتبسةً من تشغيلٍ فعليٍّ على بياناتٍ بعينها. الأرقامُ التوضيحية (نسبُ *QC*، تقديراتُ الوراثة، قيمُ *r*، آثارُ المتغيرات) تمثيليةٌ لما يُصادفُ في البحث الواقعي. للأرقام الدقيقة، راجع الدراسات المنشورة المذكورة أعلاه، خاصةً سلسلة *CKDGen* لأبحاث الكلى.

وقل ربّ زدني علماً.

القسم الإنجليزي

English Section

Table of Contents

Chapter 1 — إعداد البيئة الكاملة / Complete Environment Setup	1
Chapter 2 — تنسيقات ملفات البيانات الجينية / Genetic Data File Formats	2
Chapter 3 — مراقبة جودة المتغيرات / Variant Quality Control	3
Chapter 4 — مراقبة جودة العينات / Sample Quality Control	4
Chapter 5 — تحليل المكونات الرئيسية المتقدم / Advanced PCA Analysis	5
Chapter 6 — استيفاء البيانات الجينية / Genotype Imputation	6
Chapter 7 — اختبارات الارتباط الأساسية بـ PLINK2 / Basic Association Testing with PLINK2	7

Chapter 8 — REGENIE: Whole Genome Regression / نموذج الانحدار على مستوى الجينوم	8
Chapter 9 — SAIGE: Mixed Models for Imbalanced Data / النماذج المختلطة للبيانات غير المتوازنة	9
Chapter 10 — Multiple Testing and Power / تصحيح الاختبارات المتعددة والقوة الإحصائية	10
Chapter 11 — Linkage Disequilibrium and Haplotype Analysis / تحليل عدم التوازن الترابطي والهابلوتايب	11
Chapter 12 — Fine-Mapping a GWAS Locus / التحليل الدقيق للموضع الجيني	12
Chapter 13 — eQTL Analysis and Gene Expression / والتعبير الجيني eQTL تحليل	13
Chapter 14 — LDSC و GCTA الوراثة ومعامل الارتباط الجيني بـ /	14
Chapter 15 — Polygenic Risk Scores: Advanced Methods / درجات الخطر متعدد الجينات: طرق متقدمة	15
Chapter 16 — Rare Variant Analysis / تحليل المتغيرات النادرة	16

Chapter 17 — التحليل متعدد السكان / Multi-Ancestry Analysis	17
Chapter 18 — المحاكاة والإطار الإحصائي / Simulation and Statistical Framework	18
Chapter 19 — ميتا-أناليسيس / Meta-Analysis	19
Chapter 20 — التفاعل الجيني والبيئي / Gene-Environment Interaction	20
Chapter 21 — العشوائية المندلية: طرق متقدمة / Mendelian Randomization: Advanced Methods	21
Chapter 22 — تحليل البقاء الجينومي والوقت حتى الحدث / Survival GWAS and Time-to-Event Analysis	22
Chapter 23 — فارماكوجينوميكس والجينات الدوائية / Pharmacogenomics and Drug Target Genetics	23
Chapter 24 — التحقق من الصحة وإعادة الإنتاج / Validation and Reproducibility	24
Chapter 25 — المشروع النهائي: ورقة بحثية كاملة / Final Project: A Complete GWAS Paper	25

Chapter 26 — المراجع الموحّدة والموارد / Consolidated References 26
and Resources

Chapter 1 — إعداد البيئة الكاملة / Complete Environment Setup

﴿اقْرَأْ بِاسْمِ رَبِّكَ الَّذِي خَلَقَ﴾

"Read in the name of your Lord who created." — Surah Al-'Alaq: 1

The first command of revelation was "Read" — and reading requires a tool, an environment, a preparation. Likewise, the first step in the statistical-genetics journey is building the environment through which we read the genome: installing the tools and verifying them before we read a single letter of data.

Research Scenario

Your first day in a genomics lab. The lab director gave you an account on the high-performance computing (HPC) cluster and said: "Before you analyze any data, I want a working environment: PLINK2, REGENIE, SAIGE, GCTA, LDSC, and all the R packages. And I want a single script that verifies

everything is installed and working." The task sounds simple, but in reality it is what most blocks new researchers: version conflicts, library paths, clashing conda environments. This chapter gets you past this obstacle once and for all.

We will build a clean, isolated environment, install every tool, verify each one with small test data, then write a comprehensive verification script that produces a pass/fail report for every tool. When you finish, you will have a solid foundation on which to build the rest of the book.

Dataset for This Chapter

We use the small HapMap3 test data shipped with the PLINK tutorials:

```
wget https://www.cog-genomics.org/static/bin/plink/
# Files: .bed (binary genotypes), .bim (variant info)
# Size: about 1,115 individuals and 1.4M variants
```

We also use chromosome 22 from the 1000 Genomes Project for heavier tests:


```
wget http://ftp.1000genomes.ebi.ac.uk/vol1/ftp/rel
```

Learning Objectives

After this chapter you can: (1) install and verify PLINK2; (2) run REGENIE step 1 and interpret its output; (3) install SAIGE via conda; (4) compute a genetic relationship matrix with GCTA; (5) set up the full R environment; (6) write an automated comprehensive verification script.

Essential Background

Every statistical-genetics tool shares one logic: read the genotype matrix (individuals $\times$ variants), then perform linear operations on it. The central formula uniting them all is the generalized linear regression model:

$$E[y] = X\beta + G\gamma$$

where y is the trait, X the covariates (age, sex, principal components), G the genotype, and g the link function (identity for continuous traits, logistic for binary).

Analogy: Setting up a computing environment is like preparing a professional kitchen before cooking. A chef does not start cooking and then look for the knife; they arrange their tools first, sharpen them, verify them, so that when cooking time comes everything is in place. The script we write in Problem 6 is the "kitchen prep checklist" you run once and rest assured.

Problems

Problem 1.1 ★ [Beginner]

Install PLINK2 and verify it using the HapMap3 data. Run a command that reads the files and outputs the number of samples and variants. What tells you the installation succeeded?

Hint: The `--freq` command, or simply reading the file with `--validate`, suffices to verify.

Solution 1.1

```
# Download and install
wget https://s3.amazonaws.com/plink2-assets/plink2_
```

```
unzip plink2_linux_x86_64_20240105.zip
chmod +x plink2
./plink2 --version

# Verify with HapMap3 data
./plink2 --bfile hapmap3_r3_b36_fwd.consensus.qc.ped \
        --freq \
        --out hapmap_check
```

Expected output (representative):

```
PLINK v2.00a5.10 64-bit (5 Jan 2024)
1115 samples (562 females, 553 males) loaded from .
1457897 variants loaded from .bim.
Calculating allele frequencies... done.
--freq: Allele frequencies written to hapmap_check
```

Interpretation: The appearance of the sample count (1,115) and variant count (1,457,897) is conclusive proof that PLINK2 reads the binary files successfully. The resulting `.afreq` file contains the frequency of each allele — your first real output.

Had the installation failed, you would see "command not found" or a file-read error.

What if? If your data were in VCF format instead of BED, you replace `--bfile` with `--vcf` and everything else stays the same.

Problem 1.2 ★ [Beginner]

Install REGENIE, run step 1 on test data, and interpret the output files. What does the `_pred.list` file mean?

Hint: Step 1 builds polygenic predictions using the leave-one-chromosome-out (LOCO) scheme.

Solution 1.2

```
wget https://github.com/rgcgithub/regenie/releases/
unzip re genie_v3.4_linux_x86_64.zip
chmod +x re genie_v3.4_linux_x86_64

./regenie_v3.4_linux_x86_64 \
  --step 1 \
```

```
--bed hapmap3_r3_b36_fwd.consensus.qc.poly \
--phenoFile phenotypes.txt \
--bsize 1000 \
--bt \
--out fit_step1
```

Expected output (representative):

```
|=====|
|      REGENIE v3.4.gha      |
|=====|
```

Number of individuals retained: 1115

Number of variants used: 145320 (after QC)

Fitting null model... done in 42.3s

Output files: fit_step1_pred.list, fit_step1_1.loco

Interpretation: The `_pred.list` file is an index linking each trait to its `.loco` predictions file. LOCO predictions are the essence of REGENIE: for each chromosome, a polygenic prediction is computed based on the **remaining** chromosomes, to avoid the "proximal contamination" that loses statistical power. You feed this file into step 2.

Problem 1.3 ★ [Beginner]

Install SAIGE via conda and verify it with the built-in example.

✓ Solution 1.3

```
conda create -n saige_env -c conda-forge -c bioconda  
conda activate saige_env  
# Verify  
Rscript -e 'library(SAIGE); print(packageVersion("SAIGE"))'
```

Expected output:

```
[1] '1.3.0'
```

Interpretation: The appearance of the version number without library-loading errors means SAIGE and all its dependencies (RcppArmadillo, SPAtest, ...) installed cleanly. SAIGE is notoriously hard to install due to its compiled C++ dependencies; hence many researchers prefer the official Docker image over conda.

Problem 1.4 ★★ [Intermediate]

Install GCTA and compute the genetic relationship matrix (GRM) on chromosome 22 of 1000 Genomes.

✓ Solution 1.4

```
wget https://yanglab.westlake.edu.cn/software/gcta/  
unzip gcta-1.94.1-linux-kernel-3-x86_64.zip  
./gcta-1.94.1 --bfile chr22_1kg --make-grm --out chr22_grm
```

Expected output (representative):

```
Computing the genetic relationship matrix (GRM) ...  
2504 individuals are in common in these files.  
145112 SNPs are included in the analysis.  
GRM of 2504 individuals has been saved: chr22_grm.q  
Mean of diagonal GRM elements: 1.001
```

Interpretation: The GRM measures the degree of genetic relatedness between every pair of individuals. The mean diagonal near 1.0 is a sanity check (each individual relates to

itself at ≈ 1). Very high off-diagonal values reveal relatives — the basis of all mixed models later.

Problem 1.5 ★★ [Intermediate]

Set up the R environment, install all packages, and run a version-check script.

✓ Solution 1.5

```
pkgs <- c("data.table", "ggplot2", "dplyr", "qqman", "T",
          "coloc", "susier", "SNPRelate", "GWASTools")
for (p in pkgs) {
  if (!requireNamespace(p, quietly = TRUE))
    install.packages(p)
  cat(sprintf("%-15s : %s\n", p, as.character(packa
})
```

Expected output (representative):

```
data.table      : 1.15.0
ggplot2         : 3.4.4
TwoSampleMR     : 0.5.7
```



```
coloc                : 5.2.3
susieR               : 0.12.35
```

Interpretation: Printing each package with its version proves successful installation. Documenting versions matters for reproducibility (Chapter 24): your paper must report tool versions precisely.

Problem 1.6 ★★★ [Advanced]

Write a master `setup_check.sh` script that installs and verifies all tools and outputs a pass/fail report.

✓ Solution 1.6

```
#!/bin/bash

report() { printf "%-12s : %s\n" "$1" "$2"; }

check() { command -v "$1" >/dev/null 2>&1 && report

echo "=== Statistical Genetics Environment Check ==="
check ./plink2
check ./regenie_v3.4_linux_x86_64
```

```
check ./gcta-1.94.1
Rscript -e 'q <- c("SAIGE","data.table","coloc","su
  for (p in q) cat(sprintf("%-12s : %s\n", p,
    ifelse(requireNamespace(p,quietly=TRUE),"PASS","P
```

Expected output:

```
=== Statistical Genetics Environment Check ===
./plink2      : PASS
gcta-1.94.1   : PASS
SAIGE         : PASS
coloc         : PASS
```

Interpretation: This script is your complete "kitchen prep checklist." You run it once in each new environment, and it tells you precisely which tool is missing before you start an analysis that runs for hours and then fails midway.

Common Errors and Debugging

plink2: command not found — you forgot `chmod +x` or did not add to `PATH`; use `./plink2` or add it to

`$PATH.` error while loading shared libraries: `libgomp.so.1` — missing OpenMP library; `conda install libgomp`. REGENIE: phenotype file has fewer samples — column order or headers wrong; FID IID must be the first two columns. SAIGE installation fails compiling `RcppArmadillo` — old C++ compiler; use Docker. GCTA segmentation fault — corrupt BED file or insufficient memory; check with `--validate` and raise memory. cannot allocate vector of size in R — memory exhausted; read data in chunks with `data.table::fread`.

Deep Dive

In our lab at the University of Michigan, we run dozens of parallel projects on a shared HPC cluster, each with its own isolated conda environment. I learned the hard way that mixing tools in one environment is a disaster: the kidney project needs one R version, the single-cell project another, and they clash. The solution we adopted: an isolated conda environment per project, with an `environment.yml` file kept in a git

repository, so any colleague can rebuild the environment with one command. This discipline in setup saved us weeks of debugging and made our results reproducible when reviewers checked them. The HPC system loads software via `module load`, but available versions are limited, so we build our critical tools locally in the project folder.

Open Challenge

Write a script that builds a single Docker image containing all six tools at their pinned versions, so a researcher anywhere can run the book's entire pipeline with one `docker run` command. Verify the image size is under 5 GB and document every version.

Key References

Chang C.C. et al. (2015). "Second-generation PLINK." *GigaScience* — the reference paper for PLINK2. Mbatchou J. et al. (2021). "Computationally efficient whole-genome regression (REGENIE)." *Nature Genetics*. Zhou W. et al. (2018). "Efficiently controlling for case-control imbalance (SAIGE)." *Nature*

Genetics. Yang J. et al. (2011). "GCTA: A Tool for Genome-wide Complex Trait Analysis." *AJHG*.

Chapter 2 — تنسيقات ملفات البيانات الجينية / Genetic Data File Formats

﴿وَعَلَّمَ الْبَيَانَ﴾

"And taught him eloquence (clear expression)." — Surah Ar-Rahman:

4

God taught humanity *al-bayan* — the capacity to express and encode. Genetic data files are nothing but an encoded "expression" of the genome; whoever masters reading their encoding masters reading the life written within them.

Research Scenario

Data arrived from three collaborators: the first sent a VCF file, the second PLINK BED files, the third a BGEN file from imputed data. Each used a different array, and some encoded alleles on the positive strand and others on the negative. Your task: unify all of this into one clean format, while verifying the

integrity of each file. It sounds like a boring administrative task, but 90% of catastrophic GWAS errors begin here: a flipped allele, a mismatched sample, or a truncated file.

Genetic data is stored in multiple formats for historical and technical reasons: VCF for flexibility and human readability, BED for efficiency, BGEN for probabilistic imputed data. Understanding when and how to convert between them is an essential skill no researcher can do without.

Dataset for This Chapter

```
# VCF from 1000 Genomes
wget http://ftp.1000genomes.ebi.ac.uk/vol1/ftp/rel
# BED from HapMap3 (from the previous chapter)
# Test BGEN from the REGENIE documentation
wget https://github.com/rgcgithub/regenie/raw/maste
```

Learning Objectives

After this chapter you can: (1) read a VCF in R and decompose its components; (2) convert VCF to BED; (3) understand BIM/

FAM/BED encoding at the byte level; (4) convert BGEN to PGEN; (5) merge datasets from different arrays handling strand flips; (6) write a function reading five formats; (7) validate file integrity.

Essential Background

A VCF file is text divided into a header (lines starting with ##) and a table, each row a variant and each column after the ninth a sample. BED is binary and compressed: each genotype is encoded in **just two bits**, so four genotypes fit in one byte. The formula:

$$\text{BED size} \approx \frac{N_{\text{samples}}}{N_{\text{variants}}} \times 4 \text{ bytes}$$

Analogy: Different formats are like different languages for writing the same number: VCF is like a number spelled in words ("twenty-three") — readable but verbose; BED is like compressed Roman numerals — efficient but requiring expertise to read; BGEN is like scientific notation carrying uncertainty

(23 ± 0.1). Converting between them is like translation: it must preserve the meaning exactly, or a real signal is lost.

? Problems

Problem 2.1 ★ [Beginner]

Read a VCF file in R, and decompose the header, genotype matrix, and INFO fields.

Hint: The `VariantAnnotation` package from Bioconductor is the standard tool.

✓ Solution 2.1

```
library(VariantAnnotation)
vcf <- readVcf("ALL.chr22.phase3.vcf.gz", "hg19")
header(vcf)                # the header
geno(vcf)$GT[1:5, 1:5]     # the genotype matrix
info(vcf)$AF[1:5]          # allele frequency from
```

Expected output (representative):

	HG00096	HG00097	HG00099
rs587	"0 0"	"0 1"	"1 1"
rs588	"0 0"	"0 0"	"0 1"
[1]	0.12	0.45	0.03 0.88 0.21

Interpretation: The encoding 0|1 means the individual is heterozygous, and the pipe | means the data is **phased**. The GT matrix is the heart of a VCF file. The AF field gives the pre-computed allele frequency — useful for a quick sanity check.

Problem 2.2 ★ [Beginner]

Convert VCF to PLINK BED format.

✓ Solution 2.2

```
./plink2 --vcf ALL.chr22.phase3.vcf.gz \
        --make-bed \
        --max-alleles 2 \
        --out chr22_bed
```

Expected output (representative):

```
1103547 variants loaded from .pvar.
```

```
2504 samples loaded.
```

```
Note: 12043 multiallelic variants skipped (--max-al
```

```
--make-bed: chr22_bed.bed + .bim + .fam written.
```

Interpretation: `--max-alleles 2` is necessary because the BED format **does not support** multiallelic variants; they must be split or dropped. Ignoring this is a common cause of later errors.

Problem 2.3 ★ [Beginner]

Inspect the BIM/FAM/BED files. What does each column mean, and how is BED encoded at the byte level?

✓ Solution 2.3

```
head -3 chr22_bed.bim
```

```
# 22   rs587   0   16050075   A   G
```

```
# Columns: chromosome, ID, genetic position (cM), p
```

```
head -3 chr22_bed.fam
```

```
# 0 HG00096 0 0 0 -9
```

```
# Columns: FID, IID, father, mother, sex (1=male,2=
```

Interpretation: A BED file begins with three magic bytes (0x6c 0x1b 0x01), then each genotype in two bits: 00=homozygous allele1, 11=homozygous allele2, 01=missing, 10=heterozygous. Understanding this encoding explains why BED is 32× smaller than text VCF.

Problem 2.4 ★★ [Intermediate]

Convert BGEN to PGEN, handling a sample-file mismatch.

✓ Solution 2.4

```
./plink2 --bgen example.bgen ref-first \  
        --sample example.sample \  
        --make-pgen \  
        --out example_pgen
```

Expected output:

```
500 samples loaded from .sample.
```

```
1000 variants loaded from example.bgen.
```

```
--make-pgen: example_pgen.pgen + .pvar + .psam writ
```

Interpretation: `ref-first` specifies which allele is the reference — a common error here flips the direction of every effect! The PGEN (second-generation) format supports probabilistic dosages for imputed data, unlike BED which stores only hard genotypes.

Problem 2.5 ★★ [Intermediate]

Merge three PLINK datasets from different arrays, handling strand flips.

✓ Solution 2.5

```
# Align strand first using a reference
```

```
./plink2 --bfile array1 --ref-from-fa hg19.fa --ma
```

```
# Merge
```

```
./plink2 --bfile array1_aligned --pmerge-list merge
```

Expected output:

```
Variants in common across 3 filesets: 287654
```

```
Warning: 1832 variants with strand inconsistency flipped
```

```
merged.bed + .bim + .fam written: 3500 samples, 287654 variants
```

Interpretation: Palindromic variants (A/T, G/C) are dangerous when merging because they are identical under strand flip, so the flip cannot be detected from alleles alone — reference frequencies are needed. That is why we usually drop them (a problem in Chapter 3).

Problem 2.6 ★★★ [Advanced]

Write an R function that reads any of five formats (VCF/BED/BGEN/GEN/HDF5) and returns a standardized data frame.

✓ Solution 2.6

```
read_genetic <- function(path) {  
  ext <- tools::file_ext(path)  
  geno <- switch(ext,  
    "vcf" = , "gz" = as(geno(readVcf(path))$GT, "A"),  
    "bed" = snpStats::read.plink(sub(".k", ext, file.path(path)))
```

```

    "bgen"          = rbgen::bgen.load(path)$data,
    "gen"           = data.table::fread(path),
    "h5"            = rhdf5::h5read(path, "genotype")
  stop("Unsupported format")
}
return(as.data.frame(geno))
}

```

Interpretation: This "universal converter" function reduces handling multiple formats to a single interface. `switch` routes each extension to the appropriate reader. In practice, you add error handling to each branch.

Problem 2.7 ★★ ★ [Advanced]

Validate file integrity: concordance of counts between BIM, FAM, and BED, and detection of truncated files.

✓ Solution 2.7

```

n_var=$(wc -l < chr22_bed.bim)
n_sam=$(wc -l < chr22_bed.fam)
expected=$(( (n_var * n_sam + 3) / 4 + 3 ))

```

```
actual=$(stat -c%s chr22_bed.bed)
echo "Expected: $expected bytes, Actual: $actual bytes"
[ "$actual" -ge "$expected" ] && echo "Intact" || echo "Truncated"
```

Interpretation: The BED file size must match the arithmetic formula (2 bits per genotype + 3 magic bytes). A mismatch reveals a truncated file — a silent error that can ruin an entire analysis with no clear error message.

Common Errors and Debugging

Error: Multiallelic variant — convert with `--max-alleles 2` or `bcftools norm -m`. Sample IDs don't match — the `.sample` file order does not match BGEN; check the column. Strand inconsistency — use a FASTA reference to align strand. Wrong allele as reference — mind `ref-first` vs. `ref-last`. Truncated BED file — re-download and verify the md5 checksum. Memory error reading VCF — read by ranges with `which=GRanges(...)`. INFO score

column missing — the data is not imputed or the field has a different name (R2 instead of INFO).

Deep Dive

When we imputed Arab kidney-patient samples at the University of Michigan, we hit the format problem head on. Our data came from two different arrays over the years, and when we merged them, an exciting "discovery" appeared in some region — later revealed to be purely a technical artifact from an uncorrected strand flip in palindromic variants. The lesson that stuck: **trust no merge until you align strand against a reference and drop ambiguous palindromes.** Today we prefer BGEN/PGEN for imputed data because it preserves the uncertainty dosage; a variant imputed with confidence 0.7 differs statistically from a directly measured genotype, and ignoring that difference inflates errors.

Open Challenge

Write a tool that automatically detects strand-flipped variants between two datasets by comparing their frequencies, without

needing a FASTA reference, using the correlation between frequencies to distinguish a true flip from population difference. At what frequency does the distinction become impossible?

Key References

Danecek P. et al. (2011). "The variant call format and VCFtools." *Bioinformatics* — the VCF standard. Band G., Marchini J. (2018). "BGEN: a binary file format for imputed genotype data." *bioRxiv*. Purcell S. et al. (2007). "PLINK: a toolset for whole-genome association." *AJHG* — origin of the BED format. Lin P. et al. (2014). "Strand-flip issues in GWAS meta-analysis." *Genetic Epidemiology*.

Chapter 3 — مراقبة جودة المتغيرات / Variant Quality Control

﴿وَلَا تُفْسِدُوا فِي الْأَرْضِ بَعْدَ إِصْلَاحِهَا﴾

"And do not cause corruption upon the earth after its reformation." —
Surah Al-A'raf: 56

God forbade corruption after reformation; and in data analysis, a poor-quality variant is a corruption that must be removed before it spoils the entire analysis. Quality control is reforming the earth before we plant in it.

Research Scenario

You have array data with 650K variants and 3,500 samples from five different collection sites. Before any association analysis, you must perform complete variant quality control and produce a site-level report. Some sites used less precise

protocols, producing variants with higher error rates. Your task is to distinguish real signal from technical noise.

Variant quality control is not an optional step; it is the first line of defense against false discoveries. A single bad variant can appear above the significance threshold and lead you to chase a biological mirage that does not exist.

Dataset for This Chapter

We use the HapMap3 data with simulated site information:

```
# Base data + a file linking each sample to its coordinates
# sites.txt: FID IID SITE
./plink2 --bfile hapmap3_qc --missing --hardy --freq
```

Learning Objectives

After this chapter you can: (1) apply MAF, missingness, and HWE filters; (2) plot the MAF distribution; (3) detect and remove palindromic variants; (4) perform site-level QC; (5) test differential missingness; (6) QC by batch; (7) build a Snakemake pipeline.

Essential Background

Three core filters: **minor allele frequency (MAF)** — we remove the very rare for low power; **missingness rate** — we remove variants exceeding a threshold (e.g., 2%); **Hardy-Weinberg equilibrium (HWE)** — we remove those sharply deviating in controls. The HWE test rests on the chi-square statistic:

$$\chi^2 = \sum \frac{(O - E)^2}{E}$$

where O are observed counts and E expected under $p^2+2pq+q^2$.

Analogy: Quality control is like inspecting eggs before cooking. You hold each up to the light (missingness), smell it (HWE), check its size (MAF). One rotten egg spoils the whole omelet, so inspecting beforehand is cheaper than throwing out the entire dish.

? Problems

Problem 3.1 ★ [Beginner]

Apply MAF, missingness, and HWE filters, and report counts at each step.

Hint: Use `--maf`, `--geno`, `--hwe` in one command.

✓ Solution 3.1

```
./plink2 --bfile hapmap3_raw \  
        --maf 0.01 \  
        --geno 0.02 \  
        --hwe 1e-6 \  
        --make-bed --out hapmap3_qc
```

Expected output (representative):

```
1457897 variants loaded.  
--geno: 18234 variants removed (missingness > 0.02)  
--maf: 312045 variants removed (MAF < 0.01).
```

```
--hwe: 4128 variants removed (p < 1e-6).  
1123490 variants remaining.
```

Interpretation: We started with 1.46M variants and 1.12M remain. 312K were removed for rarity (low MAF) — the largest group, as expected. 4,128 were removed for HWE deviation — these are candidates for technical errors. Order matters: we usually apply missingness before MAF.

Problem 3.2 ★ [Beginner]

Plot the MAF distribution before and after filtering, with cutoffs marked.

✓ Solution 3.2

```
library(data.table); library(ggplot2)  
frq <- fread("qc_stats.afreq")  
ggplot(frq, aes(ALT_FREQS)) +  
  geom_histogram(bins=50, fill="#1B3A5C") +  
  geom_vline(xintercept=c(0.01,0.99), color="#C9A840")  
labs(x="Allele frequency", y="Number of variants")
```

Expected output: A U-shaped histogram: two peaks at the extremes (rare variants) and a dip in the middle. The two gold lines at 0.01 and 0.99 bound the removed region.

Interpretation: The U-shape is natural: most variants are either very rare or very common. The region between the thresholds is what we keep for analysis.

Problem 3.3 ★★ [Intermediate]

Detect and remove palindromic variants (A/T and G/C). Why are they dangerous?

✓ Solution 3.3

```
bim <- fread("hapmap3_qc.bim")
palindromic <- bim[(V5=="A" & V6=="T") | (V5=="T" &
                                           (V5=="G" & V6=="C") | (V5=="C" &
                                                                    V6=="G"))]
fwrite(palindromic[,.(V2)], "palindromic.txt", col.names=V2)
# then: ./plink2 --bfile hapmap3_qc --exclude palindromic.txt
```

Expected output:

Number of palindromic variants: 47823

After removal: 1075667 variants

Interpretation: Palindromes are dangerous because A/T on the positive strand equals T/A on the negative — the strand cannot be distinguished from alleles alone. When merging or meta-analyzing, the effect direction may flip without our knowing. Removal is the safe solution for palindromes with frequency near 0.5.

Problem 3.4 ★★ [Intermediate]

Perform site-level QC: some sites have higher error rates.

✓ Solution 3.4

```
for site in 1 2 3 4 5; do
    ./plink2 --bfile hapmap3_qc --keep site${site}.txt
    --missing --out site${site}_miss
done

# Compare missingness across sites
sapply(1:5, function(s) mean(fread(paste0("site", s,
```

Expected output:

```
[1] 0.003 0.004 0.021 0.003 0.005
```

Interpretation: Site 3 has a sevenfold higher missingness rate (2.1% vs. 0.3%) — an indicator of a technical problem at that site. We may apply stricter filtering to its variants or exclude its suspect samples.

Problem 3.5 ★★ [Intermediate]

Test differential missingness: variants with more missingness in cases than controls indicate a batch effect.

✓ Solution 3.5

```
./plink2 --bfile hapmap3_qc --test-missing --out d  
dm <- fread("diffmiss.missing")  
sum(dm$P < 1e-5) # variants with significant diffe
```

Expected output:

```
[1] 213
```

Interpretation: 213 variants differ in missingness between cases and controls with strong significance. This is very dangerous: if cases and controls were collected in separate batches, differential missingness creates spurious associations. We remove these variants.

Problem 3.6 ★★★ [Advanced]

Perform QC by genotyping batch and identify batch-specific problematic variants.

✓ Solution 3.6

```
batches <- fread("batches.txt") # FID IID BATCH
results <- lapply(unique(batches$BATCH), function(k)
  # run --hardy and --missing per batch, then collect
  hwe <- fread(sprintf("batch_%s.hardy", b))
  hwe[P < 1e-6, SNP]
})
problem_snps <- table(unlist(results))
# variants failing in only one batch = suspected batch
batch_specific <- names(problem_snps)[problem_snps
```


Expected output:

```
Building DAG of jobs...  
rule variant_qc: 1 of 1 steps (100%) done
```

Interpretation: Snakemake makes the pipeline **reproducible**: it tracks dependencies and reruns only what changed. This is a gold standard for serious research (Chapter 24).

Common Errors and Debugging

--hwe filters too many variants — you applied it to cases and controls together; apply it to controls only with --keep controls. MAF threshold removes real signals — for rare variants use dedicated analysis (Chapter 16) instead of removal. Palindromic removal too aggressive — drop only those near frequency 0.5. test-missing requires phenotype — a case/control column must exist. Batch column not recognized — ensure FID/IID match. Snakemake: MissingInputException — the input file does not exist or its path is wrong.

Deep Dive

In the kidney study at the University of Michigan, our samples were collected over a decade from multiple sites and different arrays. The first GWAS we ran gave an inflation factor of $\lambda=1.15$ — alarmingly high. On investigation, we found the cause was not population stratification but a **batch effect**: a set of variants was genotyped with different quality between two time-batches, and cases concentrated in one batch while controls in another. When we applied the differential-missingness test and removed 400 suspect variants, λ dropped to 1.03. The lesson: **inflation is not always population-driven; it can be purely technical**, and strict batch- and site-level QC saves a study before false results are published.

Open Challenge

Design a composite variant-quality metric that integrates missingness, HWE, differential missingness, and cross-batch consistency into a single 0–1 score, then search for the optimal threshold that maximizes the number of reproducible true

discoveries and minimizes false ones. How do you verify your threshold is not overfit to your data?

Key References

Anderson C.A. et al. (2010). "Data quality control in genetic case-control association studies." *Nature Protocols* — the reference guide for QC. Marees A.T. et al. (2018). "A tutorial on conducting GWAS: QC and statistical analysis." *Int J Methods Psychiatr Res*. Laurie C.C. et al. (2010). "Quality control and quality assurance in genotypic data." *Genet Epidemiol*. Köster J., Rahmann S. (2012). "Snakemake — a scalable bioinformatics workflow engine." *Bioinformatics*.

Chapter 4 — مراقبة جودة العينات / Sample Quality Control

﴿وَفِي أَنْفُسِكُمْ أَفَلَا تُبْصِرُونَ﴾

"And within yourselves. Then will you not see?" — Surah Adh-Dharyat: 21

A call to reflect on the self; in sample quality control we reflect on every individual in our data: is their data sound? Are they who we think? Are they a hidden relative of another? Discernment about individuals protects the analysis from flaws.

Research Scenario

After variant QC, you have 3,500 samples left. Now you must identify and remove: high-missingness samples, heterozygosity outliers, sex mismatches, cryptic duplicates, and related individuals. Each of these problems contaminates the analysis

differently: a poor-quality sample injects noise, and cryptic relatives break the independence assumption.

Sample QC is the other face of variant QC. There we cleaned columns, here we clean rows. A single contaminated sample may suffice to spoil a real signal or create a false one.

Dataset for This Chapter

```
./plink2 --bfile hapmap3_qc --missing --het --check
# For relatedness:
./plink2 --bfile hapmap3_qc --make-king-table --out
```

Learning Objectives

After this chapter you can: (1) filter samples by missingness; (2) detect heterozygosity outliers; (3) check sex; (4) detect duplicates with IBS; (5) analyze relatedness with KING; (6) detect PCA outliers; (7) write a comprehensive QC report.

Essential Background

The heterozygosity statistic **F** measures the deviation of an individual's heterozygosity from expectation: $F = \frac{O_{\text{hom}} - E_{\text{hom}}}{N - E_{\text{hom}}}$ where high positive values mean less heterozygosity than expected (contamination or consanguinity), and high negative values mean more heterozygosity (one sample contaminated by another). **IBD/PI_HAT** measures the fraction of genome shared between two individuals: 0 for strangers, 0.5 for siblings or parent-child, 1 for twins/duplicates.

Analogy: Sample QC is like screening passengers before a flight. You verify identity (sex check), detect duplicate tickets (duplicates), ensure no one is on two lists (relatives), and turn away those with suspicious documents (high missingness). Your goal is a clean flight with no surprises.

? Problems

Problem 4.1 ★ [Beginner]

Calculate and filter by sample missingness rate.

✓ Solution 4.1

```
./plink2 --bfile hapmap3_qc --mind 0.02 --make-bed
```

Expected output:

```
3500 samples loaded.
```

```
--mind: 23 samples removed (missingness > 0.02).
```

```
3477 samples remaining.
```

Interpretation: 23 samples exceeding 2% missingness were removed. A high-missingness sample often indicates degraded DNA or genotyping failure — its data is unreliable across all variants.

Problem 4.2 ★ [Beginner]

Calculate the heterozygosity F-statistic, identify and remove outliers, and annotate the plot.

✓ Solution 4.2

```
het <- fread("sampleqc.het")
het[, F_stat := (`O(HOM)` - `E(HOM)`) / (`N(NM)` -
m <- mean(het$F_stat); s <- sd(het$F_stat)
outliers <- het[abs(F_stat - m) > 3*s]
ggplot(het, aes(F_stat)) + geom_histogram(bins=50)
  geom_vline(xintercept=c(m-3*s, m+3*s), color="red")
```

Expected output:

Number of outliers (>3 SD): 18

Normal range: -0.03 to 0.04

Interpretation: 18 samples beyond 3 SD. High positive outliers = possible contamination or consanguinity; high negative = two-sample contamination. Both warrant removal or investigation.

Problem 4.3 ★★ [Intermediate]

Check sex by comparing reported sex to genotype-inferred sex using X-chromosome heterozygosity.

✓ Solution 4.3

```
./plink2 --bfile hapmap3_qc --check-sex --out sexch  
  
sc <- fread("sexcheck.sexcheck")  
sc[STATUS == "PROBLEM"]
```

Expected output:

IID	PEDSEX	SNPSEX	STATUS	F
NA12878	2	1	PROBLEM	0.98
NA10859	1	2	PROBLEM	0.12

Interpretation: Males have one X copy, so their X heterozygosity ≈ 0 (F near 1). Females have two copies, so F is near 0. A mismatch (e.g., NA12878: reported female but $F=0.98$ indicating male) reveals a sample mislabeling or tube swap — a red flag warranting removal.

Problem 4.4 ★★ [Intermediate]

Detect cryptic duplicates using IBS with $PI_HAT > 0.9$.

✓ Solution 4.4

```
./plink2 --bfile hapmap3_qc --genome --min 0.9 --ou
```

Expected output:

IID1	IID2	PI_HAT	Z0	Z1	Z2
NA12005	NA12006	0.998	0.00	0.00	1.00

Interpretation: $PI_HAT \approx 1$ with $Z2 \approx 1$ (probability of sharing two alleles) means a duplicate or identical twin. In most studies, we remove one of the two (usually the higher-missingness one) to preserve sample independence.

Problem 4.5 ★★ [Intermediate]

Analyze relatedness with KING, build a kinship table, and decide which duplicate to remove.

✓ Solution 4.5

```
./plink2 --bfile hapmap3_qc --make-king-table --kin
king <- fread("king.kin0")
# KINSHIP > 0.354 = twin/dup, 0.177-0.354 = first degree
king[KINSHIP > 0.177]
```

Expected output:

ID1	ID2	KINSHIP	relationship
NA12005	NA12006	0.498	twin/dup
NA11843	NA11881	0.241	first degree

Interpretation: KING is more accurate than PI_HAT because it is **robust to population stratification**. A kinship of 0.5 is a twin, 0.25 first degree (siblings/parents), 0.125 second degree. We remove one individual from each close pair to preserve independence, preferring to keep the higher-quality one.

Problem 4.6 ★★★ [Advanced]

Detect population outliers: compute PCA and flag samples more than 6 SD from the centroid in PC1 and PC2.

✓ Solution 4.6

```
./plink2 --bfile hapmap3_qc --pca 10 --out pca

pca <- fread("pca.eigenvec")
for (pc in c("PC1", "PC2")) {
  m <- mean(pca[[pc]]); s <- sd(pca[[pc]])
  pca[, paste0(pc, "_out")] := abs(get(pc) - m) > 6*s]
}

outliers <- pca[PC1_out | PC2_out]
```

Expected output:

Number of PCA outliers: 7

Interpretation: Samples very distant in the principal components are either of an entirely different ancestry from the rest of the sample, or contaminated. 6 SD is a conservative

threshold avoiding removal of natural diversity. We inspect them before deciding.

Problem 4.7 ★★ ★ [Advanced]

Write a sample QC report in R Markdown with one plot per metric and a final exclusion table.

Solution 4.7

```
# sample_qc_report.Rmd
# For each metric: plot + threshold + excluded list
excluded <- unique(c(highmiss$IID, het_out$IID,
                    sex_problem$IID, dups$IID2, po
exclusion_table <- data.table(
  Reason = c("High missingness", "Het outlier", "Sex
            "Duplicate", "PCA outlier"),
  N = c(23, 18, 5, 12, 7))
knitr::kable(exclusion_table)
```

Expected output:

Reason	N
High missingness	23
Het outlier	18
Sex mismatch	5
Duplicate	12
PCA outlier	7
Total (unique)	61

Interpretation: The unified report makes exclusion decisions **transparent and auditable**. Every removed sample has a documented reason — exactly what reviewers require for publication.

Common Errors and Debugging

--check-sex needs X chromosome — ensure your data contains chromosome X. Heterozygosity needs LD pruning — prune LD first or F is biased. KING vs PI_HAT disagree — trust KING in multi-ancestry samples. Removing both duplicates — remove only one, keep the higher quality. PCA outliers are real

ancestry — do not remove true diversity; inspect before removal. mind before geno — filter variants before samples to avoid bias.

Deep Dive

In the kidney cohort at the University of Michigan, KING analysis revealed that 12 pairs of "independent patients" were in fact first-degree relatives — likely due to family recruitment at a single clinic. Had we ignored this, we would have broken the sample-independence assumption and inflated our standard errors. More importantly, we learned that Arab populations with high consanguinity rates show more cryptic relatedness than European populations, so KING analysis for us is not a luxury but a necessity. This is also a scientific opportunity: rich relatedness structures enable family-based linkage analyses unavailable in dispersed European samples.

Open Challenge

In a highly consanguineous population, background relatedness is inherently high, so removing every pair with

KINSHIP>0.088 may remove half the sample. Design a strategy that retains the largest possible "unrelated" subset (the maximum independent set problem in graph theory), then compare it to a mixed-model approach that retains everyone. Which gives higher power for your population?

Key References

Manichaikul A. et al. (2010). "Robust relationship inference in GWAS (KING)." *Bioinformatics*. Anderson C.A. et al. (2010). "Data quality control in genetic case-control studies." *Nature Protocols*. Turner S. et al. (2011). "Quality control procedures for GWAS." *Curr Protoc Hum Genet*. Price A.L. et al. (2006). "PCA corrects for stratification." *Nature Genetics*.

Chapter 5 — تحليل المكونات الرئيسية المتقدم / Advanced PCA Analysis

﴿وَجَعَلْنَاكُمْ شُعُوبًا وَقَبَائِلَ لِتَعَارَفُوا﴾

"And We made you into peoples and tribes that you may know one another." — Surah Al-Hujurat: 13

God made us peoples and tribes for mutual recognition; principal component analysis is the tool by which we "recognize" the ancestries of our samples, distinguishing the peoples and tribes hidden in the genome so we can adjust for them justly.

Research Scenario

Your cohort is multi-ethnic: Europeans, Africans, East Asians, South Asians, and Arabs. Before any GWAS, you must project your samples onto the 1000 Genomes reference, assign each sample its ancestry, and create covariates (PCs) to control for

population stratification. Mixing ancestries without adjustment is the leading cause of false discoveries in GWAS.

PCA in genetics is not mere dimensionality reduction; it is the astonishing discovery that the first two components capture continental geography with accuracy nearly matching the map. This chapter takes you from basic pruning to admixture proportion estimation.

Dataset for This Chapter

```
# Your samples + the ancestry-labeled 1000G reference
./plink2 --bfile study --indep-pairwise 200 50 0.2
./plink2 --bfile study --extract pruned.prune.in --
```

Learning Objectives

After this chapter you can: (1) prune LD for PCA; (2) run and plot PCA; (3) project samples onto the 1000G reference; (4) assign ancestry; (5) apply the Tracy-Widom test; (6) perform stratified analysis; (7) detect PCA outliers; (8) estimate admixture with ADMIXTURE.

Essential Background

PCA finds the axes explaining the most variance in the genotype matrix. Mathematically, we compute the eigenvalues and eigenvectors of the genetic relationship matrix:

$$\mathbf{G} \mathbf{v}_i = \lambda_i \mathbf{v}_i$$

where the eigenvector $\mathbf{v}_i$ is principal component i , and the eigenvalue λ_i the amount of variance it explains.

Analogy: PCA is like taking a silhouette of a three-dimensional object. The object is complex, but you choose the angle that shows the most distinction. PC1 is the "best angle" separating groups, PC2 the second-best angle perpendicular to it, and so on. In genetics, these angles coincide with continents.

? Problems

Problem 5.1 ★ [Beginner]

Prune LD for PCA. Why, with what parameters, and how do you verify?

✓ Solution 5.1

```
./plink2 --bfile study --indep-pairwise 200 50 0.2
```

Expected output:

```
Pruned 847291 variants, 198453 remaining.
```

Interpretation: PCA assumes relatively independent variants; variants in tight LD skew the components toward LD-dense regions (such as inversions). We keep one variant per 200-variant window, step 50, $r^2=0.2$ threshold. The ~200K independent variants remaining suffice for PCA.

Problem 5.2 ★ [Beginner]

Run PCA with PLINK2 and plot PC1 vs PC2 colored by population.

✓ Solution 5.2

```
pca <- fread("study_pca.eigenvec")
pop <- fread("populations.txt")
d <- merge(pca, pop, by="IID")
ggplot(d, aes(PC1, PC2, color=POP)) + geom_point(aes(
  scale_color_brewer(palette="Set1")
```

Expected output: Separate clouds: Africans in one corner, Europeans in another, East Asians in a third, and Arabs between Europeans and Africans (reflecting admixture history).

Interpretation: The separation of clouds confirms that PC1 and PC2 capture continental ancestry. The intermediate position of Arabs is biologically meaningful: it reflects components from several ancestries.

Problem 5.3 ★★ [Intermediate]

Project new samples onto the 1000G reference components.

✓ Solution 5.3

```
# Compute components in the reference, then project
./plink2 --bfile 1000G_ref --freq --pca 20 allele-v
./plink2 --bfile study --read-freq ref_pca.afreq \
    --score ref_pca.eigenvec.allele 2 5 header
    --score-col-nums 6-25 --out projected
```

Expected output:

Projected 3477 samples onto 20 reference PCs.

Interpretation: Projection places your samples in the **same space** as the reference, so you compare their ancestry by a unified standard. This is more accurate than computing a separate PCA because it ties them to populations of known ancestry.

Problem 5.4 ★★ [Intermediate]

Assign ancestry using the 3-SD rule from reference population centroids.

✓ Solution 5.4

```
centroids <- proj_ref[, .(mPC1=mean(PC1), mPC2=mean(PC2),  
                          sPC1=sd(PC1), sPC2=sd(PC2))]  
assign_anc <- function(pc1, pc2){  
  d <- centroids[, sqrt(((pc1-mPC1)/sPC1)^2 + ((pc2-mPC2)/sPC2)^2)]  
  if (min(d) < 3) centroids$POP[which.min(d)] else "Admixed"  
}  
study[, ancestry := mapply(assign_anc, PC1, PC2)]
```

Expected output:

```
EUR: 1840  AFR: 612  EAS: 410  SAS: 380  Admixed: 2
```

Interpretation: The standardized Euclidean distance from each centroid determines ancestry. Those more than 3 SD from every centroid are classed as "admixed" — and these need special handling in multi-ancestry GWAS (Chapter 17).

Problem 5.5 ★★ [Intermediate]

Use the Tracy-Widom test to determine the optimal number of components.

✓ Solution 5.5

```
library(AssocTests)
tw_result <- tw(eigenvalues, eigenL=length(eigenvalues))
cat("Number of significant components:", tw_result)
```

Expected output:

```
Number of significant components: 6
```

Interpretation: The Tracy-Widom test determines how many components capture real structure vs. noise. Here 6 significant components — meaning population structure in 6 dimensions. We include at least these six as covariates.

Problem 5.6 ★★★ [Advanced]

Perform stratified analysis: run PCA separately within each ancestry group.

✓ Solution 5.6

```
for anc in EUR AFR EAS SAS; do
    ./plink2 --bfile study --keep ${anc}.txt \
        --extract pruned.prune.in --pca 10 --out
done
```

Interpretation: Within each ancestry, the components reveal **fine** structure (such as North/South Europe) invisible in mixed PCA dominated by the major continental differences. This is essential for fine-grained adjustment within each group.

Problem 5.7 ★★★ [Advanced]

Detect PCA outliers and write an automated exclusion script.

✓ Solution 5.7

```
detect_outliers <- function(pca, n_pc=10, sd_thresh)
  out <- rep(FALSE, nrow(pca))
  for (i in 1:n_pc){
    pc <- pca[[paste0("PC",i)]]
    out <- out | (abs(pc - mean(pc)) > sd_thresh*sd)
  }
  pca[out, .(FID, IID)]
}

fwrite(detect_outliers(study_pca), "pca_exclude.txt")
```

Interpretation: Checking 10 components (not just two) reveals outliers in finer dimensions too. The script produces an exclusion list ready for `--remove`.

Problem 5.8 ★★★★★ [Expert]

Estimate admixture proportions with ADMIXTURE (K=2 to K=7) with cross-validation to find the best K, visualized with stacked bar plots.

✓ Solution 5.8

```
for K in 2 3 4 5 6 7; do
  admixture --cv study_pruned.bed $K | tee log${K}.out
done
grep -h CV log*.out

# Plot the best K
Q <- fread("study_pruned.5.Q")
barplot(t(as.matrix(Q)), col=rainbow(5), border=NA,
```

Expected output:

```
CV error (K=2): 0.4821
CV error (K=4): 0.4503  <-- lowest
CV error (K=5): 0.4519
```

Interpretation: The lowest cross-validation error (K=4) indicates 4 ancestral groups. The stacked bars show each ancestry's proportion in each individual — an admixed individual appears in multiple colors. ADMIXTURE is more accurate than PCA for quantitative admixture proportion estimation.

Common Errors and Debugging

PCA dominated by one region — you did not prune LD, or an inversion region (such as the chr8 inversion, MHC) dominates; remove it. Projection gives wrong scale — you must use reference frequencies with `--read-freq`. Too few/many PCs — use Tracy-Widom or a scree plot. ADMIXTURE very slow — prune LD and reduce variant count. Ancestry assignment fails for Arabs — Arabs are poorly represented in 1000G; use a custom reference if available. negative eigenvalues — a non-positive-definite matrix; check the data.

Deep Dive

When we projected Arab kidney-patient samples onto the 1000G reference at the University of Michigan, we faced a fundamental challenge: Arabs are not represented in 1000G, so our samples fell into an "intermediate" region between Europeans, Africans, and South Asians, and no reference centroid matched them. We had to build custom components

within the Arab sample itself to adjust for fine structure. This embodied for me, in practice, the "Arab genomics gap": the tools are all calibrated on populations that do not include us. I usually include 10 components in kidney models, but I learned the number is not sacred; I inspect the scree plot and λ after each choice. Not more than necessary (which wastes power), nor fewer (which leaves inflation).

Open Challenge

Arabs fall into a void in the 1000G space. Design a method to build an "Arab-centered" component reference from available Arab data (such as the Greater Middle East Variome), then measure how much inflation control (λ) improves in an Arab GWAS compared to using Europe-centered 1000G components. What is the minimum Arab-reference size to be useful?

Key References

Price A.L. et al. (2006). "Principal components analysis corrects for stratification in GWAS." *Nature Genetics*. Patterson N. et al.

(2006). "Population structure and eigenanalysis." *PLoS Genetics*
— origin of the Tracy-Widom application. Alexander D.H. et al.
(2009). "Fast model-based estimation of ancestry
(ADMIXTURE)." *Genome Research*. Novembre J. et al. (2008).
"Genes mirror geography within Europe." *Nature*.

Chapter 6 — استيفاء البيانات الجينية / Genotype Imputation

﴿وَمَا أُوتِيتُمْ مِّنَ الْعِلْمِ إِلَّا قَلِيلًا﴾

"And you have not been given of knowledge except a little." — Surah Al-Isra: 85

We were given but little knowledge; the array measures only a little of the genome (650K), so we impute the rest (8 million) by inferring the unknown from the known. Imputation is a methodical epistemic humility: we admit what we do not measure, and estimate it with the best we have.



Research Scenario

Your genotyped data contains 650K SNPs. You want to expand to over 8 million variants by imputation using the TOPMed reference panel. Why? Because imputation increases coverage density, allowing detection of signals between measured

variants, and enables meta-analysis between studies using different arrays (harmonizing variants).

Imputation exploits LD: neighboring measured variants predict the unmeasured variants between them, based on haplotype patterns in a huge reference panel. The result is not certainty but a probability (a dosage), and each variant has a confidence score (INFO).

Dataset for This Chapter

```
# Genotyped data after QC + TOPMed panel via the impute2 pipeline
# Preparation:
./plink2 --bfile study_qc --recode vcf --out study_for_imputation
bcftools sort study_for_imputation.vcf -Oz -o study_for_imputation.vcf.gz
```

Learning Objectives

After this chapter you can: (1) prepare data for the Michigan server; (2) understand the output and INFO; (3) filter imputed variants; (4) compare frequencies to gnomAD; (5) impute locally

with MINIMAC4; (6) evaluate quality; (7) build a parallel pipeline.

Essential Background

The INFO score (also called r^2 or R^2) measures imputation confidence, between 0 and 1. Approximately, it is the ratio of true variance in the imputed dosage to expected variance:

$$\text{INFO} \approx \frac{\text{Var}(\text{dosage})}{2p(1-p)}$$

Variants with $\text{INFO} < 0.8$ are usually excluded for low confidence.

Analogy: Imputation is like completing missing words in a familiar sentence. If you read "In the name of God, the Most Gracious, the Most..." you would complete "Merciful" with near-total confidence (high INFO), because the context (LD) is strong. But in a rare, obscure sentence, your completion is a weak guess (low INFO). Reference density (panel size) is the richness of your linguistic library: the more texts you know, the better you complete.

? Problems

Problem 6.1 ★ [Beginner]

Prepare data for the Michigan Imputation Server. What QC steps are required and what does the server check?

✓ Solution 6.1

```
# Per chromosome: sorted compressed VCF, strand alignment
for chr in {1..22}; do
    ./plink2 --bfile study_qc --chr $chr --recode vcf
    --out chr${chr}
done

# Pre-upload check tool:
perl HRC-1000G-check-bim.pl -b study_qc.bim -f stud
```

Expected output:

```
Matching to reference panel...
Position matches: 648203
Strand flips corrected: 1204
```

```
Allele frequency outliers removed: 312
```

```
Ready for upload: chr1.vcf.gz ... chr22.vcf.gz
```

Interpretation: The server checks: position matching to the reference, strand alignment, frequency outliers. The pre-check tool corrects these before upload, avoiding server rejection. A frequency outlier (a variant whose frequency differs greatly from the reference) signals a strand or position error.

Problem 6.2 ★ [Beginner]

Submit to the server and understand the output: INFO, imputed vs. genotyped.

Solution 6.2

```
# After download and decryption:
bcftools view -h chr1.dose.vcf.gz | grep "INFO"
zcat chr1.info.gz | head -3
```

Expected output:

SNP	REF	ALT	MAF	Rsq	Genotyped
chr1:10583	G	A	0.21	0.94	Genotyped
chr1:10611	C	G	0.03	0.71	Imputed

Interpretation: The Genotyped column distinguishes the actually measured from the imputed. A genotyped variant has Rsq=1 (directly measured), the imputed less. Here the second variant (Rsq=0.71) is relatively weak — near the exclusion threshold.

Problem 6.3 ★★ [Intermediate]

Filter imputed variants by INFO > 0.8 and MAF > 0.01.

✓ Solution 6.3

```
for chr in {1..22}; do
    ./plink2 --vcf chr${chr}.dose.vcf.gz dosage=DS \
        --extract-if-info "R2 > 0.8" \
        --maf 0.01 --make-pgen --out chr${chr}_p
done
```

Expected output:

Before: 8243110 variants

After INFO>0.8 & MAF>0.01: 6102488 variants

Interpretation: From 8.2M to 6.1M after filtering. dosage=DS preserves the probabilistic dosage (does not convert it to a hard genotype), which matters for retaining the uncertainty information in later analysis.

Problem 6.4 ★★ [Intermediate]

Compare allele frequencies between your imputed data and gnomAD, and detect discordances.

✓ Solution 6.4

```
imp <- fread("chr1.info.gz")[, .(SNP, MAF_imp=MAF)]
gnomad <- fread("gnomad_chr1.tsv")[, .(SNP, MAF_gnomad)]
m <- merge(imp, gnomad, by="SNP")
m[, diff := abs(MAF_imp - MAF_gnomad)]
ggplot(m, aes(MAF_gnomad, MAF_imp)) + geom_point(aes(alpha=diff)) +
  geom_abline(color="red")
discordant <- m[diff > 0.1]
```

Expected output:

```
Number of discordant variants (diff>0.1): 1847  
Correlation: 0.991
```

Interpretation: The high correlation (0.99) confirms good imputation overall. The discordant variants (1,847) may be strand errors or real population differences (if your sample differs from the gnomAD reference). We inspect them before relying on them.

Problem 6.5 ★★ [Intermediate]

Perform local imputation with MINIMAC4 (when you cannot send data to a cloud server, as with sensitive data).

✓ Solution 6.5

```
# Phase first, then impute  
eagle --vcf=chr1.vcf.gz --geneticMapFile=genetic_map.txt  
      --outPrefix=chr1_phased  
minimac4 --refHaps TOPMed_chr1.msav \
```

```
--haps chr1_phased.vcf.gz \  
--prefix chr1_imputed
```

Expected output:

```
Estimated Rsq distribution: mean=0.86
```

```
Imputation finished: chr1_imputed.dose.vcf.gz
```

Interpretation: Local imputation is necessary for sensitive data (patients, privacy agreements) that may not be uploaded to external servers. MINIMAC4 gives the same results but under your full control. It requires downloading the TOPMed reference panel locally (large size).

Problem 6.6 ★★ ★ [Advanced]

Evaluate imputation quality: plot the INFO distribution by MAF bin.

 Solution 6.6

```
info <- fread("all_chr.info.gz")  
info[, maf_bin := cut(MAF, breaks=c(0,0.01,0.05,0.1
```

```
ggplot(info, aes(maf_bin, Rsq)) + geom_boxplot(fill=
  labs(x="MAF bin", y="INFO/Rsq score")
```

Expected output: Boxes showing INFO rises with MAF: rare variants ($\text{MAF} < 0.01$) have a mean INFO of ~ 0.5 , common ones ($\text{MAF} > 0.1$) ~ 0.95 .

Interpretation: Imputation is harder for the rare: few copies in the reference weaken confidence. That is why stricter INFO thresholds are used for the rare (e.g., 0.9) than the common (0.8). This relationship is fundamental to understanding where to trust your imputed data.

Problem 6.7 ★★ ★ [Advanced]

Create a post-imputation processing pipeline that handles all chromosomes in parallel.

✓ Solution 6.7

```
#!/bin/bash
#SBATCH --array=1-22
chr=${SLURM_ARRAY_TASK_ID}
```

```
plink2 --vcf chr${chr}.dose.vcf.gz dosage=DS \  
      --extract-if-info "R2 > 0.8" --maf 0.01 \  
      --make-pgen --out chr${chr}_clean
```

Interpretation: A SLURM array (--array=1-22) runs 22 parallel jobs, one per chromosome, reducing hours to minutes. This pattern (parallelism by chromosome) is the backbone of every genomic computation on HPC.

Common Errors and Debugging

Server rejects upload: build mismatch — convert coordinates to the correct build (hg19 vs hg38) with liftOver. Strand errors at server — run the pre-check tool. INFO column named differently — TOPMed calls it R2, others Rsq or INFO. dosage lost after filtering — always use dosage=DS. MINIMAC4 out of memory — split the chromosome into windows. Allele frequency mismatch with gnomAD — ensure ancestry match between your sample and the reference. liftOver drops variants — some

positions do not translate between builds; losing a small fraction is normal.

Deep Dive

When we imputed Arab kidney-patient samples at the University of Michigan, we chose TOPMed over HRC, for a fundamental reason: TOPMed is a more diverse panel (including African, Hispanic, and other ancestries), so it gave higher INFO scores for our non-European samples. With HRC (mostly European), many variants common in Arabs were imputed with low confidence because they are rare or absent in the European reference. This is another embodiment of the diversity gap: even the reference itself is biased. I learned to always inspect the INFO distribution **within** the Arab group specifically, not the overall sample, because the overall mean can hide poor imputation in minorities.

Open Challenge

Design an experiment measuring how much imputation for Arabs improves when a few hundred complete Arab genomes

are added to the TOPMed panel, compared to TOPMed alone. At what added Arab-sample size does the improvement in mean INFO become practically significant (e.g., +0.05)? And is the improvement larger for rare or common variants?

Key References

Das S. et al. (2016). "Next-generation genotype imputation service (Michigan Imputation Server)." *Nature Genetics*. Taliun D. et al. (2021). "Sequencing of 53,831 diverse genomes from the NHLBI TOPMed Program." *Nature*. Howie B. et al. (2012). "Fast and accurate genotype imputation." *Nature Genetics*. Loh P.R. et al. (2016). "Reference-based phasing using the Haplotype Reference Consortium (Eagle2)." *Nature Genetics*.

Chapter 7 — اختبارات الارتباط الأساسية بـ

PLINK2 / Basic Association Testing

with PLINK2

﴿إِنَّ اللَّهَ يَأْمُرُ بِالْعَدْلِ وَالْإِحْسَانِ﴾

"Indeed, God commands justice and good conduct." — Surah An-Nahl: 90

Justice is comparing like with like; an association test, if adjusted with covariates, is statistical justice that ensures what we attribute to a gene is truly a gene, not the effect of age or hidden ancestry.



Research Scenario

You have 5,000 samples (2,000 cases, 3,000 controls) for type 2 diabetes. Your task is to run a basic GWAS with PLINK2 logistic regression. This is the first real association analysis in

the book — everything before it was preparation. Here you will learn to format the phenotype and covariate files, interpret the output columns, and choose the appropriate genetic model.

PLINK2 is fast and sufficient for moderate, unrelated samples. When the sample grows or relatedness appears, we move to REGENIE and SAIGE (Chapters 8 and 9). But understanding PLINK2 is the foundation for understanding them.

Dataset for This Chapter

```
# T2D data: 5000 samples + phenotype file + covariate files
# pheno.txt: FID IID T2D
# covar.txt: FID IID AGE SEX PC1..PC10
./plink2 --bfile t2d_qc --glm --pheno pheno.txt --covar covar.txt
```

Learning Objectives

After this chapter you can: (1) format phenotype and covariate files; (2) run logistic regression for a binary trait; (3) run linear regression for a continuous trait; (4) add covariates; (5) test the

three models; (6) perform conditional analysis; (7) run sex-stratified GWAS.

Essential Background

Logistic regression models the log odds of disease as a linear function:

$$\log\left(\frac{P(\text{disease})}{1-P(\text{disease})}\right) = \beta_0 + \beta_G \cdot G + \sum \beta_k X_k$$

where β_G is the gene effect (log odds ratio), and X_k the covariates. The odds ratio = e^{β_G} .

Analogy: Regression is like a balance weighing each factor's contribution separately. When you ask "does this allele raise risk?", regression answers after "fixing" age, sex, and ancestry — as if asking: if two people were equal in everything except this allele, how much would their risk differ?

? Problems

Problem 7.1 ★ [Beginner]

Format the phenotype and covariate files correctly. What are the common mistakes and how do you avoid them?

✓ Solution 7.1

```
head -2 pheno.txt
# FID IID T2D      (1=control, 2=case in PLINK, or 0)
# fam1 ind1 2
head -2 covar.txt
# FID IID AGE SEX PC1 PC2 ... PC10
```

Interpretation: The first two columns are always FID and IID in the same order across all files. PLINK's default case coding is 1=control and 2=case (and 0/-9=missing); to use 0/1 add --1. The most common error: mixed coding or wrong column headers.

Problem 7.2 ★ [Beginner]

Run logistic regression for the binary trait and interpret the output columns.

✓ Solution 7.2

```
./plink2 --bfile t2d_qc --glm --pheno pheno.txt --p  
--covar covar.txt --out gwas_logistic
```

Expected output (representative):

#CHROM	POS	ID	A1	OR	SE	Z_STAT
10	114758	rs7903146	T	1.37	0.021	15.2

Interpretation: A1 is the effect allele, OR=1.37 means each copy of T raises the odds of diabetes by 37%, SE the standard error, Z_STAT the test statistic, $P=4\times 10^{-52}$ overwhelming genome-wide significance. This is rs7903146 in the TCF7L2 gene — the strongest known common variant for diabetes.

Problem 7.3 ★ [Beginner]

Run linear regression for a continuous trait (eGFR) and interpret the difference in output.

✓ Solution 7.3

```
./plink2 --bfile kidney_qc --glm --pheno egfr.txt --covar covar.txt --out gwas_linear
```

Expected output:

#CHROM	POS	ID	A1	BETA	SE	T_STAT
16	20392	rs12917707	T	-1.24	0.18	-6.9

Interpretation: The key difference: for a continuous trait we get BETA (not OR). BETA=-1.24 means each copy of T lowers eGFR by 1.24 units. This is rs12917707 near the UMOD gene — the most famous signal for kidney function.

Problem 7.4 ★★ [Intermediate]

Add covariates (age, sex, 10 PCs), and compare Manhattan plots before and after.

✓ Solution 7.4

```
# Without covariates
./plink2 --bfile t2d_qc --glm allow-no-covars --pheno pheno.txt --out no_cov

# With covariates
./plink2 --bfile t2d_qc --glm --pheno pheno.txt --cov cov.txt --out with_cov

# Compare  $\lambda$ 
lambda <- function(p) median(qchisq(1-p, 1)) / qchisq(0.5, 1)
c(no_cov=lambda(fread("no_cov.T2D.glm.logistic")$P),
  with_cov=lambda(fread("with_cov.T2D.glm.logistic")$P))
```

Expected output:

no_cov	with_cov
1.21	1.03

Interpretation: Without component adjustment, $\lambda=1.21$ (inflation from population stratification). Adding components dropped it to 1.03. The "before" Manhattan plot is full of scattered false signals, the "after" is clean with isolated real towers. This is the clearest proof of the necessity of adjustment.

Problem 7.5 ★★ [Intermediate]

Test the three models (additive, dominant, recessive). When does model choice matter?

 Solution 7.5

```
./plink2 --bfile t2d_qc --glm --pheno pheno.txt --c
--genotypic --out gwas_models
```

Expected output:

TEST	OR	P	
ADD	1.37	4e-52	(additive)
DOMDEV	1.02	0.78	(non-significant dominant)

Interpretation: The additive model (each copy adds a constant effect) is the default and suffices for most variants. The non-significance of DOMDEV confirms the effect is additive. The recessive model matters only when the effect requires two copies (rare), as in some immune diseases. Testing many models increases the multiple-testing burden.

Problem 7.6 ★★★ [Advanced]

Perform conditional analysis: condition on a known signal and search for independent signals.

✓ Solution 7.6

```
./plink2 --bfile t2d_qc --glm --pheno pheno.txt --condition rs7903146 --out conditional
```

Expected output:

```
# Before conditioning: peak at rs7903146 (P=4e-52)
# After conditioning: rs7903146 disappears, but rs7
```


Interpretation: By including rs7903146 as a covariate, we ask: is there a signal **independent** of it in the region? rs7901695 remaining significant means a second, separate signal (allelic heterogeneity) — an important discovery revealing a complex locus structure.

Problem 7.7 ★★★ [Advanced]

Run sex-stratified GWAS, test for heterogeneity, and plot the comparison.

✓ Solution 7.7

```
./plink2 --bfile t2d_qc --keep males.txt --glm --ph
./plink2 --bfile t2d_qc --keep females.txt --glm --ph

# Heterogeneity test between sexes
m <- fread("males_gwas.T2D.glm.logistic"); f <- fread("females_gwas.T2D.glm.logistic")
d <- merge(m, f, by="ID", suffixes=c("_m", "_f"))
d[, z_het := (log(OR_m)-log(OR_f)) / sqrt(SE_m^2 + SE_f^2)]
d[, p_het := 2*pnorm(-abs(z_het))]
d[p_het < 5e-8] # variants with different effects
```

Interpretation: The heterogeneity test reveals variants whose effect differs between males and females (a sex-specific effect). Rare but biologically intriguing — it may indicate a hormonal interaction. Plotting `OR_m` vs `OR_f` shows the variants deviating from the diagonal.

Common Errors and Debugging

All p-values are NA — the phenotype is constant or coding is wrong; check 0/1 with `--1`. Covariate file mismatch — FID/IID do not match; align the files. Quasi-separation warning — a rare variant perfectly separates cases; drop it or use Firth with `--glm firth`. lambda too high — add components or move to a mixed model. `--condition` variant not found — ensure the variant exists in the data. OR vs BETA confusion — logistic gives OR, linear gives BETA.

Deep Dive

In my kidney GWAS work at the University of Michigan, I always start with PLINK2 as a fast exploratory step before the heavy models. An important lesson I learned: Firth regression (`--glm firth-fallback`) is a lifesaver for rare variants in imbalanced case-control settings. When cases are few and the risk allele rare, ordinary logistic regression fails (quasi-complete separation) and gives fantastical odds ratios ($OR=10^6$, say). Firth corrects this with a deliberate bias. I also learned that the UMOD variant (rs12917707) appears in nearly every kidney-function analysis we run, to the point that it became an internal "sanity check": if UMOD does not appear, there is a pipeline error.

Open Challenge

Design a simulation that determines at what sample size and what case:control imbalance ratio ordinary PLINK2 logistic regression begins to give inflated results compared to Firth and

to SAIGE. Draw a "decision map" telling the researcher when PLINK2 suffices and when to switch.

Key References

Chang C.C. et al. (2015). "Second-generation PLINK." *GigaScience*. Mahajan A. et al. (2022). "Multi-ancestry genetic study of type 2 diabetes (DIAMANTE)." *Nature Genetics* — the latest diabetes GWAS. Grant S.F. et al. (2006). "Variant of TCF7L2 confers risk of type 2 diabetes." *Nature Genetics*. Ma C. et al. (2013). "Recommended joint and meta-analysis strategies (Firth)." *Genet Epidemiol*.

Chapter 8 — REGENIE: نموذج الانحدار على مستوى الجينوم / REGENIE: Whole Genome Regression

﴿وَوَجَدَكَ ضَالًّا فَهَدَىٰ﴾

"And He found you lost and guided you." — Surah Ad-Duha: 7

From wandering to guidance; when GWAS results are inflated by cryptic relatedness ($\lambda=1.18$), PLINK2 regression is lost, and REGENIE is the guidance: a model that embraces relatedness instead of stumbling over it.

Research Scenario

Your cohort has grown to 50,000 samples with cryptic relatedness. Standard PLINK2 logistic regression is inflated ($\lambda=1.18$) because it assumes sample independence — an assumption broken by the presence of relatives. The solution:

REGENIE, which models relatedness implicitly via a polygenic prediction, controlling inflation without losing power.

REGENIE works in two steps: the first builds polygenic predictions using the leave-one-chromosome-out (LOCO) scheme; the second tests each variant including the LOCO prediction as a covariate. This chapter is the backbone of large-scale GWAS.

Dataset for This Chapter

```
# 50K samples, binary and continuous traits
# Step 1 on high-quality genotyped variants, step 2
```

Learning Objectives

After this chapter you can: (1) understand step 1 and LOCO; (2) run it for a continuous trait; (3) step 2 on genotyped; (4) step 2 on imputed BGEN; (5) multiple phenotypes; (6) HPC optimization; (7) compare before/after.

Essential Background

REGENIE in step 1 fits a polygenic ridge regression: it splits the genome into blocks, computes predictions per block, then aggregates them. The LOCO prediction for chromosome c is computed from all chromosomes **except** c :

$$\hat{y}_{\text{LOCO}(c)} = \sum_k \hat{g}_k$$

Including this prediction as a covariate in step 2 absorbs the effect of relatedness and polygenic structure.

Analogy: LOCO is like an exam in a school that prevents cheating. When you test a chromosome, you hide its own answers from it (exclude it from the prediction) to prevent "proximal contamination" — the variant predicting itself via its LD neighbors, which falsely inflates power. Each chromosome is tested with information from its siblings, not itself.

? Problems

Problem 8.1 ★ [Beginner]

Understand step 1 (ridge and LOCO) and run it for a binary trait.

✓ Solution 8.1

```
./regenie --step 1 --bed array_qc --bt \  
  --phenoFile pheno.txt --phenoCol T2D \  
  --covarFile covar.txt --covarColList AGE,SEX,PC1-PC10 \  
  --bsize 1000 --lowmem --out fit_bin
```

Expected output:

Number of individuals: 50000

Level 0 ridge: 5 parameters

Level 1 ridge: cross-validated, best lambda selected

Output: fit_bin_pred.list, fit_bin_1.loco ... _22.1

Interpretation: Level 0 fits ridge within small blocks, and level 1 aggregates them with cross-validation. The .loco files (one

per chromosome) are the fruit of step 1, fed into step 2. `--lowmem` reduces memory usage for large samples.

Problem 8.2 ★ [Beginner]

Run step 1 for a continuous trait (eGFR), and compare to binary.

Solution 8.2

```
./regenie --step 1 --bed array_qc \  
  --phenoFile egfr.txt --phenoCol eGFR \  
  --covarFile covar.txt --covarCollist AGE,SEX,PC1-  
  --bsize 1000 --out fit_qt
```

Interpretation: The only difference: dropping `--bt` (the default is a continuous trait). REGENIE for a continuous trait uses linear regression in the later model. The LOCO output structure is the same. Continuous traits compute faster because they need no Saddlepoint approximation.

Problem 8.3 ★★ [Intermediate]

Run step 2 (association testing) on the genotyped variants, and visualize the output.

✓ Solution 8.3

```
./regenie --step 2 --bed array_qc --bt \  
  --phenoFile pheno.txt --phenoCol T2D \  
  --covarFile covar.txt --covarColList AGE,SEX,PC1-PC10 \  
  --pred fit_bin_pred.list --bsize 400 --firth --approx \  
  --out test_bin
```

Expected output:

CHROM	GENPOS	ID	ALLELE0	ALLELE1	AFREQ	BETA
10	114758	rs7903146	C	T	0.30	0.31

Interpretation: $\text{LOG}_{10}P=51.4$ means $p=10^{-51.4}$. REGENIE outputs $\text{LOG}_{10}P$ instead of P to avoid numerical underflow at very small values. `--firth --approx` applies the fast Firth correction for imbalanced traits.

Problem 8.4 ★★ [Intermediate]

Run step 2 on imputed BGEN files for 8 million variants, with chromosome splitting.

✓ Solution 8.4

```
for chr in {1..22}; do
    ./regenie --step 2 --bgen chr${chr}.bgen --ref-first \
        --sample chr${chr}.sample --bt \
        --phenoFile pheno.txt --phenoCol T2D \
        --pred fit_bin_pred.list --bsize 400 --firth -- \
        --out test_chr${chr}
done
```

Interpretation: We pass each chromosome separately (parallelism). `--ref-first` is crucial for specifying the reference allele in BGEN. REGENIE reads the probabilistic dosages directly from BGEN, preserving the imputation-uncertainty information.

Problem 8.5 ★★★ [Advanced]

Run multi-phenotype REGENIE: 5 kidney phenotypes together, and compare runtime to single-phenotype.

✓ Solution 8.5

```
./regenie --step 1 --bed array_qc \  
  --phenoFile kidney_phenos.txt \  
  --phenoColList eGFR,UACR,BUN,Creatinine,CKD \  
  --covarFile covar.txt --covarColList AGE,SEX,PC1-  
  --bsize 1000 --out fit_multi
```

Expected output:

5 phenotypes processed simultaneously

Runtime: 1.4× single phenotype (not 5×)

Interpretation: The major advantage: processing 5 phenotypes takes only 1.4× a single one, not 5×, because REGENIE reuses the shared matrix operations. This is ideal for biobanks with many phenotypes.

Problem 8.6 ★★★ [Advanced]

Optimize REGENIE for HPC: parallel submission, `--bsize` tuning, memory requirements.

✓ Solution 8.6

```
#SBATCH --array=1-22 --mem=16G --cpus-per-task=8
chr=$SLURM_ARRAY_TASK_ID
./regenie --step 2 --bgen chr${chr}.bgen --threads
    --bsize 400 --pred fit_pred.list --out chr${chr}
```

Interpretation: `--bsize` balances speed and memory: larger = faster but more memory. 400 is good for step 2. `--threads 8` uses the cores. The SLURM array parallelizes chromosomes. The rule: step 1 needs more memory (whole genome), step 2 less.

Problem 8.7 ★★★★★ [Expert]

Compare REGENIE results before/after: λ values, QQ plots, correlation of beta estimates.

✓ Solution 8.7

```
plink <- fread("plink_gwas.logistic")
regenie <- fread("regenie_test.regenie")
d <- merge(plink, regenie, by="ID")
cor(d$BETA_plink, d$BETA_regenie) # correlation of
#  $\lambda$  for each
lambda_plink <- median(qchisq(1-d$P_plink,1))/qchisq(1-0.05,1)
lambda_regenie <- median(qchisq(1-10^(-d$LOG10P),1))/qchisq(1-0.05,1)
```

Expected output:

```
beta correlation: 0.94
 $\lambda$  PLINK: 1.18       $\lambda$  REGENIE: 1.02
```

Interpretation: The beta estimates are strongly correlated (0.94) — REGENIE does not change the real signals, it corrects inflation. λ dropped from 1.18 to 1.02: REGENIE absorbed the relatedness and polygenic structure. The "after" QQ plot hugs the diagonal up to the tail.

Common Errors and Debugging

Step 2 needs pred file from step 1 — pass `--pred`. LOG10P not P — REGENIE outputs LOG10P; convert with $10^{(-\text{LOG10P})}$. `--firth` slow — add `--approx` for fast approximation. `bsize` too large: out of memory — reduce `--bsize`. phenotype not found — match column names. BGEN ref allele wrong — use `--ref-first` or `--ref-last` per your file. Step 1 very slow — reduce step-1 variant count (high-quality genotyped suffices).

Deep Dive

I ran REGENIE on a 70,000-sample kidney GWAS at the University of Michigan, and it was a transformative decision. REGENIE's block-diagonal approximation is the secret to its speed: instead of inverting a huge relatedness matrix (70K×70K, memory-impossible), it splits the problem into solvable blocks. But this approximation may "miss" subtle long-range relatedness in rare cases. I learned to always verify by comparing λ with

SAIGE in a subsample. In most of our analyses, REGENIE and SAIGE agree practically, but REGENIE is many times faster for multiple phenotypes — which is decisive when we analyze dozens of kidney traits together.

Open Challenge

Design an experiment measuring when REGENIE's block-diagonal approximation begins to diverge from exact SAIGE: vary the degree of relatedness in simulated samples (from strangers to a highly inbred population), and observe at what relatedness level the λ difference begins to exceed 0.02. Are highly consanguineous Arab populations within the safe range for REGENIE?

Key References

Mbatchou J. et al. (2021). "Computationally efficient whole-genome regression for quantitative and binary traits (REGENIE)." *Nature Genetics*. Loh P.R. et al. (2018). "Mixed-model association for biobank-scale datasets (BOLT-LMM)." *Nature Genetics*. Wuttke M. et al. (2019). "Catalog of genetic loci

for kidney function." *Nature Genetics*. Yang J. et al. (2014).
"Advantages and pitfalls of mixed linear models." *Nature Genetics*.

Chapter 9 — SAIGE: المختلطة للبيانات

SAIGE: Mixed Models for Imbalanced Data / غير المتوازنة

﴿وَلَا تَيْأَسُوا مِنْ رَوْحِ اللَّهِ﴾

"And do not despair of the mercy of God." — Surah Yusuf: 87

Do not despair when cases seem tiny against a sea of controls; where others fail, SAIGE brings relief: the Saddlepoint approximation that rescues the test from inflation in the most severe imbalance.

Research Scenario

Your chronic kidney failure study is severely imbalanced: 1,500 cases against 48,500 controls (a 1:32 ratio). REGENIE — despite its power — may give inflated p-values for rare variants in this imbalance, because its normal approximation assumes a

symmetric distribution. The solution: SAIGE, which uses the Saddlepoint approximation (SPA) to correct the asymmetric distribution tail.

SAIGE combines two features: a logistic mixed model (adjusting for relatedness) + SPA correction (adjusting for imbalance). This makes it the gold standard for rare diseases in biobanks.

Dataset for This Chapter

CKD: 1500 cases, 48500 controls, imputed + sparse

Learning Objectives

After this chapter you can: (1) fit the null model; (2) run single-variant tests on chr22; (3) run the full genome in parallel; (4) a continuous trait; (5) interpret SAIGE-specific output; (6) SAIGE-GENE for rare variants; (7) SAIGE-GENE+ multi-trait; (8) a three-way comparison.

Essential Background

In severe imbalance, the test statistic's distribution deviates from symmetry, so ordinary regression gives inflated p-values in the tail. The Saddlepoint approximation approximates the moment-generating function to reconstruct the tail accurately:

$$P(S > s) \approx \text{SPA}\{K(t), s\}$$

where $K(t)$ is the cumulant-generating function. This corrects the extreme values where the normal approximation fails.

Analogy: Ordinary regression is like a straight ruler measuring accurately near the middle but deviating at the edges. SPA is like a curved ruler that follows the true curvature of the distribution at the edges (very small p-values) — exactly where we need accuracy in GWAS.

? Problems

Problem 9.1 ★ [Beginner]

Fit the SAIGE null model for a binary trait, and understand variance ratio estimation.

✓ Solution 9.1

```
step1_fitNULLGLMM.R \  
  --plinkFile=array_qc \  
  --phenoFile=pheno.txt --phenoCol=CKD \  
  --covarColList=AGE,SEX,PC1,PC2,PC3,PC4 \  
  --traitType=binary \  
  --outputPrefix=ckd_null --nThreads=8
```

Expected output:

```
Variance component estimate (tau): 0.18
```

```
Variance ratio estimate: 0.992
```

```
Null model fitted. Output: ckd_null.rda, ckd_null.v
```

Interpretation: τ is the genetic variance component (relatedness). The variance ratio (0.992) is a calibration that lets SAIGE compute genome-wide tests quickly without inverting a full GRM for each variant. This approximation is the secret of its efficiency.

Problem 9.2 ★ [Beginner]

Run single-variant tests on chr22, and verify against PLINK2.

✓ Solution 9.2

```
step2_SPAtests.R \  
  --bgenFile=chr22.bgen --sampleFile=chr22.sample \  
  --GMMATmodelFile=ckd_null.rda \  
  --varianceRatioFile=ckd_null.varianceRatio.txt \  
  --SAIGEOutputFile=ckd_chr22.txt --minMAF=0.01
```

Expected output:

CHR	POS	SNPID	Allele1	Allele2	AC_Allele2	AF
22	20392	rs12345	C	T	1820	0.0

Interpretation: The `p.value` column is SPA-corrected. For rare variants, `p` here is larger (less inflated) than in ordinary PLINK — that is the correction. `AF_Allele2` is the frequency of the tested allele.

Problem 9.3 ★★ [Intermediate]

Run SAIGE on the full genome in parallel, and merge the results.

✓ Solution 9.3

```
#SBATCH --array=1-22
chr=$SLURM_ARRAY_TASK_ID
step2_SPAtests.R --bgenFile=chr${chr}.bgen \
  --GMMATmodelFile=ckd_null.rda \
  --varianceRatioFile=ckd_null.varianceRatio.txt \
  --SAIGEOutputFile=ckd_chr${chr}.txt
# Merge:
cat ckd_chr*.txt > ckd_all.txt
```

Interpretation: The null model is fitted **once**, then reused across all parallel chromosomes. This separation of two steps (a heavy model once, many light tests) is the pattern of all modern mixed-model tools.

Problem 9.4 ★★ [Intermediate]

Run SAIGE for a continuous trait, and compare to REGENIE for the same trait.

✓ Solution 9.4

```
step1_fitNULLGLMM.R --traitType=quantitative \  
  --phenoCol=eGFR --invNormalize=TRUE \  
  --plinkFile=array_qc --outputPrefix=egfr_null
```

Interpretation: `--invNormalize=TRUE` applies the rank inverse-normal transformation, useful for non-normal traits. For a balanced continuous trait, SAIGE and REGENIE give near-identical results; SAIGE's advantage shows mainly in imbalanced binary traits.

Problem 9.5 ★★ [Intermediate]

Interpret SAIGE-specific output: allele frequency in cases vs. controls.

✓ Solution 9.5

```
saige <- fread("ckd_all.txt")  
# SAIGE outputs separate case/control AF on request  
saige[, .(SNPID, AF_case, AF_ctrl, BETA, p.value)]
```

Expected output:

SNPID	AF_case	AF_ctrl	BETA	p.value
rs77924	0.045	0.021	0.78	3e-11

Interpretation: The allele frequency is higher in cases (0.045) than controls (0.021) — consistent with the positive BETA. This direct comparison helps understand the effect direction and size, and catches errors (if BETA were positive but frequency higher in controls, there is a problem).

Problem 9.6 ★★★ [Advanced]

Run SAIGE-GENE: a gene-level burden test for rare variants, preparing the grouping file.

✓ Solution 9.6

```
step2_SPAtests.R --bgenFile=exome.bgen \  
  --GMMATmodelFile=ckd_null.rda \  
  --groupFile=gene_groups.txt \  
  --annotation_in_groupTest=lof,missense \  
  --maxMAF_in_groupTest=0.01 \  
  --SAIGEOutputFile=ckd_gene.txt
```

Expected output:

Gene	Pvalue_Burden	Pvalue_SKAT	Pvalue_SKATO
PKD1	1.2e-8	3e-7	4e-8

Interpretation: The group file links each rare variant to its gene. SAIGE-GENE collapses the rare variants within a gene into one test (burden/SKAT/SKAT-O, Chapter 16). PKD1 (the

polycystic kidney disease gene) appears significant — a classic example of a strong rare signal.

Problem 9.7 ★★★ [Advanced]

Run SAIGE-GENE+ multi-trait simultaneously.

Solution 9.7

```
step1_fitNULLGLMM.R --phenoColList=CKD,eGFR,UACR \
  --traitType=binary,quantitative,quantitative \
  --outputPrefix=multi_null
```

Interpretation: SAIGE-GENE+ tests gene sets across multiple traits together, increasing power by exploiting the correlation between traits. Useful when traits are biologically related (like the three kidney traits).

Problem 9.8 ★★★★★ [Expert]

Head-to-head: SAIGE vs. REGENIE vs. PLINK2 on the same data — three Manhattan plots, λ comparison, compute-time table.

✓ Solution 9.8

```
tools <- c("PLINK2", "REGENIE", "SAIGE")
lambda <- c(1.24, 1.04, 1.01)
runtime_min <- c(15, 95, 320)
data.table(Tool=tools, Lambda=lambda, Runtime=runtime_min)
```

Expected output:

Tool	Lambda	Runtime (min)
PLINK2	1.24	15
REGENIE	1.04	95
SAIGE	1.01	320

Interpretation: The trade-off is clear: PLINK2 is fastest but inflated in severe imbalance. SAIGE is most accurate ($\lambda=1.01$) but slowest. REGENIE is an excellent middle ground. The rule: PLINK2 for exploration, REGENIE for relatively balanced multiple traits, SAIGE for severely imbalanced rare diseases.

Common Errors and Debugging

Variance ratio estimation fails — reduce the number of variants in ratio estimation or increase the sample. SPA does not converge — a very rare variant ($\text{MAC} < 5$); raise `--minMAC`. groupFile format error — check the group file format (variant, annotation). Memory error in null model — use a sparse GRM `--sparseGRMFile`. p.value inflated despite SAIGE — check the principal components in the null model. Docker needed — many prefer the official SAIGE image to avoid installation issues.

Deep Dive

In the chronic kidney failure study at the University of Michigan, imbalance was our biggest problem: confirmed cases were few and controls many. The first time we tried PLINK2, many rare "discoveries" appeared with fantastically small p-values — all false, resulting from the normal approximation's failure in the tail under imbalance. SAIGE corrected them all:

the spurious signals evaporated and the real ones remained. The practical lesson that stuck: **for every rare disease with an imbalance ratio exceeding 1:10, SAIGE is not an option but a necessity**. I also learned that SAIGE-GENE opened the door to rare variants for us (Chapter 16); the PKD1 gene and its relatives do not appear in common GWAS, but they emerge in the gene-burden test.



Open Challenge

Design a simulation drawing the "imbalance frontier": at what case:control ratio and what MAF does the difference between PLINK2 and SAIGE in Type I error rate become practically significant? Build a two-axis map (imbalance $\times$ MAF) coloring the regions where PLINK2 suffices and those requiring SAIGE. Where do Arab rare-disease studies fall on this map?



Key References

Zhou W. et al. (2018). "Efficiently controlling for case-control imbalance and sample relatedness (SAIGE)." *Nature Genetics*.
Zhou W. et al. (2020). "Scalable generalized linear mixed model

for region-based tests (SAIGE-GENE)." *Nature Genetics*. Dey R. et al. (2017). "Saddlepoint approximation for sequence association tests." *AJHG*. Lee S. et al. (2012). "Optimal tests for rare variant effects (SKAT-O)." *Biostatistics*.

Chapter 10 — تصحيح الاختبارات المتعددة / Multiple Testing and Power

﴿وَلَا تَقْفُ مَا لَيْسَ لَكَ بِهِ عِلْمٌ﴾

"And do not pursue that of which you have no knowledge." — Surah Al-Isra: 36

Do not pursue what you have no knowledge of; with millions of tests, some deceive us with false signals. Multiple-testing correction and power calculation are two guards preventing us from "pursuing" without sufficient evidence.

Research Scenario

You are planning a new GWAS. How large must your sample be? What effect sizes can you detect? These questions must be answered **before** collecting data, not after the study fails. Power

calculation turns planning from guesswork into science: it tells you whether 5,000 samples suffice or you need 50,000.

At the other end, after the analysis, you face the multiple-testing problem: 8 million tests mean thousands of false positives by chance. This chapter joins the two faces of the coin: error control and power estimation.

Dataset for This Chapter

```
# Simulated data + real GWAS results for correction  
gwas <- fread("gwas_results.txt") # ID, BETA, SE,
```

Learning Objectives

After this chapter you can: (1) Bonferroni correction; (2) FDR with BH; (3) build a power curve; (4) power simulation; (5) compute required sample size; (6) a permutation threshold; (7) post-hoc power analysis.

Essential Background

Statistical power is the probability of detecting a true effect. It depends on four things: effect size, sample size, allele frequency (MAF), and significance threshold. For a continuous trait, the variance explained by the effect:

$$R^2 = 2 \cdot \text{MAF} \cdot (1 - \text{MAF}) \cdot \beta^2$$

The smaller the MAF or β , the smaller the R^2 , so the larger the sample needed to detect it.

Analogy: Power is like a telescope's ability to see a faint star. A faint star (small effect, rare MAF) needs a bigger telescope (larger sample). Designing a study without a power calculation is like buying a telescope without knowing whether it suffices to see what you want — you may spend a fortune and then see nothing.

? Problems

Problem 10.1 ★ [Beginner]

Compute the Bonferroni threshold for 8 million tests, and verify why 5×10^{-8} is used.

✓ Solution 10.1

```
n_tests <- 8e6
alpha <- 0.05
bonferroni <- alpha / n_tests
cat("Raw Bonferroni threshold:", bonferroni, "\n")
# But effectively independent tests ~1 million due
independent_tests <- 1e6
cat("Adjusted threshold:", alpha/independent_tests,
```

Expected output:

```
Raw Bonferroni threshold: 6.25e-09
Adjusted threshold: 5e-08
```

Interpretation: Raw Bonferroni for 8 million gives 6×10^{-9} , but LD makes the number of **independent** tests about one million, so the standard threshold is 5×10^{-8} . This balances excessive caution (8 million) against leniency.

Problem 10.2 ★ [Beginner]

Apply FDR with the BH method to real results. When do you use it instead of Bonferroni?

✓ Solution 10.2

```
gwas[, fdr := p.adjust(P, method="BH")]  
cat("Bonferroni discoveries:", sum(gwas$P < 5e-8),  
cat("FDR<0.05 discoveries:", sum(gwas$fdr < 0.05),
```

Expected output:

```
Bonferroni discoveries: 42  
FDR<0.05 discoveries: 118
```

Interpretation: FDR is less stringent (118 vs. 42), because it controls the **proportion** of false positives, not the existence of

any. We use it in exploratory analyses (expression analysis, pathways) where we tolerate some false positives for more discoveries. In confirmatory GWAS we adhere to Bonferroni.

Problem 10.3 ★★ [Intermediate]

Build a power curve: sample size vs. power for a given MAF and OR.

✓ Solution 10.3

```
library(genspwr)

power_curve <- sapply(seq(1000, 50000, 5000), function(n) {
  genpwr.calc(calc="power", model="logistic", N=n,
    Case.Rate=0.3, MAF=0.2, OR=1.2, Alpha=5e-8)$Power
})

plot(seq(1000,50000,5000), power_curve, type="b",
  xlab="Sample size", ylab="Power")
```

Expected output: A rising curve reaching 80% power at ~25,000 samples for OR=1.2 and MAF=0.2.

Interpretation: The curve tells you precisely: to detect a moderate effect ($OR=1.2$) with 80% power, you need ~25,000 samples. This is the basis of planning: if your budget allows only 5,000, you will detect only very large effects.

Problem 10.4 ★★ [Intermediate]

Power simulation: simulate 1,000 datasets, and count how often the causal variant is detected.

✓ Solution 10.4

```
detect <- replicate(1000, {  
  n <- 10000; maf <- 0.2; beta <- 0.15  
  g <- rbinom(n, 2, maf)  
  y <- beta*g + rnorm(n)  
  summary(lm(y ~ g))$coefficients[2,4] < 5e-8  
})  
cat("Simulated power:", mean(detect))
```

Expected output:

```
Simulated power: 0.83
```

Interpretation: Out of 1,000 simulations, the variant was detected in 83% — i.e., 83% power. Simulation is more accurate than analytical formulas because it mimics your actual conditions. 83% power means you will miss 17% of true effects at this size.

Problem 10.5 ★★ [Intermediate]

Compute the required sample size for 80% power at multiple (MAF, OR) combinations, producing a heatmap.

✓ Solution 10.5

```
grid <- expand.grid(MAF=c(0.05,0.1,0.2,0.4), OR=c(1,2,3,4,5,10))
grid$N <- mapply(function(m,o)
  genpwr.calc(calc="ss", model="logistic", Power=0.8,
    Case.Rate=0.5, MAF=m, OR=o, Alpha=5e-8)$N, grid$MAF, grid$OR)
ggplot(grid, aes(factor(MAF), factor(OR), fill=N))
  geom_tile() + geom_text(aes(label=round(N)))
```

Expected output: A map showing a small rare effect ($OR=1.1$, $MAF=0.05$) needs $>150K$ samples, while a large common effect ($OR=1.5$, $MAF=0.4$) needs $\sim 2,000$.

Interpretation: The map reveals why small rare effects are the "missing heritability": detecting them requires enormous sizes. This explains the evolution of GWAS toward massive biobanks.

Problem 10.6 ★★ ★ [Advanced]

Compute the significance threshold by permutation. When and how do you use it instead of Bonferroni?

✓ Solution 10.6

```
max_stats <- replicate(1000, {  
  y_perm <- sample(y) # shuffle the phenotype  
  max(abs(sapply(1:ncol(G), function(j)  
    cor(y_perm, G[,j]) * sqrt(length(y)-2))))  
})  
emp_threshold <- quantile(max_stats, 0.95)
```


Interpretation: Permutation builds the "max statistic" distribution under the null for your specific data, respecting LD structure automatically. The empirical threshold (95th percentile) is more accurate than Bonferroni for correlated data, but it is computationally expensive. We use it when the LD structure is complex or the sample is small.

Problem 10.7 ★★★ [Advanced]

Post-hoc power analysis: for signals that did **not** replicate, calculate what power you had to detect them.

✓ Solution 10.7

```
failed_replication <- fread("non_replicated_hits.txt")
failed_replication[, power := mapply(function(b, se) {
  pnorm(abs(b)/se_rep - qnorm(1-5e-8/2)), BETA_discovery,
  SE_discovery, SIMULATED_EFFECT_SIZE, SIMULATED_EFFECT_SIZE),
  MTEC, SIMULATED_EFFECT_SIZE, SIMULATED_EFFECT_SIZE)]
failed_replication[power < 0.5] # failed due to low power
```

Interpretation: A replication failure may be because the signal is false, **or** because the replication sample is small (low power). This analysis distinguishes the two: a signal with 0.3 power in

replication failed for lack of power, not falsehood. A fair verdict on signals.

Common Errors and Debugging

Bonferroni too conservative for correlated tests — use the standard 5×10^{-8} threshold or permutation. `p.adjust` wrong method — BH for FDR, bonferroni for FWER. Power calc ignores LD — simulation with LD is more accurate. Winner's curse inflates effect — the discovery effect is inflated; expect smaller in replication. `genpwr` wrong model — match logistic/linear to your trait. Permutation too slow — reduce permutations or use approximation. Post-hoc power misused — compute it with a pre-assumed effect size, not the observed.

Deep Dive

In planning kidney studies at the University of Michigan, prior power calculation saved us from doomed projects. Once, a collaborator wanted to study a rare variant's effect (MAF=0.02)

on kidney decline with a sample of 800 patients. The power calculation showed we would have only 15% power — i.e., an 85% chance of missing a true effect. We stopped the project before wasting resources, and waited until a larger sample accumulated. The lesson: **low power means not only failure to detect, but also that any positive result is suspect** (the winner's curse, where the discovered effect is inflated). I teach my students to begin every project with the question: what is our power? before the question: what did we find?



Open Challenge

Develop a simulation framework integrating the "winner's curse" into replication-study planning: given a discovered effect of a certain size and p-value, estimate the corrected (shrunk) **true** effect size, then compute the replication sample size needed to confirm it at 80% power. How misleading are the estimates if we ignore the shrinkage?

Key References

Benjamini Y., Hochberg Y. (1995). "Controlling the false discovery rate." *JRSS B*. Dudbridge F., Gusnanto A. (2008). "Estimation of significance thresholds for GWAS." *Genet Epidemiol*. Sham P.C., Purcell S.M. (2014). "Statistical power and significance testing in GWAS." *Nature Reviews Genetics*. Zhong H., Prentice R.L. (2008). "Bias-reduced estimators for the winner's curse." *Biostatistics*.

Chapter 11 — تحليل عدم التوازن الترابطي والهابلوتايب / Linkage Disequilibrium and Haplotype Analysis

﴿وَجَعَلْنَا مِنْ كُلِّ شَيْءٍ زَوْجَيْنِ﴾

"And of all things We created pairs." — Surah Adh-Dhariyat: 49

Of all things, pairs; and in the genome there are positions that travel coupled, scarcely parting. Linkage disequilibrium is the language of this coupling, and whoever reads it understands the structure of the signal in every region.



Research Scenario

You found a GWAS signal on chromosome 10. Now you must analyze the LD structure in that region to understand which variants travel together, and which may be causal. The signal is not a single variant but an entire "neighborhood" of correlated

variants, and understanding this neighborhood is a necessary step toward fine-mapping (Chapter 12).

LD is the basis of GWAS efficiency but also the source of its ambiguity: the statistically strongest variant is not necessarily causal, but may be merely a correlated "tag." This chapter teaches you to read LD structure and analyze haplotypes.

Dataset for This Chapter

```
# A 1Mb region around a signal, from 1000 Genomes  
./plink2 --bfile chr10_region --r2-unphased --out 1
```

Learning Objectives

After this chapter you can: (1) compute and plot an LD matrix; (2) identify LD blocks; (3) compare LD across populations; (4) clump results; (5) draw a regional association plot; (6) phase with SHAPEIT4; (7) run a haplotype association test.

Essential Background

The r^2 statistic measures predictive power between two positions:

$$r^2 = \frac{(p_{AB} - p_A p_B)^2}{p_A(1-p_A)p_B(1-p_B)}$$

$r^2=1$ means perfect prediction, and 0 means independence. r^2 decays with distance due to recombination.

Analogy: LD blocks are like "neighborhoods" on the chromosome; the neighborhood's residents move together. When you find a signal, you find an entire suspect neighborhood, not a single house. The task of fine-mapping later is to identify the culprit "house" (variant) within the neighborhood.

Problems

Problem 11.1 ★ [Beginner]

Compute the LD matrix for a 1Mb region around a signal, and plot the heatmap.

✓ Solution 11.1

```
./plink2 --bfile chr10_region --r2-unphased square  
  
library(LDheatmap)  
ld <- as.matrix(fread("ld.ld"))  
LDheatmap(ld, color=heat.colors(20))
```

Expected output: A triangular map with dark blocks along the diagonal (high LD within blocks) and light between them.

Interpretation: The dark blocks are LD "neighborhoods": tightly correlated variants. The causal variant usually lies within the largest dark block around the signal. This is the first glimpse of the region's structure.

Problem 11.2 ★ [Beginner]

Identify LD blocks using the four-gamete test.

✓ Solution 11.2

```
./plink2 --bfile chr10_region --blocks no-pheno-rec  
head blocks.blocks.det
```

Expected output:

CHR	BP1	BP2	KB	NSNPS	SNPS
10	114700	114780	80	23	rs.. rs..

Interpretation: The four-gamete test identifies block boundaries: where all four allele combinations exist, there was a recombination breaking the block. The block here is 80 kilobases containing 23 variants — a natural inheritance unit.

Problem 11.3 ★★ [Intermediate]

Compare LD in Europeans vs. Africans in the same region.

✓ Solution 11.3

```
./plink2 --bfile region --keep EUR.txt --r2-unphase  
./plink2 --bfile region --keep AFR.txt --r2-unphase
```

```
cat("European mean r2:", mean(fread("ld_eur.ld")$UN  
cat("African mean r2:", mean(fread("ld_afr.ld")$UN
```

Expected output:

European mean r²: 0.34

African mean r²: 0.19

Interpretation: LD is shorter in Africans ($r^2=0.19$ vs. 0.34) because they are an older population, so recombination has accumulated. This means fine-mapping is **easier** in Africans (smaller blocks = higher resolution), an advantage for multi-ancestry GWAS (Chapter 17).

Problem 11.4 ★★ [Intermediate]

Clump GWAS results: reduce 500K significant variants to independent signals.

✓ Solution 11.4

```
./plink2 --bfile ref --clump gwas_results.txt \  
        --clump-p1 5e-8 --clump-r2 0.1 --clump-kb \  
        --out clumped
```

Expected output:

```
500234 significant variants  
--clump: 47 independent loci identified
```

Interpretation: Clumping takes the strongest variant in each region and groups its correlated neighbors ($r^2 > 0.1$ within 250 kilobases) with it. From 500K "signals" to 47 truly **independent** loci. This distinguishes the count of significant variants from the count of real discoveries.

Problem 11.5 ★★ [Intermediate]

Draw a regional association (LocusZoom-style) plot for a GWAS signal.

✓ Solution 11.5

```
library(ggplot2)
region <- gwas[CHR==10 & BP > 114e6 & BP < 115e6]
lead <- region[which.min(P)]
region[, r2_with_lead := ld_with_lead] # from the
ggplot(region, aes(BP, -log10(P), color=r2_with_lead))
  geom_point() + scale_color_gradient(low="blue", high="red")
```

Expected output: Points colored by LD with the lead signal: red (high LD) near the peak, blue (low) scattered.

Interpretation: The regional association plot visually reveals: is the signal a single coherent block (one cause) or scattered (multiple signals)? Coloring by LD distinguishes true correlated variants from independent neighboring ones.

Problem 11.6 ★★★ [Advanced]

Phase the data with SHAPEIT4, and estimate the switch error rate.

✓ Solution 11.6

```
shapeit4 --input region.vcf.gz --map genetic_map.txt  
        --region 10 --output region_phased.vcf.gz
```

Expected output:

```
Phasing completed.
```

```
Estimated switch error rate: 0.018 (1.8%)
```

Interpretation: Phasing infers which allele is on which chromosome. The switch error rate (1.8%) measures quality: the fraction of positions where phasing errs between the two copies. Below 2% is good. Quality depends on reference size and variant density.

Problem 11.7 ★★★ [Advanced]

Run a haplotype association test, and compare it to the single-variant test.

✓ Solution 11.7

```
./plink2 --bfile region --hap-assoc haplotype_block1  
--pheno pheno.txt --out hap_test
```

Expected output:

```
Haplotype   Freq   OR    P  
A-T-G       0.21   1.45  2e-9   (risk haplotype)  
G-C-A       0.34   0.92  0.03  
Best single-variant test: P=3e-7
```

Interpretation: The haplotype test ($p=2\times 10^{-9}$) is stronger than the best single-variant test ($p=3\times 10^{-7}$) here, because the true effect is carried by a specific allele **combination**, not a single variant. This happens when variants interact on the same copy (cis-interaction).

⚠ Common Errors and Debugging

r^2 vs D' confusion — r^2 for prediction, D' for evolutionary history. LD computed across populations — compute LD within a single ancestry.

clump-kb too small — may split one signal; use 250–500. Phasing without genetic map — the genetic map is essential for accuracy. Switch error high — small reference or low variant density. Haplotype test underpowered — many haplotypes dilute power. LD heatmap too large — limit the range to a reasonable region.

Deep Dive

In analyzing a kidney region at the University of Michigan, LD structure taught me a fundamental lesson. We found a strong signal at a single variant, but clumping revealed it was in a block of 40 variants in tight LD ($r^2 > 0.9$). The statistically strongest variant was not causal — fine-mapping later revealed the causal one was another variant in the block, a regulatory one in an enhancer. This cemented a rule for me: **never trust that the "lead variant" is causal; it is merely the peak of the neighborhood**. We also benefited from the shorter LD in our non-European samples: smaller blocks narrowed the candidate

list quickly, so population diversity was a mapping tool, not an obstacle.

Open Challenge

Design a method that exploits LD-structure differences across multiple ancestries (short in Africans, long in Europeans) to narrow a shared signal region to the fewest causal candidates, without functional data. How many variants can be excluded by combining three ancestries compared to one?

Key References

Gabriel S.B. et al. (2002). "The structure of haplotype blocks in the human genome." *Science*. Pritchard J.K., Przeworski M. (2001). "Linkage disequilibrium in humans." *AJHG*. Delaneau O. et al. (2019). "Accurate, scalable phasing (SHAPEIT4)." *Nature Communications*. Pruim R.J. et al. (2010). "LocusZoom: regional visualization of GWAS results." *Bioinformatics*.

Chapter 12 — التحليل الدقيق للموضع الجيني / Fine-Mapping a GWAS Locus

﴿أَفَلَا يَتَدَبَّرُونَ الْقُرْآنَ﴾

"Then do they not reflect upon the Qur'an?" — Surah Muhammad:
24

Reflection is moving beyond the surface to the meaning; fine-mapping is moving beyond the "signal" to the true "causal variant" hidden among dozens of correlated ones.

Research Scenario

The eGFR GWAS showed a peak on chromosome 2. There are 47 variants in LD. Which one is likely causal? The statistical signal alone is insufficient — they are all correlated and significant. Fine-mapping uses probabilistic models to estimate "the probability that each variant is causal," reducing 47 candidates to a small credible set.

This chapter is the bridge between statistical discovery and biology. Without it, GWAS results remain obscure regions; with it, we approach the functional variant worthy of a lab experiment.

Dataset for This Chapter

```
# chr2 region + z-scores from GWAS + LD matrix  
# Preparing input for FINEMAP and SuSiE
```

Learning Objectives

After this chapter you can: (1) FINEMAP; (2) SuSiE; (3) compare them; (4) annotate the credible set; (5) colocalization; (6) hypercoloc; (7) the full fine-mapping pipeline.

Essential Background

Fine-mapping computes the **posterior inclusion probability** (PIP) for each variant: the probability it is among the causal variants, conditional on the data and LD. The "95% credible set" is the smallest set whose cumulative probability is $\geq 95\%$. SuSiE

models several independent signals via "single-effect regression" components:

$$\mathbf{y} = \sum_{l=1}^L \mathbf{X} \mathbf{b}_l + \mathbf{e}$$

where each $\mathbf{b}_l$ is a sparse vector carrying one causal signal.

Analogy: Fine-mapping is like a criminal investigation in a neighborhood of 47 suspects. The evidence (LD + signal strength) does not convict one with certainty, but narrows the list to 3–5 main suspects (the credible set). PIP is the "degree of suspicion" for each individual.

❓ Problems

Problem 12.1 ★ [Beginner]

Run FINEMAP: prepare the input (z-scores, LD matrix), and interpret the output.

✓ Solution 12.1

```
# A master file pointing to .z and .ld
finemap --sss --in-files master --n-causal-snps 5
cat region.snp | sort -grk11 | head
```

Expected output:

rsid	prob	log10bf
rs13391	0.62	8.4
rs13388	0.21	5.1
rs13402	0.08	3.2

Interpretation: The prob column is the PIP. rs13391 has a 62% probability of being causal — the strongest candidate. The probabilities sum toward 1 for each causal signal. `--n-causal-snps 5` allows up to 5 independent signals in the region.

Problem 12.2 ★★ [Intermediate]

Run SuSiE (`susie_rss`): credible sets vs. FINEMAP probabilities.

✓ Solution 12.2

```
library(susieR)
fit <- susie_rss(z=zscores, R=ld_matrix, n=765000,
print(fit$sets$cs)          # credible sets
susie_get_pip(fit)[1:5]     # inclusion probabilities
```

Expected output:

```
$L1: rs13391 (a single-variant credible set!)
$L2: rs13450, rs13455, rs13460 (a set of 3)
PIP: rs13391=0.94
```

Interpretation: SuSiE separates independent signals into distinct sets. Set L1 has only one variant (rs13391, PIP=0.94) — near-complete fine-mapping! L2 has 3 variants we could not distinguish (tight LD). This is clearer than FINEMAP at separating signals.

Problem 12.3 ★★ [Intermediate]

Compare FINEMAP and SuSiE credible sets: how often do they agree?

✓ Solution 12.3

```
finemap_top <- finemap_res[prob > 0.5, rsid]  
susie_top <- unlist(lapply(fit$sets$cs, function(s)  
intersect(finemap_top, susie_top)
```

Expected output:

```
Agreement: rs13391 (both place it as the main causal variant)  
Agreement rate across 47 loci: 89%
```

Interpretation: The two methods' agreement (89%) boosts confidence. When they agree, we trust the candidate; when they disagree, we suspect LD-matrix quality or complex signals. Using two independent methods is good practice.

Problem 12.4 ★★ [Intermediate]

Annotate the credible set: coding/non-coding, regulatory, eQTL overlap.

✓ Solution 12.4

```
library(VariantAnnotation)
credible_set <- c("rs13391", "rs13450", "rs13455")
# Functional annotation via VEP API or biomaRt
annotations <- query_vep(credible_set)
annotations[, .(rsid, consequence, regulatory, eqtl_kidney)]
```

Expected output:

rsid	consequence	regulatory	eqtl_kidney
rs13391	intron_variant	enhancer	YES (UMOD)
rs13450	missense	-	NO

Interpretation: rs13391 is in an enhancer and is an eQTL for UMOD in the kidney — a strong regulatory causal candidate. Functional annotation turns a "statistical variant" into a "biological hypothesis": it affects UMOD expression in kidney tissue.

Problem 12.5 ★★★ [Advanced]

Run colocalization with coloc: does the GWAS signal colocalize with an eQTL in GTEx kidney?

✓ Solution 12.5

```
library(coloc)
result <- coloc.abf(
  dataset1=list(beta=gwas_beta, varbeta=gwas_se^2,
  dataset2=list(beta=eqlt_beta, varbeta=eqlt_se^2,
result$summary["PP.H4.abf"]
```

Expected output:

```
PP.H4 (shared signal): 0.91
PP.H3 (two independent signals): 0.06
```

Interpretation: PP.H4=0.91 means a high probability that the GWAS and eQTL signals share the **same causal variant**. This is strong evidence that the variant's effect on the kidney acts **through** changing UMOD expression. The low PP.H3 rules out coincidence.

Problem 12.6 ★★★ [Advanced]

Run `hyprcoloc` for multiple traits together, sharing fine-mapping information across traits.

✓ Solution 12.6

```
library(hyprcoloc)
betas <- cbind(eGFR_beta, BUN_beta, UACR_beta, UMOD_beta)
ses <- cbind(eGFR_se, BUN_se, UACR_se, UMOD_eqtl_se)
hyprcoloc(betas, ses, trait.names=c("eGFR", "BUN", "UACR", "UMOD"),
          snp.id=snp_ids)
```

Expected output:

```
Cluster: eGFR, BUN, UMOD_eQTL share candidate rs13305420
UACR: separate signal
```

Interpretation: `hyprcoloc` reveals that 3 traits (eGFR, BUN, UMOD expression) share the same variant — a coherent causal network. UACR is a separate signal. Sharing information across traits increases mapping power compared to a single trait.

Problem 12.7 ★★★★★ [Expert]

The full fine-mapping pipeline: GWAS → credible set → annotation → colocalization → target gene → 1-page summary.

✓ Solution 12.7

```
finemap_pipeline <- function(locus){  
  cs <- run_susie(locus)          # 1. credible set  
  annot <- annotate_vep(cs)       # 2. annotation  
  coloc <- run_coloc(locus, gtex) # 3. colocalization  
  target <- coloc[PP.H4 > 0.8, gene] # 4. target gene  
  list(credible_set=cs, target_gene=target, evidence=coloc)  
}
```

Interpretation: This pipeline turns a raw GWAS signal into a testable target gene, in four automated steps. The output: "Region chr2 → variant rs13391 → enhancer → eQTL for UMOD → target gene UMOD". This is the final product needed for every discovered locus.

Common Errors and Debugging

LD matrix mismatch with z-scores — they must be from the same population and in the same order. SuSiE too many credible sets — reduce L or check LD quality. coloc assumes single causal — use SuSiE-coloc for multiple signals. PP.H4 low but signals overlap — they may be independent signals in LD (H3). FINEMAP n-causal too high — slows it and injects noise. Reference LD vs in-sample LD — in-sample LD is more accurate. eQTL different tissue — match the relevant tissue (kidney for kidney diseases).

Deep Dive

The full fine-mapping pipeline is the heart of my work at the University of Michigan. For a kidney variant, we started with a GWAS signal in a region with dozens of candidates. SuSiE narrowed it to a single variant with PIP=0.9. We found it in GTEx as an eQTL for a particular gene **specifically in kidney tissue**. coloc confirmed colocalization (PP.H4=0.91). So we

moved from an "obscure region" to a "target gene" in days. The UMOD region is a classic example where this worked exactly. The deeper lesson: **fine-mapping turns statistics into biology**, but it depends entirely on LD-matrix quality — and the European reference LD matrix gives misleading results for our non-European samples, so we take care to use in-sample LD.

Open Challenge

Fine-mapping fails when the reference LD matrix differs from the sample. Design an experiment measuring how much SuSiE accuracy degrades (does it place the true causal variant in the credible set?) as the divergence between reference LD and actual sample LD increases, especially for Arab samples mapped with a European reference. At what divergence does fine-mapping become unreliable?

Key References

Wang G. et al. (2020). "A simple new approach to variable selection in regression, with application to fine-mapping

(SuSiE)." *JRSS B*. Benner C. et al. (2016). "FINEMAP: efficient variable selection using summary data." *Bioinformatics*. Giambartolomei C. et al. (2014). "Bayesian test for colocalisation (coloc)." *PLoS Genetics*. Foley C.N. et al. (2021). "A fast and efficient colocalization algorithm (HyPrColoc)." *Nature Communications*.

Chapter 13 — والتعبير الجيني eQTL تحليل / eQTL Analysis and Gene Expression

﴿وَفَوْقَ كُلِّ ذِي عِلْمٍ عِلْمٌ﴾

"And above every possessor of knowledge is one more knowing." —
Surah Yusuf: 76

Above every knowledge is more knowledge; knowing a variant is associated with disease is knowledge, but above it is deeper knowledge: **how** does it work? eQTL analysis lifts us a layer: from association to the mechanism of gene expression.

Research Scenario

You want to understand which genes your GWAS variants regulate. You analyze eQTLs in kidney tissue: does the disease-associated variant raise or lower the expression of a particular gene? Most GWAS variants are regulatory, not coding, so their

effect on disease passes through changing the **amount** of protein produced, not its structure.

An eQTL (expression Quantitative Trait Locus) is the bridge between the genome and function. GTEx — which measured expression in 49 tissues — is the gold-standard reference. This chapter teaches you to link variants to the genes they regulate.

Dataset for This Chapter

```
# GTEx v8: eQTL data for 49 tissues
# API or download of kidney summaries
wget https://storage.googleapis.com/gtex/GTEx_Analy
```

Learning Objectives

After this chapter you can: (1) query the GTEx API; (2) identify cis-eQTLs; (3) FastQTL for trans; (4) colocalization; (5) sQTL; (6) single-cell eQTL; (7) TWAS; (8) the integration pipeline.

Essential Background

An eQTL tests the association of genotype with a gene's expression level:

$$\text{Expression}_{\text{gene}} = \beta_0 + \beta G + \text{covariates}$$

cis-eQTL: the variant near the gene ($\pm 1\text{Mb}$) — common and strong. **trans-eQTL**: the variant distant or on another chromosome — rare and weak.

Analogy: A gene is like a lamp, and an eQTL like a dimmer switch. A coding variant changes the shape of the lamp itself (the protein), whereas an eQTL changes its **brightness** (the amount of expression). Most GWAS signals act through distant "dimmer switches," not by changing the lamp.

? Problems

Problem 13.1 ★ [Beginner]

Query the GTEx API for eQTLs of a candidate gene in kidney cortex.

✓ Solution 13.1

```
library(httr); library(jsonlite)
url <- "https://gtexportal.org/api/v2/association/"
res <- GET(url, query=list(gencodeId="UMOD", tissue="kidney_cortex"))
eqtls <- fromJSON(content(res, "text"))$data
head(eqtls[, c("variantId", "pValue", "nes")])
```

Expected output:

variantId	pValue	nes
chr16_20364_C_T	3.2e-15	-0.42
chr16_20392_A_G	1.1e-12	-0.38

Interpretation: nes (normalized effect size) is negative: the alternate allele lowers UMOD expression. The very small p

(3×10^{-5}) = a strong eQTL in the kidney. This links the variant to a biological mechanism: reducing UMOD.

Problem 13.2 ★ [Beginner]

Download GTEx kidney summaries and identify cis-eQTLs for GWAS signals.

✓ Solution 13.2

```
gtex <- fread("Kidney_Cortex.v8.signif_variant_genes.tsv")
gwas_hits <- fread("gwas_loci.txt")
overlap <- merge(gtex, gwas_hits, by.x="variant_id", by.y="variant_id")
overlap[, .(variant_id, gene_id, pval_nominal, slope)]
```

Expected output:

variant_id	gene_id	pval_nominal	slope
chr16_20392	UMOD	1.1e-12	-0.38
chr2_15310	SHROOM3	4e-9	0.31

Interpretation: The overlap of GWAS variants with eQTLs reveals candidate genes: UMOD and SHROOM3 — both

known kidney genes. Overlap alone is not conclusive evidence (it may be coincidence in LD); we need colocalization (Problem 13.4).

Problem 13.3 ★★ [Intermediate]

Run FastQTL for trans-eQTL mapping. What are trans-eQTLs and why are they rare?

✓ Solution 13.3

```
fastQTL --vcf genotypes.vcf.gz --bed expression.bed  
        --region 1:1-250000000 --window 5e6 --out t
```

Interpretation: A trans-eQTL is a variant affecting a distant gene (or one on another chromosome), often via an intermediate transcription factor. They are rare because their effect is diluted along the chain (variant → transcription factor → target gene), and weak ones require huge samples and strict correction (every variant × every gene = enormous tests). The trans threshold is much stricter.

Problem 13.4 ★★ [Intermediate]

Run colocalization with a $PP.H4 > 0.8$ threshold, and test sensitivity to priors.

✓ Solution 13.4

```
library(coloc)
res <- coloc.abf(dataset1=gwas_data, dataset2=eqtl_
                  p1=1e-4, p2=1e-4, p12=1e-5)
sensitivity(res, "H4 > 0.8") # sensitivity test to
```

Expected output:

```
PP.H4 = 0.89
Sensitivity: robust to p12 in [1e-6, 1e-4]
```

Interpretation: $PP.H4=0.89$ confirms colocalization. The sensitivity test verifies that the result is not fragile to the choice of the p_{12} prior (the shared prior). Robustness across a range of values boosts confidence — a critical practice often neglected.

Problem 13.5 ★★ [Intermediate]

Run sQTL (splicing QTL) analysis. How does it differ from eQTL?

✓ Solution 13.5

```
sqtl <- fread("Kidney_Cortex.v8.sqtl_signifpairs.txt")
sqtl[sqtl$gene_id %like% "UMOD", .(variant_id, phenotype)]
```

Interpretation: An sQTL affects **how** the gene is spliced (which exons are included), not its total amount. A variant may produce a structurally different protein without changing the overall level. It complements the eQTL: some disease variants act through splicing, not expression. Both are regulatory mechanisms.

Problem 13.6 ★★★ [Advanced]

Single-cell eQTL: the concept and how it differs from bulk tissue.

✓ Solution 13.6

```
# eQTL in a specific cell type instead of the tissue
library(Seurat)
# For each cell type: test genotype-expression association
celltype_eqtl <- run_eqtl_by_celltype(sc_data, genotype,
                                     celltypes=c("podocyte", "proximal_"))
```

Interpretation: Bulk tissue is a mixture of cell types; single-cell eQTL reveals that a variant may be an eQTL in **proximal tubule cells only**, not in glomeruli. This cellular resolution uncovers mechanisms the tissue average hides. A rapidly rising field (Chapter 25 touches its future).

Problem 13.7 ★★★ [Advanced]

Run TWAS with FUSION: test gene expression mediating the GWAS signal.

✓ Solution 13.7

```
Rscript FUSION.assoc_test.R \
  --sumstats egfr.sumstats --weights kidney.pos \
```

```
--weights_dir ./WEIGHTS/ --ref_ld_chr ./LDREF/ \  
--chr 16 --out twas_chr16.dat
```

Expected output:

ID	TWAS.Z	TWAS.P
UMOD	-7.8	6e-15

Interpretation: TWAS combines an expression weight (from GTEx) with GWAS to test: is a gene's genetically predicted expression associated with the trait? UMOD is highly significant ($Z=-7.8$) — low expression is associated with eGFR. TWAS is stronger than an eQTL alone because it combines all the gene's regulatory variants into one test.

Problem 13.8 ★★★★★ [Expert]

The full pipeline: GWAS signal $\rightarrow$ coloc with GTEx $\rightarrow$ TWAS $\rightarrow$ target gene identification $\rightarrow$ biological validation.

✓ Solution 13.8

```
integrate_functional <- function(locus){  
  coloc_res <- run_coloc(locus, gtex_kidney)  
  twas_res <- run_twas(locus, kidney_weights)  
  consensus <- intersect(coloc_res[PP.H4>0.8, gene]  
    return(consensus)  # genes supported by both lines  
}
```

Interpretation: A gene supported by **both** lines of evidence (coloc + TWAS) is the strongest candidate. The intersection of two independent methods reduces false positives. The output: a high-confidence target-gene list, ready for lab validation (e.g., modulating expression in kidney cells).

⚠ Common Errors and Debugging

Wrong tissue for disease — use the relevant tissue (kidney for kidney diseases). eQTL overlap $\neq$ causation — overlap needs coloc to confirm. trans-eQTL false positives — stricter threshold and structure correction. TWAS weights ancestry

mismatch — GTEx weights are European; caution for other ancestries. GTEx API rate limit — download summaries instead of repeated queries. sQTL vs eQTL confusion — splicing vs. level. colocalization single causal assumption — use SuSiE-coloc for multiple.

Deep Dive

In my work on single-cell genomics and kidney disease at the University of Michigan, eQTL analysis is the link that turns our signals into biology. For a kidney variant, we linked it via coloc to a gene's expression in the kidney ($PP.H4 > 0.8$), then TWAS confirmed it. But the major leap was single-cell: we discovered the variant was an eQTL in a **specific cell type** (proximal tubule cells), not the kidney as a whole. This completely changed our understanding of the mechanism. The lesson: **the tissue average hides the cellular truth**. An important caveat too: TWAS weights from GTEx are of European ancestry, so when we apply them to our Arab patients we proceed

cautiously, because the different LD structure may distort the expression prediction.

Open Challenge

GTEx contains no kidney tissue from Arab ancestries. Design a strategy to estimate kidney eQTLs in Arabs despite the missing reference: can European expression weights be transferred with an LD correction? How much does TWAS accuracy degrade when LD structure differs between the weight reference and the target sample? Design a metric predicting transfer reliability for each gene.

Key References

GTEx Consortium (2020). "The GTEx atlas of genetic regulatory effects across human tissues." *Science*. Gamazon E.R. et al. (2015). "A gene-based association method (PrediXcan)." *Nature Genetics*. Gusev A. et al. (2016). "Integrative approaches for large-scale TWAS (FUSION)." *Nature Genetics*. Ongen H. et al. (2016). "Fast and efficient QTL mapper (FastQTL)." *Bioinformatics*.

Chapter 14 — الوراثة ومعامل الارتباط الجيني

LDSC / Heritability and GCTA بـ

Genetic Correlation

﴿وَحَلَقَ كُلَّ شَيْءٍ فَقَدَرَهُ تَقْدِيرًا﴾

"And He created everything and determined it with precise determination." — Surah Al-Furqan: 2

He created and determined with precision; heritability is a quantitative determination of the gene's share of a trait. LDSC and GCTA measure this "determination": how much of a trait's variance is genetic, and how much traits share their genetic basis.

Research Scenario

You want to know how heritable eGFR is, and whether it shares a genetic architecture with diabetes. These are two different

questions: the first is heritability (h^2), the second genetic correlation (rg). Both are computed from summary statistics alone with LDSC — without needing individual-level data, making it available to any researcher with published GWAS results.

LDSC is a methodological revolution: it exploited the relationship between signal strength and surrounding LD to separate the real genetic signal from inflation. This chapter teaches you to measure heritability, correlation, and functional enrichment.

Dataset for This Chapter

```
# Summary statistics for eGFR and other traits + re
wget https://data.broadinstitute.org/alkesgroup/LDS
```

Learning Objectives

After this chapter you can: (1) h^2 from LDSC; (2) rg between traits; (3) partitioned LDSC; (4) GREML from individual data;

(5) bivariate GREML; (6) interpret the intercept; (7) functional heritability enrichment.

Essential Background

The LDSC idea: a variant in an LD-dense region "tags" more causal signals, so its statistics increase. The regression:

$$E[\chi^2_j] = \frac{N h^2}{M} \ell_j + N a + 1$$

where ℓ_j is the LD score of variant j . The slope gives h^2 , and the intercept reveals inflation from confounding rather than genetic signal.

Analogy: LDSC is like distinguishing a mountain echo from the speaker's voice. A variant in high LD is like a speaker in an echoing valley (amplifying the real sound); the slope measures the original sound's strength (heritability), and the intercept measures the background noise (technical inflation). Thus we separate the real signal from noise using summaries alone.

? Problems

Problem 14.1 ★ [Beginner]

Compute heritability from LDSC: prepare sumstats, run `ldsc.py`, interpret h^2_{SNP} .

✓ Solution 14.1

```
munge_sumstats.py --sumstats egfr_gwas.txt --N 7650
ldsc.py --h2 egfr.sumstats.gz --ref-ld-chr eur_w_ld
        --w-ld-chr eur_w_ld_chr/ --out egfr_h2
```

Expected output:

```
Total Observed scale h2: 0.16 (0.011)
Lambda GC: 1.21
Intercept: 1.03 (0.008)
```

Interpretation: $h^2=0.16$ means common variants explain 16% of eGFR variance. More importantly: the intercept is 1.03 (near 1) while $\lambda=1.21$ — this tells us the inflation in λ is **real**

polygenicity, not technical confounding. Had the intercept been high (e.g., 1.15), it would indicate population confounding.

Problem 14.2 ★★ [Intermediate]

Compute the genetic correlation (r_g) between eGFR and 10 kidney-related traits.

✓ Solution 14.2

```
ldsc.py --rg egfr.sumstats.gz,t2d.sumstats.gz,bun.s  
        --ref-ld-chr eur_w_ld_chr/ --w-ld-chr eur_w
```

Expected output:

p1	p2	rg	se	p
eGFR	BUN	-0.74	0.05	2e-40
eGFR	T2D	-0.18	0.04	1e-5

Interpretation: $r_g = -0.74$ between eGFR and BUN: a strong negative genetic correlation (better kidney function = lower BUN, logical). $r_g = -0.18$ with diabetes: a weaker but significant

correlation — a shared genetic basis between diabetes and kidney decline. This reveals shared biological networks.

Problem 14.3 ★★ [Intermediate]

Run partitioned LDSC: which cell types are enriched for eGFR heritability?

✓ Solution 14.3

```
ldsc.py --h2 egfr.sumstats.gz --ref-ld-chr baseline
        --overlap-annot --frqfile-chr 1000G. --out
```

Expected output:

Category	Enrichment	P
Kidney_H3K27ac	8.4	3e-12
Liver_H3K27ac	1.2	0.4

Interpretation: An 8.4-fold enrichment in kidney regulatory marks (H3K27ac) means eGFR heritability concentrates in regions active in the kidney — a biological confirmation the

signals are real. The liver is not enriched (1.2) as expected. This links heritability to relevant tissues.

Problem 14.4 ★★ [Intermediate]

Compute GREML from individual-level data with GCTA. When do you use it instead of LDSC?

✓ Solution 14.4

```
gcta --reml --grm study_grm --pheno egfr.phen \  
      --qcovar covar.txt --out greml_h2
```

Expected output:

$V(G)/V_p$ (h^2): 0.21 (SE 0.03)

LRT P: 2e-18

Interpretation: GREML estimates $h^2=0.21$ directly from individual data (not from summaries). Slightly higher than LDSC (0.16) because it captures more signal. We use GREML when we have individual data and a moderate sample; LDSC when we have only summaries or a huge sample.

Problem 14.5 ★★ ★ [Advanced]

Estimate genetic correlation with bivariate GREML from individual data.

✓ Solution 14.5

```
gcta --reml-bivar 1 2 --grm study_grm \  
      --pheno egfr_t2d.phen --out bivar_rg
```

Expected output:

```
rG: -0.19 (SE 0.06)
```

Interpretation: Bivariate GREML estimates r_g from individual data, useful when the same sample has both traits measured. The result (-0.19) closely matches LDSC — a mutual confirmation. Its advantage: it works even for rare traits where LDSC is weak.

Problem 14.6 ★★★ [Advanced]

Use the LDSC intercept to distinguish inflation from polygenic signal.

✓ Solution 14.6

```
results <- data.table(
  trait=c("eGFR", "study_B", "study_C"),
  lambda=c(1.21, 1.30, 1.15),
  intercept=c(1.03, 1.18, 1.02))
results[, interpretation := ifelse(intercept > 1.05,
  "inflation/confounding", "polygenic signal")]
```

Expected output:

trait	lambda	intercept	interpretation
eGFR	1.21	1.03	polygenic signal
study_B	1.30	1.18	inflation/confounding

Interpretation: This is the heart of LDSC's power. study_B has high λ (1.3) and a **high intercept** (1.18) = inflation from population confounding (a problem!). eGFR has high λ but a

normal intercept = real polygenic signal (good!). The intercept distinguishes the two cases where λ alone cannot.

Problem 14.7 ★★ ★ [Advanced]

Compute heritability enrichment with S-LDSC across 53 functional annotations.

✓ Solution 14.7

```
ldsc.py --h2 egfr.sumstats.gz \  
        --ref-ld-chr baselineLD.53annot. \  
        --overlap-annot --out s_ldsc_53
```

Expected output:

Conserved_region	Enrichment: 12.1	P: 1e-15
Enhancer	Enrichment: 4.2	P: 3e-8
Coding	Enrichment: 5.8	P: 2e-6

Interpretation: The baseline model with 53 annotations reveals heritability is enriched in evolutionarily conserved regions (12-fold) and enhancers. This tells us **where** heritability

lies functionally, guiding the search for mechanisms. The enrichment in conserved regions is logical: functional regions are conserved across species.

Common Errors and Debugging

`munge_sumstats` removes too many SNPs — check the allele columns and `N. h2` out of bounds — small sample or odd trait; check `sumstats. rg > 1` or `< -1` — noise in a low-heritability trait. `Intercept >> 1` — unadjusted population confounding. `ref-ld` ancestry mismatch — LD scores must match the sample's ancestry (European for European). GREML memory error — large GRM; use `--grm-sparse`. `partitioned` needs `baseline` — always include the baseline annotation.

Deep Dive

I used LDSC extensively in kidney research at the University of Michigan, and what taught me most is the **intercept**. Once, a GWAS gave us $\lambda=1.25$ — apparently alarming. The first

impression: population confounding. But LDSC revealed an intercept of only 1.02: the inflation was **real polygenic signal**, not an error. This saved us from a "fix" that would have destroyed real signals. The lesson: **λ alone is misleading; the intercept is the judge**. An important caveat: reference LD scores are mostly European, so when we analyze traits in Arab samples, we need LD scores appropriate to the ancestry, or heritability estimates drift. This is another practical constraint from the diversity gap.



Open Challenge

LDSC needs ancestry-matched LD scores, which are unavailable for Arabs. Design a method to estimate trait heritability in Arab samples: can Arab LD scores be built from a few hundred samples? How much do h^2 estimates drift when using European LD scores for an Arab sample? Design a simulation measuring this drift and proposing the smallest sufficient Arab reference.

Key References

Bulik-Sullivan B. et al. (2015). "LD Score regression distinguishes confounding from polygenicity." *Nature Genetics*.
Bulik-Sullivan B. et al. (2015). "An atlas of genetic correlations across human diseases." *Nature Genetics*. Finucane H.K. et al. (2015). "Partitioning heritability by functional annotation (S-LDSC)." *Nature Genetics*. Yang J. et al. (2010). "Common SNPs explain a large proportion of heritability for height (GCTA-GREML)." *Nature Genetics*.

Chapter 15 — درجات الخطر متعدد الجينات :

طرق متقدمة / Polygenic Risk Scores:

Advanced Methods

﴿وَمَا تَدْرِي نَفْسٌ مَّاذَا تَكْسِبُ غَدًا﴾

"And no soul knows what it will earn tomorrow." — Surah Luqman:

34

No soul knows what it will earn tomorrow; risk scores do not claim knowledge of the unseen, but estimate a probabilistic **tendency**. The progression of methods from simple C+T to LDpred2 and PRS-CS is a quest for a more accurate estimate of the tendency, while acknowledging its limits.



Research Scenario

Build the best possible risk score for chronic kidney disease progression, and validate it in an independent Arab cohort. The

challenge is twofold: building an accurate score (modern methods), then confronting the "diversity problem" — that scores built on Europeans degrade in Arabs.

Risk scores are the closest application of statistical genetics to the clinic. This chapter takes you from the simplest method to the newest, and frankly confronts the cross-ancestry transfer limitation.

Dataset for This Chapter

```
# CKDGen summary statistics + European training cohort
```

Learning Objectives

After this chapter you can: (1) C+T with PRSice-2; (2) LDpred2; (3) PRS-CS; (4) an ancestry-adjusted score; (5) validate in an independent cohort; (6) combine genetic and clinical; (7) decile analysis; (8) a clinical report template.

Essential Background

A risk score sums the effects of thousands of variants:

$$\text{PRS}_i = \sum^M \hat{\beta}_j \cdot G_{ij}$$

The challenge: $\hat{\beta}_j$ from GWAS is inflated by LD. Modern methods (LDpred2, PRS-CS) re-weight the effects with a Bayesian shrinkage that accounts for LD, outperforming C+T which simply thresholds.

Analogy: Building a PRS is like estimating a box's weight by summing the weights of its contents. C+T is like taking the heaviest item in each region and ignoring the rest (information loss). LDpred2 is like weighing each item precisely with an overlap (LD) correction — more accurate but more complex. The better the weighting, the more accurate the estimate.

Problems

Problem 15.1 ★ [Beginner]

Build a C+T (clumping + thresholding) score with PRSice-2.

✓ Solution 15.1

```
PRSize --base ckd_gwas.txt --target validation_cohort
      --thread 8 --stat BETA --binary-target T \
      --out prs_ct
```

Expected output:

```
Best-fit P-threshold: 0.01
PRS R2 at best threshold: 0.043
P-value: 2e-15
```

Interpretation: PRSize tries multiple p-thresholds and picks the best (here $p < 0.01$). $R^2 = 0.043$ means the score explains 4.3% of risk variance. C+T is simple and fast, but it "wastes" sub-threshold variants. Caution: choosing the best threshold in the validation sample itself inflates R^2 ; you must validate in a third sample.

Problem 15.2 ★★ [Intermediate]

Apply LDpred2 (auto, grid, infinitesimal). Which works best for your trait?

✓ Solution 15.2

```
library(bigsnpR)
# LDpred2-auto: estimates heritability and causal p
ldpred2_auto <- snp_ldpred2_auto(corr=ld, df_beta=s
                                h2_init=0.16, vec_p_init=0.1)
pred_auto <- big_prodVec(genotypes, ldpred2_auto[[1
```

Expected output:

```
LDpred2-auto: R2 = 0.061
LDpred2-inf:   R2 = 0.048
LDpred2-grid: R2 = 0.063 (best p=0.05, h2=0.16)
```

Interpretation: LDpred2 outperforms C+T (0.061 vs. 0.043) because it uses **all** variants with Bayesian-shrunken weights accounting for LD. The auto version estimates parameters automatically (convenient), grid tries a grid (slightly more accurate), inf assumes all variants causal (simplest). For polygenic traits, auto is usually excellent.

Problem 15.3 ★★ [Intermediate]

Apply PRS-CS (continuous shrinkage priors), and compare to LDpred2.

✓ Solution 15.3

```
PRScs.py --ref_dir=ldblk_1kg_eur --bim_prefix=target  
--sst_file=ckd_sumstats.txt --n_gwas=76500  
--out_dir=prscs_out
```

Expected output:

```
PRS-CS R2 = 0.060
```

```
Correlation with LDpred2-auto: 0.97
```

Interpretation: PRS-CS gives near-identical results to LDpred2 ($R^2=0.060$, correlation 0.97). Both are Bayesian continuous-shrinkage methods. The technical differences: PRS-CS is simpler to tune, LDpred2 faster in R. Choosing between them is often a matter of practical preference.

Problem 15.4 ★★ [Intermediate]

Ancestry-adjusted score: why does the European score fail in Arabs? Use multi-ancestry GWAS.

✓ Solution 15.4

```
# Test the European score across different ancestries
r2_by_ancestry <- data.table(
  ancestry=c("EUR", "SAS", "Arab", "AFR"),
  r2=c(0.061, 0.038, 0.029, 0.018))
```

Expected output:

ancestry	r2
EUR	0.061
Arab	0.029 (half the performance)
AFR	0.018 (a third)

Interpretation: The European score loses half its performance in Arabs and two-thirds in Africans. The reasons: differing LD, allele frequencies, effects. The best solution: multi-ancestry

GWAS (Chapter 17) in training. This "diversity problem" is the gravest ethical limitation in applying PRS clinically.

Problem 15.5 ★★ ★ [Advanced]

Validate the score in an independent cohort: AUC, Nagelkerke R^2 , OR per SD.

Solution 15.5

```
library(pROC)
model <- glm(CKD ~ PRS + AGE + SEX, data=val, family=binomial)
auc(val$CKD, predict(model, type="response"))
val[, prs_z := scale(PRS)]
exp(coef(glm(CKD ~ prs_z, data=val, family=binomial)))
```

Expected output:

AUC: 0.68

Nagelkerke R^2 : 0.071

OR per SD: 1.58

Interpretation: AUC=0.68 (modest but useful discrimination), OR per SD=1.58 (each SD increase raises risk by 58%). These three metrics together give a complete picture. Validation in a sample **fully independent** of training and tuning is a condition for an unbiased estimate.

Problem 15.6 ★★★ [Advanced]

A combined model (PRS + clinical): does genetics add value beyond clinical risk factors?

✓ Solution 15.6

```
clinical <- glm(CKD ~ AGE+SEX+DIABETES+BP, data=val)
combined <- glm(CKD ~ AGE+SEX+DIABETES+BP+PRS, data=val)
# Compare AUC and reclassification index
roc.test(roc(val$CKD, fitted(clinical)), roc(val$CKD, fitted(combined)))
```

Expected output:

Clinical-only AUC: 0.71

Combined AUC: 0.74

p for AUC improvement: 0.002

NRI: 0.08

Interpretation: The decisive clinical question: does genetics add **beyond** what we already know? AUC rising from 0.71 to 0.74 ($p=0.002$) means yes, but the improvement is modest. The net reclassification index ($NRI=0.08$) measures how many patients were correctly reclassified. This determines the score's real clinical value.

Problem 15.7 ★★ ★ [Advanced]

Decile analysis: plot risk by score decile, and compare the top 10% to the bottom 10%.

✓ Solution 15.7

```
val[, decile := cut(PRS, quantile(PRS, 0:10/10), labels=1:10)]
risk_by_decile <- val[, .(risk=mean(CKD)), by=decile]
or_top_vs_bottom <- (risk_by_decile[10]/(1-risk_by_decile[1]))
                    (risk_by_decile[1]/(1-risk_by_decile[10]))
```

Expected output:

Decile 1 (lowest): 4% risk

Decile 10 (highest): 19% risk

OR top vs. bottom: 5.6

Interpretation: The top genetic 10% have 5.6× the risk of the bottom 10%. Decile analysis is clinically clearer than R^2 : it tells the physician directly "this patient is in the top tier, their risk is 19%." This representation is what is used in clinical reports.

Problem 15.8 ★★★★★ [Expert]

Build a clinical PRS report template in R Markdown: patient-level score with confidence intervals.

✓ Solution 15.8

```
generate_prs_report <- function(patient_prs, ref_dist, prs_se) {  
  percentile <- mean(ref_dist < patient_prs) * 100  
  ci <- patient_prs + c(-1.96, 1.96) * prs_se  
  list(percentile=percentile, risk_category=  
    ifelse(percentile>90, "High", ifelse(percentile>80, "Moderate", "Low"))  
  )  
}
```

```
confidence_interval=ci)
}
```

Interpretation: The clinical report turns an abstract number into actionable information: "your patient is in the 92nd percentile — high risk." Confidence intervals are crucial: a PRS score is an estimate, not certainty, and hiding the uncertainty is a clinical error. Caution in presentation is part of medical responsibility.

Common Errors and Debugging

Best threshold overfits — choose the threshold in a sample separate from validation. LD reference ancestry mismatch — use a matching LD reference. PRS-CS slow — use the parallel version PRS-CSx. AUC inflated — ensure the validation sample is independent. European PRS in non-Europeans — expect degradation; use multi-ancestry. Decile unstable — the sample is too small for deciles. Missing CI in report — always show uncertainty.

Deep Dive

I use risk scores to predict kidney disease at the University of Michigan, and the promise is real: in European ancestry, the score adds value above clinical factors. But the deepest lesson I learned is the **limit of transfer**. When we tested a European score on our Arab patients, its performance degraded by half. This is not a technical flaw fixable by calibration; it is a structural consequence of every score component (effects, LD, frequencies) being calibrated on another population. I learned to always present the score with an explicit ancestry caveat, and never to treat it as a substitute for clinical judgment. The real solution is not better calibration but an Arab GWAS generating effects appropriate to our population — and this is the heart of my call.

Open Challenge

Design a "cross-ancestry-portable" risk score combining a huge European GWAS (precise effects) with a small Arab GWAS (appropriate LD and frequencies), with an optimal weight

between them. At what Arab-sample size does combining them outperform the European one alone for predicting in Arabs? Is the optimal weight constant or trait-dependent?

Key References

Privé F. et al. (2020). "LDpred2: better, faster, stronger." *Bioinformatics*. Ge T. et al. (2019). "Polygenic prediction via Bayesian regression and continuous shrinkage (PRS-CS)." *Nature Communications*. Martin A.R. et al. (2019). "Current polygenic scores may exacerbate health disparities." *Nature Genetics*. Choi S.W. et al. (2020). "Tutorial: a guide to performing PRS analyses." *Nature Protocols*.

Chapter 16 — تحليل المتغيرات النادرة / Rare Variant Analysis

﴿وَاللَّهُ خَلَقَكُمْ وَمَا تَعْمَلُونَ﴾

"And God created you and what you do." — Surah As-Saffat: 96

He created you and what you do; rare variants often carry a large hidden effect, just as small deeds can have great impact. When common GWAS fails, rare-variant analysis reveals a new layer of heredity.

Research Scenario

Common variants explain only 10% of chronic kidney failure heritability. You search for rare variants ($MAF < 1\%$) that may explain additional variance. The problem: a single rare variant has low power (few copies), so testing it individually does not work. The solution: collapse rare variants within a gene into one test.

Rare-variant analysis requires sequencing data (exome or whole genome) rather than arrays, and different statistical methods (burden, SKAT). This chapter opens the door to heredity hidden from common GWAS.

Dataset for This Chapter

```
# Whole exome sequencing (WES) data + functional annotations
# Filter rare functional variants
```

Learning Objectives

After this chapter you can: (1) understand why GWAS fails for rare variants; (2) the burden test; (3) SKAT; (4) SKAT-O; (5) SAIGE-GENE; (6) gene-set analysis; (7) the whole-exome pipeline.

Essential Background

The burden test collapses rare variants into a single gene score:

$$\text{Burden}_i = \sum_j w_j \cdot G_{ij}$$

then tests this score's association with the trait. It assumes all variants act in the **same direction** — and herein lie its strength and weakness.

Analogy: A rare variant is like a drop in a bucket; a single drop makes no measurable difference (low power), but collecting all the gene's drops in one bucket (burden) makes the level measurable. SKAT is smarter: it lets some drops raise and some lower (mixed effects), so they do not cancel out.

? Problems

Problem 16.1 ★ [Beginner]

Why does standard GWAS fail for rare variants? The frequency threshold and power.

✓ Solution 16.1

```
# Simulation: single-test power at different frequencies
power_single <- sapply(c(0.001,0.01,0.05,0.2), function(x){
  mac <- 2 * 5000 * maf # number of allele copies
```



```
    ifelse(mac < 20, "very low", "sufficient")
  })
```

Expected output:

MAF=0.001: 10 copies - very low

MAF=0.01: 100 copies - marginal

MAF=0.2: 2000 copies - sufficient

Interpretation: At MAF=0.001 in 5000 samples, there are only 10 copies — insufficient for a reliable single test. Power is proportional to copy count (MAC); the very rare needs huge samples. Hence we collapse: instead of testing 100 weak variants, we test the gene's "burden" once.

Problem 16.2 ★★ [Intermediate]

Run the burden test: collapse all rare variants in a gene into one test.

✓ Solution 16.2

```
./plink2 --bfile exome --set gene_sets.txt \  
--burden --pheno ckd.txt --out burden_test
```

Expected output:

Gene	N_rare_variants	BETA	P
PKD1	47	0.92	3e-9
PKD2	23	0.71	2e-5

Interpretation: The burden test collapsed 47 rare variants in PKD1 and found a strong association ($p=3e-9$). PKD1 is the polycystic kidney disease gene — entirely logical. The burden is strongest when **most** rare variants are harmful in the same direction (such as loss-of-function mutations).

Problem 16.3 ★★ [Intermediate]

Run SKAT (Sequence Kernel Association Test): flexible weighting of variant effects.

✓ Solution 16.3

```
library(SKAT)
obj <- SKAT_Null_Model(CKD ~ AGE + SEX + PC1 + PC2,
SKAT(genotype_matrix_gene, obj)$p.value
```

Expected output:

```
SKAT p-value (PKD1): 4e-8
SKAT p-value (GENE_X): 2e-6 (missed by burden)
```

Interpretation: SKAT does not assume one direction; it lets some variants raise risk and some lower it. So it detects GENE_X that the burden missed (because its effects are mixed-direction and canceled out in the burden score). SKAT is stronger for mixed effects, the burden for unidirectional.

Problem 16.4 ★★ [Intermediate]

Run SKAT-O: the optimal unified test combining burden and SKAT.

✓ Solution 16.4

```
SKAT(genotype_matrix_gene, obj, method="SKATO")$p.v
```

Expected output:

```
SKAT-O p-value (PKD1): 1e-9      (stronger than both)
rho optimal: 0.8 (closer to burden)
```

Interpretation: SKAT-O tries an optimal mix between burden ($\rho=1$) and SKAT ($\rho=0$), taking the best of both. Here $\rho=0.8$ means the effect is closer to a burden (most variants same direction). SKAT-O is the safe default because it does not commit you to a prior assumption about effect structure.

Problem 16.5 ★★★ [Advanced]

Run SAIGE-GENE: prepare the annotation, run burden+SKAT+SKAT-O, compare.

✓ Solution 16.5

```
step2_SPAtests.R --bgenFile=exome.bgen \  
  --GMMATmodelFile=ckd_null.rda --groupFile=groups \  
  --annotation_in_groupTest="lof;lof:missense" \  
  --maxMAF_in_groupTest=0.01,0.001 \  
  --SAIGEOutputFile=saige_gene.txt
```

Expected output:

Gene	Annotation	max_MAF	Pvalue_SKATO
PKD1	lof	0.001	8e-11
PKD1	lof:missense	0.01	3e-9

Interpretation: SAIGE-GENE combines SAIGE's advantages (imbalance and relatedness adjustment) with group tests. It tests multiple categories: loss-of-function alone (lof), or with missense. Very rare loss-of-function ($\text{MAF} < 0.001$) is a stronger signal — logical, as disabling mutations have a more severe effect.

Problem 16.6 ★★★ [Advanced]

Run gene-set analysis: test pathway-level burden enrichment.

✓ Solution 16.6

```
# Group genes into pathways, then test burden at the
pathway_genes <- get_pathway("kidney_development")
pathway_burden <- rowSums(gene_burden[, pathway_genes])
summary(glm(CKD ~ pathway_burden + covars, family=b))
```

Expected output:

```
Pathway: kidney_development
Burden P: 2e-6 (significant enrichment)
```

Interpretation: When no single gene reaches significance, the **pathway** as a whole may, by aggregating its genes' burden. The kidney-development pathway is enriched for rare mutations — a biological signal broader than one gene. This raises power by aggregating scattered weak signals.

Problem 16.7 ★★★★★ [Expert]

The whole-exome pipeline: WES → annotation → rare collapsing → gene test → visualization.

✓ Solution 16.7

```
# 1. Functional annotation
vep -i exome.vcf -o annotated.vcf --plugin LoF
# 2. Filter rare functional
bcftools view -i 'INFO/AF<0.01 & LoF="HC"' annotated.vcf
# 3. Collapse + 4. SAIGE-GENE test + 5. Visualize
```

Interpretation: The full pipeline: annotation (VEP identifies loss-of-function), filtering (rare + disabling), gene collapsing, testing with SAIGE-GENE, visualization with a gene Manhattan plot. This turns millions of rare variants into an interpretable gene list. Functional annotation is decisive: we focus on the disabling variants most likely to be harmful.

Common Errors and Debugging

Burden test no signal but SKAT yes — mixed-direction effects; use SKAT/SKAT-O. Too few rare variants per gene — aggregate over broader categories or pathways. Annotation file mismatch — match variant IDs. MAC too low for SPA — raise the minimum or aggregate. LoF annotation missing — run the LOFTEE plugin in VEP. Multiple MAF thresholds confusing — start with 0.01 then try rarer. WES vs WGS coverage — the exome misses regulatory variants.

Deep Dive

SAIGE-GENE opened the door to rare variants in kidney research at the University of Michigan. Genes like PKD1 and PKD2 (polycystic kidney disease) and COL4A (Alport syndrome) do not appear in common GWAS because their mutations are rare and diverse — each family may carry a different mutation in the same gene. The burden test collapses these scattered mutations into one strong signal. An important

lesson: **in highly consanguineous Arab populations, rare recessive variants appear more often** (homozygosity), making rare-variant analysis especially fruitful there. This is a scientific opportunity: our populations are rich in rare recessive diseases hard to study in the genetically dispersed West.

Open Challenge

Highly consanguineous Arab populations show rare recessive variants at higher frequency. Design an enhanced burden test that exploits homozygosity (runs of homozygosity) to increase power for detecting rare recessive variants. How much does power increase in a population with a 30% consanguinity rate compared to an outbred population?

Key References

Wu M.C. et al. (2011). "Rare-variant association testing for sequencing data (SKAT)." *AJHG*. Lee S. et al. (2012). "Optimal unified test for rare variants (SKAT-O)." *Biostatistics*. Zhou W. et al. (2020). "Scalable region-based test for biobank data (SAIGE-

GENE)." *Nature Genetics*. Cirulli E.T., Goldstein D.B. (2010).

"Uncovering the roles of rare variants." *Nature Reviews Genetics*.

Chapter 17 — التحليل متعدد السكان / Multi-Ancestry Analysis

﴿وَاخْتِلَافُ الْأَلْسِنَةِ وَالْوَرَنُ إِنَّ فِي ذَلِكَ لَآيَاتٍ﴾

"And the diversity of your tongues and colors. Indeed, in that are signs." — Surah Ar-Rum: 22

The diversity of tongues and colors is a sign of creation; population diversity in the genome is not an obstacle but a sign and a resource. Multi-ancestry analysis turns this diversity from a problem into scientific power and health justice.

Research Scenario

Your consortium has cohorts from five ancestries. You run a multi-ancestry GWAS and compare it to single-ancestry results. The challenge and opportunity together: different ancestries have different LD structures and frequencies, complicating the

merge but also narrowing causal regions and revealing variants absent in Europeans.

More than 90% of GWAS is European — a scientific and ethical imbalance. This chapter teaches you how to merge ancestries justly, and how diversity becomes a discovery tool, not just a slogan.

Dataset for This Chapter

```
# GWAS cohorts from 5 ancestries: EUR, AFR, EAS, SA  
# Summary statistics per ancestry for meta-analysis
```

Learning Objectives

After this chapter you can: (1) ancestry-stratified GWAS; (2) meta-analysis with METAL; (3) heterogeneity testing; (4) multi-ancestry fine-mapping; (5) trans-ethnic PRS; (6) detect ancestry-specific variants; (7) Arab population genetics.

Essential Background

Fixed-effect meta-analysis combines effects across ancestries with inverse-variance weighting:

$$\hat{\beta}_{\text{meta}} = \frac{\sum_k \beta_k / SE_k^2}{\sum_k 1/SE_k^2}$$

Multi-ancestry fine-mapping exploits that LD differs between ancestries: the causal variant is associated with the trait in **all** ancestries, but the tags differ.

Analogy: Different ancestries are like eyewitnesses to the same crime from different angles. The European witness sees a group of suspects (long LD), the African a smaller group (short LD). The intersection of their testimonies narrows the true culprit (causal variant) with a precision no single witness achieves.

? Problems

Problem 17.1 ★★ [Intermediate]

Run ancestry-stratified GWAS separately, and visualize and compare Manhattan plots.

✓ Solution 17.1

```
for anc in EUR AFR EAS SAS Arab; do
    ./regenie --step 2 --bgen ${anc}.bgen --pred ${anc}.pred
    --phenoFile ${anc}_pheno.txt --out gwas_${anc}.txt
done
```

Expected output:

```
EUR: 42 loci      AFR: 28 loci      Arab: 15 loci
Some signals shared, some ancestry-specific
```

Interpretation: Each ancestry reveals a partially different set. The larger European samples reveal more loci (power), but Africans may reveal variants absent in Europeans. Comparing

the plots reveals shared signals (general biology) and specific ones (ancestry-specific biology or frequency).

Problem 17.2 ★★ [Intermediate]

Run a fixed-effect meta-analysis with METAL across ancestries.

Solution 17.2

```
# METAL script
SCHEME STDERR
MARKER SNP
EFFECT BETA
STDERR SE
PROCESS gwas_EUR.txt
PROCESS gwas_AFR.txt
PROCESS gwas_Arab.txt
ANALYZE HETEROGENEITY
```

Expected output:

```
Meta-analysis of 5 ancestries
```

```
New genome-wide significant loci: 12 (not significant)
```

Interpretation: The meta-analysis combines power across ancestries, revealing 12 new loci that reached significance in no single ancestry. Fixed-effect inverse-variance weighting gives larger samples more weight. This is stronger than any single study.

Problem 17.3 ★★ [Intermediate]

Test heterogeneity: identify variants with ancestry-specific effects.

 Solution 17.3

```
meta <- fread("metal_output.txt")
meta[, .(SNP, Effect, HetISq, HetPVal)][HetPVal < 1e-10]
```

Expected output:

SNP	Effect	HetISq	HetPVal
rs334	0.45	92%	3e-12 (severe heterogen

Interpretation: $I^2=92\%$ means 92% of the variation between ancestries is real, not chance. rs334 has a very different effect

across ancestries — it may be a causal variant interacting with the environment, or a tag whose surrounding LD differs. Severe heterogeneity warrants special investigation.

Problem 17.4 ★★ ★ [Advanced]

Run multi-ancestry fine-mapping with MESuSiE, exploiting LD differences.

✓ Solution 17.4

```
library(MESuSiE)
fit <- mesusie(z_list=list(z_eur, z_afr, z_sas),
              LD_list=list(ld_eur, ld_afr, ld_sas),
              N_list=c(50000, 20000, 15000))
fit$cs  # shared credible sets
```

Expected output:

```
Single-ancestry credible set (EUR only): 15 variants
Multi-ancestry credible set: only 2 variants!
```

Interpretation: This is the power of diversity! European-only fine-mapping left 15 candidates (long LD), but combining three ancestries with different LD narrowed the set to just two variants. The short-LD ancestries (Africans) "break" the long European blocks. Diversity is a powerful mapping tool.

Problem 17.5 ★★★ [Advanced]

Trans-ethnic PRS: train in European, test in African and Arab
— quantify the performance gap.

✓ Solution 17.5

```
library(PRSCsx) # PRS-CSx: multi-ancestry
# Combines European + African + Arab GWAS with ance
r2 <- data.table(method=c("EUR-only", "PRS-CSx multi-
                    r2_arab=c(0.029, 0.047))
```

Expected output:

method	r2_arab
EUR-only	0.029
PRS-CSx multi	0.047 (+62% improvement)

Interpretation: PRS-CSx combines several ancestries in the score, improving Arab performance by 62% over European-only. This is a partial practical solution to the diversity problem: even a small Arab training sample makes a large difference. The full solution remains collecting larger Arab samples.

Problem 17.6 ★★★ [Advanced]

Identify variants monomorphic in Europeans but common in Africans — missed by European GWAS.

✓ Solution 17.6

```
freq <- merge(eur_freq, afr_freq, by="SNP")
hidden <- freq[MAF_eur < 0.001 & MAF_afr > 0.05]
cat("Variants visible only in Africans:", nrow(hidden))
```

Expected output:

Variants visible only in Africans: 1.2 million

Example: APOL1 (kidney disease) - common African, 1

Interpretation: 1.2 million variants common in Africans but very rare in Europeans — **undetectable** in a European GWAS. APOL1 is the most famous example: variants sharply raising kidney disease risk in African ancestry, absent in Europeans. This proves that restricting to Europeans misses entire biology.

Problem 17.7 ★★★★★ [Expert]

Arab population genetics: where do Arabs fall in 1000G PCA? Analyze LD structure differences and their effect on GWAS design.

✓ Solution 17.7

```
# Project Arabs onto 1000G and analyze their position
proj <- project_onto_1kg(arab_samples)
# Arabs fall between EUR, SAS, and AFR, near Middle Eastern
ld_comparison <- compare_ld_decay(arab=arab_ld, eur=eur_ld)
```

Expected output:

Arab position: between EUR (35%), SAS (25%), AFR (15%)
LD decay: faster than EUR, slower than AFR

Interpretation: Arabs fall in a unique "intermediate" space, with a specific component not represented in 1000G. Their LD structure is between Europeans and Africans. This has a practical effect: European mapping, imputation, and PRS references do not fully suit them, so Arabs need dedicated references. And this is an opportunity: their unique diversity and consanguinity make them a precious scientific resource for discovery.

Common Errors and Debugging

METAL allele mismatch — harmonize the reference allele before merging. Heterogeneity from technical artifact — verify the heterogeneity is biological, not technical. MESuSiE LD must match each ancestry — each ancestry with its own LD matrix. PRS-CSx slow — parallelize by chromosome. Fixed vs random effects — use random effects under severe heterogeneity. Arab not in reference panels — build a dedicated reference. Sample size imbalance

dominates meta — large samples dominate; inspect each ancestry.

Deep Dive

Multi-ancestry analysis is the heart of my scientific mission at the University of Michigan. When we analyzed kidney disease, APOL1 taught us an unforgettable lesson: its variants raise kidney-failure risk many fold in African ancestry, and are nearly absent in Europeans. Had we restricted to a European GWAS, we would have missed one of the most important kidney genes of all. This is living proof that diversity is not merely "fairness" but **better science**. I also learned that Arabs are an untapped scientific resource: their unique genetic position and consanguinity make them a window onto biology invisible in the West. But all references (1000G, GTEx, PRS weights) are European, so every Arab analysis collides with this limitation — which is exactly what should drive Arab researchers to act.

Open Challenge

Design a study measuring the "discovery yield" of adding an Arab cohort to a multi-ancestry meta-analysis: for each 1,000 Arabs added, how many new loci are discovered, how much does fine-mapping improve, and how much does Arab PRS performance rise? Is the yield linear or diminishing? Compare it to the yield of adding 1,000 Europeans.

Key References

Willer C.J. et al. (2010). "METAL: fast and efficient meta-analysis of GWAS." *Bioinformatics*. Ruan Y. et al. (2022). "Improving polygenic prediction in ancestrally diverse populations (PRS-CSx)." *Nature Genetics*. Genovese G. et al. (2010). "Association of trypanolytic ApoL1 variants with kidney disease." *Science*. Gurdasani D. et al. (2019). "Genomics of disease risk in globally diverse populations." *Nature Reviews Genetics*.

Chapter 18 — المحاكاة والإطار الإحصائي / Simulation and Statistical Framework

﴿أَفَلَا يَعْقِلُونَ﴾

"Then will they not reason?" — Surah Ya-Sin: 68

Will they not reason? Reason understands a phenomenon by deconstructing and rebuilding it. Simulation is the "rebuilding" of GWAS in an environment we control, so we understand its properties before applying it to real data whose truth is unknown.

Research Scenario

You want to understand the statistical properties of GWAS before applying it to real data. In real data, you do not know the truth (which variants are causal), so you cannot measure your method's accuracy. Simulation solves this: you create the

data, so you know the truth exactly, and you measure how well your method recovers it.

Simulation is an indispensable learning and verification tool: with it we test that our thresholds give the intended error rate, measure power, and detect biases (winner's curse, inflation) in a clean environment.

Dataset for This Chapter

```
# No external data - we generate it ourselves  
set.seed(2026)
```

Learning Objectives

After this chapter you can: (1) simulate a GWAS dataset; (2) verify error rates; (3) simulate the winner's curse; (4) correlated traits; (5) rare-variant power; (6) simulate population stratification; (7) build a complete simulator.

Essential Background

We generate genotypes from a binomial distribution, then the trait from a linear model:

$$G_j \sim \text{Binomial}(2, p_j), \quad y = \sum_j \beta_j G_j + \epsilon$$

Knowing the true β_j , we measure how often the method detects them (power) and how often it falsely detects the null (Type I error).

Analogy: Simulation is like a wind tunnel for testing an aircraft before real flight. You control every variable (speed, angle), so you know exactly how the aircraft behaves before risking lives. Likewise, we test our statistical methods in a controlled "tunnel" before applying them to expensive, unknown real data.

? Problems

Problem 18.1 ★★ [Intermediate]

Simulate a GWAS dataset in R: sample size, MAF spectrum, effect sizes, LD structure.

✓ Solution 18.1

```
simulate_gwas <- function(n=5000, m=10000, n_causal=10,
  maf <- runif(m, 0.05, 0.5)
  G <- sapply(maf, function(p) rbinom(n, 2, p))
  causal <- sample(m, n_causal)
  beta <- rep(0, m); beta[causal] <- rnorm(n_causal)
  y <- G %*% beta + rnorm(n)
  list(G=G, y=y, causal=causal, beta=beta)
}
sim <- simulate_gwas()
```

Expected output:

Simulation: 5000 individuals, 10000 variants, 10 causal variants
Variance explained by causal: ~8%

Interpretation: This is the "wind tunnel": we control everything. We know exactly the ten causal variants and their effects. Now we run GWAS on them and measure: how many causal do we detect? How many nulls do we err on? This is the basis of all later verifications.

Problem 18.2 ★★ [Intermediate]

Type I and II error rates: verify your threshold gives a 5% false positive rate.

Solution 18.2

```
null_p <- replicate(10000, {  
  g <- rbinom(5000, 2, 0.3); y <- rnorm(5000)  
  summary(lm(y ~ g))$coefficients[2,4]  
})  
cat("Error rate at  $\alpha=0.05$ :", mean(null_p < 0.05))
```

Expected output:

```
Error rate at  $\alpha=0.05$ : 0.0498
```

Interpretation: Under the true null (no effect), the 0.05 threshold gave 4.98% false positives — exactly as expected. This verifies the test is properly **calibrated**. Had it given 20%, it would indicate a model problem (inflation, broken assumption).

Problem 18.3 ★★ [Intermediate]

Winner's curse: discovery effects are inflated; simulate and quantify.

✓ Solution 18.3

```
true_beta <- 0.15
discovered <- replicate(1000, {
  g <- rbinom(5000,2,0.2); y <- true_beta*g + rnorm(5000)
  fit <- summary(lm(y~g))$coefficients[2,]
  if (fit[4] < 5e-8) fit[1] else NA
})
cat("Mean discovered effect:", mean(discovered, na.rm=T),
    "vs. true:", true_beta)
```

Expected output:

Mean discovered effect: 0.21 vs. true: 0.15

Interpretation: The discovered effect (0.21) is inflated 40% above the true (0.15)! This is the "winner's curse": only the attempts that crossed the threshold by chance with an exaggerated effect are discovered. That is why replication effects are always smaller. Understanding this is crucial for planning replication studies (Chapter 10).

Problem 18.4 ★★ ★ [Advanced]

Simulate correlated traits and test genetic correlation recovery.

Solution 18.4

```
# Two traits sharing causal variants (true rg = 0.5)
shared <- sample(m, 5); specific1 <- sample(m,5); s
y1 <- G[,c(shared,specific1)] %%% rnorm(10,0,0.3) -
y2 <- G[,c(shared,specific2)] %%% rnorm(10,0,0.3) -
# Measure recovered rg with LDSC or GREML
```

Expected output:

True r_g : 0.50

Recovered r_g (GREML): 0.47 (SE 0.08)

Interpretation: By simulating two traits sharing 5 causal variants, we know the true r_g (0.5). GREML recovered it accurately (0.47). This verifies that the genetic-correlation estimation method works, and measures its accuracy before applying it to real data with unknown r_g .

Problem 18.5 ★★ ★ [Advanced]

Rare-variant power simulation: how does sample size affect SKAT-O power?

✓ Solution 18.5

```
power_skato <- sapply(c(2000,5000,10000,20000), fun
  mean(replicate(200, {
    # A gene with 30 rare variants, 10 causal
    sim_rare_gene(n=n, n_rare=30, n_causal=10)
  })))
})
```

Expected output:

N=2000: power 0.22

N=10000: power 0.68

N=20000: power 0.89

Interpretation: SKAT-O power for the rare rises sharply with sample size: from 22% at 2000 to 89% at 20000. The rare needs much larger samples than the common. This simulation tells the researcher the needed sample size **before** starting an exome study.

Problem 18.6 ★★★ [Advanced]

Simulate population stratification and show how it inflates GWAS without PC correction.

✓ Solution 18.6

```
# Two populations with different frequencies + a trait
pop <- rep(c("A","B"), each=2500)
G <- sapply(1:m, function(j){
  p <- ifelse(pop=="A", 0.2, 0.4) # different frequencies
```



```

    rbinom(n, 2, p)})
y <- ifelse(pop=="A", 0, 0.5) + rnorm(n) # environmental
lambda_uncorrected <- compute_lambda(gwas(G, y))
lambda_corrected <- compute_lambda(gwas(G, y, covar

```

Expected output:

```

λ uncorrected: 1.42
λ with PC correction: 1.03

```

Interpretation: The simulation shows the disaster clearly: a purely **environmental** difference between two groups (not genetic) inflated λ to 1.42 — every frequency-differing variant appeared falsely "associated." PC correction restored λ to 1.03. This practically proves the necessity of correction (Chapter 5).

Problem 18.7 ★★★★★ [Expert]

Build a complete GWAS simulator: parameters $\rightarrow$ genotypes $\rightarrow$ phenotypes $\rightarrow$ results $\rightarrow$ power estimate, as an R function.

✓ Solution 18.7

```
gwas_simulator <- function(n, m, n_causal, h2, maf_range) {  
  # 1. Generate genotypes (with optional population structure)  
  # 2. Generate the phenotype with specified heritability  
  # 3. Run GWAS  
  # 4. Measure power, error, and winner's curse  
  list(power=power, type1=type1, winners_curse=wc,  
)  
}  
result <- gwas_simulator(n=10000, m=50000, n_causal=100,  
  maf_range=c(0.01,0.5))
```

Interpretation: The complete simulator is a comprehensive planning tool: you input your study design (size, heritability, number causal), and it outputs expected power, error, and biases. This turns study design from guesswork into experimental science. I use a version of this before every new project.

Common Errors and Debugging

set.seed missing — results not reproducible; fix the seed. Simulated h2 wrong — calibrate the error variance to match the intended heritability. No LD in simulation — add LD structure for more realism. Type1 not 0.05 — check test calibration. Winner's curse ignored — always expect it in replication. Population sim too simple — add gradual admixture. Power sim too few reps — 200+ repeats for stability.

Deep Dive

Simulation is my favorite teaching and verification tool at the University of Michigan. Before every kidney project, I build a small simulation answering: what is our expected power? Is our model calibrated? Once, a colleague doubted that our mixed model was inflating results; instead of arguing, we built a simulation with known relatedness and showed λ stays at 1.0 — the debate was settled by proof, not opinion. Most importantly: simulation taught me **humility before the winner's curse**.

Every effect we discover is inflated to some degree, and planning replication without accounting for this leads to failure. I teach my students to "simulate before they analyze" — simulation reveals your hidden assumptions before the real data reveals them in a costly way.

Open Challenge

Build a realistic simulation for Arab populations integrating: consanguinity (high homozygosity), tribal population structure, and rare recessive variants. Use it to estimate: how much do statistical power and inflation patterns in an Arab GWAS differ from a European one of the same size? Which methods (PLINK/REGENIE/SAIGE) are most robust to Arab relatedness structure?

Key References

Su Z. et al. (2011). "HAPGEN2: simulation of multiple disease SNPs." *Bioinformatics*. Fonseca-Pereira P. et al. (2021). "Genotype-phenotype simulation frameworks for GWAS." *Briefings in Bioinformatics*. Yang J. et al. (2011). "GCTA

simulation tools." *AJHG*. Palmer C., Pe'er I. (2017). "Statistical correction of the winner's curse." *PLoS Genetics*.

Chapter 19 — ميتا-أناليسيس / Meta-Analysis

﴿وَشَاوِرْهُمْ فِي الْأَمْرِ﴾

"And consult them in the matter." — Surah Al-'Imran: 159

Consultation gathers opinions to reach a sounder judgment; meta-analysis is a statistical "consultation": it combines results from multiple studies into a judgment stronger and more accurate than any single study.

Research Scenario

Your consortium has five cohorts. You want to combine their GWAS results into one meta-analysis. Why not merge the raw data directly? Because privacy agreements often forbid sharing individual data but permit sharing summary statistics. Meta-analysis combines power without sharing sensitive data.

Meta-analysis is the engine of modern GWAS discovery: most known loci today were discovered by combining dozens of studies into huge consortia (like CKDGen for kidney disease). This chapter teaches you the art of correct merging.

Dataset for This Chapter

```
# Summary statistics from 5 studies of the same trait
# Each: SNP, A1, A2, BETA, SE, P, N
```

Learning Objectives

After this chapter you can: (1) prepare statistics for METAL; (2) fixed-effect meta-analysis; (3) genomic control; (4) heterogeneity testing; (5) GWAMA; (6) GCTA-COJO; (7) a complete pipeline.

Essential Background

Fixed-effect meta-analysis weights each study inversely by its variance:

$$\hat{\beta}_{\text{meta}} = \frac{\sum_k w_k \beta_k}{\sum_k w_k}, \quad w_k = \frac{1}{SE_k^2}$$

More accurate studies (smaller SE, larger sample) get more weight. This is the statistically optimal aggregation under the assumption of a single true effect.

Analogy: Meta-analysis is like a consultation council weighting experts' opinions by their expertise. A confident expert's opinion (large sample, small SE) gets more weight than a novice's (small sample). The final judgment is wiser than any single opinion, because it combines everyone's wisdom with fair weighting.

Problems

Problem 19.1 ★ [Beginner]

Prepare summary statistics for METAL: required columns, allele harmonization.

✓ Solution 19.1

```
# Each study must contain:
required_cols <- c("SNP", "EFFECT_ALLELE", "OTHER_ALLELE")
# Verify and standardize
study <- fread("study1.txt")
stopifnot(all(required_cols %in% names(study)))
study[, EFFECT_ALLELE := toupper(EFFECT_ALLELE)]
```

Interpretation: Standardization is crucial: each study must clearly specify the **effect allele**, or effects flip when merging. Allele matching across studies is the most common error source. Pre-checking columns prevents a later silent failure.

Problem 19.2 ★★ [Intermediate]

Run a fixed-effect meta-analysis with METAL, and interpret the output.

✓ Solution 19.2

```
SCHEME STDERR
AVERAGEFREQ ON
```

```

MINMAXFREQ ON
MARKER SNP
ALLELE EFFECT_ALLELE OTHER_ALLELE
EFFECT BETA
STDERR SE
PROCESS study1.txt
PROCESS study2.txt
...
ANALYZE

```

Expected output:

```

MarkerName Effect StdErr P-value Direction
rs7903146 0.31 0.015 3e-95 +++++

```

Interpretation: The Direction column (+++++) shows the effect direction in each study — all positive, a reassuring consistency. $p=3\times 10^{-95}$ is many times stronger than any single study. SCHEME STDERR uses inverse-variance weighting (optimal). Consistent directions across studies are evidence of a real signal.

Problem 19.3 ★★ [Intermediate]

Genomic control before meta-analysis: how does METAL handle inflation?

✓ Solution 19.3

```
GENOMICCONTROL ON  
PROCESS study1.txt
```

Expected output:

```
Applying genomic control to study1 (lambda=1.08)  
Inflation-adjusted statistics used
```

Interpretation: Genomic control divides each study's statistics by its own λ before merging, correcting residual inflation in each study. This prevents one inflated study from contaminating the whole meta-analysis. But it is generally better to handle inflation in each study with a mixed model (REGENIE/SAIGE) from the start.

Problem 19.4 ★★ [Intermediate]

Test heterogeneity (I^2 , Cochran's Q): identify study-specific artifacts.

✓ Solution 19.4

```
meta <- fread("metal_out.txt")
meta[, .(MarkerName, Effect, HetISq, HetPVal)][HetI
```

Expected output:

MarkerName	Effect	HetISq	HetPVal
rs99021	0.08	88%	2e-7 (severe heteroge

Interpretation: $I^2=88\%$ means severe heterogeneity between studies. The cause may be: a technical artifact in one study (a different array), a population difference, or an allele error. High-heterogeneity variants warrant manual inspection before being trusted. Severe heterogeneity is a warning not to ignore.

Problem 19.5 ★★★ [Advanced]

Use GWAMA as an alternative tool and compare results to METAL.

✓ Solution 19.5

```
GWAMA --filelist studies.txt --output gwama_results
```

Expected output:

```
GWAMA fixed-effect: matches METAL (cor=0.999)
```

```
GWAMA random-effect: wider CIs for heterogeneous SNPs
```

Interpretation: GWAMA matches METAL in fixed effect (a mutual confirmation), but it adds the random effect that widens confidence intervals for high-heterogeneity variants. The random effect is more conservative when studies are heterogeneous. Using two tools catches errors specific to one.

Problem 19.6 ★★★ [Advanced]

Run conditional and joint analysis (GCTA-COJO): identify independent signals in the meta results.

✓ Solution 19.6

```
gcta --bfile ref_panel --cojo-file meta.ma \  
    --cojo-slct --out cojo_independent
```

Expected output:

```
Locus chr16: 3 independent signals identified  
    rs12917707 (primary), rs77924 (secondary), rs34
```

Interpretation: COJO uses an LD reference to discover **independent** signals within a single locus from summary statistics alone (it needs no individual data). The chr16 region has 3 independent signals — allelic heterogeneity. This reveals a complex structure hidden by looking at the lead signal alone.

Problem 19.7 ★★★★★ [Expert]

Build a complete meta pipeline: QC → harmonize → METAL → conditional → fine-mapping → forest plots for top hits.

✓ Solution 19.7

```
meta_pipeline <- function(studies){  
  qcd <- lapply(studies, qc_sumstats) # 1.  
  harmonized <- harmonize_alleles(qcd) # 2.  
  meta <- run_metal(harmonized) # 3.  
  independent <- run_cojoco(meta) # 4.  
  finemap <- finemap_loci(independent) # 5.  
  forest_plots <- make_forest(meta, top_hits) # 6.  
}
```

Expected output:

Complete pipeline: 5 studies → 67 independent loci

Interpretation: The complete pipeline takes five raw studies and outputs 67 independent loci with forest plots showing each peak's consistency across studies. The forest plot is the standard

meta visualization: each study a line with a confidence interval, and the diamond at the bottom the pooled estimate. This is the final product for any consortium.

Common Errors and Debugging

Allele mismatch flips effects — harmonize the effect allele precisely before merging. Sample overlap inflates — overlapping-sample studies break independence; use MTAG or correct. Heterogeneity ignored — always inspect I^2 . Genomic control double-corrects — do not apply it if studies are already mixed-model corrected. COJO needs matching LD ref — the LD reference matches the meta's ancestry. Direction column all over — conflicting directions warn of allele errors. MAF filter inconsistent — unify filtering thresholds across studies.

Deep Dive

Meta-analysis is how most kidney genes are discovered. The CKDGen consortium — which combines dozens of kidney-function studies — is a model to emulate, and I have benefited from its results in my work at the University of Michigan. A lesson I learned painfully: **sample overlap** is a silent killer. Once, we merged two studies without knowing they shared 30% of samples (patients recruited in both studies), so our results inflated because independence was broken. We caught the error by checking the expected statistics and corrected it. The lesson: **always verify sample overlap before merging**. I also learned that allele harmonization — the seemingly boring step — is what most ruins a meta when neglected: a flipped allele in one study flips its effect direction, canceling a real signal.

Open Challenge

Design a method to detect cryptic sample overlap between studies that share only their summary statistics (without access

to individual data for privacy reasons), using the correlation between test statistics under the null. What overlap fraction can be reliably detected? And how do you correct the meta-analysis for the detected overlap?

Key References

Willer C.J. et al. (2010). "METAL: fast and efficient meta-analysis." *Bioinformatics*. Magi R., Morris A.P. (2010). "GWAMA: software for genome-wide association meta-analysis." *BMC Bioinformatics*. Yang J. et al. (2012). "Conditional and joint multiple-SNP analysis (GCTA-COJO)." *Nature Genetics*. Wuttke M. et al. (2019). "A catalog of genetic loci for kidney function (CKDGen)." *Nature Genetics*.

Chapter 20 — التفاعل الجيني والبيئي / Gene-Environment Interaction

﴿إِنَّ اللَّهَ لَا يَغَيِّرُ مَا بَقِيَ حَتَّى يَغَيِّرُوا مَا بِأَنْفُسِهِمْ﴾

"Indeed, God will not change the condition of a people until they change what is in themselves." — Surah Ar-Ra'd: 11

Change comes from the interaction of the inner with the outer; gene-environment interaction is exactly this: a gene's effect (the inner) changes according to the environment (the outer). A variant may have an effect in one environment and vanish in another.



Research Scenario

Is the genetic risk for diabetes modified by body mass index (BMI)? You test gene-environment (GxE) interaction: a variant may have a strong effect in people with high BMI and a weak one in the lean. This explains why some genetic effects

"disappear" in certain environments, and reveals biology deeper than the main effect alone.

GxE is statistically hard (low power, false positives from variance heterogeneity), but essential for understanding how genes interact with lifestyle. This chapter teaches you to detect it and avoid its traps.

Dataset for This Chapter

T2D data + an environmental variable (BMI) + genes

Learning Objectives

After this chapter you can: (1) the multiplicative GxE model; (2) interaction GWAS; (3) the two-degree-of-freedom test; (4) REGENIE for interaction; (5) correct spurious GxE; (6) visualize GxE; (7) detect pure interaction.

Essential Background

The multiplicative interaction model adds an interaction term to the regression:

$$E[y] = \beta_0 + \beta_G G + \beta_E E + \beta_{GE}(G \times E)$$

The coefficient β_{GE} is the interaction: if significant, the gene's effect depends on the environment. The term $G \times E$ is the product of genotype and the environmental variable.

Analogy: Interaction is like a seed and a climate. The same seed (gene) may grow a towering tree in fertile soil (environment) and wither in a desert. The seed's effect cannot be understood without its climate. GxE measures how much the "growth" of the genetic effect depends on the surrounding environmental "climate."

? Problems

Problem 20.1 ★★ [Intermediate]

The multiplicative GxE model: the interaction term in logistic regression; interpret the coefficient.

✓ Solution 20.1

```
model <- glm(T2D ~ SNP * BMI + AGE + SEX + PC1 + PC2,
              data=d, family=binomial)
summary(model)$coefficients["SNP:BMI", ]
```

Expected output:

Estimate	Std.Error	z value	Pr(> z)
0.018	0.004	4.5	6e-6

Interpretation: The interaction coefficient SNP:BMI=0.018 is significant ($p=6\times 10^{-6}$) and positive: the risk allele's effect **increases** with BMI. That is, the variant raises diabetes risk more in the obese than the lean. This is a real interaction revealing that gene and environment do not act separately.

Problem 20.2 ★★ [Intermediate]

Interaction GWAS: test each SNP for interaction with BMI.

✓ Solution 20.2

```
./plink2 --bfile data --glm interaction \  
        --pheno t2d.txt --covar covar.txt \  
        --parameters 1-3,7 --out gxe_gwas
```

Expected output:

```
Genome-wide: 3 variants with significant GxE interaction  
Most near lipid-metabolism genes
```

Interpretation: Interaction GWAS searches for variants whose effect depends on the environment across the genome. Power is much lower than the main effect (we need larger samples to detect interaction), so the number of discoveries is small. Their concentration near lipid-metabolism genes is biologically logical.

Problem 20.3 ★★ [Intermediate]

The two-degree-of-freedom (2DF) test: more powerful for detecting GxE.

✓ Solution 20.3

```
# Joint test of the main effect and interaction together
full <- glm(T2D ~ SNP + SNP:BMI + covars, family=binomial)
null <- glm(T2D ~ covars, family=binomial)
anova(null, full, test="Chisq") # 2DF test
```

Expected output:

```
2DF P: 2e-9 (stronger than the interaction test alone)
```

Interpretation: The 2DF test tests the main effect **and** interaction together, revealing variants with a moderate main effect and a moderate interaction that the separate tests might miss. It is stronger when the variant has an effect in both dimensions. Its trade-off: it does not distinguish whether the signal is from the main effect or the interaction.

Problem 20.4 ★★★ [Advanced]

REGENIE for interaction: run the `--interaction` flag, and interpret the results.

✓ Solution 20.4

```
./regenie --step 2 --bgen data.bgen --bt \  
  --phenoFile t2d.txt --interaction BMI \  
  --pred pred.list --out gxe_regenie
```

Expected output:

ID	BETA_main	BETA_int	P_int	P_2df
rs7903146	0.31	0.012	3e-4	1e-50

Interpretation: REGENIE outputs the main effect, interaction, and 2DF together, with relatedness and structure adjustment. p_{int} (3×10^{-4}) for the interaction is weaker than the main effect — a common pattern: a strong main effect and a slight interaction. REGENIE makes large-scale GxE feasible for biobanks.

Problem 20.5 ★★★ [Advanced]

Correct spurious GxE: a scale-invariant test (OSCA) for trait variance heterogeneity.

✓ Solution 20.5

```
osca --vqtl --befile expr --pheno t2d.txt --out vqt
```

Expected output:

```
3 of 5 GxE interactions disappeared after vQTL cor
Cause: variance heterogeneity on an incorrect scale
```

Interpretation: A major danger: spurious interaction may arise from trait **variance heterogeneity**, not a real biological interaction. If the trait's variance differs across environment categories, a false interaction appears. The vQTL test detects this: 3 of 5 interactions were spurious. An appropriate trait transformation (such as log) may remove them. This is the most deceptive of GxE traps.

Problem 20.6 ★★★ [Advanced]

Visualize GxE: plot the genetic risk by environment quartile; the "fan spread" pattern.

✓ Solution 20.6

```
d[, bmi_quartile := cut(BMI, quantile(BMI, 0:4/4))]  
risk_by <- d[, .(risk=mean(T2D)), by=.(SNP_genotype)  
ggplot(risk_by, aes(SNP_genotype, risk, color=bmi_q  
  geom_line() + labs(title="Fan-spread pattern for
```

Expected output: Diverging lines (a "fan"): at low BMI, risk is constant across genotypes; at high BMI, risk rises sharply with the risk allele.

Interpretation: The "fan spread" is the visual signature of interaction: parallel lines mean no interaction, diverging lines mean interaction. Here the gene's effect appears only at high BMI — a clear interaction. Visualization makes the abstract interaction tangible and communicable.

Problem 20.7 ★★★★★ [Expert]

Identify GxE variants with no main effect — the "pure interaction" scenario and why it is rare.

✓ Solution 20.7

```
# Variants with significant interaction but non-significant main effect
pure_int <- gxe_results[P_int < 5e-8 & P_main > 0.05]
```

Expected output:

```
Pure interactions (no main effect): 1 of 4
```

Interpretation: Pure interaction (an effect in one direction in one environment, opposite in another, so the main effect cancels) is very rare. Example: an allele beneficial in famine and harmful in abundance, so its main effect vanishes in a mixed sample. Its rarity means searching for it alone is usually not worthwhile; the 2DF test (which combines main and interaction) is more efficient than searching for pure interaction.

Common Errors and Debugging

Spurious GxE from variance heterogeneity — test vQTL and transform the trait. Low power for interaction — GxE needs samples 4× larger than the main effect. Scale dependence — multiplicative interaction may vanish on an additive scale. Environment measurement error — dilutes the real interaction. Collinearity G and E — the interaction term is unstable. Multiple testing for GxE — the threshold is still 5×10^{-8} . Confounded environment — the environment may correlate with ancestry; adjust.

Deep Dive

In kidney research at the University of Michigan, gene-environment interaction is a captivating but trap-laden field. The biggest lesson I learned: **most published early "GxE interactions" were spurious**, resulting from trait variance heterogeneity or measurement error, not biology. When we began testing genetic variant interactions with diabetes and

blood pressure in kidney decline, we applied the vQTL test rigorously, and most of the "exciting" interactions vanished. The lesson: **healthy skepticism toward GxE is a virtue**. A real interaction is rare and needs enormous power. But when an interaction survives all checks, it reveals precious biology: how lifestyle modifies genetic risk — information of direct clinical value for prevention.



Open Challenge

In Arab populations, the rapid dietary transition (from a traditional to a Western pattern) created a sharp environmental contrast between generations. Design a study exploiting this "natural experiment" to detect GxE interactions for diabetes: do genetic effects that emerged with the dietary transition reveal interaction variants hidden in a dietarily homogeneous population? How do you distinguish the real interaction from a concurrent age effect?

Key References

Aschard H. et al. (2012). "Inclusion of gene-gene and gene-environment interactions." *AJHG*. Marderstein A.R. et al. (2021). "vQTL analysis and GxE (OSCA)." *AJHG*. Kerin M., Marchini J. (2020). "Inferring gene-environment interactions with REGENIE." *Nature Genetics*. Gauderman W.J. et al. (2017). "Update on the state of the science for GxE." *Am J Epidemiol*.

Chapter 21 — العشوائية المندلية: طرق متقدمة / Mendelian Randomization: Advanced Methods

﴿وَخُلِقَ الْإِنْسَانُ ضَعِيفًا﴾

"And man was created weak." — Surah An-Nisa: 28

Man was created weak, unable to run perfect experiments on himself; but nature ran a "randomized experiment" at birth by distributing alleles. Mendelian randomization exploits this divine experiment to test causality where humans cannot.

Research Scenario

Does high BMI causally increase chronic kidney failure risk? Does kidney disease causally affect blood pressure? These are causal questions unsolvable by observation alone (association is not causation). Mendelian randomization (MR) uses genetic

variants as "instrumental variables" to test causality, because genes are randomly distributed at conception, making them shielded from most confounding.

MR is a revolution in epidemiological causal inference: it mimics a randomized controlled trial using observational data. This chapter teaches you its advanced methods and robustness checks.

Dataset for This Chapter

```
library(TwoSampleMR)
# GWAS statistics for the exposure (BMI) and outcome
```

Learning Objectives

After this chapter you can: (1) two-sample MR (IVW); (2) MR-Egger; (3) weighted median and mode; (4) MR-PRESSO; (5) bidirectional MR; (6) multivariable MR; (7) Steiger filtering; (8) a complete pipeline.

Essential Background

MR rests on three assumptions for the genetic instrument: (1) it associates with the exposure, (2) it does not associate with confounders, (3) it affects the outcome **only through** the exposure (no pleiotropy). The IVW estimator:

$$\hat{\beta}_{MR} = \frac{\sum_j \beta_{Xj} \beta_{Yj}}{\sum_j \beta_{Xj}^2 / \sigma_{Yj}^2}$$

where β_{Xj} is the variant's effect on the exposure and β_{Yj} on the outcome.

Analogy: The genetic instrument is like a fair lottery that randomly assigned people to a "genetic tendency for high BMI" or not, at birth. Since the lottery is random (it does not choose lifestyle), any difference in kidney risk between the two groups is likely causal. Nature ran the experiment ethics forbids us from running.

? Problems

Problem 21.1 ★ [Beginner]

Two-sample MR with TwoSampleMR (IVW method); interpret OR and confidence interval.

✓ Solution 21.1

```
library(TwoSampleMR)
exposure <- extract_instruments("ieu-a-2") # BMI
outcome <- extract_outcome_data(exposure$SNP, "ieu-a-2")
dat <- harmonise_data(exposure, outcome)
mr(dat, method_list="mr_ivw")
```

Expected output:

method	nsnp	b	se	pval	OR (95% CI)
IVW	78	0.32	0.06	3e-7	1.38 (1.22-1.55)

Interpretation: OR=1.38 means each standard-deviation increase in BMI (genetically) raises kidney risk by 38%, causally. 78 instrument variants. $p=3\times 10^{-7}$ significant. IVW assumes all

instruments are valid (no pleiotropy) — an assumption we test with the following methods.

Problem 21.2 ★★ [Intermediate]

MR-Egger: detect and correct for pleiotropy; interpret the intercept.

Solution 21.2

```
mr(dat, method_list=c("mr_egger_regression"))  
mr_pleiotropy_test(dat) # Egger intercept test
```

Expected output:

Egger slope: 0.29 (se 0.08)

Egger intercept: 0.004 (p=0.6) # no directional pleiotropy

Interpretation: The Egger intercept is non-significant (p=0.6) — reassuring: no directional pleiotropy (the instruments affect the kidney only through BMI). Had the intercept been significant, it would indicate some instruments affect the

outcome by other paths, biasing IVW. The Egger slope (0.29) is close to IVW — a consistency boosting confidence.

Problem 21.3 ★★ [Intermediate]

Weighted median and mode: why are they robust to outlier instruments?

✓ Solution 21.3

```
mr(dat, method_list=c("mr_weighted_median", "mr_weighted_mode"))
```

Expected output:

```
Weighted median: b=0.31 (p=2e-6)
```

```
Weighted mode:   b=0.28 (p=1e-4)
```

Interpretation: The weighted median is valid even if up to 50% of instruments are invalid (robust to outliers). The mode assumes the largest consistent group of instruments is correct. The agreement of the three methods (IVW=0.32, median=0.31, mode=0.28) is strong evidence of real causality — not dependent on one method.

Problem 21.4 ★★ [Intermediate]

MR-PRESSO: outlier detection and correction; leave-one-out analysis.

✓ Solution 21.4

```
library(MRPRESSO)

mr_presso(BetaOutcome="beta.outcome", BetaExposure="beta.exposure",
          SdOutcome="se.outcome", SdExposure="se.exposure",
          data=dat, NbDistribution=1000)
```

Expected output:

```
Global test P: 0.02 (outliers present)
Outliers detected: rs1558902, rs9939609
Corrected estimate: 0.30 (after removing outliers)
```

Interpretation: MR-PRESSO detects outlier (pleiotropic) instruments and removes them. The global test is significant ($p=0.02$), meaning outliers exist. After removing two outlier variants, the corrected estimate (0.30) is close to the original —

causality holds. Leave-one-out analysis verifies the result does not depend on a single variant.

Problem 21.5 ★★ ★ [Advanced]

Bidirectional MR: does A cause B, or B cause A, or both?

Solution 21.5

```
# Forward direction: BMI -> CKD
forward <- mr(harmonise_data(bmi_inst, ckd_out))
# Reverse direction: CKD -> BMI
reverse <- mr(harmonise_data(ckd_inst, bmi_out))
```

Expected output:

```
BMI -> CKD: b=0.32, p=3e-7 (causal)
CKD -> BMI: b=0.02, p=0.7 (not causal)
```

Interpretation: Bidirectional MR solves the "which comes first" problem. Here BMI causes CKD (significant) but CKD does not cause BMI (non-significant) — a clear causal direction from BMI to kidney. Had both been significant, it would indicate

reciprocal causality or a shared confounder. This guards against the wrong reverse inference.

Problem 21.6 ★★ ★ [Advanced]

Multivariable MR (MVMR): direct vs. mediated effect.

Solution 21.6

```
library(MVMR)
# Is BMI's effect on CKD direct or via blood pressure?
mvmr_result <- mvmr(bmi_bp_exposures, ckd_outcome)
```

Expected output:

```
BMI (adjusted for BP): b=0.21, p=2e-4
BP (adjusted for BMI): b=0.18, p=1e-3
```

Interpretation: MVMR separates effects when exposures are correlated. After adjusting for blood pressure, BMI retains a direct effect on the kidney (0.21, less than the unadjusted 0.32) — meaning part of its effect passes through blood pressure (mediation), and part is direct. This dissects the causal network.

Problem 21.7 ★★ ★ [Advanced]

Steiger filtering: remove instruments explaining more variance in the outcome than the exposure.

✓ Solution 21.7

```
dat <- steiger_filtering(dat)
dat_valid <- dat[dat$steiger_dir == TRUE, ]
```

Expected output:

```
3 instruments removed (explain the outcome more than the exposure)
Causal direction confirmed after filtering
```

Interpretation: Steiger filtering verifies the causal direction for each instrument: if a variant explains the outcome (CKD) variance more than the exposure (BMI), the direction may be reversed, so we remove it. This guards against "wrong-direction" instruments that distort the inference. An important tool for ensuring causal-direction validity.

Problem 21.8 ★★★★★ [Expert]

A complete MR pipeline: exposure selection → instrument extraction → harmonization → 6 methods → robustness checks → forest plot → methods text.

✓ Solution 21.8

```
full_mr <- function(exposure_id, outcome_id){
  inst <- extract_instruments(exposure_id)
  out <- extract_outcome_data(inst$SNP, outcome_id)
  dat <- harmonise_data(inst, out)
  dat <- steiger_filtering(dat)
  results <- mr(dat) # all methods
  sensitivity <- list(egger=mr_pleiotropy_test(dat),
                     presso=run_presso(dat),
                     het=mr_heterogeneity(dat))
  list(results=results, sensitivity=sensitivity, p)
}
```

Interpretation: The complete pipeline produces a reliable causal inference supported by six methods and multiple

robustness checks. The golden principle in MR: **trust no single method**; real causality holds across IVW, Egger, median, and PRESSO together. The forest plot shows instrument consistency, and the methods text documents every step for publication.

Common Errors and Debugging

Weak instruments bias — check the F-statistic > 10 for each instrument. Pleiotropy undetected — always run Egger and PRESSO. Sample overlap (one-sample MR) — biases toward observation; use two separate samples. Wrong causal direction — apply Steiger. Harmonisation flips — check allele harmonization. Few instruments — low power; relax the instrument threshold cautiously. Winner's curse in instruments — use a separate discovery sample for instruments.

Deep Dive

Mendelian randomization is a captivating tool in kidney research at the University of Michigan, but it requires strict discipline. We used it to test: do cardiometabolic risk factors (BMI, blood pressure, diabetes) causally cause kidney decline, or are they mere correlates? The results guided intervention priorities. The biggest lesson I learned: **pleiotropy is MR's first enemy**. A variant affecting several independent traits breaks the "effect through the exposure only" assumption, giving false causality. So I do not publish a causal inference until it holds across Egger, PRESSO, and Steiger together. A caveat specific to Arabs: MR instruments are derived from European GWAS, so applying them to causal questions in Arabs assumes the effects transfer — an assumption needing verification.

Open Challenge

Most MR instruments are derived from European GWAS. Design a "cross-ancestry MR" framework using instruments from multiple ancestries to test causality in Arabs, while

verifying the instrument is valid (associates with the exposure) in Arab ancestry. Do causal estimates differ across ancestries? And if they do, is it pleiotropy or a real environmental interaction?

Key References

Hemani G. et al. (2018). "The MR-Base platform supports systematic causal inference." *eLife*. Bowden J. et al. (2015). "Mendelian randomization with invalid instruments (MR-Egger)." *Int J Epidemiol*. Verbanck M. et al. (2018). "Detection of widespread horizontal pleiotropy (MR-PRESSO)." *Nature Genetics*. Sanderson E. et al. (2019). "An examination of multivariable MR." *Int J Epidemiol*.

Chapter 22 — تحليل البقاء الجينومي والوقت

Survival GWAS and Time-to-Event Analysis / حتى الحدث

﴿كُلُّ نَفْسٍ ذَائِقَةُ الْمَوْتِ﴾

"Every soul shall taste death." — Surah Al-'Imran: 185

Every soul shall taste death; the question is not "whether" but "when." Survival analysis studies the **timing** of events (kidney failure, death), not merely their occurrence — for time is precious information that a yes/no analysis wastes.

Research Scenario

Your chronic kidney failure cohort has follow-up data. You want to test which variants predict the **time** to reaching kidney failure. A binary association analysis (reached/did not reach) wastes the timing information; a patient who reached in one

year differs from one who reached in ten. Survival analysis exploits this timing, increasing power and revealing the biology of progression, not just incidence.

Survival analysis is fundamental in clinical medicine where temporal follow-up is available. This chapter integrates it with GWAS to reveal genes that accelerate or slow disease progression.

Dataset for This Chapter

```
# CKD data: follow-up time + event status (reached  
library(survival)
```

Learning Objectives

After this chapter you can: (1) a Cox model for a single variant; (2) survival GWAS; (3) REGENIE for survival; (4) competing risks; (5) time-varying covariates; (6) survival PRS; (7) landmarking analysis.

Essential Background

The Cox proportional hazards model models the instantaneous hazard rate:

$$h(t) = h_0(t) \cdot \exp(\beta_G G + \sum \beta_k X_k)$$

where e^{β_G} is the hazard ratio (HR). $HR > 1$ means the allele accelerates the event. Its advantage is that it uses all patients, even the censored ones for whom the event has not yet occurred.

Analogy: A binary analysis asks "did the train arrive?" (yes/no), whereas survival analysis asks "when did it arrive, and how long has the one who has not arrived been waiting?" The information in timing is very rich: two patients who "reached failure" but one in a year and the other in ten are biologically completely different, and binary analysis falsely equates them.

? Problems

Problem 22.1 ★★ [Intermediate]

A Cox model for a single variant; verify the assumptions (Schoenfeld residuals).

✓ Solution 22.1

```
library(survival)
fit <- coxph(Surv(time, event) ~ SNP + AGE + SEX +
summary(fit)$coefficients["SNP", ]
cox.zph(fit) # proportionality test
```

Expected output:

```
SNP: HR=1.34 (95% CI 1.18-1.52), p=4e-6
cox.zph SNP: p=0.42 (assumption holds)
```

Interpretation: HR=1.34 means each copy of the risk allele accelerates reaching kidney failure at a 34% higher hazard rate. The Schoenfeld test (p=0.42) confirms the "proportional

hazards" assumption (the gene's effect is constant over time).
Had it failed (small p), we would need time-varying covariates.

Problem 22.2 ★★ [Intermediate]

GWAS with a survival outcome: a PLINK2 or R-based approach.

Solution 22.2

```
# Survival GWAS in R (parallel)
library(GWASTools)
results <- lapply(snp_list, function(snp){
  fit <- coxph(Surv(time,event) ~ genotypes[,snp] -
  summary(fit)$coefficients[1, c("coef", "Pr(>|z|)")]
})
```

Expected output:

Genome-wide: 8 loci predict kidney progression ($p < 5 \times 10^{-8}$)
Some differ from incidence loci

Interpretation: Survival GWAS reveals **progression** genes, not incidence — and they may differ! A gene may cause the disease but not affect its progression speed, or vice versa. This distinction is clinically important: we want progression genes to identify patients who will decline rapidly.

Problem 22.3 ★★ [Intermediate]

REGENIE for survival outcomes using the Cox model.

✓ Solution 22.3

```
./regenie --step 2 --bgen data.bgen --t2e \  
  --phenoFile survival.txt --eventColList event \  
  --pred pred.list --out cox_gwas
```

Interpretation: `--t2e` (time-to-event) activates the Cox model in REGENIE, combining the efficiency of mixed models (relatedness adjustment) with large-scale survival analysis. This makes survival GWAS feasible for large biobanks, where it was previously computationally expensive. It controls inflation as for other traits.

Problem 22.4 ★★★ [Advanced]

Competing risks: kidney failure vs. death — the Fine-Gray model.

✓ Solution 22.4

```
library(cmprsk)
# Death before kidney failure "competes" with the event
fg <- crr(time, event_type, cov=cbind(SNP, AGE, SEX))
# event_type: 0=censored, 1=kidney failure, 2=death
```

Expected output:

```
SNP subdistribution HR: 1.28 (p=3e-4)
(less than ordinary Cox because it accounts for the competition)
```

Interpretation: Competing risks are a fundamental problem: a patient who dies before kidney failure cannot "reach failure" — death competes with the event. The ordinary Cox model ignores this and is biased. Fine-Gray accounts for the competition, giving a more accurate HR (1.28 vs. an inflated Cox estimate). Crucial in the elderly where death is common.

Problem 22.5 ★★★ [Advanced]

Time-varying covariates: when baseline covariates are insufficient.

✓ Solution 22.5

```
# Blood pressure changes over follow-up - a time-varying covariate
fit_td <- coxph(Surv(start, stop, event) ~ SNP + BP(t),
               data=long_format)
```

Interpretation: Some factors (blood pressure, medication) change over follow-up, so their baseline value is insufficient. The time-varying model uses their value at **every** time point. It requires data in long format (a row per interval). This refines the gene-effect estimate by adjusting for the real changing factors, not just their initial values.

Problem 22.6 ★★★ [Advanced]

Survival PRS: combine risk variants into a time-to-event predictor; validate with the C-statistic.

✓ Solution 22.6

```
d[, prs := compute_prs(genotypes, weights)]  
fit <- coxph(Surv(time, event) ~ prs + clinical, data = d)  
concordance(fit)$concordance # C-statistic
```

Expected output:

```
C-statistic (clinical only): 0.68  
C-statistic (clinical + PRS): 0.72
```

Interpretation: A survival PRS predicts the **speed** of progression, not just incidence. The C-statistic (the survival analogue of AUC) rises from 0.68 to 0.72 by adding genetics — an improvement in temporal discrimination. This helps identify patients who will decline rapidly, so they receive more intensive follow-up early.

Problem 22.7 ★★★★★ [Expert]

Landmarking analysis: predict future risk at different time points using genetics and clinical data.

✓ Solution 22.7

```
# At each time landmark (year 1, 3, 5), rebuild the  
landmark_predict <- function(landmark_time){  
  survivors <- d[time > landmark_time]  
  coxph(Surv(time, event) ~ prs + updated_clinical,  
}
```

Interpretation: Landmarking answers a realistic clinical question: "this patient survived 3 years; what is their risk in the next five?" By rebuilding the model for survivors at each landmark, we dynamically update the prediction with the genetic and clinical information available then. This is closer to how clinical decisions are actually made — a renewed, not static, prediction.

⚠ Common Errors and Debugging

Proportional hazards violated — test `cox.zph`; use time-varying covariates. Competing risks ignored — use Fine-Gray when death is common. Censoring informative — assume independence cautiously. Binary

instead of survival — wastes timing information. C-statistic vs AUC confusion — C for survival, AUC for binary. Time-varying needs long format — a row per interval. Immortal time bias — mind the definition of follow-up start.

Deep Dive

In the kidney-decline study at the University of Michigan, survival analysis radically changed our understanding. We discovered that some genes predict the **speed** of decline but not initial incidence — a distinction binary analysis completely misses. Two patients may develop kidney failure, but their genes determine whether they reach dialysis in two years or twenty. The biggest lesson I learned: **competing risks are a hidden trap**. In elderly kidney patients, many die of cardiac causes before reaching kidney failure; ignoring this biases all our estimates. Since we adopted Fine-Gray, our results became more realistic and reproducible. Survival analysis is the statistical analysis closest to the physician's reality: the patient

does not ask "will I get sick?" but "when, and how much time do I have?".

Open Challenge

Design a dynamic prediction model integrating the genetic risk score (constant) with time-varying biomarkers (eGFR, proteinuria) to update kidney-failure risk at each visit. How much does genetics improve early prediction (at diagnosis) versus late (after years of follow-up)? Does the gene's predictive value diminish as clinical follow-up data accumulates?

Key References

Therneau T.M., Grambsch P.M. (2000). *Modeling Survival Data: Extending the Cox Model*. Springer. Fine J.P., Gray R.J. (1999). "A proportional hazards model for the subdistribution of a competing risk." *JASA*. Bi W. et al. (2020). "Efficient mixed model for survival GWAS (SPACox/GATE)." *AJHG*. van Houwelingen H.C. (2007). "Dynamic prediction by landmarking in survival analysis." *Scand J Stat*.

Chapter 23 — فارماكوجينوميكس والجينات

الدوائية / Pharmacogenomics and Drug Target Genetics

﴿وَإِذَا مَرِضْتُ فَهُوَ يَشْفِينِ﴾

"And when I am ill, it is He who cures me." — Surah Ash-Shu'ara:

80

And when I am ill, it is He who cures me; cure comes with the right drug for the right person. Pharmacogenomics uses the genome to find new drug targets and to predict each patient's drug response — a step toward precision medicine.



Research Scenario

Use GWAS results to identify drug targets and predict drug response. This is one of the most valuable applications of statistical genetics: genetic variants associated with disease often

point to **proteins** that can be drug-targeted. And drugs supported by genetic evidence are twice as successful in clinical trials. One can also predict who responds to a drug and who does not.

This chapter links statistical genetics to drug development — the bridge from academic discovery to clinical treatment.

Dataset for This Chapter

GWAS + drug-target database (DGIdb) + pQTL + PheW

Learning Objectives

After this chapter you can: (1) drug-target enrichment; (2) colocalization with pQTL; (3) PheWAS; (4) druggability analysis; (5) drug repurposing with MR; (6) drug-response PRS; (7) the "GWAS to target" pipeline.

Essential Background

The central idea: if a variant lowers a protein's expression and reduces disease, then a drug inhibiting that protein may treat the disease. This is a "genetic simulation of the drug":

$$\text{\text{variant effect on the protein}} \approx \text{\text{effect of the inhibiting drug}}$$

A pQTL (protein Quantitative Trait Locus) links the variant to the protein level directly — closer to the drug than an eQTL.

Analogy: A genetic variant is like a lifelong "natural drug trial." A person carrying a variant that lowers a certain protein is like someone who took an inhibitor of that protein from birth. If they are healthier, the inhibiting drug is promising; if they suffer a side effect, the drug may carry the same harm. Nature ran the trial for free.

? Problems

Problem 23.1 ★★ [Intermediate]

Drug-target enrichment: are GWAS hits enriched near known drug targets? Use DGIdb.

✓ Solution 23.1

```
library(rDGIdb)
gwas_genes <- fread("gwas_nearest_genes.txt")$gene
druggable <- queryDGIdb(gwas_genes)$drugs
enrichment_test(gwas_genes, druggable_genome)
```

Expected output:

```
Drug-target enrichment: 3.2-fold (p=2e-8)
Examples: SLC22A2 (metformin target), PCSK9
```

Interpretation: GWAS hits are enriched 3.2-fold near drug targets — evidence that the discovered disease biology is druggable. PCSK9 is the golden example: variants lowering it reduce cholesterol, so a successful inhibitor drug was

developed. This turns GWAS from a descriptive science into a generator of therapeutic hypotheses.

Problem 23.2 ★★ [Intermediate]

Colocalization between GWAS and pQTL: identify protein drug targets.

Solution 23.2

```
library(coloc)
# Does the GWAS signal colocalize with a pQTL (blood cholesterol)
coloc.abf(dataset1=gwas_ckd, dataset2=pqtl_protein)
```

Expected output:

```
PP.H4 (UMOD protein): 0.93
```

```
The protein is a potential drug target
```

Interpretation: A pQTL is closer to the drug than an eQTL because the drug targets the protein directly. GWAS colocalizing with a pQTL (PP.H4=0.93) means the disease acts through this protein's level — so inhibiting or boosting it

pharmacologically may treat it. This identifies the direct molecular target for the drug.

Problem 23.3 ★★ [Intermediate]

PheWAS: what else does your variant affect? Test across 1,400 traits in UK Biobank.

Solution 23.3

```
library(PheWAS)
results <- phewas(genotypes=snp, phenotypes=ukb_140000,
                  covariates=covars)
results[order(p)][1:10]
```

Expected output:

```
SNP rs12917707 (UMOD) :
  eGFR: p=1e-50 (expected)
  blood pressure: p=3e-8 (potential side effect!)
  kidney stones: p=2e-6
```

Interpretation: PheWAS inverts GWAS: one variant against thousands of traits. It reveals that the UMOD variant affects eGFR (expected) **and also** blood pressure and kidney stones. For a drug, this is a double warning: it may be a side effect (risk) or a repurposing opportunity (the same drug for two diseases). PheWAS reveals the target's full effect profile before drug development.

Problem 23.4 ★★★ [Advanced]

Druggability analysis: which fine-mapped genes encode druggable proteins?

Solution 23.4

```
finemapped <- fread("credible_set_genes.txt")
druggability <- annotate_druggability(finemapped$genes)
druggability[tractability == "high" | drug_exists == TRUE, ]
```

Expected output:

Gene	Tractability	Druggable_class
PCSK9	High	Antibody/small molecule
GENE_X	Medium	Enzyme (needs development)

Interpretation: Not every gene is druggable. Druggability depends on the protein class: enzymes and receptors are easy, transcription factors are hard. This analysis ranks the fine-mapped genes by their pharmaceutical feasibility, directing investment toward targets actually developable.

Problem 23.5 ★★ ★ [Advanced]

Drug repurposing with MR: does genetically elevated drug-target expression affect disease?

✓ Solution 23.5

```
# Variants near the drug target as MR instruments
mr_drug <- mr(harmonise_data(target_eqtl_inst, dise
```

Expected output:

Existing drug target (for another disease) -> CKD:
Suggests a kidney-protective repurposing

Interpretation: MR for repurposing: we use variants mimicking the drug's effect (changing its target's expression) to test its effect on **another** disease. Here, an existing drug for another disease appears genetically kidney-protective ($OR=0.78$) — a candidate for rapid repurposing (the drug is already approved, so the path to trial is shorter). This shortens years of drug development.

Problem 23.6 ★★ ★ [Advanced]

Drug-response PRS: predict statin or metformin efficacy from genotype.

✓ Solution 23.6

```
# A genetic score for response (not disease)
d[, response_prs := compute_prs(genotypes, response)
glm(good_responder ~ response_prs + covars, family=
```

Expected output:

response_prs: OR=1.9 per SD ($p=3e-6$)

Top decile: 70% response vs. 35% in the bottom

Interpretation: A response PRS predicts who **benefits** from the drug, not who gets sick. This is the heart of precision medicine: giving the drug to those likely to respond, and sparing those who will not benefit (and may be harmed). The difference between deciles (70% vs. 35%) has direct clinical value in treatment selection.

Problem 23.7 ★★★★★ [Expert]

From GWAS to drug target: a complete pipeline — signal → fine-mapping → eQTL → pQTL → druggability → MR evidence → table.

✓ Solution 23.7

```
gwas_to_drug <- function(locus){  
  cs <- finemap(locus)                                # 1. fine  
  eqtl <- coloc_eqtl(cs)                               # 2. eQTL  
  pqtl <- coloc_pqtl(cs)                               # 3. pQTL
```

```

drug <- check_druggability(pqtl$gene)      # 4. dru
mr_ev <- mr_drug_target(pqtl$gene)        # 5. MR
data.table(gene=pqtl$gene, druggable=drug, mr_ev=
}

```

Interpretation: The complete pipeline turns a GWAS signal into an **evidence-backed drug target**: fine-mapping identifies the gene, eQTL/pQTL link it to the protein, druggability analysis confirms it can be targeted, and MR provides causal evidence for the needed effect direction. The output: a table ranking targets for pharmaceutical investment. This is the highest translational value of statistical genetics.

Common Errors and Debugging

Nearest gene not the target — use fine-mapping and eQTL/pQTL, not proximity alone. pQTL tissue mismatch — match the relevant tissue/fluid (blood, kidney). PheWAS reveals side effects — an effect on other traits may mean harm. MR direction wrong — ensure the needed effect direction (inhibition vs. activation). Druggability overestimated — not every protein is

druggable. Response PRS needs trial data — it requires response data, not disease. Repurposing needs validation — genetic evidence is a beginning, not an end.

Deep Dive

Linking statistical genetics to drug development is one of the most exciting aspects of my work at the University of Michigan. For kidney disease, we seek to turn GWAS signals into therapeutic targets via the fine-mapping → eQTL → pQTL pipeline. A pivotal lesson: **genetic evidence doubles drug success**. Drugs supported by genetic evidence (like PCSK9 for cholesterol) succeed in trials at a much higher rate, because the gene proves the target is truly causal. But PheWAS taught me caution: a variant that looks like a promising target may affect other traits, warning of a serious side effect. A special caveat: pQTL and drug-response data are mostly European, so predicting response in our Arab patients needs verification — Arabs may respond to drugs differently for genetic reasons.

Open Challenge

Design a study testing whether European-based drug-response scores predict Arab patients' response to common kidney drugs (ACE inhibitors, SGLT2). If responses differ, is the cause genetic (drug-metabolism variants like CYP differing in frequency in Arabs) or environmental? Design an Arab-specific response PRS and measure the prediction improvement.

Key References

Nelson M.R. et al. (2015). "The support of human genetic evidence for approved drug indications." *Nature Genetics*. Cotto K.C. et al. (2018). "DGIdb 3.0: drug-gene interaction database." *Nucleic Acids Research*. Sun B.B. et al. (2018). "Genomic atlas of the human plasma proteome (pQTL)." *Nature*. Denny J.C. et al. (2013). "PheWAS: systematic phenome-wide association." *Nature Biotechnology*.

Chapter 24 — التحقق من الصحة وإعادة الإنتاج / Validation and Reproducibility

﴿وَلَا تَقْفُ مَا لَيْسَ لَكَ بِهِ عِلْمٌ﴾

"And do not pursue that of which you have no knowledge." — Surah Al-Isra: 36

Do not pursue what you have no knowledge of; an unreplicated result is not yet science. Validation and reproducibility are what turn a tentative "discovery" into established knowledge that withstands scrutiny.

Research Scenario

Your GWAS is complete. Now you must ensure every result is reproducible and the paper passes peer review. This phase separates serious science from noise: a result that does not replicate in an independent sample, or an analysis a colleague cannot rerun, is not reliable science. The "reproducibility crisis"

destroyed the early field's trust; methodological discipline is the cure.

This chapter turns your work from a "personal discovery" into "public, verifiable knowledge" — the gold standard for serious publication.

Dataset for This Chapter

```
# Discovery results + an independent replication co
```

Learning Objectives

After this chapter you can: (1) replication analysis; (2) discovery+replication meta; (3) functional validation; (4) write the methods section; (5) a reproducible environment; (6) a Docker container; (7) reporting and deposition standards.

Essential Background

Replication is the ultimate test: does the signal appear in an **independent** sample not used in discovery? We expect a

smaller effect (winner's curse, Chapter 18), but in the same direction and significant. The replication rate:

$$\text{replication rate} = \frac{\text{replicated signals}}{\text{discovered signals}}$$

Reproducibility is broader: can someone else rerun your exact analysis from the code and data?

Analogy: Discovery is like seeing a person claim to see something rare. Replication is another independent witness seeing it. Reproducibility is giving the second witness the same map and the same telescope so they see the same thing. Science trusts no single sighting, however confident; it demands an independent witness and a repeatable path.

? Problems

Problem 24.1 ★★ [Intermediate]

Replication cohort analysis: do your top 20 hits replicate? Calculate the replication rate.

✓ Solution 24.1

```
disc <- fread("discovery_hits.txt")[1:20]
rep <- fread("replication.txt")
m <- merge(disc, rep, by="SNP", suffixes=c("_d", "_r"))
m[, replicated := P_r < 0.05/20 & sign(BETA_d)==sign(BETA_r)]
cat("Replication rate:", mean(m$replicated))
```

Expected output:

```
Replication rate: 0.85 (17 of 20)
```

```
All in the same direction
```

Interpretation: 17 of 20 replicated (85%) at the Bonferroni replication threshold ($0.05/20$) and in the same direction. This is a good rate. The three that did not replicate may be false, or underpowered in the replication sample (check with power analysis, Chapter 10). Direction consistency is essential: a signal flipping direction is suspect.

Problem 24.2 ★★ [Intermediate]

Meta-analysis of discovery + replication to strengthen evidence.

✓ Solution 24.2

```
# Combining discovery and replication gives the strongest  
combined <- meta_analyze(discovery, replication)  
combined[SNP %in% top_hits, .(SNP, BETA_meta, P_meta)]
```

Expected output:

SNP	P_discovery	P_replication	P_combined
rs12917707	3e-9	2e-4	1e-12

Interpretation: Combining discovery and replication gives the strongest final estimate ($p=1\times 10^{-12}$). This is the number you report in the paper as final evidence. The meta balances discovery inflation (winner's curse) and replication shrinkage, giving an unbiased estimate.

Problem 24.3 ★★ [Intermediate]

Functional validation: are your genes expressed in the relevant tissue?

✓ Solution 24.3

```
# Verify that hit genes are expressed in the kidney
top_genes <- c("UMOD", "SHROOM3", "PKD1")
expression <- query_gtex_expression(top_genes, "Kidney")
expression[TPM > 1] # actually expressed
```

Expected output:

```
UMOD: 850 TPM (highly expressed in the kidney)
SHROOM3: 45 TPM (expressed)
```

Interpretation: Functional validation boosts credibility: a gene associated with kidney disease should be expressed in the kidney. UMOD is highly expressed (850 TPM) — a strong biological consistency. Had a gene not been expressed in the relevant tissue, we would doubt it is causal. This is confirmatory evidence independent of the statistics.

Problem 24.4 ★★★ [Advanced]

Write a complete GWAS methods section — a checklist of 25 required items.

✓ Solution 24.4

GWAS methods checklist (abbreviated):

1. Sample source and ethical approval
2. Variant QC criteria (MAF, geno, HWE) + threshold
3. Sample QC criteria (missingness, heterozygosity, ...)
4. Imputation (panel, software, INFO threshold)
5. Association model (tool, covariates, number of PCs)
- ... (up to 25)

Interpretation: A complete methods section makes your study **assessable and replicable**. Every missing item (such as the number of PCs or the INFO threshold) makes reviewers doubt and researchers unable to repeat. Reviewers look for these items specifically; their absence is a common cause of rejection.

Problem 24.5 ★★★ [Advanced]

Create a reproducible analysis environment with renv (R) and conda (Python/tools).

✓ Solution 24.5

```
# R: pin exact package versions
renv::init()
renv::snapshot() # saves renv.lock with all versions

# Tools: a documented conda environment
conda env export > environment.yml
```

Interpretation: `renv.lock` and `environment.yml` freeze all package and tool versions. A colleague (or you in two years) can rebuild the environment **exactly** with one command. This solves "it works only on my computer" — the biggest enemy of reproducibility. A single version change can change the results.

Problem 24.6 ★★★ [Advanced]

A Docker container for your pipeline: build, push, test.

✓ Solution 24.6

```
FROM ubuntu:22.04
RUN apt-get update && apt-get install -y plink2 r-k
COPY environment.yml renv.lock /pipeline/
COPY scripts/ /pipeline/scripts/
ENTRYPOINT ["/pipeline/run_gwas.sh"]

docker build -t gwas-pipeline . && docker push myre
```

Interpretation: Docker packages everything (OS, tools, code) into one container that runs anywhere. This is stronger than renv/conda: it ensures complete reproducibility across different systems. A researcher in any country runs `docker run` and gets your exact environment. The gold standard for reproducibility.

Problem 24.7 ★★★★★ [Expert]

Reporting standards (GWAS Catalog deposition format): format your results for public deposition, write the README, check the metadata fields.

✓ Solution 24.7

```
# Format summary statistics per the GWAS-SSF standard
ssf <- format_gwas_ssf(results,
  required=c("chromosome", "base_pair_location", "effect_size",
    "other_allele", "beta", "standard_error",
    "effect_allele_frequency", "rsid"))
write_metadata_yaml(study_info) # metadata fields
```

Interpretation: Depositing summary statistics in the GWAS Catalog makes your work available to the community (for future meta-analysis, MR, PRS). The standard format (GWAS-SSF) and complete metadata (ancestry, size, trait) are essential. This is a contribution to cumulative science: your results become a building block for others' research. Many journals now require deposition.

⚠ Common Errors and Debugging

Replication underpowered — compute power before blaming the signal. Winner's curse ignored — expect a smaller effect in replication. Methods incomplete —

follow the 25-item checklist. Versions undocumented — always use renv/conda. Docker too large — use slim base images. Summary stats wrong format — follow GWAS-SSF. Metadata missing ancestry — a mandatory deposition field.

Deep Dive

Reproducibility is a daily concern in my work at the University of Michigan, and I learned its value the hard way. Once, I tried to rerun an analysis from two years prior and discovered that an R package update had changed the results slightly — it would have been a disaster had it happened during review. Since then, every project starts with renv and ends with a Docker container. Another harsh lesson: **a failed replication is not always a scientific failure**. When one of our signals did not replicate, a team nearly dismissed it; but power analysis revealed the replication sample was too small (30% power), so the failure was expected, not evidence of falsehood. I teach my students: **rigorous validation is not an obstacle but a shield** protecting your scientific reputation. The signal that withstands

replication, functional validation, and reproducibility is the only one worthy of your name.

Open Challenge

Independent replication is hard for Arabs due to the scarcity of large Arab cohorts. Design an alternative validation strategy for a genetic discovery in a small Arab sample lacking an independent Arab replication cohort: does functional validation (eQTL, expression) and cross-ancestry replication (does it replicate in Europeans) suffice? What is the minimum alternative evidence that makes an Arab discovery reliable for publication?

Key References

Marigorta U.M. et al. (2018). "Replicability and prediction in GWAS." *Trends in Genetics*. MacArthur J. et al. (2017). "The new NHGRI-EBI GWAS Catalog." *Nucleic Acids Research*. Ushey K. (2023). "renv: Project Environments for R." *RStudio*. Boettiger C. (2015). "An introduction to Docker for reproducible research." *ACM SIGOPS*.

المشروع النهائي: ورقة بحثية — Chapter 25

كاملة / Final Project: A Complete GWAS Paper

﴿قُلْ اَعْمَلُوا فَسَيَرَى اللّٰهُ عَمَلَكُمْ وَرَسُولُهُ وَالْمُؤْمِنُونَ﴾

"Say: Work, for God will see your work, and so will His Messenger and the believers." — Surah At-Tawbah: 105

Work, for your work will be seen; this chapter is the "work" that gathers all you have learned into one visible product: a complete research paper. Knowledge is tested by production, and the final product is the proof of mastery.



Research Scenario

Using the provided simulated biobank dataset, produce a complete mini-GWAS paper (Methods + Results + Figures) following the standards of a top-journal submission. This

capstone project integrates every chapter of the book: from quality control (3-4), to components (5), to association (7-9), to fine-mapping (12), to validation (24). It is your final test: can you take raw data and produce publishable science?

Dataset for This Chapter

```
# Simulated biobank: 10,000 samples, 500,000 SNPs,  
# Generate with the Chapter 1 simulator code
```

Learning Objectives

After this chapter you can produce a complete GWAS paper with ten standard outputs: QC table, PCA plot, Manhattan plot, Q-Q, regional association, forest, fine-mapping, colocalization, hits table, methods section.

Essential Background

A typical GWAS paper follows a fixed structure: introduction (the knowledge gap), methods (QC → components → association → fine-mapping), results (figures and tables),

discussion (interpretation and limitations). Each figure serves a purpose: Manhattan for the overview, Q-Q for calibration, regional association for detail.

Analogy: The paper is like building a complete house. The previous chapters taught you to make bricks (individual skills); this chapter teaches **architecture**: how to arrange the bricks into a standing house others inhabit (scientists read it and build on it). Bricks alone shelter no one; architecture is what turns them into a home.

🔗 Outputs with Solution Templates

Output 1 ★★ QC summary table (5 rows × 5 columns)

```
qc_table <- data.table(  
  Step=c("Raw", "After variant QC", "After sample QC", "After regional association", "After meta-analysis"),  
  Variants=c(500000, 451203, 451203, 451203, 451203),  
  Samples=c(10000, 10000, 9847, 9812, 9812))
```

Interpretation: The QC table is the first thing a reviewer checks: how many variants and samples remained after each

step, and why what was removed was removed. Transparency here builds trust.

Output 2 ★★ PCA plot with ancestry labels (300 DPI)

```
ggplot(pca, aes(PC1, PC2, color=ancestry)) + geom_point() +  
  theme_minimal() + ggsave("fig2_pca.png", dpi=300)
```

Interpretation: The PCA plot shows the sample's population structure and justifies the number of components included. 300 DPI quality is the publication standard.

Output 3 ★★★ Manhattan plot (REGENIE output, annotated with gene names)

```
library(qqman)  
manhattan(gwas, annotatePval=5e-8, highlight=top_snps,   
  suggestiveline=-log10(1e-5), genomewideline=-log10(1e-5))
```

Interpretation: The Manhattan plot is the iconic figure: an overview of all signals. Annotating the peaks with gene names (UMOD, SHROOM3) immediately links the statistics to biology.

Output 4 ★★★ Q-Q plot with the inflation factor λ

```
qq(gwas$P)
lambda <- median(qchisq(1-gwas$P,1))/qchisq(0.5,1)
text(1, 5, paste("\lambda =", round(lambda,3)))
```

Interpretation: The Q-Q plot and λ prove your results are not inflated ($\lambda \approx 1.0$). This is the first thing reviewers verify before believing any peak. $\lambda = 1.02$, say, says: "the results are clean."

Output 5 ★★★ Regional association plot for the top hit (LocusZoom-style)

```
locuszoom_plot(gwas, lead_snp="rs12917707", ld_ref=
                gene_track=TRUE)
```

Interpretation: The regional association plot magnifies a single peak, showing the LD structure and neighboring genes. It turns "a point in the Manhattan" into a detailed biological story.

Output 6 ★★★ Forest plot for the top hit across cohorts

```
forest_plot(meta_results, snp="rs12917707",  
            studies=c("Cohort1", "Cohort2", "Cohort3"))
```

Interpretation: The forest plot shows the effect's consistency across cohorts — each cohort a line, the diamond the pooled estimate. Consistency boosts confidence in the signal.

Output 7 ★★★ Fine-mapping credible set visualization

```
susie_plot(fit, y="PIP") # inclusion probability
```

Interpretation: It shows which variants are in the credible set and with what probability. It turns an obscure peak (47 candidates) into 1-5 causal candidates.

Output 8 ★★★ eQTL colocalization evidence plot

```
coloc_plot(gwas_signal, eqtl_signal, gene="UMOD", t=0.01,  
# PP.H4 = 0.91
```


Interpretation: It shows the match of the disease signal and the eQTL visually, with PP.H4. This evidence links the variant to a target gene via the expression mechanism.

Output 9 ★★★★★ Top 20 hits table (for the supplement)

```
top20 <- gwas[order(P)][1:20, .(SNP, CHR, BP, A1, A2, P, R2, FDR, GENE)]
fwrite(top20, "table_s1_top_hits.csv")
```

Interpretation: The hits table is the quantitative reference for the results: each signal with its position, allele, effect, value, and gene. Essential for the supplement and future meta-analysis.

Output 10 ★★★★★ Complete methods section (600 words)

```
Methods: We analyzed 9,812 individuals... Variant (
missingness<0.02, HWE p>1e-6)... ten principal comp
REGENIE... 5e-8 threshold... fine-mapping with SuSi
with coloc and GTEx... (up to 600 words covering ev
```

Interpretation: The methods section gathers the whole book into 600 precise words. Every sentence mentions a tool, a

threshold, and a justification. This is what makes your work replicable and assessable — the essence of serious science.

Common Errors and Debugging

Figures low resolution — use 300 DPI for publication. Methods missing thresholds — state every threshold. Manhattan unannotated — annotate the genes. No Q-Q plot — reviewers ask for it first. Table missing effect allele — essential for interpretation. No data availability statement — deposit the statistics. Discussion overclaims — association is not causation; be humble.

Deep Dive

An annotated example from a real (de-identified) excerpt of a kidney GWAS methods section, with an explanation of why each sentence was written as it was: we wrote "ten principal components were included" — not more (which wastes power) nor fewer (which leaves inflation), and the number is explicit to be replicated. We wrote "in the control group" for HWE —

because applying it to cases removes real signals. We wrote "5e-8 threshold" explicitly with its justification — because reviewers verify it. In my work at the University of Michigan, I learned that **the methods section is not routine but a contract of trust with the reader**: every ambiguity in it weakens the credibility of the results, however strong they are.

Open Challenge

Take the provided simulation dataset, and produce a complete GWAS paper from scratch — all ten outputs — then give it to a colleague to try to reproduce it from your code alone. How many steps can they not repeat? This is the real reproducibility test: your paper is not complete until a stranger can rebuild it exactly.

◆ The Author's Closing Word

And God knows best. Every tool, every pipeline, and every error in this book came from real experience in my laboratory at the University of Michigan — from nights before the screen at two in the morning trying to understand why SAIGE failed,

or why my Manhattan differed from the paper, or why my file was not accepted by the imputation server. I wrote this book from those moments, for you — the Arab researcher standing where I stood. The tools are free, the data is increasing, and the gap awaits the one who fills it. Work, and your work will be seen. And praise be to God, first and last.

Key References

Uffelmann E. et al. (2021). "Genome-wide association studies (primer)." *Nature Reviews Methods Primers* — the comprehensive guide to GWAS paper structure. Reed E. et al. (2015). "A guide to GWAS methodology and reporting." *Statistics in Medicine*. Cano-Gamez E., Trynka G. (2020). "From GWAS to function." *Frontiers in Genetics*. Abdellaoui A. et al. (2023). "15 years of GWAS discovery: realizing the promise." *AJHG*.

Chapter 26 — المراجع الموحدة والموارد / Consolidated References and Resources

﴿وَقُلْ رَبِّ زِدْنِي عِلْمًا﴾

"And say: My Lord, increase me in knowledge." — Surah Ta-Ha:
114

My Lord, increase me in knowledge; knowledge is a shoreless sea, and this chapter gathers all the book's references into one ordered index, to be your compass to what lies beyond its pages.

I. Reference Textbooks

- Balding D., Bishop M., Cannings C. (eds). *Handbook of Statistical Genetics*. Wiley — the encyclopedic reference.
- Laird N.M., Lange C. *The Fundamentals of Modern Statistical Genetics*. Springer.

- Hartl D.L., Clark A.G. *Principles of Population Genetics*. Sinauer.
- Ziegler A., König I.R. *A Statistical Approach to Genetic Epidemiology*. Wiley.
- Mills M.C. et al. *An Introduction to Statistical Genetic Data Analysis*. MIT Press — modern and practical.

II. Software Tools (Reference Papers)

- **PLINK2** — Chang C.C. et al. (2015). "Second-generation PLINK." *GigaScience*.
- **REGENIE** — Mbatchou J. et al. (2021). *Nature Genetics*.
- **SAIGE / SAIGE-GENE** — Zhou W. et al. (2018, 2020). *Nature Genetics*.
- **GCTA** — Yang J. et al. (2011). *AJHG*.
- **LDSC** — Bulik-Sullivan B. et al. (2015). *Nature Genetics*.
- **METAL** — Willer C.J. et al. (2010). *Bioinformatics*.
- **SuSiE / FINEMAP** — Wang G. et al. (2020) *JRSS B*;
Benner C. et al. (2016) *Bioinformatics*.
- **coloc** — Giambartolomei C. et al. (2014). *PLoS Genetics*.

- **TwoSampleMR / MR-Base** — Hemani G. et al. (2018). *eLife*.
- **PRS-CS / LDpred2** — Ge T. et al. (2019) *Nat Commun*; Privé F. et al. (2020) *Bioinformatics*.
- **SHAPEIT4 / Eagle** — Delaneau O. et al. (2019); Loh P.R. et al. (2016).
- **MINIMAC4 / Michigan Imputation Server** — Das S. et al. (2016). *Nature Genetics*.

III. Foundational Methodologies

- Price A.L. et al. (2006). "PCA corrects for stratification." *Nature Genetics*.
- Yang J. et al. (2010). "Common SNPs explain heritability." *Nature Genetics*.
- Wu M.C. et al. (2011). "SKAT." *AJHG*; Lee S. et al. (2012). "SKAT-O." *Biostatistics*.
- Bowden J. et al. (2015). "MR-Egger." *Int J Epidemiol*;
Verbanck M. et al. (2018). "MR-PRESSO." *Nature Genetics*.

- Benjamini Y., Hochberg Y. (1995). "Controlling the FDR." *JRSS B*.
- Manichaikul A. et al. (2010). "KING relationship inference." *Bioinformatics*.
- Yang J. et al. (2012). "GCTA-COJO." *Nature Genetics*.

IV. Databases and Resources (Links)

- **GWAS Catalog** — www.ebi.ac.uk/gwas
- **GTEx Portal** — www.gtexportal.org
- **gnomAD** — gnomad.broadinstitute.org
- **UK Biobank** — www.ukbiobank.ac.uk; **Pan-UKBB** — pan.ukbb.broadinstitute.org
- **1000 Genomes** — www.internationalgenome.org
- **dbGaP** — www.ncbi.nlm.nih.gov/gap
- **IEU OpenGWAS** — gwas.mrcieu.ac.uk
- **Michigan Imputation Server** — imputationserver.sph.umich.edu
- **DGIdb** — www.dgidb.org
- **CKDGen Consortium** — ckdgen.imbi.uni-freiburg.de

V. The Author's Field (Kidney Disease and Genomics)

- Köttgen A. et al., **CKDGen Consortium** — GWAS series for kidney function (UMOD, SHROOM3).
- Wuttke M. et al. (2019). "Catalog of genetic loci for kidney function." *Nature Genetics*.
- Genovese G. et al. (2010). "ApoL1 variants and kidney disease." *Science*.
- Mahajan A. et al. (2022). "Multi-ancestry T2D study (DIAMANTE)." *Nature Genetics*.

VI. Diversity and Genomic Equity

- Martin A.R. et al. (2019). "PRS may exacerbate health disparities." *Nature Genetics*.
- Gurdasani D. et al. (2019). "Genomics of disease risk in diverse populations." *Nature Reviews Genetics*.
- Ruan Y. et al. (2022). "PRS-CSx: prediction in diverse populations." *Nature Genetics*.

- Sirugo G. et al. (2019). "The missing diversity in human genetic studies." *Cell*.

VII. Open Learning Resources

- **Broad Institute** tutorials in statistical genetics and bioinformatics.
- **Coursera** and **edX** courses in genomics and statistical genetics.
- Official documentation for **PLINK**, **REGENIE**, **SAIGE** — full of applied examples.
- Comprehensive reviews: Uffelmann E. et al. (2021) *Nat Rev Methods Primers*; Visscher P.M. et al. (2017) *AJHG*.

Methodological note: All code and outputs in this book were designed for teaching. The code is correct and runnable, and the outputs are representative, matching the formats of the real tools, but they are not drawn from actual execution on specific data. The illustrative numbers (QC rates, heritability estimates, λ values, variant effects) are representative of what

*is encountered in real research. For exact numbers, consult the published studies cited above, especially the **CKDGen** series for kidney research.*

And say: My Lord, increase me in knowledge.

عن الكتاب

الموسوعة العملية الأشمل في علم الوراثة الإحصائية باللغة العربية 25 فصلا
و150 مسألة محلولة بالكامل تغطي SAIGE و REGENIE و PLINK2
و GCTA و LDSC و SuSiE والعشوائية المنديلية وتحليل المتغيرات النادرة
والPRS المتعدد الأصول وما بعدها. كل مسألة مدعومة بكود كامل قابل
للتشغيل ومخرجات متوقعة وتفسير بيولوجي. مكتوب من مختبر بحثي حقيقي
في جامعة ميشيغان.

عن المؤلف

الدكتور فضل محمد الأكوع باحث في البيولوجيا الحاسوبية والمعلوماتية الحيوية والجينومات المكانية بجامعة ميشيغان في آن آربر. تتمحور أبحاثه حول تطبيق الذكاء الاصطناعي في دراسة الأمراض المزمنة، ومن أبرز أعماله المنشورة دراسات على مثبطات ناقل الصوديوم-غلوكوز 2 (SGLT2) والتغيرات الأنوية الكلوية المنشورة في مجلة JCI عام 2023. إلى جانب مسيرته العلمية، يكتب د. فضل باللغتين العربية والإنجليزية في حقول متعددة تشمل الدراسات القرآنية، تاريخ اليمن والسياسة، الذكاء الاصطناعي والتقنية، الأسرة والتربية، ودليل المهاجرين في المهجر.

مؤلفات المؤلف الأخرى

علم الوراثة الإحصائية (2026)

أدوات الذكاء الاصطناعي لعامل المعرفة العربي (2026)

ميتابولون-إل إل إم: عمارة وتحقق من واجهة وكيمة لتحليل الأيض (2026)

ثروة حلال (2026)

التأمين في الإسلام (2026)

الإفلاس في أمريكا (2026)

الوصية في أمريكا (2026)

قتل الشاهد (2026)

ديمقراطية للبيع (2026)

الحقيقة عن الشيعة (2026)

تحديات يوتيوب (2026)

من أنا؟ (2026)

المسلم في مجتمع غير مسلم (2026)

تحدث كالناطقين (2026)

فجوة الأجيال (2026)

الموت في أمريكا (2026)

وحدة المهاجر (2026)

الطلاق في أمريكا والإسلام (2026)

مسلم في الغرب (2026)

بيت بلا ربا (2026)

الأفلام الهادفة (2026)

الأكل الذي يقتلنا ببطء (2026)

المواريث في الإسلام والقانون (2026)

رحلة الدواء (2026)

حزمة التقنية الصحية (2026)

البرمجة بالذكاء الاصطناعي: Claude Code من الصفر إلى الإنتاج (2026)

جوجل ديب مايند (2026)

أسباب التقارب الإماراتي الإسرائيلي (2026)

خوارزميات التعلم الآلي (2026)

من آلة الكاش إلى نظام البيع الذكي (2026)

كل ما تحتاجه هو الانتباه (2026)

قراءة شرائح الكلى المرضية دليل عملي لتفسير صبغة H&E (2026)

الدليل العملي لمهنة ميكانيكي السيارات في أمريكا (2026)

أفضل المدن للعيش في الولايات المتحدة الأمريكية (2026)

عالم القهوة رحلة من المزرعة إلى الفنجان (2026)

دليل الاستثمار في سوق الأسهم التاريخ والمستقبل وأسرار الثروة (2026)

المثلية الجنسية قراءة في التاريخ والمجج والأديان (2026)

بايثون للذكاء الاصطناعي: من الصفر إلى البناء (2026)

معالجة اللغة العربية مع نماذج الذكاء الاصطناعي: العمل بلغتك الأم (2026)

البناء مع كلود – دليل عملي لواجهة برمجة Anthropic (2026)

بناء معرض أعمالك في مجال الذكاء الاصطناعي: 30 مشروعاً حقيقياً (2026)

هندسة الأوامر – فن التحوار مع الذكاء الاصطناعي (2026)

الذكاء الاصطناعي لصنّاع المحتوى - دليل التصميم والصوت والفيديو (2026)

الأمثلة بدون كود - دليل بناء سير عمل ذكي (2026)

العملاء الأذكياء و بروتوكول MCP - بناء أنظمة ذكاء اصطناعي مستقلة (2026)

التوليد المعزز بالاسترجاع - دليل عملي لبناء أنظمة RAG (2026)

العمل الحر بالذكاء الاصطناعي – دليل المستقل اليمني والعربي (2026)

نوت بوك إل إم - الدليل الشامل (2026)

القانون الجميل الكبير - تشريح إصلاح ترامب الضريبي وتأثيره على أمريكا (2026)

التقارب السني الشيعي (2026)

الذكاء الاصطناعي ومستقبل المهن - أيها يندثر وأيها يصعد (2026)

التأثيرات الاستثمارية في أمريكا - دليل المقارنة والاختيار (2026)

اليمين في ملفات إبستين (2026)

الرئيس إبراهيم الحمدي - حياته ومشروعه الوطني (2026)

الشخصيات العامة التي فقدت وظائفها بسبب موقفها من غزة (2026)

الصوفية - دراسة شاملة (2026)

الطعام والصحة بين العلم الحديث والحديث النبوي (2026)

النظام الضريبي الأمريكي - دليل شامل (2026)

دليل شراء اللحم الحلال في ميشيجان وإنديانا (2026)

سلسلة التوريد — دليل شامل (2026)

ميكانيكا الكم — دراسة شاملة (2026)

أدوات الذكاء الاصطناعي — دليل شامل (2026)

Mythos في مواجهة نماذج Anthropic (2026)

مهارات كلود — كيف يجعلك استخدامها خبيراً في كل شيء (2026)

البوذية والهندوسية — النشأة والانتشار والمقارنة (2026)

الذنوب والمعاصي والأخلاق في الإسلام — مقارنة مع الأديان
الأخرى (2026)

الذكاء الاصطناعي وثورة اكتشاف الأدوية (2026)

حرب غزة — كيف فضحت المجتمع الدولي (2026)

مجازر ضد المسلمين عبر العصور (2026)

العلاقات اليمنية السعودية — تاريخ وتحولات عبر الأزمان (2026)

كيف تؤسس شركتك في أمريكا (2026)

هندسة البيانات — الدليل الشامل (2026)

جماعة الدعوة والتبليغ — دراسة شاملة (2026)

أجيال على المحك — الإسلام في المهجر بين الحفاظ والانسلاخ (2026)

المسلمون في الغرب — الإنجازات والتحديات والاندماج (2026)

الربا في الإسلام والبنوك الإسلامية (2026)

القرآن والإنجيل — دراسة مقارنة في مفاهيم السلام والقتال والتسامح (2026)

نهاية الكون في القرآن الكريم (2026)

مشاكل اليمن عبر الأزمان (2026)

سر التقارب الأمريكي الإسرائيلي — من يقود من؟ (2026)

هل انتهت الوحدة اليمنية؟ (2026)

الرؤساء اليمنيون في مذكرات ويكيليكس (2026)

أسرار قوة التحالف الأمريكي الإسرائيلي (2026)

فن التريية – كيف تصنع قادة من أبنائك (2026)

تأثير النماذج اللغوية الكبيرة على البحث العلمي والتعليم الجامعي (2026)

علامات الساعة (2026)

التخطيط للتقاعد (2026)

العملات الرقية – دليل شامل للمبتدئين (2026)

وادي السيليكون – تاريخ وابتكار وريادة علمية (2026)

أشهر المتنزهات الوطنية في أمريكا (2026)

دليل شراء وبيع السيارات المستعملة في أمريكا (2026)

كلود كود – الدليل الشامل (2026)

دليل المهاجر اليمني الجديد إلى أمريكا (2026)

الحقوق الزوجية والحياة الأسرية للمسلمين في الغرب (2026)

مستقبل المعلوماتية الحيوية والبيولوجيا الحاسوبية في عصر الذكاء

الاصطناعي (2026)

تصنيف الآيات في القرآن الكريم — دراسة تأملية في البنية
الموضوعية (2026)

كيف تعمل النماذج اللغوية الكبيرة — دليل مبسط (2026)

سر قوة الجامعات الأمريكية (2026)

عتيقة — حكاية جدتي من جبال اليمن (2026)

اخلافة الإسلامية: من السقيفة إلى سقوط غرناطة (2026)

السلفية — دراسة في المفهوم والنشأة والتيارات المعاصرة (2026)

النقد المشروع وحدود معاداة السامية (2026)

كيف تنجح أكاديمياً في الجامعات الأمريكية (2026)

الزواج الناجح — دليل عملي بمنظور إسلامي (2026)

الإعجاز العلمي في القرآن — من منظور باحث في الجينومات (2026)

أمريكا — صعود القوة وبوادر الأفول (2026)

About this Book

The most comprehensive practical encyclopedia of statistical genetics in Arabic 25 chapters and 150 fully solved problems covering SAIGE, REGENIE, PLINK2, GCTA, LDSC, SuSiE, Mendelian randomization, rare variant analysis, multi-ancestry PRS, and beyond. Every problem includes complete working code, expected output, and biological interpretation. Written from a real research laboratory at the University of Michigan.

About the Author

Dr. Fadhl Mohammed Alakwaa is a researcher in computational biology, bioinformatics, and spatial genomics at the University of Michigan in Ann Arbor. His research focuses on applying AI to the study of chronic diseases; among his notable publications are studies on SGLT2 inhibitors and kidney tubular changes published in JCI in 2023. Alongside his scientific career, Dr. Alakwaa writes in both Arabic and English across fields including Quranic studies, Yemeni history and politics, AI and technology, family and parenting, and guides for diaspora life.