

علم الوراثة الإحصائية

دليل المبتدئ والمتوسط من الجينوم إلى GWAS وما بعدها

Statistical Genetics

د. فضل محمد الأكوع

Dr. Fadhl Mohammed Alakwaa

2026

عربي · English

علم الوراثة الإحصائية

Statistical Genetics

دليل المبتدئ والمتوسط من الجينوم إلى GWAS وما بعدها

د. فضل محمد الأكوع

Dr. Fadhl Mohammed Alakwaa

الطبعة الأولى — 2026 · First Edition

جميع الحقوق محفوظة للمؤلف

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

إهداء

إلى كل طالب دكتوراه وقف أمام مخطط مناهاتن أول مرة ولم يفهم ما يعنيه وإلى كل باحث عربي يريد أن يقرأ أوراق الجينوم بثقة وإتقان. هذا الكتاب كتب من المختبر لا من الكتب المدرسية.

تنبيه

هذا الكتاب أُنتج بمساعدة نموذج Claude Opus 4.7 من شركة Anthropic، تحت إشراف وتوجيه المؤلف. التوجيه الفكري واختيار الموضوع والمراجعة والمسؤولية النهائية للمؤلف الدكتور فضل محمد الأكوع. الكتاب لأغراض تثقيفية وإثرائية، ولا يُغني عن استشارة المتخصصين في الموضوعات القانونية والطبية والمالية والشرعية.

Notice

This book was produced with the assistance of Anthropic's Claude Opus 4.7 model, under the author's direction and supervision. Intellectual direction, topic selection, review, and final responsibility rest with the author, Dr. Fadhl Mohammed Alakwaa. The book is for educational purposes and does not substitute for consultation with specialists in legal, medical, financial, or religious matters.

المحتويات

- 1 الفصل الأول: ما هو علم الوراثة الإحصائية؟
- 2 الفصل الثاني: المفاهيم الجينية الأساسية للمبتدئين
- 3 الفصل الثالث: توازن هاردي-واينبرغ: القانون الأساسي
- 4 الفصل الرابع: عدم التوازن الترابطي: اللغة السرية للجينوم
- 5 الفصل الخامس: دراسات الارتباط على مستوى الجينوم (GWAS)
- 6 الفصل السادس: تصحيح الاختبارات المتعددة: مشكلة عشرة ملايين اختبار
- 7 الفصل السابع: معامل الوراثة: كم الجيني يحدّد الصفة؟
- 8 الفصل الثامن: درجات الخطر متعدّد الجينات: التنبؤ بالمرض من آلاف المتغيّرات
- 9 الفصل التاسع: الهابلوتايب والفازينج: قراءة نسخيّ الجينوم

10	الفصل العاشر: التحكم في الخلط: السكّان والعوامل المربكة
11	الفصل الحادي عشر: تفسير النتائج: من الارتباط إلى الوظيفة
12	الفصل الثاني عشر: الخاتمة: الأدوات والموارد والطريق إلى الأمام
13	الفصل الثالث عشر: المراجع والقراءات الموصى بها

الفصل الأول: ما هو علم الوراثة الإحصائية؟

﴿وَعَلَّمَ آدَمَ الْأَسْمَاءَ كُلَّهَا﴾

— سورة البقرة: ٣١

عَلَّمَ اللَّهُ آدَمَ الْأَسْمَاءَ كُلَّهَا؛ فكانت أولُ منحةٍ للإنسان هي القدرةُ على التسمية والتصنيف والمعرفة. وعلمُ الوراثة الإحصائية، في جوهره، هو امتدادٌ لهذه المنحة: محاولةُ الإنسان أن يقرأ "الأسماء" المكتوبة في جينومه، وأن يربط كلَّ حرفٍ من حروف الحمض النووي بما يعنيه في الصحة والمرض والصفة. هذا الفصل يضع بين يديك السؤالَ المركزي الذي يدور حوله الكتابُ كله، ويرسم لك خريطة الطريق.

السؤال المركزي

تخيّل أنّ لديك مليونَ شخص، نصفهم مصابٌ بمرض السكرى من النوع الثاني والنصف الآخر سليم. السؤال الذي يطرحه عالمُ الوراثة الإحصائية بسيطٌ في صياغته، عميقٌ في تبعاته: أيُّ المتغيّرات الجينية يجعل صاحبه أكثرَ عرضةً للمرض؟ بكلماتٍ أخرى: من بين ثلاثة مليارات حرفٍ في الجينوم، أيُّ الحروف

إذا تبدّل ارتبط بزيادة خطر المرض؟ هذا هو لبّ المجال: إيجاد المتغيّرات الجينية التي تؤثر في المرض والصفات والبيولوجيا، باستخدام أدوات الإحصاء.

تحدي المقياس

ما يجعل هذا السؤال صعباً ليس غموضه، بل حجمه. الجينوم البشري يتكوّن من نحو ٣ مليارات زوج قاعديّ (base pairs). ومن بين هذه المليارات، هناك نحو ٨ ملايين متغيّرٍ شائع (common variants) تختلف بين الناس. فإذا أردتَ أن تختبر كلّ متغيّرٍ على حدة بحثاً عن ارتباطه بالمرض، فأنت أمام ملايين الاختبارات الإحصائية المتتالية. تخيل أنّك تبحث عن إبرة في كومة قش، لكنّ كومة القش بحجم جبل، والإبر قد تكون عشراتٍ لا واحدة، وبعضها مزيف. هذا التحديّ — الجمع بين الحجم الهائل والإشارة الضعيفة — هو ما يجعل الإحصاء ضرورةً لا رفاهية.

الأعمدة الثلاثة

يقوم علم الوراثة الإحصائية على ثلاثة أعمدة:

الأول: علم الوراثة السكانية (Population Genetics) — وهو يدرس كيف تنتشر المتغيّرات الجينية بين الأجيال والشعوب، ولماذا يشيع متغيّرٌ في شعبٍ

ويندر في آخره. هذا العمود يعطينا قوانين مثل توازن هاردي-واينبرغ (الفصل الثالث) وعدم التوازن الترابطي (الفصل الرابع).

الثاني: علم الوراثة الكمية (Quantitative Genetics) — وهو يربط المتغيرات بالصفات القابلة للقياس: الطول، ضغط الدم، مستوى السكر. هذا العمود يعطينا مفهوم معامل الوراثة (الفصل السابع) ودرجات الخطر متعدد الجينات (الفصل الثامن).

الثالث: الاستدلال الإحصائي (Statistical Inference) — وهو الأداة التي بها نختبر الفرضيات: هل هذا الارتباط حقيقي أم محض صدفة؟ هذا العمود يعطينا الانحدار، وقيمة p ، وتصحيح الاختبارات المتعددة (الفصل السادس).

ما ليس هو علم الوراثة الإحصائية

لتفهم المجال جيداً، من المفيد أن تعرف ما ليس هو. علم الوراثة الإحصائية ليس البيولوجيا الجزيئية (التي تدرس كيف تعمل الجينات داخل الخلية ميكانيكياً)، وليس الاستشارة الوراثية (التي تُعنى بإرشاد العائلات حول مخاطر الأمراض الوراثية)، وليس الطبّ الوراثيّ السريريّ (الذي يشخص الأمراض النادرة). إنّه اللغة الرياضية التي تربط هذه المجالات كلّها. حين يكتشف عالم الوراثة الإحصائية متغيراً مرتبطاً بالمرض، يأخذ البيولوجيّ الجزيئيّ هذا المتغير ليفهم آليته، ويأخذ الطبيب النتيجة ليُحسن التشخيص. فالجال جسر، لا جزيرة.

تطبيقات واقعية

هذا العلم ليس نظرياً بحتاً. به اكتُشفت عشرات الجينات المرتبطة بالسكري، وبه تُبنى نماذجُ التنبؤ بخطر السرطان قبل ظهوره، وبه استطاع العلماء أن يتتبعوا تاريخ هجرات البشر عبر القارات من خلال قراءة أنماط المتغيرات في الشعوب المختلفة. كلُّ هذه الإنجازات ولدت من فكرة واحدة: أنَّ الاختلافات الصغيرة في الحمض النووي تحمل معلومات كبيرة، إن نحن أحسنّا قراءتها إحصائياً.

نقطة دخولي إلى المجال

دخلتُ هذا المجال من بابٍ عمليٍّ. في جامعة ميشيغان، كنتُ أبحث عن مؤشرات حيوية (biomarkers) لأمراض الكلى المزمنة. كان السؤال: لماذا يتدهور أداء الكلى عند بعض المرضى أسرع من غيرهم؟ ولأنَّ جزءاً من الإجابة جينيٌّ، لجأتُ إلى دراسات الارتباط على مستوى الجينوم (GWAS). أتذكرُ أولَ مرّةٍ نظرتُ فيها إلى "مخطط مانهاتن" — ذلك الرسمُ المليء بالنقاط الذي يشبه أفقَ مدينةٍ — ولم أفهم منه شيئاً. هذا الكتاب هو، في جزءٍ منه، الكتابُ الذي تَمَنَيْتُ لو وجدتهُ في ذلك اليوم.

كيف يُستخدم هذا في البحث الواقعي؟ حين بدأنا تحليل بيانات جينية لمئات المرضى المصابين بالقصور الكلوي المزمن، لم يكن الهدف مجرد

إيجاد جين، بل بناء أداة تنبؤية تُساعد الطبيب على معرفة أي مريض يحتاج إلى متابعة أشد. هذا هو الوعد العملي للبحال: تحويل الحروف إلى قرارات.

ما يفترضه هذا الكتاب وما يغطيه

يفترض هذا الكتاب أنك تعرف أساسيات الإحصاء — المتوسط، التباين، قيمة p — لكنه لا يفترض أي خلفية في علم الوراثة. سنبدأ من المفاهيم الجينية الأساسية (الفصل الثاني)، ثم نبني طبقة فوق طبقة: القوانين السكانية، فدراسات الارتباط، فتصحيح الأخطاء، فالتنبؤ بالخطر، فتفسير النتائج. هدفنا في نهاية الرحلة أن تكون قادراً على أن تقرأ ورقة علمية في GWAS، وتفسر مخططات مانهاتن، وتفهم درجات الخطر متعدد الجينات، وتُجري اختبارات ارتباط بسيطة بنفسك. والله الموفق.

الفصل الثاني: المفاهيم الجينية الأساسية للمبتدئين

﴿وَفِي أَنْفُسِكُمْ أَفَلَا تُبْصِرُونَ﴾

— سورة الذاريات: ٢١

دعا الله الإنسان أن يتأمل في نفسه، فإن في تكوينه آيات بيّنة. وما من تأملٍ أعمق من النظر في ذلك الكتاب المكتوب داخل كلّ خلية من خلايانا: الحمض النووي. في هذا الفصل نضع المفردات الأساسية التي بدونها لا يستقيم أي حديث عن الوراثة الإحصائية، ونفعل ذلك بأبسط التشبيهات.

تشبيه المكتبة

تخيّل الجينوم البشري على أنّه مكتبة كاملة. هذه المكتبة فيها ٢٣ رفاً (هذه هي الكروموسومات، وعندنا منها زوجان من كلّ نوع). كلّ رفاً يحمل آلاف الكتب (هذه هي الجينات، ومجموعها نحو ٢٠ ألف جين مشفر للبروتين). كلّ كتاب مكتوب بأربعة أحرف فقط: A و C و G و T (وهي القواعد النيتروجينية). وحين يختلف حرف واحد على صفحة واحدة بين شخص وآخر، نسمّي هذا الاختلاف SNP — وهو بطل هذا الكتاب.

ال SNP: حصان العمل

ال SNP — أو تعدد النوكليوتيدة المفردة (Single Nucleotide Polymorphism) — هو موضعٌ في الجينوم يختلف فيه حرفٌ واحد بين الناس. مثلاً: عند موضع معين، يحمل ٧٠٪ من الناس الحرف A ويحمل ٣٠٪ الحرف G. هذا الموضع هو SNP. ولكل SNP اسمٌ مرجعيّ يبدأ بالحرفين rs، مثل rs7903146 (وهو SNP شهير مرتبط بالسكري). هناك نحو ٨ ملايين SNP شائع في البشر، وهي العملة التي تتعامل بها في كل تحليلٍ إحصائيٍّ تقريباً، لأنها كثيرةٌ، ومتفرقةٌ على طول الجينوم، وسهلةُ القياس.

الأليلات والأنماط الجينية

عند كل SNP، يُسمّى كلُّ شكلٍ من أشكال الحرف أليلاً (allele). ففي مثالنا، الأليل A والأليل G. ولأننا بشرٌ ثنائيو الصبغيات (لكلٍّ منا نسختان من كلِّ كروموسوم: واحدة من الأب وواحدة من الأم)، فإنَّ كلَّ شخصٍ يحمل أليلين عند كلِّ موضع. مجموع الأليلين يُسمّى النمط الجينيّ (genotype). فعندنا ثلاثة أنماط ممكنة: AA و AG و GG.

نُسمي النمط متماثل الأليلات (homozygous) إذا كان الأليلان متطابقين (AA أو GG)، ومتغاير الأليلات (heterozygous) إذا كانا مختلفين (AG). شبه ذلك بلون العينين: إن ورثت "تعليلة العين الزرقاء" من كلا الوالدين فأنت

متمائل، وإن ورثت "زرقاء" من أحدهما و"بنية" من الآخر فأنت متغير - وغالباً يظهر عليك اللون البني لأنه سائد.

العقيدة المركزية ولماذا تهتم المناطق غير المشفرة

تسير المعلومة في الخلية وفق ما يُسمى العقيدة المركزية: الحمض النووي (DNA) يُنسخ إلى حمض نووي ريبوي (RNA)، ثم يُترجم إلى بروتين. البروتينات هي عمال الجسم: الإنزيمات، والهرمونات، ومكونات البنية. لكن مفاجأة كبرى في علم الوراثة الإحصائية أنّ أكثر المتغيرات المرتبطة بالأمراض لا تقع داخل الجينات المشفرة للبروتين، بل في المناطق غير المشفرة التي تتحكم في متى وكم يُنتج البروتين. فالمنطقة غير المشفرة ليست "نفاية" كما ظن قديماً، بل أشبه بمفاتيح الإضاءة وأزرار التحكم في المصنع.

أحادي ومضاعف: لماذا نسختان؟

كوننا ثنائيي الصبغيات (diploid) له أثر إحصائي مهم. فلأن لكل موضع نسختين، يمكن حساب تواتر الأليل (allele frequency) بدقة، ويمكن دراسة كيف يتوزع النمط الجيني في السكّان. هذه الازدواجية هي أساس قانون هاردي-واينبرغ الذي سنراه في الفصل القادم.

مثال محسوب: حساب تواتر الأليل يدوياً

لنأخذ مجموعةً صغيرةً من ١٠ أشخاص، وننظر إلى SNP له أليلان: A و G. لنفترض أنّ الأنماط الجينية كالتالي:

- ٤ أشخاص نمطهم AA
- ٤ أشخاص نمطهم AG
- ٢ شخصان نمطهما GG

المجموع: ١٠ أشخاص، أي ٢٠ أليلاً (لأنّ لكل شخصٍ نسختين).

عدّ الأليل A: من الأشخاص الأربعة AA نحصل على $4 \times 2 = 8$ نسخ من A. ومن الأربعة AG نحصل على $4 \times 1 = 4$ نسخ من A. المجموع: $8 + 4 = 12$ نسخة من A.

عدّ الأليل G: من الشخصين GG نحصل على $2 \times 2 = 4$ نسخ. ومن الأربعة AG نحصل على $4 \times 1 = 4$ نسخ. المجموع: ٨ نسخ من G.

$$\begin{aligned} \text{تواتر } A &= 12 \div 20 = 0.60 \text{ (} 60\% \text{)} \\ \text{تواتر } G &= 8 \div 20 = 0.40 \text{ (} 40\% \text{)} \end{aligned}$$

لاحظ أن المجموع $0.60 + 0.40 = 1.00$ ، كما يجب دائماً. الأليل الأقل شيوعاً (هنا G بتواتر 0.40) يُسمى الأليل الأقلية (minor allele)، وتواتره يُسمى MAF – وهو رقم ستره في كل ورقة GWAS.

أخطاء شائعة

كثيراً ما يخلط المبتدئ بين الأليل والنمط الجيني: الأليل هو الحرف الواحد (A)، والنمط هو الزوج (AG). وخطأ آخر شائع هو الظن أن متغيراً خارج الجينات لا أثر له – وقد رأينا أن العكس غالباً هو الصحيح.

من بحثي: في تحليلاتنا لأمراض الكلى في جامعة ميشيغان، نبدأ دائماً بحساب MAF لكل SNP، ونستبعد المتغيرات النادرة جداً (مثلاً MAF أقل من 0.001) لأن الإشارة الإحصائية فيها ضعيفة وغير موثوقة. هذه الخطوة البسيطة – عد الأليلات – هي جبر الأساس الذي يقوم عليه كل تحليل لاحق.

الفصل الثالث: توازن هاردي-واينبرغ: القانون الأساسي

﴿إِنَّ اللَّهَ لَا يَغَيِّرُ مَا بَقِيَ حَتَّى يَغْيُرُوا مَا بِأَنْفُسِهِمْ﴾

— سورة الرعد: ١١

تحدّث الآية عن قانون في الاجتماع: أنّ الأحوال تبقى مستقرّة حتى يطرأ تغيير من الداخل. وفي علم الوراثة السكانية قانون يشبهه في روحه: أنّ تواترات الأنماط الجينية تبقى مستقرّة وقابلة للتنبؤ ما لم تتدخل قوى تُغيّرُها. هذا القانون هو توازن هاردي-واينبرغ (Hardy-Weinberg Equilibrium، أو HWE)، وهو حجرُ الزاوية في كلِّ تحليلٍ جينيّ.

ماذا يقول القانون؟

ينصّ القانون على أنّه في ظلّ ظروفٍ مثالية، يمكن التنبؤ بتواترات الأنماط الجينية انطلاقاً من تواترات الأليلات وحدها، وأنّ هذه التواترات تبقى ثابتة جيلاً بعد جيل. بكلماتٍ أخرى: إنّ عرفت تواتر الأليل، استطعت أن تتوقع كم نسبة الناس الذين سيكونون AA و AG و GG — دون أن تفحص أحداً.

الصيغة من المبادئ الأولى

لنفترض أنّ تواتر الأليل A هو p وتواتر الأليل a هو q ، وأنّ $p + q = 1$ حين يتزاوج الناس عشوائياً، فإنّ احتمال أن يلتقي أيلان لتكوين نمط جينيّ يتبع قانون ضرب الاحتمالات:

• احتمال النمط $AA = p \times p = p^2$

• احتمال النمط $aa = q \times q = q^2$

• احتمال النمط $Aa = (q \times p) + (p \times q) = 2pq$ (لأنّ A قد تأتي من الأب أو من الأم)

ومجموع هذه الاحتمالات يساوي الواحد الصحيح:

$$p^2 + 2pq + q^2 = 1$$

وهذه ليست إلا مفكوك $(p+q)^2 = 1^2 = 1$. أناقة القانون أنّه يخرج من جبر بسيط في الصفّ الثانوي.

الافتراضات الخمسة

يصحّ هذا القانون بشروطٍ خمسة، وكلُّ خرقٍ لأحدها يدفع السكّان بعيداً عن التوازن:

1. التزاوج العشوائيّ – لا تفضيل لأنماطٍ بعينها في اختيار الشريك. خرقه (كالزواج بين الأقارب) يزيد تماثل الأليلات.
2. انعدام الانتقاء الطبيعيّ – لا نمط يموت أو يتكاثر أكثر من غيره. خرقه يبدّل التواترات لصالح أليلٍ نافع.
3. انعدام الطفرة – لا تحوّل لأليلٍ إلى آخر. خرقه نادر الأثر على المدى القصير.
4. انعدام الهجرة – لا دخول ولا خروج لأليلاتٍ من سكّانٍ آخرين. خرقه يخلط التواترات.
5. حجم سكّانيّ كبير – لتلافي تذبذبات الصدفة (الانجراف الجينيّ). خرقه في السكّان الصغيرة يحدث تقلّباتٍ عشوائية.

لماذا يهمنّا في الوراثة الإحصائية؟

قد تظنّ أنّ هذا القانون مجردُ نظريةٍ سكّانية، لكنّ له استخداماً عملياً مهماً جداً: مرشّح لجودة البيانات. فحين نقيس ملايين الـ SNP في آلاف الأشخاص باستخدام شرائح الجينوم (genotyping arrays)، تحدث أخطاءٌ تقنية في القياس. ومن

أوضح علامات الخطأ التقنيّ أن يخرف SNP انحرافاً شديداً عن توازن هاردي-واينبرغ في عينة الأصحاء. فإذا وجدنا SNP أنماطه الجينية بعيدة جداً عما يتنبأ به القانون، نشكّ في القياس ونستبعده.

مثال محسوب: متوقع مقابل ملاحظ مع اختبار كاي-تربيع

لنأخذ SNP بأليلين A و a، في عينة من ١٠٠٠ شخص. لنفترض أن تواتر A هو $p = ٠.٧$ وتواتر a هو $q = ٠.٣$

$$\begin{aligned} \text{الأعداد المتوقعة وفق القانون: } p^2 - AA: & ١٠٠٠ \times ٠.٤٩ = ٤٩٠ \\ 2pq - Aa: & ١٠٠٠ \times ٠.٤٢ = ٤٢٠ \\ q^2 - aa: & ١٠٠٠ \times ٠.٠٩ = ٩٠ \end{aligned}$$

الأعداد الملاحظة فعلاً (لنفترض أننا عدناها): AA: ٥٢٠، Aa: ٣٦٠، aa: ١٢٠

اختبار كاي-تربيع خطوة بخطوة، بالصيغة $\chi^2 = \sum \frac{(O-E)^2}{E}$

$$\bullet \quad AA: \frac{1084}{490} = \frac{490}{2^{(490-520)}}$$

$$\bullet \quad Aa: \frac{8057}{420} = \frac{420}{2^{(420-360)}}$$

$$\chi^2_{1df} = 90 / 900 = 90 / 2^{(90-120)} = 10000$$

$$\chi^2_{1df} = 10000 + 8057 + 1084 = 20041$$

درجات الحرية في اختبار HWE تساوي ١ (عدد الأنماط ٣ ناقص عدد الأليلات ٢). والقيمة الحرجة عند مستوى ٠.٠٠٥ هي ٣.٨٤. وبما أن ٢٠٠٤١ أكبر بكثير من ٣.٨٤، فإن هذا الـ SNP يفشل في اختبار التوازن (p أصغر من ٠.٠٠٠١)، ونزج أن فيه خطأ قياس تقني، فنستبعده.

كيف استخدمه في عملي

من مبحثي: في كل تحليل GWAS تجريه في جامعة ميشيغان لأمراض الكلى، نمرر الملايين من الـ SNP عبر مرشح هاردي-واينبرغ في مجموعة الضبط (الأصحاء). عملياً، يفشل نحو ٣٪ من الـ SNP في هذا الاختبار (عند عتبة صارمة مثل p أصغر من 10^{-6})، فنحذفها قبل أي تحليل للارتباط. لماذا في الأصحاء فقط؟ لأن المرضى قد يخفون عن التوازن لسبب بيولوجي حقيقي (الانتقاء المرتبط بالمرض)، فلا نخلط الخطأ التقني بالإشارة الحقيقية.

خلاصة

توازن هاردي-واينبرغ ليس مجرد معادلة أنيقة، بل أداة عملية: يخبرنا بما ينبغي أن نراه إذا كان كلُّ شيءٍ "طبيعياً"، فإذا رأينا غيرَ ذلك، عرفنا أين نبحث — إما عن خطأ تقنيّ، وإما عن بيولوجيا مثيرة.

الفصل الرابع: عدم التوازن الترابطي: اللغة السرية للجينوم

﴿وَجَعَلْنَا مِنْ كُلِّ شَيْءٍ زَوْجَيْنِ لَعَلَّكُمْ تَذَكَّرُونَ﴾

— سورة الذاريات: ٤٩

في الكون أزواجٌ متلازمة، وفي الجينوم كذلك مواضعٌ تسيّر مقترنةً لا تكاد تفترق. هذا الاقتران بين المواضع المتجاورة هو ما نسميه عدم التوازن الترابطي (Linkage Disequilibrium، أو LD)، وهو — رغم اسمه المُرَبِّك — أحدُ أجمل المفاهيم في علم الوراثة الإحصائية، وسرُّ كفاءة دراسات الارتباط كليهما.

المفهوم

حين يُورَث الجينوم من جيلٍ إلى جيلٍ، تحدث عملية إعادة التركيب (recombination) التي تخلط الكروموسومات. لكنّ هذا الخلط لا يفصل بين المواضع المتجاورة بسهولة، فالمواضع القريبة بعضها من بعضٍ على الكروموسوم ذاته تُورَث معاً أكثرَ ممَّا تُنبأ به الصدفة. هذا الارتباط الإحصائي بين أليلات مواضع مختلفة هو LD. وكلّما تقاربت المواضع، قوي ارتباطها؛ وكلّما تباعدت، ضعف.

تشبيه الأحياء السكنية

تخيّل الكروموسوم كمدينة طويلة مقسّمة إلى أحياء (haplotype blocks). الناس الذين يسكنون الحيّ نفسه يتنقلون معاً، يذهبون إلى السوق نفسه والمسجد نفسه. كذلك المتغيّرات في "الحيّ الجينيّ" الواحد تنتقل معاً عبر الأجيال. فإذا عرفت متغيّراً واحداً في الحيّ، استطعت أن تستنتج جيرانه بدقّة عالية، دون أن تفحصهم كلّهم. هذه هي الفكرة التي تختزل العمل من ٨ ملايين متغيّر إلى مليونٍ "مثّل" تقريباً.

إحصاء r^2 و 'D'

نقيس LD بمقياسين رئيسيين:

المقياس r^2 (دي برايم): يتراوح بين ٠ و ١، و يقيس ما إذا كان هناك أيّ ارتباطٍ تاريخيّ بين موضعين بغضّ النظر عن تواتر الأليلات. قيمة $r^2 = ١$ تعني أنّه لم تحدث إعادة تركيبٍ تفصل بينهما (ارتباطٌ "كامل" تاريخياً).

المقياس r^2 (آر تريغ): يتراوح أيضاً بين ٠ و ١، لكنه يقيس القدرة التنبؤية: إن كان $r^2 = ١$ ، فإنّ معرفة أليل موضع تخبرك بأليل الآخر تماماً. هذا هو المقياس الأهمّ في GWAS، لأننا نريد أن نعرف: إلى أيّ مدى يمكن لمتغيّرٍ مقيسٍ أن "ينوب" عن متغيّرٍ غير مقيسٍ؟ نستخدم 'D' لفهم التاريخ التطوّري، و r^2 لتصميم الدراسات واختيار المتغيّرات الممثّلة (tag SNPs).

لماذا يهم LD؟

هنا يكمن سرُّ كفاءة GWAS. بفضل LD، لا حاجة لقياس كلِّ متغيِّرٍ من الـ ٨ ملايين. يكفي أن نقيس مجموعةً منتقاةً من "المتغيِّرات الممثَّلة"، فكلُّ متغيِّرٍ مقيسٍ يلتقط — عبر LD — إشارةً عشراتٍ من المتغيِّرات المجاورة غير المقيسة. هذا ما جعل شرائح الجينوم رخيصةً وممكنة: نقيس نحو مليون SNP، فنغطِّي عملياً معظم التنوع الشائع في الجينوم.

منحنى تضال LD

كلّما زادت المسافة بين موضعين، تضال LD بينهما، لأنَّ احتمال حدوث إعادة تركيبٍ تفصل بينهما يزداد مع المسافة. حين نرسم r^2 على المحور الرأسيّ والمسافة (بالكيلوقاعدة) على المحور الأفقيّ، نحصل على منحنى تضالٍ ينحدر من قيمةٍ عالية عند المسافات القصيرة إلى قيمةٍ قريبةٍ من الصفر عند المسافات الطويلة. سرعةُ هذا الانحدار تختلف بين الشعوب.

اختلافات الشعوب في LD

في الشعوب الأفريقية، تكون أحياء LD أقصر منها في الشعوب الأوروبية أو الآسيوية. السببُ تاريخيٌّ: الشعوب الأفريقية أقدمُ (الإنسان نشأ في أفريقيا)، فمرتُّ بأجيالٍ أكثر، وحدثت فيها إعادة تركيبٍ أكثر، فتفتَّت الأحياء الطويلة

إلى أحياء أصغر. هذا له أثر عملي مهم: الدراسات المصممة للشعوب الأوروبية قد لا تنقل نتائجها بدقة إلى الشعوب الأفريقية، لأن بنية الأحياء مختلفة.

مثال محسوب: حساب r^2 بين متغيرين

لنأخذ موضعين، A/a و B/b ، وننظر إلى الهابلوتايبات (تركيبات الأليلات على الكروموسوم الواحد) في عينة. لنفترض هذه التواترات:

$$\begin{aligned} \bullet \text{ الأليل } A \text{ تواتره } p_A = 0.6, \text{ والأليل } B \text{ تواتره } p_B = 0.5 \\ \bullet \text{ تواتر الهابلوتايب } AB \text{ معاً: } p_{AB} = 0.45 \end{aligned}$$

$$\begin{aligned} \text{نحسب أولاً معامل عدم التوازن } D: D = p_{AB} - (p_A \times p_B) \\ \$\$ 0.15 = 0.30 - 0.45 = (0.5 \times 0.6) - 0.45 = \end{aligned}$$

$$\begin{aligned} \text{ثم نحسب } r^2 \text{ بالصيغة: } r^2 = \frac{D^2}{p_A (1-p_A) \times p_B (1-p_B)} \\ \$\$ \end{aligned}$$

$$\begin{aligned} \text{نعوض: } r^2 = \frac{(0.15)^2}{0.5 \times 0.4 \times 0.6 \times 0.5} = \frac{0.0225}{0.06} = 0.375 \\ \$\$ \end{aligned}$$

فقيمة $r^2 \approx 0.38$ تعني ارتباطاً متوسطاً: معرفة أليل أحد الموضعين تفسّر نحو ٣٨٪ من التباين في الآخر. في GWAS، نعتبر عادةً r^2 أكبر من ٠.٨ "ارتباطاً قوياً" كافياً لاعتبار أحد المتغيرين ممثلاً للآخر.

قراءة خريطة LD الحرارية

تُعرض علاقات LD غالباً في خريطة حرارية مثلثية (triangle plot): كلُّ مربعٍ صغير يمثل قيمة LD بين متغيرين، وتدرج اللون (من الفاتح إلى الداكن) يدلُّ على قوة الارتباط. الأحياء تظهر ككتلٍ مثلثية داكنة على القطر، فتُريكَ بصرياً أين تقع "الأحياء" على الكروموسوم.

من بحثي: عند تحليل منطقة مرتبطة بأمراض الكلى، نبدأ دائماً بفحص بنية LD حول المتغير الرائد. ففي إحدى مناطق الكلى المعروفة، وجدنا أنَّ المتغير الأقوى إحصائياً يقع في حيِّ يضمَّ عشرات المتغيرات في LD شديد ($r^2 > 0.9$)، ما يعني أنَّ المتغير "الوظيفي" الحقيقي قد يكون أياً منها – وهنا تبدأ مهمة التخریط الدقيق (الفصل الحادي عشر).

الفصل الخامس: دراسات الارتباط على مستوى الجينوم (GWAS)

﴿أَفَلَا يَنْظُرُونَ إِلَى الْإِبِلِ كَيْفَ خُلِقَتْ﴾

— سورة الغاشية: ١٧

دعوة إلى النظر المتأمل في خلق الإبل، نظرة من يبحث عن الإتيان في التفاصيل. وهذا هو روح دراسة الارتباط على مستوى الجينوم (Genome-Wide Association Study، أو GWAS): أن ننظر — متغيراً متغيراً — في ملايين المواضع، باحثين عن الإشارة التي تربط حرفاً من الجينوم بمرض أو صفة. هذا الفصل قلبُ الكتاب.

فكرة GWAS

الفكرة بسيطة ومذهلة: بدلاً من تخمين الجين المسؤول عن مرض ما، نختبر كل متغيرٍ شائع (٥ إلى ١٠ ملايين SNP) لمعرفة ارتباطه بالصفة، في آلاف بل مئات الآلاف من الأشخاص. لا نفترض مسبقاً أين يقع الجين؛ ندع البيانات تتكلم. هذا التحول من "الفرضية الموجهة" إلى "المسح الشامل غير المتحيز" هو ما أحدث ثورة في علم الوراثة منذ عام ٢٠٠٧.

الاختبار الإحصائي الأساسي

لكلّ SNP، نسأل سؤالاً واحداً: هل يختلف تواتر الأليل بين المرضى والأصحاء أكثر مما نتوقعه الصدفة؟ نَجيب باستخدام الانحدار (regression):

• للأمراض (نتيجة ثنائية: مريض/سليم) نستخدم الانحدار اللوجستي (logistic regression).

• للصفات المتصلة (مثل الطول أو ضغط الدم) نستخدم الانحدار الخطي (linear regression).

بلغة مبسطة: نضع النمط الجيني (0 أو 1 أو 2 نسخة من الأليل) متغيراً مستقلاً، والصفة متغيراً تابعاً، ونحسب معامل التأثير (effect size، يُرمز له بـ β أو نسبة الأرجحية OR) وقيمة p التي تقيس قوة الدليل ضدّ فرضية "لا ارتباط". نكرر هذا ملايين المرات — مرةً لكلّ SNP.

مخطط مانهاتن

كيف نعرض ملايين قيم p دفعةً واحدة؟ بـ مخطط مانهاتن (Manhattan plot)، المسمّى كذلك لأنّه يشبه أفقَ ناطحات السحاب. على المحور الأفقيّ: موضعُ الـ SNP على الكروموسومات، مرتبةً من 1 إلى 22 ثمّ الجنسية. على المحور الرأسيّ: القيمة $-\log_{10}(p)$ — أي أنّ قيمة p الأصغر (الأقوى)

تظهر أعلى. فإذا كانت $p = 10^{-8}$ ، صارت على المحور ٨. كل نقطة SNP، وكل "برج" من النقاط المرتفعة هو منطقة مرتبطة بالصفة.

يُرسَم على المخطط خطان أفقيان عادةً: خط أحمر عند عتبة الدلالة الجينومية ($p = 10^{-8}$)، وخط أزرق عند عتبة "موحية" أقل صرامة (مثل $p = 10^{-5}$). كل ما تجاوز الخط الأحمر يُعتبر اكتشافاً ذا دلالة.

عتبة الدلالة الجينومية: لماذا 10^{-8} ؟

قد تتساءل: لماذا هذا الرقم تحديداً، وليس ٥٠٠٥ المألوف؟ السبب هو تصحيح بونفيروني للاختبارات المتعددة. حين نُجري نحو مليون اختبارٍ مستقلٍّ، يجب أن نقسم العتبة المعتادة ٥٠٠٥ على عدد الاختبارات:

$$\frac{0.05}{10^6} = 5 \times 10^{-8}$$

ولماذا مليون اختبار وليس ٨ ملايين؟ لأن كثيراً من المتغيرات مترابطة عبر LD (الفصل الرابع)، فعدد الاختبارات المستقلة فعلياً في الجينوم الأوروبي نحو مليون. سنفصل هذا في الفصل القادم.

مخطط Q-Q ومعامل التضخم

قبل أن نتق بنتائج GWAS، نفحص مخطط Q-Q (quantile-quantile plot). يقارن هذا المخطط قيم p الملاحظة بما نتوقعه لو لم يكن هناك أي ارتباط حقيقي. إذا سارت النقاط على الخط القطري ثم انحرفت لأعلى في الذيل، فهذا جيد: معظم المتغيرات لا ارتباط لها (كما يُتوقع)، وقليل منها يظهر إشارة حقيقية.

لكن إذا انحرف المنحنى كله لأعلى من البداية، فهذا تضخم (inflation) ينذر بمشكلة – غالباً اختلاط سكاني (الفصل العاشر). نقيس التضخم بمعامل لامبدا (genomic control factor, λ): إذا كان λ قريباً من ١.٠ فالأمور سليمة؛ وإذا تجاوز ١.٠٥ أو ١.١ فهناك تضخم يجب معالجته.

قراءة ورقة GWAS حقيقية

من بحثي: حين أقرأ ورقة GWAS لأمراض الكلى، أتبع ترتيباً ثابتاً. أولاً، أنظر إلى مخطط Q-Q ومعامل λ لأتأكد أن النتائج غير متضخمة (نريد $\lambda \approx ١.٠٢$ مثلاً). ثم أنتقل إلى مخطط مانهاتن وأعد الأبراج التي تجاوزت الخط الأحمر. في دراسات كبيرة لوظيفة الكلى (مقاسة بمعدل الترشيح الكبيبي $eGFR$)، يظهر عشرات المواضيع، وأشهرها منطقة جين *UMOD* على الكروموسوم ١٦ – وهي إشارة قوية ومتكررة في كل

دراسةً تقريباً. أتُحقّق من معامل التأثير واتجاهه: هل الأليل يرفع أم
يخفض وظيفة الكلي؟

ما ليس هو "نتيجة GWAS"

تنبيهٌ جوهريٌّ: الارتباط ليس سببياً. حين نجد SNP مرتبطاً بالمرض، فهذا لا
يعني أنّه السبب المباشر. غالباً يكون المتغيّر المكتشف مجرد "ممثل" (عبر LD)
لمتغيّر وظيفيّ حقيقيّ مجاور لم نفسه. كذلك قد يكون الارتباط ناتجاً عن اختلاطٍ
لم نضبطه. الانتقالُ من "ارتباط" إلى "وظيفة بيولوجية" يتطلب خطواتٍ إضافيةٍ
كاملة، نخصّص لها الفصل الحادي عشر.

أخطاء شائعة

من أكثر أخطاء المبتدئين: التعاملُ مع كلّ نقطة فوق الخطّ الأحمر على أنّها "جينٌ
مكتشف"، بينما النقطة متغيّر في منطقة قد تضمّ عدّة جينات. وخطأ آخر:
تجاهلُ مخطط Q-Q والقفزُ مباشرةً إلى مانهاتن — وهو ما قد يجعلك تحتفل
بنتائجٍ هي في الحقيقة محض تضخيم ناتج عن اختلاطٍ سكانيّ.

الفصل السادس: تصحيح الاختبارات المتعددة: مشكلة عشرة ملايين اختبار

﴿وَلَا تَقْفُ مَا لَيْسَ لَكَ بِهِ عِلْمٌ﴾

— سورة الإسراء: ٣٦

نهى الله عن أن تتع ما لا علم لنا به، أن نجزم بلا دليل كافٍ. وهذا بالضبط جوهر مشكلة الاختبارات المتعددة في علم الوراثة الإحصائية: حين نُجري ملايين الاختبارات، يحدعنا بعضها بإشارات كاذبة، فنظن أننا "اكتشفنا" ما هو في الحقيقة محض صدفة. هذا الفصل يعلّك كيف تحرس نفسك من القفو بلا علم.

أصل المشكلة

تخيّل أنّك تُجري مليون اختبار عند مستوى الدلالة المعتاد p أصغر من ٠.٠٠٠٥. تذكر معنى ٠.٠٠٥: هو احتمال أن نرى نتيجة بهذه القوة بحض الصدفة حتى لو لم يكن هناك ارتباط حقيقي. فإذا كان كل مليون SNP بلا ارتباط حقيقي، فكم منها سيتجاوز العتبة صدفة؟

$$\$ \$ ٥٠٠,٠٠٠ = ٠.٠٠٥ \text{ times } \backslash ١,٠٠٠,٠٠٠ \$ \$$$

نحسون ألف "اكتشاف" كاذب! هذه هي الكارثة التي يجب تصحيحها، وإلا غرقنا في إيجابيات زائفة.

تصحيح بونفيروني

أبسط الحلول وأكثرها صرامة هو تصحيح بونفيروني (Bonferroni): اقسم مستوى الدلالة α على عدد الاختبارات.

مثال محسوب: إن أجرينا مليون اختبار وأردنا معدل خطأً كلياً قدره 0.0005:

$$\alpha = \frac{0.0005}{1,000,000} = 5 \times 10^{-10}$$

وهكذا نفهم من أين جاءت عتبة 5×10^{-8} الشهيرة في GWAS. أي SNP قيمته p أصغر من هذه العتبة يُعتبر ذا دلالة جينومية. عيب بونفيروني أنه محافظ جداً: يفترض أن كل الاختبارات مستقلة، فإذا كانت مترابطة (كما في LD) صار التصحيح أشد من اللازم، وقد نفقد اكتشافات حقيقية.

معدل الاكتشاف الكاذب وطريقة بنياميني-هوكبرغ

بديل أقل صرامة هو التحكم في معدل الاكتشاف الكاذب (False Discovery Rate، أو FDR). الفرق الفلسفي مهم: بونفيروني يتحكم في احتمال وجود ولو

إيجابية كاذبة واحدة، أما FDR فيتحكم في نسبة الإيجابيات الكاذبة بين الاكتشافات. فإذا قلت "أقبل FDR قدره ٥٪"، فأنت تقول: "أرضى بأن يكون نحو ٥٪ من اكتشافاتي كاذباً".

طريقة بنياميني-هوكبرغ (Benjamini-Hochberg) تطبق هذا عملياً: رتب قيم p تصاعدياً، وأعط كل واحدة رتبة i ، ثم قارن p بالعبارة $(i/m) \times \alpha$ حيث m عدد الاختبارات. أكبر p تحقق الشرط، هي وكل ما دونها، تعتبر ذات دلالة. نستخدم FDR حين نريد توازناً بين الحذر والاكتشاف، خاصة في الدراسات الاستكشافية أو تحليلات التعبير الجيني.

نهج التبديل (Permutation)

المعيار الذهبي للبيانات المعقدة هو التبديل (permutation). الفكرة: اخلط تسميات الحالات (مريض/سليم) عشوائياً مرات كثيرة، وأعد التحليل في كل مرة. هذا يبني توزيع "الارتباط" الحقيقي لبياناتك تحديداً، دون افتراضات نظرية. ميزته أنه يحترم بنية الارتباط في بياناتك (LD، الاختلاط) تلقائياً، وعيبه أنه مكلف حسابياً جداً (آلاف الإعادات لملايين الـ SNP).

لماذا 10×5^{-8} بالذات؟

عرفنا أنّ بونفيروني للمليون اختبارٍ يعطي 10×5^{-8} . لكنّ لماذا مليون وليس ٨ ملايين؟ لأنّ التصحيح يجب أن يقوم على عدد الاختبارات المستقلة فعلياً. وبسبب LD، فإنّ الـ ٨ ملايين متغيّرٍ شائعٍ في الجينوم الأوروبيّ تُتصرّف كأنّها نحو مليونٍ اختبارٍ مستقلّ. ولهذا استقرّ المجالُ على 10×5^{-8} كعتبةٍ موحّدة، تجعل نتائج الدراسات المختلفة قابلةً للمقارنة.

قراري في الممارسة

من بحثي: في عملي على أمراض الكلى في جامعة ميشيغان، أفرّق بين مرحلتين. في المسح الجينوميّ الأوّل، ألزمت بعتبة بونفيروني الصارمة 10×5^{-8} ، لأنّي أريد ألا أعلن اكتشافاً إلا بأعلى درجات اليقين. أمّا حين أنتقل إلى تحليلٍ مستهدفٍ أضيق – مثل فحص تأثير مجموعةٍ صغيرةٍ من جينات الكلى المعروفة على التعبير الجينيّ – فأستخدم FDR عند ٥٪، لأنّ عدد الاختبارات أقلّ بكثير، والهدفُ استكشافيٌّ يحتملُ قدراً محسوباً من المخاطرة.

أخطاء شائعة

خطآن متقابلان يقع فيهما الباحثون:

الإفراط في الصرامة: تطبيقُ بونفيروني على اختباراتٍ مترابطة بشدة (كما في تحليل منطقة صغيرة مليئة بـ LD). هنا يصير بونفيروني محافظاً أكثر من اللازم، فتضيع إشاراتٌ حقيقية.

الإفراط في التساهل: تجاهلُ تصحيح الاختبارات المتعددة تماماً، والاكتفاء بـ p أصغر من ٠.٠٠٠٥. هذا هو الخطأ الأخطر، وهو سبب رئيس في "أزمة عدم قابلية التكرار" التي ضربت كثيراً من الدراسات الجينية المبكرة قبل عصر GWAS الصارم.

خلاصة

التصحيحُ للاختبارات المتعددة ليس ترفاً إحصائياً، بل ضرورة أخلاقية ومنهجية. هو ترجمة عملية للنهي القرآني عن اتباع ما لا علم لنا به: لا نعلن اكتشافاً حتى نتأكد أنه ليس محض ظلٍ من ظلال الصدفة في بحرٍ من ملايين الاختبارات.

الفصل السابع: معامل الوراثة: كم الجيني يحدّد الصفة؟

﴿وَخَلَقْنَاكُمْ أَزْوَاجًا﴾

— سورة النبأ: ٨

خلقنا الله أزواجاً، ومن هذا الازدواج تأتي التوائم — وهي أقدم أداة استخدمها العلماء لقياس "كم من الصفة جيني؟". هذا الفصل يعالج مفهوماً تُساء فهمه أكثر من أي مفهوم آخر في علم الوراثة: معامل الوراثة (heritability)، ويرمز له h^2 .

ما هو معامل الوراثة؟

معامل الوراثة هو نسبة التباين الظاهري (في الصفة) الذي يُفسّر بالتباين الجيني، في سكان معينين وزمن معين. لاحظ القيدَين الأخيرين جيداً؛ فهما مفتاحٌ تجنّب أكثر الأخطاء شيوعاً. معامل الوراثة ليس صفةً ثابتةً للكائن، بل خاصيةٌ لمجموعةٍ سكانية في ظرفها البيئيّ.

بصيغة مبسّطة:
$$h^2 = \frac{V_G}{V_P} = \frac{S}{S_{\text{التباين الظاهري الكلي}}}$$

حيث التباين الظاهري الكلي V_P هو مجموع التباين الجيني V_G والتباين البيئي V_E .

دراسات التوائم

الطريقة الكلاسيكية لقياس h^2 تقارن نوعين من التوائم: المتماثلة (identical، تشارك ١٠٠٪ من الجينات) وغير المتماثلة (fraternal، تشارك ٥٠٪ في المتوسط). الفكرة: إذا كانت صفة ما جينية بقوة، فستشابه التوائم المتماثلة فيها أكثر بكثير من غير المتماثلة. صيغة فالكورنر الشهيرة:

$$h^2 = 2 \times (r_{MZ} - r_{DZ})$$

حيث r_{MZ} معامل الارتباط بين التوائم المتماثلة و r_{DZ} بين غير المتماثلة.

مثال محسوب على الطول: لنفترض أنّ ارتباط الطول بين التوائم المتماثلة $r_{MZ} = 0.90$ ، وبين غير المتماثلة $r_{DZ} = 0.50$. إذن:

$$0.80 = 0.40 \times 2 = (0.90 - 0.50) h^2 = 2 \times$$

أي إنّ نحو ٨٠٪ من التباين في الطول بين الناس (في هذه العينة) يُفسّر بالاختلافات الجينية. وهذا قريب جداً من القيمة المقبولة عالمياً للطول.

معامل الوراثة من الـ SNP ومشكلة "الوراثة المفقودة"

حين بدأت GWAS، حدثت مفاجأة: المتغيرات المكتشفة ذات الدلالة كانت تفسّر جزءاً صغيراً فقط من معامل الوراثة المقدّر من التوائم. سُميت هذه الفجوة الوراثة المفقودة (missing heritability). مثلاً: الطول $h^2 \approx$ ٨٠٪ من التوائم، لكنّ أوائل دراسات GWAS فسّرت أقلّ من ١٠٪. أين ذهبت البقية؟

طوّر العلماء مفهوم معامل الوراثة من الـ SNP (h^2_{SNP}): التباين الذي تفسّره كلّ متغيرات الشريحة مجتمعة، لا فقط ذوات الدلالة. تبين أنّ معظم الوراثة "المفقودة" موجودة في آلاف المتغيرات صغيرة الأثر التي لا تبلغ فردياً عتبة الدلالة، لكنها تتراكم. الجزء المتبقي يعود إلى متغيرات نادرة لم تقسها الشرائح، وإلى تفاعلات معقدة.

سوء فهم خطير

أكبر خطأ يقع فيه الناس: الظنّ أنّ $h^2 = ٨٠\%$ يعني أنّ ٨٠٪ من طولك جاء من جيناتك. هذا خطأ تامّ. معامل الوراثة يتحدّث عن التباين بين الناس في مجموعة، لا عن الفرد. طولك أنت ناتج عن جيناتك وبيئتك معاً بشكلٍ لا ينفصل. كذلك معامل الوراثة ليس حتميةً جينية: صفةٌ عاليةُ الوراثة قد تتغيّر

تماماً بتغيّر البيئة (مثالٌ كلاسيكيّ: الطولُ عاليُ الوراثة، ومع ذلك ازداد متوسطُ الأطوال جيلًا بعد جيلٍ بسبب تحسّن التغذية).

التفاعل بين الجين والبيئة

التباينُ ليس مجردَ جمعٍ بسيطٍ لجينٍ وبيئةٍ؛ هناك تفاعلٌ بينهما (gene $\times$ environment). قد يكون لمتغيّرٍ جينيّ أثرٌ قويٌّ في بيئةٍ وضعيفٍ في أخرى. مثالٌ شهير: متغيّراتٌ تزيد خطرَ السمنة يظهر أثرها بقوةٍ في بيئةٍ غنيةٍ بالطعام، ويكاد يختفي في بيئةٍ شحيحة.

مكونات التباين

نفكّك التباينَ الجينيّ إلى ثلاثة مكونات: الجمعيّ (additive)، أثرُ كلِّ أليلٍ يُجمع)، والسيادي (dominance)، تفاعلُ الأليلين في الموضع نفسه)، والتفوّقيّ (epistatic)، تفاعلُ مواضع مختلفة). عملياً، يهيمن المكوّنُ الجمعيّ على معظم الصفات المعقّدة، ولهذا تركّز معظمُ نماذج GWAS ودرجات الخطر عليه.

أرقامٌ واقعية

من المفيد حفظُ هذه التقديرات التقريبية لمعامل الوراثة: الطول $\approx 0.80\%$ ، السكرّي من النوع الثاني $\approx 0.40\%$ ، الفصام $\approx 0.80\%$ ، التحصيل الدراسي $\approx 0.40\%$ -

٥٠٪. لاحظ أنَّ الصفات السلوكية والمعرفية لها معاملُ وراثَةٍ معتبرٌ، لكنّه دائماً أقلُّ من ١٠٠٪، ما يترك مساحةً واسعةً للبيئة.

من بحثي: في دراستنا لتدهور وظيفة الكلى في مجموعةٍ من مرضى القصور الكلويّ المزمن (CKD) بجامعة ميشيغان، قدّرنا معاملَ الوراثة لمعدّل تدهور الترشيح الكلبيّ. وجدنا تقديراً تمثيلاً في حدود $sh^2 \approx 0.3-0.4$ — أي إنّ نحو ثلثٍ إلى رُبع الاختلاف بين المرضى في سرعة تدهور الكلى يُعزى إلى عواملٍ جينية، والبقية لعواملٍ بيئيةٍ وسريّة (السكري، ضغط الدم، العلاج). هذا الرقمُ يوجّه قرارنا: الجيناتُ مهمّة لكنها ليست القدر، وثمة مجالٌ واسعٌ للتدخل العلاجيّ.

أخطاء شائعة

تذكّر دائماً: معامل الوراثة خاصيّةٌ لمجموعةٍ لا فرد، ويعتمد على البيئة فيتغيّر بتغيّرها، ولا يعني الحتمية. الخلطُ في أيٍّ من هذه الثلاثة هو أصلُ معظم الجدل المُضلل حول "جينات الذكاء" أو "جينات الإجرام".

الفصل الثامن: درجات الخطر متعدّد الجينات: التنبؤ بالمرض من آلاف المتغيرات

﴿وَمَا تَدْرِي نَفْسٌ مَّاذَا تَكْسِبُ غَدًا﴾

— سورة لقمان: ٣٤

علم الغيب لله وحده؛ لا تدري نفس ماذا تكسب غداً. ودرجات الخطر متعدّد الجينات لا تدعي علم الغيب، بل تقدّم احتمالاً مبنياً على ما نعرفه من الجينوم — تقديراً للهيل، لا حكماً قطعاً بالقدر. هذا التمييز جوهر الفصل: أن نفهم ما نستطيع هذه الدرجات قوله، وما لا نستطيع.

الفكرة

عرفنا في الفصل السابق أنّ معظم الصفات المعقّدة تتشكّل من آلاف المتغيرات صغيرة الأثر. فكرة درجة الخطر متعدّد الجينات (Polygenic Risk Score، أو PRS) بسيطة ومباشرة: بدلاً من النظر إلى متغير واحد، اجمع آثار آلاف المتغيرات معاً لتحصل على رقم واحد يلخص الميل الجيني للفرد نحو مرض أو صفة.

الصيغة

تُحسب درجة الخطر لكل شخص بضرب عدد نسخ أليل الخطر في كل موضع بمعامل تأثيره، ثم جمع الحاصل عبر كل المواضع:

$$\text{PRS} = \sum_{i=1}^N \beta_i \times G_i$$

حيث β_i معامل تأثير المتغير i (مأخوذ من نتائج GWAS)، و G_i عدد نسخ أليل الخطر لدى الشخص (٠ أو ١ أو ٢)، و N عدد المتغيرات (قد يبلغ مليوناً).

كيف تُبنى درجة الخطر؟

تمرّ عملية البناء بثلاث خطوات: أولاً، نأخذ الإحصاءات الموجزة (summary statistics) من دراسة GWAS كبيرة — أي معاملات التأثير β لكل متغير. ثانياً، نُجري تشذيباً وتجميعاً (LD pruning/clumping) لإزالة المتغيرات المترابطة عبر LD حتى لا نعدّ الإشارة نفسها مرّتين. ثالثاً، نختار عتبةً لقيمة p (مثلاً نضمّ كل متغير بـ p أصغر من ٠.٠٠١، أو نضمّ كل المتغيرات بأوزانٍ متدرّجة باستخدام طرقٍ حديثة مثل LDpred).

مثال محسوب: درجة من ٥ متغيرات لخطر السكري

لنبن درجةً مبسّطةً من ٥ متغيرات لخطر السكري من النوع الثاني. الجدول يبين معامل التأثير (بصيغة لوغاريتم نسبة الأرجحية) وعدد نسخ أليل الخطر لدى مريضٍ افتراضيٍّ:

المتغير معامل التأثير β عدد نسخ الخطر G الحاصل $\beta \times G$

المتغير ١ ٠.٢٠ ٢ ٠.٤٠

المتغير ٢ ٠.١٥ ١ ٠.١٥

المتغير ٣ ٠.٣٠ ٠ ٠.٠٠

المتغير ٤ ٠.١٠ ٢ ٠.٢٠

المتغير ٥ ٠.٢٥ ١ ٠.٢٥

$$\text{نجم: PRS} = ٠.٢٥ + ٠.٢٠ + ٠.٠٠ + ٠.١٥ + ٠.٤٠ = ١.٠٠$$

هذا الرقمُ بحدّ ذاته لا معنى له منفرداً؛ معناه يأتي من مقارنته بتوزيع الدرجات في السكّان. فإذا كان متوسطُ السكّان ٠.٦٠ وانحرافُهم المعياري ٠.٢٠، فإنّ درجةً مريضنا (١.٠٠) تقع عند انحرافين معياريين فوق المتوسط — أي ضمن الشريحة العليا في الخطر. ثمّ تتخيّل هذه العملية مكررةً لا على ٥ متغيرات بل على مليون متغيرٍ، فتكتمل الصورة.

تقييم درجة الخطر

كيف نعرف أنّ درجةً ما "جيدة"؟ بمقاييس عدّة: AUC (المساحة تحت منحنى ROC، تقيس قدرة التمييز بين المرضى والأصحاء؛ ٠.٥ تعني صدفةً محضة و ١.٠ تعني تمييزاً مثاليًا)، و R^2 (نسبة التباين المُفسّر للصفات المتّصلة)، ونسبة الأرجحية لكل انحرافٍ معياري (كم يزيد خطرُ المرض مع كلّ زيادة بمقدار انحرافٍ معياري في الدرجة).

الوعد السريريّ

الوعدُ مغزٍ: تصنيفُ المرضى حسب خطرهم الجينيّ قبل ظهور المرض. تخيّل أن نعرف أنّ شاباً في العشرين يقع في أعلى ٢٪ من خطر السكريّ جينياً، فنبدأ معه التدخّل الوقائيّ مبكراً (حمية، رياضة، متابعة) قبل عقودٍ من احتمال ظهور المرض. هذا هو حلمُ الطبّ الوقائيّ الدقيق.

القيد الكبير: مشكلة التنوّع

لكنّ هناك قيداً خطيراً يجب أن يُذكر بصراحة: درجات الخطر المبنية على دراسات GWAS أوروبية (وهي الغالبة الساحقة) تؤدّي أداءً ضعيفاً في الشعوب الأفريقية والآسيوية والعربية. السببُ مرّكب: اختلافُ بنية LD بين الشعوب (الفصل الرابع)، واختلافُ تواترات الأليلات، واختلافُ البيئات.

وهذا يعني أنّ نقلَ درجةٍ أوروبيةٍ إلى مريضٍ عربيٍّ قد يعطي تقديرًا مُضللًا. هذه "مشكلة التنوع" من أخطر التحديات الأخلاقية في المجال اليوم.

من بحثي: أستخدم درجات الخطر متعدّد الجينات في التنبؤ بخطر أمراض الكلى في جامعة ميشيغان. الوعدُ حقيقيّ: في بيانات ذات أصلٍ أوروبيّ، تضيف الدرجةُ قدرةً تنبؤيةً فوق العوامل السريرية التقليدية (العمر، السكري، ضغط الدم). لكنني أتعامل معها بحذرٍ شديد، خاصةً حين يتعلّق الأمر بمرضى من أصولٍ غير أوروبية، لأنّ الأداء يتدهور. درسي العمليّ: الدرجةُ أداةٌ مساعدة، لا بديلٌ عن الحكم السريريّ، ولا تصلح للنقل الأعمى بين الشعوب.

أخطاء شائعة

من الأخطاء: تفسيرُ درجةٍ عاليةٍ على أنّها "حكمٌ بالمرض" (بينما هي ميلٌ احتماليّ)، ونقلُ درجةٍ مبنيةٍ على شعبٍ إلى شعبٍ آخر دون تحقّق، ونسيانُ أنّ العوامل البيئية والسريرية قد تفوق الجينَ أثرًا في كثيرٍ من الأمراض. درجةُ الخطر تُخبرك بالميل، لا بالمصير — ﴿وَمَا تَدْرِي نَفْسٌ مَّاذَا تَكْسِبُ غَدًا﴾.

الفصل التاسع: الهابلوتايب والفازينج: قراءة نسختي الجينوم

﴿وَجَعَلْنَاكُمْ شُعُوبًا وَقَبَائِلَ لِتَعَارَفُوا﴾

— سورة الحجرات: ١٣

جعلنا الله شعوباً وقبائل، والقبيلة سلسلة نسب تُورث متصلة. وفي الجينوم نظير لهذا النسب: الهابلوتايب (haplotype)، وهو سلسلة أليلات تُورث معاً على كروموسوم واحد، كأنها "قبيلة" جينية. هذا الفصل يعلّمك كيف نقرأ كل نسخة من نسختي الجينوم على حدة.

المشكلة

حين نقيس النمط الجيني لشخصٍ عند موضعين متجاورين، نخبرنا الشريحة مثلاً أنّه متغيّر في الموضعين: عنده A/a في الأوّل و B/b في الثاني. لكنّها لا نخبرنا أيّ أليل على أيّ كروموسوم. هل A و B معاً على الكروموسوم الأبويّ (a و b على الأموميّ)؟ أم A مع b، و a مع B؟ هذا الغموض يُسمّى عدم معرفة الطور (phase). فالنمط الجينيّ يخبرك بما تملك، لا بكيفية توزّعه على النسختين.

الهابلوتايب ولماذا مهم

الهابلوتايب هو التركيبة المحددة للأليلات على كروموسوم واحد. معرفته مهم في حالات عدة. مثلاً في التغاير المركب (compound heterozygosity): قد يحمل مريضٌ طفرتين ضارّتين في الجين نفسه؛ فإن كنا على كروموسومين مختلفين (واحدة على كل نسخة) تعطلت نسختا الجين معاً وظهر المرض، أما إن كنا على الكروموسوم نفسه فالنسخة الأخرى سليمة وقد لا يظهر المرض. الفرق بين الحالتين مصيريّ، ولا يتضح إلا بمعرفة الطور. كذلك تحليل منطقة HLA المناعية يعتمد كلياً على الهابلوتايبات.

الفازينج الإحصائيّ

كيف نستنتج الطور إن كانت الشريحة لا تعطيه؟ بـ الفازينج الإحصائيّ (statistical phasing): نستغل أنماط LD في السكّان (الفصل الرابع). الفكرة الجوهرية: بعض تركيبات الأليلات (الهابلوتايبات) شائعة في السكّان وأخرى نادرة. فإذا كان لدى شخص غموض بين تفسيرين، نرّجح التفسير الذي يُنتج هابلوتايبات شائعة في السكّان. تكرر الخوارزمية هذا الاستدلال عبر ملايين المواضع وآلاف الأشخاص في آن واحد، فتبني خريطة متّسقة للأطوار. (لا نحتاج هنا إلى اشتقاق رياضيّ؛ يكفي فهم المبدأ: السكّان مرجعٌ نستدلّ به على الفرد.)

لوحات المرجع

تعتمد دقة الفازينج على لوحات المرجع (reference panels): مجموعات ضخمة من الجينومات المعروفة الأطوار. أشهرها مشروع الجينومات الألف (1000 Genomes) والبنك الحيوي البريطاني (UK Biobank)، بمئات الآلاف من المشاركين). تستخدم برمجيات الفازينج (مثل SHAPEIT و Eagle) هذه اللوحات مرجعاً: كلما كان المرجع أكبر وأقرب لأصل الشخص، زادت دقة الاستنتاج. وهنا تظهر مشكلة مألوفة: المراجع غنية بالأوروبيين وفقيرة بالعرب، فدقة الفازينج للعرب أقل.

أحياء الهابلوتايب

تتجمع المواضع المترابطة في أحياء هابلوتايب (haplotype blocks): مناطق على الكروموسوم تنتقل ككتلة واحدة نادراً ما تكسر إعادة التركيب. تُحدد هذه الأحياء بتحليل أنماط LD، وهي الوحدات الطبيعية التي يُفكر بها في كثير من التحليلات بدلاً من المتغيرات المفردة.

منطقة HLA: الأصعب والأغنى

أكثر مناطق الجينوم تنوعاً على الإطلاق هي منطقة HLA (مستضدات الكريات البيض البشرية) على الكروموسوم ٦. هذه المنطقة مسؤولة عن التعرف

المناعيّ (تمييز الذات من غير الذات)، وفيها مئات الأليّلات لكلّ جين. تنوعها الهائل يجعلها صعبةً الفازينج والتحليل، لكنّها بالغة الأهميّة: مرتبطةٌ بأمراض المناعة الذاتية، وتتوافق زراعة الأعضاء، وبلاستجابة لبعض الأدوية. تحليلُ HLA فنٌّ قائمٌ بذاته يعتمد على هابلوتايباتٍ مرجعيةٍ متخصّصة.

مثال واقعيّ

من بحثي: في تحليل منطقةٍ مرتبطةٍ بخطر السكري قرب جينٍ يؤثّر في إفراز الإنسولين، لم يكن يكفي أن نعرف أنّ المريض يحمل متغيّرين متغيّرين. كان السؤال الحاسم: هل أليلا الخطر يقعان على الهابلوتايب نفسه (فيتضافر أثرهما) أم على هابلوتايبين متقابلين؟ بإجراء الفازينج، استطعنا أن نحدّد الهابلوتايب السببيّ — التركيبة المحدّدة التي تحمل أعلى خطر — بدلاً من التعامل مع المتغيّرات منفصلة. هذا التمييز غير تفسيرنا لآلية البيولوجية. وفي عملنا على الكلى، نلجأ إلى الفازينج حين نريد ربط متغيّر تنظيميّ بجينٍ مستهدفٍ معيّن على النسخة نفسها.

أخطاء شائعة

من الأخطاء الشائعة: التعاملُ مع نتائج الفازينج وكأنّها يقينٌ تامّ، بينما هي استنتاجٌ احتماليٌّ قد يخطئ، خاصّةً للأليات النادرة أو في الشعوب ضعيفة التمثيل في لوحات المرجع. وخطأٌ آخر: الخلطُ بين النمط الجينيّ (ما تملك) والهابلوتايب (كيف يتوزّع)؛ فالأوّل يُقاس مباشرةً، والثاني غالباً يُستنتج. حين يُذكر هابلوتايبٌ في ورقةٍ علمية، اسأل دائماً: أقيس مباشرةً (بتسلسلٍ عائليٍّ) أم استنتج إحصائياً؟ فدرجةُ ثقتك تختلف بحسب الجواب.

الفصل العاشر: التحكم في الخلط: السكّان والعوامل المربكة

﴿إِنَّ اللَّهَ يَأْمُرُ بِالْعَدْلِ وَالْإِحْسَانِ﴾

— سورة النحل: ٩٠

أمر الله بالعدل، والعدل في العلم أن نقارن الأشياء المتكافئة، وآلا ننسب أثراً إلى سببٍ وهمي. أخطر ما يفسد العدل في دراسات الارتباط هو الخلط (confounding): أن نظنّ متغيّراً مرتبطاً بالمرض، بينما الرابط الحقيقي شيء آخر تماماً. هذا الفصل يعلمك كيف تحرس تحليلك من الظلم الإحصائي.

مشكلة الخلط

تخيّل دراسةً عن مرضٍ ما، صودف أنّ معظم المرضى فيها من أصلٍ أوروبيٍّ ومعظم الأصحاء من أصلٍ أفريقيٍّ. الآن، أيُّ متغيّرٍ جينيٍّ يختلف تواتره بين الأوروبيّين والأفارقة سيظهر مرتبطاً بالمرض — لا لأنّه يسبّبه، بل لأنّه يميّز المجموعتين السكانيّتين أصلاً. هذا متغيّرٌ بريءٌ أتهم ظلماً، الرابط الحقيقي هو الأصلُ السكّاني، لا المرض.

التقسيم السكانيّ

هذه الظاهرة تُسمى التقسيم السكانيّ (population stratification): وجودُ بنيةٍ سكانيةٍ خفيةٍ في العينة تُحدِث ارتباطاتٍ زائفة، أثرها العمليّ أنّها تُضخّم نتائج GWAS بأكملها — يرتفع منحني Q-Q من بدايته (الفصل الخامس)، ويتجاوز معاملُ لامبدا ١٠٠ بوضوح. قد ينتج عن اختلاطٍ سكانيّ غير مضبوطٍ عشرات "الاكتشافات" الكاذبة التي لا علاقة لها بالبيولوجيا.

تحليل المكونات الرئيسية في الجينات

أهمُّ أداةٍ لكشف هذه البنية ومعالجتها هي تحليل المكونات الرئيسية (Principal Component Analysis، أو PCA). الفكرة: نأخذ ملايين الـ SNP ونلخّص التباينَ الجينيّ بينها في عددٍ قليلٍ من "المكونات" التي تلتقط أكبر قدرٍ من الاختلاف. والمدهش أنّ هذه المكونات تلتقط الأصلَ الجغرافيّ بدقّةٍ عجيبة.

كيف تبدو لوحة PCA للشعوب؟

حين نرسم المكوّن الأوّل (PC1) على محورٍ والثاني (PC2) على آخر، لكلِّ شخصٍ نقطة، فإنّ النقاطَ تتجمّع حسب القارّة: الأوروبيون في زاوية، والأفارقة في أخرى، وشرقُ آسيا في ثالثة. بل إنّ الخريطةَ الجينية الناتجة تشبه خريطة أوروبا الجغرافية بشكلٍ مذهلٍ (دراسةٌ شهيرة بعنوان "الجينات تعكس

الجغرافيا). فالمكوّنات الأولان غالباً يفصلان القارّات، والمكوّنات التالية تلتقط تباينات أدقّ داخلها.

إدخال المكوّنات كمتغيّرات ضابطة

كيف نستفيد من هذا في التصحيح؟ ندخل المكوّنات الرئيسية متغيّراتٍ مشتركة (covariates) في نموذج الانحدار. أي بدلاً من:

$$\text{\text{\$}\text{\$}}\{\text{النمط الجيني}\}\sim \text{\text{\$}\text{\$}}\{\text{المرض}\}\text{\text{\$}\text{\$}}$$

نكتب:

$$\text{\text{\$}\text{\$}}\{\text{المرض}\}\text{\text{\$}\text{\$}}\sim \text{\text{\$}\text{\$}}\{\text{النمط الجيني}\} + \text{PC}_1 + \text{PC}_2 + \dots + \text{\text{\$}\text{\$}}\{\text{PC}_{10}\}$$

بهذا "نطرح" أثر الأصل السكانيّ، فلا يبقى إلّا الارتباط الحقيقيّ بالمتغيّر. كم مكوّنًا ندخل؟ كثيرٌ من الدراسات تستخدم نحو ١٠ مكوّنات: عددٌ كافٍ لالتقاط البنية الكبرى، دون إفراطٍ يبدّد قوّة التحليل بإضافة متغيّراتٍ لا تحمل إشارةً سكانيةً.

النماذج المختلطة الخطية

هناك نهج أكثر تطوراً: النماذج المختلطة الخطية (Linear Mixed Models)، أو (LMM)، تطبقها برمجيات مثل BOLT-LMM و SAIGE و REGENIE. تحلّ هذه النماذج مشكلتين دفعةً واحدة: التقسيم السكانيّ والقرابة الخفية بين المشاركين (أقارب في العينة دون أن ندري). تفعل ذلك بإدماج مصفوفة العلاقات الجينية في النموذج. صارت هذه النماذج معياراً في البنوك الحيوية الكبرى لأنها تتعامل مع مئات الآلاف من العينات بكفاءة.

مثال محسوب: قبل وبعد تصحيح المكونات

لنتخيل بيانات محاكاة فيها تقسيم سكاني. لنفترض أننا اختبرنا متغيراً لا أثر له حقيقياً على المرض، لكنّ تواتره يختلف بين مجموعتين سكانيّتين مختلطتين في العينة:

• قبل التصحيح: يعطي الانحدار البسيط قيمة $p = 1 \times 10^{-9}$ (دلالة "جينومية" زائفة!)، ومعامل لامبدا الكلي للدراسة = 1.025 (تضخم واضح).

• بعد إدخال 10 مكونات رئيسية: يصبح $p = 0.04$ (لا دلالة، كما ينبغي)، ويهبط لامبدا إلى 1.002 (سليم).

هذا الفرقُ الدراماتيكيّ يوضح لماذا يُعدّ تصحيحُ المكوّنات الخطوةَ الأهمّ في ضبط جودة أيّ GWAS. متغيّرُ بدا "اكتشافاً مثيراً" تجرّ تماماً بمجرد أن عاملنا المجموعتين بعدل.

من بحثي: في كلّ نموذج GWAS نبنيه لأمرض الكلى في جامعة ميشيغان، ندخل ١٠ مكوّناتٍ رئيسيةً افتراضياً. لماذا لا أكثر؟ لأنّ المكوّنات بعد العاشر غالباً تلتقط ضوضاءً لا بنيةً سكانية، فتُضعف التحليلَ دون فائدة. ولماذا لا أقلّ؟ لأنّ مجموعتنا متعدّدةُ الأصول، والاكتفاءُ بمكوّنين أو ثلاثة يترك بنيةً دقيقةً غير مضبوطة. القاعدةُ عندنا: اخفض لوحةَ PCA ومعاملَ لامبدا، وعدّل عددَ المكوّنات حتى يستقرّ لامبدا قرب ١٠٠.

أخطاء شائعة

أخطرُ خطأ: تجاهلُ التصحيح السكّاني كلياً، فتُنشر "اكتشافات" هي محض آثار سكانية. وخطأٌ مقابل: الإفراطُ في إدخال مكوّناتٍ كثيرة جداً، ما يبدّد القوةَ الإحصائية. والعدلُ — كما أمرت الآية — في الوسط: اضبط ما يجب ضبطه، ولا تُسرف.

الفصل الحادي عشر: تفسير النتائج: من الارتباط إلى الوظيفة

﴿أَفَلَا يَتَذَكَّرُونَ الْقُرْآنَ أَمْ عَلَى قُلُوبٍ أَقْفَالُهَا﴾

— سورة محمد: ٢٤

التدبرُ غيرُ القراءة؛ القراءةُ أن ترى الحروف، والتدبرُ أن تفهم المعنى وراءها. ودراسةُ GWAS تعطيك "الحروف": مواضعَ مرتبطةٍ إحصائيًا. أمّا "التدبر" — الانتقالُ من الارتباط إلى الآلية البيولوجية — فهو الفصلُ الأصعب والأمتع، وهو ما نخصّص له هذا الباب.

الفجوة

نتيجةُ GWAS ليست جيناً ولا آلية؛ هي منطقةٌ كروموسومية قد تمتدّ على مئات الآلاف من القواعد وتضمّ عدّة جينات وعشرات المتغيّرات في LD شديد. كيف ننتقل من "هذه المنطقة مرتبطة بالمرض" إلى "هذا الجين، عبر هذه الآلية، يسبّب هذا الأثر"؟ هذه هي الفجوة التي تسدّها سلسلةٌ من الأدوات التحليلية.

التخريط الدقيق

الخطوة الأولى التخريط الدقيق (fine-mapping): تضيق المنطقة من مئة متغيرٍ مرشحٍ إلى المتغيرات الأرجح سببياً (عادةً ١ إلى ٥). تستخدم طرقٌ مثل SuSiE وFINEMAP نماذجَ احتمالية لتقدير "احتمال أن يكون كلُّ متغيرٍ هو السببي"، أخذةً بنية LD في الحسبان. النتيجة "مجموعة ثقة" (credible set) صغيرة تركز عليها بقية التحليل.

التعليق الوظيفي

ثمّ نسأل: أين يقع المتغيرُ المرشح؟ هذا التعليق الوظيفي (functional annotation). هل هو في منطقة مُشفرةٍ للبروتين (فيغير تسلسل الأحماض الأمينية مباشرة)؟ أم في مُعزّز (enhancer) أو مُحفّز (promoter) ينظم التعبير؟ أدواتٌ مثل Ensembl VEP (تنبأً بأثر المتغير) وENCODE (تُعلم المناطق التنظيمية) وGTEx (تربط المتغيرات بالتعبير) تساعد على وضع المتغير في سياقه الوظيفي. وكما ذكرنا سابقاً، معظم متغيرات GWAS تنظيمية لا مُشفرة.

تحليل eQTL

سؤال محوري: هل يؤثر المتغير في مقدار تعبير جينٍ ما؟ إن كان كذلك، فهو eQTL (موضع صفة كمية تعبيرية، expression Quantitative Trait)

(Locus). قاعدة بيانات GTEx هي المرجع: قاست التعبير الجيني في عشرات الأنسجة البشرية، فتُخبرك أي متغير يرفع أو يخفض تعبير أي جين في أي نسيج. فإذا وجدنا أنّ متغير GWAS لأمراض الكلى هو eQTL لجين معين في نسيج الكلى تحديداً، اقتربنا من الآلية.

التوضع المشترك

لكنّ التزامن ليس كافياً. قد يكون في المنطقة متغير يسبب المرض وآخر منفصل يؤثر في التعبير، وهما في LD يخدعان الناظر. لذا نُجري التوضع المشترك (colocalization، بطريقة coloc): اختبار إحصائي يسأل: هل إشارة GWAS وإشارة eQTL تتشاركان المتغير السببي نفسه؟ إن كان الجواب نعم باحتمال عالٍ، قوِي الدليل على أنّ المرض يعمل عبر تغيير تعبير ذلك الجين.

العشوائية المندلية

أداةً أنيقة أخرى: العشوائية المندلية (Mendelian Randomization، أو MR). الفكرة تشبه التجربة الطبيعية: بما أنّ الأليلات تُوزع عشوائياً عند التكوين (كأنّها قرعة زهية)، يمكن استخدام متغير جيني "متغيراً أداتياً" (instrumental variable) لاختبار علاقة سببية. مثال: هل ارتفاع الكوليسترول يسبب مرض القلب أم مجرد مرافق له؟ نستخدم متغيرات تؤثر في الكوليسترول كأداة، فإذا ارتبطت هذه المتغيرات بمرض القلب، قوِي الاستدلال السببي — لأنّ الجينات

لا "تختار" نمط الحياة، فهي محصنةٌ من كثيرٍ من الخلط. شَبَّها بتجربةٍ سريريةٍ عشوائيةٍ أجرتها الطبيعةُ عند الولادة.

خطُّ أنابيب متكامل

من بحثي: هذا بالضبط مسارُ عملنا في جامعة ميشيغان لمتغيّرٍ من متغيّرات الكلى. نبدأ بإشارة *GWAS* قويّةٍ في منطقةٍ ما. نُخرطها دقيقاً (*SuSiE*) فتنحصر في بضعة متغيّرات. نفحصها في *GTEx* فنجد أنّ أحدها *eQTL* لجينٍ معيّنٍ في نسيج الكلى. نُجري التوضع المشترك فيؤكّد أنّ إشارة المرض وإشارة التعبير تشاركان المتغيّر السببي نفسه. وهكذا ننقل من "منطقة غامضة" إلى جينٍ مستهدفٍ محدّد، يصلح فرضيةً للتجربة المخبرية اللاحقة. منطقة *UMOD* الكلوية مثالٌ كلاسيكيّ نجح فيه هذا المسار، إذ رُبط المتغيّر التنظيمي بتعبير الجين ثمّ بوظيفة الكلى.

قراءة مخطط Locus Zoom

أداةُ العرض الأساسية هنا هي مخطط **Locus Zoom**. على المحور الأفقيّ: الموضعُ على الكروموسوم. على الرأسيّ: $-\log_{10}(p)$. كلُّ نقطةٍ متغيّر، ويُلَوّن بحسب قوّة *LD* مع المتغيّر الرائد (الأحمر = *LD* عالٍ، الأزرق =

منخفض). أسفل المخطط مسار الجينات يبين أين تقع الجينات. قراءته تخبرك بلوحة: أين الإشارة، ولم تمتد، وأي الجينات قريبة، وأي المتغيرات في حي واحد.

أخطاء شائعة

من الأخطاء: افتراض أن أقرب جين للإشارة هو الجين السببي — وهذا كثيراً ما يخطئ، فالمعزّزات قد تؤثر في جينات بعيدة. وخطأ آخر: الخلط بين التزامن (متغير هو eQTL وقريب من إشارة المرض) والتموضع المشترك (المتغير السببي نفسه) — فالأول دليل ضعيف، والثاني قوي. التدبر الحق لا يقف عند أول ارتباط يلمع.

الفصل الثاني عشر: الخاتمة: الأدوات والموارد والطريق إلى الأمام

﴿قُلْ هَلْ يَسْتَوِي الَّذِينَ يَعْلَمُونَ وَالَّذِينَ لَا يَعْلَمُونَ﴾

— سورة الزمر: ٩

سؤال قرآني لا يحتاج إلى جواب: لا يستوي العالم والجاهل. وأنت الآن، بعد أحد عشر فصلاً، لم تعد كما بدأت. هذا الفصل يجمع الخيوط، ويضع بين يديك صندوق الأدوات والموارد، ويرسم الطريق إلى الأمام — خاصةً للباحث العربي.

خريطة الرحلة كاملة

لنستعرض خط سير العمل في علم الوراثة الإحصائية من بدايته إلى نهايته. نبدأ بـ القياس الجيني (genotyping) لآلاف الأشخاص. ثم نُجري ضبط الجودة: مرشح هاردي-واينبرغ (الفصل الثالث)، واستبعاد المتغيرات النادرة (الفصل الثاني). ثم نصحّح التقسيم السكاني بتحليل المكونات الرئيسية (الفصل العاشر). بعدها نُجري اختبار الارتباط متغيراً متغيراً بالانحدار (الفصل الخامس)، ونصحّح الاختبارات المتعددة بـ 10×5 (الفصل السادس). نعرض النتائج في مخطط مانهاتن، ونتحقق من Q-Q ولا مبداء. ثم ننتقل من الارتباط إلى الوظيفة

بالتخريط الدقيق وتحليل eQTL والتوضع المشترك (الفصل الحادي عشر).
وبالتوازي، نبني درجات الخطر للتنبؤ (الفصل الثامن). هذه هي الرحلة من
الحرف إلى البيولوجيا.

صندوق الأدوات للمبتدئين

هذه البرمجيات الأساسية التي ستحتاجها، وكلُّها مجانية:

- **PLINK** – أداة ضبط الجودة واختبار الارتباط الأكثر شهرة؛ نقطة البداية لكل مبتدئ.
- **R** مع **ggplot2** – للتحليل الإحصائي والرسوم (مخططات مانهاتن و (Q-Q).
- **SAIGE** و **REGENIE** – لتحليل GWAS واسع النطاق بالنماذج المختلطة في البنوك الحيوية الكبرى.
- **LDpred** و **PRSice** – لبناء درجات الخطر متعدد الجينات.
- **SuSiE** و **FINEMAP** – للتخريط الدقيق.
- **coloc** – لاختبار التوضع المشترك.

موارد البيانات

البيانات الكبرى أصبحت في متناول الباحثين (بعد إجراءات الوصول المعتادة):

- UK Biobank – نصف مليون مشارك بيانات جينية وصحية غنية.
- dbGaP – مستودع أمريكي لدراسات جينية كثيرة.
- GWAS Catalog – فهرس لكل نتائج GWAS المنشورة؛ مرجعك الأول للبحث عما اكتشف.
- GTEx – قاعدة التعبير الجيني في الأنسجة البشرية (لتحليل eQTL).
- gnomAD – أضخم مرجع لتواترات المتغيرات عبر الشعوب.

موارد التعلم

للتعمق، أنصح بالبدء بدروس معهد Broad (تتلمذ مواد تدريبية مجانية)، ودورات Coursera في الوراثة الإحصائية والمعلوماتية الحيوية، وقراءة الأوراق المرجعية الكلاسيكية (انظر فصل المراجع). اقرأ أوراق GWAS الكبرى وتبّع أشكالها خطوة بخطوة كما تعلّمت في هذا الكتاب؛ فلا شيء يعلم مثل تشرّح ورقة حقيقية.

فجوة الجينوم العربيّ

هنا لبُ رسالتي. أكثرُ من ٩٠٪ من المشاركين في دراسات GWAS الكبرى من أصلٍ أوروبيّ. الشعوبُ العربيةُ — رغم تنوّعها الجينيّ الثريّ وتاريخها العريق وأثماطها الفريدة من زواج الأقارب التي تجعلها كنزاً علمياً — غائبةٌ تقريباً عن هذه الخرائط. وقد رأينا في الفصلين الرابع والثامن أنّ هذا الغياب ليس مجرد نقصٍ في التمثيل، بل خللٌ عمليّ: درجاتُ الخطر والاكتشافاتُ الأوروبية لا تنتقل بدقةٍ إلى مرضانا. فالفجوةُ فجوةٌ عدالةٍ صحيّة، لا مجردَ فضول.

ندائي إلى الباحثين العرب

الأدواتُ مجانية، والبياناتُ تزايدت، والفرصةُ هائلة. لا يحتاج الباحثُ العربيُّ اليوم إلى مختبرٍ بمليارات الدولارات ليسهم؛ يحتاج إلى حاسوبٍ جيد، وإتقانٍ للأدوات التي عرضناها، وعيناتٍ من مجتمعه. كلُّ دراسةٍ جينيةٍ عربيةٍ صغيرة تزدحم جزءاً من الفجوة، وتقربنا من طبٍّ دقيقٍ يخدم شعوبنا لا شعوبَ غيرنا. هذا الكتاب، في جوهره، دعوةٌ إلى هذا الميدان.

ما القادم؟

المجالُ يتطوّر بسرعة. ثلاثة آفاقٍ تستحقّ المتابعة: مواضع الصفات الكميّة على مستوى الخلية المفردة (single-cell QTLs) التي تكشف أيّ نوعٍ من الخلايا

تحديداً متأثر بالمتغير، وGWAS متعدد الأصول (multiancestry) الذي يدمج شعوباً مختلفة ليزيد الدقة والعدالة؛ وتسلسل الجينوم الكامل (whole-genome sequencing) الذي يحلّ تدريجياً محلّ الشرائح، فيكشف المتغيرات النادرة التي تقلت منها. ومن هذه الأبواب — الخلية المفردة، تعدد الأصول، التسلسل الكامل — سيدخل علمُ الوراثة الإحصائية عقده القادم.

كلمة ختام

تعلمت في هذا الكتاب أن تقرأ مخطّط مانهاتن، وتفهم توازن هاردي-واينبرغ وعدم التوازن الترابطي، وتحسب درجة خطر، وتفسّر إشارة من الارتباط إلى الوظيفة. لكنّ الأهمّ أنّك صرت تنظر إلى الجينوم لا كنصّ غامض، بل كرسالة قابلة للقراءة بالعلم والصبر. والعلم رحلة لا تنتهي؛ فها هذا الكتاب إلاّ أوّل الطريق.

والله أعلم.

الفصل الثالث عشر: المراجع والقراءات الموصى بها

﴿وَقُلْ رَبِّ زِدْنِي عِلْمًا﴾

— سورة طه: ١١٤

العلمُ بحرٌ لا ساحلَ له، وهذا الكتابُ قطرةٌ منه. ما يلي قائمةٌ مختارةٌ من المراجع الأساسية والأوراق الكلاسيكية وقواعد البيانات والكتب الدراسية، رتبناها بحسب الموضوع، ليتمكن القارئُ الجادُّ من المضيَّ أبعدَ ممَّا وسعه هذا الكتاب.

كتبٌ دراسيةٌ أساسيةٌ

- *Handbook of*.Balding D., Bishop M., Cannings C. (eds) •
Statistical Genetics.Wiley. — مرجعٌ موسوعيٌّ للمجال.
- *A Statistical Approach to Genetic*.Ziegler A., König I.R. •
Epidemiology.Wiley. — مدخلٌ متوازنٌ بين النظرية والتطبيق.
- *The Fundamentals of Modern*.Laird N.M., Lange C. •
Statistical Genetics.Springer. — مناسبٌ للمستوى المتوسط.
- *Principles of Population Genetics*.Hartl D.L., Clark A.G. •
Sinauer. — المرجعُ الكلاسيكيُّ في الوراثة السكانية.

أوراق تأسيسية ومراجعات

- Visscher P.M. et al. (2017). "10 Years of GWAS •
American "Discovery: Biology, Function, and Translation
Journal of Human Genetics. — مراجعةٌ لا غنى عنها لفهم عقدٍ من
اكتشافات GWAS.
- -Bush W.S., Moore J.H. (2012). "Chapter 11: Genome •
— *PLoS Computational Biology* ".Wide Association Studies
مدخلٌ تعليميٌ ممتاز لل مبتدئين.
- Pritchard J.K., Stephens M., Donnelly P. (2000). أعمالٌ
مؤسسة في بنية السكان والاستدلال.
- Price A.L. et al. (2006). "Principal components analysis •
corrects for stratification in genome-wide association
studies". *Nature Genetics*. — الورقة التي أرست PCA في GWAS.
- Yang J. et al. (2010). "Common SNPs explain a large •
Nature ".proportion of the heritability for human height
Genetics. — أصلٌ مفهوم معامل الوراثة من ال SNP.

التخريط الدقيق والتفسير الوظيفي

- Wang G., Sarkar A., Carbonetto P., Stephens M. (2020). SuSiE: A simple new approach to variable selection in "fine-mapping". *Journal of the Royal Statistical Society B*.
- Benner C. et al. (2016). "FINEMAP: efficient variable selection". *Bioinformatics*.
- Giambartolomei C. et al. (2014). "Bayesian test for colocalisation (coloc)". *PLoS Genetics*.
- GTEx Consortium (2020). "The GTEx atlas of genetic regulatory effects across human tissues". *Science*.

درجات الخطر متعدد الجينات

- Choi S.W., Mak T.S.H., O'Reilly P.F. (2020). "Tutorial: a guide to performing polygenic risk score analyses". *Nature Protocols*. — دليل عملي خطوة بخطوة.
- Martin A.R. et al. (2019). "Clinical use of current polygenic risk scores may exacerbate health disparities". *Nature Genetics*. — مرجع جوهري في مشكلة التنوع.

أمراض الكلى وعلم الجينوم (مجال المؤلف)

- Köttgen A. et al.، ومجموعة **CKDGen Consortium** — سلسلة دراسات GWAS لوظيفة الكلى ومعدل الترشيح الكبيبي (eGFR)، التي رسّخت مواضع مثل **UMOD** و**SHROOM3**.
Genovese G. et al. (2010). "Association of trypanolytic •
ApoL1 variants with kidney disease — اكتشاف متغيرات **APOL1** المرتبطة بأمراض الكلى، وأهميتها للأصول الأفريقية.
Wuttke M. et al. (2019). "A catalog of genetic loci •
associated with kidney function — أحد أكبر تحليلات GWAS الكلوية.

قواعد البيانات والأدوات (روابط مرجعية)

- **GWAS Catalog** — www.ebi.ac.uk/gwas
- **GTEx Portal** — www.gtexportal.org
- **gnomAD** — gnomad.broadinstitute.org
- **UK Biobank** — www.ukbiobank.ac.uk
- **PLINK** — www.cog-genomics.org/plink
- **Genomes Project 1000** — www.internationalgenome.org

موارد التعلّم المفتوحة

- دروسُ معهد **Broad** التعليمية في الوراثة الإحصائية والمعلوماتية الحيوية.
- دوراتُ **Coursera** و **edX** في الجينوم والإحصاء الوراثي.
- توثيقُ برمجيات **PLINK** و **SAIGE** و **REGENIE** الرسميّ — مليّءٌ بالأمثلة التطبيقية.

ملاحظة منهجية: الأرقامُ التوضيحية الواردة في أمثلة هذا الكتاب (نسبُ فشل *HWE*، تقديراتُ معامل الوراثة لتدهور الكلي، معاملاتُ التأثير في درجات الخطر) قدّمت لأغراضٍ تعليمية وهي تمثيلية لما يُصادف في الأبحاث الواقعية، لا اقتباساتٌ من بياناتٍ بعينها. للأرقام الدقيقة، يُرجى الرجوعُ إلى الدراسات المنشورة المذكورة أعلاه، خاصةً سلسلة *CKDGen* لأبحاث الكلي.

وقل ربّ زدني علماً.

القسم الإنجليزي

English Section

Table of Contents

Chapter 1: What Is Statistical Genetics?	1
Chapter 2: Core Genetics Concepts for Beginners	2
Chapter 3: Hardy-Weinberg Equilibrium: The Foundational Law	3
Chapter 4: Linkage Disequilibrium: The Genome's Secret Language	4
Chapter 5: Genome-Wide Association Studies: The Manhattan Plot Explained	5
Chapter 6: Multiple Testing Correction: The Problem of 10 Million Tests	6
Chapter 7: Heritability: How Much Is Genetic?	7

Chapter 8: Polygenic Risk Scores: Predicting Disease from Thousands of Variants	8
--	---

Chapter 9: Haplotypes and Phasing: Reading Both Copies of the Genome	9
---	---

Chapter 10: Controlling Confounding: Population Stratification and Covariates	10
--	----

Chapter 11: Interpreting Results: From Association to Function	11
---	----

Chapter 12: Conclusion: Tools, Resources, and the Road Ahead	12
---	----

Chapter 13: References and Recommended Reading	13
--	----

Chapter 1: What Is Statistical Genetics?

﴿وَعَلَّمَ آدَمَ الْأَسْمَاءَ كُلَّهَا﴾

"And He taught Adam the names of all things." — Surah Al-Baqarah: 31

The first gift granted to humanity was the capacity to name, to classify, to know. Statistical genetics, at its core, extends that gift: it is the human attempt to read the "names" written in our genome, and to connect each letter of DNA to what it means for health, disease, and trait. This chapter lays out the central question the whole book revolves around, and draws the road map.

The Central Question

Imagine you have one million people, half affected by type 2 diabetes and half healthy. The question a statistical geneticist asks is simple to state but profound in its consequences: **which**

genetic variants make their carriers more susceptible to disease? Put differently: among three billion letters in the genome, which letters, when changed, are associated with increased disease risk? That is the heart of the field — finding the genetic variants that influence disease, traits, and biology, using the tools of statistics.

The Scale Challenge

What makes this question hard is not its obscurity but its **size**. The human genome contains roughly 3 billion base pairs. Among those billions, about 8 million common variants differ between people. If you want to test each variant separately for association with disease, you face millions of statistical tests in a row. Imagine searching for a needle in a haystack — but the haystack is the size of a mountain, the needles may number in the dozens rather than just one, and some are counterfeit. This challenge — the combination of enormous scale and weak signal — is exactly what makes statistics a necessity rather than a luxury.

The Three Pillars

Statistical genetics rests on three pillars:

First: population genetics — the study of how genetic variants spread across generations and peoples, and why a variant is common in one population and rare in another. This pillar gives us laws like Hardy-Weinberg equilibrium (Chapter 3) and linkage disequilibrium (Chapter 4).

Second: quantitative genetics — which links variants to measurable traits: height, blood pressure, glucose level. This pillar gives us heritability (Chapter 7) and polygenic risk scores (Chapter 8).

Third: statistical inference — the tool with which we test hypotheses: is this association real, or pure chance? This pillar gives us regression, the p-value, and multiple-testing correction (Chapter 6).

What Statistical Genetics Is NOT

To understand the field, it helps to know what it is **not**. Statistical genetics is not molecular biology (which studies how genes work mechanically inside the cell), not genetic counseling (which guides families about hereditary risk), and not clinical medical genetics (which diagnoses rare diseases). It is the **mathematical language** that connects all of them. When a statistical geneticist discovers a variant associated with disease, the molecular biologist takes that variant to understand its mechanism, and the physician takes the result to improve diagnosis. The field is a bridge, not an island.

Real Applications

This science is far from purely theoretical. It has uncovered dozens of genes associated with diabetes; it builds models that predict cancer risk before onset; and it has let scientists trace the history of human migration across continents by reading variant patterns in different populations. All these achievements

were born from one idea: that small differences in DNA carry large information — if only we read them statistically well.

My Own Entry Point

I entered this field through a practical door. At the University of Michigan, I was searching for biomarkers of chronic kidney disease. The question was: why does kidney function decline faster in some patients than in others? Because part of the answer is genetic, I turned to genome-wide association studies (GWAS). I still remember the first time I looked at a "Manhattan plot" — that figure full of dots resembling a city skyline — and understood nothing of it. This book is, in part, the book I wish I had found that day.

How is this used in real research? When we began analyzing genetic data from hundreds of patients with chronic kidney failure, the goal was not merely to find a gene, but to build a predictive tool helping the physician know which

patient needs closer follow-up. That is the practical promise of the field: turning letters into decisions.

What This Book Assumes and Covers

This book assumes you know the basics of statistics — mean, variance, p-value — but assumes no background in genetics. We start from core genetics concepts (Chapter 2), then build layer upon layer: population laws, association studies, error correction, risk prediction, and result interpretation. By the journey's end, you should be able to read a GWAS paper, interpret a Manhattan plot, understand polygenic scores, and run basic association tests yourself. Let us begin.

Chapter 2: Core Genetics Concepts for Beginners

﴿وَفِي أَنْفُسِكُمْ أَفَلَا تُبْصِرُونَ﴾

"And within yourselves. Then will you not see?" — Surah Adh-Dhariyat: 21

God invites us to reflect on our own selves, for in our composition are clear signs. No reflection runs deeper than gazing at that book written inside every one of our cells: DNA. In this chapter we lay down the basic vocabulary without which no discussion of statistical genetics can stand — and we do it with the simplest analogies.

The Library Analogy

Picture the human genome as a complete **library**. This library has 23 **shelves** (these are the **chromosomes**, and we have two of each kind). Each shelf holds thousands of **books** (these are

the **genes**, totaling about 20,000 protein-coding genes). Each book is written with just four letters: A, C, G, and T (the nitrogenous bases). And when a **single letter** on a **single page** differs between one person and another, we call that difference a **SNP** — the hero of this book.

The SNP: The Workhorse

A SNP — **Single Nucleotide Polymorphism** — is a position in the genome where a single letter differs between people. For example: at a certain position, 70% of people carry the letter A and 30% carry G. That position is a SNP. Each SNP has a reference name beginning with "rs," such as rs7903146 (a famous SNP associated with diabetes). There are about 8 million common SNPs in humans, and they are the currency of nearly every statistical analysis we perform — because they are abundant, scattered along the genome, and easy to measure.

Alleles and Genotypes

At each SNP, each form of the letter is called an **allele**. In our example, allele A and allele G. Because we are humans — diploid organisms, with two copies of every chromosome (one from the father, one from the mother) — every person carries **two alleles** at each position. The pair of alleles together is the **genotype**. So three genotypes are possible: AA, AG, and GG.

We call the genotype **homozygous** if the two alleles are identical (AA or GG), and **heterozygous** if they differ (AG). Think of eye color: if you inherit the "blue-eye instruction" from both parents you are homozygous, and if you inherit "blue" from one and "brown" from the other you are heterozygous — and brown usually shows because it is dominant.

The Central Dogma, and Why Non-Coding Regions Matter

Information flows in the cell according to the **Central Dogma**: DNA is transcribed into RNA, then translated into **protein**. Proteins are the body's workers: enzymes, hormones, structural components. But a great surprise in statistical genetics is that most disease-associated variants lie not inside protein-coding genes, but in **non-coding** regions that control **when** and **how much** protein is made. The non-coding region is not "junk" as once thought, but more like the light switches and control buttons of the factory.

Diploid: Why Two Copies?

Being diploid has an important statistical consequence. Because every position has two copies, we can compute **allele frequency** precisely, and study how genotypes distribute in a population. This duality is the foundation of the Hardy-Weinberg law we meet in the next chapter.

Worked Example: Calculating Allele Frequency by Hand

Take a small group of **10 people**, and look at a SNP with two alleles: A and G. Suppose the genotypes are:

- 4 people with genotype AA
- 4 people with genotype AG
- 2 people with genotype GG

Total: 10 people, meaning 20 alleles (each person has two copies).

Counting allele A: From the four AA individuals we get $4 \times 2 = 8$ copies of A. From the four AG individuals we get $4 \times 1 = 4$ copies of A. Total: $8 + 4 = 12$ copies of A.

Counting allele G: From the two GG individuals we get $2 \times 2 = 4$ copies. From the four AG individuals we get $4 \times 1 = 4$ copies. Total: 8 copies of G.

Frequency of A = $12 \div 20 = 0.60$ (60%) **Frequency of G** = $8 \div 20 = 0.40$ (40%)

Note that the sum $0.60 + 0.40 = 1.00$, as it always must. The less common allele (here G, at 0.40) is the **minor allele**, and its frequency is the **MAF** — a number you will see in every GWAS paper.

Common Mistakes

Beginners often confuse **allele** with **genotype**: the allele is the single letter (A), the genotype is the pair (AG). Another common error is assuming a variant outside genes has no effect — and we have seen that the opposite is usually true.

***From my research:** In our kidney-disease analyses at the University of Michigan, we always begin by computing the MAF for every SNP, and we exclude very rare variants (say, MAF below 0.01) because their statistical signal is weak and*

unreliable. This simple step — counting alleles — is the cornerstone on which every later analysis is built.

Chapter 3: Hardy-Weinberg

Equilibrium: The Foundational Law

﴿إِنَّ اللَّهَ لَا يَغَيِّرُ مَا بِقَوْمٍ حَتَّىٰ يَغَيِّرُوا مَا بِأَنفُسِهِمْ﴾

"Indeed, God will not change the condition of a people until they change what is in themselves." — Surah Ar-Ra'd: 11

The verse speaks of a social law: conditions remain stable until change arises from within. Population genetics has a law similar in spirit: genotype frequencies remain stable and predictable as long as no force intervenes to change them. That law is **Hardy-Weinberg Equilibrium** (HWE), the cornerstone of every genetic analysis.

What the Law States

The law states that under ideal conditions, **genotype** frequencies can be predicted from **allele** frequencies alone, and these frequencies stay constant generation after generation. In

other words: if you know the allele frequency, you can predict what fraction of people will be AA, AG, and GG — without examining anyone.

The Formula from First Principles

Let the frequency of allele A be **p** and the frequency of allele a be **q**, with $p + q = 1$. When people mate randomly, the probability that two alleles meet to form a genotype follows the multiplication rule of probability:

- Probability of genotype **AA** = $p \times p = \mathbf{p^2}$
- Probability of genotype **aa** = $q \times q = \mathbf{q^2}$
- Probability of genotype **Aa** = $(p \times q) + (q \times p) = \mathbf{2pq}$
(because A may come from the father or the mother)

And the sum of these probabilities equals one:

$$p^2 + 2pq + q^2 = 1$$

This is nothing but the expansion of $(p+q)^2 = 1^2 = 1$. The law's elegance is that it falls straight out of high-school algebra.

The Five Assumptions

The law holds under five conditions, and violating any one pushes the population away from equilibrium:

1. **Random mating** — no preference for particular genotypes in mate choice. Violation (such as marriage between relatives) increases homozygosity.
2. **No selection** — no genotype dies or reproduces more than others. Violation shifts frequencies toward a beneficial allele.
3. **No mutation** — no allele converts to another. Violation rarely matters in the short term.
4. **No migration** — no alleles entering or leaving from other populations. Violation mixes frequencies.
5. **Large population size** — to avoid chance fluctuations (genetic drift). Violation in small populations causes random swings.

Why It Matters in Statistical Genetics

You might think this law is mere population theory, but it has a crucial practical use: a **quality-control filter**. When we measure millions of SNPs in thousands of people using genotyping arrays, technical measurement errors occur. One of the clearest signs of technical error is a SNP that deviates sharply from Hardy-Weinberg equilibrium in a sample of healthy controls. So if we find a SNP whose genotypes are far from what the law predicts, we suspect the measurement and exclude it.

Worked Example: Expected vs. Observed with a Chi-Square Test

Take a SNP with two alleles A and a, in a sample of **1000 people**. Suppose the frequency of A is $p = 0.7$ and a is $q = 0.3$.

Expected counts under the law: - AA: $p^2 \times 1000 = 0.49 \times 1000 = 490$ - Aa: $2pq \times 1000 = 2 \times 0.7 \times 0.3 \times 1000 = 0.42 \times 1000 = 420$ - aa: $q^2 \times 1000 = 0.09 \times 1000 = 90$

Observed counts (suppose we counted them): - AA: 520, Aa: 360, aa: 120

Chi-square test step by step, using $\chi^2 = \sum \frac{(O-E)^2}{E}$:

- AA: $\frac{(520-490)^2}{490} = 900 / 490 = 1.84$
- Aa: $\frac{(360-420)^2}{420} = 3600 / 420 = 8.57$
- aa: $\frac{(120-90)^2}{90} = 900 / 90 = 10.00$

Sum: $\chi^2 = 1.84 + 8.57 + 10.00 = 20.41$

The degrees of freedom in an HWE test equal 1 (number of genotypes, 3, minus number of alleles, 2). The critical value at the 0.05 level is 3.84. Since 20.41 far exceeds 3.84, this SNP **fails** the equilibrium test ($p < 0.001$), and we judge it likely to carry a technical genotyping error, so we exclude it.

How I Use It in My Work

From my research: In every kidney-disease GWAS we run at the University of Michigan, we pass millions of SNPs through

the Hardy-Weinberg filter in the control group (the healthy). In practice, about 3% of SNPs fail this test (at a strict threshold such as $p < 10^{-6}$), and we drop them before any association analysis. Why in controls only? Because patients may deviate from equilibrium for a genuine biological reason (disease-related selection), so we do not confuse technical error with a real signal.

Summary

Hardy-Weinberg equilibrium is not merely an elegant equation but a practical tool: it tells us what we should see if everything were "normal," so that when we see otherwise, we know where to look — either for a technical error, or for interesting biology.

Chapter 4: Linkage Disequilibrium: The Genome's Secret Language

﴿وَجَعَلْنَا مِنْ كُلِّ شَيْءٍ زَوْجَيْنِ لَعَلَّكُمْ تَذَكَّرُونَ﴾

"And of all things We created pairs, that perhaps you may remember."

— Surah Adh-Dhariyat: 49

In the universe there are paired things that travel together, and in the genome there are positions that move in tandem, scarcely parting. This coupling between neighboring positions is what we call **Linkage Disequilibrium** (LD) — and despite its confusing name, it is one of the most beautiful concepts in statistical genetics, and the secret behind the efficiency of every association study.

The Concept

When the genome is inherited from one generation to the next, a process of **recombination** shuffles the chromosomes. But this

shuffling does not easily separate neighboring positions; positions close to one another on the same chromosome are **inherited together** more often than chance would predict. This statistical association between alleles at different positions is LD. The closer the positions, the stronger their correlation; the farther apart, the weaker.

The Neighborhood Analogy

Picture the chromosome as a long city divided into **neighborhoods** (haplotype blocks). People who live in the same neighborhood move together — they go to the same market, the same mosque. Likewise, variants in the same "genetic neighborhood" travel together across generations. So if you know one variant in the neighborhood, you can infer its neighbors with high accuracy, without examining them all. This is the idea that shrinks the work from 8 million variants to roughly one million "representatives."

The D' and r^2 Statistics

We measure LD with two main statistics:

D' (D-prime): ranges from 0 to 1, and measures whether there is any historical association between two positions regardless of allele frequencies. A value of $D' = 1$ means no recombination has separated them (a "complete" historical link).

r^2 (r-squared): also ranges from 0 to 1, but measures **predictive power**: if $r^2 = 1$, then knowing the allele at one position tells you the allele at the other exactly. This is the more important statistic in GWAS, because we want to know: to what degree can a measured variant "stand in" for an unmeasured one? We use D' to understand evolutionary history, and r^2 to design studies and select tag SNPs.

Why LD Matters

Here lies the secret of GWAS efficiency. Thanks to LD, there is no need to measure each of the 8 million variants. It is enough to measure a selected set of "tag variants," and each measured

variant captures — via LD — the signal of dozens of neighboring unmeasured variants. This is what made genotyping arrays cheap and feasible: we measure about one million SNPs and effectively cover most of the common variation in the genome.

The LD Decay Curve

The greater the distance between two positions, the weaker the LD between them, because the chance of a recombination event separating them grows with distance. When we plot r^2 on the vertical axis and distance (in kilobases) on the horizontal, we get a **decay curve** that drops from a high value at short distances to near zero at long distances. The speed of this drop differs between populations.

Population Differences in LD

In African populations, **LD blocks are shorter** than in European or Asian populations. The reason is historical: African populations are older (humans arose in Africa), so they have

passed through more generations and accumulated more recombination events, fragmenting long blocks into smaller ones. This has an important practical consequence: studies designed for European populations may not transfer their findings accurately to African populations, because block structure differs.

Worked Example: Calculating r^2 Between Two Variants

Take two positions, A/a and B/b, and look at the **haplotypes** (allele combinations on a single chromosome) in a sample. Suppose these frequencies:

- Allele A has frequency $p_A = 0.6$, and allele B has frequency $p_B = 0.5$
- Frequency of haplotype AB together: $p_{AB} = 0.45$

First compute the disequilibrium coefficient **D**: $D = p_{AB} - (p_A \times p_B) = 0.45 - (0.6 \times 0.5) = 0.45 - 0.30 = 0.15$

Then compute r^2 with the formula: $r^2 = \frac{D^2}{p_A (1-p_A) \cdot p_B (1-p_B)}$

Substituting: $r^2 = \frac{(0.15)^2}{0.6 \cdot 0.4 \cdot 0.5 \cdot 0.5} = \frac{0.0225}{0.06} = 0.375$

So $r^2 \approx 0.38$ indicates moderate correlation: knowing the allele at one position explains about 38% of the variance at the other. In GWAS, we typically regard r^2 above 0.8 as a "strong correlation" sufficient to treat one variant as a tag for the other.

Reading an LD Heatmap

LD relationships are often shown in a **triangular heatmap** (triangle plot): each small square represents the LD value between two variants, and the color gradient (light to dark) indicates correlation strength. Blocks appear as dark triangular clusters along the diagonal, showing you visually where the "neighborhoods" fall on the chromosome.

From my research: *When analyzing a region associated with kidney disease, we always begin by inspecting the LD structure around the lead variant. In one known kidney region, we found that the statistically strongest variant sat in a neighborhood containing dozens of variants in tight LD ($r^2 > 0.9$), meaning the true "functional" variant could be any of them — and here begins the task of fine-mapping (Chapter 11).*

Chapter 5: Genome-Wide Association Studies: The Manhattan Plot Explained

﴿أَفَلَا يَنْظُرُونَ إِلَى الْإِبِلِ كَيْفَ خُلِقَتْ﴾

"Do they not look at the camels, how they are created?" — Surah Al-Ghashiyah: 17

A call to contemplative looking at creation — the look of one searching for mastery in the details. That is the spirit of the **Genome-Wide Association Study** (GWAS): to look — variant by variant — across millions of positions, searching for the signal that links a letter of the genome to a disease or trait. This chapter is the heart of the book.

The Idea of GWAS

The idea is simple and astonishing: instead of guessing which gene is responsible for a disease, we **test every common variant** (5 to 10 million SNPs) for association with a trait, in

thousands — even hundreds of thousands — of people. We make no prior assumption about where the gene lies; we let the data speak. This shift from "directed hypothesis" to "unbiased comprehensive scan" is what revolutionized genetics from 2007 onward.

The Basic Statistical Test

For each SNP, we ask one question: does the allele frequency differ between patients and healthy people more than chance would expect? We answer using **regression**:

- For diseases (a binary outcome: affected/unaffected) we use **logistic regression**.
- For continuous traits (such as height or blood pressure) we use **linear regression**.

In plain terms: we put the genotype (0, 1, or 2 copies of the allele) as the independent variable, the trait as the dependent variable, and we compute the **effect size** (denoted β , or odds ratio OR) and the **p-value** that measures the strength of

evidence against the "no association" hypothesis. We repeat this millions of times — once for each SNP.

The Manhattan Plot

How do we display millions of p-values at once? With a **Manhattan plot**, so named because it resembles a skyline of skyscrapers. On the **horizontal** axis: the SNP's position along the chromosomes, ordered 1 through 22 and then the sex chromosomes. On the **vertical** axis: the value $-\log_{10}(p)$ — meaning the smaller (stronger) the p-value, the **higher** it appears. So if $p = 10^{-8}$, it sits at 8 on the axis. Each point is a SNP, and each "tower" of high points is a region associated with the trait.

Two horizontal lines are usually drawn: a red line at the genome-wide significance threshold ($p = 5 \times 10^{-8}$), and a blue line at a less stringent "suggestive" threshold (such as $p = 10^{-5}$). Anything crossing the red line is considered a significant discovery.

The Genome-Wide Significance

Threshold: Why 5×10^{-8} ?

You might wonder: why this specific number, and not the familiar 0.05? The reason is **Bonferroni correction** for multiple testing. When we run about one million independent tests, we must divide the usual threshold of 0.05 by the number of tests:

$$\frac{0.05}{1,000,000} = 5 \times 10^{-8}$$

And why one million tests rather than 8 million? Because many variants are correlated through LD (Chapter 4), so the number of **effectively independent** tests in the European genome is about one million. We will detail this in the next chapter.

The Q-Q Plot and the Inflation Factor

Before trusting GWAS results, we inspect the **Q-Q plot** (quantile-quantile plot). This compares the observed p-values to what we expect if there were no real association at all. If the

points follow the diagonal line and then deviate upward in the tail, that is good: most variants have no association (as expected), and a few show a real signal.

But if the **entire curve** deviates upward from the start, that is **inflation** — a warning of a problem, usually population stratification (Chapter 10). We measure inflation with the **lambda** factor (genomic control factor, λ): if λ is near 1.0, all is well; if it exceeds 1.05 or 1.1, there is inflation that must be addressed.

Reading a Real GWAS Paper

***From my research:** When I read a kidney-disease GWAS paper, I follow a fixed order. First, I look at the Q-Q plot and the λ factor to make sure the results are not inflated (we want $\lambda \approx 1.02$, say). Then I move to the Manhattan plot and count the towers that crossed the red line. In large studies of kidney function (measured by estimated glomerular filtration rate, eGFR), dozens of loci appear, the most famous being the*

UMOD gene region on chromosome 16 — a strong, recurrent signal in nearly every study. I check the effect size and its direction: does the allele raise or lower kidney function?

What a GWAS Hit Is NOT

An essential caution: **association is not causation**. When we find a SNP associated with disease, that does not mean it is the direct cause. Often the discovered variant is merely a "tag" (via LD) for a true nearby functional variant we did not measure. The association may also arise from unaddressed confounding. Moving from "association" to "biological function" requires a whole set of additional steps, which we devote Chapter 11 to.

Common Mistakes

A frequent beginner error: treating every point above the red line as a "discovered gene," when the point is a variant in a region that may contain several genes. Another error: ignoring the Q-Q plot and jumping straight to the Manhattan plot —

which can lead you to celebrate results that are in fact pure inflation from population stratification.

Chapter 6: Multiple Testing

Correction: The Problem of 10 Million Tests

﴿وَلَا تَقْفُ مَا لَيْسَ لَكَ بِهِ عِلْمٌ﴾

"And do not pursue that of which you have no knowledge." — Surah Al-Isra: 36

God forbade us to follow what we have no knowledge of — to assert without sufficient evidence. This is precisely the essence of the multiple-testing problem in statistical genetics: when we run millions of tests, some deceive us with false signals, so we think we have "discovered" what is in truth pure chance. This chapter teaches you how to guard yourself against pursuing without knowledge.

The Origin of the Problem

Imagine running **one million tests** at the usual significance level $p < 0.05$. Recall what 0.05 means: the probability of seeing a result this strong by pure chance even if there is no real association. So if all one million SNPs have **no real association**, how many will cross the threshold by chance?

$$1,000,000 \times 0.05 = 50,000$$

Fifty thousand false "discoveries"! This is the catastrophe that must be corrected, lest we drown in false positives.

Bonferroni Correction

The simplest and most stringent solution is **Bonferroni correction**: divide the significance level α by the number of tests.

Worked example: If we run one million tests and want an overall error rate of 0.05:

$$\alpha_{\text{corrected}} = \frac{0.05}{1,000,000} = 5 \times 10^{-8}$$

And so we understand where the famous GWAS threshold of 5×10^{-8} comes from. Any SNP with a p-value below this threshold is considered genome-wide significant. Bonferroni's drawback is that it is **very conservative**: it assumes all tests are independent, so when they are correlated (as in LD), the correction becomes harsher than necessary, and we may lose real discoveries.

False Discovery Rate and the Benjamini-Hochberg Method

A less stringent alternative is controlling the **False Discovery Rate** (FDR). The philosophical difference matters: Bonferroni controls the probability of **even a single false positive**, whereas FDR controls the **proportion** of false positives among discoveries. So when you say "I accept an FDR of 5%," you are saying: "I am content for about 5% of my discoveries to be false."

The **Benjamini-Hochberg** method applies this in practice: sort the p-values in ascending order, give each a rank i , then compare p to the threshold $(i/m) \times \alpha$ where m is the number of tests. The largest p satisfying the condition, and everything below it, are considered significant. We use FDR when we want a balance between caution and discovery, especially in exploratory studies or gene-expression analyses.

The Permutation Approach

The gold standard for complex data is **permutation**. The idea: shuffle the case/control labels randomly many times, and rerun the analysis each time. This builds the true "null" distribution for your specific data, with no theoretical assumptions. Its advantage is that it respects your data's correlation structure (LD, confounding) automatically; its drawback is that it is **computationally very expensive** (thousands of repeats for millions of SNPs).

Why 5×10^{-8} Specifically?

We saw that Bonferroni for one million tests gives 5×10^{-8} . But why one million and not 8 million? Because the correction must rest on the number of **effectively independent** tests. Due to LD, the 8 million common variants in the European genome behave as about **one million** independent tests. That is why the field settled on 5×10^{-8} as a unified threshold, making results from different studies comparable.

My Decision in Practice

*From my research: In my work on kidney disease at the University of Michigan, I distinguish between two stages. In the **initial genome-wide scan**, I adhere to the strict Bonferroni threshold of 5×10^{-8} , because I want to announce a discovery only with the highest certainty. But when I move to a narrower **targeted analysis** — such as testing the effect of a small set of known kidney genes on gene expression — I use*

FDR at 5%, because the number of tests is far smaller and the goal is exploratory, tolerating a calculated degree of risk.

Common Mistakes

Two opposing errors trap researchers:

Excessive stringency: applying Bonferroni to heavily **correlated** tests (as when analyzing a small region full of LD). Here Bonferroni becomes more conservative than necessary, and real signals are lost.

Excessive leniency: ignoring multiple-testing correction entirely and settling for $p < 0.05$. This is the more dangerous error, and a chief cause of the "reproducibility crisis" that struck many early genetic studies before the era of strict GWAS.

Summary

Correcting for multiple testing is not a statistical luxury but a methodological and ethical necessity. It is the practical

translation of the Quranic injunction against pursuing what we have no knowledge of: we do not announce a discovery until we are sure it is not merely a shadow of chance in a sea of millions of tests.

Chapter 7: Heritability: How Much Is Genetic?

﴿وَخَلَقْنَاكُمْ أَزْوَاجًا﴾

"And We created you in pairs." — Surah An-Naba: 8

We were created in pairs, and from this pairing come twins — the oldest tool scientists used to measure "how much of a trait is genetic." This chapter addresses a concept misunderstood more than any other in genetics: **heritability**, denoted h^2 .

What Is Heritability?

Heritability is the **proportion of phenotypic variance (in a trait) explained by genetic variance**, in a **specific population** at a **specific time**. Note those last two qualifiers well; they are the key to avoiding the most common errors. Heritability is not a fixed property of an organism, but a property of a **population** in its environmental context.

In simplified form: $h^2 = \frac{V_G}{V_P} = \frac{\text{genetic variance}}{\text{total phenotypic variance}}$

where the total phenotypic variance V_P is the sum of genetic variance V_G and environmental variance V_E .

Twin Studies

The classic method for measuring h^2 compares two kinds of twins: **identical** (sharing 100% of genes) and **fraternal** (sharing 50% on average). The idea: if a trait is strongly genetic, identical twins will resemble each other in it far more than fraternal twins. Falconer's famous formula:

$$h^2 = 2 \times (r_{\text{MZ}} - r_{\text{DZ}})$$

where r_{MZ} is the correlation between identical twins and r_{DZ} between fraternal twins.

Worked example with height: Suppose the correlation of height between identical twins is $r_{\text{MZ}} = 0.90$, and between fraternal twins $r_{\text{DZ}} = 0.50$. Then:

$$h^2 = 2 \times (0.90 - 0.50) = 2 \times 0.40 = 0.80$$

So about 80% of the **variance** in height among people (in this sample) is explained by genetic differences. This is very close to the globally accepted value for height.

SNP Heritability and the "Missing Heritability" Problem

When GWAS began, a surprise emerged: the significant discovered variants explained only a small portion of the heritability estimated from twins. This gap was named **missing heritability**. For example: height has $h^2 \approx 0.80$ from twins, but early GWAS explained less than 10%. Where did the rest go?

Scientists developed the concept of **SNP heritability** (h^2_{SNP}): the variance explained by **all** the array's variants together, not just the significant ones. It turned out that most of the "missing" heritability lies in thousands of small-effect variants that individually fall short of significance, but

accumulate. The remaining portion is due to rare variants the arrays did not measure, and complex interactions.

A Dangerous Misunderstanding

The biggest mistake people make: thinking that $h^2 = 80\%$ means "80% of your height came from your genes." **This is entirely wrong.** Heritability speaks about **variance among people** in a group, not about the individual. Your height is the inseparable product of your genes and environment together. Likewise, heritability is **not genetic determinism**: a highly heritable trait can change completely as the environment changes (a classic example: height is highly heritable, yet average heights rose generation after generation thanks to improved nutrition).

Gene × Environment Interaction

Variance is not a simple sum of gene and environment; there is an **interaction** between them (gene × environment). A genetic variant may have a strong effect in one environment and a

weak one in another. A well-known example: variants increasing obesity risk show their effect strongly in a food-rich environment and nearly vanish in a scarce one.

Variance Components

We decompose the genetic variance into three components: **additive** (each allele's effect adds up), **dominance** (interaction of the two alleles at the same position), and **epistatic** (interaction of different positions). In practice, the **additive** component dominates most complex traits, which is why most GWAS models and risk scores focus on it.

Real Numbers

It helps to remember these approximate heritability estimates: height $\approx 80\%$, type 2 diabetes $\approx 40\%$, schizophrenia $\approx 80\%$, educational attainment $\approx 40\text{--}50\%$. Note that behavioral and cognitive traits have substantial heritability, but always below 100%, leaving wide room for the environment.

***From my research:** In our study of kidney-function decline in a cohort of chronic kidney disease (CKD) patients at the University of Michigan, we estimated the heritability of the rate of glomerular filtration decline. We found a representative estimate around $h^2 \approx 0.3 - 0.4$ — meaning roughly a quarter to a third of the difference between patients in the speed of kidney decline is attributable to genetic factors, the rest to environmental and clinical factors (diabetes, blood pressure, treatment). This number guides our decisions: genes matter but are not destiny, and there is wide scope for therapeutic intervention.*

Common Mistakes

Always remember: heritability is a **property of a population**, **not an individual**, it **depends on the environment** and changes with it, and it **does not mean determinism**. Confusing any of these three is the source of most misleading debate about "genes for intelligence" or "genes for crime."

Chapter 8: Polygenic Risk Scores: Predicting Disease from Thousands of Variants

﴿وَمَا تَدْرِي نَفْسٌ مَّاذَا تَكْسِبُ غَدًا﴾

"And no soul knows what it will earn tomorrow." — Surah Luqman:

34

Knowledge of the unseen belongs to God alone; no soul knows what it will earn tomorrow. Polygenic risk scores do not claim knowledge of the unseen; they offer a **probability** built on what we know of the genome — an estimate of tendency, not a verdict of fate. This distinction is the heart of the chapter: to understand what these scores can say, and what they cannot.

The Idea

We saw in the previous chapter that most complex traits are shaped by thousands of small-effect variants. The idea of a **Polygenic Risk Score** (PRS) is simple and direct: instead of looking at a single variant, **sum the effects of thousands of variants** together to get one number summarizing an individual's genetic tendency toward a disease or trait.

The Formula

A risk score is computed for each person by multiplying the number of risk-allele copies at each position by its effect size, then summing across all positions:

$$\text{PRS} = \sum_{i=1}^N \beta_i \times G_i$$

where β_i is the effect size of variant i (taken from GWAS results), G_i is the number of risk-allele copies the person carries (0, 1, or 2), and N is the number of variants (which may reach one million).

How a Risk Score Is Built

The construction passes through three steps: first, we take the **summary statistics** from a large GWAS — the effect sizes β for each variant. Second, we perform **LD pruning/clumping** to remove variants correlated through LD so we do not count the same signal twice. Third, we choose a **threshold** for the p-value (for example, include every variant with $p < 0.01$, or include all variants with graduated weights using modern methods such as LDpred).

Worked Example: A 5-SNP Score for Diabetes Risk

Let us build a simplified 5-variant score for type 2 diabetes risk. The table shows the effect size (as log odds ratio) and the number of risk-allele copies in a hypothetical patient:

Variant	Effect size β	Risk copies	G	Product $\beta \times G$
Variant 1	0.20	2		0.40

Variant Effect size β Risk copies G Product $\beta \times G$

Variant 2 0.15 1 0.15

Variant 3 0.30 0 0.00

Variant 4 0.10 2 0.20

Variant 5 0.25 1 0.25

Summing: PRS = 0.40 + 0.15 + 0.00 + 0.20 + 0.25 = **1.00**

This number means nothing on its own; its meaning comes from comparing it to the distribution of scores in the population. If the population mean is 0.60 with a standard deviation of 0.20, then our patient's score (1.00) falls two standard deviations above the mean — within the top risk tier. Now imagine this process performed not on 5 variants but on **one million**, and the picture is complete.

Evaluating a Risk Score

How do we know a score is "good"? By several measures: **AUC** (area under the ROC curve, measuring the ability to discriminate patients from healthy people; 0.5 means pure

chance and 1.0 means perfect discrimination), R^2 (the proportion of variance explained for continuous traits), and the **odds ratio per standard deviation** (how much disease risk increases with each standard-deviation rise in the score).

The Clinical Promise

The promise is enticing: stratifying patients by their genetic risk **before** disease onset. Imagine knowing that a twenty-year-old falls in the top 2% of genetic diabetes risk, so we begin preventive intervention early (diet, exercise, follow-up) decades before the disease might appear. This is the dream of precise preventive medicine.

The Major Limitation: The Diversity Problem

But there is a serious limitation that must be stated frankly: risk scores built on European GWAS (the overwhelming majority) **perform poorly** in African, Asian, and Arab populations. The reason is compound: differing LD structure between

populations (Chapter 4), differing allele frequencies, and differing environments. This means transferring a European score to an Arab patient may give a misleading estimate. This "diversity problem" is among the gravest ethical challenges in the field today.

***From my research:** I use polygenic risk scores to predict kidney-disease risk at the University of Michigan. The promise is real: in data of European ancestry, the score adds predictive power above traditional clinical factors (age, diabetes, blood pressure). But I treat it with great caution, especially when it concerns patients of non-European ancestry, because performance degrades. My practical lesson: the score is an assisting tool, not a substitute for clinical judgment, and it does not transfer blindly between populations.*

Common Mistakes

Among the errors: interpreting a high score as a "verdict of disease" (when it is a probabilistic tendency), transferring a score built on one population to another without validation, and forgetting that environmental and clinical factors may outweigh the gene in many diseases. A risk score tells you the tendency, not the destiny — ﴿وَمَا تَدْرِي نَفْسٌ مَّاذَا تَكْسِبُ غَدًا﴾.

Chapter 9: Haplotypes and Phasing: Reading Both Copies of the Genome

﴿وَجَعَلْنَاكُمْ شُعُوبًا وَقَبَائِلَ لِتَعَارَفُوا﴾

"And We made you into peoples and tribes that you may know one another." — Surah Al-Hujurat: 13

God made us peoples and tribes, and a tribe is a lineage inherited intact. The genome has an analogue to this lineage: the **haplotype**, a string of alleles inherited together on a single chromosome, as if it were a genetic "tribe." This chapter teaches you how we read each of the genome's two copies separately.

The Problem

When we measure a person's genotype at two neighboring positions, the array tells us, say, that they are heterozygous at both: A/a at the first and B/b at the second. But it does **not** tell us which allele is on which chromosome. Are A and B together

on the paternal chromosome (and a, b on the maternal)? Or A with b, and a with B? This ambiguity is the unknown **phase**. The genotype tells you what you **have**, not how it is **distributed** across the two copies.

The Haplotype and Why It Matters

A **haplotype** is the specific combination of alleles on a single chromosome. Knowing it matters in several cases. For instance, in **compound heterozygosity**: a patient may carry two harmful mutations in the same gene; if they lie on two different chromosomes (one on each copy), both copies of the gene are disabled and disease appears, whereas if they lie on the same chromosome, the other copy is intact and disease may not appear. The difference between the two cases is decisive, and only phase reveals it. Likewise, analysis of the **HLA** immune region depends entirely on haplotypes.

Statistical Phasing

How do we infer phase when the array does not provide it? By **statistical phasing**: we exploit population LD patterns (Chapter 4). The core idea: some allele combinations (haplotypes) are common in the population and others rare. So if a person has an ambiguity between two interpretations, we favor the interpretation yielding haplotypes that are **common** in the population. The algorithm repeats this inference across millions of positions and thousands of people simultaneously, building a consistent map of phases. (No mathematical derivation is needed here; it is enough to grasp the principle: the population is a reference by which we infer the individual.)

Reference Panels

Phasing accuracy depends on **reference panels**: huge collections of genomes with known phase. The most famous are the **1000 Genomes** project and the **UK Biobank** (with hundreds of thousands of participants). Phasing software (such as SHAPEIT and Eagle) uses these panels as a reference: the

larger the panel and the closer it is to the person's ancestry, the more accurate the inference. And here a familiar problem appears: the panels are rich in Europeans and poor in Arabs, so phasing accuracy for Arabs is lower.

Haplotype Blocks

Correlated positions cluster into **haplotype blocks**: regions on the chromosome that travel as a single unit rarely broken by recombination. These blocks are identified by analyzing LD patterns, and they are the natural units many analyses reason about instead of single variants.

The HLA Region: The Hardest and Richest

The most variable region of the genome by far is the **HLA** region (human leukocyte antigens) on chromosome 6. This region is responsible for immune recognition (distinguishing self from non-self), and it contains hundreds of alleles per gene. Its enormous diversity makes it hard to phase and analyze, yet

it is extremely important: associated with autoimmune diseases, organ-transplant compatibility, and the response to certain drugs. HLA analysis is an art in its own right, relying on specialized reference haplotypes.

A Real Application

***From my research:** In analyzing a region associated with diabetes risk near a gene affecting insulin secretion, it was not enough to know that the patient carried two heterozygous variants. The decisive question was: do the two risk alleles lie on the same haplotype (so their effects compound) or on two opposite haplotypes? By performing phasing, we could identify the **causal haplotype** — the specific combination carrying the highest risk — rather than dealing with the variants in isolation. This distinction changed our interpretation of the biological mechanism. And in our kidney work, we turn to phasing when we want to link a regulatory variant to a specific target gene on the same copy.*

Common Mistakes

Among the common errors: treating phasing results as **complete certainty**, when they are a **probabilistic inference** that may err, especially for rare alleles or in populations poorly represented in reference panels. Another error: confusing genotype (what you have) with haplotype (how it is distributed); the first is measured directly, the second is usually inferred. When a haplotype is mentioned in a paper, always ask: was it measured directly (by family sequencing) or inferred statistically? Your degree of confidence differs by the answer.

Chapter 10: Controlling Confounding: Population Stratification and Covariates

﴿إِنَّ اللَّهَ يَأْمُرُ بِالْعَدْلِ وَالْإِحْسَانِ﴾

"Indeed, God commands justice and good conduct." — Surah An-Nahl: 90

God commands justice, and justice in science means comparing like with like, and never attributing an effect to a phantom cause. The gravest threat to justice in association studies is **confounding**: thinking a variant is associated with disease, when the true link is something else entirely. This chapter teaches you how to guard your analysis against statistical injustice.

The Confounding Problem

Imagine a study of some disease in which, by chance, most patients are of European ancestry and most healthy controls are of African ancestry. Now, any genetic variant whose frequency differs between Europeans and Africans will appear **associated with disease** — not because it causes it, but because it distinguishes the two populations to begin with. This is an innocent variant falsely accused. The true link is ancestry, not disease.

Population Stratification

This phenomenon is called **population stratification**: a hidden population structure in the sample producing spurious associations. Its practical effect is that it **inflates** the entire GWAS — the Q-Q curve rises from its start (Chapter 5), and the lambda factor clearly exceeds 1.0. Unaddressed population mixing can produce dozens of false "discoveries" with no relation to biology.

Principal Component Analysis in Genetics

The most important tool for detecting and addressing this structure is **Principal Component Analysis** (PCA). The idea: we take millions of SNPs and summarize the genetic variation among them into a small number of "components" that capture the largest amount of variation. Remarkably, these components capture geographic ancestry with astonishing accuracy.

What Does a PCA Plot of Populations Look Like?

When we plot the first component (PC1) on one axis and the second (PC2) on another, with one point per person, the points **cluster by continent**: Europeans in one corner, Africans in another, East Asians in a third. Indeed, the resulting genetic map strikingly resembles the geographic map of Europe (a famous study titled "Genes Mirror Geography"). The first two

components usually separate continents, and the later components capture finer variation within them.

Including Components as Covariates

How do we use this in correction? We include the principal components as **covariates** in the regression model. So instead of:

$$\text{disease} \sim \text{genotype}$$

we write:

$$\text{disease} \sim \text{genotype} + \text{PC}_1 + \text{PC}_2 + \dots + \text{PC}_{10}$$

This "subtracts out" the effect of ancestry, leaving only the true association with the variant. How many components do we include? Many studies use about **10 components**: enough to capture the major structure, without overdoing it and wasting analytical power by adding components that carry no population signal.

Linear Mixed Models

There is a more sophisticated approach: **Linear Mixed Models** (LMM), implemented by software such as BOLT-LMM, SAIGE, and REGENIE. These models solve two problems at once: population stratification **and** hidden **relatedness** among participants (relatives in the sample without our knowledge). They do this by incorporating a genetic relationship matrix into the model. These models have become a standard in large biobanks because they handle hundreds of thousands of samples efficiently.

Worked Example: Before vs. After PC Correction

Let us imagine simulated data with population stratification. Suppose we tested a variant that truly has no effect on disease,

but whose frequency differs between two mixed populations in the sample:

- **Before correction:** simple regression gives $p = 1 \times 10^{-9}$ (a spurious "genome-wide" significance!), and the study's overall lambda factor = 1.25 (clear inflation).
- **After including 10 principal components:** p becomes 0.4 (no significance, as it should be), and lambda drops to 1.02 (healthy).

This dramatic difference shows why PC correction is the **most important** quality-control step in any GWAS. A variant that looked like an "exciting discovery" evaporated the moment we treated the two groups justly.

***From my research:** In every GWAS model we build for kidney disease at the University of Michigan, we include **10 principal components** by default. Why not more? Because components beyond the tenth usually capture noise rather than population structure, weakening the analysis without benefit. And why not fewer? Because our cohort is of mixed*

ancestries, and settling for two or three components leaves fine structure uncorrected. Our rule: inspect the PCA plot and the lambda factor, and adjust the number of components until lambda settles near 1.0.

Common Mistakes

The gravest error: ignoring ancestry correction entirely, so that "discoveries" that are pure ancestry effects get published. The opposite error: overdoing it by including far too many components, wasting statistical power. Justice — as the verse commanded — lies in the middle: correct what must be corrected, and do not overdo it.

Chapter 11: Interpreting Results: From Association to Function

﴿أَفَلَا يَتَدَبَّرُونَ الْقُرْآنَ أَمْ عَلَى قُلُوبٍ أَقْفَالُهَا﴾

"Then do they not reflect upon the Qur'an, or are there locks upon their hearts?" — Surah Muhammad: 24

Reflection is more than reading; reading is to see the letters, reflection is to grasp the meaning behind them. A GWAS gives you the "letters": statistically associated positions. But the "reflection" — moving from association to biological mechanism — is the hardest and most rewarding chapter, and that is what we devote this section to.

The Gap

A GWAS result is neither a gene nor a mechanism; it is a **chromosomal region** that may stretch over hundreds of thousands of bases and contain several genes and dozens of

variants in tight LD. How do we move from "this region is associated with disease" to "this gene, through this mechanism, causes this effect"? This is the gap bridged by a sequence of analytical tools.

Fine-Mapping

The first step is **fine-mapping**: narrowing the region from a hundred candidate variants to the most likely causal ones (usually 1 to 5). Methods such as **SuSiE** and **FINEMAP** use probabilistic models to estimate "the probability that each variant is the causal one," taking LD structure into account. The result is a small "credible set" that the rest of the analysis focuses on.

Functional Annotation

Then we ask: where does the candidate variant lie? This is **functional annotation**. Is it in a protein-coding region (so it changes the amino-acid sequence directly)? Or in an **enhancer** or **promoter** that regulates expression? Tools such as **Ensembl**

VEP (which predicts a variant's effect), **ENCODE** (which annotates regulatory regions), and **GTEx** (which links variants to expression) help place the variant in its functional context. And as mentioned earlier, most GWAS variants are regulatory, not coding.

eQTL Analysis

A central question: does the variant affect the **amount** of a gene's expression? If so, it is an **eQTL** (expression Quantitative Trait Locus). The **GTEx** database is the reference: it measured gene expression in dozens of human tissues, telling you which variant raises or lowers the expression of which gene in which tissue. So if we find that a kidney-disease GWAS variant is an eQTL for a particular gene **specifically in kidney tissue**, we have moved closer to the mechanism.

Colocalization

But coincidence is not enough. The region may contain a variant that causes disease and a separate one that affects

expression, both in LD, deceiving the observer. So we perform **colocalization** (via the **coloc** method): a statistical test asking whether the GWAS signal and the eQTL signal share the **same causal variant**. If the answer is yes with high probability, the evidence strengthens that the disease acts through changing that gene's expression.

Mendelian Randomization

Another elegant tool: **Mendelian Randomization** (MR). The idea resembles a natural experiment: because alleles are randomly distributed at conception (as if by a fair lottery), a genetic variant can be used as an "instrumental variable" to test a causal relationship. Example: does high cholesterol **cause** heart disease, or merely accompany it? We use variants that affect cholesterol as an instrument, and if these variants associate with heart disease, the causal inference strengthens — because genes do not "choose" lifestyle, so they are shielded from much confounding. Think of it as a randomized clinical trial conducted by nature at birth.

An Integrated Pipeline

***From my research:** This is exactly our workflow at the University of Michigan for one kidney variant. We start with a strong GWAS signal in some region. We fine-map it (SuSiE), narrowing it to a few variants. We examine them in **GTEx** and find that one of them is an eQTL for a particular gene **in kidney tissue**. We perform **colocalization**, which confirms that the disease signal and the expression signal share the same causal variant. And so we move from an "obscure region" to a specific **target gene**, suitable as a hypothesis for a subsequent lab experiment. The kidney **UMOD** region is a classic example where this path succeeded: the regulatory variant was linked to the gene's expression and then to kidney function.*

Reading a Locus Zoom Plot

The main visualization tool here is the **Locus Zoom plot**. On the horizontal axis: position on the chromosome. On the vertical: $-\log_{10}(p)$. Each point is a variant, colored by its LD strength with the lead variant (red = high LD, blue = low). Below the plot is a **gene track** showing where the genes lie. Reading it tells you at a glance: where the signal is, how far it extends, which genes are nearby, and which variants are in one neighborhood.

Common Mistakes

Among the errors: assuming the **nearest gene** to the signal is the causal gene — this is often wrong, as enhancers may act on distant genes. Another error: confusing coincidence (a variant is an eQTL and near a disease signal) with colocalization (the same causal variant) — the first is weak evidence, the second strong. True reflection does not stop at the first association that glitters.

Chapter 12: Conclusion: Tools, Resources, and the Road Ahead

﴿قُلْ هَلْ يَسْتَوِي الَّذِينَ يَعْلَمُونَ وَالَّذِينَ لَا يَعْلَمُونَ﴾

"Say: Are those who know equal to those who do not know?" —
Surah Az-Zumar: 9

A Quranic question that needs no answer: the knowing and the ignorant are not equal. And you, now, after eleven chapters, are no longer where you began. This chapter gathers the threads, hands you the toolbox and the resources, and draws the road ahead — especially for the Arab researcher.

The Full Journey Map

Let us review the statistical-genetics workflow from start to finish. We begin with **genotyping** thousands of people. Then we perform **quality control**: the Hardy-Weinberg filter (Chapter 3), and excluding rare variants (Chapter 2). Then we

correct for **population stratification** with principal component analysis (Chapter 10). After that we run the **association test** variant by variant via regression (Chapter 5), and correct for **multiple testing** with the 5×10^{-8} threshold (Chapter 6). We display the results in a Manhattan plot and verify the Q-Q and lambda. Then we move from association to function with fine-mapping, eQTL analysis, and colocalization (Chapter 11). In parallel, we build **risk scores** for prediction (Chapter 8). This is the journey from letter to biology.

The Beginner's Toolbox

These are the essential software tools you will need, all **free**:

- **PLINK** — the most famous quality-control and association-testing tool; the starting point for every beginner.
- **R with ggplot2** — for statistical analysis and plots (Manhattan and Q-Q).
- **REGENIE** and **SAIGE** — for large-scale GWAS with mixed models in big biobanks.

- **PRSice** and **LDpred** — for building polygenic risk scores.
- **FINEMAP** and **SuSiE** — for fine-mapping.
- **coloc** — for testing colocalization.

Data Resources

Big data has become accessible to researchers (after the usual access procedures):

- **UK Biobank** — half a million participants with rich genetic and health data.
- **dbGaP** — a U.S. repository of many genetic studies.
- **GWAS Catalog** — an index of all published GWAS results; your first reference for what has been discovered.
- **GTEx** — the database of gene expression across human tissues (for eQTL analysis).
- **gnomAD** — the largest reference for variant frequencies across populations.

Learning Resources

To go deeper, I recommend starting with the **Broad Institute** tutorials (free tutorials and training materials), **Coursera** courses in statistical genetics and bioinformatics, and reading the classic reference papers (see the references chapter). Read the major GWAS papers and trace their figures step by step as you learned in this book; nothing teaches like dissecting a real paper.

The Arab Genomics Gap

Here is the heart of my message. More than 90% of participants in large GWAS are of European ancestry. Arab populations — despite their rich genetic diversity, their ancient history, and their unique patterns of consanguineous marriage that make them a scientific treasure — are nearly **absent** from these maps. And we saw in Chapters 4 and 8 that this absence is not mere underrepresentation, but a practical defect: European risk scores and discoveries do not transfer accurately to our patients. The gap is a gap of health justice, not mere curiosity.

My Call to Arab Researchers

The tools are free, the data is increasingly available, and the opportunity is enormous. The Arab researcher today does not need a billion-dollar laboratory to contribute; they need a good computer, mastery of the tools we presented, and samples from their community. Every small Arab genetic study fills part of the gap, and brings us closer to a precise medicine serving our peoples rather than others'. This book, at its core, is an invitation to this field.

What Comes Next?

The field is advancing rapidly. Three horizons deserve attention: **single-cell QTLs**, which reveal exactly which cell type a variant affects; **multiancestry GWAS**, which combines different populations to increase accuracy and justice; and **whole-genome sequencing**, which is gradually replacing arrays, revealing the rare variants they miss. Through these doors — single cell, multiancestry, whole-genome sequencing — statistical genetics will enter its coming decade.

Closing Word

In this book you learned to read a Manhattan plot, to understand Hardy-Weinberg equilibrium and linkage disequilibrium, to compute a risk score, and to interpret a signal from association to function. But more importantly, you have come to see the genome not as an obscure text, but as a message readable through science and patience. And science is a journey without end; this book is but the first of the road.

And God knows best.

Chapter 13: References and Recommended Reading

﴿وَقُلْ رَبِّ زِدْنِي عِلْمًا﴾

"And say: My Lord, increase me in knowledge." — Surah Ta-Ha:
114

Knowledge is a shoreless sea, and this book is a drop of it. What follows is a curated list of essential references, classic papers, databases, and textbooks, organized by topic, so the serious reader can advance beyond what this book could hold.

Essential Textbooks

- Balding D., Bishop M., Cannings C. (eds). *Handbook of Statistical Genetics*. Wiley. — an encyclopedic reference for the field.

- Ziegler A., König I.R. *A Statistical Approach to Genetic Epidemiology*. Wiley. — a balanced introduction bridging theory and application.
- Laird N.M., Lange C. *The Fundamentals of Modern Statistical Genetics*. Springer. — suitable for the intermediate level.
- Hartl D.L., Clark A.G. *Principles of Population Genetics*. Sinauer. — the classic reference in population genetics.

Foundational Papers and Reviews

- Visscher P.M. et al. (2017). "10 Years of GWAS Discovery: Biology, Function, and Translation." *American Journal of Human Genetics*. — an indispensable review of a decade of GWAS discovery.
- Bush W.S., Moore J.H. (2012). "Chapter 11: Genome-Wide Association Studies." *PLoS Computational Biology*. — an excellent tutorial introduction for beginners.
- Pritchard J.K., Stephens M., Donnelly P. (2000). Foundational work on population structure and inference.

- Price A.L. et al. (2006). "Principal components analysis corrects for stratification in genome-wide association studies." *Nature Genetics*. — the paper that established PCA in GWAS.
- Yang J. et al. (2010). "Common SNPs explain a large proportion of the heritability for human height." *Nature Genetics*. — the origin of the SNP-heritability concept.

Fine-Mapping and Functional Interpretation

- Wang G., Sarkar A., Carbonetto P., Stephens M. (2020). "SuSiE: A simple new approach to variable selection in fine-mapping." *Journal of the Royal Statistical Society B*.
- Benner C. et al. (2016). "FINEMAP: efficient variable selection." *Bioinformatics*.
- Giambartolomei C. et al. (2014). "Bayesian test for colocalisation (coloc)." *PLoS Genetics*.
- GTEx Consortium (2020). "The GTEx atlas of genetic regulatory effects across human tissues." *Science*.

Polygenic Risk Scores

- Choi S.W., Mak T.S.H., O'Reilly P.F. (2020). "Tutorial: a guide to performing polygenic risk score analyses." *Nature Protocols*. — a practical step-by-step guide.
- Martin A.R. et al. (2019). "Clinical use of current polygenic risk scores may exacerbate health disparities." *Nature Genetics*. — an essential reference on the diversity problem.

Kidney Disease and Genomics (the Author's Field)

- Köttgen A. et al., and the **CKDGen Consortium** — a series of GWAS studies of kidney function and estimated glomerular filtration rate (eGFR), which established loci such as **UMOD** and **SHROOM3**.
- Genovese G. et al. (2010). "Association of trypanolytic ApoL1 variants with kidney disease." *Science*. — the

discovery of **APOL1** variants associated with kidney disease, and their importance for African ancestry.

- Wuttke M. et al. (2019). "A catalog of genetic loci associated with kidney function." *Nature Genetics*. — one of the largest kidney GWAS analyses.

Databases and Tools (Reference Links)

- **GWAS Catalog** — www.ebi.ac.uk/gwas
- **GTEx Portal** — www.gtexportal.org
- **gnomAD** — gnomad.broadinstitute.org
- **UK Biobank** — www.ukbiobank.ac.uk
- **PLINK** — www.cog-genomics.org/plink
- **1000 Genomes Project** — www.internationalgenome.org

Open Learning Resources

- **Broad Institute** tutorials in statistical genetics and bioinformatics.

- **Coursera** and **edX** courses in genomics and statistical genetics.
- The official documentation of **PLINK**, **SAIGE**, and **REGENIE** — full of applied examples.

***Methodological note:** The illustrative numbers given in this book's examples (HWE failure rates, heritability estimates for kidney decline, effect sizes in risk scores) were presented for educational purposes and are representative of what is encountered in real research, not citations from specific datasets. For exact figures, please refer to the published studies cited above, especially the **CKDGen** series for kidney research.*

And say: My Lord, increase me in knowledge.

عن الكتاب

دليل شامل لعلم الوراثة الإحصائية مكتوب بأسلوب يجمع بين الدقة العلمية وسهولة الفهم من مفاهيم SNP وتوازن هاردي-واينبرغ إلى GWAS ومخططات مانهاتن ودرجات الخطر متعدد الجينات وتفسير النتائج. يستند المؤلف إلى تجربته الحية في أبحاث الجينوم وأمراض الكلى في جامعة ميشيغان.

عن المؤلف

الدكتور فضل محمد الأكوع باحث في البيولوجيا الحاسوبية والمعلوماتية الحيوية والجينومات المكانية بجامعة ميشيغان في آن آربر. تتمحور أبحاثه حول تطبيق الذكاء الاصطناعي في دراسة الأمراض المزمنة، ومن أبرز أعماله المنشورة دراسات على مثبطات ناقل الصوديوم-غلوكوز 2 (SGLT2) والتغيرات الأنوية الكلوية المنشورة في مجلة JCI عام 2023. إلى جانب مسيرته العلمية، يكتب د. فضل باللغتين العربية والإنجليزية في حقول متعددة تشمل الدراسات القرآنية، تاريخ اليمن والسياسة، الذكاء الاصطناعي والتقنية، الأسرة والتربية، ودليل المهاجرين في المهجر.

مؤلفات المؤلف الأخرى

أدوات الذكاء الاصطناعي لعامل المعرفة العربي (2026)

ميتابولون-إل إل إم: عمارة وتحقيق من واجهة وكالة لتحليل الأيض (2026)

ثروة حلال (2026)

التأمين في الإسلام (2026)

الإفلاس في أمريكا (2026)

الوصية في أمريكا (2026)

قتل الشاهد (2026)

ديمقراطية للبيع (2026)

الحقيقة عن الشيعة (2026)

تحديات يوتيوب (2026)

من أنا؟ (2026)

المسلم في مجتمع غير مسلم (2026)

تحدث كالناطقين (2026)

فجوة الأجيال (2026)

الموت في أمريكا (2026)

وحدة المهاجر (2026)

الطلاق في أمريكا والإسلام (2026)

مسلم في الغرب (2026)

بيت بلا ربا (2026)

الأفلام الهادفة (2026)

الأكل الذي يقتلنا ببطء (2026)

المواريث في الإسلام والقانون (2026)

رحلة الدواء (2026)

حزمة التقنية الصحية (2026)

البرمجة بالذكاء الاصطناعي: Claude Code من الصفر إلى الإنتاج (2026)

جوجل ديب مايند (2026)

أسباب التقارب الإماراتي الإسرائيلي (2026)

خوارزميات التعلم الآلي (2026)

من آلة الكاش إلى نظام البيع الذكي (2026)

كل ما تحتاجه هو الانتباه (2026)

قراءة شرائح الكلى المرضية دليل عملي لتفسير صبغة H&E (2026)

الدليل العملي لمهنة ميكانيكي السيارات في أمريكا (2026)

أفضل المدن للعيش في الولايات المتحدة الأمريكية (2026)

عالم القهوة رحلة من المزرعة إلى الفنجان (2026)

دليل الاستثمار في سوق الأسهم التاريخ والمستقبل وأسرار الثروة (2026)

المثلية الجنسية قراءة في التاريخ والمجج والأديان (2026)

بايثون للذكاء الاصطناعي: من الصفر إلى البناء (2026)

معالجة اللغة العربية مع نماذج الذكاء الاصطناعي: العمل بلغتك الأم (2026)

البناء مع كلود – دليل عملي لمواجهة برمجة Anthropic (2026)

بناء معرض أعمالك في مجال الذكاء الاصطناعي: 30 مشروعاً حقيقياً (2026)

هندسة الأوامر – فن التحوار مع الذكاء الاصطناعي (2026)

الذكاء الاصطناعي لصنّاع المحتوى - دليل التصميم والصوت والفيديو (2026)

الأتمة بدون كود - دليل بناء سير عمل ذكي (2026)

العملاء الأذكياء وپروتوكول MCP - بناء أنظمة ذكاء اصطناعي مستقلة (2026)

التوليد المعزز بالاسترجاع - دليل عملي لبناء أنظمة RAG (2026)

العمل الحر بالذكاء الاصطناعي – دليل المستقل اليمني والعربي (2026)

نوت بوك إل إم – الدليل الشامل (2026)

القانون الجميل الكبير - تشريح إصلاح ترامب الضريبي وتأثيره على أمريكا (2026)

التقارب السني الشيعي (2026)

الذكاء الاصطناعي ومستقبل المهن - أيها يندثر وأيها يصعد (2026)

التأثيرات الاستثمارية في أمريكا - دليل المقارنة والاختيار (2026)

اليمين في ملفات إبستين (2026)

الرئيس إبراهيم الحمدي - حياته ومشروعه الوطني (2026)

الشخصيات العامة التي فقدت وظائفها بسبب موقفها من غزة (2026)

الصوفية - دراسة شاملة (2026)

الطعام والصحة بين العلم الحديث والحديث النبوي (2026)

النظام الضريبي الأمريكي - دليل شامل (2026)

دليل شراء اللحم الحلال في ميشيجان وإنديانا (2026)

سلسلة التوريد - دليل شامل (2026)

ميكانيك الكم – دراسة شاملة (2026)

أدوات الذكاء الاصطناعي – دليل شامل (2026)

Mythos في مواجهة نماذج Anthropic (2026)

مهارات كلود – كيف يجعلك استخدامها خبيراً في كل شيء (2026)

البوذية والهندوسية – النشأة والانتشار والمقارنة (2026)

الذنوب والمعاصي والأخلاق في الإسلام – مقارنة مع الأديان
الأخرى (2026)

الذكاء الاصطناعي وثورة اكتشاف الأدوية (2026)

حرب غزة – كيف فضحت المجتمع الدولي (2026)

مجازر ضد المسلمين عبر العصور (2026)

العلاقات اليمنية السعودية – تاريخ وتحولات عبر الأزمان (2026)

كيف تؤسس شركتك في أمريكا (2026)

هندسة البيانات – الدليل الشامل (2026)

جماعة الدعوة والتبليغ — دراسة شاملة (2026)

أجيال على المحك — الإسلام في المهجر بين الحفاظ والانسلاخ (2026)

المسلمون في الغرب — الإنجازات والتحديات والاندماج (2026)

الربا في الإسلام والبنوك الإسلامية (2026)

القرآن والإنجيل — دراسة مقارنة في مفاهيم السلام والقتال والتسامح (2026)

نهاية الكون في القرآن الكريم (2026)

مشاكل اليمن عبر الأزمان (2026)

سر التقارب الأمريكي الإسرائيلي — من يقود من؟ (2026)

هل انتهت الوحدة اليمنية؟ (2026)

الرؤساء اليمنيون في مذكرات ويكيليكس (2026)

أسرار قوة التحالف الأمريكي الإسرائيلي (2026)

فن التريية — كيف تصنع قادة من أبنائك (2026)

تأثير النماذج اللغوية الكبيرة على البحث العلمي والتعليم الجامعي (2026)

علامات الساعة (2026)

التخطيط للتقاعد (2026)

العملات الرقمية — دليل شامل للمبتدئين (2026)

وادي السيليكون — تاريخ وابتكار وريادة عالمية (2026)

أشهر المتنزهات الوطنية في أمريكا (2026)

دليل شراء وبيع السيارات المستعملة في أمريكا (2026)

كلود كود — الدليل الشامل (2026)

دليل المهاجر اليمني الجديد إلى أمريكا (2026)

الحقوق الزوجية والحياة الأسرية للمسلمين في الغرب (2026)

مستقبل المعلوماتية الحيوية والبيولوجيا الحاسوبية في عصر الذكاء

الاصطناعي (2026)

تصنيف الآيات في القرآن الكريم — دراسة تأملية في البنية

الموضوعية (2026)

كيف تعمل النماذج اللغوية الكبيرة – دليل مبسّط (2026)

سرقة الجامعات الأمريكية (2026)

عتيقة – حكاية جدتي من جبال اليمن (2026)

الخلافة الإسلامية: من السقيفة إلى سقوط غرناطة (2026)

السلفية – دراسة في المفهوم والنشأة والتيارات المعاصرة (2026)

النقد المشروع وحدود معاداة السامية (2026)

كيف تنجح أكاديمياً في الجامعات الأمريكية (2026)

الزواج الناجح – دليل عملي بمنظور إسلامي (2026)

الإعجاز العلمي في القرآن – من منظور باحث في الجينومات (2026)

أمريكا – صعود القوة وبوادر الأفول (2026)

About this Book

A comprehensive guide to statistical genetics written with scientific rigor and accessible clarity from SNPs and Hardy-Weinberg equilibrium to GWAS, Manhattan plots, polygenic risk scores, and functional interpretation. Grounded in the author's hands-on research experience in genomics and kidney disease at the University of Michigan.

About the Author

Dr. Fadhl Mohammed Alakwaa is a researcher in computational biology, bioinformatics, and spatial genomics at the University of Michigan in Ann Arbor. His research focuses on applying AI to the study of chronic diseases; among his notable publications are studies on SGLT2 inhibitors and kidney tubular changes published in JCI in 2023. Alongside his scientific career, Dr. Alakwaa writes in both Arabic and English across fields including Quranic studies, Yemeni history and politics, AI and technology, family and parenting, and guides for diaspora life.